

Wykład Specjalizujący

Motywacje, sylabus, przygotowanie i transformacja danych

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

23 lutego 2026



Πάντα ρεῖ

„Wszystko płynie”

Heraklit z Efezu

(ok. 535 r. p.n.e. – ok. 475 r. p.n.e.)

„Niepodobna
wstąpić
do tej samej rzeki.”

ARYSTOTELES: ISTOTA (OUSIA) W RZECZY



MATERIA
(HYLE)

ZMIENNE
PRZYPADŁOŚCI

STAŁA
ISTOTA

Arystoteles i logika prognozowania zmian bytu


Wprowadzenie koncepcji **stałej istoty** oraz rozróżnienia **aktu i potencji** sprawiło, że zmiana przestała być pojmowana jako czysty przepływ, a została zrozumiana jako *aktualizacja możliwości wpisanych w naturę bytu*.

Rozwinięcie **logiki** dostarczyło formalnych narzędzi do systematycznego wnioskowania o przyszłych stanach rzeczy na podstawie ich natury i przyczyn.

To stworzyło ontologiczne podstawy przewidywania w nauce klasycznej — fundament przekonania, że świat posiada strukturę umożliwiającą budowę modeli wyjaśniających i predykcyjnych (w tym prognozowania zmian).

Arystoteles

384 p.n.e. – 322 p.n.e.



Arystoteles

Popiersie — Muzea Kapitołińskie, Rzym

ARYSTOTELES: Istota + Logika ~ Deszcz



MATERIA
(HYLE)

STAŁA
ISTOTA

Prognozowanie anomalii w szeregach czasowych

Ekonomia, Geofizyka i Astrofizyka

- **Krachy rynkowe:** Nagłe załamania cen aktywów (risk contagion).
- **Kryzysy walutowe:** Gwałtowne deprecjacje kursów (systemic stress).
- **Trzęsienia ziemi:** Rzadkie zdarzenia ekstremalne (prognozowanie prekursorów).
- **Wybuchy wulkanów:** Nagłe przejścia do stanu erupcji (critical transition).
- **Ekstremalne zjawiska pogodowe:** Huragany, powodzie, fale upałów.
- **Pogoda kosmiczna:** Wzrosty promieniowania słonecznego (zagrożenie infrastruktury).
- **Załamania produkcji i/lub gospodarki:** Gwałtowne spadki aktywności gospodarczej.
- **Przyspieszone topnienie lodowców:** Zmiana uwarunkowań klimatycznych.

Medycyna i Systemy Techniczne

- **Nagłe arytmie:** Krytyczne epizody w sygnałach EKG.
- **Ogniska epidemiczne:** Gwałtowne wzrosty liczby zakażeń.
- **Awaria maszyn:** Nieliniowe zmiany w sygnale drgań (fault onset).
- **Ataki cybernetyczne:** Nietypowe wzorce ruchu sieciowego (DDoS).
- **Blackouty energetyczne:** Przeciążenia prowadzące do cascade failure.
- **Zmiana reżimu systemu:** Przejście do nowego stanu dynamicznego.
- **Nagłe spadki saturacji:** Krytyczne epizody niedotlenienia pacjenta.
- **Błędy sensoryczne w systemach autonomicznych:** Nagła utrata

Co łączy zjawiska w ekonomii, geofizyce, astrofizyce, medycynie i systemach technicznych?

Wspólna struktura matematyczna

- Każde zjawisko można modelować jako **wielowymiarowy szereg czasowy**

$$X_t = (X_t^{(1)}, \dots, X_t^{(d)}) \in \mathbb{R}^d$$

- Zmienne są **wzajemnie sprzężone** (korelacje, zależności nieliniowe).
- System może przechodzić przez **zmiany reżimu** (regime shifts).
- Kluczowe są **rzadkie zdarzenia ekstremalne** (heavy tails).
- Prognozowanie wymaga analizy **całej struktury wektorowej**, nie pojedynczej zmiennej.

Dane jako wektory w $\mathbb{R}^n$

Trzy perspektywy na dane

(1) Szereg w czasie:

r_t jako skalar dla każdego t

(2) Wektor obserwacji:

$$\mathbf{r} = (r_1, r_2, \dots, r_T)^T \in \mathbb{R}^T$$


Cały szereg = jeden punkt w przestrzeni

(3) Macierz obserwacji (n szeregów):

$$X = \begin{pmatrix} r_{1,1} & r_{2,1} & \cdots & r_{n,1} \\ r_{1,2} & r_{2,2} & \cdots & r_{n,2} \\ \vdots & & \ddots & \vdots \\ r_{1,T} & r_{2,T} & \cdots & r_{n,T} \end{pmatrix} \in \mathbb{R}^{T \times n}$$

Wiersz = obserwacja w chwili t

Kolumna = jeden szereg czasowy



Przesunięcie perspektywy

Dane to nie "tabelka liczb" – to **chmura punktów** w przestrzeni $\mathbb{R}^n$.

Przyszłość prognozowania: od klasyki do AI

Fundamenty nagradzane najwyższymi wyróżnieniami naukowymi

- **Harry Markowitz** – Nagroda Nobla (1990) Teoria portfela i optymalizacja ryzyka.
- **Robert Engle** – Nagroda Nobla (2003) Modele ARCH/GARCH i dynamika zmienności.
- **Clive Granger** – Nagroda Nobla (2003) Kointegracja i relacje długookresowe.
- **Eugene Fama** – Nagroda Nobla (2013) Empiryczna analiza rynków kapitałowych.

Nowa warstwa:

- Deep learning (LSTM, Transformers) dla danych (w tym szeregów czasowych) wielowymiarowych.
- Representation learning i modele latent state.
- LLM/RAG do analizy informacji tekstowych i kontekstowych.
- Neuro-symbolic computing.
- Logiki nieklasyczne, fuzzy, rough, IGrC.

Przyszłość = hybrydowe systemy łączące interpretowalność klasyki z elastycznością AI.

Dwie intuicje wprowadzające

Intuicja finansowa

Cena Apple 5 lat temu = X . Dziś = Y .

Relacja Y/X to zwrot; **log-zwrot** to $\log(Y/X)$.
Ale...

- Ten sam zwrot możesz osiągnąć przy **bardzo różnym ryzyku**.
- Rok 2020 i rok 2016 mogły dać podobne zwroty, ale dramatycznie różną zmienność.

Pytanie: Jak niebezpieczna była ta inwestycja?

Intuicja meteorologiczna

Prognoza na jutro: **12 °C**

To jest prognoza *poziomu*. Ale...

- Czy to będzie stabilne 12 °C?
- Czy wahania od 4 °C do 20 °C?

Prognoza zmienności odpowiada na pytanie o *szerokość koperty niepewności*, nie o jej środek.

Kluczowe rozróżnienie

Termometr mierzy poziom $\longleftrightarrow$ **Barometr ryzyka** mierzy zmienność


Dlaczego zmienność jest matematycznie interesująca?

Cztery cechy zmienności

- **Dynamiczna** – zmienia się w czasie, nie jest stała
- **Grupująca się** – *volatility clustering*: po burzliwym dniu przychodzi burzliwy dzień
- **Warunkowa** – zależy od przeszłości ($\mathcal{F}_{t-1}$)
- **Modelowalna** – parametrycznie przez ARCH/GARCH

Obserwacja empiryczna

Na danych S&P 500 widoczne są **skupiska** dużych wahań: kryzysy 2008, 2020. Spokojne okresy przeplatają się z burzliwymi. To właśnie *volatility clustering*.



Definicja kotwica: czym jest zmienność?

Zmienność empiryczna (bezwarunkowa)

Dla okna T obserwacji:

$$\hat{\sigma} = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2}$$

Jest **stała** – jeden numer dla całego okna.

Rolling volatility: przesuwamy okno w czasie $\rightarrow$ otrzymujemy szereg $\hat{\sigma}_t$.

Zmienność warunkowa (dynamiczna)

$$\sigma_t^2 = \text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1})$$

$\mathcal{F}_{t-1}$ = wszystko, co wiemy do chwili $t-1$.

Jest **dynamiczna** – zmienia się co krok.
Właśnie **tę** wartość prognozuje GARCH.

Kluczowe rozróżnienie

Bezwarunkowa

jedna liczba

statyczna

opisuje historię

Warunkowa

szereg σ_t

dynamiczna

prognozuje przyszłość

Intuicja

Bezwarunkowa: “W ciągu roku rynek ruszał się o $\pm 1\%$ dziennie.”

Warunkowa: “*Jutro* rynek może ruszyć się o $\pm 3\%$, bo dziś był wstrząs.”

Cel kursu formalnie

Zbudować model dla $\hat{\sigma}_t$ – warunkowego odchylenia standardowego.

Od zmienności do paska ryzyka

Krok 1: Prognoza średniej

$$\hat{\mu}_{t+1}$$

Model ARMA daje prognozę poziomu (środką rozkładu).

Krok 2: Prognoza zmienności

$$\hat{\sigma}_{t+1}$$


Model GARCH daje prognozę warunkowego odchylenia standardowego.

Krok 3: Pasek ryzyka

Dynamiczny przedział:

$$\hat{\mu}_{t+1} \pm k \hat{\sigma}_{t+1}$$

- $k = 1$ – ok. 68% (przy normalności),
- $k = 1,96$ – ok. 95%,
- k zależy od przyjętego poziomu ufności.



Interpretacja

Pasek ryzyka wizualizuje szerokość niepewności. Gdy $\hat{\sigma}_t$ rośnie, pasek „puchnie”.

Kluczowa myśl

Nie prognozujemy jednej liczby. Prognozujemy **szerokość dopuszczalnych scenariuszy**.

Teza numer jeden kursu

**Modelujemy zmienność,
nie sterujemy szeregiem czasowym.**

Czego NIE robimy

- Nie przewidujemy, czy jutro rynek wzrośnie czy spadnie
- Nie sterujemy pogodą ani cenami
- Nie prowadzimy analizy fundamentalnej

Co ROBIMY

- Prognozujemy **pasek** - szerokość przedziałów możliwych wyników
- Modelujemy dynamikę σ_t – warunkowego odchylenia
- Oceniamy i kwantyfikujemy **ryzyko**

Różnica operacyjna

Prognoza poziomu: $\hat{y}_{t+1} = 12,3^\circ\text{C}$

Prognoza zmienności: $\hat{\sigma}_{t+1} = \pm 2,1^\circ\text{C}$

Co zademonstrujemy na tym wykładzie?

Główny cel

Zademonstrujemy **ogromną siłę praktyczną** głębokich twierdzeń z matematyki i statystyki – teoria żyje w rzeczywistych problemach.

Gwiazdą wykładu jest...

Twierdzenie Spektralne – jedno z filarów algebry liniowej, które okazuje się niezbędnym narzędziem w analizie danych.

Liczne zastosowania, które poznamy

- **Analiza Składowych Głównych (PCA)** – redukcja wymiaru, wizualizacja danych, kompresja informacji
- Dekompozycja spektralna macierzy kowariancji
- Optymalizacja kwadratowa i diagonalizacja form
- Zastosowania w uczeniu maszynowym i statystyce wielowymiarowej

„Każde wielkie twierdzenie jest bezużyteczne – dopóki go nie zastosujesz.”

Przykładowe zastosowania Twierdzenia Spektralnego

AI & Machine Learning

- **PCA** — redukcja wymiarowości; wektory własne macierzy kowariancji = kierunki max wariancji.
- **SVD** — rekomendacje, kompresja ($A = U\Sigma V^T$); kolumny U , V to wektory własne AA^T , $A^T A$.
- **Spectral Clustering** — segmentacja danych przez wektory własne Laplacjanu grafu.
- **Kernel PCA** — nieliniowa redukcja wymiarowości w przestrzeni cech.
- **Graph Neural Networks** — spektralne filtry sygnałów (konwolucja w dziedzinie Laplacjanu).
- **Zbieżność GD** — warunkowanie Hessiana $\kappa = \lambda_{\max}/\lambda_{\min}$ determinuje szybkość Gradient Descent.


Fizyka & Inżynieria

- **Mechanika kwantowa** — obserwable jako operatory hermitowskie; λ_i = możliwe wyniki pomiaru.
- **Analiza modalna** — częstotliwości drgań własnych konstrukcji (mosty, budynki, samoloty).
- **Równania różniczkowe** —
 $\dot{x} = Ax \Rightarrow x(t) = Qe^{\Lambda t}Q^T x_0$.
- **Teoria obwodów** — sieci RLC przez wartości własne macierzy admitancji.

Matematyka & Statystyka

- **Funkcje macierzowe** — $f(A) = Qf(\Lambda)Q^T$, np. e^A , $\sqrt{A}$, $\log A$.
- **Kowariancja** — test Mahalanobisa, elipsoidy ufności.
- **MES** — metody spektralne w równaniach różniczkowych cząstkowych.

Rozdział 17 pt. "AlgoTradix" jest uzupełniający do wykładu



O kursie

Czym jest ten kurs?

Wprowadzenie do **modelowania i prognozowania zmienności** szeregów czasowych dynamicznych – od strony:

- matematycznej i statystycznej,
- nowoczesnych metod uczenia maszynowego.

Na jakich danych pracujemy?

Studenci pracują na **rzeczywistych danych**:

- anomalie pogodowe (temperatura Olsztyn),
- wielowymiarowe szeregi czasowe rynków finansowych (S&P 500 i inne).

Teoria jest osadzona w **praktycznym kontekście analitycznym i decyzyjnym**.

Cel kursu

Wyposażenie studentów w spójne narzędzia do:

- 1 **budowania** modeli zmienności,
- 2 **szacowania** ich parametrów,
- 3 **oceny** ich jakości,
- 4 **prognozowania ryzyka anomalii** na ich podstawie.

Słowo kluczowe

Nie prognozujemy *poziomu*.
Prognozujemy **zmienność**.

Cele nauczania

Po ukończeniu kursu student:

Fundamenty

- Rozumie matematyczne i probabilistyczne podstawy modelowania zmienności – wariancję warunkową, estymację MLE oraz strukturę szeregów AR i ARMA.
- Identyfikuje i obsługuje **sezonowość** w danych (cykl deterministyczny i stochastyczny) przed budową modelu zmienności.
- Buduje i dopasowuje modele klasy **ARCH/GARCH(1,1)** do rzeczywistych szeregów czasowych.
- Prognozuje zmienność i interpretuje wyniki w kategoriach **ryzyka**.

Zastosowania

- Oblicza i interpretuje miary ryzyka: **VaR**, **ES** oraz **MDD**.
- Stosuje **walk-forward validation** jako metodę dynamicznej oceny stabilności modelu.
- Łączy prognozę zmienności z **optymalizacją portfelową** w ujęciu Markowitza z ograniczeniami na ryzyko.
- Interpretuje ryzyko ścieżkowe przez pryzmat **hitting time** i **recovery time**.

Program kursu: VIII bloków i 46 Części Tematycznych (CT)

Bloki I–V

- 1 **Przygotowanie i transformacja danych.** Log-zwroty, wstępne przetwarzanie, anomalie temperatur i cen.
- 2 **Matematyczne fundamenty.** Wektory, macierze, wartości własne, Σ , forma kwadratowa $\mathbf{w}^T \Sigma \mathbf{w}$, SVD i PCA.
- 3 **Podstawy probabilistyczne i estymacja.** Zmienna losowa, wariancja, kowariancja, MLE.
- 4 **Modele średniej i sezonowość.** AR(1), ARMA, zmienne dummy, Fourier, STL, SARIMA.
- 5 **Modelowanie zmienności warunkowej.** Wariancja warunkowa, ARCH, GARCH(1,1), sezonowa heteroskedastyczność.

Bloki VI–VIII

- 6 **Prognozowanie zmienności.** Wielokrokowe prognozy, walk-forward validation.
- 7 **Miary ryzyka.** VaR – interpretacja i wyznaczanie. Expected Shortfall (ES). Maximum Drawdown (MDD).
- 8 **Optymalizacja portfelowa.** Portfel Markowitza, mnożniki Lagrange'a, optymalizacja z ograniczeniem na VaR.
- 9 **Ryzyko ścieżkowe.** Hitting time i recovery time – stabilność szeregu w kategoriach czasowych.

Sylabus – trzy poziomy realizacji

Minimum (ocena 3.0)

Rdzeń kursu (szkic):

- Transformacja danych
- Wektory, macierze, wartości własne
- Zmienna losowa, wariancja
- MLE i estymacja
- AR(1) i ARMA
- ARCH i GARCH(1,1)
- VaR i MDD
- Walk-forward

Rozszerzony (4.0–5.0)

Dodatkowo (szkic):

- SVD i PCA
- Mnożniki Lagrange'a
- Portfel Markowitza
- Opt. z ograniczeniem VaR
- Expected Shortfall (ES)
- Hitting time i recovery time

Student łączy prognozę zmienności z decyzją optymalizacyjną.

Moduły opcjonalne (5+)

Zaawansowane (szkic) - o ile zdążymy?:


- MAP jako rozszerzenie MLE
- Bayes i posterior
- Posterior predictive
- MCMC
- Conformal Prediction

Formalna analiza kalibracji i gwarancje pokrycia.

Filozofia dydaktyczna

Jeden pipeline przez cały kurs · Teoria wyjaśniana na danych · Tempo dostosowane do grupy

Architektura kursu – jeden pipeline



Zasada niezmiennicza

W części wykładowej używamy konsekwentnie S&P 500 i temperatury. W projekcie każdy pracuje na własnych danych. **Pipeline jest ten sam** – zmienia się tylko **narzędzie** realizujące każdy etap.

Dwie domeny – jeden model matematyczny

S&P 500 – finanse

- Ceny zamknięcia indeksu
- Dane dzienne, źródło: Yahoo Finance
- Zakres: min. 10 lat wstecz
- Zmienna: **log-zwroty** r_t

\$ yfinance: ^GSPC

Temperatura Olsztyn – meteorologia

- Dienne temperatury (śr. lub maks.)
- Źródło: IMGW, dane publiczne
- Zakres: 1951–2023
- Zmienna: **anomalie** a_t

Dlaczego DWIE domeny?

- Ten sam model GARCH, ta sama MLE, to samo VaR – działają identycznie na obu zbiorach
- Demistyfikacja “finanse” jako czegoś wyjątkowego
- **Matematyka jest neutralna** wobec interpretacji dziedzinowej
- Wzmacnia ogólność myślenia o zmienności

Jeden model matematyczny



Dwa zbiory danych

Zastrzeżenia

Do kogo adresowany jest kurs?

Kurs adresowany jest do studentów zainteresowanych **ilościową analizą danych**, a zwłaszcza:

- szeregami czasowymi,
- zarządzaniem ryzykiem,
- finansami obliczeniowymi.

Wymagania wstępne

Zakładana jest podstawowa znajomość:

- algebry liniowej,
- analizy matematycznej,
- rachunku prawdopodobieństwa i statystyki.

Planujemy przypomnieć intuicję pojęć niezbędnych dla kursu.

Czym kurs NIE jest

Kurs ma charakter **edukacyjny i analityczny**.

Nie stanowi:

- szkolenia z zakresu praktycznego handlu instrumentami finansowymi,
- doradztwa inwestycyjnego.

Elastyczność tempa

Tempo realizacji kursu będzie **dostosowywane** do poziomu grupy oraz dynamiki przyswajania materiału.

Zadanie 1: Źródło danych – (każdy student ma różne dane!!!) wymaganie

Ważne: skąd pobrać dane?

Dane muszą pochodzić z jednego z dwóch źródeł:

- **Stacje pogodowe** – co najmniej 4 zmienne meteorologiczne (np. temperatura, ciśnienie, wilgotność, opady, prędkość wiatru)
- **Notowania giełdowe** – co najmniej 4 szeregi czasowe (np. ceny zamknięcia akcji jednego sektora, indeksy, kursy walut)

Dane pogodowe – przykłady źródeł

- IMGW-PIB: danepubliczne.imgw.pl
- NOAA Climate Data: ncdc.noaa.gov
- Meteostat API: meteostat.net

Dane giełdowe – przykłady źródeł

- Stooq: stooq.pl
- Yahoo Finance: finance.yahoo.com
- GPW: gpw.pl

Zadanie 1: Minimalne wymagania dotyczące danych

Struktura danych

- Co najmniej **4 szeregi czasowe** (zmienne) – rekomendowane 4–5
- Zmienne powinny być **tematycznie powiązane** (np. dane z jednego regionu / jednego sektora giełdowego)
- Wystarczająca liczba obserwacji – minimum **kilkadziesiąt** rekordów
- Dane **bez braków** lub z brakami uzupełnionymi / usuniętymi

Uwaga o skalach

Jeśli zmienne mają **różne jednostki lub rzędy wielkości** (np. temperatura w °C i ciśnienie w hPa), należy dokonać **standaryzacji** lub użyć **macierzy korelacji** zamiast kowariancji.

Zadanie 1: Krok 1 – Macierz obserwacji $\mathbf{X}$

Definicja

Utwórz macierz $\mathbf{X} \in \mathbb{R}^{n \times p}$, gdzie:

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

- n – liczba obserwacji (wiersze = chwile czasowe)
- $p \geq 4$ – liczba zmiennych (kolumny = szeregi)

Centrowanie

Przed PCA wycentruj każdą zmienną: $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}\bar{\mathbf{x}}^\top$

Zadanie 1: Krok 2 – Macierz kowariancji

Estymator próbkowy

$$\hat{\Sigma} = \frac{1}{n-1} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} \in \mathbb{R}^{p \times p}$$

- Macierz **symetryczna** i **dodatnio półokreślona**
- Diagonała: **wariancje** zmiennych
- Poza diagonalą: **kowariancje** par zmiennych

Alternatywa

Przy różnych skalach zmiennych użyj macierzy **korelacji**:

$$R_{ij} = \frac{\hat{\Sigma}_{ij}}{\sqrt{\hat{\Sigma}_{ii} \hat{\Sigma}_{jj}}}$$

Zadanie 1: Krok 3 – Analiza Głównych Składowych (PCA)

Rozkład spektralny

Wyznacz wartości i wektory własne z równania:

$$\hat{\Sigma} \mathbf{v}_k = \lambda_k \mathbf{v}_k, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

- $\mathbf{v}_k$ – k -ty **kierunek główny** (loading vector)
- λ_k – **wariancja** wyjaśniona przez PC k
- Nowe współrzędne (scores): $\mathbf{z}_k = \tilde{\mathbf{X}} \mathbf{v}_k$

Odsetek wyjaśnionej wariancji

$$\text{Var}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j} \times 100\%$$


Zadanie 1: Wykres osypiska (Scree Plot)

Co przedstawia?

- Oś X : numer składowej głównej
- Oś Y : wartość własna λ_k
- Szukamy „łokcia” – punktu, w którym krzywa się wypłaszcza
- Składowe **przed** łokciem: sygnał
- Składowe **po** łokciu: szum / osypisko

Dodaj do wykresu


Linie kumulatywnego odsetka wyjaśnionej wariancji
(prawa oś Y lub osobny panel)



Zadanie 1: Wykres 2D PCA (biplot)

Co przedstawia?

- Rzut obserwacji na płaszczyznę $\mathbf{PC1} \times \mathbf{PC2}$
- Punkty = obserwacje w nowej przestrzeni
- **Biplot**: strzałki ładunków (loadings) pokazujące wkład oryginalnych zmiennych
- Opcjonalnie: koloruj punkty wg kategorii (sezon, rok, spółka, ...)



Wskazówka

Długość strzałki $\propto$ istotność zmiennej;
kąt między strzałkami $\approx$ korelacja zmiennych

Zadanie 1: Interpretacja – pytania obowiązkowe

1. Ile składowych wyjaśniłoby 90% wariancji?

Wyznacz minimalne k^* takie, że:

$$\frac{\sum_{j=1}^{k^*} \lambda_j}{\sum_{j=1}^p \lambda_j} \geq 0,90$$

Czy ta liczba jest zaskakująca? Co mówi o strukturze danych?

2. Czy PC1 ma interpretację czynnika wspólnego?

Sprawdź ładunki (loadings) PC1. Jeśli wszystkie zmienne mają **podobny znak i zbliżoną wartość**, PC1 może reprezentować wspólny trend – np. ogólny poziom rynku lub średnią temperaturę regionu.

3. Jak interpretować dominujące kierunki zmienności?

Które oryginalne zmienne **najbardziej** kształtują PC1 i PC2? Nadaj im **ekonomiczną lub fizyczną interpretację**.

Zadanie 1: Co należy oddać?

Wymagane wykresy

- 1 **Wykres osypiska** (scree plot)
z zaznaczonym „łokciem” i krzywą kumulatywnej wariancji
- 2 **Wykres 2D PCA** ($PC1 \times PC2$)
punkty obserwacji, opcjonalnie biplot z ładunkami

Interpretacja geometryczna (ok. 1 strona)


Powinna zawierać:

- Opis danych i źródło
- Odpowiedzi na **3 pytania** interpretacyjne
- Komentarz do wykresów
- Wnioski: co PCA ujawniło w danych?

Kryterium oceny

Liczy się **jakość interpretacji**,
nie tylko poprawność obliczeń.

Zadanie 1: Podsumowanie – mapa drogowa



Zadanie 2: Krok 0 – Sprawdzenie stacjonarności

Warunek wstępny – nie pomijaj tego kroku!

Model ARMA jest poprawnie zdefiniowany **tylko dla procesów stacjonarnych**. Przed dopasowaniem modelu należy zweryfikować stacjonarność szeregu.

Testy stacjonarności

- **Test ADF** (Augmented Dickey–Fuller)
 H_0 : szereg ma pierwiastek jednostkowy
- **Test KPSS**
 H_0 : szereg jest stacjonarny
- Oba testy razem dają mocniejszą diagnozę

Co zrobić przy niestacjonarności?

- Różnicowanie rzędu d : $\nabla^d X_t$
- Transformacja logarytmiczna przy trendzie wariancji
- Przejście do modelu **ARIMA**(p, d, q)

Zadanie 2: Obowiązkowa diagnostyka sezonowości – pytanie 1

Pytanie 1

„Czy moje dane wykazują sezonowość? Jak to sprawdziłem?”

Wymagany **co najmniej jeden** z poniższych instrumentów:

Wykres ACF

Istotne skoki przy opóźnieniach $s, 2s, 3s, \dots$ sugerują sezonowość okresu s

Wykres sezonowy

Nakładanie przebiegów z kolejnych sezonów (seasonal plot) – wzrokowe wykrycie wzorca

Test statystyczny

Test Friedmana lub periodogram (test Fishera) na obecność składowej sezonowej

Odpowiedź powinna zawierać

Wskazanie okresu s (np. $s = 12$ dla danych miesięcznych) oraz **uzasadnienie oparte na wyniku** wybranego instrumentu, a nie tylko stwierdzenie faktu.

Zadanie 2: Obowiązkowa diagnostyka sezonowości – pytanie 2

Pytanie 2

„Jakie podejście wybrałem do obsługi sezonowości i dlaczego?”

Opcja A – Dekompozycja (np. STL)

- Rozdziel szereg na trend, sezonowość i resztę
- Modeluj składową resztkową modelem ARMA
- Zaleta: elastyczna, odporna na outliery
- Wada: nie modeluje interakcji sezon–trend

Opcja B – SARIMA(p, d, q)(P, D, Q)[s]

- Rozszerzenie ARIMA o człony sezonowe
- Modeluje sezonowość bezpośrednio w strukturze modelu
- Zaleta: spójna estymacja parametrów
- Wada: większa liczba parametrów

Uwaga

Jeśli dane wykazują sezonowość, dopuszczalne jest wyjście poza ARMA(p, q) z $p, q \in \{0, 1, 2\}$ i zastosowanie modelu SARIMA. **Wybór musi być uzasadniony pisemnie.**

Zadanie 2: Obowiązkowa diagnostyka sezonowości – pytanie 3

Pytanie 3


„Czy ACF reszt wykazuje istotne skoki przy opóźnieniach $s, 2s, 3s$? Co z tego wynika?”

- Oblicz ACF reszt $\hat{\varepsilon}_t$ dla opóźnień $h = 1, 2, \dots, 3s$
- Sprawdź, czy $|\hat{\rho}(ks)|$ przekracza pasmo ufności $\pm 1,96/\sqrt{n}$ dla $k = 1, 2, 3$
- Wykonaj **test Ljunga–Boxa** dla opóźnień będących wielokrotnościami s :

$$LB = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}^2(k)}{n-k} \sim \chi^2(m)$$

- **Wniosek:** jeśli test istotny – model nie usunął struktury sezonowej, konieczna rewizja

Pożądany kształt ACF reszt



Zadanie 2: Selekcja modelu – kryteria informacyjne

Przestrzeń modeli

Rozważ wszystkie modele $\text{ARMA}(p, q)$ dla $p, q \in \{0, 1, 2\}$ – łącznie **9 kandydatów**.
Przy wykryciu sezonowości: rozszerz do $\text{SARIMA}(p, d, q)(P, D, Q)[s]$.

Kryterium AIC

$$\text{AIC} = -2\ell(\hat{\theta}) + 2k$$

Penalizuje liczbę parametrów k łagodniej;
preferuje modele lepiej dopasowane

Kryterium BIC

$$\text{BIC} = -2\ell(\hat{\theta}) + k \ln n$$

Silniejsza penalizacja dla dużych n ;
preferuje modele oszczędniejsze

Jak interpretować tabelę AIC/BIC?

Wybierz model z **najniższą wartością** kryterium. Jeśli AIC i BIC wskazują różne modele – preferuj BIC (mniejsze ryzyko przeparametryzowania). Podaj pełną tabelę porównawczą.

Zadanie 2: Estymacja MLE – wymagania

Metoda największej wiarygodności (MLE)

Parametry $\theta = (\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \sigma^2)$ estymuj przez maksymalizację log-wiarygodności:

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta \mid x_1, \dots, x_n)$$

- Sprawdź **zbieżność estymatora**
(komunikat optymalizatora, gradient ≈ 0)
- Podaj **przedziały ufności** dla każdego parametru
- Zweryfikuj **istotność statystyczną** parametrów
(p -wartość lub $|z| > 1,96$)

Uwaga o identyfikowalności

Sprawdź, czy model nie ma **wspólnych pierwiastków** wielomianów AR i MA (nadmierne uproszczenie – model redukuje się do niższego rzędu).

Zadanie 2: Diagnostyka reszt – autokorelacja i efekty ARCH

ACF reszt $\hat{\varepsilon}_t$

Testuje **autokorelację w średniej**

- Wszystkie $\hat{\rho}(h)$ powinny leżeć w paśmie $\pm 1,96/\sqrt{n}$
- Test Ljunga–Boxa dla $m = \lfloor \sqrt{n} \rfloor$
- H_0 : brak autokorelacji reszt
Pożądany wynik: **nie odrzucamy** H_0

ACF kwadratów reszt $\hat{\varepsilon}_t^2$

Testuje **efekty ARCH** (zmiennosc warunkowa)

- Istotne $\hat{\rho}(h)$ przy $\hat{\varepsilon}_t^2$
 $\Rightarrow$ heteroskedastyczność warunkowa
- Sugeruje konieczność modelu **GARCH**(r, s) dla wariancji
- Formalny test: **test ARCH–LM** (Engle, 1982)

Normalność reszt – dodatkowy wymóg

Wykonaj **test Shapiro–Wilka** lub narysuj **wykres Q–Q**. Odchylenie od normalności wpływa na ważność przedziałów ufności i prognoz. Wskaż, czy reszty są leptokurtyczne (grube ogony – typowe dla danych finansowych).

Zadanie 2: Co należy oddać?

Wymagane materiały

- 1 Tabela AIC/BIC dla wszystkich 9 kandydatów
- 2 Wykres ACF reszt $\hat{\varepsilon}_t$
- 3 Wykres ACF kwadratów $\hat{\varepsilon}_t^2$
- 4 Wykres Q-Q reszt (normalność)
- 5 Odpowiedź pisemna na 3 pytania diagnostyczne o sezonowości (ok. 0,5–1 strona)

Interpretacja poprawności modelu


Odpowiedz na każde z pytań:

- Czy reszty są **białym szumem**?
(test Ljunga–Boxa)
- Czy brak **efektów ARCH**?
(ACF($\hat{\varepsilon}_t^2$), test ARCH–LM)
- Czy reszty są **w przybliżeniu normalne**?
(Q–Q, Shapiro–Wilk)
- Czy parametry są **istotne statystycznie**?

Kryterium oceny

Liczy się **jakość uzasadnienia** wyboru modelu i interpretacji diagnostyki.

Zadanie 2: Podsumowanie – mapa drogowa



Zadanie 3: Punkt wyjścia – wyniki z Zadania 2

Obowiązkowe uzasadnienie

Przed przystąpieniem do estymacji GARCH odpowiedz pisemnie:

„Na podstawie których wyników z Zadania 2 stwierdzam, że model ARMA nie opisuje w pełni struktury danych i konieczne jest modelowanie zmienności warunkowej?”

Przesłanki z Zadania 2

- Istotne wartości **ACF kwadratów reszt** $\hat{\varepsilon}_t^2$ przy małych opóźnieniach
- Odrzucenie H_0 w **teście ARCH-LM**
- Widoczne **skupiska zmienności** (volatility clustering) na wykresie szeregu

Co to oznacza?

Wariancja warunkowa σ_t^2 nie jest stała – zależy od przeszłości. Model ARMA zakłada homoskedastyczność reszt, więc **nie wystarczy** do pełnego opisu danych. Potrzebny jest model dla **drugiego momentu**.

Zadanie 3: Specyfikacja modelu GARCH(1,1)

Równanie wariancji warunkowej

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha \geq 0, \quad \beta \geq 0$$

Interpretacja parametrów

- ω – poziom bazowy zmienności
- α – **reakcja na szok**
(jak silnie σ_t^2 reaguje na ε_{t-1}^2)
- β – **trwałość zmienności**
(jak długo szok zanika)
- $\alpha + \beta$ – **pamięć systemu**
(bliskie 1 $\Rightarrow$ długa pamięć)

Wariancja bezwarunkowa

Przy $\alpha + \beta < 1$ istnieje skończona wariancja bezwarunkowa:

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}$$

Podaj tę wartość i zinterpretuj ją w kontekście swoich danych.

Zadanie 3: Warunek stabilności i rozkład warunkowy

Warunek stacjonarności

$$\alpha + \beta < 1$$

- Gwarantuje skończoność wariancji bezwarunkowej
- Jeśli warunek **nie jest spełniony**: rozważ model **IGARCH** lub transformację danych
- Podaj wartość $\alpha + \beta$ wraz z przedziałem ufności

Porównanie rozkładów warunkowych

Estymuj model dla **dwóch specyfikacji**:

- **Normal**: $\varepsilon_t \mid \mathcal{F}_{t-1} \sim \mathcal{N}(0, \sigma_t^2)$
- **Student- t** : grubsze ogony, dodatkowy parametr ν (stopnie swobody)

Porównaj modele przez **BIC** i **log-wiarygodność**. Zinterpretuj wartość $\hat{\nu}$.

Wskazówka

Dla danych finansowych typowo $\hat{\nu} \in (4, 8)$ – grube ogony są regułą, nie wyjątkiem. Dla danych pogodowych rozkład normalny może być wystarczający.

Zadanie 3: Diagnostyka – standaryzowane reszty

Definicja standaryzowanych reszt

$$z_t = \frac{\hat{\varepsilon}_t}{\hat{\sigma}_t}$$

Jeśli model jest poprawnie dopasowany, z_t powinny zachowywać się jak **niezależne realizacje** wybranego rozkładu warunkowego.

ACF(z_t^2) – test efektów ARCH

- Oblicz ACF kwadratów z_t^2
- Wszystkie wartości powinny leżeć w paśmie $\pm 1,96/\sqrt{n}$
- **Pożądany wynik:** brak istotnych autokorelacji – GARCH usunął efekty ARCH

Test Ljunga–Boxa dla z_t i z_t^2

- Test dla z_t : brak autokorelacji w średniej (kontrola po ARMA)
- Test dla z_t^2 : brak efektów ARCH (kontrola po GARCH)
- Pożądany wynik: p -wartość $> 0,05$ dla obu testów

Zadanie 3: Wizualizacja prognozowanej zmienności


Co narysować?

- Szereg X_t (górny panel) z nałożonymi pasmami $\pm 2\hat{\sigma}_t$ – widoczne skupiska zmienności
- Osobny wykres $\hat{\sigma}_t^2$ lub $\hat{\sigma}_t$ w funkcji czasu (dolny panel)
- Opcjonalnie: zaznaczyć okresy wysokiej / niskiej zmienności

Interpretacja ekonomiczna

Dla danych **giełdowych**: wskaż, czy okresy wysokiej zmienności pokrywają się z wydarzeniami rynkowymi.

Dla danych **pogodowych**: wskaż sezonowe wzorce zmienności (np. zima vs. lato).



Zadanie 3: Co należy oddać?

Wymagane materiały

- ❶ **Uzasadnienie** potrzeby modelu GARCH (na podstawie wyników Zadania 2)
- ❷ **Tabela porównawcza** BIC / log-wiarygodność dla rozkładu Normal vs. Student- t
- ❸ **Wykres** szeregu z pasmami $\pm 2\hat{\sigma}_t$
- ❹ **Wykres** $\hat{\sigma}_t$ w czasie
- ❺ **Wykresy** **ACF**(z_t) i **ACF**(z_t^2)

Interpretacja (ok. 0,5 strony)


Odpowiedz na każde z pytań:

- Czy $\alpha + \beta < 1$? Jaka jest wariancja bezwarunkowa $\bar{\sigma}^2$?
- Który rozkład warunkowy lepiej opisuje dane i dlaczego?
- Czy z_t^2 są wolne od efektów ARCH? (ACF i test Ljunga–Boxa)
- Jak interpretujesz okresy wysokiej zmienności?

Kryterium oceny

Liczy się **powiązanie wyników** Zadania 2 z uzasadnieniem i diagnostyką GARCH.

Zadanie 3: Podsumowanie – mapa drogowa



Zadanie 4: Punkt wyjścia – zmienność warunkowa z Zadania 3


Obowiązkowe powiązanie

Zadanie 4 jest **bezpośrednią kontynuacją** Zadania 3. Dynamiczny VaR i ES wyznaczamy na podstawie **prognozowanej zmienności warunkowej** $\hat{\sigma}_t$ uzyskanej z modelu GARCH(1,1).

Co przenosimy z Zadania 3?

- Szereg standaryzowanych reszt z_t
- Prognozowaną zmienność $\hat{\sigma}_t$
- Wybrany rozkład warunkowy (Normal lub Student- t)
- Estymowane parametry $\hat{\omega}, \hat{\alpha}, \hat{\beta}$

Łańcuch modeli



Zadanie 4: Value at Risk – definicja i wyznaczanie

Definicja dynamicznego VaR

Dla poziomu ufności $\alpha \in \{0,95; 0,99\}$:

$$\text{VaR}_t(\alpha) = \hat{\mu}_t + \hat{\sigma}_t \cdot q_\alpha$$

gdzie q_α to kwantyl rzędu $(1 - \alpha)$ wybranego rozkładu warunkowego, a $\hat{\mu}_t$ – prognoza warunkowej średniej z ARMA.

Kwantyle dla obu rozkładów

- **Normal:** $q_{0,95} = -1,645$, $q_{0,99} = -2,326$
- **Student- t_ν :** $q_\alpha = t_\nu^{-1}(1 - \alpha)$
(grubsze ogony $\Rightarrow$ wyższy VaR)
- Użyj tego samego rozkładu, który wygrał w Zadaniu 3

Co oznacza dynamiczność?

VaR zmienia się w czasie razem z $\hat{\sigma}_t$:

- W okresach wysokiej zmienności VaR jest **bardziej ujemny**
- W spokojnych okresach VaR jest **bliżej zera**
- To kluczowa przewaga nad statycznym VaR historycznym

Zadanie 4: Expected Shortfall – definicja i obliczanie

Definicja ES (CVaR)

Expected Shortfall to **oczekiwana strata** pod warunkiem, że strata przekroczyła VaR:

$$ES_t(\alpha) = \hat{\mu}_t + \hat{\sigma}_t \cdot \frac{\phi(q_\alpha)}{1 - \alpha}$$

dla rozkładu normalnego, gdzie ϕ – gęstość standardowego rozkładu normalnego.

ES dla rozkładu Student- t_ν

$$ES_t(\alpha) = \hat{\mu}_t - \hat{\sigma}_t \cdot \frac{f_\nu(q_\alpha)}{1 - \alpha} \cdot \frac{\nu + q_\alpha^2}{\nu - 1}$$

gdzie f_ν – gęstość rozkładu t_ν ,
 $q_\alpha = t_\nu^{-1}(1 - \alpha)$.

Dlaczego ES lepszy niż VaR?

- VaR mówi: „strata nie przekroczy x z prawdopodobieństwem α ”
- ES mówi: „gdy VaR zostanie przekroczony, średnia strata wyniesie y ”
- ES jest **spójną miarą ryzyka** (subaddytywność) – VaR nie zawsze

Zadanie 4: Backtesting – weryfikacja modelu ryzyka

Na czym polega backtesting?

Sprawdzamy, czy rzeczywiste straty przekraczają VaR z oczekiwaną częstością. Definiujemy zmienną wskaźnikową:

$$I_t = \mathbf{1}\{X_t < \text{VaR}_t(\alpha)\}$$

Oczekiwana liczba przekroczeń w próbie n : $\mathbb{E}\left[\sum I_t\right] = n(1 - \alpha)$

Reguła kciuka

- Poziom 95%: oczekujemy $\approx 5\%$ przekroczeń
- Poziom 99%: oczekujemy $\approx 1\%$ przekroczeń
- Zbyt wiele przekroczeń $\Rightarrow$ model **niedoszacowuje** ryzyko
- Zbyt mało przekroczeń $\Rightarrow$ model **przesadza** z ryzykiem

Test Kupca (Kupiec, 1995)

Formalny test proporcji przekroczeń:

$$LR_{uc} = -2 \ln \frac{(1 - \alpha)^{n_1} \alpha^{n_0}}{\hat{p}^{n_1} (1 - \hat{p})^{n_0}} \sim \chi^2(1)$$

gdzie n_1 – liczba przekroczeń, $n_0 = n - n_1$,
 $\hat{p} = n_1/n$.

$H_0: p = 1 - \alpha$ (model poprawny)

Zadanie 4: Wizualizacja backtestingu


Co narysować?

- Szereg X_t (niebieski)
- Linia $\text{VaR}_t(0,95)$ (czerwona przerywana)
- Linia $\text{ES}_t(0,95)$ (pomarańczowa)
- **Zaznaczone punkty przekroczeń** (czerwone trójkąty lub kropki)
- Podaj liczbę przekroczeń i wynik testu Kupca

Interpretacja

Przekroczenia powinny być **losowo rozłożone** w czasie. Skupiska przekroczeń wskazują na błędną specyfikację modelu.

Szereg, VaR i przekroczenia



Zadanie 4: Prognoza wielokrokowa zmienności

Prognoza h -krokowa z GARCH(1,1)

Dla modelu GARCH(1,1) prognoza wariancji warunkowej na h kroków naprzód dana jest rekurencyjnie:

$$\hat{\sigma}_{t+h|t}^2 = \bar{\sigma}^2 + (\alpha + \beta)^{h-1} (\hat{\sigma}_{t+1|t}^2 - \bar{\sigma}^2), \quad h \geq 1$$

gdzie $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$ – wariancja bezwarunkowa z Zadania 3.

- Dla $\alpha + \beta < 1$: prognoza **powraca do** $\bar{\sigma}^2$ wraz z wydłużaniem horyzontu
- Im bliżej $\alpha + \beta = 1$, tym **wolniejszy powrót** (długa pamięć)
- Wyznacz prognozy dla $h = 1, 5, 10, 20$ kroków
- Narysuj krzywą powrotu do $\bar{\sigma}^2$

Interpretacja

Szybkość powrotu $\hat{\sigma}_{t+h}^2 \rightarrow \bar{\sigma}^2$ mówi, jak długo rynek „pamięta” szok.

Dla danych **giełdowych**: dni do uspokojenia rynku.
Dla danych **pogodowych**: dni do powrotu do normy.

Zadanie 4: Krytyczna analiza ograniczeń modelu

Wymaganie

Napisz krótki komentarz (5–8 zdań) omawiający **co najmniej dwa** z poniższych ograniczeń w kontekście swoich danych.

Ograniczenia założeń

- **Rozkład warunkowy:** nawet Student- t może nie oddać ekstremalnych ogonów
- **Symetria:** GARCH(1,1) traktuje szoki dodatnie i ujemne jednakowo (asymetrię modeluje GJR-GARCH)
- **Stałe parametry:** α , β mogą zmieniać się w czasie

Ograniczenia procedury

- **Ryzyko modelu:** VaR jest tak dobry, jak model, z którego pochodzi
- **Okno estymacji:** parametry estymowane na całej próbie – w praktyce używa się okna kroczonego
- **Backtesting:** test Kupca nie wykrywa skupisk przekroczeń (potrzebny test Christoffersena)

Zadanie 4: Co należy oddać?

Wymagane materiały

- 1 **Wykres** szeregu z VaR_t , ES_t i zaznaczonymi przekroczeniami
- 2 **Liczba przekroczeń** i wynik **testu Kupca** (p -wartość)
- 3 **Wykres prognozy** $\hat{\sigma}_{t+h}^2$ na $h = 1, \dots, 20$ kroków
- 4 **Krytyczna analiza ograniczeń** (5–8 zdań, co najmniej 2 ograniczenia)

Interpretacja jakości modelu


Odpowiedz na każde z pytań:

- Ile było przekroczeń VaR?
Czy zgodnie z oczekiwaniem?
- Czy test Kupca odrzuca H_0 ?
Co to oznacza?
- Jak szybko $\hat{\sigma}_{t+h}^2$ wraca do $\bar{\sigma}^2$?
- Które ograniczenie modelu jest najpoważniejsze dla Twoich danych?

Kryterium oceny

Liczy się **spójność z Zadaniem 2 i 3** oraz jakość krytycznej analizy.

Zadanie 4: Podsumowanie – mapa drogowa



Zadanie 5: Czym jest Zadanie 5 i co można zyskać?

Zadanie opcjonalne – poziom 5+

Zadanie 5 jest przeznaczone wyłącznie dla studentów, którzy **ukończyli Zadania 1–4** i chcą pogłębić analizę. Nie jest wymagane do zaliczenia projektu.

Co zyskujesz?

- **Podwyższenie oceny** o pół stopnia (warunkowo – przy poprawnym wykonaniu)
- **Wyróżnienie** w recenzji projektu
- Przygotowanie do **pracy dyplomowej** lub badań naukowych w obszarze probabilistycznego prognozowania

Po co kalibracja modelu?

Zadania 1–4 odpowiadają na pytanie:
„Jak dobrze model dopasowuje się do danych?”

Zadanie 5 odpowiada na pytanie głębsze:
„Czy model wie, kiedy myli się i jak bardzo?”

To różnica między **dopasowaniem** a **kalibracją probabilistyczną**.

Zadanie 5: Metoda A – Probability Integral Transform (PIT)

Definicja i procedura

Dla poprawnie skalibrowanego modelu warunkowego $F_t(\cdot)$:

$$u_t = F_t(X_t \mid \mathcal{F}_{t-1}) = F_t(X_t \mid \hat{\mu}_t, \hat{\sigma}_t) \stackrel{iid}{\sim} \mathcal{U}[0, 1]$$


Kroki:

- 1 Oblicz u_t dla każdej obserwacji z próby testowej
- 2 Narysuj **histogram** wartości u_t – powinien być płaski
- 3 Wykonaj **test Kołmogorowa–Smirnowa** na jednostajność: $H_0: u_t \sim \mathcal{U}[0, 1]$

Interpretacja odchyleń

- Nadmiar $u_t \approx 0$ lub $u_t \approx 1$: model **niedoszacowuje ogony**
- Koncentracja w centrum: model **przeszacowuje zmienność**
- Skośność histogramu: model ma **błąd systematyczny średniej**

Poprawna kalibracja – histogram PIT



Zadanie 5: Metoda B – Conformal Prediction

Ważna uwaga o zależności czasowej

Standardowe Conformal Prediction zakłada **wymienność** obserwacji, co jest sprzeczne z zależnością czasową. Dlatego w tym zadaniu stosujemy wyłącznie **split conformal prediction** na wydzielonym oknie walidacyjnym.

Procedura split CP dla szeregów czasowych

- 1 Podziel dane: **próba ucząca** (pierwsze 80%) / **okno walidacyjne** (ostatnie 20%) – podział **chronologiczny**, nie losowy
- 2 Na próbie uczącej estymuj model ARMA-GARCH
- 3 Na oknie walidacyjnym oblicz **nonconformity scores**: $s_t = |z_t| = |\hat{\varepsilon}_t / \hat{\sigma}_t|$
- 4 Wyznacz kwantyl $\hat{q}_{1-\alpha}$ ze zbioru $\{s_t\}_{t \in \text{val}}$
- 5 Przedział predykcyjny dla nowej obserwacji: $\hat{\mu}_{t+1} \pm \hat{\sigma}_{t+1} \cdot \hat{q}_{1-\alpha}$

Zadanie 5: Conformal Prediction – weryfikacja coverage

Definicja empirycznego coverage

Sprawdź, czy empiryczna częstość pokrycia przedziału predykcyjnego na poziomie $1 - \alpha$ wynosi co najmniej $1 - \alpha$:

$$\widehat{\text{cov}} = \frac{1}{|\mathcal{T}_{\text{test}}|} \sum_{t \in \mathcal{T}_{\text{test}}} \mathbf{1}\{X_t \in [\hat{\mu}_t - \hat{\sigma}_t \hat{q}_{1-\alpha}, \hat{\mu}_t + \hat{\sigma}_t \hat{q}_{1-\alpha}]\} \geq 1 - \alpha$$

Gwarancja teoretyczna CP

Split CP gwarantuje **marginalny coverage**:

$$P(X_{t+1} \in C_{t+1}) \geq 1 - \alpha$$

– bez założeń o rozkładzie, o ile obserwacje w oknie walidacyjnym są **w przybliżeniu wymienne** (stacjonarność)

Co zgłosić?

- Wartość $\widehat{\text{cov}}$ dla $\alpha \in \{0,05; 0,10\}$
- Szerokość przedziałów vs. przedziały z modelu parametrycznego (Zadanie 3)
- Czy CP daje węższe czy szersze przedziały?

Zadanie 5: Metoda C – Posterior Predictive (wariant Bayesowski)

Idea

Zamiast estymować parametry punktowo (MLE), traktujemy je jako zmienne losowe z rozkładem *a posteriori*:

$$p(\boldsymbol{\theta} \mid \mathbf{X}) \propto p(\mathbf{X} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})$$

Prognoza to **rozkład predykcyjny** marginalizujący po parametrach:

$$p(X_{t+1} \mid \mathbf{X}) = \int p(X_{t+1} \mid \boldsymbol{\theta}, \mathbf{X}) p(\boldsymbol{\theta} \mid \mathbf{X}) d\boldsymbol{\theta}$$

Prosta implementacja (MCMC)

- Przyjmij słabo informatywne priory na ω, α, β
- Próbuj $\boldsymbol{\theta}^{(s)}$ metodą MCMC (np. Metropolis-Hastings lub Stan)
- Dla każdego $\boldsymbol{\theta}^{(s)}$ wyznacz $\sigma_t^{(s)}$ i próbuj $X_{t+1}^{(s)}$
- Histogram próbek = rozkład predykcyjny

Co daje podejście Bayesowskie?

- Automatycznie uwzględnia **niepewność parametrów** (szerokie posteriory $\Rightarrow$ szersze przedziały)
- Naturalny mechanizm **weryfikacji coverage**: porównaj HDI z empirycznym pokryciem
- Interpretacja: szansa, że model jest dobrze skalibrowany

Zadanie 5: Krytyczna dyskusja zawodności modelu

Wymaganie

Napisz esej (ok. 1 strona) omawiający **co najmniej dwa** z poniższych kierunków zawodności, osadzając je w kontekście **własnych danych**.

1. Ryzyko ogonów

Model może być dobrze skalibrowany **w centrum** rozkładu, ale systematycznie **niedoszacowywać ogony**.

Sprawdź: czy PIT wykazuje nadmiar przy $u_t \approx 0$ lub $u_t \approx 1$?

2. Niestacjonarność parametrów

Parametry α , β mogą **zmieniać się w czasie**. Model estymowany na całej próbie jest uśrednionym przybliżeniem.

Sprawdź: czy coverage jest jednorodne w różnych podokresach próby?

3. Ryzyko modelu

Wybór specyfikacji (GARCH vs. inne, Normal vs. t) sam w sobie jest źródłem niepewności.

Sprawdź: jak bardzo różnią się przedziały predykcyjne dla alternatywnych specyfikacji z Zadania 3?

Zadanie 5: Co należy oddać?

Wymagane materiały

Wybierz **jedną** metodę (A, B lub C) i dostarcz:

- 1 Dla **PIT**: histogram u_t i wynik testu K-S
- 2 Dla **CP**: wartość $\widehat{cov}$ i wykres przedziałów na próbie testowej
- 3 Dla **Bayes**: wykres rozkładu predykcyjnego i empiryczne pokrycie HDI
- 4 **Esej o zawodności modelu**
(ok. 1 strona, min. 2 kierunki)


Pytania przewodnie eseju

- Czy model jest dobrze skalibrowany w centrum i w ogonach?
- W którym podokresie model zawodzi najbardziej i dlaczego?
- Jak zmiana specyfikacji wpływa na szerokość przedziałów?
- Gdybyś miał ulepszyć model – co byś zmienił w pierwszej kolejności?

Kryterium oceny

Oceniana jest **dojrzałość krytyczna** – nie samo wykonanie obliczeń, ale zdolność do kwestionowania modelu.

Zadanie 5: Podsumowanie – mapa drogowa



Kryteria oceny projektu – oceny 3.0 i 4.0

Ocena 3.0 – Zadania 1–3

Plus terminowe oddanie prac i zwrócenie uwagi na:

- Analiza PCA z interpretacją geometryczną
- Model ARMA z diagnostyką sezonowości i diagnostyką reszt
- GARCH(1,1) z weryfikacją warunku $\alpha + \beta < 1$

Wymagana poprawna interpretacja wyników, nie tylko ich obliczenie.

Ocena 4.0 – Zadania 1–3 + elementy Zadania 4

Plus terminowe oddanie prac i zwrócenie uwagi na:

- Porównanie Normal vs. Student- t (wybór uzasadniony przez BIC)
- Diagnostyka standaryzowanych reszt: $ACF(z_t^2)$, test Ljunga–Boxa
- Dynamiczny VaR 95% lub 99% z podstawowym backtestingiem (liczba przekroczeń, reguła kciuka)

Wymagana poprawna interpretacja wyników, nie tylko ich obliczenie.

Zasada ogólna

Przy **każdym** progu oceny liczy się nie tylko poprawność techniczna obliczeń, ale przede wszystkim **jakość interpretacji wyników** w kontekście wybranych danych.

Kryteria oceny projektu – oceny 5.0 i 5+

Ocena 5.0 – Zadania 1–4 w całości

Plus terminowe oddanie prac i zwrócenie uwagi na:

- Pełny backtesting z formalnym **testem Kupca**
- Prognoza wielokrokowa $\hat{\sigma}_{t+h}^2$
- Krytyczna analiza co najmniej **dwóch ograniczeń modelu**

Wymagana **spójna narracja** ARMA → GARCH → VaR:

logiczny przepływ argumentacji, poprawna terminologia, interpretacja wykraczająca poza opis mechaniczny.

Ocena 5+ – Zadania 1–4 + Zadanie 5 (opcjonalne)

Plus terminowe oddanie prac i zwrócenie uwagi na:

- Formalna analiza kalibracji: PIT, Conformal Prediction lub posterior predictive
- Empiryczna weryfikacja **coverage** przedziałów predykcyjnych
- Meta-analiza co najmniej **dwóch** kierunków zawodności modelu (w kontekście danych)

Oceniana jest dojrzałość krytyczna – zdolność do kwestionowania modelu, nie samo wykonanie obliczeń.

Progresja zadań



Harmonogram oddania zadań

Zadanie	Termin	Uwagi
Zadanie 1	20 kwietnia 2026	Fundament projektu – dane i analiza PCA
Zadanie 2	4 maja 2026	Wymaga ukończonego Zadania 1
Zadanie 3	18 maja 2026	Wymaga ukończonego Zadania 2
Zadanie 4	25 maja 2026	Wymaga ukończonego Zadania 3
Zadanie 5 (opcjonalne)	1 czerwca 2026	Wymaga ukończonych Zadań 1–4
Zadanie 5+ (opcjonalne)	8 czerwca 2026	Rozszerzenie Zadania 5

Zasada ogólna

Każde zadanie może zostać oddane **wyłącznie po ukończeniu zadań poprzednich**. Spóźnienia powyżej 3 dni roboczych skutkują obniżeniem oceny o pół stopnia.

Blok I – Część Tematyczna 1 CzT01

Źródła i przygotowanie danych, definicja zmiennej modelowej
Poziom (Level) vs Zmienność (Volatility)

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

23 lutego 2026

Plan Części Tematycznej 1 (CzT01)

Co robimy

- 1 **Przykładowe zbiory danych** – S&P 500 i temperatura
- 2 **Transformacja** – log-zwroty i anomalie
- 3 **Pierwsza inspekcja** wizualna danych

Mikrocel pipeline

Na koniec części tematycznej definiujemy **zmienną modelowaną**, na której będziemy pracować przez wszystkie 37 części tematycznych.

Wymagania wstępne

Brak – to jest Część tematyczna CT1. Wystarczy Python z bibliotekami pandas, numpy, matplotlib, yfinance.

Zbiór danych 1 – S&P 500: log-zwroty dzienne

Charakterystyka

- **Ticker:** (Yahoo Finance^a)
- **Zakres:** min. 10 lat (dla backtestingu VaR)
- **Co pobieramy:** cena zamknięcia (*Close*)
- **Częstość:** dzienna

^a<https://finance.yahoo.com/>

```
import yfinance as yf
import numpy as np

sp500 = yf.download("^GSPC",
start="2014-01-01",
end="2024-12-31")
prices = sp500["Close"]
log_ret = np.log(
prices / prices.shift(1)
).dropna()
```

Pierwsza inspekcja

- Liczba obserwacji
- Zakres dat (start, koniec)
- Wartości min/max ceny
- Wartości min/max log-zwrotu
- Czy są braki danych?

Co zobaczymy na wykresie?

Na wykresie log-zwrotów widoczne będą **skupiska** dużych wahań – to jest *volatility clustering*, główna motywacja dla GARCH.

Zbiór danych 2 – Anomalie temperatury (Olsztyn)

Charakterystyka

- **Open-Meteo**^a
- **Źródło:** IMGW (dane publiczne)
- **Stacja:** Olsztyn
- **Zakres:** 1951–2023
- **Zmienna:** temperatura śr. dobowa lub maks.

^ahttps://open-meteo.com/en/docs/historical-weather-api?latitude=53.7799&longitude=20.4942&start_date=1999-01-03

Definicja anomalii

Anomalia a_t w dniu t to odchylenie od wieloletniej średniej dla tego dnia roku:

$$a_t = T_t - \bar{T}_{d(t)}$$

gdzie $\bar{T}_{d(t)}$ to średnia ze wszystkich historycznych obserwacji dnia roku $d(t)$.

Dlaczego anomalia, nie surowa temperatura?

- Surowa temperatura ma silną **sezonowość** – lato ciepłe, zima zimna
- Po usunięciu sezonowości pozostaje **czysta zmienność** wokół normy klimatologicznej
- To jest nasz “sygnał” do modelowania

Analogia ze zwrotami

Tak jak log-zwroty usuwają trend cenowy, anomalie usuwają cykl sezonowy.

Transformacja 1 – Log-zwroty: motywacja matematyczna

Definicja

$$r_t = \log\left(\frac{P_t}{P_{t-1}}\right) = \log P_t - \log P_{t-1}$$

Trzy powody dla logarytmu

1. Addytywność w czasie:

$$r_{t,t+k} = r_{t+1} + r_{t+2} + \dots + r_{t+k}$$

Zwroty proste nie są addytywne!


2. Symetria:

Spadek o 50% i wzrost o 100%: $|\log 0,5| = |\log 2|$


3. Przybliżenie dla małych zmian:

Dla $|r| \ll 1$: $\log(1 + r) \approx r$

Ceny S&P 500



Log-zwroty S&P 500



Transformacja 2 – Anomalie: usunięcie sezonowości

Procedura krok po kroku


Krok 1. Dla każdego dnia roku $d \in \{1, \dots, 366\}$ oblicz wieloletnią średnią:

$$\bar{T}_d = \frac{1}{|I_d|} \sum_{t \in I_d} T_t$$

Krok 2. Odejmij od każdej obserwacji:

$$a_t = T_t - \bar{T}_{d(t)}$$

Krok 3 (opcjonalnie). Wygładź $\bar{T}_d$ filtrem (np. harmoniki Fouriera), aby uniknąć skokowych przejść.



Mikrocel: co uzyskujemy?

Szereg a_t jest **bliższy stacjonarności** (sezonowość usunięta; opcjonalnie: odtrendowanie / zmiana baseline) i centrowany wokół zera – ma dynamiczną zmienność gotową do modelowania.

Definicja zmiennej modelowanej

Mikrocel pipeline CzT01: zdefiniowanie zmiennej modelowanej

Domena	Zmienna surowa	Transformacja	Zmienna modelowana	Własności
S&P 500	cena P_t	$\log(P_t/P_{t-1})$	log-zwrot r_t	bliższa stacjonarności,
Temperatura	temp. T_t	$T_t - \bar{T}_{d(t)}$	anomalia a_t	bliższa stacjonarności,

Wspólne cechy obu zmiennych

- Bliskie stacjonarności (sezonowość usunięta; opcjonalnie: usunięcie trendu klimatycznego)
- Centrowane wokół zera
- Wykazują **dynamiczną zmienność**

Co będziemy modelować?

Nie wartość r_t ani a_t jako taką, ale ich **warunkową wariancję**:

$$\sigma_t^2 = \text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1})$$

To jest zmienna, którą prognozuje GARCH.

Podsumowanie CzT01

Kluczowe idee

- ➊ **Prognozujemy zmienność**, nie poziom
- ➋ **Pipeline** to spójna architektura – od danych do decyzji
- ➌ **Dwie domeny** (finanse + meteorologia) – jeden model matematyczny
- ➍ **Log-zwroty i anomalie temperatury** to dwie realizacje tego samego problemu

Zapowiedź CzT02

Na kolejnej części tematycznej budujemy **geometryczne fundamenty**:

- Dane jako elementy $\mathbb{R}^n$
- Iloczyn skalarny i norma
- Macierz kowariancji Σ
- Forma kwadratowa $\mathbf{w}^T \Sigma \mathbf{w}$

Zadanie domowe – Faza 0 projektu

Pobierz własny zestaw danych (min. 4 strumienie, min. 5 lat dziennych obserwacji). Przygotuj: **(1)** wykres szeregu surowego, **(2)** wykres zmiennej transformowanej, **(3)** podstawowe statystyki opisowe: $\bar{r}$, $\hat{\sigma}$, min, max, n .

Wykład Specjalizujący

Motywacje, sylabus, przygotowanie i transformacja danych

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

23 lutego 2026