

Prognozowania ryzyka zmian dynamiki szeregów czasowych

Geometryczne i algebraiczne aspekty danych

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

2 marca 2026

Podstawowe intuicje prognozowania zmienności szeregów czasowych

Intuicje wprowadzające dotyczące strumieni danych

Intuicja finansowa

Cena Apple 5 lat temu = X . Dziś = Y .

Relacja Y/X to zwrot; **log-zwrot** to $\log(Y/X)$.
Ale...

- Ten sam zwrot możesz osiągnąć przy **bardzo różnym ryzyku**.
- Rok 2020 i rok 2016 mogły dać podobne zwroty, ale dramatycznie różną zmienność.

Pytanie: Jak niebezpieczna była ta inwestycja?

Intuicja meteorologiczna

Prognoza na jutro: **12°C**

To jest prognoza *poziomu*. Ale...

- Czy to będzie stabilne 12°C?
- Czy wahania od 4°C do 20°C?

Prognoza zmienności odpowiada na pytanie o *szerokość koperty niepewności*, nie o jej środek.

Kluczowe rozróżnienie

Termometr mierzy poziom $\longleftrightarrow$ **Barometr ryzyka** mierzy zmienność


Dlaczego zmienność jest matematycznie interesująca?

Cztery cechy zmienności

- **Dynamiczna** – zmienia się w czasie, nie jest stała
- **Grupująca się** – *volatility clustering*: po burzliwym dniu przychodzi burzliwy dzień
- **Warunkowa** – zależy od przeszłości ($\mathcal{F}_{t-1}$)
- **Modelowalna** – parametrycznie przez ARCH/GARCH

Obserwacja empiryczna

Na danych S&P 500 widoczne są **skupiska** dużych wahań: kryzysy 2008, 2020. Spokojne okresy przeplatają się z burzliwymi. To właśnie *volatility clustering*.



Intuicje: Poziom (Level) vs Zmienność (Volatility)

Termometr vs Barometr

Termometr	Mierzy poziom (średnią)
------------------	--------------------------------

Barometr ryzyka	Mierzy zmienność (wariancję)
----------------------------	-------------------------------------

Pogoda:

“Jutro 20 °C” = prognoza poziomu

“Błąd: ± 2 °C lub ± 10 °C” = prognoza zmienności

Finanse:

Poziom = oczekiwany zwrot

Zmienność = szerokość paska ryzyka

Błąd prognozy jako sygnał

Niech model poziomu prognozuje $\hat{y}_t$. Wtedy:

$$\varepsilon_t = y_t - \hat{y}_t$$

jest **błędem prognozy**.

Model zmienności to model dla ε_t^2 – kwadratu błędu.

Duże ε_t^2 = byliśmy daleko od prawdy.

Skupienie dużych ε_t^2 w czasie = *volatility clustering*.

Teza kursu

Sukces kursu = trafna prognoza σ_t (szerokości przedziału), **nie** wartości y_t .

Definicja kotwica: czym formalnie jest zmienność? (1/2)

Zmienność empiryczna (bezwarunkowa)

Dla okna T obserwacji:

$$\hat{\sigma} = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2}$$

Jest **stała** – jeden numer dla całego okna.

Rolling volatility: przesuwamy okno w czasie $\rightarrow$ otrzymujemy szereg $\hat{\sigma}_t$.

Zmienność warunkowa (dynamiczna)

$$\sigma_t^2 = \text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1})$$

$\mathcal{F}_{t-1}$ = wszystko, co wiemy do chwili $t-1$.

Jest **dynamiczna** – zmienia się co krok.
Właśnie **tę** wartość prognozuje GARCH.

UWAGA: *Tradycyjnie zmienność w punkcie czasowym t mierzymy **odchyleniem standardowym** σ_t lub **wariancją** σ_t^2*

Kluczowe rozróżnienie

Bezwarunkowa (historyczne ryzyko)

Warunkowa (bieżąca prognoza ryzyka)

wartość	jedna liczba $\hat{\sigma}$
charakter	statyczna
zastosowanie	opisuje historię

szereg punktów σ_t
dynamiczna
buduje przedziały prognoz

Definicja kotwica: czym formalnie jest zmienność? (2/2)

Intuicja

Bezwarunkowa:

„W ciągu roku rynek ruszał się o $\pm 1\%$ dziennie.”

Warunkowa:

„Jutro rynek może ruszyć się o $\pm 3\%$, bo dziś był wstrząs.”

Cel kursu formalnie


Zbudować model dla $\hat{\sigma}_t$ – **warunkowego odchylenia standardowego**.

$$\sigma_t^2 = f(\varepsilon_{t-1}, \sigma_{t-1}, \dots) \longrightarrow \text{GARCH}$$

Podsumowanie

GARCH modeluje **warunkową** wariancję – nie opisuje przeszłości, lecz **prognozuje jutrzejsze ryzyko** na podstawie dzisiejszych informacji.

Od zmienności do paska ryzyka (1/2): Wizualizacja



Interpretacja wykresu

Linia ciągła ($\hat{\mu}_t$): prognoza średniej

Linie przerywane: pasek $\hat{\mu}_t \pm k\hat{\sigma}_t$

Gdy $\hat{\sigma}_t$ rośnie → pasek **puchnie**.

Gdy $\hat{\sigma}_t$ maleje → pasek **zwęża się**.

Kluczowa myśl

Nie prognozujemy jednej liczby. Prognozujemy **szerokość dopuszczalnych scenariuszy**.

Od zmienności do paska ryzyka (2/2): Budowa prognozy

Krok 1: Prognoza średniej

$$\hat{\mu}_{t+1}$$

Model ARMA daje prognozę poziomu (środka rozkładu).

Krok 2: Prognoza zmienności

$$\hat{\sigma}_{t+1}$$

Model GARCH daje prognozę warunkowego odchylenia standardowego.

Krok 3: Pasek ryzyka - Dynamiczny przedział:

$$\hat{\mu}_{t+1} \pm k \hat{\sigma}_{t+1}$$

gdzie:

- $k = 1$ – ok. 68% (przy normalności),
- $k = 1,96$ – ok. 95%,
- k zależy od przyjętego poziomu ufności.

Logika składania kroków

- 1 ARMA wyznacza **środek** przedziału: $\hat{\mu}_{t+1}$
- 2 GARCH wyznacza **szerokość** przedziału: $\hat{\sigma}_{t+1}$
- 3 Razem dają **pełny obraz niepewności**


Analogia

Prognoza pogody:

„Jutro 20°C” → tylko środek

„Jutro 20 ± 5°C” → środek + niepewność

Architektura kursu – jeden pipeline



Zasada niezmiennicza

W części wykładowej używamy konsekwentnie S&P 500 i temperatury. W projekcie każdy pracuje na własnych danych. **Pipeline jest ten sam** – zmienia się tylko **narzędzie** realizujące każdy etap.

CzT01: Przygotowanie i transformacja danych

Plan Części Tematycznej 1 (CzT01)

Co robimy

- 1 **Przykładowe zbiory danych** – S&P 500 i temperatura
- 2 **Transformacja** – log-zwroty i anomalie
- 3 **Pierwsza inspekcja** wizualna danych

Mikrocel pipeline

Na koniec części tematycznej definiujemy **zmienną modelowaną**, na której będziemy pracować przez wszystkie 37 części tematycznych.

Wymagania wstępne

Brak – to jest Część tematyczna CzT01. Wystarczy Python z bibliotekami pandas, numpy, matplotlib, yfinance.

Dane jako wektory i macierze

Co łączy zjawiska w ekonomii, geofizyce, astrofizyce, medycynie i systemach technicznych?

Wspólna struktura matematyczna

- Każde zjawisko można modelować jako **wielowymiarowy szereg czasowy**

$$X_t = (X_t^{(1)}, \dots, X_t^{(d)}) \in \mathbb{R}^d$$

- Zmienne są **wzajemnie sprzężone** (korelacje, zależności nieliniowe).
- System może przechodzić przez **zmiany reżimu** (regime shifts).
- Kluczowe są **rzadkie zdarzenia ekstremalne** (heavy tails).
- Prognozowanie wymaga analizy **całej struktury wektorowej**, nie pojedynczej zmiennej.

Dane jako wektory w $\mathbb{R}^n$

Trzy perspektywy na dane

(1) Szereg w czasie:

r_t jako skalar dla każdego t

(2) Wektor obserwacji:

$$\mathbf{r} = (r_1, r_2, \dots, r_T)^T \in \mathbb{R}^T$$


Cały szereg = jeden punkt w przestrzeni

(3) Macierz obserwacji (n szeregów):

$$X = \begin{pmatrix} r_{1,1} & r_{2,1} & \cdots & r_{n,1} \\ r_{1,2} & r_{2,2} & \cdots & r_{n,2} \\ \vdots & & \ddots & \vdots \\ r_{1,T} & r_{2,T} & \cdots & r_{n,T} \end{pmatrix} \in \mathbb{R}^{T \times n}$$

Wiersz = obserwacja w chwili t

Kolumna = jeden szereg czasowy



Przesunięcie perspektywy

Dane to nie “tabelka liczb” – to **chmura punktów** w przestrzeni $\mathbb{R}^n$.

Zbiór danych 1 – S&P 500: log-zwroty dzienne

Charakterystyka

- **Ticker:** (Yahoo Finance^a)
- **Zakres:** min. 10 lat (dla backtestingu VaR)
- **Co pobieramy:** cena zamknięcia (*Close*)
- **Częstość:** dzienna

^a<https://finance.yahoo.com/>

```
import yfinance as yf
import numpy as np

sp500 = yf.download("^GSPC",
start="2014-01-01",
end="2024-12-31")
prices = sp500["Close"]
log_ret = np.log(
prices / prices.shift(1)
).dropna()
```

Pierwsza inspekcja

- Liczba obserwacji
- Zakres dat (start, koniec)
- Wartości min/max ceny
- Wartości min/max log-zwrotu
- Czy są braki danych?

Co zobaczymy na wykresie?

Na wykresie log-zwrotów widoczne będą **skupiska** dużych wahań – to jest *volatility clustering*, główna motywacja dla GARCH.

Zbiór danych 2 – Anomalie temperatury (Olsztyn)

Charakterystyka

- **Open-Meteo**^a
- **Źródło:** IMGW (dane publiczne)
- **Stacja:** Olsztyn
- **Zakres:** 1951–2023
- **Zmienna:** temperatura śr. dobową lub maks.

^ahttps://open-meteo.com/en/docs/historical-weather-api?latitude=53.7799&longitude=20.4942&start_date=1999-01-03

Definicja anomalii

Anomalia a_t w dniu t to odchylenie od wieloletniej średniej dla tego dnia roku:

$$a_t = T_t - \bar{T}_{d(t)}$$

gdzie $\bar{T}_{d(t)}$ to średnia ze wszystkich historycznych obserwacji dnia roku $d(t)$.

Dlaczego anomalia, nie surowa temperatura?

- Surowa temperatura ma silną **sezonowość** – lato ciepłe, zima zimna
- Po usunięciu sezonowości pozostaje **czysta zmienność** wokół normy klimatologicznej
- To jest nasz “sygnał” do modelowania

Analogia ze zwrotami

Tak jak log-zwroty usuwają trend cenowy, anomalie usuwają cykl sezonowy.

Transformacja 1 – Log-zwroty: motywacja matematyczna

Definicja

$$r_t = \log\left(\frac{P_t}{P_{t-1}}\right) = \log P_t - \log P_{t-1}$$

Trzy powody dla logarytmu

1. Addytywność w czasie:

$$r_{t,t+k} = r_{t+1} + r_{t+2} + \dots + r_{t+k}$$

Zwroty proste nie są addytywne!


2. Symetria:

Spadek o 50% i wzrost o 100%: $|\log 0,5| = |\log 2|$


3. Przybliżenie dla małych zmian:

Dla $|r| \ll 1$: $\log(1 + r) \approx r$

Ceny S&P 500



Log-zwroty S&P 500



Transformacja 2 – Anomalie: usunięcie sezonowości

Procedura krok po kroku


Krok 1. Dla każdego dnia roku $d \in \{1, \dots, 366\}$ oblicz wieloletnią średnią:

$$\bar{T}_d = \frac{1}{|I_d|} \sum_{t \in I_d} T_t$$

Krok 2. Odejmij od każdej obserwacji:

$$a_t = T_t - \bar{T}_{d(t)}$$

Krok 3 (opcjonalnie). Wygładź $\bar{T}_d$ filtrem (np. harmoniki Fouriera), aby uniknąć skokowych przejść.



Mikrocel: co uzyskujemy?

Szereg a_t jest **bliższy stacjonarności** (sezonowość usunięta; opcjonalnie: odtrendowanie / zmiana baseline) i centrowany wokół zera – ma dynamiczną zmienność gotową do modelowania.

Definicja zmiennej modelowanej

Mikrocel pipeline CzT01: zdefiniowanie zmiennej modelowanej

Domena	Zmienna surowa	Transformacja	Zmienna modelowana	Własności
S&P 500	cena P_t	$\log(P_t/P_{t-1})$	log-zwrot r_t	bliższa stacjonarności,
Temperatura	temp. T_t	$T_t - \bar{T}_{d(t)}$	anomalia a_t	bliższa stacjonarności,

Wspólne cechy obu zmiennych

- Bliskie stacjonarności (sezonowość usunięta; opcjonalnie: usunięcie trendu klimatycznego)
- Centrowane wokół zera
- Wykazują **dynamiczną zmienność**

Co będziemy modelować?

Nie wartość r_t ani a_t jako taką, ale ich **warunkową wariancję**:

$$\sigma_t^2 = \text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1})$$

To jest zmienna, którą prognozuje GARCH.

Podsumowanie CzT01

Kluczowe idee

- ➊ **Prognozujemy zmienność**, nie poziom
- ➋ **Pipeline** to spójna architektura – od danych do decyzji
- ➌ **Dwie domeny** (finanse + meteorologia) – jeden model matematyczny
- ➍ **Log-zwroty i anomalie temperatury** to dwie realizacje tego samego problemu

Zapowiedź CzT02

Na kolejnej części tematycznej budujemy **geometryczne fundamenty**:

- Dane jako elementy $\mathbb{R}^n$
- Iloczyn skalarny i norma
- Macierz kowariancji Σ
- Forma kwadratowa $\mathbf{w}^T \Sigma \mathbf{w}$

Zadanie domowe – Faza 0 projektu

Pobierz własny zestaw danych (min. 4 strumienie, min. 5 lat dziennych obserwacji). Przygotuj: **(1)** wykres szeregu surowego, **(2)** wykres zmiennej transformowanej, **(3)** podstawowe statystyki opisowe: $\bar{r}$, $\hat{\sigma}$, min, max, n .

Część Tematyczna CzT02

Plan wykładu z Część Tematycznej CzT02


Cele bieżącej Części Tematycznej CzT

- Zbudować formalny model danych wielowymiarowych jako punktów w $\mathbb{R}^n$.
- Zinterpretować szereg czasowy jako **chmurę punktów** w przestrzeni wysokiego wymiaru.
- Zrozumieć, że **portfel** jest kombinacją liniową, a jego zwrot jest funkcjonałem liniowym $w^\top r$.
- Ustawić precyzyjnie most do kolejnych pojęć: **normy, iloczynu skalarnego, kowariancji, PCA i Markowitza**.

Minimalny słownik pojęć (będzie używany dalej)

- wektor $x \in \mathbb{R}^n$, współrzędne $x_1, \dots, x_n$,
- zbiór obserwacji $\{x^{(t)}\}_{t=1}^T$ jako chmura punktów,
- wagi portfela $w \in \mathbb{R}^n$, zwrot portfela $w^\top x^{(t)}$.

Pipeline kursu i miejsce CzT02



Co dokładnie robi Część Tematyczna CzT02 w tym pipeline?

- Ustala **formalny obiekt danych**: obserwacja dzienna to wektor w $\mathbb{R}^n$.
- Ustala **geometrię danych**: zbiór obserwacji to chmura punktów.
- Ustala **działanie portfela**: $w^\top r$ to projekcja (później: rzut i wariancja).

Motywacja: dlaczego nie wystarczą „kolumny w Excelu”?

Problem praktyczny (finanse + temperatura)

- Dane: dzienne log-zwroty n aktywów oraz temperatura (np. Olsztyn) jako dodatkowa zmienna.
- Pytanie: **co oznacza „kształt” danych** i dlaczego wpływa na ryzyko portfela?
- Cel: zobaczyć, że „ryzyko” nie jest tylko listą wariancji, lecz **geometrią chmury**.

Zadanie heurystyczne (pytanie na sali)

- Jeśli mamy dwa aktywa A, B i ich zwroty są **zawsze identyczne**, to:
 - czy potrzebujemy wymiaru 2, czy wystarczy 1?
 - co to znaczy dla „chmury punktów” w $\mathbb{R}^2$?

Definicja: wektor w $\mathbb{R}^n$

Definicja (wektor i współrzędne)

Niech $n \in \mathbb{N}$. Przez $\mathbb{R}^n$ rozumiemy zbiór wszystkich uporządkowanych n -tek liczb rzeczywistych:

$$\mathbb{R}^n := \{(x_1, \dots, x_n) : x_i \in \mathbb{R}\}.$$

Element $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ nazywamy **wektorem**, a liczby $x_1, \dots, x_n$ jego **współrzędnymi**.

Operacje (dodawanie i mnożenie przez skalar)

Dla $x, y \in \mathbb{R}^n$ oraz $\alpha \in \mathbb{R}$ definiujemy:

$$(x + y)_i := x_i + y_i, \quad (\alpha x)_i := \alpha x_i, \quad i = 1, \dots, n.$$

Po co ta formalność?

W kolejnych wykładach będziemy definiować **kowariancję**, **formy kwadratowe** i **PCA** jako własności obiektów w $\mathbb{R}^n$.

Przestrzeń liniowa: aksjomaty, których będziemy używać

Fakty (używane w dalszym pipeline)

Dla wszystkich $x, y, z \in \mathbb{R}^n$ oraz $\alpha, \beta \in \mathbb{R}$ zachodzą:

- $(x + y) + z = x + (y + z)$ (łączność dodawania)
- $x + y = y + x$ (przemienność dodawania)
- istnieje $0 \in \mathbb{R}^n$: $x + 0 = x$ (wektor zerowy)
- dla każdego x istnieje $-x$: $x + (-x) = 0$ (przeciwny)
- $\alpha(x + y) = \alpha x + \alpha y$ (rozdzielność)
- $(\alpha + \beta)x = \alpha x + \beta x$ (rozdzielność)
- $(\alpha\beta)x = \alpha(\beta x)$, $1 \cdot x = x$ (zgodność)

Interpretacja w finansach

- Dodawanie wektorów: **sumowanie zmian** (np. suma dwóch dni).
- Mnożenie przez skalar: **skalowanie ekspozycji** (np. lewar).

Dane jako wektor: 1 dzień = 1 punkt

Model danych (najprostszy, ale wystarczający do CzT02)

Niech n oznacza liczbę zmiennych (np. aktywów, ewentualnie + temperatura).

$$r^{(t)} = \begin{bmatrix} r_1^{(t)} \\ \vdots \\ r_n^{(t)} \end{bmatrix} \in \mathbb{R}^n$$

oznacza **wektor obserwacji w dniu t** (np. log-zwroty).

Przykład (4 aktywa)

$$r^{(t)} = (0.01, -0.005, 0.002, 0.012) \in \mathbb{R}^4.$$

To nie są „cztery liczby obok siebie”. To **jeden punkt** w przestrzeni $\mathbb{R}^4$.

Wizualizacja 2D (gdzie zrobić na wykładzie?)

Wybieramy dwie współrzędne: np. zwrot S&P 500 oraz temperatura $\Rightarrow$ wykres punktowy.

Iloczyn skalarny

Definicja: iloczyn skalarny (dot product)

Dla $x = (x_1, \dots, x_n)$ oraz $y = (y_1, \dots, y_n)$ z $\mathbb{R}^n$:

$$\langle x, y \rangle = x^\top y = \sum_{i=1}^n x_i y_i$$

Twierdzenie (interpretacja geometryczna)

Dla dowolnych $x, y \in \mathbb{R}^n \setminus \{0\}$:

$$\langle x, y \rangle = \|x\| \|y\| \cos \theta$$

gdzie $\|x\| = \sqrt{\langle x, x \rangle}$ jest normą euklidesową, a $\theta \in [0, \pi]$ — kątem między wektorami.

Konsekwencje

- $\langle x, y \rangle > 0$ — wektory tworzą kąt ostry (zmiany „w tym samym kierunku”).
- $\langle x, y \rangle = 0$ — wektory prostopadłe (nieskorelowane kierunki).
- $\langle x, y \rangle < 0$ — kąt rozwarty (zmiany „przeciwnie”).

Dowód: iloczyn skalarny a kąt między wektorami

Twierdzenie cosinusów (przypomnienie)

Dla trójkąta o bokach a, b, c i kącie θ naprzeciwko boku c :

$$c^2 = a^2 + b^2 - 2ab \cos \theta$$

Zarys dowodu

Weźmy wektory $x, y \in \mathbb{R}^n$. Tworzą one trójkąt o bokach: a, b oraz c (stosujemy twierdzenie cosinusów):

$$a = \|x\|, \quad b = \|y\|, \quad c = \|x - y\|$$

$$\|x - y\|^2 = \|x\|^2 + \|y\|^2 - 2\|x\| \|y\| \cos \theta$$

Rozwijamy lewą stronę:

$$\|x - y\|^2 = \langle x - y, x - y \rangle = \|x\|^2 - 2\langle x, y \rangle + \|y\|^2$$

Porównując obie strony:

$$\cancel{\|x\|^2} - 2\langle x, y \rangle + \cancel{\|y\|^2} = \cancel{\|x\|^2} + \cancel{\|y\|^2} - 2\|x\| \|y\| \cos \theta$$

$$\boxed{\langle x, y \rangle = \|x\| \|y\| \cos \theta}$$

Szereg czasowy jako chmura punktów

Zbiór obserwacji

Dla T dni mamy zbiór:

$$\mathcal{X} := \{r^{(1)}, r^{(2)}, \dots, r^{(T)}\} \subset \mathbb{R}^n.$$

Co oznacza „kształt chmury”?

Kształt chmury zależy od:

- zmienności każdej współrzędnej,
- zależności pomiędzy współrzędnymi (później: korelacja, kowariancja),
- obecności podprzestrzeni o małym wymiarze (później: PCA).

Kontrprzykład (dlaczego geometria jest konieczna)

Jeśli dla wszystkich t zachodzi $r_2^{(t)} = 2r_1^{(t)}$, to chmura w $\mathbb{R}^2$ leży na prostej. Wtedy „wymiar danych” jest **mniejszy** niż liczba kolumn.

Wektor losowy: formalny most do probabilistyki

Definicja (wektor losowy)

Wektor losowy $R : \Omega \rightarrow \mathbb{R}^n$ jest funkcją, która każdemu wynikowi $\omega \in \Omega$ przypisuje wektor:

$$R(\omega) = (R_1(\omega), \dots, R_n(\omega)).$$

Każda współrzędna R_i jest zmienną losową.

Co „mierzymy” statystycznie?

Z danych $\{r^{(t)}\}$ estymujemy własności rozkładu R :

- średnią $\mu = \mathbb{E}[R]$,
- kowariancję $\Sigma = \mathbb{E}[(R - \mu)(R - \mu)^\top]$,
- dalej: ryzyko portfela $w^\top \Sigma w$.

Pytanie heurystyczne

Dlaczego nie wolno utożsamiać „średniej z próby” z „prawdą”? (Odp.: błąd estymacji, potrzeba walidacji i kalibracji.)

Portfel jako kombinacja liniowa: definicja i sens

Definicja (wagi i zwrot portfela)

Niech $w = (w_1, \dots, w_n) \in \mathbb{R}^n$ oznacza wektor wag portfela. Dla obserwacji $r^{(t)} \in \mathbb{R}^n$ zwrot portfela w dniu t definiujemy jako:

$$r_{\text{port}}^{(t)} := w^\top r^{(t)} = \sum_{i=1}^n w_i r_i^{(t)}.$$

Interpretacja geometryczna (zapowiedź rzutów)

Mapa $r \mapsto w^\top r$ jest funkcjonałem liniowym. W geometrii euklidesowej będzie to powiązane z **rzutem na kierunek** w (Część Tematyczna (CzT0x)2/4 w CzT02).

Typowy błąd

Mylenie „wag” z „procentami kapitału” bez sprawdzenia, czy dopuszczamy:

- krótką sprzedaż (ujemne wagi),
- lewar (sumy wag różne od 1).

W Markowitzu ograniczenia muszą być jawne.

Przykład liczbowy: 3 aktywa, 2 dni, portfel

Dane (mały wymiar)

Niech $n = 3$, $T = 2$:

$$r^{(1)} = (0.01, -0.02, 0.005), \quad r^{(2)} = (0.015, -0.01, -0.002).$$

Wagi portfela:

$$w = (0.5, 0.3, 0.2).$$

Obliczenie zwrotu portfela (krok po kroku)

Dzień 1:

$$r_{\text{port}}^{(1)} = 0.5 \cdot 0.01 + 0.3 \cdot (-0.02) + 0.2 \cdot 0.005 = 0.005 - 0.006 + 0.001 = 0.000.$$

Dzień 2:

$$r_{\text{port}}^{(2)} = 0.5 \cdot 0.015 + 0.3 \cdot (-0.01) + 0.2 \cdot (-0.002) = 0.0075 - 0.003 - 0.0004 = 0.0041.$$

Komentarz

Już tutaj widać, że kombinacja liniowa może „znosić” wahania jednych aktywów innymi. Formalizacją będzie kowariancja i forma kwadratowa $w^\top \Sigma w$.

Wizualizacja 2D: chmura punktów i portfel jako kierunek

Co rysujemy?


- Oś x : zwrot S&P 500 (lub aktywo 1).
- Oś y : aktywo 2).
- Punkty: $(r_1^{(t)}, r_2^{(t)})$ dla $t = 1, \dots, T$.

Portfel w 2D

Dla $w = (w_1, w_2)$ kierunek w wyznacza „agregację” dwóch zmiennych. W kolejnych wykładach pokażemy, że:

$$\text{zmiennosc portfela} \approx w^\top \Sigma w.$$

Miejsce na szkic na tablicy



Kontrprzykład do omówienia

Chmura może leżeć na prostej (wymiar efektywny 1). Wtedy PCA ma sens, a kowariancja ma rangę 1.

Najczęstsze błędy i pułapki (już na poziomie wektorów)

Błędy formalne

- Mylenie: $r^{(t)}$ (obserwacja) z R (wektor losowy).
- Brak jawnego określenia, co jest wymiarem n i co jest liczbą obserwacji T .
- Niezgodny zapis: raz obserwacje w wierszach, raz w kolumnach (później psuje kowariancję).


Błędy interpretacyjne

- „Ryzyko = wariancja aktywa” (pomija zależności między aktywami).
- „Portfel = średnia zwrotów” (bez wag i bez geometrii).
- „Wymiar danych = liczba kolumn” (ignoruje liniowe zależności).

Jak to naprawimy w pipeline?

- Część Tematyczna CzT03: dokładniej wyjaśnienie normy i iloczynu skalarnego $\Rightarrow$ kąty i korelacja.
- Część Tematyczna CzT04: kowariancja $\Rightarrow$ forma kwadratowa ryzyka.
- Część Tematyczna CzT04: twspektralne/SVD $\Rightarrow$ PCA oraz przygotowanie Markowitza.

Powiązanie z kolejnymi tematami CzT03 (mapa zależności)



Co trzeba zapamiętać po dzisiaj?

- Dane wielowymiarowe to wektory i chmura punktów.
- Portfel to kombinacja liniowa $w^\top r$.
- Zależności między zmiennymi nie znikają: one **kształtują geometrię chmury**.

Checklist: proste ćwiczenia z CzT02?

Minimalne kompetencje (weryfikowalne)

Po dzisiejszym wykładzie student powinien umieć:

- zapisać obserwację dzienną jako $r^{(t)} \in \mathbb{R}^n$,
- zbudować macierz danych $X \in \mathbb{R}^{T \times n}$,
- obliczyć zwrot portfela $w^\top r^{(t)}$ dla danego w ,
- wskazać, co jest „wymiar” n , a co „liczbą obserwacji” T .

Zapowiedź Czt03

- Normy jako długości i miary zmienności,
- iloczyn skalarny jako miara współzmienności,
- kąt i korelacja: **korelacja = znormalizowany iloczyn skalarny.**

Pytanie końcowe (kontrprzykład do przemyslenia)

Czy dwie zmienne mogą mieć korelację 0, a mimo to być zależne? (Odp.: tak, brak zależności liniowej nie oznacza niezależności.)

Część Tematyczna CzT03

Plan wykładu z Część Tematycznej CzT03


Cele bieżącej Części Tematycznej CzT

- Utrwalenie podstawowych pojęć **normy** oraz **iloczynu skalarnego** w $\mathbb{R}^n$.
- Samodzielnie powtórzyć pełny dowód relacji: $\langle x, y \rangle = \|x\| \|y\| \cos \theta$.
- Zinterpretować **korelację** jako **znormalizowany iloczyn skalarny**.
- Zobaczyć, jak te pojęcia staną się podstawą dla **kowariancji** i **formy kwadratowej ryzyka** $w^\top \Sigma w$.

Minimalny słownik (używany dalej)

- norma $\|x\|$ (długość), iloczyn skalarny $\langle x, y \rangle$ (zależność liniowa),
- kąt $\theta(x, y)$ oraz cosinus kąta,
- korelacja ρ jako cosinus kąta między wektorami danych (po standaryzacji).

Pipeline kursu: gdzie dokładnie wchodzi geometria?



Miejsce Wykładu CzT03

- Dane $\rightarrow$ wektory $r^{(t)} \in \mathbb{R}^n$ (Część Tematyczna (CzT002)).
- **Część Tematyczna CzT03:** długość i „zgodność kierunków” $\Rightarrow$ norma i iloczyn skalarny.
- **Część Tematyczna CzT04:** kowariancja i forma kwadratowa ryzyka.

Motywacja finansowa: zmienność i współzmienność w praktyce

Problem motywacyjny (3–4 aktywa + temperatura)

Mamy $n = 4$ zmienne: 3 aktywa + temperatura. Dla dwóch zmiennych (np. S&P 500 oraz temperatura) obserwujemy dwa szeregi:

$$x = (x_1, \dots, x_T), \quad y = (y_1, \dots, y_T),$$

gdzie x_t i y_t są wycentrowanymi zmianami (odchylenia od średniej).

Pytanie praktyczne

- Jak **zmierzyć** „jak bardzo” oba szeregi idą razem (w tę samą stronę)?
- Jak rozróżnić:
 - „duże wahania” (zmienność pojedyncza),
 - „wahania wspólne” (zależność liniowa)?

Odpowiedź strukturalna (zapowiedź)

- zmienność $\Rightarrow$ **norma** wektora odchyleń,
- współzmienność $\Rightarrow$ **iloczyn skalarny**,
- zależność bez skali $\Rightarrow$ **korelacja** jako cosinus kąta.

Normy: definicja aksjomatyczna i przykłady

Definicja (norma na przestrzeni liniowej)

Niech V będzie przestrzenią liniową nad $\mathbb{R}$. Funkcję $\|\cdot\| : V \rightarrow \mathbb{R}$ nazywamy **normą**, jeśli dla wszystkich $x, y \in V$ i $\alpha \in \mathbb{R}$ zachodzi:

- ❶ **Nieujemność i rozdzielnosc:** $\|x\| \geq 0$ oraz $\|x\| = 0 \Leftrightarrow x = 0$.
- ❷ **Jednorodność:** $\|\alpha x\| = |\alpha| \|x\|$.
- ❸ **Nierówność trójkąta:** $\|x + y\| \leq \|x\| + \|y\|$.

Przykłady w $\mathbb{R}^n$ (będą używane dalej)

Dla $x = (x_1, \dots, x_n)$:

$$\|x\|_1 := \sum_{i=1}^n |x_i|, \quad \|x\|_2 := \sqrt{\sum_{i=1}^n x_i^2}, \quad \|x\|_\infty := \max_{1 \leq i \leq n} |x_i|.$$

Dlaczego w kursie dominuje norma euklidesowa?

Bo jest zgodna z iloczynem skalarnym i prowadzi do geometrii kątów, projekcji oraz twierdzeń spektralnych.

Norma euklidesowa i jej związek z iloczynem skalarnym

Definicja (norma euklidesowa przez iloczyn skalarny)

W $\mathbb{R}^n$ definiujemy:

$$\|x\| := \sqrt{x^\top x}.$$

Własność (kwadrat normy)

$$\|x\|^2 = x^\top x = \sum_{i=1}^n x_i^2.$$

Most do probabilistyki (zapowiedź)

Dla wycentrowanego szeregu odchyleń $x = (x_1, \dots, x_T)$:

$$\hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=1}^T x_t^2 = \frac{1}{T-1} \|x\|^2.$$

Wariancja empiryczna jest więc **normą kwadratową przeskalowaną**.

Iloczyn skalarny: definicja i podstawowe własności

Definicja (iloczyn skalarny w $\mathbb{R}^n$)

Dla $x, y \in \mathbb{R}^n$ definiujemy:

$$\langle x, y \rangle := x^\top y = \sum_{i=1}^n x_i y_i.$$

Własności (używane dalej)

Dla wszystkich $x, y, z \in \mathbb{R}^n$ i $\alpha \in \mathbb{R}$:

- **Symetria:** $\langle x, y \rangle = \langle y, x \rangle$.
- **Liniowość w pierwszym argumencie:** $\langle \alpha x + z, y \rangle = \alpha \langle x, y \rangle + \langle z, y \rangle$.
- **Dodatnia określoność:** $\langle x, x \rangle \geq 0$, oraz $\langle x, x \rangle = 0 \Leftrightarrow x = 0$.

Interpretacja geometryczna (zapowiedź)

Iloczyn skalarny mierzy „zgodność kierunku” wektorów. Kąt pojawi się po udowodnieniu nierówności Cauchy'ego–Schwarza.

Twierdzenie: nierówność Cauchy'ego–Schwarza

Twierdzenie (Cauchy'ego–Schwarza)

Dla dowolnych $x, y \in \mathbb{R}^n$ zachodzi:

$$|\langle x, y \rangle| \leq \|x\| \|y\|.$$

Dlaczego to jest kluczowe?

- Zapewnia, że ułamek $\frac{\langle x, y \rangle}{\|x\| \|y\|}$ ma wartość w przedziale $[-1, 1]$.
- Dzięki temu możemy **zdefiniować cosinus kąta** i powiązać go z korelacją.

Dowód: z interpretacji geometrycznej

Punkt wyjścia

Korzystamy z twierdzenia (udowodnionego wcześniej):

$$\langle x, y \rangle = \|x\| \|y\| \cos \theta$$

gdzie $\theta \in [0, \pi]$ jest kątem między wektorami x i y .

Dowód

Bierzemy wartość bezwzględną obu stron:

$$|\langle x, y \rangle| = \|x\| \|y\| |\cos \theta|$$

Ponieważ $|\cos \theta| \leq 1$ dla każdego θ :

$$|\langle x, y \rangle| = \|x\| \|y\| |\cos \theta| \leq \|x\| \|y\| \cdot 1 = \|x\| \|y\|$$

Wniosek

$$|\langle x, y \rangle| \leq \|x\| \|y\|$$

Równość $\Leftrightarrow |\cos \theta| = 1 \Leftrightarrow \theta \in \{0, \pi\} \Leftrightarrow$ wektory są **współliniowe**.

Dowód nierówności Cauchy'ego–Schwarza (1/2)

Założenia i przypadki brzegowe

Jeśli $y = 0$, to $\langle x, y \rangle = 0$ i nierówność jest spełniona. Dalej zakładamy $y \neq 0$.

Krok 1: funkcja nieujemna

Rozważamy funkcję:

$$f(t) = \|x - ty\|^2 = \langle x - ty, x - ty \rangle \geq 0 \quad \text{dla każdego } t \in \mathbb{R}.$$

Krok 2: rozwinięcie trójkianu

$$f(t) = \langle x, x \rangle - 2t\langle x, y \rangle + t^2\langle y, y \rangle = \|x\|^2 - 2t\langle x, y \rangle + t^2\|y\|^2.$$

To trójkian kwadratowy w t o współczynniku przy t^2 równym $\|y\|^2 > 0$.

Dowód nierówności Cauchy'ego–Schwarza (2/2)

Krok 3: warunek na wyróżnik

Skoro $f(t) \geq 0$ dla każdego t , wyróżnik musi spełniać:

$$\Delta = (-2\langle x, y \rangle)^2 - 4\|x\|^2\|y\|^2 \leq 0.$$

Krok 4: wniosek

$$4\langle x, y \rangle^2 \leq 4\|x\|^2\|y\|^2 \Rightarrow |\langle x, y \rangle| \leq \|x\| \|y\|.$$

Równość zachodzi wtedy i tylko wtedy, gdy

$\Delta = 0$, czyli istnieje t^* takie, że $f(t^*) = 0$, co oznacza $x = t^*y$ — wektory są **liniowo zależne** (współliniowe).

Kąt między wektorami: definicja formalna

Definicja (kąt przez cosinus)

Dla $x, y \in \mathbb{R}^n$, $x \neq 0$, $y \neq 0$ definiujemy:

$$\cos \theta(x, y) := \frac{\langle x, y \rangle}{\|x\| \|y\|}.$$

Na mocy Cauchy'ego–Schwarza:

$$-1 \leq \cos \theta(x, y) \leq 1,$$

więc istnieje $\theta(x, y) \in [0, \pi]$ takie, że powyższa równość zachodzi.

Twierdzenie (postać iloczynu skalarnego)

Dla $x, y \neq 0$ zachodzi:

$$\langle x, y \rangle = \|x\| \|y\| \cos \theta(x, y).$$

Interpretacja geometryczna

- $\theta = 0$ ($\cos \theta = 1$): zgodne kierunki (równoległe).
- $\theta = \frac{\pi}{2}$ ($\cos \theta = 0$): ortogonalne.
- $\theta = \pi$ ($\cos \theta = -1$): przeciwne kierunki.

Most do statystyki: od wektorów danych do korelacji

Model danych (2 zmienne, T obserwacji)

Niech $x = (x_1, \dots, x_T)$ i $y = (y_1, \dots, y_T)$ oznaczają **wycentrowane** obserwacje dwóch zmiennych:

$$\sum_{t=1}^T x_t = 0, \quad \sum_{t=1}^T y_t = 0.$$

Kowariancja empiryczna (zapowiedź Wykładu 3)

$$\widehat{\text{Cov}}(x, y) = \frac{1}{T-1} \sum_{t=1}^T x_t y_t = \frac{1}{T-1} \langle x, y \rangle.$$

Korelacja empiryczna

Odchylenia standardowe:

$$\hat{\sigma}_x = \sqrt{\frac{1}{T-1} \sum_{t=1}^T x_t^2} = \sqrt{\frac{1}{T-1}} \|x\|, \quad \hat{\sigma}_y = \sqrt{\frac{1}{T-1}} \|y\|.$$

META: korelacja jako cosinus kąta (bez metafor)

META-RÓWNOŚĆ (klucz kursu)

Dla wycentrowanych danych $x, y \in \mathbb{R}^T$:

$$\hat{\rho}_{xy} = \frac{\langle x, y \rangle}{\|x\| \|y\|} = \cos \theta(x, y).$$

To jest **równość** wynikająca z definicji, a nie luźna intuicja.

Interpretacja finansowa (co oznacza znak i wartość?)

- $\hat{\rho} \approx 1$ ($\theta \approx 0$): aktywa zachowują się podobnie.
- $\hat{\rho} \approx 0$ ($\theta \approx 90^\circ$): brak zależności liniowej.
- $\hat{\rho} \approx -1$ ($\theta \approx 180^\circ$): zachowanie przeciwne (hedging liniowy).

Uwaga krytyczna (kontrprzykład do omówienia)

$\hat{\rho} = 0$ nie oznacza niezależności. Istnieją zmienne zależne nieliniowo, ale o korelacji 0. To wróci w walidacji modeli oraz w kalibracji (ostatni blok pipeline).

Prognozowania ryzyka zmian dynamiki szeregów czasowych

Geometryczne i algebraiczne aspekty danych

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

2 marca 2026