

Prognostowanie ryzyka zmian dynamiki szeregów czasowych

Przykłady podstawowych metod algebry liniowej
w analizie: szeregów czasowych (TS), DS oraz AI/ML

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

9 marca 2026

Wektor – intuicja i definicja

Intuicja słowna

Wektor to *uporządkowana lista liczb*, która reprezentuje ciąg pomiarów lub obserwacji. Można go wyobrazić sobie jako punkt lub strzałkę w przestrzeni wielowymiarowej.

Definicja formalna

Wektor kolumnowy $\mathbf{v} \in \mathbb{R}^n$:

$$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix}, \quad v_i \in \mathbb{R}$$

Wektor wierszowy: $\mathbf{v}^\top = (v_1, v_2, \dots, v_n)$.

Przykład: Ceny akcji PKN Orlen

Ceny zamknięcia przez 5 dni (w zł):

$$\mathbf{p} = \begin{pmatrix} 100 \\ 102 \\ 99 \\ 105 \\ 103 \end{pmatrix} \in \mathbb{R}^5$$

Każda współrzędna p_t = cena w dniu t .

Cały tydzień notowań = **jeden punkt** w $\mathbb{R}^5$.

Wektor – przykłady

Przykład: Temperatury tygodniowe

Pomiary temperatury przez 7 dni (w °C):

$$\mathbf{T} = \begin{pmatrix} 12 \\ 15 \\ 11 \\ 9 \\ 14 \\ 16 \\ 13 \end{pmatrix} \text{ °C} \in \mathbb{R}^7$$

Każda współrzędna T_t = temperatura w dniu t .

Cały tydzień pomiarów = **jeden punkt** w $\mathbb{R}^7$.

Podsumowanie

Wektor pozwala zakodować **wiele obserwacji** jako *jeden obiekt matematyczny*.

Wymiar n = liczba obserwacji.

Operacje na wektorach $\Rightarrow$ operacje na całych zbiorach danych naraz.

Operacje na wektorach

Dodawanie wektorów

$$\mathbf{v} + \mathbf{w} = \begin{pmatrix} v_1 + w_1 \\ \vdots \\ v_n + w_n \end{pmatrix}$$

Interpretacja: agregacja zwrotów dwóch aktywów.

Mnożenie przez skalar

$$\lambda \mathbf{v} = \begin{pmatrix} \lambda v_1 \\ \vdots \\ \lambda v_n \end{pmatrix}$$

Interpretacja: lewarowanie strategii o czynnik λ .

Przykład: Zwroty portfela

Zwroty PKN Orlen i KGHM w 3 dniach:

$$\mathbf{r}_A = \begin{pmatrix} 2 \\ -3 \\ 6 \end{pmatrix}, \quad \mathbf{r}_B = \begin{pmatrix} 1 \\ 4 \\ -2 \end{pmatrix}$$

Portfel 50/50:

$$\mathbf{p} = 0,5 \mathbf{r}_A + 0,5 \mathbf{r}_B = \begin{pmatrix} 1,5 \\ 0,5 \\ 2,0 \end{pmatrix} \%$$

Średni dzienny zwrot = $\frac{1,5+0,5+2,0}{3} = 1,33\%$.

Transpozycja wektora

Definicja transpozycji

Zamiana wektora kolumnowego na wierszowy:

$$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} \xrightarrow{\top} \mathbf{v}^\top = (v_1, v_2, \dots, v_n)$$

Własność: $(\mathbf{v}^\top)^\top = \mathbf{v}$

Przykład

$$\mathbf{r}_A = \begin{pmatrix} 2 \\ -3 \\ 6 \end{pmatrix} \Rightarrow \mathbf{r}_A^\top = (2, -3, 6)$$

Iloczyn skalarny jako mnożenie macierzowe:

$$\mathbf{r}_A^\top \mathbf{r}_B = (2)(1) + (-3)(4) + (6)(-2) = -22$$

Po co transpozycja?

- Zapis iloczynu skalarnego: $\mathbf{v}^\top \mathbf{w}$
- Budowa macierzy z wektorów wierszowych
- Konwencja zapisu w statystyce i ML

Iloczyn skalarny i norma euklidesowa

Iloczyn skalarny (definicja)

Dla $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^\top \mathbf{w} = \sum_{i=1}^n v_i w_i$$

Forma geometryczna:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \|\mathbf{v}\| \|\mathbf{w}\| \cos \theta$$

Norma euklidesowa

$$\|\mathbf{v}\| = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle} = \sqrt{\sum_{i=1}^n v_i^2}$$

Interpretacja: miara zmienności (volatility) szeregu czasowego.

Przykład: Zwroty dwóch spółek

$$\mathbf{r}_A = \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}, \quad \mathbf{r}_B = \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix}$$

$$\begin{aligned} \langle \mathbf{r}_A, \mathbf{r}_B \rangle &= 1 \cdot 2 + 2 \cdot 1 + (-1) \cdot 3 \\ &= 2 + 2 - 3 = 1 \end{aligned}$$

$$\|\mathbf{r}_A\| = \sqrt{1 + 4 + 1} = \sqrt{6}$$

$$\|\mathbf{r}_B\| = \sqrt{4 + 1 + 9} = \sqrt{14}$$

Zmienność portfela KGHM ($\mathbf{r}_A$):


$$\sigma = \|\mathbf{r}_A\| = \sqrt{6} \approx 2,45\%$$

Korelacja jako cosinus kąta

Definicja

Korelacja liniowa dwóch szeregów:

$$\text{corr}(\mathbf{v}, \mathbf{w}) = \frac{\langle \mathbf{v}, \mathbf{w} \rangle}{\|\mathbf{v}\| \|\mathbf{w}\|} = \cos \theta$$



Im mniejszy θ – większa korelacja

Interpretacja geometryczna

- $\cos \theta = 1$: wektory równoległe – zwroty *identyczne*
- $\cos \theta = 0$: wektory prostopadłe – brak korelacji
- $\cos \theta = -1$: antyrównoległe – *doskonale ujemna* korelacja

Zapis przez iloczyn skalarny

$$\cos \theta = \frac{\mathbf{v}^\top \mathbf{w}}{\|\mathbf{v}\| \|\mathbf{w}\|}$$

Geometria $\Leftrightarrow$ statystyka.

Własność

$-1 \leq \cos \theta \leq 1$ odpowiada zakresowi współczynnika Pearsona.

Korelacja jako cosinus kąta – przykład

Przykład: PKN Orlen vs KGHM

$$\mathbf{r}_A = \begin{pmatrix} 2 \\ 4 \\ -2 \end{pmatrix}, \quad \mathbf{r}_B = \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}$$

$$\langle \mathbf{r}_A, \mathbf{r}_B \rangle = 2 + 8 + 2 = 12$$

$$\|\mathbf{r}_A\| = \sqrt{4 + 16 + 4} = \sqrt{24}$$

$$\|\mathbf{r}_B\| = \sqrt{1 + 4 + 1} = \sqrt{6}$$

$$\cos \theta = \frac{12}{\sqrt{24} \cdot \sqrt{6}} = \frac{12}{\sqrt{144}} = 1$$

Interpretacja

$\mathbf{r}_B = \frac{1}{2}\mathbf{r}_A$ – KGHM porusza się *dokładnie* tak jak Orlen.

Geometrycznie: oba wektory wskazują ten sam kierunek w $\mathbb{R}^3$.

Wniosek praktyczny

Korelacja = 1 oznacza liniową zależność – jedno z aktywów jest *zbędne* w portfelu (brak dywersyfikacji).

Macierz – definicja i dwa sposoby patrzenia

Intuicja

Macierz to prostokątna tabela liczb organizująca relacje między wieloma wektorami. Można na nią patrzeć jako na zbiór kolumn *lub* zbiór wierszy.

Definicja formalna

Macierz $\mathbf{M} \in \mathbb{R}^{m \times n}$:

$$\mathbf{M} = \begin{pmatrix} m_{11} & m_{12} & \cdots & m_{1n} \\ m_{21} & m_{22} & \cdots & m_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ m_{m1} & m_{m2} & \cdots & m_{mn} \end{pmatrix}$$

m wierszy, n kolumn, element (i, j) : m_{ij} .

Dwa sposoby patrzenia

Kolumnowo:

$$\mathbf{M} = [\mathbf{m}_1 \mid \mathbf{m}_2 \mid \cdots \mid \mathbf{m}_n]$$

Każda kolumna = jeden wektor obserwacji.

Wierszowo:

$$\mathbf{M} = \begin{pmatrix} \mathbf{m}_1^\top \\ \vdots \\ \mathbf{m}_m^\top \end{pmatrix}$$

Każdy wiersz = jeden przekrój czasowy.

Dualizm interpretacji

Ta sama macierz: $\text{czas} \leftrightarrow \text{aktywa}$. Zmiana perspektywy = zmiana bazy.

Macierz – przykład finansowy

Macierz zwrotów portfela

3 dni, 2 spółki (A = PKN Orlen, B = KGHM):

$$\mathbf{R} = \begin{pmatrix} 2 & 1 \\ -3 & 4 \\ 6 & -2 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

- **Kolumna 1** = $(2, -3, 6)^\top$: zwroty Orlenu przez 3 dni
- **Kolumna 2** = $(1, 4, -2)^\top$: zwroty KGHM przez 3 dni
- **Wiersz 1** = $(2, 1)$: przekrój rynku w dniu 1

Odczyt wymiarów

$\mathbf{R} \in \mathbb{R}^{3 \times 2}$:

- $m = 3$ wiersze = dni
- $n = 2$ kolumny = spółki
- Element $r_{21} = -3$: zwrot Orlenu w dniu 2

Dualizm interpretacji

Ta sama macierz: *czas* $\leftrightarrow$ *aktywa*. Zmiana perspektywy = zmiana bazy.

Mnożenie macierzy – złożenie przekształceń

Definicja

$\mathbf{A} \in \mathbb{R}^{m \times k}$, $\mathbf{B} \in \mathbb{R}^{k \times n}$:

$$(\mathbf{AB})_{ij} = \sum_{l=1}^k a_{il} b_{lj}$$

$$\underbrace{\mathbf{A}}_{m \times k} \cdot \underbrace{\mathbf{B}}_{k \times n} = \underbrace{\mathbf{AB}}_{m \times n}$$

Nieprzemienność: $\mathbf{AB} \neq \mathbf{BA}$ (ogólnie)!

Warunek zgodności wymiarów

$$(m \times k) \cdot (k \times n) = (m \times n)$$

Wewnętrzne wymiary muszą być równe!

Przykłady:

- $(3 \times 2) \cdot (2 \times 4) = (3 \times 4) \checkmark$
- $(3 \times 2) \cdot (3 \times 4)$ – **niemożliwe**
- $(1 \times n) \cdot (n \times 1) = (1 \times 1)$ – iloczyn skalarny

Mnożenie przez wektor

$\mathbf{M}\mathbf{v}$ = kombinacja liniowa kolumn $\mathbf{M}$:

$$\mathbf{M}\mathbf{v} = v_1 \mathbf{m}_1 + \cdots + v_n \mathbf{m}_n$$

Mnożenie macierzy – przykład: zwrot portfela

Przykład: Zwrot portfela

$$\mathbf{R} = \begin{pmatrix} 2 & 1 \\ -3 & 4 \\ 6 & -2 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} 0,5 \\ 0,5 \end{pmatrix}$$

$$\mathbf{R}\mathbf{w} = \begin{pmatrix} 2 \cdot 0,5 + 1 \cdot 0,5 \\ -3 \cdot 0,5 + 4 \cdot 0,5 \\ 6 \cdot 0,5 + (-2) \cdot 0,5 \end{pmatrix} = \begin{pmatrix} 1,5 \\ 0,5 \\ 2,0 \end{pmatrix}$$

Interpretacja

$\mathbf{R}\mathbf{w}$ = dzienne zwroty portfela 50/50 (Orlen + KGHM) przez 3 dni.

Geometrycznie: $\mathbf{w}$ wybiera *kombinację liniową kolumn* $\mathbf{R}$.

Uogólnienie

Wiele portfeli jednocześnie: $\mathbf{R}\mathbf{W}$, $\mathbf{W} \in \mathbb{R}^{2 \times p}$.
Każda kolumna $\mathbf{W}$ = jeden portfel.

Proste operacje algebraiczne na macierzach

Dodawanie macierzy

$$(\mathbf{A} + \mathbf{B})_{ij} = a_{ij} + b_{ij} \quad (\text{wymiarzy identyczne!})$$

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} + \begin{pmatrix} 5 & 0 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$$

Interpretacja: suma strategii inwestycyjnych.

Transpozycja macierzy

$$(\mathbf{A}^T)_{ij} = a_{ji} - \text{zamiana wierszy i kolumn:}$$

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}$$

Mnożenie przez skalar

$$(c\mathbf{A})_{ij} = c \cdot a_{ij}$$

$$3 \cdot \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 3 & 6 \\ 9 & 12 \end{pmatrix}$$

Interpretacja: lewarowanie macierzy zwrotów.

Algebra transpozycji

$$(c\mathbf{A})^T = c\mathbf{A}^T$$

$$(\mathbf{A} + \mathbf{B})^T = \mathbf{A}^T + \mathbf{B}^T$$

$$(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$$

Uwaga: w iloczynie kolejność się odwraca!

Operacje na macierzach – przykład finansowy

Macierz korelacji jest symetryczna

$$\mathbf{C} = \begin{pmatrix} 1,00 & 0,65 & 0,30 \\ 0,65 & 1,00 & 0,45 \\ 0,30 & 0,45 & 1,00 \end{pmatrix}$$

(Orlen, KGHM, Pekao)

$\mathbf{C} = \mathbf{C}^\top$, bo $\text{corr}(A, B) = \text{corr}(B, A)$.

Dlaczego symetria ma znaczenie?

- Wystarczy przechować tylko *górny trójkąt* macierzy
- Macierze symetryczne mają *rzeczywiste* wartości własne
- Warunek konieczny poprawnie zbudowanej macierzy korelacji

Uwaga

W iloczynie: $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$ – kolejność się odwraca!

Kombinacje liniowe i portfel inwestycyjny

Definicja kombinacji liniowej

$$c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 + \dots + c_k \mathbf{v}_k, \quad c_i \in \mathbb{R}$$

Rozpiętość (Span)

$$\text{Span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \left\{ \sum_i c_i \mathbf{v}_i : c_i \in \mathbb{R} \right\}$$

Połączenie z finansami

- Portfel = kombinacja liniowa wektorów zwrotów aktywów
- Long-only: $w_i \geq 0$, $\sum w_i = 1$
- Spółki tej samej branży – mały span, podobne zachowanie

Geometria spanu

- $\text{Span}\{\mathbf{v}_1\}$: prosta przez 0
- $\text{Span}\{\mathbf{v}_1, \mathbf{v}_2\}$: płaszczyzna (gdy niezależne)
- $\text{Span}\{\mathbf{e}_1, \dots, \mathbf{e}_n\} = \mathbb{R}^n$

Baza kanoniczna $\mathbb{R}^n$

Wektory $\mathbf{e}_i$ mają 1 na pozycji i , resztę 0:

$$\mathbf{e}_i = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} \leftarrow i$$

np. $\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, $\mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ w $\mathbb{R}^2$.

Kombinacje liniowe – przykład: portfel trzech spółek

Portfel trzech spółek

$$\mathbf{r}_A = \begin{pmatrix} 4 \\ -2 \\ 3 \end{pmatrix}, \mathbf{r}_B = \begin{pmatrix} 1 \\ 5 \\ -1 \end{pmatrix}, \mathbf{r}_C = \begin{pmatrix} 2 \\ 0 \\ 4 \end{pmatrix}$$

Wagi: $w_A = 0,4$, $w_B = 0,3$, $w_C = 0,3$:

$$\begin{aligned} \mathbf{p} &= 0,4\mathbf{r}_A + 0,3\mathbf{r}_B + 0,3\mathbf{r}_C \\ &= \begin{pmatrix} 1,6 + 0,3 + 0,6 \\ -0,8 + 1,5 + 0 \\ 1,2 - 0,3 + 1,2 \end{pmatrix} = \begin{pmatrix} 2,5 \\ 0,7 \\ 2,1 \end{pmatrix} \end{aligned}$$

Interpretacja

- Dzień 1: +2,5%
- Dzień 2: +0,7%
- Dzień 3: +2,1%

Wniosek

Każdy portfel to *jeden punkt* w przestrzeni rozpiętej przez wektory zwrotów.

Dywersyfikacja = wybór optymalnego punktu w tym spanie.

Niezależność liniowa i wymiar przestrzeni

Definicja

Wektory $v_1, \dots, v_k$ są **liniowo niezależne**, gdy:

$$c_1 v_1 + \dots + c_k v_k = \mathbf{0} \Rightarrow c_1 = \dots = c_k = 0$$

Wymiar i baza

Baza = maksymalny zbiór liniowo niezależnych wektorów rozpiętych na przestrzeń.

$$\dim(\mathbb{R}^n) = n$$

Intuicja geometryczna

- Wektory *zależne*: jeden leży w spanie pozostałych – zbędny
- Wektory *niezależne*: każdy wnosi nowy kierunek w przestrzeni
- Baza kanoniczna $\mathbb{R}^2$: $e_1 = (1, 0)^\top$, $e_2 = (0, 1)^\top$

Finansowy sens

- Liniowa zależność aktywów = możliwy arbitraż
- 5 spółek tej samej branży może mieć efektywny wymiar < 5
- Multikolinearność w modelach czynnikowych

Niezależność liniowa – przykłady

Wektory zależne

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 3 \\ 6 \end{pmatrix}$$

$c_1 + 3c_2 = 0$, $2c_1 + 6c_2 = 0$ ma rozwiązanie niezerowe: $c_1 = 3$, $c_2 = -1$.

$$\Rightarrow \mathbf{v}_2 = 3\mathbf{v}_1$$

Wniosek: liniowo *zależne*.

Spółka $B = 3 \times$ spółka A – jedna jest zbędna w portfelu.

Wektory niezależne

$$\mathbf{u}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \mathbf{u}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Jedyne rozwiązanie $c_1\mathbf{u}_1 + c_2\mathbf{u}_2 = \mathbf{0}$:
 $c_1 = c_2 = 0$.

Baza kanoniczna $\mathbb{R}^2$: dwa niezależne kierunki ryzyka.

Reguła praktyczna

Sprawdź macierz korelacji – wysokie korelacje sygnalizują bliską zależność liniową.

Przekształcenia liniowe – definicja i własności

Intuicja

Przekształcenie liniowe zachowuje dodawanie i mnożenie przez skalar – proste struktury nie „zakrzywiają się”.

Definicja formalna

$T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ jest liniowe, gdy:

$$T(\mathbf{v} + \mathbf{w}) = T(\mathbf{v}) + T(\mathbf{w})$$

$$T(c\mathbf{v}) = cT(\mathbf{v})$$

Fundamentalna zasada

Każda macierz $\mathbf{M} \in \mathbb{R}^{m \times n}$ definiuje przekształcenie liniowe:

$$T(\mathbf{v}) = \mathbf{M}\mathbf{v}$$

I odwrotnie: każde T liniowe $\mathbb{R}^n \rightarrow \mathbb{R}^m$ ma swoją macierz.

Konsekwencje liniowości

- $T(\mathbf{0}) = \mathbf{0}$ zawsze
- Złożenie = mnożenie macierzy:
 $T_2(T_1(\mathbf{v})) = \mathbf{M}_2\mathbf{M}_1\mathbf{v}$
- Portfel = $\sum w_i \mathbf{r}_i$ jest liniowy w wagach

Granica liniowości

Opcje finansowe, modele nieliniowe (GARCH) – *nie* są przekształceniami liniowymi.

Przekształcenia liniowe – przykład: filtr MA

Filtr średniej ruchomej

Średnia z 2 ostatnich obserwacji:

$$T \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} \frac{x_1+x_2}{2} \\ \frac{x_2+x_3}{2} \\ \frac{x_3+x_4}{2} \end{pmatrix}$$

Macierz filtra:

$$\mathbf{M}_{\text{MA}} = \frac{1}{2} \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

Weryfikacja liniowości

Niech $\mathbf{x} = (10, 12, 9, 11)^\top$:

$$\mathbf{M}_{\text{MA}}\mathbf{x} = \begin{pmatrix} 11 \\ 10,5 \\ 10 \end{pmatrix}$$

Wygładzony przebieg kursu.


Zastosowania w finansach

- Wygładzanie kursów giełdowych
- Sygnały MA(20), MA(200)
- Każdy filtr liniowy = macierz Toeplitza

Macierz jako przekształcenie geometryczne

Rodzaje przekształceń (2×2)

- **Skalowanie:** $\begin{pmatrix} s_1 & 0 \\ 0 & s_2 \end{pmatrix}$ – różna zmienność każdego aktywa
- **Obrót o θ :** $\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$ – rotacja układu (PCA)
- **Rzutowanie:** $\mathbf{P}^2 = \mathbf{P}$ – redukcja wymiaru
- **Macierz jednostkowa:** $\mathbf{I}v = v$



Złożenie przekształceń

$$\mathbf{R}_\phi \mathbf{R}_\theta = \mathbf{R}_{\theta+\phi}$$

Kolejność mnożenia macierzy = kolejność stosowania przekształceń.

Macierz kowariancji jako przekształcenie

$$\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 9 \end{pmatrix}$$

Transformuje elipsę rozkładu zwrotów.
 $\sigma_A^2 = 4$, $\sigma_B^2 = 9$, $\text{Cov}(A, B) = 2$.

Macierz jako przekształcenie – przykład finansowy

Skalowanie zmienności

$$\mathbf{S} = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}, \quad \mathbf{r} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

$$\mathbf{S}\mathbf{r} = \begin{pmatrix} 2 \\ 6 \end{pmatrix}$$

Spółka A: 2× zwrot, spółka B: 3× zwrot.

Geometria Σ

- Osie elipsy = wektory własne Σ
- Długości osi = $\sqrt{\lambda_i}$
- Im bardziej wydłużona elipsa, tym silniejsza korelacja aktywów

Zastosowanie w PCA

Obrót do układu wektorów własnych Σ =
wyznaczenie *niezależnych czynników ryzyka*.

Przestrzeń kolumnowa i jądro macierzy

Przestrzeń kolumnowa (obraz)

$$\text{Im}(\mathbf{M}) = \{\mathbf{M}\mathbf{v} : \mathbf{v} \in \mathbb{R}^n\} \subseteq \mathbb{R}^m$$

Wymiar = $\text{rank}(\mathbf{M})$.

Intuicja: zbiór wszystkich możliwych wyników przekształcenia.

Jądro (ker)

$$\ker(\mathbf{M}) = \{\mathbf{v} \in \mathbb{R}^n : \mathbf{M}\mathbf{v} = \mathbf{0}\}$$

Twierdzenie o rzędzie:

$$\text{rank}(\mathbf{M}) + \dim(\ker(\mathbf{M})) = n$$

Portfel market-neutral

$\mathbf{w} \in \ker(\mathbf{X}) \Rightarrow$ portfel z $\beta = 0$: brak ekspozycji na czynnik rynkowy.

Intuicja geometryczna

- $\text{Im}(\mathbf{M})$: dokąd przekształcenie *może dotrzeć*
- $\ker(\mathbf{M})$: co przekształcenie *unicestwia*
- $\text{rank} = n$: macierz odwracalna, $\ker = \{\mathbf{0}\}$

Związek z układami równań

$\mathbf{M}\mathbf{x} = \mathbf{b}$ ma rozwiązanie $\Leftrightarrow \mathbf{b} \in \text{Im}(\mathbf{M})$.

Przestrzeń kolumnowa i jądro – przykład

Rank i jądro

$$\mathbf{M} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}, \quad \det(\mathbf{M}) = 0$$

$$\Rightarrow \text{rank}(\mathbf{M}) = 1, \dim(\ker) = 1.$$

$$\mathbf{M}\mathbf{v} = \mathbf{0} : \quad v_1 + 2v_2 = 0 \Rightarrow \mathbf{v} = t \begin{pmatrix} 2 \\ -1 \end{pmatrix}$$

Interpretacja finansowa

Portfel $\mathbf{v} = (2, -1)^\top$: długa 2 jedn. spółki A, krótka 1 jedn. spółki B.

$\mathbf{M}\mathbf{v} = \mathbf{0}$: portfel daje **zerowy zwrot w każdym dniu**.

Jest to strategia *market-neutral* lub arbitrażu statystycznego.

Wniosek

$\det(\mathbf{M}) = 0$: kolumny liniowo zależne – jedna spółka jest *repliką* drugiej.

Wyznacznik macierzy

Intuicja geometryczna

Wyznacznik mierzy, jak bardzo przekształcenie rozciąga lub zwija przestrzeń.

- 2×2 : pole równoległoboku
- 3×3 : objętość równoległościanu
- $\det = 0$: macierz zdegenerowana

Wzór dla 2×2

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$$

Interpretacja znaku i wartości

- $|\det| > 1$: przekształcenie *powiększa* obszar
- $|\det| < 1$: *kurczy* obszar
- $\det < 0$: odwrócenie orientacji
- $\det = 0$: utrata wymiaru, macierz nieodwracalna

Macierz odwrotna i własności wyznacznika

Definicja macierzy odwrotnej

Macierz $\mathbf{A}^{-1}$ jest **odwrotna** do $\mathbf{A}$, gdy:

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}$$

gdzie $\mathbf{I}$ to macierz jednostkowa (jedyńki na przekątnej, zera poza nią).

Wzór jawny dla 2×2

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Własności wyznacznika

$$\det(\mathbf{AB}) = \det \mathbf{A} \cdot \det \mathbf{B}$$

$$\det(\mathbf{A}^{\top}) = \det(\mathbf{A})$$

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}$$

Warunek istnienia $\mathbf{A}^{-1}$

$\mathbf{A}^{-1}$ istnieje $\Leftrightarrow \det \mathbf{A} \neq 0$.

Wyznacznik 3×3 — rozwinięcie Laplace'a

Rozwinięcie Laplace'a (wg 1. wiersza)

$$\det \mathbf{A} = \sum_{j=1}^3 (-1)^{1+j} a_{1j} M_{1j}$$

gdzie M_{1j} to wyznacznik podmacierzy powstałej przez usunięcie wiersza 1 i kolumny j .

Macierz znaków cofaktorów

$$\begin{pmatrix} + & - & + \\ - & + & - \\ + & - & + \end{pmatrix}$$

Nasza macierz

$$\mathbf{A} = \begin{pmatrix} \mathbf{2} & -\mathbf{1} & \mathbf{3} \\ 0 & 4 & -2 \\ 1 & 5 & 6 \end{pmatrix}$$

Rozwijamy wzdłuż **pierwszego wiersza**
(pogrubione elementy):

$$\det \mathbf{A} = \mathbf{2} M_{11} - (-1) M_{12} + \mathbf{3} M_{13}$$

Wyznacznik 3×3 — obliczenia

Krok 1: minory 2×2

$$M_{11} = \det \begin{pmatrix} 4 & -2 \\ 5 & 6 \end{pmatrix} = 24 - (-10) = 34$$

$$M_{12} = \det \begin{pmatrix} 0 & -2 \\ 1 & 6 \end{pmatrix} = 0 - (-2) = 2$$

$$M_{13} = \det \begin{pmatrix} 0 & 4 \\ 1 & 5 \end{pmatrix} = 0 - 4 = -4$$

Krok 2: składamy wynik

$$\begin{aligned} \det \mathbf{A} &= 2 \cdot 34 + 1 \cdot 2 + 3 \cdot (-4) \\ &= 68 + 2 - 12 \\ &= \mathbf{58} \end{aligned}$$

Wniosek

$\det \mathbf{A} = 58 \neq 0$, zatem:

- macierz $\mathbf{A}$ jest **odwracalna**
- przekształcenie *powiększa* objętości 58-krotnie
- orientacja zachowana ($\det > 0$)

Wyznacznik – przykład: macierz korelacji

Macierz korelacji 2 aktywów

$$\mathbf{C} = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}, \quad \det \mathbf{C} = 1 - r^2$$

- $r = 0$: $\det = 1$ – aktywa niezależne
- $r = 0,65$: $\det = 0,58$ – pewna korelacja
- $r = 1$: $\det = 0$ – **idealna korelacja**, macierz osobliwa, jeden zasób zbędny

Wniosek dla OLS

$\det(\mathbf{C}) = 0 \Rightarrow$ **kolinearność**.

Estymator: $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ przestaje istnieć, bo $\mathbf{X}^\top \mathbf{X}$ nieodwracalna.

Im bliżej zera...

... tym bardziej zdegenerowana macierz korelacji i mniej stabilne szacunki modelu.

Macierz odwrotna i układy równań

Definicja

$\mathbf{A} \in \mathbb{R}^{n \times n}$ ma odwrotność $\mathbf{A}^{-1}$, gdy:

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$$

Istnieje $\Leftrightarrow \det \mathbf{A} \neq 0$.

Wzór dla 2×2

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Rozwiązanie układu równań

$$\mathbf{A}\mathbf{x} = \mathbf{b} \Rightarrow \mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

Zamiast dzielić przez $\mathbf{A}$, mnożymy przez $\mathbf{A}^{-1}$ z lewej strony.

Optymalizacja Markowitza

$$\mathbf{w}^* = \Sigma^{-1}\boldsymbol{\mu}$$

Σ — macierz kowariancji zwrotów,
 $\boldsymbol{\mu}$ — wektor oczekiwanych zwrotów.

Macierz odwrotna — własności i ograniczenia

Własności

$$(\mathbf{A}^{-1})^{-1} = \mathbf{A}$$

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$$

$$(\mathbf{A}^{\top})^{-1} = (\mathbf{A}^{-1})^{\top}$$

Kolejność ma znaczenie

Ogólnie $\mathbf{A}^{-1}\mathbf{B}^{-1} \neq \mathbf{B}^{-1}\mathbf{A}^{-1}$,
dlatego przy odwracaniu iloczynu **odwracamy**
kolejność czynników.

Gdy odwrotność nie istnieje

- $\det \mathbf{A} = 0$ — macierz osobliwa
- Multikolinearność w danych (np. silnie skorelowane aktywa)

⇒ Użyj **pseudoodwrotności**
Moore'a-Penrose'a:

$$\mathbf{A}^{+} = \lim_{\delta \rightarrow 0} (\mathbf{A}^{\top} \mathbf{A} + \delta \mathbf{I})^{-1} \mathbf{A}^{\top}$$

Macierz odwrotna – przykład: układ równań

Model prognozowania

Szukamy współczynników β spełniających $\mathbf{X}\beta = \hat{y}$:

$$\underbrace{\begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}}_{\mathbf{X}} \underbrace{\begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}}_{\beta} = \underbrace{\begin{pmatrix} 5 \\ 10 \end{pmatrix}}_{\hat{y}}$$

Interpretacja współczynników

- $\beta_1 = 1$: współczynnik trendu
każda jednostka czasu dodaje +1 do prognozy
- $\beta_2 = 3$: współczynnik sezonowości
każda jednostka czynnika sezonowego dodaje +3 do prognozy

Obliczenia

$$\det \mathbf{X} = 6 - 1 = 5 \neq 0$$

$$\mathbf{X}^{-1} = \frac{1}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix}$$

$$\beta = \mathbf{X}^{-1}\hat{y} = \frac{1}{5} \begin{pmatrix} 15 - 10 \\ -5 + 20 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$$

Weryfikacja

$$\mathbf{X}\beta = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 5 \\ 10 \end{pmatrix} = \hat{y} \checkmark$$

Macierz odwrotna a prognozowanie

Ogólny model liniowy

Mamy n obserwacji i p cech:

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\boldsymbol{\beta}}_{p \times 1} = \underbrace{\mathbf{y}}_{n \times 1}$$

Gdy $\mathbf{X}$ jest kwadratowa i odwracalna:

$$\boldsymbol{\beta} = \mathbf{X}^{-1} \mathbf{y}$$

Dla nowych danych $\mathbf{x}_{\text{new}}$:

$$\hat{y}_{\text{new}} = \mathbf{x}_{\text{new}}^{\top} \boldsymbol{\beta}$$

Przypadek ogólny: $n > p$

Gdy więcej obserwacji niż parametrów, używamy **pseudoodwrotności**:

$$\boldsymbol{\beta} = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{y}$$

Schemat prognozowania

- 1 **Dane historyczne** $(\mathbf{X}, \mathbf{y})$
np. notowania, wskaźniki makro
- 2 **Wyznaczyć** $\boldsymbol{\beta} = \mathbf{X}^{-1} \mathbf{y}$
kalibracja modelu
- 3 **Prognoza** dla nowych danych:
 $\hat{y} = \mathbf{x}_{\text{new}}^{\top} \boldsymbol{\beta}$
np. jutrzejszy kurs akcji

Kiedy model zawodzi?

- $\det(\mathbf{X}^{\top} \mathbf{X}) = 0$: multikolinearność cech
⇒ Regularyzacja (Ridge): $(\mathbf{X}^{\top} \mathbf{X} + \lambda \mathbf{I})^{-1}$

Macierze symetryczne – kowariancja i korelacja

Definicja

$\mathbf{A} = \mathbf{A}^\top$, tzn. $a_{ij} = a_{ji}$.

Macierz kowariancji

$$\Sigma_{ij} = \text{Cov}(X_i, X_j)$$

Symetria: $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i) \Rightarrow \Sigma = \Sigma^\top$.

Dodatnio półokreślona (PSD):

$$\mathbf{v}^\top \Sigma \mathbf{v} \geq 0 \quad \forall \mathbf{v} \in \mathbb{R}^n$$

Twierdzenie spektralne

$$\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top$$

$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$, $\mathbf{Q}$ ortogonalna.

Dlaczego PSD ma znaczenie?

Wariancja każdego portfela jest nieujemna:

$$\sigma_P^2 = \mathbf{w}^\top \Sigma \mathbf{w} \geq 0$$

Twierdzenie spektralne w PCA

Rozkład $\Sigma = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top$ daje *niezależne czynniki ryzyka* (kolumny $\mathbf{Q}$) i ich wariancje (λ_i).

Związek z korelacją

$$\Sigma = \mathbf{D} \mathbf{C} \mathbf{D}$$

$\mathbf{D} = \text{diag}(\sigma_1, \dots, \sigma_n)$, $\mathbf{C}$ – macierz korelacji.

Macierz kowariancji – przykład obliczeniowy

Dane: odchylenia od średniej

Obserwujemy temperaturę i wilgotność przez 3 dni.
Kolumny macierzy $\mathbf{D}$ to *odchylenia od średniej*:

$$\mathbf{D} = \begin{pmatrix} 2 & 5 \\ -1 & 3 \\ 4 & -2 \end{pmatrix}$$

kol. 1: odchyl. temp. ($^{\circ}\text{C}$), kol. 2: odchyl. wilgotności (%)

Wzór na macierz kowariancji

Dla $n = 3$ obserwacji (dzielimy przez $n - 1 = 2$):

$$\mathbf{\Sigma} = \frac{1}{n-1} \mathbf{D}^{\top} \mathbf{D} = \frac{1}{2} \mathbf{D}^{\top} \mathbf{D}$$

$$\Sigma_{11} = \frac{2^2 + (-1)^2 + 4^2}{2} = \frac{21}{2} = 10,5$$

Co oznaczają elementy $\mathbf{\Sigma}$?

- **Przekątna** – wariancje zmiennych:

$\Sigma_{11} = 10,5$ – rozrzut temperatury

$\Sigma_{22} = 19$ – rozrzut wilgotności

- **Poza przekątną** – kowariancje:

$\Sigma_{12} = -0,5 < 0$

gdy temperatura rośnie powyżej średniej,
wilgotność *spada* poniżej swojej średniej – i
odwrotnie

Symetria i dodatnia półokreśloność

$$\Sigma_{12} = \Sigma_{21} = -0,5 \checkmark$$

Zawsze $\mathbf{\Sigma} = \mathbf{\Sigma}^{\top}$ oraz $\mathbf{w}^{\top} \mathbf{\Sigma} \mathbf{w} \geq 0$ dla każdego portfela $\mathbf{w}$.

Macierz kowariancji – obliczenie $\mathbf{D}^\top \mathbf{D}$ (1/2)

Krok 1: transpozycja $\mathbf{D}$

$$\mathbf{D} = \begin{pmatrix} 2 & 5 \\ -1 & 3 \\ 4 & -2 \end{pmatrix}, \quad \mathbf{D}^\top = \begin{pmatrix} 2 & -1 & 4 \\ 5 & 3 & -2 \end{pmatrix}$$

Wymiary: $\mathbf{D}$ jest 3×2 , więc $\mathbf{D}^\top$ jest 2×3 ,
a wynik $\mathbf{D}^\top \mathbf{D}$ będzie 2×2 .

Krok 2: setup iloczynu

$$\mathbf{D}^\top \mathbf{D} = \begin{pmatrix} 2 & -1 & 4 \\ 5 & 3 & -2 \end{pmatrix} \begin{pmatrix} 2 & 5 \\ -1 & 3 \\ 4 & -2 \end{pmatrix} = \begin{pmatrix} ? & ? \\ ? & ? \end{pmatrix}$$

Każdy element (i, j) to iloczyn skalarny i -tego wiersza $\mathbf{D}^\top$ z j -tą kolumną $\mathbf{D}$.

Przypomnienie: iloczyn skalarny

$$\langle \mathbf{u}, \mathbf{v} \rangle = \sum_k u_k v_k$$

np. dla pierwszego wiersza i pierwszej kolumny:

$$\langle (2, -1, 4), (2, -1, 4) \rangle = 4 + 1 + 16$$

Dlaczego $\mathbf{D}^\top \mathbf{D}$?

Element $(\mathbf{D}^\top \mathbf{D})_{ij}$ to kowariancja
(nieznormalizowana) między i -tą a j -tą zmienną.

Przekątna: sumy kwadratów odchyłeń

Poza przekątną: sumy iloczynów odchyłeń

Macierz kowariancji – obliczenie $\mathbf{D}^\top \mathbf{D}$ (2/2)

Element (1, 1): wariancja temperatury

$$(\mathbf{D}^\top \mathbf{D})_{11} = 2 \cdot 2 + (-1) \cdot (-1) + 4 \cdot 4 = 4 + 1 + 16 = 21$$

Elementy (1, 2) i (2, 1): kowariancja

$$(\mathbf{D}^\top \mathbf{D})_{12} = 2 \cdot 5 + (-1) \cdot 3 + 4 \cdot (-2) = 10 - 3 - 8 = -1$$

$$(\mathbf{D}^\top \mathbf{D})_{21} = (\mathbf{D}^\top \mathbf{D})_{12} = -1 \quad (\text{symetria})$$

Element (2, 2): wariancja wilgotności

$$(\mathbf{D}^\top \mathbf{D})_{22} = 5 \cdot 5 + 3 \cdot 3 + (-2) \cdot (-2) = 25 + 9 + 4 = 38$$

Krok 3: składamy i skalujemy

$$\mathbf{D}^\top \mathbf{D} = \begin{pmatrix} 21 & -1 \\ -1 & 38 \end{pmatrix}$$

Dzielimy przez $n - 1 = 2$:

$$\boldsymbol{\Sigma} = \frac{1}{2} \begin{pmatrix} 21 & -1 \\ -1 & 38 \end{pmatrix} = \begin{pmatrix} 10,5 & -0,5 \\ -0,5 & 19 \end{pmatrix}$$

Interpretacja wyniku

- $\Sigma_{11} = 10,5$ – wariancja temperatury
- $\Sigma_{22} = 19$ – wariancja wilgotności
- $\Sigma_{12} = -0,5$ – ujemna kowariancja: wzrost temp. $\Rightarrow$ spadek wilgotności

Macierz kowariancji – co nam mówi o ryzyku?

Od danych meteorologicznych do finansów

Ta sama struktura Σ opisuje **ryzyko portfela**:

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$$

- σ_i^2 – wariancja zwrotu i -tego aktywa
- σ_{12} – kowariancja między aktywami
- $\rho_{12} = \frac{\sigma_{12}}{\sigma_1 \sigma_2}$ – korelacja ($\in [-1, 1]$)

Ryzyko portfela

Dla portfela $w = (w_1, w_2)^\top$:

$$\sigma_P^2 = w^\top \Sigma w = w_1^2 \sigma_1^2 + 2w_1 w_2 \sigma_{12} + w_2^2 \sigma_2^2$$

Ujemna kowariancja ($\sigma_{12} < 0$) **redukuje** ryzyko portfela.

Dywersyfikacja a kowariancja

- $\rho = +1$: aktywa poruszają się *identycznie* – brak dywersyfikacji
- $\rho = 0$: brak związku liniowego – dywersyfikacja częściowa
- $\rho = -1$: ruchy przeciwne – *pełna* dywersyfikacja, można zbliżyć ryzyko do 0

Optymalizacja Markowitza

Minimalizujemy $w^\top \Sigma w$ przy zadanym oczekiwanym zwrocie.

Rozwiązanie: $w^* = \Sigma^{-1} \mu$
– stąd kluczowa rola odwrotności Σ

Przykłady zastosowań macierzy do analizy danych z szeregów czasowych

Przykłady zastosowań macierzy do analizy danych z szeregów czasowych

Część I. Przygotowanie danych

- 1 Normalizacja Min–Max
- 2 Centrowanie
- 3 Standaryzacja
- 4 Standaryzacja z parametrami referencyjnymi

Część II. Czas i dynamika

- 1 Operator przesunięcia
- 2 Różnicowanie
- 3 SMA i EMA
- 4 AR, MA, ARMA, pierwsze podejście do GARCH

Idea przewodnia

- Zaczynamy od prostych operacji na wartościach danych, a dopiero potem przechodzimy do operacji wykorzystujących strukturę czasu.
- Analogiczna logika prowadzi później do filtrów, modeli ARMA, modeli zmienności typu GARCH i w dalszym ciągu do bardzo zaawansowanych metod analizy szeregów czasowych.

Szereg czasowy jako wektor

Punkt wyjścia

Traktujemy szereg czasowy jako wektor


$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n.$$

Każda operacja tworzy nowy wektor:


$$\mathbf{x} \mapsto \mathbf{y}.$$

Dwie klasy operacji

- **operacje na skali i poziomie:** Min-Max, centrowanie, standaryzacja,
- **operacje czasowe:** przesunięcie, różnicowanie, wygładzanie.



Pipeline prezentacji przykładów zastosowań macierz do analizy danych z szeregów czasowych



Najważniejsza myśl

Szereg czasowy można traktować jako wektor danych, a analizę jako ciąg coraz bogatszych transformacji tego wektora.

Operacje przygotowania danych

Przykład 1: Normalizacja Min–Max

Formalna definicja

Dla szeregu $\mathbf{x} = (x_1, \dots, x_n)^\top$ definiujemy

$$x_{\min} = \min_t x_t, \quad x_{\max} = \max_t x_t.$$

Następnie

$$y_t = \frac{x_t - x_{\min}}{x_{\max} - x_{\min}}.$$

Wektorowo:

$$\mathbf{y} = \frac{1}{x_{\max} - x_{\min}} \mathbf{x} - \frac{x_{\min}}{x_{\max} - x_{\min}} \mathbf{1}.$$

Intuicja

Przeskalowujemy wszystkie dane do przedziału $[0, 1]$, zachowując ich relatywne położenie.

Normalizacja Min–Max – przykład rachunkowy

Mała próbka danych


$$\mathbf{x} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix}, \quad x_{\min} = 10, \quad x_{\max} = 15.$$

Zatem

$$\mathbf{y} = \frac{1}{5} \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix} - 2 \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0.4 \\ 1 \\ 0.6 \end{pmatrix}.$$

Interpretacja

- najmniejsza wartość trafia do 0,
- największa trafia do 1,
- pozostałe lądują pomiędzy nimi.



Przykład 2: Centrowanie danych

Formalna definicja

Średnia szeregu wynosi

$$\bar{x} = \frac{1}{n} \mathbf{1}^\top \mathbf{x}.$$

Szereg scentrowany:

$$\mathbf{y} = \mathbf{x} - \bar{x} \mathbf{1}.$$

Po podstawieniu wzoru na średnią:

$$\mathbf{y} = \left(\mathbf{I} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \right) \mathbf{x}.$$

Macierz

$$\mathbf{C} := \mathbf{I} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top$$

nazywamy **macierzą centrowania**.

Intuicja

Odejmujemy od każdej obserwacji wspólny poziom średni, więc nowy szereg ma średnią równą zero.

Centrowanie – przykład rachunkowy

Obliczenia

Dla

$$\mathbf{x} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix}$$

otrzymujemy

$$\bar{x} = \frac{10 + 12 + 15 + 13}{4} = 12.5.$$

Zatem

$$\mathbf{y} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix} - 12.5 \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -2.5 \\ -0.5 \\ 2.5 \\ 0.5 \end{pmatrix}.$$

Macierz centrowania dla $n = 4$

$$\mathbf{C} = \begin{pmatrix} \frac{3}{4} & -\frac{1}{4} & -\frac{1}{4} & -\frac{1}{4} \\ -\frac{1}{4} & \frac{3}{4} & -\frac{1}{4} & -\frac{1}{4} \\ -\frac{1}{4} & -\frac{1}{4} & \frac{3}{4} & -\frac{1}{4} \\ -\frac{1}{4} & -\frac{1}{4} & -\frac{1}{4} & \frac{3}{4} \end{pmatrix}$$

$$\mathbf{C}\mathbf{x} = \begin{pmatrix} -2.5 \\ -0.5 \\ 2.5 \\ 0.5 \end{pmatrix}$$

Przykład 3: Standaryzacja Z-score

Formalna definicja

Definiujemy

$$z_t = \frac{x_t - \bar{x}}{s},$$

gdzie

$$s = \sqrt{\frac{1}{n} \sum_{t=1}^n (x_t - \bar{x})^2}.$$

Wektorowo zapisujemy to jako

$$\mathbf{z} = \frac{1}{s} \mathbf{C} \mathbf{x}.$$

Intuicja

Najpierw przesuwamy dane tak, by miały średnią 0, a potem skalujemy je tak, by ich rozrzut był porównywalny między szeregami.

Uwaga formalna

Jeśli s liczymy z tego samego szeregu, to cała procedura nie jest globalnie liniowa, ale nadal daje się wygodnie zapisać w rachunku macierzowym.

Standaryzacja Z-score – przykład rachunkowy

Obliczenia

Mamy już

$$\mathbf{C}\mathbf{x} = \begin{pmatrix} -2.5 \\ -0.5 \\ 2.5 \\ 0.5 \end{pmatrix}.$$

Dalej

$$s = \sqrt{\frac{(-2.5)^2 + (-0.5)^2 + (2.5)^2 + (0.5)^2}{4}} = \sqrt{\frac{13}{4}} \approx 1.803.$$

Zatem

$$\mathbf{z} = \frac{1}{1.803} \begin{pmatrix} -2.5 \\ -0.5 \\ 2.5 \\ 0.5 \end{pmatrix} \approx \begin{pmatrix} -1.387 \\ -0.277 \\ 1.387 \\ 0.277 \end{pmatrix}.$$

Interpretacja

Widzimy, o ile odchyłeń standardowych każda obserwacja leży od średniej.

Przykład 4: Standaryzacja z parametrami referencyjnymi

Formalna definicja

Czasem używamy parametrów ustalonych wcześniej:

$$\mu_{\text{ref}}, \quad s_{\text{ref}} > 0.$$

Wtedy definiujemy

$$\mathbf{z} = \frac{1}{s_{\text{ref}}} (\mathbf{x} - \mu_{\text{ref}} \mathbf{1}).$$

Jest to transformacja afiniczna:

$$\mathbf{z} = \frac{1}{s_{\text{ref}}} \mathbf{I} \mathbf{x} - \frac{\mu_{\text{ref}}}{s_{\text{ref}}} \mathbf{1}.$$

Intuicja

Nie uczymy się skali na nowych danych, lecz używamy parametrów wyznaczonych wcześniej, np. z próby treningowej.

Mały przykład

Jeśli $\mu_{\text{ref}} = 11$ oraz $s_{\text{ref}} = 2$, to dla

$$\begin{pmatrix} 10 \end{pmatrix}$$

$$\begin{pmatrix} -0.5 \end{pmatrix}$$

Przykład 5: Poza Z-score: Standaryzacja nieliniowa oraz inne metody

Problem: Dane nienormalne

Z-score zmienia jedynie skalę i położenie, nie zmieniając **kształtu** rozkładu. Dla danych o grubych ogonach lub asymetrycznych jest to niewystarczające.

- **Robust Scaling:** Wykorzystuje medianę i kwartyle. Odporny na outliery (rozstęp *IQR* zamiast *s*).
- **Transformacja Box-Cox:** Rodzina przekształceń potęgowych:

$$y(\lambda) = \begin{cases} \frac{x^\lambda - 1}{\lambda} & \text{jeśli } \lambda \neq 0 \\ \ln(x) & \text{jeśli } \lambda = 0 \end{cases}$$

- **Quantile Mapping:** Mapowanie rankingu danych na kwantyle rozkładu docelowego (np. $\mathcal{N}(0, 1)$).

Wniosek

Wybór standaryzacji powinien wynikać z **analizy dystrybucyjnej (CDF)**. Jeśli dane są silnie skośne, logarytmowanie lub transformacja kwantylowa są lepszym wyborem niż Z-score.

Standaryzacja Nieparametryczna i Bootstrap

Problem: Nieznany rozkład populacji

Z-score zawodzi, gdy rozkład jest silnie asymetryczny lub posiada „grube ogony”. Bootstrap pozwala wyznaczyć parametry skalujące bez założeń o normalności.

- **Bootstrapping parametrów:** Wielokrotne losowanie ze zwracaniem pozwala wyznaczyć przedziały ufności dla $\bar{x}$ oraz s , co stabilizuje standaryzację w małych próbkach.
- **Transformacja przez ECDF:** Mapowanie wartości na ich rangi:

$$z_t = \hat{F}_n(x_t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(x_i \leq x_t)$$

- **Zaleta:** Wynik $z_t \in [0, 1]$ jest całkowicie odporny na kształt rozkładu wejściowego i wartości odstające (outliery).

Interpretacja Bayesowska

W podejściu Bayesowskim (MCMC) parametry standaryzacji są częścią modelu hierarchicznego, co pozwala „wybaczać” danym odchylenia od normy.

Przykład 6: Agregacja danych: Np. Generowanie świec (1/4)

Modelowanie okna czasowego d

Dla szeregu $\mathbf{x}$ i okna $d = 4$, definiujemy macierz agregacji $\mathbf{S}$:

$$\mathbf{S}_{i,j} = \begin{cases} 1 & \text{jeśli } (i-1)d < j \leq id \\ 0 & \text{w p.p.} \end{cases}$$

- **Średnia (Liniowo):** $\bar{\mathbf{x}} = \frac{1}{d}\mathbf{S}\mathbf{x}$
- **Ekstrema (Nieliniowo):** Używając operatora podziału na bloki $\mathbf{x} = [\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(k)}]^T$:

$$\text{Max}_j = \max(\mathbf{x}^{(j)}), \quad \text{Min}_j = \min(\mathbf{x}^{(j)})$$

Interpretacja

Przejdzie od danych punktowych do świec to proces **stratny** (downsampling). Tracimy informację o wewnątrz-okresowej dynamice, zachowując jedynie statystyki opisowe przedziału.

Agregacja Tensorowa: Reshape + Reduce (2/4)

Krok 1: Reshape (Zmiana kształtu)

Szereg czasowy $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ przekształcamy w macierz $\mathbf{X}$ o wymiarach $(n/d) \times d$:

$$\mathbf{x} = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{pmatrix} \xrightarrow{\text{Reshape } (d=2)} \mathbf{X} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}$$

Każdy wiersz macierzy $\mathbf{X}$ reprezentuje teraz oddzielne „okno” czasowe.

Formalizacja: Operator na wierszach $\mathcal{R}(\mathbf{r}_i)$ (3/4)

Struktura wierszowa macierzy $\mathbf{X}$

Po operacji Reshape, macierz $\mathbf{X}$ składa się z k wierszy $\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_k$, gdzie każdy wiersz $\mathbf{r}_i \in \mathbb{R}^d$ to jedno okno czasowe.

Generowanie świecy (OHLC)

Każdą składową świecy otrzymujemy stosując odpowiedni operator $\mathcal{R}$ do każdego wiersza z osobna:

$$\text{Open}_i = \mathcal{R}_{first}(\mathbf{r}_i), \quad \text{High}_i = \mathcal{R}_{max}(\mathbf{r}_i)$$

$$\text{Low}_i = \mathcal{R}_{min}(\mathbf{r}_i), \quad \text{Close}_i = \mathcal{R}_{last}(\mathbf{r}_i)$$

Zapis macierzowy świecy

Pełną tabelę świec $\mathbf{Y}_{OHLC}$ otrzymujemy jako konkatencję wyników:

$$\mathbf{Y} = [\mathbf{y}_{open} \ \mathbf{y}_{high} \ \mathbf{y}_{low} \ \mathbf{y}_{close}] \in \mathbb{R}^{k \times 4}$$

Agregacja Tensorowa: Reshape + Reduce (4/4)

Krok 2: Reduce (Redukcja wzdłuż osi)

Aplikujemy operator $\mathcal{R}$ (np. min, max, mean) na osi poziomej ($axis = 1$):

$$\mathbf{y} = \mathcal{R}_{axis=1}(\mathbf{X}) = \begin{pmatrix} \mathcal{R}(1, 2) \\ \mathcal{R}(3, 4) \\ \mathcal{R}(5, 6) \end{pmatrix}$$

Dlaczego to jest lepsze?

W tej formie operacja jest **wektoryzowalna**. Biblioteki takie jak NumPy czy PyTorch wykonują to bez pętli, co przyspiesza generowanie świec o rzędy wielkości.

Najprostsze operacje wykorzystujące czas

7. Operator przesunięcia

Formalna definicja

Operator opóźnienia definiujemy przez

$$\mathbf{L}x_t = x_{t-1}.$$

Dla $n = 4$:

$$\mathbf{L} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}.$$

Intuicja

Każda obserwacja przesuwa się o jeden krok: patrzymy na przeszłość.

Przykład

$$\mathbf{x} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix}$$

$$\mathbf{L}\mathbf{x} = \begin{pmatrix} 0 \\ 10 \\ 12 \\ 15 \end{pmatrix}$$

Przykład 8: Operator różnicowy

Formalna definicja

Pierwsza różnica ma postać

$$\Delta x_t = x_t - x_{t-1}.$$

W zapisie macierzowym:

$$\mathbf{D} = \mathbf{I} - \mathbf{L} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \end{pmatrix}.$$

Intuicja

Zamiast poziomego szeregu badamy jego zmianę między kolejnymi chwilami.

Przykład

$$\mathbf{D} \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix} = \begin{pmatrix} 10 \\ 2 \\ 3 \\ -2 \end{pmatrix}$$

Przykład 9: Różnicowanie względem opóźnienia k

Formalna definicja

Dla ustalonego $k \geq 1$ definiujemy operator

$$\mathbf{I} - \mathbf{L}^k.$$

Wtedy

$$(\mathbf{I} - \mathbf{L}^k)x_t = x_t - x_{t-k}.$$

Intuicja

Porównujemy bieżącą wartość z wartością sprzed k okresów, a nie tylko z poprzednią obserwacją.

Przykład dla $k = 2$

$$(\mathbf{I} - \mathbf{L}^2) \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix} = \begin{pmatrix} 10 \\ 12 \\ 5 \\ 1 \end{pmatrix}$$

Bo

$$15 - 10 = 5, \quad 13 - 12 = 1.$$

Filtry i modelowanie cech szeregu

Przykład 10: Prosta średnia krocząca SMA

Formalna definicja

Dla $k = 3$:

$$y_t = \frac{x_t + x_{t-1} + x_{t-2}}{3}.$$

Macierzowo:

$$\mathbf{y} = \mathbf{W}_{\text{SMA}} \mathbf{x},$$

gdzie

$$\mathbf{W}_{\text{SMA}} = \begin{pmatrix} \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{3} & \frac{1}{3} & 0 & 0 \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & 0 \\ 0 & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{pmatrix}.$$

Intuicja

Każdą wartość zastępujemy średnią z kilku ostatnich obserwacji. To wygładza szum.

SMA – przykład rachunkowy

Obliczenia

Dla

$$\mathbf{x} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix}$$

otrzymujemy

$$\mathbf{W}_{\text{SMA}} \mathbf{x} = \begin{pmatrix} \frac{1}{3} \cdot 10 \\ \frac{1}{3}(10 + 12) \\ \frac{1}{3}(10 + 12 + 15) \\ \frac{1}{3}(12 + 15 + 13) \end{pmatrix} = \begin{pmatrix} 3.33 \\ 7.33 \\ 12.33 \\ 13.33 \end{pmatrix}.$$

Komentarz

Na początku widać efekt brzegu, ale ogólna idea jest prosta: szereg po wygładzeniu jest mniej poszarpany.

Przykład 11: Wykładnicza średnia krocząca EMA

Formalna definicja

EMA spełnia rekurencję

$$m_t = \alpha x_t + (1 - \alpha)m_{t-1}, \quad 0 < \alpha < 1.$$

Po przekształceniu:

$$(\mathbf{I} - (1 - \alpha)\mathbf{L})\mathbf{m} = \alpha\mathbf{x}.$$

Intuicja

Nowsze obserwacje dostają większą wagę niż starsze, więc filtr reaguje szybciej niż SMA.

Przykład dla $\alpha = 0.5$

Dla

$$\mathbf{x} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix}, \quad m_1 = 10,$$

liczymy

$$m_2 = 11, \quad m_3 = 13, \quad m_4 = 13.$$

Czyli

$$\mathbf{m} = \begin{pmatrix} 10 \\ 11 \\ 13 \\ 13 \end{pmatrix}.$$

Pierwsze modele dynamiczne

Przykład 12: Autoregression Model AR(1)

Formalna definicja

Model autoregresyjny rzędu 1:

$$x_t = \phi x_{t-1} + \varepsilon_t.$$

Przenosimy składnik z lewej strony:

$$x_t - \phi x_{t-1} = \varepsilon_t.$$

Operatorowo:

$$(\mathbf{I} - \phi \mathbf{L})\mathbf{x} = \boldsymbol{\varepsilon}.$$

Intuicja

Bieżąca wartość zależy od przeszłej wartości oraz od nowego losowego zaburzenia.

Mała próbka danych

Dla $\phi = 0.7$ oraz

$$\mathbf{x} = \begin{pmatrix} 10 \\ 12 \\ 15 \\ 13 \end{pmatrix}$$

Przykład 13: Moving Average MA(1) – Definicja

Formalna definicja

Model średniej ruchomej rzędu 1:

$$x_t = \varepsilon_t + \theta \varepsilon_{t-1}.$$

Operatorowo:

$$\mathbf{x} = (\mathbf{I} + \theta \mathbf{L})\boldsymbol{\varepsilon}.$$

Intuicja

Bieżąca obserwacja zależy od aktualnego szoku oraz części poprzedniego szoku.

Przykład 13: Moving Average MA(1) – Ilustracja

Mała próbka danych

Niech

$$\varepsilon = \begin{pmatrix} 1 \\ -2 \\ 3 \\ 1 \end{pmatrix}, \quad \theta = 0.5.$$

Wtedy

$$(\mathbf{I} + 0.5\mathbf{L})\varepsilon = \begin{pmatrix} 1 \\ -2 + 0.5 \cdot 1 \\ 3 + 0.5 \cdot (-2) \\ 1 + 0.5 \cdot 3 \end{pmatrix} = \begin{pmatrix} 1 \\ -1.5 \\ 2 \\ 2.5 \end{pmatrix}.$$

Przykład 14: Autoregression Moving & Average Model ARMA(1,1)

Formalna definicja

Model ARMA(1,1) ma postać

$$x_t - \phi x_{t-1} = \varepsilon_t + \theta \varepsilon_{t-1}.$$

W zapisie operatorowym:

$$(\mathbf{I} - \phi \mathbf{L})\mathbf{x} = (\mathbf{I} + \theta \mathbf{L})\boldsymbol{\varepsilon}.$$

Intuicja

ARMA łączy dwa mechanizmy:

- **AR**: pamięć procesu,
- **MA**: pamięć losowego szoku.

Komentarz dydaktyczny

To jest naturalny punkt kulminacyjny pierwszej części kursu: wiemy, że operatory macierzowe prowadzą wprost do klasycznych modeli szeregów czasowych.

Przykład: Macierzowa postać ARMA(1,1)

Równanie operatorowe dla $n = 3$

Dla wektora stanów $\mathbf{x} = [x_1, x_2, x_3]^T$ i zakłóceń $\boldsymbol{\varepsilon} = [\varepsilon_1, \varepsilon_2, \varepsilon_3]^T$ przy założeniu $x_0 = 0, \varepsilon_0 = 0$:

Macierz AR (A)

$$\begin{bmatrix} 1 & 0 & 0 \\ -\phi & 1 & 0 \\ 0 & -\phi & 1 \end{bmatrix}$$

Odpowiada $(\mathbf{I} - \phi\mathbf{L})$

$\mathbf{x} =$

Macierz MA (B)

$$\begin{bmatrix} 1 & 0 & 0 \\ \theta & 1 & 0 \\ 0 & \theta & 1 \end{bmatrix}$$

Odpowiada $(\mathbf{I} + \theta\mathbf{L})$

Postać wynikowa

Pełny zapis macierzowy to: $\mathbf{Ax} = \mathbf{B}\boldsymbol{\varepsilon}$.

Rozwiązanie jawne: $\mathbf{x} = \mathbf{A}^{-1}\mathbf{B}\boldsymbol{\varepsilon}$.

Przykład liczbowy ARMA(1,1)

Założenia: $\phi = 0.5$, $\theta = 0.8$, $\varepsilon = [1, 2, 1]^T$

Krok 1: Wpływ szoków (MA)

$$\mathbf{y} = \mathbf{B}\varepsilon \implies \begin{bmatrix} 1 & 0 & 0 \\ 0.8 & 1 & 0 \\ 0 & 0.8 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2.8 \\ 2.6 \end{bmatrix}$$

Krok 2: Rozwiązanie układu AR

$$\mathbf{A}\mathbf{x} = \mathbf{y} \implies \begin{bmatrix} 1 & 0 & 0 \\ -0.5 & 1 & 0 \\ 0 & -0.5 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2.8 \\ 2.6 \end{bmatrix}$$

Wynik końcowy (podstawienie w przód)

- $x_1 = 1.0$
- $x_2 = 2.8 + 0.5 \cdot 1.0 = \mathbf{3.3}$
- $x_3 = 2.6 + 0.5 \cdot 3.3 = \mathbf{4.25}$

Model ARIMA

Przykład 15: Różnicowanie – operator Δ

Motywacja

Modele AR i ARMA wymagają **stacjonarności** szeregu. Jeśli dane mają trend, stosujemy różnicowanie:

$$\Delta x_t = x_t - x_{t-1}.$$

Zapis operatorowy

Operator różnicowy wyraża się przez operator przesunięcia $\mathbf{L}$:

$$\Delta = \mathbf{I} - \mathbf{L}, \quad \mathbf{y} = (\mathbf{I} - \mathbf{L})\mathbf{x}.$$

Różnicowanie d -krotne:

$$\mathbf{y} = (\mathbf{I} - \mathbf{L})^d \mathbf{x}.$$

Macierzowa postać dla $n = 4$, $d = 1$

$$\mathbf{D} = (\mathbf{I} - \mathbf{L}) = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

Przykład 16: Definicja modelu $ARIMA(p, d, q)$

Formalna definicja

Model $ARIMA(p, d, q)$ to model $ARMA(p, q)$ zastosowany do d -krotnie zróżnicowanego szeregu $y = (\mathbf{I} - \mathbf{L})^d x$:

$$\underbrace{(\mathbf{I} - \phi\mathbf{L})}_{AR(1)} \underbrace{(\mathbf{I} - \mathbf{L})^d}_{\text{różnicowanie}} x = \underbrace{(\mathbf{I} + \theta\mathbf{L})}_{MA(1)} \varepsilon.$$

Dla szczególnego przypadku **ARIMA(1,1,1)**:

$$(\mathbf{I} - \phi\mathbf{L})(\mathbf{I} - \mathbf{L}) x = (\mathbf{I} + \theta\mathbf{L}) \varepsilon.$$

Intuicja – trzy składniki

- **AR**(p): pamięć procesu (zależność od przeszłych wartości),
- **I**(d): usunięcie trendu przez d -krotne różnicowanie,
- **MA**(q): pamięć szoku losowego.

Komentarz

$ARIMA(1, 0, 0) = AR(1)$; $ARIMA(0, 0, 1) = MA(1)$; $ARIMA(1, 0, 1) = ARMA(1, 1)$.

Przykład 17: Macierzowa postać ARIMA(1,1,1)

Równanie operatorowe dla $n = 3$

Dla $\mathbf{x} = [x_1, x_2, x_3]^T$, $\boldsymbol{\varepsilon} = [\varepsilon_1, \varepsilon_2, \varepsilon_3]^T$, $x_0 = 0$, $\varepsilon_0 = 0$:

Macierz ARIMA (C)

$$(\mathbf{I} - \phi \mathbf{L})(\mathbf{I} - \mathbf{L}) = \begin{bmatrix} 1 & 0 & 0 \\ -(1+\phi) & 1 & 0 \\ \phi & -(1+\phi) & 1 \end{bmatrix} \quad \mathbf{x} =$$

Odpowiada $(\mathbf{I} - \phi \mathbf{L})(\mathbf{I} - \mathbf{L})$

Macierz MA (B)

$$(\mathbf{I} + \theta \mathbf{L}) = \begin{bmatrix} 1 & 0 & 0 \\ \theta & 1 & 0 \\ 0 & \theta & 1 \end{bmatrix}$$

Odpowiada $(\mathbf{I} + \theta \mathbf{L})$

Postać wynikowa

Pełny zapis macierzowy: $\mathbf{C}\mathbf{x} = \mathbf{B}\boldsymbol{\varepsilon}$.

Rozwiązanie jawne: $\mathbf{x} = \mathbf{C}^{-1}\mathbf{B}\boldsymbol{\varepsilon}$.

Przykład liczbowy ARIMA(1,1,1)

Założenia: $\phi = 0.5$, $\theta = 0.8$, $\varepsilon = [1, 2, 1]^T$

Krok 1: Wpływ szoków (MA)

$$\mathbf{y} = \mathbf{B}\varepsilon \implies \begin{bmatrix} 1 & 0 & 0 \\ 0.8 & 1 & 0 \\ 0 & 0.8 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2.8 \\ 2.6 \end{bmatrix}$$

Krok 2: Rozwiązanie układu ARIMA

$$\mathbf{C}\mathbf{x} = \mathbf{y} \implies \begin{bmatrix} 1 & 0 & 0 \\ -1.5 & 1 & 0 \\ 0.5 & -1.5 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2.8 \\ 2.6 \end{bmatrix}$$

Wynik końcowy (podstawienie w przód)

- $x_1 = 1.0$
- $x_2 = 2.8 + 1.5 \cdot 1.0 = \mathbf{4.3}$
- $x_3 = 2.6 + 1.5 \cdot 4.3 - 0.5 \cdot 1.0 = \mathbf{8.55}$

Uogólnienia ARMA

Uogólnienie: $x_t = \text{Model}(\text{Przeszłość}) + \text{Błąd}$

Model AR(1) to tylko punkt wyjścia. Możemy go rozszerzać, zastępując proste parametry bardziej złożonymi strukturami:

Element AR(1)	Uogólnienie	Co to daje?
Stała ϕ	Dowolna funkcja $f(\cdot)$ lub sieć neuronowa	Modelowanie złożonych, nieliniowych zjawisk.
Przeszłość x_{t-1}	Cała historia x_{t-k} (pamięć długotrwała)	Pozwala modelowi uchwycić trendy i sezonowość.
Błąd ε_t	Modelowanie zmienności (np. GARCH)	Przewidywanie ryzyka i skali błędów (np. giełda).

Kierunek rozwoju

Przejsie od ϕx_{t-1} do $f(x_{t-1}, \dots, x_{t-k})$ pozwala na ewolucję od prostej statystyki do **Głębokiego Uczenia (Deep Learning)**. Modele takie jak GPT to w rzeczywistości potężne funkcje autoregresyjne, gdzie „Model” to sieć typu Transformer, a „Przeszłość” to kontekst tysięcy słów.

Uogólnienia modelu AR (Część 1)

1 Wyższe rzędy (Model AR(p))

Zamiast tylko jednego kroku, patrzymy na p kroków wstecz. To suma ważona:

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \varepsilon_t$$

Obejmuje to dłuższą pamięć procesu.

2 Dowolny operator liniowy (Filtry i Sploty)

Zapis przy użyciu wielomianu opóźnień:

$$\Phi(L)x_t = \varepsilon_t$$

$\Phi(L)$ to operator, który „przesiewa” przeszłość. Pozwala to na projektowanie filtrów wycinających szum lub wzmacniających trendy.

3 Modele nieliniowe (NAR)

Zastępujemy ϕ dowolną funkcją nieliniową f :

$$x_t = f(x_{t-1}, x_{t-2}, \dots) + \varepsilon_t$$

Stosowane w systemach chaotycznych (np. meteorologia).

Uogólnienia modelu AR (Część 2: AI)

❶ Sieci neuronowe (Modele w Deep Learningu)

To najbardziej złożone uogólnienie – gigantyczne modele nieliniowe:

- **RNN (Recurrent Neural Networks):** Współczynnik ϕ staje się macierzą wag aktualizującą „stan ukryty” na podstawie poprzedniego kroku.
- **Transformery (np. GPT):** „G” w GPT oznacza *Generative* (autoregresyjny). Zamiast stałej ϕ , mechanizm **Attention** decyduje, które fragmenty przeszłości są najważniejsze dla przewidzenia x_t .

Wniosek

Nowoczesne AI to w istocie model autoregresyjny, w którym funkcja f jest przybliżana przez miliardy parametrów sieci neuronowej.

Podsumowanie wprowadzenia do AR, MA
oraz ARMA

Pierwsze modele: AR, MA, ARMA

AR(1)

$$x_t = \phi x_{t-1} + \varepsilon_t$$

$$(\mathbf{I} - \phi \mathbf{L})\mathbf{x} = \boldsymbol{\varepsilon}$$

Intuicja: bieżąca wartość zależy od przeszłej wartości.

MA(1)

$$x_t = \varepsilon_t + \theta \varepsilon_{t-1}$$

$$\mathbf{x} = (\mathbf{I} + \theta \mathbf{L})\boldsymbol{\varepsilon}$$

Intuicja: bieżąca wartość zależy od aktualnego i poprzedniego szoku.

ARMA(1,1)

$$x_t - \phi x_{t-1} = \varepsilon_t + \theta \varepsilon_{t-1}$$

$$(\mathbf{I} - \phi \mathbf{L})\mathbf{x} = (\mathbf{I} + \theta \mathbf{L})\boldsymbol{\varepsilon}$$

Idea

ARMA łączy **pamięć procesu** (AR) z **pamięcią szoku** (MA).

Przykład 15: kwadrat reszt

Formalna definicja

Jeżeli z modelu średniej otrzymaliśmy reszty

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix},$$

to definiujemy nowy szereg

$$v = \begin{pmatrix} \varepsilon_1^2 \\ \varepsilon_2^2 \\ \vdots \\ \varepsilon_n^2 \end{pmatrix}.$$

Intuicja

Mała próbka danych

Jeśli

$$\varepsilon = \begin{pmatrix} 1 \\ -1.5 \\ 2 \\ 2.5 \end{pmatrix},$$

to

$$v = \begin{pmatrix} 1 \\ 2.25 \\ 4 \\ 6.25 \end{pmatrix}.$$

Uwaga

To już nie jest operacja liniowa. I właśnie tutaj zaczyna się przejście od ARMA do modeli zmienności typu GARCH.

Przykład 16: równanie GARCH(1,1) – Definicja

Formalna definicja

W modelu GARCH(1,1) wariancja warunkowa spełnia równanie

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2.$$

Intuicja

Dzisiejsza zmienność zależy od:

- wczorajszego szoku ε_{t-1}^2 ,
- wczorajszej zmienności σ_{t-1}^2 .

Przykład 16: równanie GARCH(1,1) – Ilustracja

Mała próbka danych

Założmy

$$\omega = 0.2, \quad \alpha = 0.3, \quad \beta = 0.5, \quad \sigma_1^2 = 1,$$

oraz

$$\varepsilon = \begin{pmatrix} 1 \\ -1.5 \\ 2 \\ 2.5 \end{pmatrix}.$$

Wtedy

$$\sigma_2^2 = 0.2 + 0.3 \cdot 1^2 + 0.5 \cdot 1 = 1.0,$$

$$\sigma_3^2 = 0.2 + 0.3 \cdot (-1.5)^2 + 0.5 \cdot 1.0 = 1.375,$$

$$\sigma_4^2 = 0.2 + 0.3 \cdot 2^2 + 0.5 \cdot 1.375 = 2.0875.$$

Przykład 16: równanie GARCH(1,1) – Definicja

Formalna definicja

W modelu GARCH(1,1) wariancja warunkowa spełnia równanie

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2.$$

Intuicja

Dzisiejsza zmienność zależy od:

- wczorajszego szoku ε_{t-1}^2 ,
- wczorajszej zmienności σ_{t-1}^2 .

Przykład 16: równanie GARCH(1,1) – Ilustracja

Mała próbka danych

Założmy

$$\omega = 0.2, \quad \alpha = 0.3, \quad \beta = 0.5, \quad \sigma_1^2 = 1,$$

oraz

$$\varepsilon = \begin{pmatrix} 1 \\ -1.5 \\ 2 \\ 2.5 \end{pmatrix}.$$

Wtedy

$$\sigma_2^2 = 0.2 + 0.3 \cdot 1^2 + 0.5 \cdot 1 = 1.0,$$

$$\sigma_3^2 = 0.2 + 0.3 \cdot (-1.5)^2 + 0.5 \cdot 1.0 = 1.375,$$

$$\sigma_4^2 = 0.2 + 0.3 \cdot 2^2 + 0.5 \cdot 1.375 = 2.0875.$$

Generalized Autoregressive Conditional Heteroskedasticity

Uogólniony Autoregresyjny Model Warunkowej Heteroskedastyczności

GARCH: Intuicje znaczenia w analizie
szeregów czasowych

Wielka Zmiana Perspektywy: od kierunku do drgań

ARIMA – kierowca



„Gdzie będzie cena?”

Pytanie: jaka będzie wartość szeregu y_t ?

GARCH – mechanik silnika



Pytanie: jak duże będą wahania y_t ?

Kluczowa metafora

Przejście od ARIMA do GARCH to jak przejście od
prognozowania kierunku jazdy do **prognozowania drgań silnika**.

Skąd się biorą błędy / reszty?

Reszty ARIMA – surowiec dla GARCH

Model ARIMA produkuje reszty ε_t


$$y_t = \underbrace{\hat{y}_t}_{\text{prognoza ARIMA}} + \underbrace{\varepsilon_t}_{\text{reszta / szok}}$$

- Reszty ε_t to **niespodzianki** – to, czego ARIMA nie potrafiła przewidzieć.
- Ideał: $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ – stała wariancja.
- Rzeczywistość: wariancja **zmienia się w czasie!**

Zjawisko: heteroskedastyczność

Duże wstrząsy pojawiają się **grupami** – po burzliwym dniu zwykle następuje kolejny burzliwy dzień.

Typowy wygląd reszt finansowych



Dlaczego kwadraty błędów?

Transformacja kluczowa: $\varepsilon_t \mapsto \varepsilon_t^2$

Dwa równe wstrząsy – różne znaki

$\varepsilon_t = +10\%$ (skok w górę)


$\varepsilon_t = -10\%$ (spadek w dół)

$\varepsilon_t^2 = 1\%$ w **obu** przypadkach

Dlaczego to ma sens?

Dla rynkowego **ryzyka** nie interesuje nas *kierunek* zaskoczenia – zarówno nagły wzrost, jak i nagły spadek oznaczają **nerwowość** i **niepewność**.

Kwadrat wyolbrzymia duże szoki



Efekt amplifikacji

Kwadrat wyolbrzymia duże błędy: szok $3\times$ większy daje wariancję $9\times$ większą.

Wzór GARCH(1,1)

GARCH(1,1): Hybryda AR i MA dla ryzyka

$$\sigma_t^2 = \underbrace{\omega}_{\text{szum tła}} + \underbrace{\alpha \varepsilon_{t-1}^2}_{\text{reakcja na szok}} + \underbrace{\beta \sigma_{t-1}^2}_{\text{bezwładność strachu}}$$

ω – szum tła

Stały poziom napięcia rynkowego. Nawet w najspokojniejsze dni *coś* zawsze się dzieje.

$\omega > 0$ zawsze.

$\alpha \varepsilon_{t-1}^2$ – reakcja

Krótką pamięć. Jeśli wczoraj był wielki szok (ε_{t-1} duże), to dzisiaj wariancja rośnie.

Analog **MA** w ARMA.

$\beta \sigma_{t-1}^2$ – bezwładność

Długa pamięć. Jeśli wczoraj rynki panikowały, dziś panika trwa – *bez nowych złych wieści*.

Analog **AR** w ARMA.

Niesamowita analogia: GARCH to ARMA zastosowane do... błędu!

ARMA : modeluje y_t przez przeszłe y_{t-k} i przeszłe szoki ε_{t-k}

GARCH : modeluje σ_t^2 przez przeszłe σ_{t-k}^2 i przeszłe kwadraty szoków ε_{t-k}^2

Zapis Operatorowy

Zapis operatorowy GARCH – elegancja algebry

Operator opóźnienia L

Przypomnijmy: $Lx_t = x_{t-1}$, $L^2x_t = x_{t-2}$, ...


GARCH(1,1) w postaci operatorowej

$$(1 - \beta L)\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$$

- $(1 - \beta L)$: filtr **autoregresji wariancji**.
- Jeśli $|\beta| < 1$: możemy odwrócić operator i wyrazić σ_t^2 jako *nieskończoną* sumę ważonych przeszłych szoków.

Rozwinięcie w nieskończony szereg

$$\sigma_t^2 = \frac{\omega}{1 - \beta} + \alpha \sum_{k=1}^{\infty} \beta^{k-1} \varepsilon_{t-k}^2$$



Trzy składniki wariancji

Warunek stacjonarności

Model jest stacjonarny gdy: $\alpha + \beta < 1$

Klastrowanie Zmienności w celu Badania
Heteroskedastyczności (niejednorodności
wariancji)

Heteroskedastyczność: Gdy błąd zmienia skalę

Definicja

Wariancja składnika losowego **nie jest stała**:

$$\text{Var}(\varepsilon_t | x_t) = \sigma_t^2 \neq \text{const}$$


- **Na wykresie:** charakterystyczny kształt *lejka* lub *wachlarza*
- **Skutki:** estymatory nieobciążone, ale **nieskuteczne** – błędy standardowe są błędne
- **Lekarstwo:** model **GARCH** – jawnie modeluje σ_t^2 jako proces autoregresyjny

Klucz do GARCH

Klastrowanie zmienności = **autokorelacja heteroskedastyczności**:

duża σ_t^2 dzisiaj $\Rightarrow$ duża σ_{t+1}^2 jutro

Kształt „lejka” reszt




Heteroskedastyczność a klastrowanie zmienności – dwa oblicza tego samego

Klasyczna heteroskedastyczność

Wariancja rośnie **monotonicznie** wraz z x_t :

$$\sigma_t^2 = f(x_t)$$




Kształt *lejka* – typowy w regresji przekrojowej.

Klastrowanie zmienności (GARCH)

Wariancja zależy od **własnej przeszłości**:

$$\sigma_t^2 = f(\sigma_{t-1}^2, \varepsilon_{t-1}^2)$$



Fazy *ciszy* i *burzy* – typowe w finansach.


Most między pojęciami

heteroskedastyczność $\longrightarrow \sigma_t^2 \neq \text{const}$

autokorelacja het. $\longrightarrow \sigma_t^2$ zależy od σ_{t-1}^2

Kluczowe zjawisko: Klastrowanie zmienności

Ewolucja wariancji warunkowej σ_t^2



Co widać na wykresie?

- Po dużym szoku ε_{t-1}^2 wariancja **skacze w górę**.
- Dzięki β (bezwładność) wysoka wariancja **utrzymuje się** przez wiele dni.
- Stopniowo, bez nowych szoków, wariancja **wraca do poziomu** $\frac{\omega}{1-\alpha-\beta}$.

Intuicja rynkowa


„Po dzisiejszej burzy jutro **prawdopodobnie też będzie wiało**.”

Spokojne dni są spokojne. Burzliwe dni przyciągają kolejne burzliwe dni.

Długookresowa (bezwarunkowa) wariancja

Ewolucja Modeli

Podróż przez modele – rosnąca głębokość pytań



Hierarchia modelowanych obiektów

AR/MA	→ modelujemy wartość y_t
ARIMA	→ modelujemy zmianę Δy_t
GARCH	→ modelujemy błąd ε_t^2 modelu ARIMA
VaR	→ modelujemy ryzyko straty

Połączenie ARIMA + GARCH

W praktyce używamy modeli **ARIMA-GARCH**:


- ARIMA prognozuje *kierunek* (wartość oczekiwaną),
- GARCH prognozuje *rozrzut* (wariancję warunkową).

Podsumowanie intuicji znaczenia w analizie szeregów czasowych

Podsumowanie: czym jest GARCH w analizie szeregów czasowych?

Trzy filary intuicji GARCH

- 1 **Transformacja** $\varepsilon_t \mapsto \varepsilon_t^2$
Kwadrat usuwa znak, zachowuje siłę wstrząsu.
- 2 **Wzór** $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
Wariancja ma *pamięć* – krótką (szok) i długą (bezwładność).
- 3 **Klastrowanie zmienności**
Burzliwe okresy przyciągają kolejne burzliwe okresy.



Zastosowania praktyczne

- **Value at Risk (VaR)**: ile możemy stracić?
- **Opcje**: wycena zmienności implikowanej.
- **Zarządzanie ryzykiem** w bankach.

Zapis operatorowy (podsumowanie)


$$(1 - \beta L) \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$$

To ARMA zastosowane do *kwadratu błędu*.

Podsumowanie: ARMA i GARCH – dwa wymiary szeregu czasowego

Dwa modele – dwa pytania

Cecha	ARMA	GARCH
Co modeluje?	war. oczekiwana $\mathbb{E}[x_t \mathcal{F}_{t-1}]$	war. wariancji σ_t^2
Finanse	poziom ceny / stopy zwrotu	ryzyko i zmienność
Na wykresie	linia prognozy (środek)	szerokość wstęgi
Zjawisko	autokorelacja poziomów	klastrowanie zmienności
Zakłada	$\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ stałe	$\varepsilon_t \sim \mathcal{N}(0, \sigma_t^2)$ zmienne




Metafora końcowa

ARMA prognozuje *kierunek jazdy*. **GARCH** prognozuje *drgania silnika*. **VaR**: czy dojedziemy bezpiecznie?

Razem tworzą pełny obraz

„Rynek nie mówi nam, gdzie pójdzie – mówi nam, jak bardzo będzie szalał.”



Prognostowanie ryzyka zmian dynamiki szeregów czasowych

Przykłady podstawowych metod algebry liniowej
w analizie: szeregów czasowych (TS), DS oraz AI/ML

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

9 marca 2026

Co to jest ϕ w modelu AR(1)?

Model AR(1) – definicja

Równanie modelu (wersja z niezerową średnią)

$$x_t - \mu = \phi(x_{t-1} - \mu) + \varepsilon_t$$

gdzie $\mu = \mathbb{E}[x_t]$ jest (nieznaną) średnią procesu. Równoważnie:

$$x_t = \underbrace{(1 - \phi)\mu}_c + \phi x_{t-1} + \varepsilon_t$$

Założenia

- $\{\varepsilon_t\}$ jest białym szumem: $\mathbb{E}[\varepsilon_t] = 0$, $\text{Var}(\varepsilon_t) = \sigma_\varepsilon^2$, $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ dla $t \neq s$
- ε_t jest nieskorelowane z przeszłością procesu: $\text{Cov}(\varepsilon_t, x_{t-k}) = 0$ dla $k \geq 1$
- $|\phi| < 1$ (warunek stacjonarności)

Intuicja

Parametr ϕ mówi, **jak mocno** odchylenie x_t od średniej „pamięta” odchylenie x_{t-1} od średniej:

- $\phi \approx 1$: silna pamięć (wolne zanikanie odchyłeń)
- $\phi \approx 0$: prawie brak pamięci

Skąd bierze się ϕ ? – wyprowadzenie

Krok 1: oznaczmy odchylenia $\tilde{x}_t = x_t - \mu$

Model przyjmuje postać:

$$\tilde{x}_t = \phi \tilde{x}_{t-1} + \varepsilon_t$$

Weźmy kowariancję obu stron z $\tilde{x}_{t-1}$:

$$\text{Cov}(\tilde{x}_t, \tilde{x}_{t-1}) = \text{Cov}(\phi \tilde{x}_{t-1} + \varepsilon_t, \tilde{x}_{t-1})$$

Krok 2: liniowość kowariancji

$$= \phi \text{Var}(\tilde{x}_{t-1}) + \underbrace{\text{Cov}(\varepsilon_t, \tilde{x}_{t-1})}_{=0} = \phi \text{Var}(\tilde{x}_{t-1})$$

Ponieważ ε_t jest nieskorelowane z przeszłością procesu, $\text{Cov}(\varepsilon_t, \tilde{x}_{t-1}) = 0$.

Krok 3: stacjonarność $\Rightarrow \text{Var}(\tilde{x}_t) = \text{Var}(\tilde{x}_{t-1}) = \gamma(0)$

Kowariancję liczymy dla zmiennych wycentrowanych wokół μ , więc $\gamma(k) = \text{Cov}(\tilde{x}_t, \tilde{x}_{t-k})$. Stąd:

$$\gamma(1) = \phi \gamma(0)$$

Wynik

Interpretacja przez macierz kowariancji

Zapis operatorowy

Operator przesunięcia: $\mathbf{L} \tilde{x}_t = \tilde{x}_{t-1}$, więc

$$\phi = \frac{\text{Cov}(\tilde{x}_t, \mathbf{L}\tilde{x}_t)}{\text{Var}(\tilde{x}_t)} = \frac{\text{Cov}(x_t - \mu, \mathbf{L}(x_t - \mu))}{\text{Var}(x_t - \mu)}$$

Macierz kowariancji wektora $\mathbf{z} = (\tilde{x}_t, \mathbf{L}\tilde{x}_t)^T$

$$\Sigma = \text{Var}(\mathbf{z}) = \begin{bmatrix} \gamma(0) & \gamma(1) \\ \gamma(1) & \gamma(0) \end{bmatrix}$$

Dla procesu stacjonarnego macierz ta ma **strukturę Toeplitza** (każdy element zależy tylko od odległości czasowej, nie od t).

Odczyt ϕ z macierzy

$$\phi = \frac{\Sigma_{12}}{\Sigma_{11}} = \frac{\gamma(1)}{\gamma(0)}$$

Co jest specyficzne dla AR(1)?

Przykład liczbowy – dane

Dane: mała próbka $n = 5$ obserwacji szeregu czasowego

t	1	2	3	4	5
x_t	2	3	5	4	6

Cel: estymacja ϕ i μ metodą momentów

$$\hat{\mu} = \bar{x}, \quad \hat{\phi} = \frac{\hat{\gamma}(1)}{\hat{\gamma}(0)}$$

Krok 1: Średnia (estymator μ)

$$\hat{\mu} = \bar{x} = \frac{2 + 3 + 5 + 4 + 6}{5} = 4$$

Krok 2: Odchylenia od średniej $\tilde{x}_t = x_t - \bar{x}$

t	1	2	3	4	5
$\tilde{x}_t$	-2	-1	1	0	2

Przykład liczbowy – obliczenie $\hat{\phi}$

Krok 3: Wariancja $\hat{\gamma}(0)$

$$\hat{\gamma}(0) = \frac{1}{n} \sum_{t=1}^n \tilde{x}_t^2 = \frac{(-2)^2 + (-1)^2 + 1^2 + 0^2 + 2^2}{5} = \frac{4 + 1 + 1 + 0 + 4}{5} = \mathbf{2}$$

Krok 4: Autokowariancja $\hat{\gamma}(1)$

$$\hat{\gamma}(1) = \frac{1}{n} \sum_{t=2}^n \tilde{x}_t \tilde{x}_{t-1} = \frac{(-1)(-2) + (1)(-1) + (0)(1) + (2)(0)}{5} = \frac{2 - 1 + 0 + 0}{5} = \mathbf{0,2}$$

Krok 5: Wynik

$$\hat{\phi} = \frac{\hat{\gamma}(1)}{\hat{\gamma}(0)} = \frac{0,2}{2} = \boxed{0,1}$$

Słaba, dodatnia zależność od poprzedniej wartości.

Weryfikacja przez podstawienie – prognozy

Formuła prognozy – zgodna z definicją modelu

Model z niezerową średnią daje:

$$\hat{x}_t = \hat{\mu} + \hat{\phi}(x_{t-1} - \hat{\mu}) = 4 + 0,1(x_{t-1} - 4)$$

Tabela prognoz i reszt

t	x_{t-1}	$\hat{x}_t = 4 + 0,1(x_{t-1} - 4)$	reszta $\hat{\varepsilon}_t = x_t - \hat{x}_t$
2	2	$4 + 0,1(-2) = 3,8$	$3 - 3,8 = -0,8$
3	3	$4 + 0,1(-1) = 3,9$	$5 - 3,9 = 1,1$
4	5	$4 + 0,1(+1) = 4,1$	$4 - 4,1 = -0,1$
5	4	$4 + 0,1(0) = 4,0$	$6 - 4,0 = 2,0$

Obserwacja

Prognozy $\hat{x}_t$ są bliskie stałej $\hat{\mu} = 4$, a nie bliskie x_{t-1} – model „prawie nie uczy się” z poprzedniej obserwacji.

Weryfikacja przez podstawienie – wniosek

Co mówią reszty?

- Reszty $\hat{\varepsilon}_t \in \{-0,8; 1,1; -0,1; 2,0\}$ są duże w porównaniu z prognozami.
- Wynika to z małej wartości $\hat{\phi} = 0,1$: prawie cały sygnał jest „innovacją”, a nie pamięcią.

Intuicja dla różnych wartości ϕ

$ \phi $	charakter procesu
≈ 0	brak pamięci – prognozy $\approx \mu$
$\approx 0,5$	umiarkowana pamięć
≈ 1	silna pamięć – prognozy $\approx x_{t-1}$
$= 1$	błądzenie losowe (niestacjonarny!)

Podsumowanie: co to jest ϕ w AR(1)?

$$\phi = \frac{\text{Cov}(x_t - \mu, x_{t-1} - \mu)}{\text{Var}(x_t - \mu)} = \rho(1) \in (-1, 1)$$

Mała wartość $\hat{\phi} = 0,1$ sugeruje **słabą zależność liniową** od poprzedniej obserwacji.

AR(1) jako projekcja – przestrzeń $L^2(\Omega)$

Przestrzeń Hilberta zmiennych losowych

Rozważmy zbiór zmiennych losowych o skończonej wariancji:

$$L^2(\Omega) = \{X : \mathbb{E}[X^2] < \infty\}.$$

Iloczyn skalarny i norma

Dla $X, Y \in L^2(\Omega)$ definiujemy:

$$\langle X, Y \rangle = \mathbb{E}[XY], \quad \|X\| = \sqrt{\mathbb{E}[X^2]}.$$

Ortogonalność

Mówimy, że $X \perp Y$, gdy

$$\langle X, Y \rangle = \mathbb{E}[XY] = 0.$$

Dlaczego to ważne?

Geometria $L^2(\Omega)$ pozwala mówić o **rzutach** zmiennych losowych – tak jak rzuty wektorów w $\mathbb{R}^n$. Model AR(1) okaże się właśnie takim rzutem.

Dlaczego wystarczy analizować jeden moment czasu? (1/2)

Problem dopasowania modelu

Chcemy znaleźć współczynnik a , który najlepiej przybliży cały proces przez zależność

$$x_t \approx a x_{t-1}.$$

Formalnie minimalizujemy średni błąd kwadratowy:

$$\min_a \mathbb{E}[(x_t - a x_{t-1})^2].$$

Kluczowa własność: stacjonarność słaba

Jeżeli proces $\{x_t\}$ jest **słabo stacjonarny**, to:

- $\mathbb{E}[x_t] = \mu$ — nie zależy od t ,
- $\text{Var}(x_t) = \gamma(0)$ — nie zależy od t ,
- $\text{Cov}(x_t, x_{t-k}) = \gamma(k)$ — zależy tylko od opóźnienia k , nie od t .

Kluczowa obserwacja

Rozkład pary (x_t, x_{t-1}) jest **taki sam dla każdego** t :

Dlaczego wystarczy analizować jeden moment czasu? (2/2)

Konsekwencja stacjonarności

Ponieważ wszystkie pary (x_t, x_{t-1}) mają ten sam rozkład, wyrażenie

$$\mathbb{E}[(x_t - a x_{t-1})^2]$$

jest **identyczne dla każdego momentu czasu t** .

Dlatego wystarczy analizować jedną losową parę:

$$(X, Y) = (x_t, x_{t-1}).$$

Redukcja problemu

Problem dopasowania modelu AR(1) dla **całej serii czasowej**:

$$\min_a \mathbb{E}[(x_t - a x_{t-1})^2] \quad \forall t$$

redukuje się do problemu projekcji **jednej zmiennej losowej** x_t na przestrzeń $\text{span}(x_{t-1})$ w $L^2(\Omega)$.
Dzięki stacjonarności **jeden parametr** ϕ opisuje zależność między każdą parą sąsiednich obserwacji – nie potrzebujemy osobnego parametru dla każdego t .

AR(1) jako projekcja – problem minimalizacji

Pytanie

Jak najlepiej przybliżyć x_t liniowo przez x_{t-1} ?

$$x_t \approx a x_{t-1}, \quad a \in \mathbb{R}.$$

Kryterium: błąd średniokwadratowy

Szukamy a minimalizującego:

$$\min_{a \in \mathbb{R}} \mathbb{E}[(x_t - a x_{t-1})^2] = \min_a \|x_t - a x_{t-1}\|^2.$$

Warunek pierwszego rzędu

Różniczkując po a i przyrównując do zera:

$$\frac{d}{da} \mathbb{E}[(x_t - a x_{t-1})^2] = -2 \mathbb{E}[(x_t - a x_{t-1}) x_{t-1}] = 0.$$

Warunek projekcji ortogonalnej

$$\mathbb{E}[(x_t - a x_{t-1}) x_{t-1}] = 0 \quad \Longleftrightarrow \quad (x_t - a x_{t-1}) \perp x_{t-1}.$$

AR(1) jako projekcja – wyznaczenie współczynnika

Rozwiązanie warunku ortogonalności

Z równania

$$\mathbb{E}[(x_t - a x_{t-1}) x_{t-1}] = 0$$

wynika:

$$\mathbb{E}[x_t x_{t-1}] = a \mathbb{E}[x_{t-1}^2].$$

Współczynnik projekcji

$$a = \frac{\mathbb{E}[x_t x_{t-1}]}{\mathbb{E}[x_{t-1}^2]} = \frac{\text{Cov}(x_t, x_{t-1})}{\text{Var}(x_{t-1})}.$$

Dla procesu stacjonarnego ($\text{Var}(x_t) = \text{Var}(x_{t-1}) = \gamma(0)$):

$$a = \frac{\gamma(1)}{\gamma(0)}.$$

Wniosek

Optymalny współczynnik liniowej predykcji x_t na podstawie x_{t-1} to dokładnie parametr ϕ modelu AR(1).

AR(1) jako projekcja – interpretacja geometryczna

Diagram ortogonalności

$$\underbrace{x_t}_{\text{obserwacja}} = \underbrace{\phi x_{t-1}}_{\text{rzut na span}(x_{t-1})} + \underbrace{\varepsilon_t}_{\perp x_{t-1}}$$

Co oznaczają poszczególne składniki?

- ϕx_{t-1} – **projekcja ortogonalna** x_t na $\text{span}(x_{t-1})$: najlepsza liniowa predykcja,
- ε_t – **innowacja**: część x_t nieprzewidywalna z x_{t-1} , ortogonalna do predyktora:

$$\mathbb{E}[\varepsilon_t x_{t-1}] = 0.$$

Podsumowanie: dwa równoważne spojrzenia na ϕ

$$\phi = \underbrace{\frac{\text{Cov}(x_t - \mu, x_{t-1} - \mu)}{\text{Var}(x_t - \mu)}}_{\text{moment drugiego rzędu}} = \underbrace{\arg \min_a \mathbb{E}[(x_t - a x_{t-1})^2]}_{\text{projekcja w } L^2(\Omega)}$$

AR(1) jako projekcja ortogonalna – przestrzeń L^2

Przestrzeń Hilberta zmiennych losowych

Rozważmy przestrzeń $L^2(\Omega)$ ze skalarnym iloczynem

$$\langle X, Y \rangle = \mathbb{E}[XY].$$

Norma indukowana przez iloczyn skalarny:

$$\|X\| = \sqrt{\mathbb{E}[X^2]}.$$

Najlepsza aproksymacja liniowa

Chcemy najlepiej przybliżyć x_t przez wielokrotność x_{t-1} :

$$x_t \approx a x_{t-1}.$$

Minimalizujemy błąd średniokwadratowy:

$$\min_a \mathbb{E}[(x_t - a x_{t-1})^2].$$

Warunek projekcji ortogonalnej

Rozwiązaniem jest a takie, że reszta jest **ortogonalna** do x_{t-1} :

Prognostowanie ryzyka zmian dynamiki szeregów czasowych

Przykłady podstawowych metod algebry liniowej
w analizie: szeregów czasowych (TS), DS oraz AI/ML

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

9 marca 2026