

*Geometria przekształceń portfela:  
Aktywne (kowariantne) i pasywne (kontrawariantne) interpretacje  
transformacji liniowej w analizie aktywów finansowych*

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

16 marca 2026

Przekształcenie liniowe: macierz jako obraz  
bazy standardowej

# Baza standardowa przestrzeni $\mathbb{R}^n$

Aby opisać przekształcenie liniowe  $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$  za pomocą macierzy, korzystamy z wyróżnionego układu wektorów – **bazy standardowej**.

## Definicja: wektory bazy standardowej

Wektory bazy standardowej  $e_1, e_2, \dots, e_n \in \mathbb{R}^n$  definiujemy jako:

$$e_i = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \leftarrow \text{jedynka na pozycji } i$$

Formalnie:  $(e_i)_j = \delta_{ij}$ , gdzie  $\delta_{ij}$  to **delta Kroneckera**:

$$\delta_{ij} = \begin{cases} 1 & \text{jeśli } i = j \\ 0 & \text{jeśli } i \neq j \end{cases}$$

# Przekształcenie liniowe: macierz jako obraz bazy standardowej

## Własność kluczowa

Każdy wektor  $v = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$  daje się **jednoznacznie** zapisać jako kombinacja liniowa wektorów bazy standardowej:

$$v = x_1 e_1 + x_2 e_2 + \dots + x_n e_n$$

# Przekształcenie liniowe: macierz jako obraz bazy standardowej

Aby w pełni opisać przekształcenie liniowe  $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$  za pomocą macierzy  $\mathbf{M}$ , wystarczy wyznaczyć obrazy wektorów bazy standardowej  $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ .

## Uzasadnienie rachunkowe

Dowolny wektor  $\mathbf{v} \in \mathbb{R}^n$  zapisujemy jako kombinację liniową:

$$\mathbf{v} = \sum_{i=1}^n x_i \mathbf{e}_i = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_n \mathbf{e}_n$$

Z liniowości przekształcenia  $T$ :

$$T(\mathbf{v}) = x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) + \dots + x_n T(\mathbf{e}_n)$$

## Wniosek

Wartości  $T(\mathbf{e}_1), T(\mathbf{e}_2), \dots, T(\mathbf{e}_n)$  **całkowicie wyznaczają** przekształcenie  $T$  – znając obrazy bazy, potrafimy obliczyć obraz **dowolnego** wektora.

# Przekształcenie liniowe: kolumny macierzy

Wynik rachunkowy z poprzedniego slajdu pozwala jednoznacznie utożsamić kolumny macierzy  $\mathbf{M}$  z obrazami wektorów bazy standardowej.

Kolumny macierzy  $\mathbf{M}$  są dokładnie obrazami wektorów bazy:

$$\mathbf{M} = \begin{bmatrix} | & | & & | \\ T(\mathbf{e}_1) & T(\mathbf{e}_2) & \dots & T(\mathbf{e}_n) \\ | & | & & | \end{bmatrix}$$

## Kluczowa obserwacja

Wybór bazy **determinuje** macierz. Inna baza  $\Rightarrow$  inna macierz, **to samo** przekształcenie. To jest serce interpretacji pasywnej.

## Przykład rachunkowy: przekształcenie $T: \mathbb{R}^4 \rightarrow \mathbb{R}^3$ (1/2)

Niech  $T: \mathbb{R}^4 \rightarrow \mathbb{R}^3$  będzie przekształceniem liniowym o macierzy:

$$\mathbf{M} = \begin{bmatrix} 1 & 2 & 0 & -1 \\ 3 & 0 & 1 & 2 \\ -1 & 1 & 4 & 0 \end{bmatrix}$$

Kolumny macierzy = obrazy bazy standardowej

$$T(\mathbf{e}_1) = \begin{bmatrix} 1 \\ 3 \\ -1 \end{bmatrix}$$

$$T(\mathbf{e}_2) = \begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix}$$

$$T(\mathbf{e}_3) = \begin{bmatrix} 0 \\ 1 \\ 4 \end{bmatrix}$$

$$T(\mathbf{e}_4) = \begin{bmatrix} -1 \\ 2 \\ 0 \end{bmatrix}$$

## Przykład rachunkowy: przekształcenie $T: \mathbb{R}^4 \rightarrow \mathbb{R}^3$ (2/2)


Ilustracja: obraz wektora  $\mathbf{v} = [2, 1, -1, 3]^\top$

Rozkładamy  $\mathbf{v}$  na bazę i stosujemy liniowość:

$$\begin{aligned} T(\mathbf{v}) &= 2T(\mathbf{e}_1) + 1T(\mathbf{e}_2) + (-1)T(\mathbf{e}_3) + 3T(\mathbf{e}_4) \\ &= 2 \begin{bmatrix} 1 \\ 3 \\ -1 \end{bmatrix} + 1 \begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix} - 1 \begin{bmatrix} 0 \\ 1 \\ 4 \end{bmatrix} + 3 \begin{bmatrix} -1 \\ 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \\ -5 \end{bmatrix} \end{aligned}$$

**Sprawdzenie:**  $M\mathbf{v} = \begin{bmatrix} 2+2+0-3 \\ 6+0-1+6 \\ -2+1-4+0 \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \\ -5 \end{bmatrix} \checkmark$

## Geometria kolumn: Obrót o $\theta = 30^\circ$ (Wektor $e_1$ )




### Pierwsza kolumna M

Współrzędne obrazu  $e_1$  wyznaczają funkcje trygonometryczne kąta  $\theta$ :

$$c_1 = T(e_1) = \begin{bmatrix} \cos 30^\circ \\ \sin 30^\circ \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{3}}{2} \\ \frac{1}{2} \end{bmatrix}$$

## Geometria kolumn: Obrót o $\theta = 30^\circ$ (Wektor $e_2$ )




### Druga kolumna M

Obrót  $e_2$  (osi  $y$ ) o  $30^\circ$  w lewo rzutuje go na ujemną część osi  $x$ :

$$c_2 = T(e_2) = \begin{bmatrix} -\sin 30^\circ \\ \cos 30^\circ \end{bmatrix} = \begin{bmatrix} -\frac{1}{2} \\ \frac{\sqrt{3}}{2} \end{bmatrix}$$


# Przekształcenie $T$ : pełna macierz obrotu o $\theta = 30^\circ$

Kolumna 1: obraz  $e_1$



$$T(e_1) = \begin{bmatrix} \frac{\sqrt{3}}{2} \\ \frac{1}{2} \end{bmatrix}$$

Kolumna 2: obraz  $e_2$



$$T(e_2) = \begin{bmatrix} -\frac{1}{2} \\ \frac{\sqrt{3}}{2} \end{bmatrix}$$


Macierz obrotu o  $30^\circ$

$$\mathbf{M} = \begin{bmatrix} T(e_1) & T(e_2) \end{bmatrix} = \begin{bmatrix} \cos 30^\circ & -\sin 30^\circ \\ \sin 30^\circ & \cos 30^\circ \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{bmatrix}$$

# Macierz obrotu jest ortogonalna

Kolumny macierzy obrotu  $\mathbf{M}$  tworzą **ortonormalny** układ wektorów: są parami prostopadłe i każda ma długość 1.

## Ilustracja geometryczna



## Weryfikacja: prostotałość

Iloczyn skalarny kolumn wynosi zero:

$$\begin{aligned}\mathbf{c}_1 \cdot \mathbf{c}_2 &= \begin{bmatrix} \frac{\sqrt{3}}{2} \\ \frac{1}{2} \end{bmatrix} \cdot \begin{bmatrix} -\frac{1}{2} \\ \frac{\sqrt{3}}{2} \end{bmatrix} \\ &= \frac{\sqrt{3}}{2} \cdot \left(-\frac{1}{2}\right) + \frac{1}{2} \cdot \frac{\sqrt{3}}{2} \\ &= -\frac{\sqrt{3}}{4} + \frac{\sqrt{3}}{4} = \mathbf{0} \checkmark\end{aligned}$$

## Weryfikacja: normalizacja

Każda kolumna ma długość 1:

$$\begin{aligned}\|\mathbf{c}_1\|^2 &= \cos^2 30^\circ + \sin^2 30^\circ = \mathbf{1} \checkmark \\ \|\mathbf{c}_2\|^2 &= \sin^2 30^\circ + \cos^2 30^\circ = \mathbf{1} \checkmark\end{aligned}$$

# Każdy obrót płaszczyzny jest macierzą ortogonalną

Wynik nie jest przypadkiem kąta  $30^\circ$  – zachodzi dla **dowolnego** kąta  $\theta$ .

Macierz obrotu o dowolny kąt  $\theta$

$$\mathbf{R}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Prostopadłość kolumn

$$\begin{aligned} \mathbf{c}_1 \cdot \mathbf{c}_2 &= \cos \theta \cdot (-\sin \theta) + \sin \theta \cdot \cos \theta \\ &= -\cos \theta \sin \theta + \sin \theta \cos \theta \\ &= \mathbf{0} \checkmark \end{aligned}$$

Normalizacja kolumn

$$\|\mathbf{c}_1\|^2 = \cos^2 \theta + \sin^2 \theta = \mathbf{1} \checkmark$$

$$\|\mathbf{c}_2\|^2 = \sin^2 \theta + \cos^2 \theta = \mathbf{1} \checkmark$$

(tożsamość Pitagorasa dla każdego  $\theta$ )

# Obroty i ogólna charakterystyka ortonormalności

## Wniosek ogólny

Dla każdego  $\theta \in \mathbb{R}$ :

$$\mathbf{R}_\theta^\top \mathbf{R}_\theta = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I} \checkmark$$

Macierz  $\mathbf{R}_\theta$  jest ortogonalna **niezależnie od kąta** – wynika to wyłącznie z tożsamości trygonometrycznej  $\cos^2 \theta + \sin^2 \theta = 1$ .

## Wniosek: $\mathbf{M}^\top \mathbf{M} = \mathbf{I}$

Ortonormalność kolumn jest równoważna warunkowi  $\mathbf{M}^\top \mathbf{M} = \mathbf{I}$ :

$$\mathbf{M}^\top \mathbf{M} = \begin{bmatrix} \frac{\sqrt{3}}{2} & \frac{1}{2} \\ -\frac{1}{2} & \frac{\sqrt{3}}{2} \end{bmatrix} \begin{bmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I} \checkmark$$

Macierz spełniająca ten warunek nazywamy **macierzą ortogonalną**; jej odwrotność to transpozycja:  
 $\mathbf{M}^{-1} = \mathbf{M}^\top$ .

# Macierze Ortonormalne i własność $\mathbf{M}^T = \mathbf{M}^{-1}$

## Definicja

Macierz  $\mathbf{M}$  jest **ortonormalna**, jeśli jej kolumny  $\mathbf{c}_i$  spełniają:  $\mathbf{c}_i^T \mathbf{c}_j = \delta_{ij}$  (są jednostkowe i wzajemnie prostopadłe).

## Dowód własności odwrotności przez transpozycję

Rozważmy iloczyn  $\mathbf{A} = \mathbf{M}^T \mathbf{M}$ . Element  $a_{ij}$  tej macierzy to:

$$a_{ij} = (\text{wiersz } i \text{ macierzy } \mathbf{M}^T) \cdot (\text{kolumna } j \text{ macierzy } \mathbf{M})$$

Ponieważ wiersz  $i$  macierzy  $\mathbf{M}^T$  to kolumna  $\mathbf{c}_i$  macierzy  $\mathbf{M}$ :

$$a_{ij} = \mathbf{c}_i^T \mathbf{c}_j = \begin{cases} 1 & \text{dla } i = j \\ 0 & \text{dla } i \neq j \end{cases}$$

Zatem  $\mathbf{M}^T \mathbf{M} = \mathbf{I}$ , oraz łatwo pokazać, że  $\mathbf{M} \mathbf{M}^T = \mathbf{I}$  co oznacza, że  $\mathbf{M}^{-1} = \mathbf{M}^T$ .

# Dowód: $M^T M = I \implies M M^T = I$

## Założenie

$M \in \mathbb{R}^{n \times n}$  jest macierzą **kwadratową** oraz

$$M^T M = I.$$

## Kluczowa obserwacja

Z  $M^T M = I$  wynika, że  $M^T$  jest **lewą odwrotnością**  $M$ .

Dla macierzy **kwadratowych** lewa odwrotność jest jednocześnie odwrotnością właściwą:

$$M^{-1} = M^T,$$

więc natychmiast

$$M M^{-1} = I \implies \boxed{M M^T = I.}$$

## Dowód elementarny (przez transpozycję)

Zaczynamy od założenia:

$$M^T M = I.$$

Transponujemy obie strony:

$$(M^T M)^T = I^T.$$

Stosujemy własności transpozycji  $(AB)^T = B^T A^T$  oraz  $(M^T)^T = M$ :

$$(M^T M)^T = M (M^T)^T = M M^T,$$

a ponieważ  $I^T = I$ , otrzymujemy:

$$\boxed{M M^T = I.}$$

Przykład zastosowań  
przekształceń ortonormalnych  
do analizy szeregów czasowych:  
Macierz Hadamarda

# Tygodniowe zwroty spółki: punkt wyjścia

Analizujemy cztery tygodniowe zwroty akcji. To nasz szereg czasowy – punkt wyjścia do naszej analizy.


## Dane wejściowe

Zwroty tygodniowe (w %):

$$r = \begin{bmatrix} 2 \\ -1 \\ 3 \\ -2 \end{bmatrix} \leftarrow 4 \text{ tygodnie}$$

Każda współrzędna to jeden tydzień – **baza czasowa**.

## Wizualizacja



# Co kryje się w surowych zwrotach?

Za naprzemiennością zwrotów mogą stać **zupełnie różne zjawiska rynkowe**. Patrząc na surowe liczby – nie da się ich od siebie oddzielić.

Trzy możliwe składowe – niewidoczne w bazie czasowej

| składowa         | opis                             | pytanie rynkowe    |
|------------------|----------------------------------|--------------------|
| <b>trend</b>     | akcja średnio rośnie lub spada   | czy warto trzymać? |
| <b>oscylacja</b> | zwroty odbijają co tydzień       | mean-reversion?    |
| <b>asymetria</b> | I połowa okresu $\neq$ II połowa | zmiana reżimu?     |

## Problem

W bazie czasowej  $t = 1, 2, 3, 4$  wszystkie te składowe **mieszają się** w każdej obserwacji. Nie możemy ich osobno odczytać.

## Pytanie

Czy istnieje **zmiana bazy**, która automatycznie rozdzieli te składowe – i przy tym nie straci żadnej informacji?

# Zmiana bazy bez utraty informacji: warunek na $Q$

Szukamy macierzy  $Q$ , która rozdziela składowe  $i$  pozwala wrócić do oryginalnych danych. To dokładnie warunek ortonormalności.

## Transformacja i jej odwrotność

Nowe współrzędne:

$$\tilde{r} = Qr \quad - \text{rozkład na składowe}$$

Powrót do oryginału:

$$r = Q^T \tilde{r} \quad - \text{pełna rekonstrukcja}$$

Warunek gwarantujący odwracalność:

$$Q^T Q = I$$

## Co to oznacza geometrycznie?

Macierz  $Q$  tylko **obraca** układ współrzędnych – nie rozciąga, nie ściska. Każdy wektor zachowuje swoją długość:

$$\|Qr\| = \|r\|$$

## Co to oznacza finansowo?

Całkowita “energia” zwrotów jest zachowana:

$$\|\tilde{r}\|^2 = \|r\|^2$$

Nic nie ginie – **zmieniamy tylko sposób patrzenia** na te same dane.

# Rozwiązanie: macierz Hadamarda $\mathbf{H}_4$

Macierz Hadamarda spełnia warunek  $\mathbf{H}_4^\top \mathbf{H}_4 = \mathbf{I}$  i przypisuje każdemu wierszowi **dokładnie jedną** składową rynkową.

## Macierz $\mathbf{H}_4$

$$\mathbf{H}_4 = \frac{1}{2} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}$$

Każdy wiersz to wzorec  $\pm 1$  – ortonormalny z pozostałymi.

## Interpretacja wierszy

| wiersz | wzorec  | składowa   |
|--------|---------|------------|
| 1      | + + + + | trend      |
| 2      | + - + - | oscylacja  |
| 3      | + + - - | asymetria  |
| 4      | + - - + | interakcja |

## Gotowość do transformacji

Mamy dane  $\mathbf{r} = [2, -1, 3, -2]^\top$  i macierz  $\mathbf{H}_4$ . Na następnych slajdach wykonamy transformację  $\tilde{\mathbf{r}} = \mathbf{H}_4 \mathbf{r}$  i odczytamy, która składowa **dominuje** w tym szeregu.

## Przykład $n = 4$ : surowe zwroty $\rightarrow$ składowe

Cztery tygodniowe zwroty akcji. Pytanie: czy kryje się w nich trend, czy raczej mean-reversion?

### Dane wejściowe

Tygodniowe zwroty (%):

$$\mathbf{r} = \begin{bmatrix} 2 \\ -1 \\ 3 \\ -2 \end{bmatrix}$$

Na oko: naprzemiennosc – ale ile jej jest?

### Transformacja $\tilde{\mathbf{r}} = \mathbf{H}_4 \mathbf{r}$

$$\tilde{\mathbf{r}} = \frac{1}{2} \begin{bmatrix} 2-1+3-2 \\ 2+1+3+2 \\ 2-1-3+2 \\ 2+1-3-2 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 0 \\ -1 \end{bmatrix}$$

### Odczyt składowych

| $\tilde{r}_i$ | wartość | wniosek          |
|---------------|---------|------------------|
| trend         | 1%      | słaby wzrost     |
| oscylacja     | 4       | <b>dominuje!</b> |
| asymetria     | 0       | brak             |
| interakcja    | -1      | mały szum        |

### Parseval: kontrola

$$\underbrace{4 + 1 + 9 + 4}_{\|\mathbf{r}\|^2 = 18} = \underbrace{1 + 16 + 0 + 1}_{\|\tilde{\mathbf{r}}\|^2 = 18} \checkmark$$

Energia zachowana – transformacja poprawna.

# Filtracja: rekonstrukcja z wybranych składowych

Ponieważ  $\mathbf{H}_n^{-1} = \mathbf{H}_n^\top$ , możemy **celowo pominąć** wybrane składowe i zrekonstruować odsumiony szereg.

Definicja: rzut na podzbiór  $S \subset \{1, \dots, n\}$

Zerujemy składowe spoza  $S$ :

$$(\tilde{\mathbf{r}}_S)_i = \begin{cases} \tilde{r}_i & i \in S \\ 0 & i \notin S \end{cases}$$

Odfiltrowany szereg:

$$\mathbf{r}_{\text{filtr}} = \mathbf{H}_n^\top \tilde{\mathbf{r}}_S$$

## Przykłady filtrów

- $S = \{1\}$ : czysty **trend**, bez oscylacji
- $S = \{2\}$ : czysta **oscylacja** do pairs trading
- $S = \{1, 2\}$ : trend + mean-reversion, bez szumu
- $S = \{1, \dots, n-1\}$ : wszystko **oprócz** szumu

## Błąd filtracji – Parseval

Błąd rekonstrukcji to **dokładnie** energia wyrzuconych składowych:

$$\|\mathbf{r} - \mathbf{r}_{\text{filtr}}\|^2 = \sum_{i \notin S} \tilde{r}_i^2$$

Nic nie ginie bez naszej wiedzy – wiemy **ile** i **co** wyrzucamy.

## Przykład $n = 4$ : filtracja i powrót do szeregu

Wiemy, że dominuje oscylacja ( $\tilde{r}_2 = 4$ ). Zostawiamy trend i oscylację ( $S = \{1, 2\}$ ), resztę uznajemy za szum.

Filtracja:  $S = \{1, 2\}$

Zerujemy składowe 3 i 4:

$$\tilde{\mathbf{r}}_S = \begin{bmatrix} 1 \\ 4 \\ 0 \\ 0 \end{bmatrix}$$

Rekonstrukcja  $\mathbf{r}_{\text{filtr}} = \mathbf{H}_4^\top \tilde{\mathbf{r}}_S$ :

$$\mathbf{r}_{\text{filtr}} = \frac{1}{2} \begin{bmatrix} 1 + 4 \\ 1 - 4 \\ 1 + 4 \\ 1 - 4 \end{bmatrix} = \begin{bmatrix} 2.5 \\ -1.5 \\ 2.5 \\ -1.5 \end{bmatrix}$$

Interpretacja finansowa

Odfiltrowany szereg  $[2.5, -1.5, 2.5, -1.5]$  odśłania czysty rytm **mean-reversion** – akcja odbija dokładnie co tydzień.

To sygnał do strategii **pairs trading**: kupuj po tygodniu spadku, sprzedaj po wzroście.

Koszt filtracji

Wyrzuciliśmy składowe 3 i 4:

$$\|\mathbf{r} - \mathbf{r}_{\text{filtr}}\|^2 = \tilde{r}_3^2 + \tilde{r}_4^2 = 0 + 1 = 1$$

Oryginalne dane różnią się od odfiltrowanych o **zaledwie 1** jednostkę energii – szum był naprawdę mały.

# Macierz Hadamarda dla dowolnego $n$ : definicja rekurencyjna

Macierz Hadamarda budujemy przez **jednokrokowe złożenie** – każdy kolejny rząd powstaje z poprzedniego automatycznie przez jedno proste działanie.

## Definicja

Baza rekursji:

$$\mathbf{H}_1 = \begin{bmatrix} 1 \end{bmatrix}$$

Krok  $n \rightarrow 2n$ :

$$\mathbf{H}_{2n} = \frac{1}{\sqrt{2}} \begin{bmatrix} \mathbf{H}_n & \mathbf{H}_n \\ \mathbf{H}_n & -\mathbf{H}_n \end{bmatrix}$$

Czynnik  $\frac{1}{\sqrt{2}}$  na każdym poziomie zapewnia ortonormalność kolumn.

## Pierwsze dwa poziomy

$$\mathbf{H}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \quad \mathbf{H}_4 = \frac{1}{2} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}$$

# Macierz Hadamarda: dowód ortonormalności dla dowolnego $n$

Ortonormalność  $\mathbf{H}_n$  nie jest przypadkiem – wynika z samej struktury rekurencji i przenosi się na każdy kolejny poziom.

Twierdzenie (indukcja po  $k$ )

Dla każdego  $k \geq 1$ :  $\mathbf{H}_{2^k}^\top \mathbf{H}_{2^k} = \mathbf{I}$ .

Dowód: krok indukcyjny  $n \rightarrow 2n$

Zakładamy  $\mathbf{H}_n^\top \mathbf{H}_n = \mathbf{I}$ . Wtedy:

$$\begin{aligned}\mathbf{H}_{2n}^\top \mathbf{H}_{2n} &= \frac{1}{2} \begin{bmatrix} \mathbf{H}_n^\top & \mathbf{H}_n^\top \\ \mathbf{H}_n^\top & -\mathbf{H}_n^\top \end{bmatrix} \begin{bmatrix} \mathbf{H}_n & \mathbf{H}_n \\ \mathbf{H}_n & -\mathbf{H}_n \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} \mathbf{H}_n^\top \mathbf{H}_n + \mathbf{H}_n^\top \mathbf{H}_n & \mathbf{H}_n^\top \mathbf{H}_n - \mathbf{H}_n^\top \mathbf{H}_n \\ \mathbf{H}_n^\top \mathbf{H}_n - \mathbf{H}_n^\top \mathbf{H}_n & \mathbf{H}_n^\top \mathbf{H}_n + \mathbf{H}_n^\top \mathbf{H}_n \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 2\mathbf{I} & \mathbf{0} \\ \mathbf{0} & 2\mathbf{I} \end{bmatrix} = \mathbf{I}_{2n} \quad \checkmark\end{aligned}$$

# $n$ notowań $\rightarrow n$ składowych: co oznacza każda współrzędna?

Transformacja  $\tilde{\mathbf{r}} = \mathbf{H}_n \mathbf{r}$  nie zmienia wymiaru. Zamieniamy  $n$  notowań na  $n$  współrzędnych – każda ma **precyzyjną interpretację** rynkową.

Mapa: wiersz  $\mathbf{H}_n \leftrightarrow$  składowa rynkowa

| wsp.          | wzorzec           | interpretacja                       | sygnał        |
|---------------|-------------------|-------------------------------------|---------------|
| $\tilde{r}_1$ | +++...+           | <b>trend</b> : średni zwrot         | momentum      |
| $\tilde{r}_2$ | + - + - ...       | <b>oscylacja</b> : mean-reversion   | pairs trading |
| $\tilde{r}_3$ | ++--...           | <b>asymetria</b> : I vs II połowa   | breakout      |
| $\tilde{r}_n$ | najszybsza zmiana | <b>szum</b> wysokiej częstotliwości | odrzucaamy    |

## Kluczowa obserwacja

W bazie czasowej ( $t = 1, 2, \dots, n$ ) trend, oscylacja i szum **mieszają się** w każdym notowaniu. W bazie Hadamarda każda współrzędna  $\tilde{r}_i$  odpowiada **dokładnie jednej** składowej – odczytujemy je niezależnie.

Dwie interpretacje  
linowych przekształceń wektorów:  
aktywna (kowariantna)  
i pasywna (kontrawariantna)

# Intuicje na wektorach finansowych: Liczby vs Rzeczywistość

## Natura współrzędnych portfela ( $V^i$ ):

### a. Zmiana Pasywna (Walutowa):

Gdy **dolar drożeje** (wzmocnienie bazy), liczba opisująca wartość naszych aktywów w USD **maleje**.

**Kontrawariancja** – współrzędne zmieniają się odwrotnie do wartości jednostki (bazy), aby zachować realny byt fizyczny aktywa.

### b. Zmiana Aktywna (Inwestycyjna):

Gdy **dokupujemy** aktywa, ich fizyczna ilość i liczbowy opis w portfelu **rosną**.

**Transformacja Aktywna** – działamy bezpośrednio na obiekcie. Zmieniamy jego składowe (kontrawariantne) w sposób zgodny z naszą decyzją, przy niezmiennym kursie (bazie).

*Zapamiętaj: "Kontra" oznacza, że liczby muszą "walczyć" ze zmianą waluty!*

# Dwa typy przekształceń liniowych: Portfel Aktywów

## Zestawienie interpretacji transformacji liniowej ( $V^i$ )

| Cecha                       | Transformacja Pasywna         | Transformacja Aktywna          |
|-----------------------------|-------------------------------|--------------------------------|
| Natura zmiany               | Zmiana opisu (Baza)           | Zmiana obiektu (Wektor)        |
| Kontekst                    | Zmiana kursu waluty (np. USD) | Decyzja (np. kupno złota)      |
| Relacja (USD $\uparrow$ )   | Liczby maleją ( $M^{-1}$ )    | Stan posiadania rośnie ( $M$ ) |
| Relacja (USD $\downarrow$ ) | Liczby rosną ( $M^{-1}$ )     | Stan posiadania maleje ( $M$ ) |
| Rola macierzy               | Zmiana "miarki" (waluty)      | Fizyczny ruch (handel)         |

## Klucz do intuicji:

- **Pasywnie:** Twój portfel "stoi w miejscu", ale zmienia się świat wokół niego. Liczby muszą się dostosować do nowej wartości dolara.
- **Aktywnie:** Ty zmieniasz świat swojego portfela. Kupujesz więcej aktywów, więc ich liczba w zestawieniu rośnie bezpośrednio.

Bardzo proste algebraiczne wyjaśnienie  
interpretacji przekształceń liniowych:  
aktywnej i pasywnej

# Wyjaśnienie dwóch interpretacji: aktywna i pasywna: obrót o $\theta = 30^\circ$

## Transformacja aktywna: obrót wektora


Macierz obrotu o kąt  $\theta$ :

$$\mathbf{R}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Kolumny = obrazy  $e_1, e_2$  po obrocie:

$$T(e_1) = \begin{bmatrix} \cos 30^\circ \\ \sin 30^\circ \end{bmatrix}, \quad T(e_2) = \begin{bmatrix} -\sin 30^\circ \\ \cos 30^\circ \end{bmatrix}$$

Wektor  $v$  obraca się o  $+30^\circ$ ; **osie stoją w miejscu**.



## Kluczowa symetria

$$\mathbf{R}_\theta^T = \mathbf{R}_\theta^{-1} = \mathbf{R}_{-\theta}$$

Dla macierzy ortogonalnych transpozycja = odwrotność.

To nie przypadek – to **definicja** ortogonalności.

## Transformacja pasywna: obrót układu osi

Układ osi obraca się o  $+30^\circ$ ; **wektor stoi w miejscu**.

Współrzędne w nowym układzie:

$$[v]_{B'} = \mathbf{R}_\theta^T v = \mathbf{R}_\theta^{-1} v$$

Transformacja aktywna:  
obiekt naprawdę się zmienia

# Transformacja aktywna: obiekt naprawdę się zmienia

## Definicja

Transformacja aktywna to działanie

$$\mathbf{v}_{\text{new}} = \mathbf{M}\mathbf{v}_{\text{old}},$$

przy którym zmienia się **sam obiekt**.

## Interpretacja finansowa

- rebalancing portfela,
- automatyczna strategia rotacji sektorowej,
- przejście od portfela dziś do portfela po wykonaniu decyzji.

## Interpretacje poza finansami

- mechanika: ruch bryły w przestrzeni,
- grafika: obrót obiektu 3D,
- przetwarzanie sygnałów: filtr aktywnie modyfikujący dane,
- analiza TS: operator przejścia stanu w modelu liniowym.

## Pytanie kontrolne

Czy po zastosowaniu macierzy mamy **ten sam** portfel opisany inaczej, czy **inny** portfel? W transformacji aktywnej: **inny portfel**.

Transformacja pasywna:  
ten sam portfel, inny opis

## ++Jak powstaje nowy opis wektora?

Wektor  $\mathbf{v}$  to suma składników bazy pomnożonych przez ich „ilości” (współrzędne):

$$\mathbf{v} = \alpha_1 \mathbf{b}_1 + \alpha_2 \mathbf{b}_2 + \cdots + \alpha_n \mathbf{b}_n \quad (1)$$

### Zapis macierzowy

Możemy to zapisać elegancko, ustawiając wektory bazy  $\mathbf{b}_i$  jako kolumny macierzy  $\mathbf{P}$ :

$$\mathbf{v} = \underbrace{\begin{bmatrix} | & | & & | \\ \mathbf{b}_1 & \mathbf{b}_2 & \cdots & \mathbf{b}_n \\ | & | & & | \end{bmatrix}}_{\mathbf{P}} \underbrace{\begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix}}_{[\mathbf{v}]_B}$$

### Kluczowa intuicja

Wzór  $\mathbf{v} = \mathbf{P}[\mathbf{v}]_B$  to instrukcja: „Weź bazę  $\mathbf{P}$  i złóż z niej wektor  $\mathbf{v}$  używając wag  $[\mathbf{v}]_B$ ”.

## ++Jak znaleźć współrzędne?

Skoro wiemy już, że:

$$\mathbf{v} = \mathbf{P}[\mathbf{v}]_B$$

To aby wyizolować same współrzędne  $[\mathbf{v}]_B$  (czyli nasze  $\alpha_i$ ), musimy „pozbyć się” macierzy  $\mathbf{P}$  poprzez mnożenie lewostronne przez jej odwrotność:

Wzór na współrzędne (kontrawariancja)

$$\begin{aligned}\mathbf{P}^{-1}\mathbf{v} &= \mathbf{P}^{-1}\mathbf{P}[\mathbf{v}]_B \\ [\mathbf{v}]_B &= \mathbf{P}^{-1}\mathbf{v}\end{aligned}$$

- $\mathbf{P}$  – służy do składania obiektu z opisu (z bazy do świata).
- $\mathbf{P}^{-1}$  – służy do wyliczania opisu z obiektu (ze świata do bazy).

Dydaktyczna uwaga

Pamiętaj: Współrzędne  $[\mathbf{v}]_B$  transformują się **kontrawariantnie**. Jeśli baza  $\mathbf{P}$  „rośnie”, to współrzędne muszą „maleć” ( $\mathbf{P}^{-1}$ ), aby wektor  $\mathbf{v}$  pozostał ten sam.

# Transformacja pasywna: ten sam portfel, inny opis

## Definicja

Transformacja pasywna nie zmienia obiektu. Zmienia tylko sposób jego opisu:

$$[v]_B = \mathbf{P}^{-1}v.$$

## Co pozostaje stałe?

- ten sam portfel,
- ta sama wartość ekonomiczna,
- ta sama pozycja w przestrzeni portfeli.

## Interpretacja finansowa

- zmiana waluty raportowania,
- zmiana jednostki: akcje → pakiety po 10 akcji,
- zmiana bazy z „pojedynczych aktywów” na „portfele stylów inwestycyjnych”.

## Puenta

W transformacji pasywnej nie pytamy: *co zrobiła strategia?* lecz: *w jakim języku opisujemy ten sam portfel?*

# Przykład pasywny: zmiana jednostki raportowania

## Sytuacja

Portfel ma 100 akcji spółki. Wprowadzamy nową jednostkę:  
**pakiet 10 akcji.**

$$\mathbf{b}_1 = 10\mathbf{e}_1$$

Macierz bazy to więc po prostu

$$\mathbf{P} = [10].$$

## Obliczenie współrzędnych

W starej bazie:

$$\mathbf{v} = [100].$$

W nowej bazie:

$$[\mathbf{v}]_B = \mathbf{P}^{-1}\mathbf{v} = [10]^{-1}[100] = [10].$$

## Interpretacja

- portfel się nie zmienił,
- nadal mamy ten sam majątek,
- zmienił się tylko język opisu: 100 akcji = 10 pakietów.

## Wniosek

Jeżeli baza rośnie, współrzędne maleją. To jest rdzeń intuicji dla transformacji pasywnej.

Podsumowanie dwóch interpretacji  
(aktywnej i pasywnej )

# Dwie interpretacje tej samej macierzy $M$

## Transformacja **aktywna**

$$\mathbf{v}_{\text{nowy}} = \mathbf{M} \mathbf{v}_{\text{stary}}$$

- **Zmienia się obiekt**; baza stała
- Finanse: rebalancing portfela aktywów
- ML: filtr, projekcja danych, normalizacja
- Geometria: obrót/skalowanie figury

## Transformacja **pasywna**

$$[\mathbf{v}]_B = \mathbf{P}^{-1} \mathbf{v}$$

- Obiekt stały; **zmienia się układ opisu**
- Finanse: zmiana waluty raportowania
- ML: zmiana układu współrzędnych (PCA)
- Geometria: obrót układu osi

## Finansowa mapa analogii

| Dziedzina | Aktywna                 | Pasywna           |
|-----------|-------------------------|-------------------|
| Finanse   | rebalancing portfela    | zmiana waluty     |
| ML/DS     | transformacja cech      | zmiana bazy (PCA) |
| Sygnały   | filtr modyfikujący dane | nowe osie analizy |

## Puenta sekcji

Czy zmienił się **obiekt** (portfel, dane)?  
Czy zmienił się tylko **opis** (waluta, baza)?

**Rozkład  $QR$  odpowie na oba pytania.**

# Podsumowanie dwóch interpretacji (aktywnej i pasywnej )

| Obiekt               | Pytanie                                     | Wzór                                                 | Interpretacja finansowa              |
|----------------------|---------------------------------------------|------------------------------------------------------|--------------------------------------|
| Wektor               | co posiadam?                                | $\boldsymbol{v}$                                     | portfel aktywów                      |
| Cena                 | ile to jest warte?                          | $V = \boldsymbol{p}^T \boldsymbol{v}$                | wycena portfela                      |
| Operator             | co robi strategia?                          | $\boldsymbol{v}' = \mathbf{M}\boldsymbol{v}$         | rebalancing, filtr, dynamika         |
| Baza                 | jak opisuję portfel?                        | $\boldsymbol{v} = \mathbf{P}[\boldsymbol{v}]_B$      | portfele modelowe jako nowe osie     |
| Zmiana współrzędnych | jak wygląda ten sam portfel w nowym języku? | $[\boldsymbol{v}]_B = \mathbf{P}^{-1}\boldsymbol{v}$ | waluty, pakiety, zmiana raportowania |

Po tym etapie wiemy, czym różni się transformacja aktywna od pasywnej.

# Podsumowanie Intuicji Geometrycznych: Interpretacja Pasywna vs Aktywna

## Transformacja Pasywna (Kontrawariancja)

### Zmieniasz bazę (układ osi)

*Wektor (sztabka złota) leży nieruchomo. Obracamy układ współrzędnych (walutę) o  $45^\circ$ . Aby opisać ten sam punkt, współrzędne muszą się „cofnąć” o  $-45^\circ$  ( $P^{-1}$ ). Liczby idą pod prąd osi!*

## Transformacja Aktywna (Kowariancja)

### Zmieniasz wektor (obiekt)

*Układ współrzędnych stoi w miejscu. Fizycznie obracasz wektor o  $45^\circ$  (dokupujesz złoto). Wektor przemieszcza się „zgodnie” z transformacją  $M$ . Zmieniasz stan posiadania!*

## Dydaktyczny wniosek

- **Pasywna** ( $P^{-1}$ ): Przeliczasz ten sam majątek w nowym języku.
- **Aktywna** ( $M$ ): Fizycznie zmieniasz swój majątek.

# Macierze ortonormalne

# Macierze ortonormalne: $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ i $\mathbf{Q}^{-1} = \mathbf{Q}^T$

## Definicja

Macierz  $\mathbf{Q}$  jest **ortonormalna**, gdy jej kolumny  $\mathbf{q}_1, \dots, \mathbf{q}_n$  spełniają:

$$\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

Kolumny są **jednostkowe** i **wzajemnie prostopadłe**.

## Dowód: $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$

Element  $(i, j)$  iloczynu  $\mathbf{Q}^T \mathbf{Q}$ :

$$(\mathbf{Q}^T \mathbf{Q})_{ij} = \mathbf{q}_i^T \mathbf{q}_j = \delta_{ij}$$

Zatem  $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ , a z kwadratowości macierzy:

$$\boxed{\mathbf{Q}^{-1} = \mathbf{Q}^T}$$

## Dowód: $\mathbf{Q}^T \mathbf{Q} = \mathbf{I} \Rightarrow \mathbf{Q} \mathbf{Q}^T = \mathbf{I}$

Transponujemy obie strony:

$$(\mathbf{Q}^T \mathbf{Q})^T = \mathbf{I}^T$$

Stosujemy  $(AB)^T = B^T A^T$ :

$$\mathbf{Q}^T (\mathbf{Q}^T)^T = \mathbf{Q} \mathbf{Q}^T = \mathbf{I} \quad \checkmark$$

## Geometryczne właściwości $\mathbf{Q}$

- Zachowuje normy:  $\|\mathbf{Q}\mathbf{v}\| = \|\mathbf{v}\|$
- Zachowuje kąty:  $\langle \mathbf{Q}\mathbf{u}, \mathbf{Q}\mathbf{v} \rangle = \langle \mathbf{u}, \mathbf{v} \rangle$
- $\det(\mathbf{Q}) = \pm 1$  (obrot lub odbicie)

## Dla ML i analizy danych

Transformacja przez  $\mathbf{Q}$  **nie zniekształca** danych – zmienia tylko orientację. Idealna do zmiany bazy

Iloczyn skalarny i ortogonalność i G-S

# Iloczyn skalarny i ortogonalność

## Iloczyn skalarny w $\mathbb{R}^n$

$$\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i$$

Mierzy **podobieństwo kierunkowe** dwóch wektorów.

**Norma** (długość):  $\|x\| = \sqrt{\langle x, x \rangle}$

## Definicja ortogonalności


Wektory  $x$  i  $y$  są **ortogonalne** ( $x \perp y$ ) gdy:

$$\langle x, y \rangle = x^T y = 0$$

## Przykład standardowy

$$e_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad e_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad e_1^T e_2 = 0 \quad \checkmark$$

$$\begin{bmatrix} 3 \\ -1 \end{bmatrix}^T \begin{bmatrix} -1 \\ 3 \end{bmatrix} = -3 - 3 = -6 \neq 0$$



## Intuicja geometryczna

$\langle x, y \rangle = 0$  oznacza:

**brak projekcji**  $x$  w kierunku  $y$ .

Ortogonalność = **niezależne kierunki**: jeden wektor nic nie “mówi” o drugim.

# Bazy ortogonalne i ortonormalne: definicje i kluczowe własności

## Baza ortogonalna

Baza  $v_1, \dots, v_n$  jest **ortogonalna**, gdy:

$$v_i^T v_j = 0 \quad \text{dla } i \neq j$$

## Baza ortonormalna

Baza  $q_1, \dots, q_n$  jest **ortonormalna**, gdy:

$$q_i^T q_j = \delta_{ij}$$

(ortogonalna i znormalizowana:  $\|q_i\| = 1$ )

## Rozkład wektora w bazie orton.

$$x = \sum_{i=1}^n \langle x, q_i \rangle q_i$$

Współrzędne = **projekcje ortogonalne**: każda niezależna, bez układu równań.

## Tożsamość Parsewała

$$\|x\|^2 = \sum_{i=1}^n \langle x, q_i \rangle^2$$

Energia (wariancja) **rozdziela się** na niezależne składowe. Kluczowe w analizie sygnałów i PCA.

Baza **nieortogonalna**  
zależne wsp., układ równań

↓ Gram-Schmidt

Baza **ortonormalna**  
niezależne wsp., tylko projekcje

## Dla ML/analizy szeregów

W bazie ortonormalnej: cechy **niezależne**, obliczenia **numerycznie stabilne**, interpretacja **jednoznaczna**.


# Problem: co gdy baza nie jest ortogonalna?

## Przykład bazy nieortogonalnej

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$
$$\mathbf{v}_1^T \mathbf{v}_2 = 1 \cdot 1 + 0 \cdot 1 = 1 \neq 0$$

## Konsekwencje

- Współrzędne w tej bazie **nie są niezależne**
- Rozkład wektora wymaga **rozwiązania układu równań**
- W ML: cechy mają **ukryte zależności** (multikolinearność)
- Obliczenia **numerycznie niestabilne** przy dużych macierzach
- Interpretacja parametrów modelu **utrudniona**



## Naturalne pytanie

Z dowolnej bazy  $\mathbf{v}_1, \dots, \mathbf{v}_n$   
możemy zbudować ortonormalną?

**Tak!** → **Algorytm Grama-Schmidta**

Projekcja ortogonalna na wektor


# Projekcja ortogonalna na wektor: kluczowa operacja

## Definicja projekcji ortogonalnej

Projekcja wektora  $v$  na kierunek  $u$ :

$$\text{proj}_u(v) = \frac{v^T u}{u^T u} u$$

Dla wektora jednostkowego  $\|u\| = 1$ :  $\text{proj}_u(v) = (v^T u) u$



## Rozkład ortogonalny wektora

$$v = \underbrace{\text{proj}_u(v)}_{\text{składowa równoległa}} + \underbrace{(v - \text{proj}_u(v))}_{\text{składowa ortogonalna}}$$

Składowa ortogonalna  $\perp u$  z definicji!

## Wzór w pigułce

$$\text{proj}_u(v) = \frac{v^T u}{\|u\|^2} u$$

współczynnik = **iloczyn skalarny** / **norma**<sup>2</sup>

## Interpretacja dla ML/szeregów

Projekcja = “ile z  $v$  leży w kierunku  $u$ ”.

Składowa ortogonalna = **nowa informacja**, niewyjaśniana przez  $u$ .

Macierze dodatnio określone  
i projekcje na podprzestrzeń  $W$ :  
wzór macierzowy

# Macierz dodatnio określona: definicja i intuicja

## Definicja

Macierz symetryczna  $A \in \mathbb{R}^{k \times k}$  jest **dodatnio określona**

(ang. *positive definite*), gdy:

$$\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \mathbf{x} \neq \mathbf{0}$$

## Intuicja geometryczna

Wyrażenie  $\mathbf{x}^T A \mathbf{x}$  to **forma kwadratowa** — przypisuje każdemu wektorowi  $\mathbf{x}$  liczbę rzeczywistą.

Warunek  $\mathbf{x}^T A \mathbf{x} > 0$  mówi:

- każdy niezerowy  $\mathbf{x}$  daje **dodatnią** wartość
- zero tylko dla  $\mathbf{x} = \mathbf{0}$

Analogia w  $\mathbb{R}^1$ :  $A = a > 0$ , forma to  $ax^2 > 0$  dla  $x \neq 0$ .

## Przykład: macierz jednostkowa

$A = I_k$ :

$$\mathbf{x}^T I_k \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2 > 0$$

dla każdego  $\mathbf{x} \neq \mathbf{0}$ . ✓

$I_k$  jest dodatnio określona.

## Przykład: macierz $2 \times 2$

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

$$\mathbf{x}^T A \mathbf{x} = 2x_1^2 + 3x_2^2 > 0$$

dla  $(x_1, x_2) \neq (0, 0)$ . ✓

## Uwaga

Nie każda macierz symetryczna jest dodatnio

# Macierz dodatnio określona jest odwracalna

## Przypomnienie

Macierz  $A$  jest **odwracalna** wtedy i tylko wtedy, gdy:

$$\ker(A) = \{0\}$$

tzn. jedynym rozwiązaniem  $Ax = 0$  jest  $x = 0$ .

## Twierdzenie

Jeśli  $A$  jest **dodatnio określona**, to  $A$  jest **odwracalna**.

## Schemat logiczny

$A$  dodatnio określona

$\Downarrow$

$$Ax = 0 \Rightarrow x^T Ax = 0 \Rightarrow x = 0$$

$\Downarrow$

$$\ker(A) = \{0\}$$

$\Downarrow$

## Dowód

Chcemy pokazać:  $\ker(A) = \{0\}$ .

Przypuśćmy, że  $Ax = 0$  dla pewnego  $x$ .

Pomnóżmy obustronnie przez  $x^T$ :

$$x^T Ax = x^T \cdot 0 = 0$$

Ale  $A$  jest dodatnio określona, więc:

$$x^T Ax = 0 \Rightarrow x = 0$$

Zatem jedynym rozwiązaniem  $Ax = 0$  jest

$x = 0$ ,

czyli  $\ker(A) = \{0\}$ ,

a więc  $A$  jest **odwracalna**. □

# Macierz Grama $G = U^T U$ : symetria i odwracalność

## Definicja macierzy Grama

Dla  $U = [\mathbf{u}_1 \mid \cdots \mid \mathbf{u}_k] \in \mathbb{R}^{n \times k}$  definiujemy:

$$G = U^T U \in \mathbb{R}^{k \times k}$$

Wpisy macierzy:

$$G_{ij} = \mathbf{u}_i^T \mathbf{u}_j$$

(iloczyn skalarny  $i$ -tej i  $j$ -tej kolumny  $U$ )

## Symetria (łatwa)

$$G^T = (U^T U)^T = U^T (U^T)^T = U^T U = G$$

Zamiana indeksów:  $G_{ij} = \mathbf{u}_i^T \mathbf{u}_j = \mathbf{u}_j^T \mathbf{u}_i = G_{ji}$ . ✓

## Twierdzenie

Jeśli kolumny  $U$  są **liniowo niezależne**,  
to  $G = U^T U$  jest **odwracalna**.

## Dowód: $G$ jest dodatnio określona

Weźmy dowolny  $\mathbf{x} \neq \mathbf{0}$ :

$$\begin{aligned} \mathbf{x}^T G \mathbf{x} &= \mathbf{x}^T U^T U \mathbf{x} \\ &= (U \mathbf{x})^T (U \mathbf{x}) \\ &= \|U \mathbf{x}\|^2 \geq 0 \end{aligned}$$

Kiedy  $\|U \mathbf{x}\|^2 = 0$ ?

$$\Leftrightarrow U \mathbf{x} = \mathbf{0} \Leftrightarrow \mathbf{x} = \mathbf{0}$$

(bo kolumny  $U$  liniowo niezależne) Zatem  
 $\mathbf{x}^T G \mathbf{x} > 0$  dla każdego  $\mathbf{x} \neq \mathbf{0}$ :  $G$  jest **dodatnio określona**, a więc **odwracalna**. □


# Rzut na podprzestrzeń: intuicja

## Sytuacja

Mamy podprzestrzeń  $W \subseteq \mathbb{R}^n$  rozpiętą przez wektory  $\mathbf{u}_1, \dots, \mathbf{u}_k$ :

$$W = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$$

**Pytanie:** jaki wektor w  $W$  jest *najbliższy* danemu  $\mathbf{v}$ ?



## Odpowiedź geometryczna

Szukamy  $\hat{\mathbf{v}} \in W$  takiego, że:

$$\hat{\mathbf{v}} = \arg \min_{\mathbf{w} \in W} \|\mathbf{v} - \mathbf{w}\|$$

Rozwiązaniem jest **rzut ortogonalny**  $\hat{\mathbf{v}} = \text{proj}_W(\mathbf{v})$ ,

bo reszta  $\mathbf{v} - \hat{\mathbf{v}}$  jest **prostopadła** do każdego  $\mathbf{u}_i$ :

$$(\mathbf{v} - \hat{\mathbf{v}}) \perp \mathbf{u}_i \quad \forall i = 1, \dots, k$$

## Rozkład ortogonalny

$$\mathbf{v} = \underbrace{\hat{\mathbf{v}}}_{\in W} + \underbrace{(\mathbf{v} - \hat{\mathbf{v}})}_{\perp W}$$

Każdy wektor rozkłada się **jednoznacznie** na część w  $W$  i część *prostopadłą* do  $W$ .

# Macierz projekcji ortogonalnej $P_W$

## Budujemy macierz $U$

Ustawiamy wektory bazowe jako kolumny:

$$U = [\mathbf{u}_1 \mid \cdots \mid \mathbf{u}_k] \in \mathbb{R}^{n \times k}$$

Jeśli wektory są liniowo niezależne,

to macierz Grama  $G = U^T U \in \mathbb{R}^{k \times k}$  jest **odwracalna**.

## Wzór na macierz projekcji

$$P_W = U(U^T U)^{-1} U^T$$

Rzut wektora  $\mathbf{v}$  na  $W$ :

$$\text{proj}_W(\mathbf{v}) = P_W \mathbf{v}$$

**Uwaga:**  $P_W$  nie zależy od wyboru konkretnej bazy — tylko od podprzestrzeni  $W$ .

## Kluczowe własności $P_W$

$P_W^2 = P_W$  rzutowanie dwa razy  
nie zmienia wyniku

$P_W^T = P_W$  macierz symetryczna

$\text{rank}(P_W) = k$  rząd = wymiar  $W$

$P_W \mathbf{u}_i = \mathbf{u}_i$  baza  $W$  zostaje w miejscu

## Szczególny przypadek: $k = 1$

Jeden wektor  $\mathbf{u}$ ,  $U = \mathbf{u}$ :

$$P_W = \frac{\mathbf{u} \mathbf{u}^T}{\mathbf{u}^T \mathbf{u}}$$

To dokładnie wzór z projekcji 1D!  
Ogólny wzór **uogólnia** tamten przypadek.

# Baza ortonormalna upraszcza wszystko

## Czym jest baza ortonormalna (ONB)?

Wektory  $\mathbf{q}_1, \dots, \mathbf{q}_k$  są ortonormalne gdy:

- **ortogonalne:**  $\mathbf{q}_i^T \mathbf{q}_j = 0$  dla  $i \neq j$   
(każde dwa wektory prostopadłe)
- **znormalizowane:**  $\mathbf{q}_i^T \mathbf{q}_i = 1$   
(każdy ma długość 1)

Zwięźle:  $\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij}$

## Co to oznacza dla macierzy $Q$ ?

Dla  $Q = [\mathbf{q}_1 \mid \dots \mid \mathbf{q}_k]$ :

$$Q^T Q = I_k$$

Macierz Grama staje się **macierzą jednostkową!**

## Uproszczony wzór macierzowy

Wstawiamy  $Q^T Q = I_k$  do ogólnego wzoru:

$$\begin{aligned} P_W &= Q \underbrace{(Q^T Q)^{-1}}_{= I_k} Q^T \\ &= \boxed{Q Q^T} \end{aligned}$$

**Nie trzeba odwracać żadnej macierzy!**

To główna zaleta bazy ortonormalnej.

## Porównanie wzorów

Baza ogólna:  $U(U^T U)^{-1} U^T$  Algorytm

Baza ONB:  $Q Q^T$  **(prostszy!)**

Gram-Schmidta (slajd C)

zamienia dowolną bazę  $U$  w bazę ONB  $Q$ .

# Projekcja ONB = suma rzutów jednowymiarowych


## Kluczowy wzór

Gdy  $\mathbf{q}_1, \dots, \mathbf{q}_k$  ortonormalne:

$$\text{proj}_W(\mathbf{v}) = \sum_{i=1}^k \underbrace{(\mathbf{v}^T \mathbf{q}_i)}_{\text{wsp. Fouriera}} \mathbf{q}_i$$

Każdy składnik  $(\mathbf{v}^T \mathbf{q}_i) \mathbf{q}_i$

to projekcja 1D na kierunek  $\mathbf{q}_i$ .



## Dlaczego działa? (intuicja)

Ortogonalność bazy oznacza, że kierunki  $\mathbf{q}_1, \dots, \mathbf{q}_k$  nie „przeszkadzają sobie”. Każdą współrzędną wyznaczamy **niezależnie** jednym iloczynem skalarnym. Analogia: składowe  $(x, y, z)$  w kartezjańskim układzie współrzędnych — bo osie są ortogonalne.

## Jak czytać diagram

- 1 Rzutuj  $\mathbf{v}$  na  $\mathbf{q}_1$  (zielona strzałka)
- 2 Rzutuj  $\mathbf{v}$  na  $\mathbf{q}_2$  (pomarańczowa)
- 3 Zsumuj oba wyniki
- 4 Otrzymujesz  $\text{proj}_W(\mathbf{v})$  (czerwony)


# Gram-Schmidt: idea i pierwsze dwa kroki

**Problem:** mamy złą bazę

Mamy  $\mathbf{u}_1, \dots, \mathbf{u}_k$  — liniowo niezależne, ale **nie** ortonormalne.

**Cel:** znaleźć  $\mathbf{q}_1, \dots, \mathbf{q}_k$  ortonormalne, rozpiające tę samą  $W$ .

**Po co?** By korzystać z  $P_W = QQ^T$  zamiast  $U(U^T U)^{-1}U^T$ .



**Krok 1:** normalizacja  $\mathbf{u}_1$

Przyjmij pierwszy kierunek bez zmian:

$$\mathbf{q}_1 = \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|}$$

Mamy  $\|\mathbf{q}_1\| = 1$  oraz  $\text{span}\{\mathbf{q}_1\} = \text{span}\{\mathbf{u}_1\}$ . ✓

**Kluczowa idea kroku 2**

Odejmując rzut  $\mathbf{u}_2$  na  $\mathbf{q}_1$ ,  
**usuwamy** tę część  $\mathbf{u}_2$ ,  
która jest „zgodna” z  $\mathbf{q}_1$ .

Co zostaje? Część **prostopadła** do  $\mathbf{q}_1$ .

# Gram-Schmidt: algorytm ogólny i zastosowania

## Ogólny krok $j$ ( $j = 2, \dots, k$ )

Odejmij rzuty na *wszystkie* dotychczasowe  $\mathbf{q}_1, \dots, \mathbf{q}_{j-1}$ :

$$\tilde{\mathbf{u}}_j = \mathbf{u}_j - \sum_{i=1}^{j-1} (\mathbf{u}_j^T \mathbf{q}_i) \mathbf{q}_i$$

Następnie normalizuj:

$$\mathbf{q}_j = \frac{\tilde{\mathbf{u}}_j}{\|\tilde{\mathbf{u}}_j\|}$$

Każdy „kawałek” zgodny z poprzednimi  $\mathbf{q}_i$  zostaje usunięty.

## Niezmienność algorytmu

Po każdym kroku  $j$  zachodzi:

$$\text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_j\} = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_j\}$$

Budujemy **tę samą** podprzestrzeń  $W$ , lecz z coraz lepszą —

## Wynik algorytmu

- $\mathbf{q}_1, \dots, \mathbf{q}_k$  — baza ONB dla  $W$
- $Q^T Q = I_k$  — kolumny parami ortonormalne
- $P_W = Q Q^T$  — prosta macierz projekcji
- Rozkład  $U = QR$ , gdzie  $R$  górnotrójkątna

## Zastosowania

- **MNK / regresja liniowa** numerycznie stabilna wersja normalna
- **PCA**  
ortogonalne kierunki wariancji
- **Metody Kryłowa** iteracyjne solwery układów liniowych

# Podsumowanie: Algorytm Grama–Schmidta (1/2)

## Kroki algorytmu

**Krok 1:**  $\mathbf{u}_1 = \mathbf{v}_1$

**Krok 2:** usuwamy projekcję na  $\mathbf{u}_1$ :

$$\mathbf{u}_2 = \mathbf{v}_2 - \frac{\mathbf{v}_2^T \mathbf{u}_1}{\mathbf{u}_1^T \mathbf{u}_1} \mathbf{u}_1$$

**Krok  $k$ :** usuwamy projekcje na  $\mathbf{u}_1, \dots, \mathbf{u}_{k-1}$ :

$$\mathbf{u}_k = \mathbf{v}_k - \sum_{i=1}^{k-1} \frac{\mathbf{v}_k^T \mathbf{u}_i}{\mathbf{u}_i^T \mathbf{u}_i} \mathbf{u}_i$$

**Normalizacja:**  $\mathbf{q}_i = \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$

## Idea


**Z każdego wektora usuwamy jego projekcje na wszystkie wcześniejsze wektory.** Zostaje wyłącznie składowa prostopadła do wszystkich poprzednich.

## Gwarantowany wynik

$$\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij}$$

Zachowana podprzestrzeń:

$$\text{span}(\mathbf{q}_1, \dots, \mathbf{q}_k) = \text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k)$$




# Podsumowanie: Algorytm Grama–Schmidta (2/2)

## geometryczna interpretacja kroku 2

### Cztery etapy jednego kroku

- 1 Bierzemy nowy wektor  $v_2$
- 2 Obliczamy projekcję na  $u_1$ :  
 $\text{proj}_{u_1}(v_2)$  – składowa “stara”
- 3 Odejmujemy:  
 $u_2 = v_2 - \text{proj}_{u_1}(v_2)$
- 4  $u_2 \perp u_1$  z definicji różnicy



### Analogia w ML – residua regresji

Krok GS to dokładnie **regresja residualna**:

- Regresujemy  $v_2$  na  $u_1$
- Residuum = składowa ortogonalna
- Każde residuum jest **ortogonalne** do regresora

Gram–Schmidt  $\equiv$  sekwencyjne odejmowanie regresji.

### Wynik

$u_2 = v_2 - \text{proj}_{u_1}(v_2)$  jest **prostopadłe** do  $u_1$ . Po normalizacji:  $q_2 = u_2 / \|u_2\|$ .

*Geometria przekształceń portfela:  
Aktywne (kowariantne) i pasywne (kontrawariantne) interpretacje  
transformacji liniowej w analizie aktywów finansowych*

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

16 marca 2026