

Rozkład QR i wprowadzanie do Twierdzenia Spektralnego Macierzy Symetrycznych

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

23 marca 2026

Projekcja ortogonalna na wektor

Skąd bierze się rzut? — krok 1: geometria

Obserwacja geometryczna

Opuść prostopadłą z końca v na prostą wyznaczoną przez u .


Powstaje **trójkąt prostokątny** o kącie θ przy wierzchołku O .

Definicja cosinusa

Z trygonometrii elementarnej:

$$\cos \theta = \frac{\text{przyprostokątna}}{\text{przeciwprostokątna}} = \frac{s}{\|v\|}$$

gdzie s to **długość rzutu** szukana przez nas.



Wniosek — wzór na s

$$s = \|v\| \cos \theta$$

To *liczba* (może być ujemna, gdy $\theta > 90^\circ$).

Skąd bierze się rzut? — krok 2: iloczyn skalarny


Definicja iloczynu skalarnego

Z analizy wektorowej wiemy, że:

$$\mathbf{v}^T \mathbf{u} = \|\mathbf{v}\| \|\mathbf{u}\| \cos \theta$$

Stąd wyznaczamy $\cos \theta$:

$$\cos \theta = \frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{v}\| \|\mathbf{u}\|}$$



Podstawienie do wzoru na s

Ze slajdu 1: $s = \|\mathbf{v}\| \cos \theta$. Podstawiamy:

$$s = \|\mathbf{v}\| \cdot \frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{v}\| \|\mathbf{u}\|} = \frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{u}\|}$$

Kluczowe spostrzeżenie

$\|\mathbf{v}\|$ **skraca się!** Rzut skalarny zależy tylko od *kąta* między wektorami, nie od długości $\mathbf{v}$.

$$s = \frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{u}\|}$$

Skąd bierze się rzut? — krok 3: od liczby do wektora

Mamy długość — potrzebujemy kierunek

$$s = \frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{u}\|} \text{ to liczba.}$$

Rzut leży **wzdłuż** $\mathbf{u}$, więc potrzebujemy wektora (wektora jednostkowego):

$$\hat{\mathbf{u}} = \frac{\mathbf{u}}{\|\mathbf{u}\|} \quad (\|\hat{\mathbf{u}}\| = 1)$$

Złożenie: długość $\times$ kierunek

$$\text{proj}_{\mathbf{u}}(\mathbf{v}) = s \cdot \hat{\mathbf{u}} = \underbrace{\frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{u}\|}}_{\text{jak daleko}} \cdot \underbrace{\frac{\mathbf{u}}{\|\mathbf{u}\|}}_{\text{w jakim kierunku}}$$

Iloczyn skalarny

$$\mathbf{v}^T \mathbf{u} = \|\mathbf{v}\| \|\mathbf{u}\| \cos \theta$$

wyznacz $\cos \theta$, podstaw

Rzut skalarny

$$s = \frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{u}\|}$$

potrzeba kierunku

Wektor kierunku

$$\hat{\mathbf{u}} = \frac{\mathbf{u}}{\|\mathbf{u}\|}$$

$s \times \hat{\mathbf{u}}$

Rzut wektorowy

$$\frac{\mathbf{v}^T \mathbf{u}}{\|\mathbf{u}\|^2} \mathbf{u}$$

Projekcja ortogonalna — podsumowanie i interpretacja

Wzór ogólny

$$\text{proj}_{\mathbf{u}}(\mathbf{v}) = \frac{\mathbf{v}^T \mathbf{u}}{\mathbf{u}^T \mathbf{u}} \mathbf{u}$$

współczynnik = iloczyn skalarny / norma²

Przypadek szczególny: $\|\mathbf{u}\| = 1$

Jeśli $\mathbf{u}$ jest wersorem, $\|\mathbf{u}\|^2 = 1$, więc:

$$\text{proj}_{\mathbf{u}}(\mathbf{v}) = (\mathbf{v}^T \mathbf{u}) \mathbf{u}$$

Dlatego **normalizujemy** bazy przed projekcją!

Rozkład ortogonalny


$$\mathbf{v} = \underbrace{\text{proj}_{\mathbf{u}}(\mathbf{v})}_{\parallel \mathbf{u}} + \underbrace{(\mathbf{v} - \text{proj}_{\mathbf{u}}(\mathbf{v}))}_{\perp \mathbf{u}}$$

Interpretacja dla ML

Rzut = ile z $\mathbf{v}$ leży w kierunku $\mathbf{u}$.

Składowa prostopadła = nowa informacja, niewyjaśniana przez $\mathbf{u}$ — identycznie jak *residua* w regresji liniowej.

PCA: rzutujemy dane na kierunki największej wariancji (wektory własne).



Macierze dodatnio określone
i projekcje na podprzestrzeń W :
wzór macierzowy

Macierz dodatnio określona: definicja

Definicja

Macierz symetryczna $A \in \mathbb{R}^{k \times k}$ jest **dodatnio określona** (ang. *positive definite*), gdy:

$$\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \mathbf{x} \neq \mathbf{0}$$

Co to jest forma kwadratowa?

Wyrażenie $f(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$ przypisuje każdemu wektorowi $\mathbf{x}$ jedną liczbę rzeczywistą.

Warunek $\mathbf{x}^T A \mathbf{x} > 0$ oznacza:

- każdy niezerowy $\mathbf{x}$ daje **dodatnią** wartość
- zero tylko dla $\mathbf{x} = \mathbf{0}$

Najprostsza analogia: $\mathbb{R}^1$

Gdy $k = 1$: $A = a \in \mathbb{R}$, $\mathbf{x} = x \in \mathbb{R}$.

Forma kwadratowa:

$$\mathbf{x}^T A \mathbf{x} = ax^2$$

Warunek dod. określoności:

$$ax^2 > 0 \quad \forall x \neq 0 \iff a > 0$$

Uogólniamy: A dod. określona = wielowymiarowe $a > 0$.

Uwaga terminologiczna

Wymagamy **symetrii** $A = A^T$.
Bez symetrii definicja traci jednoznaczność
(zawsze można symetryzować: $\frac{1}{2}(A + A^T)$).

Macierz dodatnio określona: przykłady

Przykład 1: macierz jednostkowa

$A = I_k$:

$$\mathbf{x}^T I_k \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2 > 0$$

dla każdego $\mathbf{x} \neq \mathbf{0}$. ✓

Intuicja: I_k nie odkształca przestrzeni — forma to kwadrat długości.

Przykład 2: macierz diagonalna

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}, \quad \mathbf{x}^T A \mathbf{x} = 2x_1^2 + 3x_2^2$$

Suma nieujemnych składników, zero tylko gdy $x_1 = x_2 = 0$. ✓

Ogólnie: macierz diagonalna z **dodatnimi** wartościami na diagonalu jest dod. określona.

Kontrprzykład

$$B = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

Weźmy $\mathbf{e}_2 = (0, 1)^T$:

$$\mathbf{e}_2^T B \mathbf{e}_2 = -1 < 0$$

B **nie** jest dodatnio określona. ✗

Ujemna wartość na diagonalu "ciągnie" formę w dół wzdłuż $\mathbf{e}_2$.

Szybki test dla macierzy 2×2

$$A = \begin{pmatrix} a & b \\ b & d \end{pmatrix} \text{ dod. okr.} \iff a > 0 \text{ i } ad - b^2 > 0$$

(kryterium Sylwestera)

Forma kwadratowa jako powierzchnia: geometria

Co rysujemy?

Funkcja $f : \mathbb{R}^2 \rightarrow \mathbb{R}$,

$$f(x_1, x_2) = \mathbf{x}^T A \mathbf{x}$$

wyznacza **powierzchnię** nad płaszczyzną (x_1, x_2) .

Kształt zależy od A :

- A dod. określona $\Rightarrow$ **paraboloida** (miska)
- A nieokreślona $\Rightarrow$ **siodło**
- A ujem. określona $\Rightarrow$ odwrócona miska

Dlaczego to ważne?

W optymalizacji minimalizujemy $f(\mathbf{x})$.


Paraboloida $\Rightarrow$ jednoznaczne minimum globalne w $\mathbf{x} = \mathbf{0}$.

Siodło $\Rightarrow$ brak minimum — gradient znika, ale to nie jest minimum.

Dod. określona: $A = \text{diag}(2, 3)$



Nieokreślona: $B = \text{diag}(2, -2)$



Macierz dodatnio określona jest odwracalna

Przypomnienie: kiedy macierz jest odwracalna?

A jest odwracalna wtedy i tylko wtedy, gdy:

$$\ker(A) = \{0\}$$

tn. jedynym rozwiązaniem $Ax = 0$ jest $x = 0$.

Twierdzenie

Jeśli A jest **dodatnio określona**, to A jest **odwracalna**.

MNK (Metoda Najmniejszych Kwadratów)

W równaniu normalnym:

$$A^T A \hat{\beta} = A^T y$$

Jeśli $A^T A$ jest dod. określona, istnieje **jednoznaczne rozwiązanie**:

$$\hat{\beta} = (A^T A)^{-1} A^T y$$

Dodatnia pokrewność $\rightarrow \ker(A)=0$

A **dodatnio określona**

$\Downarrow$

Założ: $Ax = 0$

$\Downarrow$

Pomnóż przez x^T :

$$x^T Ax = x^T \cdot 0 = 0$$

$\Downarrow$

Dod. określoność $\Rightarrow x = 0$

$\Downarrow$

$$\ker(A) = \{0\}$$

$\Downarrow$

A **odwracalna**



Macierz dodatnio określona: równoważne charakteryzacje

Twierdzenie

Dla macierzy symetrycznej $A \in \mathbb{R}^{k \times k}$ następujące warunki są **równoważne**:

- 1 $x^T A x > 0$ dla wszystkich $x \neq 0$
- 2 Wszystkie **wartości własne** $\lambda_i > 0$
- 3 Wszystkie **minory wiodące** $\Delta_i > 0$ (kryterium Sylwestera)
- 4 Istnieje rozkład $A = LL^T$, gdzie L jest **dolnotrójkątna** z dodatnią diagonalą (rozkład Choleskiego)

Wartości własne a dod. określoność

Jeśli $Aq = \lambda q$ dla wektora własnego $q \neq 0$, to:

$$q^T A q = q^T (\lambda q) = \lambda \|q\|^2$$

Zatem $q^T A q > 0 \iff \lambda > 0$.

Dod. określoność = wszystkie wartości własne **dodatnie**.

Rozkład Choleskiego

Analogia do $a > 0 \Rightarrow a = (\sqrt{a})^2$:

$$A \text{ dod. okr.} \Rightarrow A = LL^T$$

gdzie L to "pierwiastek" z A .

Używany w praktyce do szybkiego rozwiązywania układów $Ax = b$ bez jawnego obliczania A^{-1} .

Forma kwadratowa jako wielomian: $k = 2$

Dane

$$A = \begin{pmatrix} a & b \\ b & d \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Macierz symetryczna — element $(1, 2)$ równy elementowi $(2, 1)$.

Krok 1: oblicz $A\mathbf{x}$

$$A\mathbf{x} = \begin{pmatrix} a x_1 + b x_2 \\ b x_1 + d x_2 \end{pmatrix}$$

Krok 2: oblicz $\mathbf{x}^T(A\mathbf{x})$

$$\begin{aligned} \mathbf{x}^T A \mathbf{x} &= \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} a x_1 + b x_2 \\ b x_1 + d x_2 \end{pmatrix} \\ &= x_1(a x_1 + b x_2) + x_2(b x_1 + d x_2) \\ &= \boxed{a x_1^2 + 2b x_1 x_2 + d x_2^2} \end{aligned}$$

Co widzimy?

$a x_1^2, d x_2^2$ z **diagonali** A

$2b x_1 x_2$ z elementów **poza-diagonalnych**
(czynniki 2 z symetrii $a_{12} = a_{21}$)

Forma kwadratowa jako wielomian: $k = 3$

Ogólna postać dla $k = 3$

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{12} & a_{22} & a_{23} \\ a_{13} & a_{23} & a_{33} \end{pmatrix}$$

$$\begin{aligned} \mathbf{x}^T A \mathbf{x} &= a_{11}x_1^2 + a_{22}x_2^2 + a_{33}x_3^2 \\ &\quad + 2a_{12}x_1x_2 \\ &\quad + 2a_{13}x_1x_3 \\ &\quad + 2a_{23}x_2x_3 \end{aligned}$$

Reguła ogólna

$$\mathbf{x}^T A \mathbf{x} = \sum_{i=1}^k a_{ii} x_i^2 + 2 \sum_{i < j} a_{ij} x_i x_j$$

Diagonala $\rightarrow$ wyrazy x_i^2 .

Poza-diagonala $\rightarrow$ wyrazy $x_i x_j$ z czynnikiem 2 (para (i, j) pojawia się dwa razy z uwagi na symetrię $a_{ij} = a_{ji}$).

Kluczowa obserwacja

Forma kwadratowa to **wielomian stopnia 2** bez wyrazów wolnych i liniowych, więc zawsze $f(\mathbf{0}) = 0$.

Dod. określoność wymaga $f(\mathbf{x}) > 0$ dla wszystkich $\mathbf{x} \neq \mathbf{0}$.

Przykład 3×2 : obliczenie macierzy Grama $A^T A$

Dlaczego $A^T A$, nie A ?

Macierz $A \in \mathbb{R}^{3 \times 2}$ nie jest kwadratowa —
 $x^T A x$ nie ma sensu wymiarowo.

Natomiast **macierz Grama**:

$$A^T A \in \mathbb{R}^{2 \times 2}$$

jest kwadratowa i symetryczna —
to ona wyznacza formę kwadratową.

Obliczenie $A^T A$

$$A^T = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix}$$

$$A^T A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix}$$

$$= \begin{pmatrix} 1+1+0 & 0+1+0 \\ 0+1+0 & 0+1+1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

Dane

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

Wynik

$$A^T A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

Macierz 2×2 , symetryczna. Sprawdźmy dod. określoność na następnym

Przykład 3×2 : forma kwadratowa i kryterium Sylwestera

Punkt wyjścia

Z poprzedniego slajdu:

$$A^T A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Rozwinięcie formy kwadratowej

Stosujemy wzór dla $k = 2$ ($a = 2$, $b = 1$, $d = 2$):

$$\mathbf{x}^T (A^T A) \mathbf{x} = 2x_1^2 + 2 \cdot 1 \cdot x_1 x_2 + 2x_2^2$$

$$= 2x_1^2 + 2x_1 x_2 + 2x_2^2$$

Sprawdzenie: kryterium Sylwestera

Minory wiodące $A^T A$:

$$\Delta_1 = 2 > 0 \checkmark$$

$$\Delta_2 = \det \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = 4 - 1 = 3 > 0 \checkmark$$

Oba minory dodatnie, zatem

$A^T A$ jest **dodatnio określona**. $\checkmark$

Przykład 3 × 2: dlaczego $A^T A$ jest zawsze dod. określona?

Kluczowa tożsamość

Dla dowolnego x :

$$x^T (A^T A) x = (Ax)^T (Ax) = \|Ax\|^2 \geq 0$$

Kwadrat normy jest zawsze ≥ 0 .

Równość $\|Ax\|^2 = 0$ zachodzi wtedy i tylko wtedy, gdy $Ax = 0$.

Warunek dod. określoności

Jeśli A ma **pełny rząd kolumnowy** ($\text{rank}(A) = k$), to:

$$Ax = 0 \implies x = 0$$

Zatem $\|Ax\|^2 > 0$ dla wszystkich $x \neq 0$,
czyli $A^T A$ jest **dodatnio określona**.

Schemat rozumowania

$$\text{rank}(A) = k$$

$\Downarrow$

$$Ax = 0 \implies x = 0$$

$\Downarrow$

$$\|Ax\|^2 > 0 \text{ dla } x \neq 0$$

$\Downarrow$

$$x^T (A^T A) x > 0 \text{ dla } x \neq 0$$

$\Downarrow$

$$A^T A \text{ dod. określona}$$

$\Downarrow$

$$A^T A \text{ odwracalna}$$

Wniosek dla MNK

Przykład 3×3 : rozwinięcie formy kwadratowej

Dane

$$A = \begin{pmatrix} 4 & 2 & 0 \\ 2 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

Wyrazy z diagonali

$$a_{11} = 4, \quad a_{22} = 3, \quad a_{33} = 2:$$

$$4x_1^2 + 3x_2^2 + 2x_3^2$$

Wyrazy poza-diagonalne

$$a_{12} = 2 \Rightarrow 2 \cdot 2 x_1 x_2 = 4x_1 x_2$$

$$a_{13} = 0 \Rightarrow 2 \cdot 0 x_1 x_3 = 0$$

$$a_{23} = 1 \Rightarrow 2 \cdot 1 x_2 x_3 = 2x_2 x_3$$

Pełna postać wielomianowa

$$\begin{aligned} f(x_1, x_2, x_3) &= 4x_1^2 + 3x_2^2 + 2x_3^2 \\ &\quad + 4x_1 x_2 \\ &\quad + 2x_2 x_3 \end{aligned}$$

(wyraz $x_1 x_3$ znika, bo $a_{13} = 0$)

Szybka weryfikacja dla $\mathbf{x} = (1, 0, 0)^T$

$$f(1, 0, 0) = 4 \cdot 1 = 4 > 0 \quad \checkmark$$

To **nie** jest dowód dod. określoności — sprawdzamy tylko jeden wektor.

Pełne sprawdzenie: kryterium Sylwestera na następnym slajdzie.

Przykład 3×3 : sprawdzenie dod. określoności

Kryterium Sylwestera

A jest dod. określona $\iff$ wszystkie **minory wiodące** są dodatnie:

$$\Delta_1 = a_{11}, \quad \Delta_2 = \det \begin{pmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{pmatrix}, \quad \Delta_3 = \det(A)$$

Obliczenia

$$\Delta_1 = 4 > 0 \checkmark$$

$$\Delta_2 = \det \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix} = 12 - 4 = 8 > 0 \checkmark$$

$$\Delta_3 = \det(A)$$

$$= 4(3 \cdot 2 - 1 \cdot 1) - 2(2 \cdot 2 - 1 \cdot 0) + 0$$

$$= 4 \cdot 5 - 2 \cdot 4 = 20 - 8 = 12 > 0 \checkmark$$

Wniosek

Wszystkie trzy minory wiodące dodatnie:

$$\Delta_1 = 4, \quad \Delta_2 = 8, \quad \Delta_3 = 12$$

Zatem A jest **dodatnio określona**.

Forma $4x_1^2 + 3x_2^2 + 2x_3^2 + 4x_1x_2 + 2x_2x_3$ jest dodatnia dla wszystkich $(x_1, x_2, x_3) \neq (0, 0, 0)$.

Weryfikacja dla $x = (1, -1, 1)^T$

$$f(1, -1, 1) = 4 + 3 + 2 - 4 - 2 = 3 > 0 \checkmark$$

Trudniejszy wektor — wciąż dodatni, zgodnie z oczekiwaniem.

Weryfikacja buduje intuicję, ale **nie zastępuje** kryterium Sylwestera.

Macierz Grama $G = U^T U$: symetria i odwracalność

Definicja macierzy Grama

Dla $U = [\mathbf{u}_1 \mid \cdots \mid \mathbf{u}_k] \in \mathbb{R}^{n \times k}$ definiujemy:

$$G = U^T U \in \mathbb{R}^{k \times k}$$

Wpisy macierzy:

$$G_{ij} = \mathbf{u}_i^T \mathbf{u}_j$$

(iloczyn skalarny i -tej i j -tej kolumny U)

Symetria (łatwa)

$$G^T = (U^T U)^T = U^T (U^T)^T = U^T U = G$$

Zamiana indeksów: $G_{ij} = \mathbf{u}_i^T \mathbf{u}_j = \mathbf{u}_j^T \mathbf{u}_i = G_{ji}$. ✓

Twierdzenie

Jeśli kolumny U są **liniowo niezależne**,
to $G = U^T U$ jest **odwracalna**.

Dowód: G jest dodatnio określona

Weźmy dowolny $\mathbf{x} \neq \mathbf{0}$:

$$\begin{aligned} \mathbf{x}^T G \mathbf{x} &= \mathbf{x}^T U^T U \mathbf{x} \\ &= (U \mathbf{x})^T (U \mathbf{x}) \\ &= \|U \mathbf{x}\|^2 \geq 0 \end{aligned}$$

Kiedy $\|U \mathbf{x}\|^2 = 0$?

$$\Leftrightarrow U \mathbf{x} = \mathbf{0} \Leftrightarrow \mathbf{x} = \mathbf{0}$$

(bo kolumny U liniowo niezależne) Zatem
 $\mathbf{x}^T G \mathbf{x} > 0$ dla każdego $\mathbf{x} \neq \mathbf{0}$: G jest **dodatnio określona**, a więc **odwracalna**. □

Rzut na podprzestrzeń: podprzestrzeń


Rzut na podprzestrzeń: podprzestrzeń

Sytuacja

Mamy podprzestrzeń $W \subseteq \mathbb{R}^n$ rozpiętą przez wektory $\mathbf{u}_1, \dots, \mathbf{u}_k$:

$$W = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$$

Pytanie: jaki wektor w W jest *najbliższy* danemu $\mathbf{v}$?



Odpowiedź geometryczna

Szukamy $\hat{\mathbf{v}} \in W$ takiego, że:

$$\hat{\mathbf{v}} = \arg \min_{\mathbf{w} \in W} \|\mathbf{v} - \mathbf{w}\|$$

Rozwiązaniem jest **rzut ortogonalny** $\hat{\mathbf{v}} = \text{proj}_W(\mathbf{v})$,

bo reszta $\mathbf{v} - \hat{\mathbf{v}}$ jest **prostopadła** do każdego $\mathbf{u}_i$:

$$(\mathbf{v} - \hat{\mathbf{v}}) \perp \mathbf{u}_i \quad \forall i = 1, \dots, k$$

Rozkład ortogonalny

$$\mathbf{v} = \underbrace{\hat{\mathbf{v}}}_{\in W} + \underbrace{(\mathbf{v} - \hat{\mathbf{v}})}_{\perp W}$$

Każdy wektor rozkłada się **jednoznacznie** na część w W i część *prostopadłą* do W .

Macierz projekcji ortogonalnej P_W

Budujemy macierz U

Ustawiamy wektory bazowe jako kolumny:

$$U = [\mathbf{u}_1 \mid \cdots \mid \mathbf{u}_k] \in \mathbb{R}^{n \times k}$$

Jeśli wektory są liniowo niezależne,

to macierz Grama $G = U^T U \in \mathbb{R}^{k \times k}$ jest **odwracalna**.

Wzór na macierz projekcji

$$P_W = U(U^T U)^{-1} U^T$$

Rzut wektora $\mathbf{v}$ na W :

$$\text{proj}_W(\mathbf{v}) = P_W \mathbf{v}$$

Uwaga: P_W nie zależy od wyboru konkretnej bazy — tylko od podprzestrzeni W .

Kluczowe własności P_W

$$P_W^2 = P_W$$

rzutowanie dwa razy
nie zmienia wyniku

$$P_W^T = P_W$$

macierz symetryczna

$$\text{rank}(P_W) = k$$

rzęd = wymiar W

$$P_W \mathbf{u}_i = \mathbf{u}_i$$

baza W zostaje w miejscu

Szczególny przypadek: $k = 1$

Jeden wektor $\mathbf{u}$, $U = \mathbf{u}$:

$$P_W = \frac{\mathbf{u} \mathbf{u}^T}{\mathbf{u}^T \mathbf{u}}$$

To dokładnie wzór z projekcji 1D!
Ogólny wzór **uogólnia** tamten przypadek.

Baza ortonormalna upraszcza wszystko

Czym jest baza ortonormalna (ONB)?

Wektory $\mathbf{q}_1, \dots, \mathbf{q}_k$ są ortonormalne gdy:

- **ortogonalne:** $\mathbf{q}_i^T \mathbf{q}_j = 0$ dla $i \neq j$
(każde dwa wektory prostopadłe)
- **znormalizowane:** $\mathbf{q}_i^T \mathbf{q}_i = 1$
(każdy ma długość 1)

Zwięźle: $\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij}$

Co to oznacza dla macierzy Q ?

Dla $Q = [\mathbf{q}_1 \mid \dots \mid \mathbf{q}_k]$:

$$Q^T Q = I_k$$

Macierz Grama staje się **macierzą jednostkową!**

Uproszczony wzór macierzowy

Wstawiamy $Q^T Q = I_k$ do ogólnego wzoru:

$$\begin{aligned} P_W &= Q \underbrace{(Q^T Q)^{-1}}_{= I_k} Q^T \\ &= \boxed{Q Q^T} \end{aligned}$$

Nie trzeba odwracać żadnej macierzy!

To główna zaleta bazy ortonormalnej.

Porównanie wzorów

Baza ogólna: $U(U^T U)^{-1} U^T$ Algorytm

Baza ONB: $Q Q^T$ **(prostszy!)**

Gram-Schmidta (slajd C)

zamienia dowolną bazę U w bazę ONB Q .

Projekcja ONB = suma rzutów jednowymiarowych


Kluczowy wzór

Gdy $\mathbf{q}_1, \dots, \mathbf{q}_k$ ortonormalne:

$$\text{proj}_W(\mathbf{v}) = \sum_{i=1}^k \underbrace{(\mathbf{v}^T \mathbf{q}_i)}_{\text{wsp. Fouriera}} \mathbf{q}_i$$

Każdy składnik $(\mathbf{v}^T \mathbf{q}_i) \mathbf{q}_i$

to projekcja 1D na kierunek $\mathbf{q}_i$.



Jak czytać diagram

- 1 Rzutuj $\mathbf{v}$ na $\mathbf{q}_1$ (zielona strzałka)
- 2 Rzutuj $\mathbf{v}$ na $\mathbf{q}_2$ (pomarańczowa)
- 3 Zsumuj oba wyniki
- 4 Otrzymujesz $\text{proj}_W(\mathbf{v})$ (czerwony)

Dlaczego działa? (intuicja)

Ortogonalność bazy oznacza, że kierunki $\mathbf{q}_1, \dots, \mathbf{q}_k$ nie „przeszkadzają sobie”. Każdą współrzędną wyznaczamy **niezależnie** jednym iloczynem skalarnym. Analogia: składowe (x, y, z) w kartezjańskim układzie współrzędnych — bo osie są ortogonalne.

Algorytm Grama–Schmidta

Podsumowanie: Algorytm Grama–Schmidta (1/2)

Kroki algorytmu

Krok 1: $\mathbf{u}_1 = \mathbf{v}_1$

Krok 2: usuwamy projekcję na $\mathbf{u}_1$:

$$\mathbf{u}_2 = \mathbf{v}_2 - \frac{\mathbf{v}_2^T \mathbf{u}_1}{\mathbf{u}_1^T \mathbf{u}_1} \mathbf{u}_1$$

Krok k : usuwamy projekcje na $\mathbf{u}_1, \dots, \mathbf{u}_{k-1}$:

$$\mathbf{u}_k = \mathbf{v}_k - \sum_{i=1}^{k-1} \frac{\mathbf{v}_k^T \mathbf{u}_i}{\mathbf{u}_i^T \mathbf{u}_i} \mathbf{u}_i$$

Normalizacja: $\mathbf{q}_i = \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}$

Idea


Z każdego wektora usuwamy jego projekcje na wszystkie wcześniejsze wektory. Zostaje wyłącznie składowa prostopadła do wszystkich poprzednich.

Gwarantowany wynik

$$\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij}$$

Zachowana podprzestrzeń:

$$\text{span}(\mathbf{q}_1, \dots, \mathbf{q}_k) = \text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k)$$




Podsumowanie: Algorytm Grama–Schmidta (2/2)

geometryczna interpretacja kroku 2

Cztery etapy jednego kroku

- 1 Bierzemy nowy wektor v_2
- 2 Obliczamy projekcję na u_1 :
 $\text{proj}_{u_1}(v_2)$ – składowa “stara”
- 3 Odejmujemy:
 $u_2 = v_2 - \text{proj}_{u_1}(v_2)$
- 4 $u_2 \perp u_1$ z definicji różnicy



Analogia w ML – residua regresji

Krok GS to dokładnie **regresja residualna**:

- Regresujemy v_2 na u_1
- Residuum = składowa ortogonalna
- Każde residuum jest **ortogonalne** do regresora

Gram–Schmidt $\equiv$ sekwencyjne odejmowanie regresji.

Wynik

$u_2 = v_2 - \text{proj}_{u_1}(v_2)$ jest **prostopadłe** do u_1 . Po normalizacji: $q_2 = u_2 / \|u_2\|$.

Rozkład QR przez pryzmat dwóch
interpretacji

Dowód “na palcach” (1/2): przepisanie algorytmu GS

Dane wejściowe i wyjściowe

Niech $\mathbf{A} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n]$ (macierz z kolumnami liniowo niezależnymi). Po algorytmie Grama–Schmidta:

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n], \quad \mathbf{Q}^T \mathbf{Q} = \mathbf{I}$$

Krok 1: przepisuj krok GS

W kroku j algorytmu Grama–Schmidta:

$$\mathbf{u}_j = \mathbf{v}_j - \sum_{i=1}^{j-1} (\mathbf{q}_i^T \mathbf{v}_j) \mathbf{q}_i, \quad \mathbf{q}_j = \frac{\mathbf{u}_j}{\|\mathbf{u}_j\|}$$

Przestaw: wyraż $\mathbf{v}_j$ przez $\mathbf{q}_i$:

$$\mathbf{v}_j = \sum_{i=1}^{j-1} \underbrace{(\mathbf{q}_i^T \mathbf{v}_j)}_{r_{ij}} \mathbf{q}_i + \underbrace{\|\mathbf{u}_j\|}_{r_{jj}} \mathbf{q}_j$$

Krok 2: rozpisz dla $n = 3$

Podstawiając definicję r_{ij} do wzoru z Kroku 1:

$$\mathbf{v}_1 = r_{11} \mathbf{q}_1$$

$$\mathbf{v}_2 = r_{12} \mathbf{q}_1 + r_{22} \mathbf{q}_2$$

$$\mathbf{v}_3 = r_{13} \mathbf{q}_1 + r_{23} \mathbf{q}_2 + r_{33} \mathbf{q}_3$$

Kluczowa obserwacja:

$\mathbf{v}_j$ zależy tylko od $\mathbf{q}_1, \dots, \mathbf{q}_j$

$\Rightarrow$ współczynniki przy $\mathbf{q}_i$ dla $i > j$ są zerem.

To jest właśnie górna trójkątność $\mathbf{R}$!

Intuicja geometryczna

GS buduje bazę **kolejno**: $\mathbf{q}_j \perp \mathbf{q}_1, \dots, \mathbf{q}_{j-1}$.

Dlatego “późniejszy” wektor bazowy $\mathbf{q}_i$ ($i > j$)

jest **ortogonalny** do $\mathbf{v}_j$ i nie może w nim uczestniczyć.

Dowód “na palcach” (2/2): zapis macierzowy i wniosek

Krok 3: złącz kolumny w macierz

Trzy równania z poprzedniego slajdu to **trzy kolumny** jednej równości macierzowej:

$$\underbrace{\begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \mathbf{v}_3 \end{bmatrix}}_{\mathbf{A}} = \underbrace{\begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 & \mathbf{q}_3 \end{bmatrix}}_{\mathbf{Q}} \underbrace{\begin{bmatrix} r_{11} & r_{12} & r_{13} \\ 0 & r_{22} & r_{23} \\ 0 & 0 & r_{33} \end{bmatrix}}_{\mathbf{R}}$$

Weryfikacja kolumny $j = 2$:

$$\mathbf{Q} \mathbf{r}_{:2} = r_{12} \mathbf{q}_1 + r_{22} \mathbf{q}_2 + \underbrace{0}_{r_{32}} \cdot \mathbf{q}_3 = \mathbf{v}_2 \quad \checkmark$$

Skąd zera w $\mathbf{R}$?

- $r_{ij} = \mathbf{q}_i^T \mathbf{v}_j = 0$ dla $i > j$
bo $\mathbf{v}_j \in \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_j)$
oraz $\mathbf{q}_i \perp \mathbf{q}_k$ dla $k \leq j < i$.
- Zera **nie są założeniem** — wynikają z kolejności kroków GS.

Wniosek końcowy

- Rozkład $\mathbf{A} = \mathbf{Q}\mathbf{R}$ wynika wprost z przepisania GS w postaci macierzowej.
- Nie ma tu żadnej magii: $\mathbf{Q}$ to nowa baza, $\mathbf{R}$ to współczynniki przejścia do tej bazy.
- Jedynność przy $r_{ii} > 0$: normalizacja $\mathbf{q}_j = \mathbf{u}_j / \|\mathbf{u}_j\|$ wyznacza zwrot jednoznacznie.

Od ortogonalizacji do rozkładu QR : zapis macierzowy

Dane wejściowe i wyjściowe

Niech $\mathbf{A} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n]$
(macierz z kolumnami liniowo niezależnymi).

Po algorytmie Grama–Schmidta:

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n], \quad \mathbf{Q}^T \mathbf{Q} = \mathbf{I}$$

Twierdzenie: rozkład QR

Każdą macierz $\mathbf{A}$ o liniowo niezależnych kolumnach można jednoznacznie (przy $r_{ii} > 0$) rozłożyć:

$$\boxed{\mathbf{A} = \mathbf{Q}\mathbf{R}}$$

- $\mathbf{Q}$: macierz **ortonormalna** ($\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$)
- $\mathbf{R}$: macierz **górnotrójkątna**, $r_{ii} > 0$

Skąd pochodzi macierz $\mathbf{R}$?

Niech $\mathbf{u}_i$ oznacza wektor **przed normalizacją** w kroku i GS. Wówczas:

$$r_{ij} = \mathbf{q}_i^T \mathbf{v}_j \ (i \leq j), \quad r_{ii} = \mathbf{q}_i^T \mathbf{v}_i = \|\mathbf{u}_i\| > 0$$

$$\mathbf{R} = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ 0 & r_{22} & r_{23} \\ 0 & 0 & r_{33} \end{bmatrix}$$

Górnotrójkątność: $\mathbf{q}_i \perp \mathbf{v}_j$ dla $i > j$,
bo $\mathbf{v}_j \in \text{span}(\mathbf{q}_1, \dots, \mathbf{q}_j)$.

Geometryczna interpretacja $A = QR$ (1/2)

Q: zmiana bazy (obrót / odbicie)

Kolumny **Q** tworzą **nową ortonormalną bazę** przestrzeni kolumn **A**.

Macierz ortogonalna **zachowuje**:

- długości: $\|Qx\| = \|x\|$
- kąty: $(Qx)^T(Qy) = x^T y$

Geometrycznie **Q** to **obrót** ($\det Q = +1$) lub **obrót z odbiciem** ($\det Q = -1$).

*Układ współrzędnych "obraca się",
figury pozostają niezniekształcone.*

R: skalowanie + ścinanie

R górnotrójkątna **nie jest** czystym skalowaniem:

- **Diagonała** r_{ii} : skaluje wzdłuż q_i
- **Naddiagonała** r_{ij} , $i < j$: **ścinanie**

Przykład 2×2 :

$$\begin{bmatrix} r_{11} & r_{12} \\ 0 & r_{22} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} r_{11}x_1 + r_{12}x_2 \\ r_{22}x_2 \end{bmatrix}$$

Oś 1 jest "pochylana" przez r_{12} —
to właśnie **ścinanie**, nie skalowanie.

Podział ról

Q przejmuje całą **geometrię obrotu** $\implies$ w **R** zostaje już tylko **zniekształcenie kształtu**.

Geometryczna interpretacja $A = QR$ (2/2)

Całość: $A = QR$

Czytaj od prawej do lewej:

$$x \xrightarrow{R} \text{skaluj} + \text{ścinaj} \xrightarrow{Q} \text{obróć} = Ax$$

Analogia z rozkładem LU:

$A = LU$: dolno- $\times$ górnotrójkątna

$A = QR$: ortogonalna $\times$ górnotrójkątna

W QR „wyciągamy” obrót do Q ;
w LU „wyciągamy” eliminację do L .

Kluczowa intuicja

- R opisuje starą bazę $\{v_j\}$ we współrzędnych nowej bazy $\{q_i\}$
- Górna trójkątność $\Leftrightarrow$ GS buduje bazę **kolejno**: $v_j \in \text{span}(q_1, \dots, q_j)$, więc nie potrzebuje $q_{j+1}, \dots, q_n$
- $r_{ii} > 0 \Leftrightarrow$ każdy nowy wektor **wnosi coś nowego** (liniowa niezależność)

Podsumowanie rozkładu QR

$A = QR$ to **zmiana bazy** (Q) złożona ze **zniekształcenia** (R) — dokładnie tyle, ile potrzeba, żeby opisać dowolny układ liniowo niezależnych kolumn.

Rozkład QR przez pryzmat dwóch interpretacji

Perspektywa aktywna

Transformacja $A = QR$ działa na wektory w dwóch etapach:

- 1 R : skaluje i ścina przestrzeń (zmienia kształt, zachowuje porządek)
- 2 Q : obraca wynik (bez zmiany kształtu)

$$Ax = Q \underbrace{(Rx)}_{\text{skalowanie}}$$

Perspektywa pasywna

Q definiuje **nową bazę ortonorm.**; R wyraża stare kolumny v_j w nowej bazie:

$$v_j = \sum_{i \leq j} r_{ij} q_i$$

Przejście od “bazy surowej” do “bazy naturalnej”

Rozwiązanie układów: $Ax = b$

Podstawiamy $A = QR$:

$$QRx = b$$

Mnożymy lewostronnie przez $Q^T = Q^{-1}$:

$$Rx = Q^T b$$

System **górnotrójkątny** $\Rightarrow$ podstawianie wsteczne.

Kluczowy krok: $Q^T b$ to projekcja b na ortonorm. bazę Q (transformacja **pasywna!**).

Numeryczna wyższość QR nad eliminacją Gaussa

Q zachowuje normy $\Rightarrow$ mnożenie przez Q^T **nie wzmacnia błędów**. Eliminacja Gaussa może amplifikować błędy zaokrągleń przy słabym uwarunkowaniu macierzy.

Rozkład QR jako fundament analizy
danych i algorytmów numerycznych

Rozkład QR jako fundament analizy danych i algorytmów numerycznych

Zastosowanie	Rola rozkładu QR	Intuicja
Regresja liniowa	Stabilne rozwiązanie $Ax \approx b$	Projekcja na przestrzeń kolumn
PCA	Ortogonalizacja kierunków wariancji	Nowe osie = niezależne kierunki danych
SVD	QR jako krok pośredni i składowa	Rozkład na wartości osobliwe
Iteracja QR	$A_k = Q_k R_k$, $A_{k+1} = R_k Q_k$	Wyznaczanie wartości własnych
Filtracja sygnałów	Projekcja na bazę ortonorm.	Rozdzielenie niezależnych składowych
Szeregi czasowe	Ortogonalizacja zmiennych objaśniających	Usunięcie multikolinearności

Regresja przez QR – wzór końcowy

Minimalizujemy $\|Ax - b\|^2$. Po $A = QR$:

$$R\hat{x} = (Q^T b)_{1:n}$$

Podstawianie wsteczne, numerycznie stabilne.

Połączenie z dalszym kursem

$QR \rightarrow SVD \rightarrow PCA \rightarrow$ redukcja wymiarowości $\rightarrow$ modele ML.

Dziś budujemy **fundament algebraiczny** – reszta kursu wyrasta na ortogonalności.

Wektor własny i wartość własna: intuicja geometryczna

Wektor własny i wartość własna: definicja

Definicja


Wektor $v \neq 0$ jest **wektorem własnym** macierzy A odpowiadającym **wartości własnej** λ , jeśli:

$$Av = \lambda v$$

Macierz A **nie zmienia kierunku** v — tylko go skaluje.

Interpretacja geometryczna

- $\lambda > 0$: wektor rozciągnięty/skrócony, **ten sam kierunek**
- $\lambda < 0$: wektor **odwrócony** i przeskalowany
- $\lambda = 0$: wektor wysłany na 0 (A **osobliwa!**)
- $|\lambda| > 1$: rozciąganie; $|\lambda| < 1$: ściskanie



Kluczowa obserwacja

Dla “zwykłych” wektorów Ax zmienia **i** kierunek, **i** długość.

Wektory własne to **wyjątkowe kierunki**, które transformacja tylko skaluje.

Wektor własny i wartość własna: po co to liczyć?

Wektory własne macierzy kowariancji

Niech Σ będzie macierzą kowariancji danych.

- Wektory własne q_i macierzy Σ = **główne kierunki zmienności** danych
- Wartości własne λ_i = **wariancja** wzdłuż q_i
- $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ (macierz dodatnio półokreślona)

⇒ fundament **PCA** (Principal Component Analysis).

Inne zastosowania

- **PageRank**: wektor własny dla $\lambda = 1$ macierzy przejść Markowa
- **Drgania**: wartości własne = częstości rezonansowe
- **Równania różniczkowe**: $\dot{x} = Ax$ — rozwiązanie przez wektory własne

PCA w pigułce. Dane: m punktów w $\mathbb{R}^n$.

Krok 1: wyznacz $\Sigma = \frac{1}{m} X^T X$

Krok 2: rozłóż $\Sigma = Q \Lambda Q^T$

Krok 3: rzutuj dane na pierwsze k kolumn Q :

$$Z = XQ_{:k}$$

Zachowujesz $\sum_{i=1}^k \frac{\lambda_i}{\sum_{i=1}^n \lambda_i}$ wariancji danych.

Kluczowy związek

$$\Sigma = Q \Lambda Q^T = \sum_{i=1}^n \lambda_i q_i q_i^T$$

Macierz kowariancji to **suma rang-1** ważonych wartościami własnymi — każdy składnik to jeden „kierunek rozrzutu”.

Wielomian charakterystyczny: wyprowadzenie

Wyprowadzenie

Szukamy λ i $v \neq 0$ takich że $Av = \lambda v$.

Przepisujemy:

$$Av - \lambda v = 0 \implies (A - \lambda I)v = 0$$

Niezerowe v istnieje $\Leftrightarrow (A - \lambda I)$ jest **osobliwa**:

$$\det(A - \lambda I) = 0$$

Wielomian charakterystyczny

$p(\lambda) = \det(A - \lambda I)$ jest wielomianem stopnia n .

Dla $A \in \mathbb{R}^{2 \times 2}$:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

$$p(\lambda) = \lambda^2 - \underbrace{(a+d)} \lambda + \underbrace{(ad-bc)}$$

Intuicja: dlaczego wyznacznik?

Układ $(A - \lambda I)v = 0$ ma niezerowe rozwiązanie

$\Leftrightarrow$ kolumny macierzy $(A - \lambda I)$ są **liniowo zależne**

$\Leftrightarrow$ macierz jest **osobliwa**

$\Leftrightarrow \det(A - \lambda I) = 0$.

Wyznacznik jest więc naturalnym **testem osobliwości**.

Przykład: obliczenie $p(\lambda)$

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

$$\det(A - \lambda I) = \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}$$

$$= (3 - \lambda)^2 - 1 = \lambda^2 - 6\lambda + 8$$

$$= (\lambda - 4)(\lambda - 2) = 0$$

Wielomian charakterystyczny: wyróżnik i klasyfikacja

Dwa wzory na wyróżnik Δ

Przypadek ogólny (b może $\neq c$):

$$\Delta = \text{tr}(\mathbf{A})^2 - 4\det(\mathbf{A}) = (a - d)^2 + 4bc$$

Przypadek symetryczny ($b = c$):

$$\Delta = (a - d)^2 + 4b^2 \geq 0$$

Suma kwadratów — **zawsze nieujemna!**

Uwaga: wzór symetryczny jest szczególnym przypadkiem ogólnego przy $b = c$. Nie używaj go dla macierzy niesymetrycznych!

Znaczenie wyróżnika

- $\Delta > 0$: dwa różne pierwiastki **rzeczywiste**
- $\Delta = 0$: pierwiastek **podwójny rzeczywisty** (może być 1 lub 2 wektory własne — zależy od macierzy)
- $\Delta < 0$: para **sprzężonych zespolonych**
 $\alpha \pm \beta i$

Kluczowy wniosek

$$\mathbf{A} = \mathbf{A}^T \Rightarrow \Delta = (a - d)^2 + 4b^2 \geq 0$$

$\Rightarrow$ wartości własne zawsze **rzeczywiste**

To jest szczególny przypadek **twierdzenia spektralnego** dla macierzy symetrycznych.

Wielomian charakterystyczny: algorytm wyznaczania

Algorytm wyznaczania wartości własnych

- 1 Oblicz $p(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I})$
- 2 Rozwiąż $p(\lambda) = 0$
 $\Rightarrow$ pierwiastki = **wartości własne**
- 3 Dla każdego λ_i rozwiąż:
 $(\mathbf{A} - \lambda_i \mathbf{I})\mathbf{v} = \mathbf{0}$
 $\Rightarrow \mathbf{v} =$ **wektor własny**

Krok 3 to zwykła eliminacja Gaussa — szukamy jądra macierzy $(\mathbf{A} - \lambda_i \mathbf{I})$.

Niezmienniki podobieństwa

Jeśli $\mathbf{B} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}$, to:

$$\operatorname{tr}(\mathbf{B}) = \operatorname{tr}(\mathbf{A}), \quad \det(\mathbf{B}) = \det(\mathbf{A})$$

Wartości własne **nie zmieniają się** przy zmianie bazy — są własnością **transformacji liniowej**, nie jej macierzy w konkretnej bazie.

Związki śladu i wyznacznika

Dla $\mathbf{A} \in \mathbb{R}^{n \times n}$:

$$\operatorname{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i, \quad \det(\mathbf{A}) = \prod_{i=1}^n \lambda_i$$


- $\det(\mathbf{A}) = 0 \Leftrightarrow \exists \lambda_i = 0 \Leftrightarrow \mathbf{A}$ **osobliwa**
- $\operatorname{tr}(\mathbf{A})$ daje szybką **sumę kontrolną**

Podsumowanie: Wielomian charakterystyczny: typologia macierzy 2×2

Typ macierzy	A	Δ	Wartości własne	Geometria
symetryczna, dod. określona	$\begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix}$	> 0	$\lambda_{1,2} = \frac{6 \pm \sqrt{8}}{2} \in \mathbb{R}, \lambda_i > 0$	rozciąganie wzdłuż osi głównych
symetryczna, nieokreślona	$\begin{bmatrix} 2 & 3 \\ 3 & -2 \end{bmatrix}$	> 0	$\lambda_1 > 0, \lambda_2 < 0$	siodło: rozciąg + odbicie
obróć o 90° , niesymetryczna	$\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$	< 0	$\lambda_{1,2} = \pm i \in \mathbb{C}$	brak rzecz. kier. własnych
ściskanie (Jordana), niesymetryczna	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	$= 0$	$\lambda_1 = \lambda_2 = 1, 1 \text{ wekt. własny}$	przesunięcie wzdłuż osi
górnortrójkątna, niesymetryczna	$\begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}$	> 0	$\lambda_1 = 2, \lambda_2 = 3$	dwie niezależne osie własne
rzut ortogonalny, symetryczna	$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$	$= 0$	$\lambda_1 = 1, \lambda_2 = 0$	ściskanie do prostej

Wielomian charakterystyczny: diagram (tr, det)

Obszary w płaszczyźnie (tr, det)



Jak czytać diagram

- Punkt $(\text{tr}, \det)$ **nad parabolą** $\Rightarrow$ pierwiastki zespolone
- **Pod parabolą, nad osią** $\Rightarrow$ dwa różne rzeczywiste
- **Na paraboli** $\Rightarrow$ pierwiastek podwójny
- **Pod osią** ($\det < 0$) $\Rightarrow$ różne znaki λ (siodło)

Przykład numeryczny: dwa typy

Symetryczna: $\mathbf{A} = \begin{bmatrix} 3 & 2 \\ 2 & 1 \end{bmatrix}$

$$\Delta = (3 - 1)^2 + 4 \cdot 2^2 = 4 + 16 = 20 > 0 \checkmark$$

Dwie różne wartości własne **rzeczywiste**.

Niesymetryczna: $\mathbf{B} = \begin{bmatrix} 1 & -3 \\ 3 & 1 \end{bmatrix}$

$$\Delta = (1 - 1)^2 + 4 \cdot (-3) \cdot 3 = -36 < 0$$

$$\Rightarrow \lambda_{1,2} = 1 \pm 3i \in \mathbb{C}$$

Dla $\mathbf{B}$: wzór ogólny ($bc = -9$), **nie symetryczny!**

Macierze symetryczne — przykłady (1/2)

Przykład 1: skalowanie

$$\mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A} = \mathbf{A}^T \checkmark$$

$$p(\lambda) = (\lambda - 3)(\lambda - 1) = 0, \quad \lambda_1 = 3, \lambda_2 = 1$$

Wektory własne (od razu z macierzy):

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

Macierz już diagonalna! Osie układu są wektorami własnymi — $\mathbf{A}$ tylko skaluje każdą oś.

Przykład 2: macierz kowariancji

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{A} = \mathbf{A}^T \checkmark$$

$$p(\lambda) = \lambda^2 - 7\lambda + 8 = 0, \quad \Delta = 17 > 0$$

$$\lambda_{1,2} = \frac{7 \pm \sqrt{17}}{2} \approx \begin{cases} 5.56 \\ 1.44 \end{cases}$$

Wektor własny dla $\lambda_1 \approx 5.56$:

$$(\mathbf{A} - 5.56 \mathbf{I})\mathbf{v} = \mathbf{0} \Rightarrow \mathbf{q}_1 \approx \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

Wektor własny dla $\lambda_2 \approx 1.44$:

$$\mathbf{q}_2 \approx \frac{1}{\sqrt{5}} \begin{bmatrix} -1 \\ 2 \end{bmatrix}, \quad \mathbf{q}_1^T \mathbf{q}_2 = 0 \checkmark$$

Macierze symetryczne — przykłady (2/2)

Przykład 3: macierz ujemnie określona

$$\mathbf{A} = \begin{bmatrix} -2 & 1 \\ 1 & -3 \end{bmatrix}, \quad \mathbf{A} = \mathbf{A}^T \checkmark$$

$$p(\lambda) = \lambda^2 + 5\lambda + 5 = 0$$

$$\lambda_{1,2} = \frac{-5 \pm \sqrt{5}}{2} \approx \begin{cases} -1.38 \\ -3.62 \end{cases}$$

Oba **ujemne i rzeczywiste!**

A ściska i **odwraca** każdy kierunek — typowe zachowanie macierzy ujemnie określonej.

Ogólna zasada: $\mathbf{A} = \mathbf{A}^T$, $\mathbf{A} \in \mathbb{R}^{n \times n}$

Dla macierzy 2×2 z $b = c$:

$$\Delta = (a - d)^2 + 4b^2 \geq 0$$

Suma kwadratów liczb rzeczywistych — **zawsze nieujemna**. $\Rightarrow$ **macierz symetryczna ma zawsze rzeczywiste wartości własne.** (Twierdzenie spektralne — zachodzi też dla $\mathbb{R}^{n \times n}$.)

Związek z twierdzeniem spektralnym

$\mathbf{A} = \mathbf{A}^T$ i $\Delta \geq 0 \Rightarrow$ istnieją n **ortogonalnych** wektorów własnych:

$$\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T, \quad \mathbf{Q}^T \mathbf{Q} = \mathbf{I}$$

To jest właśnie rozkład QR zastosowany do macierzy symetrycznej.

Macierze niesymetryczne — wartości zespolone (1/2)

Przykład 1: macierz obrotu o 90°

$$\mathbf{R} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad \mathbf{R} \neq \mathbf{R}^T \quad \times$$

$$p(\lambda) = \lambda^2 + 1 = 0, \quad \lambda_{1,2} = \pm i \in \mathbb{C}$$

Sens geometryczny:

obrót o 90° nie ma żadnego **rzeczywistego** kierunku niezmienniczego — każdy wektor zmienia kierunek.

Wartości własne **czysto urojone** $\Leftrightarrow$ transformacja to czyste obrócenie bez rozciągania ($|\lambda| = 1$).

Przykład 2: obrót + skalowanie

$$\mathbf{A} = \begin{bmatrix} 1 & -2 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{A} \neq \mathbf{A}^T \quad \times$$

$$p(\lambda) = \lambda^2 - 2\lambda + 5 = 0, \quad \Delta = -16 < 0$$

$$\lambda_{1,2} = 1 \pm 2i \in \mathbb{C}$$

Brak rzeczywistych wektorów własnych!

Interpretacja modułu:

$$|\lambda| = \sqrt{1^2 + 2^2} = \sqrt{5} \approx 2.24$$

Transformacja **obraca i rozciąga** wektory ($\sqrt{5}$ -krotnie).

Macierze niesymetryczne — blok Jordana (2/2)

Przykład 3: macierz Jordana (niediagonalizowalna)

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{A} \neq \mathbf{A}^T \quad \times$$

$$p(\lambda) = (\lambda - 2)^2 = 0, \quad \lambda_1 = \lambda_2 = 2$$

Szukamy wektorów własnych $(\mathbf{A} - 2\mathbf{I})\mathbf{v} = \mathbf{0}$:

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \mathbf{v} = \mathbf{0} \Rightarrow \mathbf{v} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

Tylko **jeden** niezależny wektor własny!

Krotność algebraiczna vs geometryczna

- **Krotność algebraiczna** = 2 (potęga $(\lambda - 2)^2$ w wielomianie)
- **Krotność geometryczna** = 1 (wymiar przestrzeni własnej)

Podsumowanie: co decyduje o charakterze pierwiastków?


Macierz	Δ	Pierwiastki
$\mathbf{A} = \mathbf{A}^T$	≥ 0	rzeczywiste
obrót, skos	< 0	zespolone
Jordana	$= 0$	podwójny rzech.

Kluczowa intuicja

Macierz Jordana **nie jest** niediagonalizowalna dlatego, że ma podwójny pierwiastek. Jest niediagonalizowalna, bo **brakuje** drugiego niezależnego wektora własnego — przestrzeń własna jest za mała. Podwójny pierwiastek $\nrightarrow$ niediagonalizowalność (np. $\mathbf{I}$ ma $\lambda = 1$ z krotnością 2, ale jest diagonalny).


Geometria wartości własnych: przypadki macierzy 2×2 (1/2)

Przypadek 1: $\lambda_1 > \lambda_2 > 0$ (sym.)



Koło jednostkowe $\rightarrow$ **elipsa**.
Półosie elipsy = wartości własne.

Przypadek 2: $\lambda_1 > 0 > \lambda_2$ (sym.)



Jeden kierunek rozciągany, drugi **odwracany**.
Macierz **nieokreślona** (różne znaki λ).


Geometria wartości własnych: przypadki macierzy 2×2 (2/2)

Przypadek 3: obrót (niesym., $\lambda \in \mathbb{C}$)



Koło $\rightarrow$ koło (zachowana norma).
Brak rzeczywistego wektora własnego.

Przypadek 4: $\lambda_2 = 0$ — ściskanie do linii



$\lambda_2 = 0 \Leftrightarrow \det(\mathbf{A}) = 0 \Leftrightarrow \mathbf{A}$ osobliwa.
Cała płaszczyzna ściszana do prostej = obrazu $\mathbf{A}$.

Wyznaczanie wektorów własnych: macierz symetryczna

Macierz symetryczna (rzech. wart. własne)

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A} = \mathbf{A}^T$$

Krok 1: wielomian charakterystyczny:

$$p(\lambda) = \lambda^2 - 6\lambda + 8 = (\lambda - 4)(\lambda - 2) = 0$$

$$\lambda_1 = 4, \quad \lambda_2 = 2 \quad (\text{rzeczywiste!})$$

Krok 2: $(\mathbf{A} - 4\mathbf{I})\mathbf{v} = \mathbf{0}$:

$$\begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{v} = \mathbf{0} \Rightarrow \mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Krok 3: $(\mathbf{A} - 2\mathbf{I})\mathbf{v} = \mathbf{0}$:

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \mathbf{v} = \mathbf{0} \Rightarrow \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Interpretacja geometryczna

$\mathbf{A}$ rozciąga **4-krotnie** wzdłuż kierunku $(1, 1)$
i **2-krotnie** wzdłuż $(1, -1)$.

Oryginalna baza $\{e_1, e_2\}$ jest “pochylona”
względem osi własnych — dopiero baza $\{\mathbf{q}_1, \mathbf{q}_2\}$
uwidacznia prostą strukturę skalowania.

Weryfikacja: $\mathbf{A}\mathbf{q}_1$

$$\mathbf{A}\mathbf{q}_1 = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 4 \\ 4 \end{bmatrix} = 4 \cdot \mathbf{q}_1 \quad \checkmark$$

Wyznaczanie wektorów własnych: macierz obrotu i rozkład spektralny

Macierz obrotu (zesp. wart. własne)

$$\mathbf{R} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad \mathbf{R} \neq \mathbf{R}^T$$

Krok 1: wielomian:

$$p(\lambda) = \lambda^2 + 1 = 0 \Rightarrow \lambda_{1,2} = \pm i$$

Krok 2: dla $\lambda_1 = i$:

$$(\mathbf{R} - i\mathbf{I})\mathbf{v} = \begin{bmatrix} -i & -1 \\ 1 & -i \end{bmatrix} \mathbf{v} = \mathbf{0}$$

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ -i \end{bmatrix} \in \mathbb{C}^2$$

Wektor własny **zespolony** — w $\mathbb{R}^2$ nie istnieje kierunek niezmienny przy obrocie o 90° .

Rozkład spektralny: przykład symet.

Z poprzedniego slajdu:

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \mathbf{\Lambda} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$$

Sprawdzenie:

$$\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \quad \checkmark$$

Interpretacja rozkładu spektralnego

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T = \sum_{i=1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^T$$

Macierz = **suma rzutowań** na kierunki własne,

Wprowadzenie do twierdzenia spektralnego
dla rzeczywistych macierzy symetrycznych

Twierdzenie spektralne: cel i narzędzia

Twierdzenie spektralne

Niech $\mathbf{A} = \mathbf{A}^T \in \mathbb{R}^{n \times n}$.

Wówczas istnieje rozkład:

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$$

gdzie:

- $\mathbf{Q}$ — macierz **ortogonalna** ($\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$)
- $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ — macierz **diagonalna**
- wszystkie $\lambda_i \in \mathbb{R}$ — wartości własne **rzeczywiste**

Plan dowodu

- L. Lemat:** macierz symetryczna ma co najmniej jedną rzeczywistą wartość własną
1. Znajdź pierwszą parę własną $(\lambda_1, \mathbf{q}_1)$
2. Obróć bazę — zredukuj problem do rozmiaru $(n-1) \times (n-1)$
3. Zastosuj **założenie indukcyjne**
4. Złóż rozkład

Potrzebne narzędzia

- Ciągłość na zbiorze zwartym (minimum istnieje)
- Gram–Schmidt (budowa bazy ortogonalnej)
- Indukcja matematyczna

Bez algebry zespolonej, bez SVD, bez teorii grup.