

Geometria Ryzyka

Zastosowania Twierdzenia Spektralnego oraz PCA w Ocenie Ryzyka

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

30 marca 2026

Wprowadzenie do Geometrii Ryzyka
z perspektywy zastosowań
Twierdzenia Spektralnego
oraz PCA
do oceny ryzyka

Plan

Część A

- 1 Co to jest ryzyko? – intuicja i definicja
- 2 Log-zwroty i wariancja (przypadek 1D)
- 3 Centralne Twierdzenie Graniczne – fundament
- 4 Kowariancja i macierz kowariancji (2D)
- 5 Dwa pytania: ryzyko vs. niepewność estymatora
- 6 Odległość Mahalanobisa i S^{-1}
- 7 Elipsoidy ufności (p -wymiarowe)

Część B

- 1 Twierdzenie Spektralne – dowód i geometria
- 2 Rozkład $A = V\Lambda V^T$ jako mapa ryzyka
- 3 PCA: definicja, algorytm, interpretacja
- 4 Zastosowanie PCA do danych giełdowych
- 5 Zastosowanie PCA do danych pogodowych
- 6 Model Markowitza i optymalny portfel
- 7 Podsumowanie i synteza

Myśl przewodnia całej serii

Jedno twierdzenie z algebry liniowej – **Twierdzenie Spektralne** – jest sercem zarówno analizy ryzyka finansowego, analizy zmienności klimatu, jak i wielu innych analiz związanych z oceną ryzyka

Co to jest ryzyko?

*Dlaczego wariancja i kowariancja mierzą
ryzyko i w jakim sensie rozumieć ro ryzyko?*

Dwa pytania o te same dane

Trader (inwestor)


Pytanie: Jak bardzo ta akcja będzie *skakać* jutro?

Ile mogę **stracić** w ciągu jednego dnia?

Interesuje go **rozrzut** pojedynczych zwrotów.

Im szerszy rozkład $\Rightarrow$ **większe ryzyko**.

Rozkład zwrotów – ryzyko portfela



Statystyk (estymator)


Pytanie: Jaka jest *prawdziwa* długoterminowa średnia zwrotów?

Jak bardzo moja estymacja $\bar{x}$ jest **niepewna**?

Interesuje go **precyzja** estymatora $\bar{x}$.

Im więcej danych $\Rightarrow$ **mniejsza niepewność**.

Rozkład estymatora – niepewność $\bar{x}$



Kluczowe rozróżnienie: Więcej danych nie uspokaja rynku. Tylko lepiej go opisuje.

Obaj używają tej samej macierzy S , ale trader mnoży przez 1, a statystyk przez $\frac{1}{n}$.

Log-zwroty – dlaczego logarytmy?

Definicja

Dla ceny P_t aktywa w chwili t definiujemy **log-zwrot**:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln P_t - \ln P_{t-1}$$

Dlaczego nie zwykłe zwroty $\frac{P_t - P_{t-1}}{P_{t-1}}$?

- **Addytywność:** $r_{1 \rightarrow 3} = r_{1 \rightarrow 2} + r_{2 \rightarrow 3}$
- **Symetria:** spadek i wzrost powrotny dają sumę 0
- **Rozkład normalny:** lepsze dopasowanie do danych

Przykład liczbowy

Akcja: $100 \rightarrow 50 \rightarrow 100$ zł


Zwroty proste:

$$-50\% + 100\% = +50\% \neq 0$$

Log-zwroty:

$$\begin{aligned} \ln \frac{50}{100} + \ln \frac{100}{50} \\ = -0,693 + 0,693 = 0 \end{aligned}$$

Rozkład log-zwrotów $\approx \mathcal{N}(\mu, \sigma^2)$



Rozkład normalny

(przypomnienie wzorów na funkcje gęstości
prawdopodobieństwa)
i metryka Mahalanobisa

Przypadek 1D – Wariancja jako miara ryzyka

Definicja wariancji

Mamy n log-zwrotów $r_1, \dots, r_n$. Szacunkowa wariancja:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (r_i - \bar{r})^2$$


Interpretacja: Im większa s^2 , tym bardziej *nieprzewidywalne* są jutrzejsze zwroty.

Odchylenie standardowe

$s = \sqrt{s^2}$ – ryzyko wyrażone w **tych samych jednostkach** co zwroty (%).

W finansach mówi się: „*zmienność*” (ang. *volatility*).

Dwie akcje – różna zmienność



Wniosek

Akcja B jest **trzy razy bardziej ryzykowna** niż A – elipsa jest trzy razy szersza.

Rozkład normalny n -wymiarowy – wzór i geometria (1/4)

Rozkład $\mathcal{N}(\mu, \Sigma)$ w $\mathbb{R}^n$

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \sqrt{\det \Sigma}} \exp \left(-\frac{1}{2} \underbrace{(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)}_{d_M^2 = \text{odl. Mahalanobisa}^2} \right)$$


- $\mu \in \mathbb{R}^n$ – **wektor średnich** (położenie “szczytu”)
- $\Sigma \in \mathbb{R}^{n \times n}$ – **macierz kowariancji** (kształt i orientacja)
- Argument eksponenty to d_M^2 :
im dalej od μ względem Σ , tym mniejsza gęstość

Linie poziomu $f = c$ to hiperelipsoidy

$\{ \mathbf{x} \in \mathbb{R}^n : (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) = k^2 \}$ – elipsoida w $\mathbb{R}^n$, której kształt jest **w całości określony przez Σ** .

Linie poziomu $\mathcal{N}(0, \Sigma)$

mała f



$v_1 \perp v_2$, długości osi = $\sqrt{\lambda_i}$

Interpretacja macierzy Σ – tabele (2/4)

Elementy macierzy Σ

Element	Znaczenie
$\sigma_{ii} = \text{Var}(X_i)$	ryzyko własne
$\sigma_{ij} = \text{Cov}(X_i, X_j)$	ryzyko relacji
$\Sigma = \Sigma^T$ (sym.)	$\sigma_{ij} = \sigma_{ji}$
$\mathbf{w}^T \Sigma \mathbf{w} \geq 0$	dod. półokr.
$\Sigma = V \Lambda V^T$	rozkł. spekt.

Parametry rozkładu $V \Lambda V^T$


Parametr	Rola w elips.
$\mathbf{v}_i$ – wekt. własny	kierunek osi
λ_i – wart. własna	(dł. osi) ²
$\sqrt{\lambda_i}$	ryzyko w $\mathbf{v}_i$
$\lambda_1 \geq \lambda_2 \geq \dots \geq 0$	malej. kanały
$\rho_{ij} \rightarrow \pm 1$	elips. $\rightarrow$ odcin.

Dlaczego obie tabele razem?

Elementy Σ mówią **co** jest ryzykiem (kowariancje). Rozkład spektralny mówi **w jakim kierunku i jak mocno** (wartości i wektory własne). Razem dają pełną geometrię elipsoidy.

Interpretacja macierzy Σ – korelacja i kształt (3/4)

Trzy przypadki korelacji ρ_{ij}



Kształt elipsoidy zmienia się *wyłącznie* przez Σ – średnia μ przesuwa jedynie środek.

Wniosek geometryczny

- **Okrąg** ($\rho = 0$, $\lambda_1 = \lambda_2$):
wszystkie kierunki równorzędne,
brak dominującego ryzyka
- **Elipsa pochylona** ($\rho > 0$):
jeden kierunek dominuje,
 $v_1 =$ główny kanał ryzyka
- **Zdegenerowana** ($\rho \rightarrow \pm 1$):
 $\lambda_2 \rightarrow 0$, macierz Σ
traci pełny rząd

Do zapamiętania

Im większa **różnica** $\lambda_1 - \lambda_2$,
tym **bardziej eliptyczny** kształt
i większe **ryzyko kierunkowe**.

$\Sigma = V\Lambda V^T$ – most między statystyką a geometrią (4/4)

Rozkaz spektralny krok po kroku

$$\Sigma = V\Lambda V^T = \sum_{i=1}^n \lambda_i v_i v_i^T$$

- 1 V^T – obraca dane do układu głównych składowych (osi elipsoidy)
- 2 Λ – skaluje każdą oś o czynnik λ_i (ryzyko w danym kierunku)
- 3 V – obraca z powrotem do oryginalnego układu


Odległość Mahalanobisa po rozkładzie:

$$d_M^2 = \mathbf{z}^T \Lambda^{-1} \mathbf{z} = \sum_{i=1}^n \frac{z_i^2}{\lambda_i}, \quad \mathbf{z} = V^T(\mathbf{x} - \boldsymbol{\mu})$$

Składowa z_i to rzut na i -ty kierunek ryzyka; dzielimy przez λ_i , bo duża zmienność to “normalna” odległość w tym kierunku

Trzy kroki rozkładu $\Sigma = V\Lambda V^T$

1. Obraca V^T



2. Skaluje Λ

3. Obraca V

Centralne Twierdzenie Graniczne

Centralne Twierdzenie Graniczne – fundament całej teorii

CTG (przypadek 1D)

Niech $r_1, \dots, r_n \stackrel{\text{i.i.d.}}{\sim} (\mu, \sigma^2)$.

Wtedy dla dużych n :

$$\sqrt{n} \frac{\bar{r} - \mu}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1)$$

a dokładniej – jeśli σ nieznane:


$$\sqrt{n} \frac{\bar{r} - \mu}{s} \sim t_{n-1}$$

Przedział ufności dla μ (1D)

$$\bar{r} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$$

Kształt geometryczny: odcinek na osi liczbowej.

Rozkład estymatora $\bar{r}$



Droga do wielu wymiarów:

CTG $\rightarrow$ elipsa (2D) $\rightarrow$ elipsoida (p D)
Kształt elipsoidy = macierz kowariancji S

Przypadek 2D – Kowariancja i “współdrżanie” aktywów

Definicja kowariancji

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (r_{xi} - \bar{r}_x)(r_{yi} - \bar{r}_y)$$


- $s_{xy} > 0$: aktywa **rosną razem**
⇒ ryzyko się kumuluje
- $s_{xy} < 0$: jedno rośnie, drugie spada
⇒ **dywersyfikacja!**
- $s_{xy} = 0$: brak liniowej zależności

Współczynnik korelacji


$$\rho_{xy} = \frac{s_{xy}}{s_x \cdot s_y} \in [-1, 1]$$

Znormalizowana miara siły zależności.

$\rho > 0$ (kumulacja ryzyka)



$\rho < 0$ (dywersyfikacja)



Przykład finansowy

Akcja + obligacja: typowo $\rho < 0$.

Dwie akcje z tej samej branży: $\rho \approx +0,8$.

Macierz kowariancji – wszystko w jednej strukturze

Definicja (p aktywów)


$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{r}_i - \bar{\mathbf{r}})(\mathbf{r}_i - \bar{\mathbf{r}})^T$$

Dla $p = 2$:

$$\mathbf{S} = \begin{pmatrix} s_x^2 & s_{xy} \\ s_{xy} & s_y^2 \end{pmatrix}$$

- **Przekątna:** wariancje (ryzyko własne każdego aktywa)
- **Poza przekątną:** kowariancje (ryzyko relacji)
- $\mathbf{S}$ jest zawsze **symetryczna**: $\mathbf{S} = \mathbf{S}^T$
- $\mathbf{S}$ jest zawsze **dodatnio półokreślona**:
 $\mathbf{w}^T \mathbf{S} \mathbf{w} \geq 0$

Elipsa – „odcisk” macierzy $\mathbf{S}$



Osie elipsy = wektory własne $\mathbf{S}$

Długości osi $\propto \sqrt{\lambda_i}$

Ta sama matematyka – inne dane: zmiany temperatur

Dane meteorologiczne

Mierzymy dobowe anomalie temperatury (odchylenie od średniej wieloletniej) w trzech miastach:

- T_G – Gdańsk
- T_W – Warszawa
- T_R – Rzym

$$\mathbf{S}_{\text{temp}} = \begin{pmatrix} s_G^2 & s_{GW} & s_{GR} \\ s_{GW} & s_W^2 & s_{WR} \\ s_{GR} & s_{WR} & s_R^2 \end{pmatrix}$$

- $s_{GW} > 0$: te same fronty atmosferyczne
- s_{GR} : słabsza korelacja – odległe klimaty

Analogia finansowa

Finanse	Meteorologia
Akcja	Miasto
Log-zwrot	Anomalia temperatury
Kowariancja	Wspólny front atm.
Wariancja	Klimat lokalny
Dywersyfikacja	Klimaty niezależne
Czynnik rynkowy (PC1)	Front ogólnoeuropejski

Kluczowy wniosek

Macierz kowariancji opisuje **strukturę zależności** w *dowolnych* wielowymiarowych danych.

Odległość Mahalanobisa – dlaczego S^{-1} ? (krok 1: 1D)

Problem: nieuczciwa odległość

Dwie akcje, obie ze średnią $\mu = 0$:

- Akcja A: $\sigma_A = 1\%$
- Akcja B: $\sigma_B = 10\%$

Jutro obie dają $+3\%$.

Czy $+3\%$ to **to samo** dla obu?


- Dla A: $\frac{3\%}{1\%} = 3$ **odch. std.** – zdarzenie rzadkie!
- Dla B: $\frac{3\%}{10\%} = 0,3$ **odch. std.** – normalny dzień

Wniosek 1D

Uczciwa odległość to $d = \frac{|x - \mu|}{s}$.

W notacji kwadratowej: $d^2 = (x - \mu) \cdot \frac{1}{s^2} \cdot (x - \mu)$.

Ten sam wynik, inne znaczenie



Przesunięcie $= +3\%$ jest zaznaczone strzałką.
Gołą liczbą nie można porównywać odległości bez normalizacji przez zmienność.

Odległość Mahalanobisa – krok 2: wiele wymiarów

Problem w 2D: różne skale osi

Akcja: $\sigma_x = 10\%$, Obligacja: $\sigma_y = 1\%$.


Punkt (3%, 0,3%) – czy daleko od centrum?

Odległość euklidesowa: $\sqrt{3^2 + 0,3^2} \approx 3,01\%$
→ zdominowana przez akcję!

Po normalizacji przez σ :

$$\sqrt{\left(\frac{3}{10}\right)^2 + \left(\frac{0,3}{1}\right)^2} = \sqrt{0,18} \approx 0,42$$

Oba aktywa mają **równy wkład**.



Krok 3: korelacja – trzeba jeszcze obrócić

Gdy aktywa są skorelowane, S^{-1} wykonuje **dwie operacje**:

- (1) normalizuje względem zmienności każdej osi,
- (2) "obraca" przestrzeń tak, by uwzględnić korelacje.

Definicja ogólna

$$d_M^2(\mathbf{x}, \boldsymbol{\mu}) = (\mathbf{x} - \boldsymbol{\mu})^T \mathbf{S}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

Półosie elipsy ryzyka mają długość $\sqrt{\lambda_i}$, nie λ_i – wyprowadzenie (1/2)

Krok 1: linia poziomu rozkładu

Rozkład $\mathcal{N}(\mathbf{0}, \Sigma)$ ma gęstość:

$$f(\mathbf{x}) \propto \exp\left(-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}\right)$$

Linia poziomu $f = \text{const}$ to zbiór punktów spełniających:

$$\boxed{\mathbf{x}^T \Sigma^{-1} \mathbf{x} = c^2}$$


Krok 2: rozkład spektralny $\Sigma = V \Lambda V^T$

Podstawiamy $\Sigma^{-1} = V \Lambda^{-1} V^T$ i zmieniamy zmienne:

$$\mathbf{z} = V^T \mathbf{x} \quad (\text{obrót do układu gł. składowych})$$

Wtedy $\mathbf{x}^T \Sigma^{-1} \mathbf{x} = \mathbf{z}^T \Lambda^{-1} \mathbf{z}$, czyli:

$$\mathbf{z}^T \Lambda^{-1} \mathbf{z} = c^2 \implies \boxed{\frac{z_1^2}{\lambda_1} + \frac{z_2^2}{\lambda_2} = c^2}$$



Półoś elipsy ryzyka – interpretacja $\sqrt{\lambda_i}$ vs λ_i (2/2)

Tabela interpretacji

Wielkość	Znaczenie
λ_i	wariancja w kier. v_i (kwadrat ryzyka)
$\sqrt{\lambda_i}$	odch. std. = ryzyko = półoś
$c\sqrt{\lambda_i}$	półoś elipsy poziomu c
$\frac{\lambda_i}{\sum_j \lambda_j}$	udział i -tej składowej w zmienności

Analogia z przypadkiem 1D

W 1D ryzyko = σ , nie σ^2 .


W n D ryzyko w kier. $v_i = \sqrt{\lambda_i}$, nie λ_i .

$\lambda_i = \sigma_i^2$ jest **wariancją**,


$\sqrt{\lambda_i} = \sigma_i$ jest **odchyleniem standardowym**.

Porównanie: λ_i vs $\sqrt{\lambda_i}$ jako półoś

Błędnie: półoś = λ_i



Poprawnie: półoś = $\sqrt{\lambda_i}$



Stosunek półosi:
błędnie 4:1, poprawnie 2:1

Własności S – dlaczego rozkład spektralny istnieje? (1/2)

Własność 1: Symetria

$$\mathbf{S} = \mathbf{S}^T$$

Dowód:

$$s_{ij} = \text{Cov}(r_i, r_j) = \text{Cov}(r_j, r_i) = s_{ji}$$

Konsekwencja: Tw. Spektralne gwarantuje rozkład na rzeczywiste wartości własne i *prostopadłe* wektory własne.

Własność 2: Dodatnia półokreśloność

$$\mathbf{w}^T \mathbf{S} \mathbf{w} \geq 0 \quad \forall \mathbf{w} \in \mathbb{R}^p$$

Dowód:

$$\mathbf{w}^T \mathbf{S} \mathbf{w} = \text{Var}(\mathbf{w}^T \mathbf{r}) \geq 0$$

bo wariancja jest nieujemna.

Konsekwencja: wszystkie $\lambda_i \geq 0$.
Elipsoida “nie odwraca się”.

Wystarczający warunek istnienia rozkładu

S symetryczna + dodatnio półokreślona $\Rightarrow$ Twierdzenie Spektralne stosuje się w pełni:
wartości własne rzeczywiste i nieujemne, wektory własne prostopadłe.


Własności S – konsekwencje geometryczne (2/2)

Co z tego wynika?

- $\lambda_i \in \mathbb{R}$, $\lambda_i \geq 0$ – osie elipsoidy są rzeczywiste
- $v_i \perp v_j$ – osie są prostopadłe
- $S = V\Lambda V^T$ – rozkład spektralny
- Elipsoida jest dobrze zdefiniowana
- S^{-1} istnieje gdy $\lambda_i > 0$ – brak degeneracji

Kluczowa obserwacja

Własności S nie są założeniem – są **fizycznym faktem** wynikającym z definicji wariancji i kowariancji.



Elipsa ufności – geometria CTG w 2D

CTG wielowymiarowe

Niech $\mathbf{r}_1, \dots, \mathbf{r}_n \stackrel{\text{i.i.d.}}{\sim} (\boldsymbol{\mu}, \Sigma)$, $p = 2$.

Wtedy:

$$\sqrt{n}(\bar{\mathbf{r}} - \boldsymbol{\mu}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$$

Statystyka T^2 Hotellinga (dokładna)

$$T^2 = n(\bar{\mathbf{r}} - \boldsymbol{\mu})^T \mathbf{S}^{-1}(\bar{\mathbf{r}} - \boldsymbol{\mu})$$


$$\frac{n-p}{p(n-1)} T^2 \sim F(p, n-p)$$

Obszar ufności $1 - \alpha$ dla $\boldsymbol{\mu}$:

$$\left\{ \boldsymbol{\mu} : T^2 \leq \frac{p(n-1)}{n-p} F_{\alpha}(p, n-p) \right\}$$

Kształt: *elipsa* na płaszczyźnie.

Elipsa ufności 95% dla $\boldsymbol{\mu}$



Interpretacja

Z 95% pewnością *prawdziwa* średnia $\boldsymbol{\mu}$ leży wewnątrz tej elipsy. Osie = wektory własne $\mathbf{S}$.

Dwa pytania – formalna tabela porównawcza

Kryterium	Ryzyko portfela	Niepewność estymatora
Pytanie	Jak drgają zwroty?	Jak myli się $\bar{r}$?
Obiekt geometryczny	Elipsoida <i>danych</i>	Elipsoida <i>ufności</i> dla μ
Rozmiar elipsoidy	Stały (własność rynku)	$\propto \frac{1}{\sqrt{n}}$
Formuła macierzy	S	$\frac{1}{n}S$
Gdy $n \rightarrow \infty$	Elipsoida nie zmienia się	Elipsoida kurczy do punktu
Zastosowanie	Value-at-Risk, wagi portfela	Testy hipotez, przedziały ufności

Zasada do zapamiętania

Więcej danych nie uspokaja rynku. Tylko lepiej go opisuje.

Przypadek 3D – Portfel trójskładnikowy

Trzy aktywa: akcja + obligacja + złoto

$$\mathbf{S} = \begin{pmatrix} s_X^2 & s_{XY} & s_{XZ} \\ s_{XY} & s_Y^2 & s_{YZ} \\ s_{XZ} & s_{YZ} & s_Z^2 \end{pmatrix}$$


Macierz 3×3 , symetryczna, PSD.

Trzy wektory własne v_1, v_2, v_3 (wzajemnie $\perp$):

- v_1 (najdłuższa oś) – ogólna koniunktura rynkowa
- v_2 (średnia oś) – czynnik stóp procentowych
- v_3 (najkrótsza oś) – **najbezpieczniejszy** kierunek

Interpretacja inwestycyjna

Portfel zorientowany wzdłuż v_3 “drga” **najmniej**, mimo że składowe aktywa mogą być osobno ryzykowne.



Elipsoida = “bańka ryzyka” w 3D.

Kształt zdeterminowany przez macierz $\mathbf{S}$.

Przypadek p -wymiarowy – uogólnienie

Obszar ufności dla μ – wzór ogólny

Dla p aktywów i n obserwacji:

$$n(\bar{\mathbf{r}} - \boldsymbol{\mu})^T \mathbf{S}^{-1}(\bar{\mathbf{r}} - \boldsymbol{\mu}) \leq \frac{p(n-1)}{n-p} F_{\alpha}(p, n-p)$$

Kształt: hiperelipsoida w $\mathbb{R}^p$.

Dla małych p możemy narysować – dla $p = 10$ już nie, ale **matematyka pozostaje identyczna**.

p	Kształt	Wzór
1	Odcinek	t_{n-1}
2	Elipsa	$F(2, n-2)$
3	Elipsoida	$F(3, n-3)$
p	Hiperelipsoida	$F(p, n-p)$

Uproszczenie dla dużego n

Gdy $n \rightarrow \infty$: rozkład F przechodzi w χ^2 :

$$n(\bar{\mathbf{r}} - \boldsymbol{\mu})^T \mathbf{S}^{-1}(\bar{\mathbf{r}} - \boldsymbol{\mu}) \leq \chi_{\alpha}^2(p)$$

Geometrycznie: kształt elipsoidy jest stały (wyznaczony przez $\mathbf{S}$); tylko skala zmienia się o czynnik $\frac{1}{n}$.

$\uparrow n \Rightarrow$ elipsoida **mniejsza**
(pewność co do μ rośnie)
Kształt osi = **bez zmian**
(wyznaczony przez $\mathbf{S}$, nie n)

Twierdzenie spektralne - przypomnienie

Twierdzenie Spektralne – sformułowanie i geometria

Twierdzenie Spektralne

Dla każdej macierzy symetrycznej $S \in \mathbb{R}^{p \times p}$ istnieje rozkład:

$$S = V \Lambda V^T$$

gdzie:

- $V = [v_1 | v_2 | \dots | v_p]$ – macierz ortogonalna ($V^T V = I$)
- $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$, $\lambda_1 \geq \dots \geq \lambda_p \geq 0$


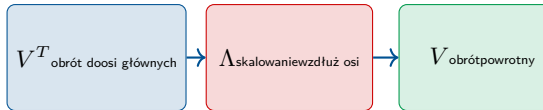
Kolumny V to **wektory własne**, λ_i to **wartości własne**.

Rozkład spektralny S^{-1}

Bezpośrednio z rozkładu:

$$S^{-1} = V \Lambda^{-1} V^T = \sum_{i=1}^p \frac{1}{\lambda_i} v_i v_i^T$$

$$S = V \Lambda V^T$$




Wartość własna = długość osi² Wektor własny = kierunek osi

Mapa ryzyka – interpretacja rozkładu spektralnego

Wartości własne λ_i – “siła” ryzyka

- $\lambda_{\max}$ = najdłuższa oś = **dominujący czynnik ryzyka**
- $\lambda_{\min}$ = najkrótsza oś = **kierunek najmniejszej zmienności**
- $\sum_i \lambda_i = \text{tr}(\mathbf{S})$ = **całkowita zmienność w danych**
- Udział PC_k : $\frac{\lambda_k}{\sum_i \lambda_i} \cdot 100\%$



Wektory własne v_i – “kierunek” ryzyka

- v_1 = „**autostrada**” rynku – gdzie idzie większość zmienności
- $v_i \perp v_j$ – kanały ryzyka są **niezależne**
- Interpretacja: liniowa kombinacja aktywów o minimalnej kowariancji krzyżowej

Metafora sejsmiczna

λ_i = **siła trzęsienia** w danym kierunku

v_i = **kierunek**, z którego nadchodzi wstrząs

Elipsoida = **mapa wszystkich możliwych wstrząsów**

Twierdzenie spektralne w praktyce: PCA i
zastosowania: finanse oraz meteorologia

Analiza Składowych Głównych (PCA) – definicja

Idea PCA

Szukamy **nowego układu współrzędnych** takiego, że:


- 1 Oś 1 (PC1) leży wzdłuż kierunku **największej zmienności**
- 2 Oś 2 (PC2) $\perp$ PC1, kolejny kierunek max. zmienności
- 3 ltd. – kolejne składowe $\perp$ poprzednim

Algorytm PCA

- 1 Wycentruj dane: $\tilde{\mathbf{r}}_i = \mathbf{r}_i - \bar{\mathbf{r}}$
- 2 Oblicz macierz kowariancji: $\mathbf{S}$
- 3 Wykonaj rozkład spektralny: $\mathbf{S} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$
- 4 Główne składowe: $\mathbf{z}_i = \mathbf{V}^T \tilde{\mathbf{r}}_i$

Wynik: dane w nowym układzie mają **zerową kowariancję krzyżową**: $\text{Cov}(z_k, z_l) = 0$ dla $k \neq l$.

PCA: obrót do osi głównych



PCA w finansach – dekompozycja ryzyka portfela

Portfel jako wektor wag

Portfel p aktywów opisany wagami $\mathbf{w} = (w_1, \dots, w_p)^T$, gdzie $\sum_i w_i = 1$.


Wariancja portfela:

$$\text{Var}(P) = \mathbf{w}^T \mathbf{S} \mathbf{w}$$

Po rozkładzie spektralnym $\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$:

$$\text{Var}(P) = \sum_{i=1}^p (\mathbf{w} \cdot \mathbf{v}_i)^2 \lambda_i$$

- $(\mathbf{w} \cdot \mathbf{v}_i)^2$ = **ekspozycja** portfela na i -ty czynnik ryzyka
- λ_i = **siła** tego czynnika
- Aby minimalizować ryzyko: **duże** $(\mathbf{w} \cdot \mathbf{v}_i)^2$ przy **małych** λ_i



Redukcja wymiaru

Zamiast analizować 500 akcji, spoglądamy na **3–5 głównych składowych** wyjaśniających np. 85% zmienności rynku.

PCA w meteorologii – czynniki zmienności klimatu

Dane: anomalie temperatur w p miastach

$$\mathbf{S}_{\text{temp}} \in \mathbb{R}^{p \times p}, \quad \mathbf{S}_{\text{temp}} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$$

Interpretacja głównych składowych:

- **PC1** (np. 55% wariancji): ogólnoeuropejski trend temperatury – wspólny front atmosferyczny
- **PC2** (np. 20% wariancji): gradient Północ-Południe (Gdańsk vs Rzym)
- **PC3** (np. 12% wariancji): efekty lokalne (ląd vs ocean)

Analogia: Ten sam wzór, inne znaczenie

Wzór $\mathbf{z} = \mathbf{V}^T \tilde{\mathbf{T}}$ przetwarza anomalie temp. tak samo jak log-zwroty. Tylko etykiety się zmieniają.

Pojęcie	Finanse	Meteorologia
Dane	log-zwroty	anomalie temp.
PC1	trend rynkowy	front europ.
λ_1	ryzyko sys.	wahania globalne
v_1	portfel rynkowy	wzorzec frontu
PC2	stopy proc.	gradient płd-płn
$\lambda_{\min}$	min. ryzyko	mikroklimat

Wniosek ogólny

Twierdzenie Spektralne opisuje strukturę zmienności w dowolnych danych – niezależnie od dziedziny.

Model Markowitza – PCA w służbie optymalizacji

Problem optymalizacji

Znajdź wagi w takie, że:

$$\min_w w^T S w \quad \text{przy} \quad w^T \mu = \mu^*, \quad w^T \mathbf{1} = 1$$

PCA upraszcza problem


Po zamianie zmiennych $u = V^T w$:

$$w^T S w = u^T \Lambda u = \sum_i \lambda_i u_i^2$$

Minimalizujemy ważoną sumę kwadratów.

Intuicja: Chcemy dużych u_i przy małych λ_i i małych u_i przy dużych λ_i .

Granica efektywna Markowitza



PCA → opis, Markowitz → **optymalizacja**.

Są to komplementarne, nie tożsame, narzędzia.

Przykład: PCA dla danych giełdowych

PCA dla danych giełdowych – punkt wyjścia

Dane: macierz dziennych stóp zwrotu 5 aktywów

Niech $\mathbf{R} \in \mathbb{R}^{T \times 5}$ będzie tablicą dziennych stóp zwrotu (wiersze = dni, kolumny = aktywa):

$$\mathbf{R} \approx \begin{bmatrix} 0.012 & 0.011 & 0.008 & 0.004 & 0.020 \\ -0.006 & -0.004 & -0.005 & 0.001 & -0.010 \\ 0.015 & 0.013 & 0.009 & 0.003 & 0.025 \\ -0.010 & -0.009 & -0.007 & -0.002 & -0.016 \\ 0.007 & 0.008 & 0.006 & 0.002 & 0.011 \end{bmatrix}.$$

Aktywa 1–3: technologiczne (silna korelacja), Aktywum 4: defensywne, Aktywum 5: tech-growth.

Krok 0: centrowanie danych

$$\mathbf{X} = \mathbf{R} - \bar{\mathbf{R}}, \quad \bar{\mathbf{R}}_j = \frac{1}{T} \sum_{t=1}^T R_{tj}.$$

Odejmujemy średnią każdej kolumny (aktywa), bo PCA szuka **zmienności**, nie poziomu.

PCA dla danych giełdowych – budowa macierzy kowariancji

Krok 1: obliczamy macierz kowariancji

$$\Sigma = \frac{1}{T-1} \mathbf{X}^T \mathbf{X} \in \mathbb{R}^{5 \times 5}.$$

Przykładowa (schematyczna) macierz kowariancji dla 5 aktywów

$$\Sigma = \begin{bmatrix} 0.040 & 0.032 & 0.028 & 0.018 & 0.035 \\ 0.032 & 0.038 & 0.027 & 0.017 & 0.033 \\ 0.028 & 0.027 & 0.035 & 0.020 & 0.030 \\ 0.018 & 0.017 & 0.020 & 0.025 & 0.019 \\ 0.035 & 0.033 & 0.030 & 0.019 & 0.045 \end{bmatrix}.$$

Uwaga: macierz ma charakter poglądowy – ilustruje strukturę, nie pochodzi wprost z tabelki zwrotów. Konsekwentne wartości liczbowe są wyznaczone przez jej ślad: $\text{tr}(\Sigma) = 0.183$.

Interpretacja elementów

- **Przekątna:** wariancje poszczególnych aktywów – ich własne ryzyko.
- **Poza przekątną:** kowariancje – jak aktywa się współporuszają.

Kowariancja jako ryzyko portfela

Wariancja portfela $\mathbf{w} = (w_1, \dots, w_5)^T$

$$\text{Var}(r_p) = \mathbf{w}^T \Sigma \mathbf{w} = \sum_{i=1}^5 \sum_{j=1}^5 w_i \Sigma_{ij} w_j.$$

Elementy diagonalne

$\Sigma_{ii} = \text{Var}(r_i)$ – wariancja i -tego aktywa. Wkład:
 $w_i^2 \text{Var}(r_i)$.

Elementy pozadiagonalne

$\Sigma_{ij} = \text{Cov}(r_i, r_j)$ – współzmiennność. Wkład:
 $2w_i w_j \text{Cov}(r_i, r_j)$.

Po co PCA?

Σ jest *gęsta* – wszystkie aktywa wzajemnie oddziałują. PCA szuka nowych osi, wzdłuż których ryzyko jest **diagonalne** (niezależne). Zamiast analizować N^2 par – analizujemy $k \ll N$ niezależnych czynników.

Krok 2: rozkład spektralny macierzy kowariancji

Twierdzenie spektralne dla Σ

$$\Sigma = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T, \quad \mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \lambda_3, \lambda_4, \lambda_5), \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_5 \geq 0.$$

Dla naszej macierzy Σ : rzeczywiste wartości własne (policzone numerycznie)

$$\lambda_1 \approx 0.1440, \quad \lambda_2 \approx 0.0159, \quad \lambda_3 \approx 0.0084, \quad \lambda_4 \approx 0.0079, \quad \lambda_5 \approx 0.0067.$$

Suma $\approx 0.183 = \text{tr}(\Sigma)$ ✓ (suma wartości własnych = ślad macierzy).

Hierarchia ryzyka

- $\lambda_1 \approx 0.144$ niesie $\approx 78.7\%$ całkowitej zmienności – **bardzo silny dominujący czynnik**.
- $\lambda_2 \approx 0.016$ niesie kolejne $\approx 8.7\%$.
- $\lambda_3 \approx 0.008$ niesie kolejne $\approx 4.6\%$.
- λ_4, λ_5 – marginalne ($\approx 4.3\%$ i 3.7%), możliwy szum.

Co dokładnie oznaczają PCA1, PCA2, PCA3?

Definicja składowych głównych

i -ta składowa główna (PC_i) to kierunek v_i (kolumna $\mathbf{V}$) o:

- 1 **największej wariancji** spośród wszystkich kierunków ortogonalnych do $PC_1, \dots, PC(i-1)$,
- 2 wartości własnej λ_i (czyli wariancji wzdłuż PC_i).

Składowa	Znaczenie matematyczne	Typowa interpretacja finansowa
PC1	Największa wariancja	Czynnik wspólny rynku (<i>market mode</i>)
PC2	Największa pozostała wariancja	Rotacja sektorowa / growth vs. value
PC3	Kolejna ortogonalna wariancja	Specyficzny sub-czynnik sektorowy
PC4,5	Małe wariancje	Szum estymacji / aktywum-specyficzne

Ważne zastrzeżenie

Interpretacja finansowa zależy od konkretnych danych – nie wynika mechanicznie z matematyki. Zawsze analizuj **znaki i moduły** ładunków (współczynników wektora własnego).

Czy PC1 można interpretować jako czynnik wspólny rynku?

Kiedy tak – analiza ładunków

Przypuśćmy, że pierwszy wektor własny to:

$$v_1 \approx \begin{bmatrix} 0.486 \\ 0.467 \\ 0.437 \\ 0.296 \\ 0.517 \end{bmatrix}.$$

Wszystkie współczynniki podobne i dodatnie – klasyczny sygnał czynnika wspólnego (*market mode*). PC1 opisuje wspólny ruch wszystkich aktywów: *risk-on* / *risk-off*.

Kiedy nie – różne znaki ładunków

Gdyby np. drugi wektor własny był:

$$v_2 \approx \begin{bmatrix} +0.265 \\ +0.274 \\ -0.370 \\ \dots \end{bmatrix},$$

Jak interpretować dominujące kierunki zmienności?

Cztery reguły interpretacji ładunków PCA

Reguła	Treść
Znaki	Wszystkie +: wspólny ruch. Mieszane znaki: kontrast między grupami.
Moduły	Większy moduł = aktywum silniej “ładuje się” na danym czynniku.
λ_i	Duże λ_i : komponent naprawdę ważny. Małe: detal lub szum.
Kontekst	PCA daje osie matematyczne – ekonomiczna interpretacja wymaga oglądu danych i znajomości sektorów.

Znaki wektorów własnych są umowne!


$-v_i$ jest równie poprawnym wektorem własnym co $+v_i$. Istotna jest **oś** kierunku, nie jego zwrot. W programach numerycznych znaki mogą się różnić między implementacjami – zawsze analizuj parę $(v_i, -v_i)$.

Projekcja danych i portfele czynnikowe

Kierunek v_i to matematyczna oś; i -ta składowa główna **dla obserwacji** x_t to

$$\tilde{x}_i = v_i^T x_t$$

Scree plot – wykres osypiska



Jak czytać wykres?

- Wartości własne **w kolejności malejącej**.
- „**Kolano**” wykresu sugeruje naturalną liczbę istotnych czynników.
- Po kolanie: obszar szumowy.

Wniosek dla tego przykładu

Bardzo silny spadek po PC1 – λ_1 dominuje wyraźnie. PC2 i PC3 mają umiarkowany wkład; PC4–PC5 są małe. Rozsądny model: 1-czynnikowy (uproszczony) lub 3-czynnikowy (zachowuje $> 93\%$ wariancji). Wybór zależy od celu analizy.

Ile składowych wyjaśnia 90% wariancji?

Wskaźnik skumulowanej wariancji

$$\text{Explained Variance Ratio}(k) = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_d}.$$

Wybieramy najmniejsze k takie, że wskaźnik przekracza 90%.


Obliczenia dla naszego przykładu ($\sum \lambda_i \approx 0.183$, wartości rzeczywiste)

k	$\sum_{i=1}^k \lambda_i$	Udział (%)	Skumulowany (%)
1	0.1440	78.7%	78.7%
2	0.1599	8.7%	87.4%
3	0.1683	4.6%	92.0% > 90%
4	0.1762	4.3%	96.3%
5	0.1829	3.7%	100.0%

Wniosek

3 składowe wystarczą do zachowania ponad 90% całkowitej wariancji. Zamiast analizować 5×5 obiekt – pracujemy w przestrzeni 3-wymiarowej. W realnym przykładzie 500 akcji: często 10–20

Wykres skumulowanej wariancji – drugie narzędzie wyboru k



Dwa narzędzia – dwa pytania

Scree plot:

„Gdzie jest naturalne kolano?”

Cumulative variance:

„Ile składowych zapewnia próg $p\%$ informacji?”

W praktyce

Czerwona linia wyznacza próg (np. 90%).
Odczytujemy, że $k = 3$ **przekracza próg**. Dla dużych portfeli próg 95% lub 99% jest standardem zarządzania ryzykiem.

Wniosek

Scree plot i cumulative variance **razem** dają pełny obraz struktury ryzyka. W okresach zmiany reżimu kształt krzywej może się istotnie zmieniać – często rośnie udział pierwszych komponentów, ale struktura zależy od typu i horyzontu stresu rynkowego.

Mini-case study: od danych do interpretacji PC1 i PC2

Przykładowy pierwszy wektor własny

$$v_1 \approx \begin{bmatrix} 0.486 \\ 0.467 \\ 0.437 \\ 0.296 \\ 0.517 \end{bmatrix}$$

Interpretacja:

- Wszystkie współczynniki **podobne i dodatnie**.
- PC1 to **wspólny ruch rynku**.
- Aktywum 4 (defensywne) ma najniższy ładunek.
- $\lambda_1 \approx 0.144$, udział $\approx 78.7\%$.

Przykładowy drugi wektor własny


$$v_2 \approx \begin{bmatrix} +0.265 \\ +0.274 \\ -0.370 \\ -0.801 \\ +0.275 \end{bmatrix}$$

Interpretacja:

- **Mieszane znaki**: aktywa 1,2,5 (+) vs. aktywa 3,4 (-).
- Ładunek aktywa 4: -0.801 – **wyrażnie dominuje** w PC2.
- PC2 to głównie **kontrast: aktywum 4 (defensywne) vs. reszta**.
- $\lambda_2 \approx 0.016$, udział $\approx 8.7\%$.

Ładunki PC1 i PC2 – co mówią wektory własne?


PC1 ($\lambda_1 \approx 0.144$, udział 78.7%)



Interpretacja PC1

Wszystkie ładunki **dodatnie i podobne**.
Aktywum 4 ma najniższy ładunek (0.296) –
uczestniczy słabiej w market mode.
PC1 = **wspólny ruch rynku**.


PC2 ($\lambda_2 \approx 0.016$, udział 8.7%)



Interpretacja PC2

A1, A2, A5: dodatnie. A3, A4: **ujemne**.
Aktywum 4 dominuje (-0.801).
PC2 = **kontrast: A4 (defensywne) vs. reszta**.

Mapa aktywów w przestrzeni czynnikowej PC1–PC2



Co widać na mapie?

- **A1, A2, A5** tworzą skupisko – podobne zachowanie, silne powiązanie z market mode i brak kontrastu w PC2.
- **A4** jest **wyraźnie odizolowane** wzdłuż osi PC2 (-0.801) – aktywum defensywne.
- **A3** pośrednie – mniejszy kontrast niż A4.
- Wszystkie aktywa po **prawej stronie** ($v_{1i} > 0$) – wspólny market mode.

Zastosowanie w portfolio

Mapa ładunków = **kompas ryzyka**: pokazuje, które aktywa dają ekspozycję na te same czynniki, a które dywersyfikują.

Aproksymacja niskiego rzędu – jak PC1 i PC2 odtwarzają Σ

	1	2	3	4	5
1	0.040	0.032	0.028	0.018	0.035
2	0.032	0.038	0.027	0.017	0.033
3	0.028	0.027	0.035	0.020	0.030
4	0.018	0.017	0.020	0.025	0.019
5	0.035	0.033	0.030	0.019	0.045

Σ (oryginalna)

	1	2	3	4	5
1	0.034	0.033	0.031	0.021	0.036
2	0.033	0.031	0.029	0.020	0.035
3	0.031	0.029	0.027	0.019	0.033
4	0.021	0.020	0.019	0.013	0.022
5	0.036	0.035	0.033	0.022	0.038

$\Sigma^{(1)}$ (78.7% wariancji)

	1	2	3	4	5
1	0.035	0.034	0.029	0.017	0.037
2	0.034	0.033	0.028	0.016	0.036
3	0.029	0.028	0.030	0.023	0.031
4	0.017	0.016	0.023	0.023	0.019
5	0.037	0.036	0.031	0.019	0.040

$\Sigma^{(2)}$ (92% wariancji)

Obserwacja

Oryginał: wyraźna dominacja wartości w lewym-górnym bloku (A1–A3,A5) oraz słabsza czwarta kolumna/rząd.

PC1 odtwarza strukturę globalną

$\Sigma^{(1)}$: jednorodny wzorzec korelacji. Ale A4 jest znacznie niedoszacowane (0.013 vs 0.025 na przekątnej).

PC2 poprawia aktywność 4

$\Sigma^{(2)}$: A4 na przekątnej wzrasta z 0.013 do 0.023 (original: 0.025). Dwa czynniki wystarczają do dobrej aproksymacji.

Macierz kowariancji jako suma „cegiełek spektralnych”

Rozkład spektralny – inaczej zapisany

Twierdzenie spektralne dla $\Sigma = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$ można rozpisać jako:

$$\Sigma = \sum_{i=1}^5 \lambda_i \mathbf{v}_i \mathbf{v}_i^T = \underbrace{\lambda_1 \mathbf{v}_1 \mathbf{v}_1^T}_{\text{główny wspólny rynek}} + \underbrace{\lambda_2 \mathbf{v}_2 \mathbf{v}_2^T}_{\text{najważniejsza poprawka}} + \underbrace{\lambda_3 \mathbf{v}_3 \mathbf{v}_3^T + \dots}_{\text{drobne korekty}}.$$

Każdy składnik $\lambda_i \mathbf{v}_i \mathbf{v}_i^T$

- Jest macierzą **rzędu 1**.
- $\mathbf{v}_i$ daje **kierunek** czynnika.
- λ_i daje **wagę** (siłę) czynnika.
- $\mathbf{v}_i \mathbf{v}_i^T$ buduje wzorzec współzależności wyłącznie wzdłuż $\mathbf{v}_i$.

Aproksymacja rzędu k

Zachowujemy tylko k największych składników:

$$\Sigma^{(k)} = \sum_{i=1}^k \lambda_i \mathbf{v}_i \mathbf{v}_i^T.$$

Jest to **najlepsza** aproksymacja Σ macierzą rzędu $\leq k$ w normie Frobeniusa (tw. Eckarta-Younga).

Idea dla naszej macierzy (λ_1 dominuje)

$$\Sigma = \begin{pmatrix} 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \end{pmatrix} \quad \Sigma^{(1)} = \begin{pmatrix} 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \\ 0.144 & 0.144 & 0.144 & 0.144 & 0.144 \end{pmatrix}$$

Krok 1 – iloczyn zewnętrzny $\mathbf{v}_1 \mathbf{v}_1^T$

Wyjście: wektor własny $\mathbf{v}_1$ (kolumna portfela czynnikowego PC1)

$$\mathbf{v}_1 \approx \begin{bmatrix} 0.486 \\ 0.467 \\ 0.437 \\ 0.296 \\ 0.517 \end{bmatrix}.$$

Iloczyn zewnętrzny $\mathbf{v}_1 \mathbf{v}_1^T$ – macierz wzajemnych ekspozycji

$$\mathbf{v}_1 \mathbf{v}_1^T = \begin{bmatrix} 0.236 & 0.227 & 0.213 & 0.144 & 0.251 \\ 0.227 & 0.218 & 0.204 & 0.138 & 0.241 \\ 0.213 & 0.204 & 0.191 & 0.129 & 0.226 \\ 0.144 & 0.138 & 0.129 & 0.088 & 0.153 \\ 0.251 & 0.241 & 0.226 & 0.153 & 0.267 \end{bmatrix}.$$

Krok 2 – pierwszy składnik $\lambda_1 \mathbf{v}_1 \mathbf{v}_1^T = \Sigma^{(1)}$

Mnożymy przez $\lambda_1 \approx 0.144$

$$\Sigma^{(1)} = \lambda_1 \mathbf{v}_1 \mathbf{v}_1^T \approx \begin{bmatrix} 0.0341 & 0.0327 & 0.0306 & 0.0207 & 0.0362 \\ 0.0327 & 0.0313 & 0.0294 & 0.0199 & 0.0347 \\ 0.0306 & 0.0294 & 0.0275 & 0.0186 & 0.0325 \\ 0.0207 & 0.0199 & 0.0186 & 0.0126 & 0.0220 \\ 0.0362 & 0.0347 & 0.0325 & 0.0220 & 0.0385 \end{bmatrix}.$$

Co już jest dobrze?

- Blok aktywów 1,2,3,5: kowariancje dobrze oddane.
- Ogólna **struktura** „wszyscy idą razem” zachowana.
- $\text{tr}(\Sigma^{(1)}) = \lambda_1 \approx 0.144$ (78.7% śladu Σ).

Co jest błędne?

Element (4, 4): aproksymacja daje 0.0126, oryginał: **0.025**. Aktywum 4 jest **ponad dwukrotnie zaniżone** – brakuje jego specyficznego ryzyka defensywnego. PC1 nie jest w stanie sam tego oddać.

Krok 3 – iloczyn zewnętrzny $\mathbf{v}_2 \mathbf{v}_2^T$ (poprawka sektorowa)

Wektor własny $\mathbf{v}_2$ (PC2 – kontrast defensywne vs. reszta)

$$\mathbf{v}_2 \approx \begin{bmatrix} +0.265 \\ +0.274 \\ -0.370 \\ -0.801 \\ +0.275 \end{bmatrix}.$$

Iloczyn zewnętrzny $\mathbf{v}_2 \mathbf{v}_2^T$

$$\mathbf{v}_2 \mathbf{v}_2^T \approx \begin{bmatrix} +0.0703 & +0.0727 & -0.0980 & -0.2125 & +0.0729 \\ +0.0727 & +0.0752 & -0.1014 & -0.2198 & +0.0754 \\ -0.0980 & -0.1014 & +0.1368 & +0.2964 & -0.1017 \\ -0.2125 & -0.2198 & +0.2964 & +\mathbf{0.6422} & -0.2205 \\ +0.0729 & +0.0754 & -0.1017 & -0.2205 & +0.0756 \end{bmatrix}.$$

Kluczowa obserwacja: element $(4, 4) = 0.6422$!

Krok 4 – drugi składnik $\lambda_2 \mathbf{v}_2 \mathbf{v}_2^T$

Mnożymy przez $\lambda_2 \approx 0.01594$

$$\lambda_2 \mathbf{v}_2 \mathbf{v}_2^T \approx \begin{bmatrix} +0.0011 & +0.0012 & -0.0016 & -0.0034 & +0.0012 \\ +0.0012 & +0.0012 & -0.0016 & -0.0035 & +0.0012 \\ -0.0016 & -0.0016 & +0.0022 & +0.0047 & -0.0016 \\ -0.0034 & -0.0035 & +0.0047 & +\mathbf{0.0102} & -0.0035 \\ +0.0012 & +0.0012 & -0.0016 & -0.0035 & +0.0012 \end{bmatrix}.$$

Co robi ten składnik?

- Element (4,4): dodaje +0.0102 do aproksymacji.
- Element (3,4) i (4,3): dodaje +0.0047 – poprawia relację A3–A4.
- Elementy (1,4), (2,4), (5,4): **ujemne** korekty – wzmacnia kontrast.
- Pozostałe elementy: mała korekta.

Efekt netto

PC2 to precyzyjna „chirurgiczna poprawka” skupiona na aktywie 4 i jego relacjach. Dlatego po dodaniu PC2 aktywum defensywne jest znacznie lepiej odwzorowane.

Krok 5 – suma $\Sigma^{(2)} = \lambda_1 \mathbf{v}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{v}_2 \mathbf{v}_2^T$

Aproksymacja rzędu 2

$$\Sigma^{(2)} \approx \begin{bmatrix} 0.0352 & 0.0338 & 0.0291 & 0.0174 & 0.0374 \\ 0.0338 & 0.0325 & 0.0277 & 0.0164 & 0.0359 \\ 0.0291 & 0.0277 & 0.0297 & 0.0234 & 0.0309 \\ 0.0174 & 0.0164 & 0.0234 & \mathbf{0.0229} & 0.0185 \\ 0.0374 & 0.0359 & 0.0309 & 0.0185 & 0.0397 \end{bmatrix}.$$

Oryginalna Σ (dla porównania)

$$\Sigma = \begin{bmatrix} 0.040 & 0.032 & 0.028 & 0.018 & 0.035 \\ 0.032 & 0.038 & 0.027 & 0.017 & 0.033 \\ 0.028 & 0.027 & 0.035 & 0.020 & 0.030 \\ 0.018 & 0.017 & 0.020 & \mathbf{0.025} & 0.019 \\ 0.035 & 0.033 & 0.030 & 0.019 & 0.045 \end{bmatrix}.$$

Bilans: co dwa czynniki poprawiły

Element	$\Sigma^{(1)}$	$\Sigma^{(2)}$	Oryginał
(4, 4) wariancja A4	0.0126	0.0229	0.025
(3, 4) kowariancja A3–A4	0.0186	0.0234	0.020
(1, 4) kowariancja A1–A4	0.0207	0.0174	0.018

PC1 niedoszacowuje ryzyko A4; PC2

większość tego błędu naprawia. Dwa składniki dają 92% wariancji.

Podsumowanie: low-rank approximation jako model czynnikowy

Trzy poziomy opisu macierzy ryzyka

$$\Sigma = \underbrace{\lambda_1 \mathbf{v}_1 \mathbf{v}_1^T}_{\substack{\text{rząd 1} \\ 78.7\% \\ \text{market mode}}} + \underbrace{\lambda_2 \mathbf{v}_2 \mathbf{v}_2^T}_{\substack{\text{rząd 1} \\ 8.7\% \\ \text{defensywne vs reszta}}} + \underbrace{\lambda_3 \mathbf{v}_3 \mathbf{v}_3^T + \lambda_4 \mathbf{v}_4 \mathbf{v}_4^T + \lambda_5 \mathbf{v}_5 \mathbf{v}_5^T}_{\substack{\text{razem 8.1\%} \\ \text{drobne korekty i szum}}}.$$

W języku quant finance

- $\Sigma^{(1)}$ = model **jednoczynnikowy** (CAPM-like): jedno ryzyko rynkowe.
- $\Sigma^{(2)}$ = model **dwuczynnikowy**: rynek + efekt defensywny.
- $\Sigma^{(k)}$ = **k -czynnikowy model ryzyka**.
- Pełna Σ = model ze wszystkimi N czynnikami.

Dlaczego to ważne w praktyce?

- $\Sigma^{(k)}$ jest **stabilniejsza** numerycznie (κ jest mała).
- Lepsza **generalizacja poza próbą** niż pełna Σ .
- Optymalizacja portfela na $\Sigma^{(k)}$: **mniej szumu**, rozsądniejsze wagi Markowitza.
- W limicie $k = N$: odtwarzamy pełne Σ bez straty.

Kluczowy wniosek

PCA nie tylko **analizuje** strukturę ryzyka – pozwala ją **odbudować selektywnie**, zachowując tylko te

Twierdzenie spektralne a optymalizacja portfela

Kluczowy wzór: ryzyko w bazie własnej

Jeśli $\Sigma = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$ i zdefiniujemy $\mathbf{y} = \mathbf{Q}^T\mathbf{w}$ (wagi w bazie wektorów własnych), to:

$$\mathbf{w}^T \Sigma \mathbf{w} = \mathbf{y}^T \mathbf{\Lambda} \mathbf{y} = \sum_{i=1}^N \lambda_i y_i^2.$$

Co to oznacza?

W bazie wektorów własnych ryzyko portfela **rozpada się na sumę niezależnych wkładów**. Każdy kierunek ryzyka ma „cenę” λ_i i ekspozycję y_i .

Duże λ_i = kosztowny kierunek

$y_i^2 \lambda_i$ to ryzyko w i -tym kierunku. Optymalizacja portfela: **minimalizuj ekspozycję** y_i na duże λ_i . Ekspozycje na kierunki o małych λ_i generują relatywnie mniejszy koszt ryzyka – ta sama wartość y_i^2 kosztuje mniej wariancji niż na kierunkach z dużymi λ_i .

Wniosek dla algo

Diagonalizacja macierzy kowariancji **upraszcza problem optymalizacji** – zamiast kwadratowego programowania z pełną macierzą Σ , pracujemy ze skalarnymi wkładami $\lambda_i y_i^2$. To jest fundament

PCA na kowariancji czy na korelacji? – ważny wybór praktyczny

Problem: aktywa o różnych skalach zmienności

Jeśli aktywum A ma $\sigma_A = 30\%$ rocznej zmienności, a aktywum B ma $\sigma_B = 5\%$, to PCA na Σ może być **zdominowane przez aktywum A** – niezależnie od struktury korelacji.

PCA na macierzy kowariancji Σ

- Faworyzuje aktywa o **dużej bezwzględnej zmienności**.
- Naturalne dla **analizy absolutnego ryzyka** portfela.
- PC1 może być silnie zdominowany przez najbardziej zmienne aktywa, zamiast czysto odzwierciedlać wspólny czynnik rynku.

PCA na macierzy korelacji C

- Równoważy skale: każde aktywum ma $\sigma = 1$ po standaryzacji.
- Naturalne dla **analizy struktury współruchu**.
- Odpowiada PCA po standaryzacji kolumn danych.

Związek formalny

Jeśli $D = \text{diag}(\sigma_1, \dots, \sigma_N)$, to $C = D^{-1}\Sigma D^{-1}$. PCA na $C = \text{PCA na } \Sigma$ po **standaryzacji** do jednostkowej zmienności.

Reguła praktyczna

Kiedy PCA może być mylące?

Pułapki stosowania PCA w finansach

- 1 **Niestabilność przy krótkiej historii:** Σ estymowana z $T = 60$ dni dla $N = 100$ akcji jest bardzo zaszumiona; kierunki własne mogą się znacznie zmieniać.
- 2 **Szum estymacji małych eigenvalues:** małe λ_i są numerycznie niestabilne i nie powinny być interpretowane jako sygnał.
- 3 **Niejednoznaczność interpretacji:** matematyka daje osie, nie etykiety finansowe. Różne okresy dają różną interpretację tych samych komponentów.
- 4 **Zmienność w czasie:** czynniki ryzyka ewoluują; PCA na oknie 2019–2020 wygląda inaczej niż na oknie 2021–2022.
- 5 **Brak kauzalności:** PCA to opis wariancji, nie model ekonomiczny.
- 6 **Problem $N \approx T$:** gdy liczba aktywów N jest porównywalna z długością historii T , estymacja Σ staje się niestabilna i wymaga regularyzacji (np. *shrinkage* Ledoita-Wolfa lub innych estymatorów regularyzowanych).

Reguła praktyczna

Im dłuższa historia, im mniej aktywów i im bardziej stacjonarny rynek – tym stabilniejsze i bardziej interpretowalne PCA. Dla $N \sim T$ stosuj shrinkage; dla $N > T$ macierz Σ jest osobliwa i PCA na surowej kowariancji jest niezgodne.

Kłątwa wymiarowości i Random Matrix Theory

Problem: $N \gg T$ w algo-tradingu

Mamy N aktywów i T dni obserwacji. Jeśli $N > T$: macierz $\Sigma \in \mathbb{R}^{N \times N}$ ma co najwyżej $T - 1$ niezerowych wartości własnych – jest **osobliwa z definicji**.

$\text{rank}(\Sigma) \leq T - 1 < N \implies$ co najmniej $N - T + 1$ zerowych wartości własnych.

Konsekwencja dla PCA

Wiele wartości własnych blisko zera to **nie sygnał** – to artefakt małej próbki. PCA “widzi” fałszywe korelacje wynikające z przypadkowego szumu estymacji, nie z prawdziwej struktury rynku.

Random Matrix Theory (RMT)

Dla macierzy zwrotów z **czystego szumu** ($N, T \rightarrow \infty$, $c = N/T$ stałe) wartości własne mają rozkład **Marchenko-Pastura**:


$$\lambda^{\pm} = \sigma^2 (1 \pm \sqrt{c})^2.$$

Wartości własne w przedziale $[\lambda^-, \lambda^+]$ to **szum**.
Wartości własne **powyżej** λ^+ to potencjalny sygnał.

Praktyczne zastosowanie RMT w finansach

- Wyrzucić wartości własne $\lambda_i \leq \lambda^+$ – zastąp je wartością σ^2 (“denoising”).

Geometria ryzyka – elipsoida rozrzutu stóp zwrotu



Elipsoida stóp zwrotu 2 aktywów

Kluczowe elementy elipsoidy

- **Osie elipsoidy** = wektory własne v_i macierzy Σ .
- **Długości półosi** = $\sqrt{\lambda_i}$ = odchylenia standardowe wzdłuż głównych kierunków.
- **Orientacja** = struktura korelacji portfela.

Co widzimy?

- **Długa oś (PC1)**: kierunek dominującego wspólnego ryzyka – np. market mode.
- **Krótka oś (PC2)**: kierunek o małej wariancji – np. spread sektorowy.
- Im bardziej **wydłużona** elipsoida, tym bardziej zdominowany przez jeden czynnik rynek.
- Kryzys: elipsoida “wyciąga się” wzdłuż PC1 (koncentracja ryzyka).

Co analityk danych powinien wynieść z sekcji PCA?

Sześć kluczowych punktów

- 1 Macierz kowariancji Σ jest **obiektem geometrycznym** – twierdzenie spektralne daje jej naturalne osie.
- 2 Wartości własne λ_i mierzą **siłę ryzyka** wzdłuż i -tego czynnika.
- 3 PCA **porządkuje ryzyko od największego do najmniejszego**.
- 4 Duże λ_i ujawniają **dominujące siły rynku**.
- 5 Wzór $w^T \Sigma w = \sum_i \lambda_i y_i^2$ **upraszcza analizę ryzyka portfela**.
- 6 Małe λ_i to potencjalny szum – **nie estymuj na nich modelu**.

Przejdźcie do SVD

PCA działa świetnie na macierzy kowariancji (symetrycznej). Ale co jeśli mamy prostokątną macierz danych – np. ekspozycje $T \times N$ – i chcemy wykryć ukrytą strukturę? Potrzebujemy **SVD** – uogólnienia twierdzenia spektralnego na dowolne macierze.

Geometria Ryzyka

Zastosowania Twierdzenia Spektralnego oraz PCA w Ocenie Ryzyka

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

30 marca 2026