

Prawdopodobieństwo i momenty

Fundament pod regresję, ARIMA, GARCH i później MLE

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

13 kwietnia 2026

Blok: Probabilistka i momenty

Przypomnienie podstawowych pojęć z rachunku
prawdopodobieństwa, statystyki i szeregów czasowych

Trzy bazowe zbiory danych

Główny cel Bloku Probabilistka i momenty

Co student ma zrozumieć po tym bloku?

- czym jest **eksperyment losowy**, **zdarzenie** i **zmienna losowa**,
- jak opisywać dane przez **rozkład** i **momenty**,
- jak odróżnić **poziom** od **zmienności**,
- czym są **estymatory**, **przedziały ufności** i **testy hipotez**,
- dlaczego **stacjonarność** jest warunkiem sensownego modelowania szeregów,
- czym są **warunkowa wartość oczekiwana** i **warunkowa wariancja**.

Najważniejszy pomost do dalszego kursu

Modelowanie szeregu czasowego to nie tylko prognoza przyszłej wartości, lecz także **prognoza niepewności tej wartości**. To prowadzi bezpośrednio do:

ARIMA przez $\mathbb{E}(X_{t+1} \mid \mathcal{F}_t)$, GARCH przez $\text{Var}(X_{t+1} \mid \mathcal{F}_t)$.

Trzy bazowe przykłady prowadzące

Przykład	Dane	Rola dydaktyczna
Moneta	4 rzuty: H, T, H, H	najprostszy model przestrzeni probabilistycznej, rozkładu Bernoulliego, testu $H_0 : p = 0.5$, intuicji CLT
Spółka Alfa	10 log-zwrotów	główny przykład kursu: średnia, wariancja, ciężkie ogony, stacjonarność, ACF/PACF, warunkowa średnia i warunkowa wariancja
Stacja Olsztyn	10 temperatur / anomalii	intuicyjne wejście do zmiennej ciągłej, trendu, sezonowości i prognozy

Idea dydaktyczna

Badamy cały czas **te same trzy światy danych**, ale opisywane coraz dojrzalszym językiem: logika → prawdopodobieństwo → statystyka → diagnostyka → modele czasowe.

Dwa stałe przykłady danych: Spółka Alfa i Olsztyn

Spółka Alfa – 10 dziennych log-zwrotów

Data	Log-zwrot
01.03.2026	0.012
02.03.2026	-0.008
03.03.2026	0.004
04.03.2026	-0.015
05.03.2026	0.020
06.03.2026	-0.006
07.03.2026	0.003
08.03.2026	-0.011
09.03.2026	0.007
10.03.2026	-0.002

Olsztyn – 10 kolejnych pomiarów temperatury

Data	Temperatura
01.03.2026	-1.2 °C
02.03.2026	-0.4 °C
03.03.2026	0.3 °C
04.03.2026	1.1 °C
05.03.2026	0.5 °C
06.03.2026	-0.2 °C
07.03.2026	0.8 °C
08.03.2026	1.4 °C
09.03.2026	0.6 °C
10.03.2026	-0.1 °C

Pierwsze statystyki opisowe dla obu przykładów

Spółka Alfa – statystyki dla 10 log-zwrotów

$$\bar{r} = \frac{1}{10} \sum_{t=1}^{10} r_t = 0.0004$$

$$s_r^2 = \frac{1}{9} \sum_{t=1}^{10} (r_t - \bar{r})^2 \approx 0.000125$$

Statystyka	Wartość
Średnia $\bar{r}$	0.0004
Wariancja s_r^2	0.000125
Minimum	-0.015
Maksimum	0.020

Olsztyn – statystyki dla 10 temperatur

$$\bar{T} = \frac{1}{10} \sum_{t=1}^{10} T_t = 0.28$$

$$s_T^2 = \frac{1}{9} \sum_{t=1}^{10} (T_t - \bar{T})^2 \approx 0.6929$$

Statystyka	Wartość
Średnia $\bar{T}$	0.28 °C
Wariancja s_T^2	0.6929
Minimum	-1.2 °C
Maksimum	1.4 °C

Pierwsze statystyki opisowe dla obu przykładów


Pierwszy wniosek

Dla Spółki Alfa średnia jest bardzo bliska zeru, natomiast interesująca jest skala wahań.


Dla temperatury średnia ma bezpośrednią interpretację fizyczną, a wariancja opisuje naturalne rozproszenie pomiarów wokół tej średniej.

Porównanie rozkładów: log-zwroty i temperatury

Spółka Alfa – szkic histogramu log-zwrotów



Olsztyn – szkic histogramu temperatur




Porównanie rozkładów: log-zwroty i temperatury

Prosta interpretacja porównawcza


- **Log-zwroty Spółki Alfa** są skupione blisko zera, z niewielkimi dodatnimi i ujemnymi odchyleniami.
- **Temperatury w Olsztynie** mają bardziej bezpośrednią interpretację fizyczną i naturalnie grupują się wokół dodatnich wartości bliskich $0-1^{\circ}\text{C}$.
- Już na tym etapie widać, że **średnia** i **wariancja** będą miały inny sens interpretacyjny w danych finansowych niż w danych środowiskowych.

Dwa szeregi czasowe: log-zwroty i temperatury

Spółka Alfa – 10 dziennych log-zwrotów



Olsztyn – 10 kolejnych pomiarów temperatury



Pierwsze intuicje

- **Log-zwroty** oscylują wokół zera i przypominają serię małych dodatnich i ujemnych szoków.
- **Temperatury** mają bardziej bezpośredni poziom fizyczny i łatwiej interpretować ich średnią.
- W analizie szeregów czasowych interesuje nas nie tylko rozkład wartości, ale i **ich kolejność w czasie**.

Od wykresu do pojęć: trend, zmienność i pierwsza intuicja stacjonarności

Spółka Alfa – jak czytać ten wykres?

- **Brak wyraźnego trendu:** dane oscylują wokół poziomu bliskiego zeru.
- **Zmienność:** obserwujemy naprzemienne dodatnie i ujemne odchylenia.
- **Pierwsza intuicja stacjonarności:**
 - średnia wydaje się w przybliżeniu stała,
 - amplituda wahań nie zmienia się dramatycznie,
 - nie widać systematycznego wzrostu ani spadku.

Olsztyn – jak czytać ten wykres?

- **Możliwy lokalny trend:** temperatury rosną w pierwszej części szeregu.
- **Zmienność:** obserwujemy wahania wokół zmieniającego się poziomu.
- **Pierwsza intuicja niestacjonarności:**
 - poziom szeregu nie wydaje się całkiem stały,
 - dane mogą zawierać komponent trendu,
 - interpretacja zależy od tego, czy analizujemy temperaturę surową czy anomalię.


Od wykresu do pojęć: trend, zmienność i pierwsza intuicja stacjonarności

Najważniejsze intuicje

- **Trend** oznacza, że średni poziom szeregu zmienia się w czasie.
- **Brak trendu** oznacza, że dane oscylują wokół w przybliżeniu stałego poziomu.
- **Zmienność** opisuje skalę wahań wokół tego poziomu.
- **Intuicja stacjonarności:** szereg wygląda podobnie w różnych fragmentach czasu – nie zmienia wyraźnie średniej ani skali wahań.


Trzy typowe sytuacje w analizie szeregów czasowych: wzorce często obserwowane w lokalnych oknach czasowych

1. Szereg stacjonarny




- brak wyraźnego trendu,
- podobna skala wahań,
- średnia w przybliżeniu stała.

2. Szereg z trendem



- średni poziom rośnie,
- zmienia się położenie szeregu,
- sygnał niestacjonarności.

3. Szereg ze zmienną wariancją



- średnia może być stała,
- rośnie amplituda wahań,
- ważny sygnał dla GARCH.

Trzy typowe sytuacje w analizie szeregów czasowych: wzorce często obserwowane w lokalnych oknach czasowych

Najważniejsza intuicja dla ustalonego lokalnego okna czasowego

- **Stacjonarność** oznacza, że szereg zachowuje się podobnie w różnych fragmentach czasu.
- **Trend** narusza stałość średniego poziomu.
- **Zmienna wariancja** narusza stałość skali wahań.
- Właśnie dlatego przed budową modelu pytamy: *czy szereg jest wystarczająco stacjonarny dla wybranego narzędzia?*

ADF i KPSS jako podstawowe testy stacjonarności szeregów czasowych

Metafora informatyczna

Zanim wdrożymy model ARIMA lub inny model szeregu czasowego, warto uruchomić **podstawowe testy jakości danych**. ADF i KPSS można traktować jak **unit testy dla stacjonarności**.

Test	Hipoteza zerowa H_0	Co to oznacza praktycznie?
ADF	szereg ma pierwiastek jednostkowy , czyli jest niestacjonarny	małe p-value wspiera tezę, że szereg jest bardziej zgodny ze stacjonarnością niż z niestacjonarnością
KPSS	szereg jest stacjonarny	małe p-value wspiera tezę, że dane są raczej niestacjonarne niż stacjonarne

ADF i KPSS jako podstawowe testy stacjonarności szeregów czasowych


Jak interpretować oba testy razem?

Wynik ADF	Wynik KPSS	Wniosek roboczy
odrzucaamy H_0	nie odrzucaamy H_0	mocny sygnał stacjonarności
nie odrzucaamy H_0	odrzucaamy H_0	mocny sygnał niestacjonarności
oba niejednoznaczne	oba niejednoznaczne	potrzebna ostrożność: wykres, wiedza domenowa i dalsza diagnostyka

Najważniejsza uwaga

ADF i KPSS nie są wyroczniami. Są bardzo użytecznymi testami pomocniczymi, ale zawsze powinny być czytane razem z wykresem szeregu, znajomością danych i celem modelowania.

Co robić dalej, gdy ADF/KPSS sugerują niestacjonarność?



Co robić dalej, gdy ADF/KPSS sugerują niestacjonarność?

Interpretacja dydaktyczna

- Jeśli problemem jest **trend**, często pomaga różnicowanie lub usunięcie komponentu deterministycznego.
- Jeśli problemem jest **sezonowość**, trzeba uwzględnić strukturę kalendarzową lub różnicowanie sezonowe.
- Jeśli średnia wygląda już stabilnie, ale amplituda wahań nadal się zmienia, to wchodzimy w temat **zmienności warunkowej** i modeli typu ARCH/GARCH.

Przestrzeń probabilistyczna i zmienne losowe

Eksperyment losowy i przestrzeń probabilistyczna

Formalnie

Przestrzeń probabilistyczna ma postać

$$(\Omega, \mathcal{F}, \mathbb{P}),$$

gdzie:

- Ω – zbiór wszystkich możliwych wyników,
- $\mathcal{F}$ – rodzina zdarzeń, o których umiemy sensownie mówić,
- $\mathbb{P}$ – miara prawdopodobieństwa.

Intuicja

Ω to “świat możliwych historii”, $\mathcal{F}$ to “pytania, które wolno zadać”, a $\mathbb{P}$ mówi, jak bardzo każda historia lub zdarzenie jest wiarygodne.

Przykład A: 4 rzuty monetą

$$\Omega = \{HHHH, HHHT, HHTH, \dots, TTTT\}, \quad |\Omega| = 2^4 = 16.$$

Przykładowe zdarzenia

- A : w pierwszym rzucie wypadł orzeł,
- B : dokładnie dwa orły,
- C : ostatnie dwa rzuty są takie same.

Pierwsza obserwacja

Zdarzenie jest jednocześnie:

- **zbiorem** wyników,
- **zdaniem logicznym** o wyniku eksperymentu.

Pomost

To, co tutaj jest prostą monetą, później stanie się opisem:

- zwrotu giełdowego,
- temperatury,
- reszty modelu ARIMA lub GARCH.

Zdarzenia elementarne i nieelementarne: 4 rzuty monetą

Przestrzeń wyników

Rozważamy eksperyment polegający na wykonaniu **4 kolejnych rzutów monetą**. Wtedy naturalna przestrzeń wyników ma postać

$$\Omega = \{H, T\}^4.$$

Każdy wynik elementarny jest więc **pełną trajektorią 4 rzutów**, np.

$$\omega = (H, T, H, H).$$

Zdarzenie elementarne

Przykład:

$$\omega = (H, T, H, H).$$

Możemy też zapisać:

$$\{\omega\} = \{(H, T, H, H)\}.$$

To jest **jeden konkretny pełny przebieg** czterech rzutów.

Zdarzenie nieelementarne

Niech R_i oznacza wynik i -tego rzutu.

Przykład:

$$\{R_1 = H\}.$$

To zdarzenie zawiera wiele trajektori:

$$(H, H, H, H), (H, H, H, T), \dots, (H, T, T, T).$$

Zatem $\{R_1 = H\}$ jest **zdarzeniem nieelementarnym**.

Zdarzenia elementarne dla dwóch bazowych zbiorów danych

Spółka Alfa – pełna trajektoria

Niech

$$\omega_R = (R_1, R_2, \dots, R_{10})$$

oznacza pełną trajektorię 10 log-zwrotów.

Przykład zdarzenia elementarnego:

$$\omega_R = (0.012, -0.008, 0.004, -0.015, 0.020, \\ -0.006, 0.003, -0.011, 0.007, -0.002).$$

To jest **jeden konkretny pełny przebieg** szeregu w 10 kolejnych dniach.

Olsztyn – pełna trajektoria

Niech

$$\omega_T = (T_1, T_2, \dots, T_{10})$$

oznacza pełną trajektorię 10 temperatur.

Przykład zdarzenia elementarnego:

$$\omega_T = (-1.2, -0.4, 0.3, 1.1, 0.5, \\ -0.2, 0.8, 1.4, 0.6, -0.1).$$

To jest **jeden konkretny pełny przebieg** temperatur w 10 kolejnych dniach.

Najważniejsza intuicja

Jeśli całym eksperymentem jest obserwacja **całego szeregu**, to **zdarzenie elementarne** odpowiada jednej pełnej trajektorii. Natomiast warunki typu

$$R_1 > 0, \quad T_4 \in [1, 2), \quad R_1 > 0 \cap R_2 < 0$$

opisują już **zdarzenia nieelementarne**.

Przykłady zdarzeń nieelementarnych dla dwóch bazowych zbiorów danych

Spółka Alfa

$R_t = \text{log-zwrot w dniu } t$

- $\{R_1 \in [0.01, 0.02)\}$ – umiarkowany wzrost
- $\{R_2 < 0\}$ – dzień spadkowy
- $\{R_1 > 0\} \cap \{R_2 < 0\}$ – wzrost, potem spadek
- $\{R_4 \leq -0.01\} \cup \{R_5 \geq 0.015\}$ – silniejszy ruch

Olsztyn

$T_t = \text{temperatura w dniu } t$

- $\{T_1 \in [-2, 0)\}$ – temperatura ujemna
- $\{T_4 \in [1, 2)\}$ – wyraźnie dodatnia
- $\{T_5 > 0\} \cap \{T_6 < 0\}$ – dodatnia, potem ujemna
- $\{T_1 < 0\} \cap \{T_2 < 0\} \cap \{T_3 \geq 0\}$ – przejście przez zero

Intuicja

Zdarzenia nieelementarne opisujemy przez **przedziały**, **nierówności** i operacje logiczne:

$$A \cap B, \quad A \cup B, \quad A^c, \quad A \Rightarrow B.$$

Zdarzenia elementarne dla dwóch bazowych zbiorów danych

Najważniejsza intuicja

Zdarzenie nieelementarne można opisać przez **przedziały**, **nierówności** oraz operacje logiczno-teoriomnogościowe:

$$A \cap B, \quad A \cup B, \quad A^c, \quad A \Rightarrow B.$$

Przyjmujemy również domknięcie rozważanej rodziny zdarzeń względem **przeliczalnych sum i iloczynów teoriomnogościowych**, co pozwala opisywać także bardziej złożone zdarzenia oraz ich aproksymacje za pomocą ciągów zbiorów.

Algebra Boole'a zdarzeń


Operacje na zdarzeniach

$$A \cup B, \quad A \cap B, \quad A^c$$

- $A \cup B$: zajdzie A lub B ,
- $A \cap B$: zajdą oba,
- A^c : A nie zajdzie.

Prawa de Morgana

$$(A \cup B)^c = A^c \cap B^c, \quad (A \cap B)^c = A^c \cup B^c.$$



Zdarzenia można analizować tak samo jak wyrażenia logiczne.

Zmienna losowa: od wyniku do liczby

Definicja intuicyjna

Zmienna losowa to funkcja

$$X : \Omega \rightarrow \mathbb{R},$$

która każdemu wynikowi eksperymentu przypisuje liczbę.

Moneta

Możemy zdefiniować:

X = liczba orłów w 4 rzutach.

Wtedy $X \in \{0, 1, 2, 3, 4\}$.

Spółka Alfa / Stacja Olsztyn

X_t = log-zwrot w dniu t

albo

X_t = temperatura w dniu t .

To już naturalne przykłady zmiennych ciągłych.

Rozkład zmiennej losowej

Dwa poziomy opisu

- **Rozkład teoretyczny:** jak zachowywałaby się zmienna w idealnym modelu.
- **Rozkład empiryczny:** jak wyglądają faktycznie zebrane dane.

Pytania, które zadajemy rozkładowi

- gdzie jest środek rozkładu?
- jak bardzo dane się rozpraszają?
- czy rozkład jest symetryczny?
- czy ma grube ogony?

Dlaczego to ważne?

ARIMA opisuje głównie **średnią warunkową**, a GARCH opisuje głównie **wariancję warunkową**. Bez dobrego rozumienia rozkładu trudno rozumieć oba modele.

Moment pierwszy i drugi: średnia oraz wariancja

Wartość oczekiwana

$$\mathbb{E}(X)$$

to długookresowy środek rozkładu.

Dla Bernoulliego:

$$\mathbb{E}(X) = p.$$

Wariancja

$$\text{Var}(X) = \mathbb{E}((X - \mathbb{E} X)^2)$$

mierzy skalę rozproszenia.

Dla Bernoulliego:

$$\text{Var}(X) = p(1 - p).$$

W praktyce

W danych finansowych średnia dziennego log-zwrotu bywa mała i trudna do oszacowania.

W praktyce

W finansach to właśnie **zmiennność** jest często bardziej przewidywalna niż sama średnia.

Moment trzeci i czwarty: skośność oraz kurtoza

Pojęcie	Intuicja	Znaczenie praktyczne
Skośność	czy rozkład ma dłuższy ogon z lewej lub prawej strony	pomaga odróżnić rozkłady symetryczne od asymetrycznych
Kurtoza	jak często pojawiają się obserwacje ekstremalne	w finansach wysoka kurtoza ostrzega, że normalność może być zbyt optymistyczna

Bardzo ważna intuicja dla finansów

Dwa zbiory danych mogą mieć podobną średnią i wariancję, a mimo to bardzo różnić się ryzykiem ekstremalnych ruchów. To właśnie sygnalizują **skośność** i **kurtoza**.

Estymatory skośności i kurtozy

Krok 1: średnia i odchylenie standardowe z próby

Dla próby $x_1, \dots, x_n$ liczymy:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Krok 2: estymator skośności

Jednym z najczęściej używanych estymatorów skośności jest:

$$\widehat{\text{Skew}} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^{3/2}}.$$

- wartość dodatnia: dłuższy prawy ogon,
- wartość ujemna: dłuższy lewy ogon,
- wartość bliska 0: rozkład w przybliżeniu symetryczny.

Krok 3: estymator kurtozy nadmiarowej

Estymator kurtozy nadmiarowej:

$$\widehat{\text{Kurt}} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2} - 3.$$

- wartość dodatnia: cięższe ogony niż w rozkładzie normalnym,
- wartość ujemna: ogony lżejsze / rozkład bardziej spłaszczony,
- wartość bliska 0: podobieństwo do normalności pod względem ogonów.

Estymatory skośności i kurtozy

Krok 1: średnia i odchylenie standardowe z próby

Dla próby $x_1, \dots, x_n$ liczymy:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Krok 2: estymator skośności

Jednym z najczęściej używanych estymatorów skośności jest:

$$\widehat{\text{Skew}} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^{3/2}}.$$

- wartość dodatnia: dłuższy prawy ogon,
- wartość ujemna: dłuższy lewy ogon,
- wartość bliska 0: rozkład w przybliżeniu symetryczny.

Krok 3: estymator kurtozy nadmiarowej

Skośność i kurtoza dla trzech bazowych przykładów

Przykład			Skośność	Kurtoza nadmiarowa	Pierwsza interpretacja
4 rzuty monetą (1, 0, 1, 1)			-1.155	-0.667	silna asymetria w lewo, mała próbka, wynik bardzo niestabilny
Spółka Alfa			0.312	-0.823	lekka asymetria prawostronna, brak sygnału ciężkich ogonów w tej małej próbce
Olsztyn			-0.401	-0.510	lekka asymetria lewostronna, rozkład dość łagodny i umiarkowanie spłaszczony

Uwaga praktyczna

Przy bardzo małych próbach estymatory skośności i kurtozy są **mało stabilne**. Dlatego wyniki trzeba traktować ostrożnie i zawsze oglądać także wykres danych.

Interpretacja wyników dla trzech bazowych przykładów

Moneta

- W próbie (1, 0, 1, 1) dominuje wartość 1.
- Stąd pojawia się **ujemna skośność**.
- To dobry przykład dydaktyczny, ale bardzo mała próba.
- Wniosek: liczby są łatwe do policzenia, ale statystycznie jeszcze słabe.

Spółka Alfa

- Skośność dodatnia jest niewielka.
- W tej mini-próbie nie widać jeszcze ciężkich ogonów.
- To ważna lekcja: **mała próbka może ukrywać ryzyko ekstremów**.
- W prawdziwych danych finansowych kurtoza bywa często dodatnia i większa.

Olsztyn

- Lekko ujemna skośność oznacza trochę dłuższy lewy ogon.
- Kurtoza bliska zera, lecz ujemna, sugeruje dość spokojny rozkład.
- To dobry kontrast wobec danych finansowych.
- Średnia i rozproszenie mają tu bardziej bezpośredni sens fizyczny.

Najważniejszy wniosek

Skośność i kurtoza pomagają opisać **kształt rozkładu**, ale w praktyce muszą być czytane razem z:

wykresem danych, wielkością próby, kontekstem dziedzinowym.

Przykłady dyskretnych rozkładów prawdopodobieństwa

Rozkład Bernoulliego

Definicja i wzór

Intuicja: model jednej próby z dwoma możliwymi wynikami: sukces lub porażka.

Parametr: $p \in [0, 1]$, gdzie

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Funkcja prawdopodobieństwa:

$$\mathbb{P}(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

Nośnik:

$$X \in \{0, 1\}.$$

Typowy przykład praktyczny

- orzeł / reszka,
- sukces / porażka,
- wzrost ceny / brak wzrostu w jednym dniu.

Podstawowe charakterystyki

$$\mathbb{E}(X) = p$$

$$\text{Var}(X) = p(1 - p)$$

$$\text{Skośność} = \frac{1 - 2p}{\sqrt{p(1 - p)}}$$

$$\text{Kurtoza nadmiarowa} = \frac{1 - 6p(1 - p)}{p(1 - p)}$$


Interpretacja

- $\mathbb{E}(X) = p$ to częstość sukcesu,
- wariancja jest największa przy $p = 0.5$,
- to najprostszy model losowości,
- bardzo ważny dla likelihood, MLE i cross-entropy.

Rozkład Bernoulliego – wykres funkcji prawdopodobieństwa

Parametr przykładowy

Przyjmujemy $p = 0.7$.



Interpretacja

Cała masa prawdopodobieństwa jest skupiona w dwóch punktach: 0 i 1.

Rozkład dwumianowy

Definicja i wzór

Intuicja: liczba sukcesów w n niezależnych próbach Bernoulliego.

Parametry: $n \in \mathbb{N}$, $p \in [0, 1]$.

Funkcja prawdopodobieństwa:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

Nośnik:

$$X \in \{0, 1, \dots, n\}.$$

Typowy przykład praktyczny

- liczba orłów w 4 rzutach,
- liczba dni wzrostowych w 10 sesjach,
- liczba poprawnych odpowiedzi w teście.

Podstawowe charakterystyki

$$\mathbb{E}(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

$$\text{Skośność} = \frac{1 - 2p}{\sqrt{np(1 - p)}}$$

$$\text{Kurtoza nadmiarowa} = \frac{1 - 6p(1 - p)}{np(1 - p)}$$


Interpretacja

- średnia to oczekiwana liczba sukcesów,
- wariancja rośnie z n , ale zależy też od p ,
- rozkład jest symetryczny dla $p = 0.5$,
- jest naturalnym mostem od Bernoulliego do CLT.

Rozkład dwumianowy – wykres funkcji prawdopodobieństwa

Parametry przykładowe

Przyjmujemy $n = 10$, $p = 0.4$.



Interpretacja

Najbardziej prawdopodobne są liczby sukcesów w pobliżu $np = 4$.

Rozkład Poissona

Definicja i wzór

Intuicja: liczba zdarzeń w jednostce czasu, przestrzeni lub objętości.

Parametr: $\lambda > 0$.

Funkcja prawdopodobieństwa:

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Nośnik:

$$X \in \{0, 1, 2, \dots\}.$$

Typowy przykład praktyczny

- liczba awarii w ciągu dnia,
- liczba zgłoszeń do systemu w godzinie,
- liczba transakcji w krótkim oknie czasu.

Podstawowe charakterystyki

$$\mathbb{E}(X) = \lambda$$

$$\text{Var}(X) = \lambda$$

$$\text{Skośność} = \frac{1}{\sqrt{\lambda}}$$

$$\text{Kurtoza nadmiarowa} = \frac{1}{\lambda}$$


Interpretacja

- średnia i wariancja są równe,
- dla małego λ rozkład jest bardziej asymetryczny,
- dla dużego λ przypomina coraz bardziej normalny,
- to podstawowy model danych zliczeniowych.

Rozkład Poissona – wykres funkcji prawdopodobieństwa

Parametr przykładowy

Przyjmujemy $\lambda = 3$.



Interpretacja

Dla $\lambda = 3$ największa masa skupia się wokół $k = 2, 3, 4$.

Rozkład ujemny dwumianowy

Definicja i wzór

Intuicja: modeluje liczbę porażek przed uzyskaniem r sukcesów.

Parametry:

$$r \in \mathbb{N}, \quad p \in (0, 1).$$

Gdzie p oznacza prawdopodobieństwo sukcesu.

Funkcja prawdopodobieństwa:

$$\mathbb{P}(X = k) = \binom{k+r-1}{k} (1-p)^k p^r, \quad k = 0, 1, 2, \dots$$

Nośnik:

$$X \in \{0, 1, 2, \dots\}.$$

Typowy przykład praktyczny

- liczba nieudanych prób przed uzyskaniem 3 trafień,
- liczba błędnych logowań przed określoną liczbą

Podstawowe charakterystyki

$$\mathbb{E}(X) = \frac{r(1-p)}{p}$$

$$\text{Var}(X) = \frac{r(1-p)}{p^2}$$

$$\text{Skośność} = \frac{2-p}{\sqrt{r(1-p)}}$$

$$\text{Kurtoza nadmiarowa} = \frac{6}{r} + \frac{p^2}{r(1-p)}$$


Interpretacja

- wariancja jest większa od średniej,
- rozkład bywa bardziej rozproszony niż Poisson,
- jest dobrym modelem przy **overdispersion**,
- ważny w praktyce analizy danych zliczeniowych.

Rozkład ujemny dwumianowy – wykres funkcji prawdopodobieństwa

Parametry przykładowe

Przyjmujemy $r = 3$, $p = 0.5$, gdzie X oznacza liczbę porażek przed uzyskaniem 3 sukcesów.



Interpretacja

Rozkład jest prawostronny: małe liczby porażek są najczęstsze, ale możliwy jest też długi prawy ogon.

Rozkład wielomianowy

Definicja i wzór

Intuicja: uogólnienie rozkładu dwumianowego na m kategorii.

Parametry:

$$n \in \mathbb{N}, \quad p_1, \dots, p_m \geq 0, \quad \sum_{i=1}^m p_i = 1.$$

Funkcja prawdopodobieństwa:

$$\mathbb{P}(X_1 = x_1, \dots, X_m = x_m) = \frac{n!}{x_1! \cdots x_m!} p_1^{x_1} \cdots p_m^{x_m},$$

gdy

$$x_1 + \cdots + x_m = n.$$

Typowy przykład praktyczny

- liczby odpowiedzi A/B/C/D w teście,
- licznosci klas w klasyfikacji wieloklasowej

Podstawowe charakterystyki

Dla każdej składowej:

$$\mathbb{E}(X_i) = np_i$$

$$\text{Var}(X_i) = np_i(1 - p_i)$$

$$\text{Cov}(X_i, X_j) = -np_i p_j, \quad i \neq j$$


Skośność i kurtozę analizujemy **komponentowo**, jak dla rozkładu dwumianowego każdej współrzędnej.

Interpretacja

- opisuje jednocześnie wiele kategorii,
- naturalny most do klasyfikacji wieloklasowej,
- bardzo ważny dla modeli kategoriycznych i cross-entropy.

Rozkład wielomianowy – reprezentacja funkcji prawdopodobieństwa

Przyjmujemy $n = 4$, $(p_1, p_2, p_3) = (0.5, 0.3, 0.2)$. Pokazujemy punkty (x_1, x_2) , gdzie $x_3 = 4 - x_1 - x_2 \geq 0$.



Interpretacja: Każdy punkt odpowiada jednej możliwej konfiguracji

$$(X_1, X_2, X_3), \quad X_3 = 4 - X_1 - X_2.$$

Podsumowanie: podstawowe rozkłady dyskretne

Rozkład	Nośnik	Parametry	Typowy przykład praktyczny
Bernoulliego	$\{0, 1\}$	p	sukces/porażka, orzeł/reszka, wzrost/spadek
Dwumianowy	$\{0, \dots, n\}$	n, p	liczba sukcesów w n próbach
Ujemny dwumianowy	$\{0, 1, 2, \dots\}$	r, p	liczba porażek przed uzyskaniem r sukcesów
Poissona	$\{0, 1, 2, \dots\}$	λ	liczba zdarzeń w jednostce czasu
Wielomianowy	$x_1 + \dots + x_m = n$	$n, p_1, \dots, p_m$	liczności wielu kategorii jednocześnie

Najważniejsza intuicja

Rozkłady dyskretne opisują sytuacje, w których możliwe wyniki tworzą zbiór **pojedynczych policzalnych wartości**: $0, 1, 2, \dots$ lub skończony zbiór kategorii.

Przykłady ciągłych rozkładów prawdopodobieństwa

Prawdopodobieństwo w przypadku dyskretnym a gęstość w ciągłym

Przypadek dyskretny

Dla zmiennej dyskretnej podajemy bezpośrednio **funkcję prawdopodobieństwa**:

$$p(x) = \mathbb{P}(X = x).$$

Wtedy dla konkretnej wartości x mamy od razu:

$$\mathbb{P}(X = x) = p(x).$$

Przykład: dla Bernoulliego

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Intuicja

W przypadku dyskretnym masa prawdopodobieństwa jest **skupiona w punktach**. Możemy więc sensownie pytać o prawdopodobieństwo pojedynczej wartości.

Przypadek ciągły

Dla zmiennej ciągłej używamy **funkcji gęstości**:

$$f(x).$$

Prawdopodobieństwo liczymy nie dla punktu, lecz dla przedziału:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx.$$

Dla pojedynczego punktu:


$$\mathbb{P}(X = x) = 0.$$

Intuicja

Gęstość nie jest sama w sobie prawdopodobieństwem punktu. Jest funkcją, której **pole pod wykresem** daje prawdopodobieństwo przedziału.

Dyskretne masy prawdopodobieństwa a ciągła gęstość


Rozkład dyskretny



$$\mathbb{P}(X = x) = p(x)$$

Prawdopodobieństwo jest skupione w punktach.

Rozkład ciągły



$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx$$

Prawdopodobieństwo odpowiada polu pod wykresem.

Dyskretne masy prawdopodobieństwa a ciągła gęstość

Najważniejsza różnica

W przypadku dyskretnym patrzymy na **wysokości słupków w punktach**, a w przypadku ciągłym na **pole pod krzywą gęstości na przedziale**.

Rozkład jednostajny ciągły

Definicja i wzór

Intuicja: każda wartość z przedziału $[a, b]$ jest jednakowo "gęsta".

Parametry:

$$a < b.$$

Gęstość:

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b], \\ 0, & \text{poza } [a, b]. \end{cases}$$

Nośnik:

$$X \in [a, b].$$

Typowy przykład praktyczny

- losowy moment czasu z przedziału,
- losowy punkt na odcinku,

Podstawowe charakterystyki

$$\mathbb{E}(X) = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

$$\text{Skośność} = 0$$

$$\text{Kurtoza nadmiarowa} = -\frac{6}{5}$$


Interpretacja

- rozkład jest symetryczny,
- nie ma ciężkich ogonów,
- to dobry model wtedy, gdy wszystkie wartości z przedziału traktujemy równorzędnie,
- świetny do wyjaśnienia pojęcia gęstości.

Rozkład jednostajny ciągły – wykres gęstości

Parametry przykładowe

Przyjmujemy $X \sim U(0, 4)$.



Interpretacja

Wszystkie punkty z przedziału $[0, 4]$ są jednakowo gęste; prawdopodobieństwo zależy od długości przedziału.

Rozkład normalny

Definicja i wzór

Intuicja: klasyczny symetryczny rozkład dzwonowy.

Parametry: $\mu \in \mathbb{R}$, $\sigma^2 > 0$.

Gęstość:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Nośnik:

$$X \in \mathbb{R}.$$

Typowy przykład praktyczny

- błąd pomiaru,
- klasyczny model szumu,
- odchylenia od średniej w wielu naturalnych zjawiskach.

Podstawowe charakterystyki

$$\mathbb{E}(X) = \mu$$

$$\text{Var}(X) = \sigma^2$$

$$\text{Skośność} = 0$$

$$\text{Kurtoza nadmiarowa} = 0$$


Interpretacja

- μ określa położenie środka,
- σ^2 określa skalę rozproszenia,
- rozkład jest symetryczny,
- jest kluczowy dla CLT, testów, regresji i klasycznego MLE.

Rozkład normalny – wykres gęstości

Parametry przykładowe

Przyjmujemy $X \sim \mathcal{N}(0, 1)$.



Interpretacja

To klasyczny symetryczny rozkład dzwonowy, z największą gęstością w pobliżu średniej.

Rozkład wykładniczy

Definicja i wzór

Intuicja: model czasu oczekiwania do pierwszego zdarzenia.

Parametr:

$$\lambda > 0.$$

Gęstość:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

Nośnik:

$$X \in [0, \infty).$$

Typowy przykład praktyczny

- czas do kolejnego zgłoszenia,
- czas do awarii urządzenia,
- czas oczekiwania na następne zdarzenie w procesie Poissona.

Podstawowe charakterystyki

$$\mathbb{E}(X) = \frac{1}{\lambda}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

$$\text{Skośność} = 2$$

$$\text{Kurtoza nadmiarowa} = 6$$


Interpretacja

- rozkład jest silnie prawostronnie skośny,
- ma długi prawy ogon,
- posiada własność **memoryless**,
- jest naturalnym modelem czasu oczekiwania.

Rozkład wykładniczy – wykres gęstości

Parametr przykładowy

Przyjmujemy $\lambda = 1$.



Interpretacja

Największa gęstość jest przy małych wartościach; rozkład szybko maleje, ale ma długi prawy ogon.

Rozkład t-Studenta

Definicja i wzór

Intuicja: rozkład podobny do normalnego, ale z cięższymi ogonami.

Parametr:

$$\nu > 0$$

– liczba stopni swobody.

Gęstość:

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi} \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad x \in \mathbb{R}.$$

Nośnik:

$$X \in \mathbb{R}.$$

Typowy przykład praktyczny

- małe próby,
- log-zwroty finansowe,

Podstawowe charakterystyki

$$\mathbb{E}(X) = 0 \quad \text{dla } \nu > 1$$

$$\text{Var}(X) = \frac{\nu}{\nu - 2} \quad \text{dla } \nu > 2$$

$$\text{Skośność} = 0 \quad \text{dla } \nu > 3$$

$$\text{Kurtoza nadmiarowa} = \frac{6}{\nu - 4} \quad \text{dla } \nu > 4$$


Interpretacja

- rozkład jest symetryczny,
- ma cięższe ogony niż normalny,
- dla dużego ν zbliża się do rozkładu normalnego,
- bardzo ważny w finansach i przy małych próbach.

Rozkład t-Studenta – wykres gęstości

Parametr przykładowy

Przyjmujemy $\nu = 5$.



Interpretacja

Rozkład jest podobny do normalnego w centrum, ale ma cięższe ogony.

Rozkład log-normalny

Definicja i wzór

Intuicja: zmienna dodatnia, której logarytm ma rozkład normalny.

Jeśli

$$\ln X \sim \mathcal{N}(\mu, \sigma^2),$$

to mówimy, że X ma rozkład log-normalny.

Gęstość:

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0.$$

Nośnik:

$$X \in (0, \infty).$$

Typowy przykład praktyczny

- dodatnie ceny aktywów,
- wielkości rosnące multiplikatywnie,

Podstawowe charakterystyki

$$\mathbb{E}(X) = e^{\mu + \sigma^2/2}$$

$$\text{Var}(X) = (e^{\sigma^2} - 1)e^{2\mu + \sigma^2}$$

$$\text{Skośność} = (e^{\sigma^2} + 2)\sqrt{e^{\sigma^2} - 1}$$

$$\text{Kurtoza nadmiarowa} = e^{4\sigma^2} + 2e^{3\sigma^2} + 3e^{2\sigma^2} - 6$$


Interpretacja

- rozkład jest silnie prawostronnie skośny,
- nie dopuszcza wartości ujemnych,
- dobrze opisuje poziomy cen, ale nie log-zwroty,
- jest naturalnym mostem między ceną a logarytmem ceny.

Rozkład log-normalny – wykres gęstości

Parametry przykładowe

Przyjmujemy $\ln X \sim \mathcal{N}(0, 1)$.



Interpretacja

Rozkład jest dodatni i silnie prawostronnie skośny. Dobrze nadaje się do modelowania dodatnich cen i wielkości.

Rozkład beta

Definicja i wzór

Intuicja: rozkład na przedziale $[0, 1]$, dobry do modelowania proporcji i prawdopodobieństw.

Parametry:

$$\alpha > 0, \quad \beta > 0.$$

Gęstość:

$$f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad x \in (0, 1).$$

Nośnik:

$$X \in (0, 1).$$

Typowy przykład praktyczny

- prawdopodobieństwo sukcesu,
- współczynnik konwersji,
- CTR reklamy,

Podstawowe charakterystyki

$$\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta}$$

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

$$\text{Skośność} = \frac{2(\beta - \alpha)\sqrt{\alpha + \beta + 1}}{(\alpha + \beta + 2)\sqrt{\alpha\beta}}$$

$$\text{Kurtoza nadmiarowa} = \frac{6[(\alpha - \beta)^2(\alpha + \beta + 1) - \alpha\beta(\alpha + \beta + 2)]}{\alpha\beta(\alpha + \beta + 2)(\alpha + \beta + 3)}$$


Interpretacja

- bardzo elastyczny kształt rozkładu,
- może być symetryczny lub asymetryczny,
- jest świetny do modelowania proporcji,
- bardzo ważny w statystyce bayesowskiej i A/B testach.

Rozkład beta – wykres gęstości

Parametry przykładowe

Przyjmujemy $\alpha = 2$, $\beta = 5$.



Interpretacja

Rozkład beta jest bardzo elastyczny. Tutaj większa masa leży przy mniejszych wartościach z przedziału $[0, 1]$.

Rozkład chi-kwadrat

Definicja i wzór

Intuicja: rozkład sumy kwadratów niezależnych zmiennych normalnych standaryzowanych.

Jeśli

$$Z_1, \dots, Z_k \sim \mathcal{N}(0, 1) \quad \text{i są niezależne,}$$

to

$$X = \sum_{i=1}^k Z_i^2 \sim \chi_k^2.$$

Parametr:

$$k \in \mathbb{N}$$

– liczba stopni swobody.

Nośnik:

$$X \in [0, \infty).$$

Podstawowe charakterystyki

$$\mathbb{E}(X) = k$$

$$\text{Var}(X) = 2k$$

$$\text{Skośność} = \sqrt{\frac{8}{k}}$$

$$\text{Kurtoza nadmiarowa} = \frac{12}{k}$$

Interpretacja


- rozkład jest prawostronnie skośny,
- dla dużego k staje się bardziej symetryczny,
- odgrywa kluczową rolę w klasycznej statystyce,
- jest naturalnie związany z wariancją i kwadratami odchyleń.

Typowy przykład praktyczny

Rozkład chi-kwadrat – wykres gęstości

Parametr przykładowy

Przyjmujemy $k = 4$ stopnie swobody.



Interpretacja

Rozkład jest prawostronny i opisuje sumę kwadratów standaryzowanych zmiennych normalnych.

Rozkład normalny dwuwymiarowy

Definicja i wzór

Intuicja: wspólny rozkład dwóch zmiennych losowych z możliwą korelacją.

Jeśli

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix}\right),$$

to mówimy o rozkładzie normalnym dwuwymiarowym.

Gęstość:

$$f(x, y) = \frac{1}{2\pi|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{z} - \boldsymbol{\mu})\right),$$

gdzie $\mathbf{z} = (x, y)^\top$.

Typowy przykład praktyczny

- para log-zwrotów dwóch spółek,

Podstawowe charakterystyki

$$\mathbb{E}\begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}$$

$$\text{Cov}\begin{pmatrix} X \\ Y \end{pmatrix} = \Sigma = \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix}$$

Skośność i kurtozę analizujemy **komponentowo** lub przez uogólnienia wielowymiarowe.


Interpretacja

- ρ opisuje siłę zależności liniowej,
- poziomicie gęstości mają kształt elips,
- rozkład ten jest kluczowy dla korelacji, regresji i MLE,
- bardzo ważny w finansach i analizie wielowymiarowej.

Rozkład normalny dwuwymiarowy – poziomicę gęstości

Parametry przykładowe

Przyjmujemy średnią $(0,0)$, wariancje równe 1 i korelację $\rho = 0.7$.



Interpretacja

Poziomicę mają kształt elips. Im większa korelacja, tym bardziej elipsy są wydłużone i nachylone.

Rozkład Dirichleta

Definicja i wzór

Intuicja: uogólnienie rozkładu beta na wektory udziałów sumujących się do 1.

Parametry:

$$\alpha_1, \dots, \alpha_K > 0.$$

Nośnik:

$$x_i \geq 0, \quad \sum_{i=1}^K x_i = 1.$$

Gęstość:

$$f(x_1, \dots, x_K) = \frac{1}{B(\alpha)} \prod_{i=1}^K x_i^{\alpha_i - 1},$$

gdzie

$$B(\alpha) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^K \alpha_i)}.$$

Podstawowe charakterystyki

Niech

$$\alpha_0 = \sum_{i=1}^K \alpha_i.$$

Wtedy dla każdej składowej:

$$\mathbb{E}(X_i) = \frac{\alpha_i}{\alpha_0}$$

$$\text{Var}(X_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)}$$

$$\text{Cov}(X_i, X_j) = -\frac{\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)}, \quad i \neq j$$

Skośność i kurtozę analizujemy komponentowo.


Interpretacja

- opisuje losowe proporcje sumujące się do 1,

Rozkład Dirichleta – wizualizacja gęstości na sympleksie

Parametry przykładowe

Przyjmujemy $K = 3$ oraz $(\alpha_1, \alpha_2, \alpha_3) = (3, 2, 2)$.



Interpretacja

Rozkład Dirichleta opisuje losowe proporcje sumujące się do 1. Większe zagęszczenie oznacza większą wiarygodność danych kombinacji udziałów (x_1, x_2, x_3) .

Podsumowanie: podstawowe rozkłady ciągłe

Rozkład	Nośnik	Parametry	Typowy przykład praktyczny
Jednostajny ciągły	$[a, b]$	a, b	losowy punkt z przedziału, losowy czas w oknie
Wykładniczy	$[0, \infty)$	λ	czas oczekiwania do pierwszego zdarzenia
Normalny	$\mathbb{R}$	μ, σ^2	błąd pomiaru, klasyczny model szumu
Normalny dwuwymiarowy	$\mathbb{R}^2$	μ, Σ	para powiązanych zmiennych, np. dwa zwroty
t-Studenta	$\mathbb{R}$	ν	cięższe ogony, małe próby, finanse
Log-normalny	$(0, \infty)$	μ, σ^2 dla $\ln X$	dodatnie ceny i wielkości multiplikatywne
Beta	$(0, 1)$	α, β	proporcje, prawdopodobieństwa, konwersje
Chi-kwadrat	$[0, \infty)$	k	testy wariancji, klasyczna statystyka
Dirichleta	$\sum x_i = 1$	$\alpha_1, \dots, \alpha_K$	wektory udziałów / proporcji

Najważniejsza intuicja

Rozkłady ciągłe opisują sytuacje, w których zmienna może przyjmować wartości z **całych przedziałów** lub przestrzeni wielowymiarowych, a prawdopodobieństwo opisujemy przez **gęstość**.

Dystrybuanta, kwantyle i percentyle

Dystrybuanta – podstawowa funkcja opisująca rozkład

Definicja

Dla zmiennej losowej X jej **dystrybuanta** jest zdefiniowana przez wzór

$$F(x) = \mathbb{P}(X \leq x).$$

Intuicja

Dystrybuanta mówi, jakie jest **skumulowane prawdopodobieństwo** tego, że zmienna losowa przyjmie wartość nie większą niż x .

Najważniejsze własności

- $0 \leq F(x) \leq 1$,
- $F(x)$ jest funkcją niemalejącą,
-

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

Dlaczego dystrybuanta jest tak ważna?

Bo działa zarówno dla rozkładów:

Przykład dystrybuanty dyskretnej: liczba orłów w 4 rzutach

Funkcja prawdopodobieństwa

Niech

X = liczba orłów w 4 rzutach monetą.

Wtedy

$$X \sim \text{Bin}(4, 0.5).$$

x	$\mathbb{P}(X = x)$
0	$\frac{1}{16}$
1	$\frac{4}{16}$
2	$\frac{6}{16}$
3	$\frac{4}{16}$
4	$\frac{1}{16}$

Dystrybuanta

Dla tego rozkładu:

$$F(x) = \mathbb{P}(X \leq x).$$

x	$F(x) = \mathbb{P}(X \leq x)$
0	$\frac{1}{16}$
1	$\frac{5}{16}$
2	$\frac{11}{16}$
3	$\frac{15}{16}$
4	1

Dystrybuanta jest tutaj **funkcją skokową**.

Najważniejsza intuicja

Dystrybuanta, kwantyle i percentyle

Dystrybuanta – podstawowa funkcja opisująca rozkład

Definicja

Dla zmiennej losowej X jej **dystrybuanta** jest zdefiniowana przez wzór

$$F(x) = \mathbb{P}(X \leq x).$$

Intuicja

Dystrybuanta mówi, jakie jest **skumulowane prawdopodobieństwo** tego, że zmienna losowa przyjmie wartość nie większą niż x .

Najważniejsze własności

- $0 \leq F(x) \leq 1$,
- $F(x)$ jest funkcją niemalejącą,
-

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

Dlaczego dystrybuanta jest tak ważna?

Dlaczego dystrybuanta jest tak ważna?

Bo działa zarówno dla rozkładów:

- dyskretnych,
- ciągłych,
- mieszanych.

Jest więc najbardziej uniwersalnym sposobem opisu rozkładu.

Rozkład dyskretny i jego dystrybuanta: liczba orłów w 4 rzutach

Funkcja prawdopodobieństwa

Niech

X = liczba orłów w 4 rzutach monetą.

Wtedy

$$X \sim \text{Bin}(4, 0.5).$$

x	$\mathbb{P}(X = x)$
0	$\frac{1}{16}$
1	$\frac{4}{16}$
2	$\frac{6}{16}$
3	$\frac{4}{16}$
4	$\frac{1}{16}$

Dystrybuanta

Dla tego rozkładu:

$$F(x) = \mathbb{P}(X \leq x).$$

x	$F(x) = \mathbb{P}(X \leq x)$
0	$\frac{1}{16}$
1	$\frac{5}{16}$
2	$\frac{11}{16}$
3	$\frac{15}{16}$
4	1

Dystrybuanta jest tutaj **funkcją skokową**.

Najważniejsza intuicja

W przypadku dyskretnym dystrybuanta powstaje przez **sumowanie kolejnych mas prawdopodobieństwa**.
Każdy skok odpowiada punktowi, w którym rozkład ma dodatnią masę.

Percentyl w przypadku dyskretnym i ciągłym

Ogólna idea

Percentyl rzędu p , gdzie $0 < p < 1$, to wartość graniczna, poniżej której znajduje się około $100p\%$ rozkładu.

Przypadek dyskretny

W przypadku dyskretnym percentyl rzędu p definiujemy zwykle jako

$$q_p = \min\{x : F(x) \geq p\}.$$

Intuicja: szukamy **pierwszej wartości**, dla której skumulowane prawdopodobieństwo osiąga poziom p .

Dla rozkładu skokowego percentyl może nie być jednoznacznie „gładki”, bo dystrybuenta rośnie skokami.

Przypadek ciągły

W przypadku ciągłym percentyl rzędu p jest zwykle definiowany przez równanie

$$F(q_p) = p.$$

Intuicja: szukamy takiego punktu q_p , aby pole pod gęstością do tego miejsca było równe p .

W przypadku rozkładów ciągłych percentyle są zwykle interpretowane bardziej „gładko” niż dla rozkładów dyskretnych.

Dlaczego percentyle będą nam potrzebne?

Dlaczego percentyle będą nam potrzebne?

Percentyle są kluczowe przy:

- bootstrapowych przedziałach ufności,
- interpretacji rozkładów,
- analizie ryzyka,
- kwantylach i miarach typu VaR.

Kwantyl rzędu p – pojęcie ogólne

Główna idea

Kwantyl rzędu p , gdzie $0 < p < 1$, to wartość graniczna, poniżej której znajduje się około $100p\%$ rozkładu.

Przypadek dyskretny

W przypadku dyskretnym kwantyl rzędu p definiujemy zwykle jako

$$q_p = \min\{x : F(x) \geq p\}.$$

Intuicja: szukamy **pierwszej wartości**, dla której skumulowane prawdopodobieństwo osiąga poziom p .

Przypadek ciągły

W przypadku ciągłym kwantyl rzędu p jest zwykle określony przez warunek

$$F(q_p) = p.$$

Intuicja: szukamy punktu q_p , dla którego pole pod gęstością do tego miejsca stanowi dokładnie ułamek p całego pola.

Dlaczego pojęcie kwantyla jest tak ważne?

Dlaczego pojęcie kwantyla jest tak ważne?

Kwantyle są kluczowe przy:

- interpretacji rozkładów,
- opisie danych,
- bootstrapowych przedziałach ufności,
- analizie ryzyka i miarach typu VaR.

Szczególne przypadki kwantyli

Jedna idea, wiele nazw

Kwantyl rzędu p jest pojęciem ogólnym. Szczególne nazwy pojawiają się wtedy, gdy wybieramy określone poziomy p .

Nazwa	Poziom	Interpretacja
Mediana	$q_{0.5}$	dzieli rozkład na dwie połowy
Kwartyle	$q_{0.25}, q_{0.5}, q_{0.75}$	dzielą rozkład na cztery części
Decyle	$q_{0.1}, q_{0.2}, \dots, q_{0.9}$	dzielą rozkład na dziesięć części
Percentyle	$q_{0.01}, q_{0.02}, \dots, q_{0.99}$	dzielą rozkład na sto części

Kwantyle: Wspólna intuicja

Wspólna intuicja

Wszystkie te pojęcia opisują **położenie punktów granicznych** w rozkładzie, tylko przy różnych poziomach szczegółowości.

Wniosek praktyczny

Percentyl, decyl, kwartył i mediana nie są odrębnymi ideami – to tylko różne szczególne przypadki **kwantyli**.

Mediana jako kwantyl rzędu 0.5

Definicja

Mediana to **kwantyl rzędu 0.5**:

$$\text{mediana} = q_{0.5}.$$

Równoważne interpretacje

Mediana to jednocześnie:

- **50-ty percentyl**,
- **5-ty decyl**,
- **środkowy punkt rozkładu w sensie położenia**.

Najważniejsza intuicja


Mediana dzieli rozkład tak, że około połowa obserwacji leży po lewej stronie, a około połowa po prawej stronie.

Dlaczego mediana jest ważna?

Bo jest odporna na obserwacje ekstremalne i często lepiej opisuje „typową wartość” niż średnia, zwłaszcza dla rozkładów asymetrycznych.

Estymacja, korelacja, bootstrap i CLT

Od populacji do próby



Kluczowe rozróżnienie

- **parametr** – cecha populacji / modelu,
- **estymator** – reguła liczenia na podstawie próby,
- **oszacowanie** – konkretna liczba otrzymana dla danej próby.

Kowariancja i korelacja

Kowariancja

$$\text{Cov}(X, Y) = \mathbb{E} [(X - \mathbb{E} X)(Y - \mathbb{E} Y)]$$

- dodatnia: rosną razem,
- ujemna: jedna rośnie, druga maleje,
- bliska zeru: brak liniowej współzależności.

Korelacja

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

- skala od -1 do 1 ,
- ułatwia porównywanie zależności między różnymi parami zmiennych.

Pomost do szeregów czasowych

Autokorelacja to po prostu korelacja między X_t i X_{t-k} .

Przedziały ufności: intuicja

Punktowe oszacowanie nie wystarcza

Sama liczba $\hat{\theta}$ nie mówi jeszcze, jak bardzo jej ufamy. Potrzebujemy **miary niepewności**.

Intuicja przedziału ufności

Przedział ufności ma odpowiadać na pytanie:

jak szeroki zakres wartości parametru jest jeszcze rozsądnie zgodny z danymi?

Przykłady w tym kursie

- przedział dla p w modelu Bernoulliego,
- przedział dla średniego log-zwrotu,
- przedział dla średniej temperatury lub anomalii.

Bootstrap: praktyczna ocena niepewności



Dlaczego bootstrap jest cenny?

- nie wymaga zawsze pełnego wzoru analitycznego,
- jest bardzo intuicyjny,
- dobrze pasuje do myślenia informatycznego: wielokrotne losowanie i agregacja.

W tym kursie

Bootstrap jest dobrym mostem między klasyczną statystyką a praktyką obliczeniową.

Centralne twierdzenie graniczne (CLT)

Idea

Dla wielu niezależnych obserwacji o tym samym rozkładzie, średnia z próby po odpowiednim przeskalowaniu staje się w przybliżeniu normalna:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \Rightarrow \mathcal{N}(0, 1).$$

Dlaczego to jest tak ważne?

CLT tłumaczy, skąd biorą się:

- klasyczne przedziały ufności,
- wiele testów statystycznych,
- asymptotyczna normalność wielu estymatorów.

CLT na intuicji monety

Bernoulli

Jeśli

$$X_i \in \{0, 1\}, \quad \mathbb{P}(X_i = 1) = p,$$

to

$$\mathbb{E}(X_i) = p, \quad \text{Var}(X_i) = p(1 - p).$$

Średnia

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

jest estymatorem proporcji orłów.

Wniosek

Dla większego n ,

$$\bar{X}_n \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right).$$

To daje intuicję przedziałów ufności i testu

$$H_0 : p = 0.5.$$

95% przedziały ufności dla średniej, wariancji i odchylenia standardowego

Przedział ufności dla średniej przy nieznanej wariancji

Jeśli próbka ma licznosc n , srednią $\bar{x}$ i odchylenie standardowe s , to 95% przedział ufności dla średniej ma postać

$$\bar{x} \pm t_{0.975, n-1} \frac{s}{\sqrt{n}}.$$

Dla naszych danych $n = 10$, więc liczba stopni swobody wynosi

$$n - 1 = 9, \quad t_{0.975, 9} \approx 2.262.$$

Wariancja

Przedział ufności dla wariancji

Zakładając normalność danych, mamy

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Stąd 95% przedział ufności dla wariancji:

$$\left(\frac{(n-1)s^2}{\chi_{0.975, n-1}^2}, \frac{(n-1)s^2}{\chi_{0.025, n-1}^2} \right).$$

Dla $n = 10$:

$$\chi_{0.975, 9}^2 \approx 19.023, \quad \chi_{0.025, 9}^2 \approx 2.700.$$

Przedział ufności dla odchylenia standardowego

Jeśli mamy przedział dla wariancji (L, U) , to dla odchylenia standardowego otrzymujemy

$$(\sqrt{L}, \sqrt{U}).$$

Spółka Alfa: dokładny rachunek 95% przedziałów ufności

Krok 1: statystyki z próby

Dla danych

0.012, -0.008, 0.004, -0.015, 0.020, -0.006, 0.003, -0.011, 0.007, -0.002

mamy:

$$n = 10, \quad \bar{r} = 0.0004, \quad s_r^2 = 0.00011849, \quad s_r \approx 0.01089.$$

Krok 2: 95% CI dla średniej. Używamy wzoru

$$\begin{aligned} & \bar{r} \pm t_{0.975,9} \frac{s_r}{\sqrt{10}}. \\ & 0.0004 \pm 2.262 \cdot \frac{0.01089}{\sqrt{10}}. \\ & 2.262 \cdot \frac{0.01089}{3.162} \approx 0.00779. \\ & 0.0004 \pm 0.00779. \end{aligned}$$

Otrzymujemy:

$$(-0.00739, 0.00819).$$

Krok 3: 95% CI dla wariancji. Używamy wzoru

Używamy wzoru

$$\left(\frac{9s_r^2}{19.023}, \frac{9s_r^2}{2.700} \right).$$

Podstawiamy:

$$\left(\frac{9 \cdot 0.00011849}{19.023}, \frac{9 \cdot 0.00011849}{2.700} \right).$$

Daje to:

$$(0.0000561, 0.0003949).$$

Olsztyn: dokładny rachunek 95% przedziałów ufności

Krok 1: statystyki z próby

Dla danych

$$-1.2, -0.4, 0.3, 1.1, 0.5, -0.2, 0.8, 1.4, 0.6, -0.1$$

mamy:

$$n = 10, \quad \bar{T} = 0.28, \quad s_T^2 = 0.59733, \quad s_T \approx 0.77287.$$

Krok 2: 95% CI dla średniej

$$\begin{aligned} \bar{T} \pm t_{0.975,9} \frac{s_T}{\sqrt{10}} \\ 0.28 \pm 2.262 \cdot \frac{0.77287}{\sqrt{10}} \\ 2.262 \cdot \frac{0.77287}{3.162} \approx 0.55288. \\ 0.28 \pm 0.55288. \end{aligned}$$

Otrzymujemy:

$$(-0.27288, 0.83288).$$

Krok 3: 95% CI dla wariancji

Używamy wzoru

$$\left(\frac{9s_T^2}{19.023}, \frac{9s_T^2}{2.700} \right).$$

Podstawiamy:

$$\left(\frac{9 \cdot 0.59733}{19.023}, \frac{9 \cdot 0.59733}{2.700} \right).$$

Daje to:

$$(0.28261, 1.99082).$$

Porównanie 95% przedziałów ufności dla obu przykładów

Przykład	95% CI dla średniej	95% CI dla wariancji	95% CI dla odchylenia std.
Spółka Alfa	(-0.00739, 0.00819)	(0.0000561, 0.0003949)	(0.00749, 0.01987)
Olsztyn	(-0.27288, 0.83288)	(0.28261, 1.99082)	(0.53161, 1.41097)

Najważniejszy wniosek dydaktyczny

Przedział ufności dla średniej mówi o niepewności dotyczącej **poziomu**, a przedział dla wariancji lub odchylenia standardowego mówi o niepewności dotyczącej **skali wahań**.

Pomost do dalszego kursu

W finansach bardzo często średnia jest trudna do oszacowania, ale zmienność jest kluczowa. To jest bezpośredni most do modeli ARCH i GARCH.

Estymacja bootstrapowa

Po co nam bootstrap?

Motywacja

Klasyczne przedziały ufności są bardzo eleganckie, ale zwykle wymagają:

- odpowiednich wzorów analitycznych,
- założeń o rozkładzie danych,
- asymptotycznych przybliżeń.

Idea bootstrapu

Bootstrap pozwala oszacować niepewność estymatora **empirycznie**, bez konieczności wyprowadzania trudnych wzorów.

dane $\rightarrow$ wiele prób bootstrapowych $\rightarrow$ wiele oszacowań $\rightarrow$ rozkład estymatora

Co będziemy estymować?

Co będziemy estymować?

Na naszych dwóch przykładach oszacujemy metodą bootstrap:

- **średnią** ($\bar{x}$) jako estymator wartości oczekiwanej,
- **odchylenie standardowe** (s) jako estymator skali zmienności.

Bardzo ważna uwaga

Na slajdach pokażemy tylko **5 przykładowych prób bootstrapowych**, aby dobrze zrozumieć mechanizm. Natomiast właściwe wyniki policzymy dla

$$B = 500$$

replikacji bootstrapowych.

Algorytm bootstrap krok po kroku

Dane wejściowe

Mamy próbę

$$x_1, x_2, \dots, x_n.$$

Chcemy oszacować niepewność estymatora $\hat{\theta}$, np.:

$$\hat{\theta} = \bar{x} \quad \text{lub} \quad \hat{\theta} = s.$$

Algorytm

- 1 Losujemy z oryginalnej próby nową próbę długości n z **powtórzeniami**.
- 2 Liczymy estymator $\hat{\theta}^{*(1)}$.
- 3 Powtarzamy to B razy i otrzymujemy:

$$\hat{\theta}^{*(1)}, \hat{\theta}^{*(2)}, \dots, \hat{\theta}^{*(B)}.$$

- 4 Te wartości traktujemy jako przybliżony rozkład bootstrapowy estymatora.

Bootstrapowy przedział ufności percentylowy

95% bootstrapowy przedział ufności wyznaczamy jako:

Spółka Alfa: 5 przykładowych prób bootstrapowych

Oryginalna próba

(0.012, -0.008, 0.004, -0.015, 0.020, -0.006, 0.003, -0.011, 0.007, -0.002)

Pięć przykładowych prób bootstrapowych

B_1 (0.003, 0.004, -0.011, -0.015, 0.004, -0.011, 0.003, 0.003, -0.002, -0.015)

B_2 (0.012, 0.012, 0.007, -0.011, -0.011, 0.004, -0.015, -0.011, 0.020, 0.012)

B_3
(-0.002, -0.008, 0.003, 0.020, -0.015, -0.008, -0.008, -0.006, 0.020, -0.008)

B_4 (-0.002, 0.007, -0.015, 0.007, 0.020, 0.020, -0.006, -0.008, 0.007, -0.008)

B_5 (0.003, -0.002, -0.006, -0.011, 0.020, -0.015, -0.002, 0.007, 0.003, 0.004)

Statystyki

	$\bar{r}^*$	s^*
B_1	-0.0037	0.00829
B_2	0.0019	0.01216
B_3	-0.0012	0.01240
B_4	0.0022	0.01347
B_5	0.0001	0.01087

Najważniejsza intuicja

Każda próba bootstrapowa jest trochę inna, więc średnia i odchylenie standardowe też się zmieniają. Właśnie z tej zmienności budujemy przybliżony rozkład estymatora.

Spółka Alfa: bootstrap dla $B = 500$

Oryginalne estymatory z próby

$$\bar{r} = 0.0004, \quad s_r = 0.01089.$$

Wyniki bootstrapowe dla $B = 500$. Dla 500 prób bootstrapowych otrzymaliśmy:

średnia bootstrapowych średnich ≈ 0.00040 ,
średnia bootstrapowych odchyleń standardowych ≈ 0.01014 .

95% bootstrapowe przedziały ufności percentylowe. Dla średniej:

$(-0.00550, 0.00660)$

Dla odchylenia standardowego:

$(0.00637, 0.01389)$

Interpretacja

Przedział dla średniej nadal zawiera 0, więc nie ma mocnego sygnału dodatniej lub ujemnej średniej. Natomiast bootstrap pokazuje też niepewność oszacowania zmienności.

Olsztyn: 5 przykładowych prób bootstrapowych

Oryginalna próba

$(-1.2, -0.4, 0.3, 1.1, 0.5, -0.2, 0.8, 1.4, 0.6, -0.1)$

Pięć przykładowych prób bootstrapowych

- B_1 $(0.8, 0.3, 1.4, -0.4, 0.3, -0.4, -1.2, 1.4, 0.6, -1.2)$
 B_2 $(-1.2, 0.5, 0.3, 0.3, -0.2, -0.1, -1.2, 0.5, -0.4, 1.1)$
 B_3 $(0.8, 0.6, -0.2, -1.2, -0.4, -0.1, 0.5, 1.1, -0.2, 0.5)$
 B_4 $(0.8, 0.5, 0.3, -0.4, 0.8, -0.4, 1.4, 0.5, 0.3, 0.6)$
 B_5 $(1.1, -0.2, -0.2, 0.6, -0.4, -0.4, -0.2, -0.2, 1.4, 0.8)$

Statystyki

	$\bar{T}^*$	s^*
B_1	0.16	0.93417
B_2	-0.04	0.73288
B_3	0.14	0.71508
B_4	0.44	0.56686
B_5	0.23	0.66850

Najważniejsza intuicja

Tak samo jak wcześniej, różne próby bootstrapowe prowadzą do różnych wartości średniej i odchylenia standardowego. To daje empiryczny obraz niepewności estymatorów.

Olsztyn: bootstrap dla $B = 500$

Oryginalne estymatory z próby

$$\bar{T} = 0.28, \quad s_T = 0.77287.$$

Wyniki bootstrapowe dla $B = 500$. Dla 500 prób bootstrapowych otrzymaliśmy:

średnia bootstrapowych średnich ≈ 0.2734 ,
średnia bootstrapowych odchyleń standardowych ≈ 0.7081 .

95% bootstrapowe przedziały ufności percentylowe. Dla średniej:

$$(-0.17525, 0.71525)$$

Dla odchylenia standardowego:

$$(0.43492, 0.98450)$$

Interpretacja


Przedział dla średniej jest nadal szeroki, co pokazuje niepewność przy małej próbie. Przedział dla odchylenia standardowego mówi, że rzeczywista zmienność może być umiarkowana, ale jej dokładne oszacowanie nie jest jeszcze bardzo precyzyjne.

Histogramy bootstrapowych średnich ($B = 500$)


Ustawienie eksperymentu

Dla każdego z dwóch zbiorów danych wygenerowano 500 prób bootstrapowych i dla każdej policzono średnią z próby.

Spółka Alfa – bootstrapowe średnie



Olsztyn – bootstrapowe średnie




Histogramy bootstrapowych odchyłeń standardowych ($B = 500$)


Ustawienie eksperymentu

Dla każdego z dwóch zbiorów danych wygenerowano 500 prób bootstrapowych i dla każdej policzono odchylenie standardowe z próby.

Spółka Alfa – bootstrapowe odchylenia



Olsztyn – bootstrapowe odchylenia



Spółka Alfa: 5 przykładowych prób bootstrapowych

Oryginalna próba

(0.012, -0.008, 0.004, -0.015, 0.020, -0.006, 0.003, -0.011, 0.007, -0.002)

Próba bootstrapowa	$\bar{r}^*$	s^*
(0.003, 0.004, -0.011, -0.015, 0.004, -0.011, 0.003, 0.003, -0.002, -0.015)	-0.00237	0.00829
(-0.007?)		

Uwaga

Na potrzeby slajdu poniżej podajemy 5 konkretnych prób bootstrapowych oraz odpowiadające im średnie i odchylenia standardowe. W rzeczywistych obliczeniach użyjemy $B = 500$ takich prób.

Porównanie: klasyczne przedziały ufności vs bootstrap

Przykład	Parametr	Klasyczny 95% CI	Bootstrap 95% CI
Spółka Alfa	średnia	(−0.00739, 0.00819)	(−0.00550, 0.00660)
Spółka Alfa	odchylenie std.	(0.00749, 0.01987)	(0.00637, 0.01389)
Olsztyn	średnia	(−0.27288, 0.83288)	(−0.17525, 0.71525)
Olsztyn	odchylenie std.	(0.53161, 1.41097)	(0.43492, 0.98450)

Najważniejszy wniosek z przykładu

Klasyczne przedziały ufności opierają się na wzorach i założeniach rozkładowych, a bootstrap na wielokrotnym losowaniu z próby i empirycznej analizie rozkładu estymatora.

Wniosek praktyczny

Dobrze znać oba podejścia:

- **klasyczne** – eleganckie i szybkie,
- **bootstrapowe** – elastyczne i bardzo praktyczne obliczeniowo.

Uwaga dla szeregów czasowych

Dla danych z silną zależnością czasową zwykły bootstrap niezależnych obserwacji bywa zbyt prosty. Wtedy stosuje się np. **block bootstrap**.

Idea block bootstrap w szeregach czasowych

Problem ze zwykłym bootstrapem

W klasycznym bootstrapie losujemy pojedyncze obserwacje z powtórzeniami. Dla danych i.i.d. jest to naturalne, ale dla szeregu czasowego może zniszczyć:

- lokalną zależność w czasie,
- krótkookresową autokorelację,
- klastry zmienności.

Główna idea block bootstrap

Zamiast losować pojedyncze obserwacje, losujemy **całe bloki kolejnych obserwacji**, na przykład:

$$(X_1, X_2, X_3), \quad (X_4, X_5, X_6), \quad (X_7, X_8, X_9).$$

Następnie składamy z takich bloków nową próbę bootstrapową.

 X_1 X_2 X_3 X_4 X_5

Idea block bootstrap w szeregach czasowych

Dlaczego to ma sens?

Losowanie bloków pozwala zachować część lokalnej struktury szeregu:

- zależności między sąsiednimi obserwacjami,
- krótkie wzorce trendu lub sezonowości,
- lokalne skupienia dużej i małej zmienności.

Najważniejsza intuicja

Zwykły bootstrap miesza pojedyncze punkty. Block bootstrap miesza **krótkie fragmenty trajektorii**. To często daje bardziej realistyczny obraz niepewności w szeregach czasowych.

Czy węższy przedział znaczy lepszy przedział?

Najkrótsza odpowiedź

Nie zawsze. **Węższy przedział ufności** jest lepszy tylko wtedy, gdy nadal daje **wiarygodną ocenę niepewności** i sensownie przybliża deklarowany poziom ufności, na przykład 95%.

Jak to rozumieć praktycznie?

Dobry przedział ufności powinien być jednocześnie:

możliwie wąski i statystycznie wiarygodny.

Zbyt szeroki przedział bywa mało użyteczny, ale szczególnie przy małych próbkach (np. wyraźnie poniżej kilkudziesięciu obserwacji) zbyt wąski przedział może dawać fałszywe poczucie precyzji.

Dlaczego bootstrap jest tak ważny?

Dlaczego bootstrap jest tak ważny?

Bootstrap jest bardzo cennym narzędziem, ponieważ:

- nie wymaga pełnej znajomości rozkładu parametrycznego,
- pozwala oszacować niepewność estymatora empirycznie,
- jest bardzo elastyczny i dobrze działa dla wielu praktycznych problemów,
- bywa jedną z najlepszych dostępnych metod, gdy klasyczne wzory są trudne lub nieosiągalne.

Najważniejszy wniosek metodologiczny

Jeśli bootstrap daje węższy przedział, to zwykle oznacza, że **na podstawie danych empirycznych** oszacowana niepewność estymatora jest mniejsza niż w metodzie klasycznej. Nie należy tego automatycznie odczytywać jako dowodu, że bootstrap jest „gorszy” lub „lepszy”, ale raczej jako **inną, bardzo praktyczną metodę oceny niepewności**.

Testowanie hipotez

Schemat

- 1 formułujemy hipotezę zerową H_0 ,
- 2 formułujemy hipotezę alternatywną H_1 ,
- 3 liczymy statystykę testową,
- 4 wyznaczamy p-value,
- 5 decydujemy, czy dane są wystarczająco niezgodne z H_0 .

Najczęstszy błąd interpretacyjny

Nieodrzućenie H_0 nie oznacza, że H_0 jest udowodniona. Oznacza tylko, że dane nie dały wystarczająco mocnego argumentu przeciwko niej.

Analogia sądowa dla p-value

Analogia

- H_0 : domniemanie niewinności,
- dowody z danych: materiał procesowy,
- małe p-value: dane słabo zgadzają się z H_0 .

Dobra interpretacja

p-value to nie jest prawdopodobieństwo, że H_0 jest prawdziwa.

Sens p-value

Jest to prawdopodobieństwo uzyskania tak ekstremalnych danych **zakładając, że H_0 jest prawdziwa.**

Test dla średniej

Przykład dla Spółki Alfa

Chcemy sprawdzić:

$$H_0 : \mu = 0 \quad \text{vs} \quad H_1 : \mu \neq 0.$$

Intuicja

Pytamy, czy średni log-zwrot jest na tyle daleki od zera, że trudno to wyjaśnić samym przypadkiem.

Dla studentów informatyki

Test dla średniej można rozumieć jako:

czy sygnał jest wystarczająco duży w porównaniu z szumem?

Test dla wariancji

Pytanie

Czy zmienność danych jest zgodna z założoną wartością? Na przykład:

$$H_0 : \sigma^2 = \sigma_0^2.$$

Intuicja praktyczna

Test dla wariancji odpowiada na pytanie, czy skala ryzyka lub niepewności jest zgodna z oczekiwaniami.

Pomost do GARCH

W tym kursie jest to ważne, bo w modelach zmienności właśnie σ_t^2 staje się centralnym obiektem zainteresowania.

Wzmianka o teście Kołmogorowa–Smirnowa

Idea testu KS

Porównujemy:

- dystrybuantę empiryczną,
- dystrybuantę teoretyczną.

Statystyką jest największa różnica:

$$D_n = \sup_x |F_n(x) - F_0(x)|.$$

Po co to studentowi?

Bo pokazuje, że testować można nie tylko pojedynczy parametr, ale także **całą zgodność rozkładu z danymi**.

Uwaga

To jest dobry test do intuicji zgodności rozkładu, ale w praktyce ma też ograniczenia, zwłaszcza gdy parametry rozkładu były wcześniej estymowane z tych samych danych.

Czym jest stacjonarność?

Intuicja

Szereg jest stacjonarny, gdy jego podstawowe własności nie zmieniają się istotnie w czasie:

- średnia jest mniej więcej stała,
- wariancja jest mniej więcej stała,
- struktura zależności zależy od opóźnienia, a nie od konkretnego momentu kalendarzowego.

Dlaczego to ważne?

Modele AR, ARMA i wiele narzędzi diagnostycznych zakładają stacjonarność lub przynajmniej przybliżoną stacjonarność.

Trzy typowe problemy ze stacjonarnością

Problem	Objaw	Skutek dla modelowania
Trend	średnia zmienia się w czasie	fałszywa autokorelacja, zła interpretacja parametrów
Sezonowość	regularne wzorce kalendaryzowe	potrzeba różnicowania lub składników sezonowych
Heteroskedastyczność	zmienia się wariancja	klasyczne modele średniej nie opisują poprawnie ryzyka

Bardzo ważne

W finansach często poziom zwrotu bywa bliski stacjonarnemu, ale **wariancja nie jest stała**. To właśnie otwiera drogę do ARCH/GARCH.

ADF i KPSS jako “unit testy dla danych”

ADF

H_0 : szereg ma pierwiastek jednostkowy
czyli jest niestacjonarny w ważnym sensie.

KPSS

H_0 : szereg jest stacjonarny
w odpowiednim sensie.

Metafora informatyczna

ADF i KPSS to **unit testy dla danych**. Zanim wdrożysz model, sprawdzasz, czy podstawowe założenia nie są już na starcie podejrzane.

Ważne

Testy nie są wyroczniami. Są raczej obowiązkową **bramką jakości**.

Jak czytać ADF i KPSS razem?

ADF	KPSS	Wniosek roboczy
odrzuca H_0	nie odrzuca H_0	mocny sygnał stacjonarności
nie odrzuca H_0	odrzuca H_0	mocny sygnał niestacjonarności
oba zgodne niejednoznacznie	oba niejednoznaczne	potrzebna ostrożność, wykres, wiedza domenowa, dalsza diagnostyka

Praktyczna zasada

Nigdy nie polegamy na jednym numerku. Łączymy: **wykres szeregu + testy + intuicję modelową.**

Co oznacza “wiedza dostępna do chwili t ”?

Idea

W chwili t nie znamy przyszłości, ale znamy przeszłość:

$$X_1, X_2, \dots, X_t.$$


Zbiór całej tej dostępnej informacji zapisujemy symbolicznie jako

$$\mathcal{F}_t.$$

Interpretacja

$\mathcal{F}_t$ to formalny zapis wszystkiego, co wiemy przed przewidywaniem chwili $t + 1$.


Wizualizacja informacji jako drzewa historii



Intuicja

Z każdym kolejnym krokiem historia staje się bardziej szczegółowa. Informacja rośnie, a zbiór możliwych przyszłości się zawęża.

Alternatywna wizualizacja: coraz drobniejszy podział Omega



Interpretacja

Każda kolejna chwila czasu daje bardziej szczegółowy podział przestrzeni możliwych historii. To jest intuicja filtracji.

Warunkowa wartość oczekiwana

Definicja intuicyjna

$$\mathbb{E}(X_{t+1} \mid \mathcal{F}_t)$$

to najlepsza prognoza przyszłej wartości na podstawie wiedzy dostępnej do chwili t .

W kontekście modeli

- w modelach ARIMA prognozujemy głównie **średnią warunkową**,
- pytamy: jaki poziom X_{t+1} jest najbardziej racjonalny, jeśli znamy przeszłość?

Przykład intuicyjny

Dla niezależnych rzutów monetą wcześniejsze rzuty nic nie mówią o następnym:

$$\mathbb{E}(X_{t+1} \mid \mathcal{F}_t) = \mathbb{E}(X_{t+1}).$$

Warunkowa wariancja

Definicja intuicyjna

$$\text{Var}(X_{t+1} \mid \mathcal{F}_t)$$

mówi, jak duża jest niepewność prognozy po uwzględnieniu dostępnej wiedzy.

Kluczowa różnica


$\mathbb{E}(X_{t+1} \mid \mathcal{F}_t)$ opisuje poziom,

$\text{Var}(X_{t+1} \mid \mathcal{F}_t)$ opisuje ryzyko / zmienność.

Najważniejszy most do GARCH

W danych finansowych średnia bywa prawie nieprzewidywalna, ale **warunkowa wariancja** bywa bardzo przewidywalna.

Dwa równoległe pytania o przyszłość



To jest centralna idea dalszego kursu

- **ARIMA** odpowiada głównie na pytanie: *jaki poziom?*
- **GARCH** odpowiada głównie na pytanie: *jakie ryzyko?*

Pierwsza intuicja martyngału

Fair game

Proces (X_t) ma intuicję martyngału, gdy

$$\mathbb{E}(X_{t+1} \mid \mathcal{F}_t) = X_t.$$

Dla zwrotów finansowych

Często wygodniej myśleć o przyrostach lub log-zwrotach:

$$\mathbb{E}(r_{t+1} \mid \mathcal{F}_t) = 0.$$

To mówi, że nie ma łatwego, systematycznego “darmowego sygnału” w średniej.

Ale uwaga

Brak przewidywalnej średniej nie oznacza braku przewidywalnej zmienności. I właśnie dlatego modele GARCH są tak ważne.

Autokorelacja: pierwsza intuicja pamięci szeregu

Pytanie

Czy dzisiejsza wartość X_t jest liniowo związana z wartością sprzed k kroków?

Autokorelacja

$$\rho(k) = \text{Corr}(X_t, X_{t-k})$$

pozwała mierzyć zależność przy opóźnieniu k .

Interpretacja

- dla białego szumu autokorelacje są bliskie zera,
- dla procesu z pamięcią pewne opóźnienia dają wyraźny sygnał,
- wolny zanik ACF bywa sygnałem niestacjonarności.

ACF i PACF: po co dwa narzędzia?

ACF

Pokazuje łączną zależność między X_t i X_{t-k} , wliczając wpływy pośrednie przez inne opóźnienia.

PACF

Pokazuje bardziej “czysty” wpływ opóźnienia k , po odjęciu wpływu krótszych opóźnień.

Intuicja praktyczna

- ACF pomaga wykryć, czy pamięć w ogóle istnieje,
- PACF pomaga zgadywać prostą strukturę typu AR.


Ostrożność

ACF i PACF są **narzędziami pomocniczymi**, nie wyroczniami.

Trzy przykłady pod koniec Bloku II

Przykład	Co widzimy?	Co z tego wyniknie później?
Moneta	brak pamięci, brak trendu	model odniesienia dla niezależności i prostych testów
Spółka Alfa	możliwa pamięć w zmienności, słaba przewidywalność średniej	pomost do ARIMA, ARCH, GARCH i diagnostyki reszt
Stacja Olsztyn	trend, możliwa sezonowość, niestacjonarność	pomost do różnicowania, ARIMA sezonowego i prognoz warunkowych

Kluczowy ciąg pojęciowy po Bloku II



Najważniejsze efekty dydaktyczne

Po tym bloku student powinien rozumieć

- skąd biorą się podstawowe obiekty rachunku prawdopodobieństwa,
- jak opisywać dane przez momenty i rozkład,
- dlaczego testowanie hipotez nie jest tylko formalnością,
- czemu stacjonarność trzeba traktować jako warunek jakości danych,
- czym różni się prognoza poziomu od prognozy ryzyka.

Najważniejszy pomost do następnego bloku

W Bloku III pytanie będzie już brzmiało:

jak z danych wyznaczyć parametry modelu w sposób systematyczny i optymalny?

Czyli przechodzimy do **optymalizacji, likelihood i MLE**.

Od tego momentu student powinien widzieć, że
modelowanie szeregów czasowych to jednocześnie
prognoza przyszłej wartości
i
prognoza niepewności tej wartości.

To jest centralny pomost do ARIMA i GARCH

ARIMA modeluje głównie **średnią warunkową**, a GARCH głównie **wariancję warunkową**.

Prawdopodobieństwo i momenty

Fundament pod regresję, ARIMA, GARCH i później MLE

Dr hab. Andrzej Jankowski, Profesor UWM

Instytut Informatyki, UWM

13 kwietnia 2026