

Ugruntowanie zrozumienia podstawowych pojęć dotyczących analizy i konstruowania modeli czasowych

dr hab. A. Jankowski

Instytut Informatyki UWM

27 kwietnia, 2026

Ugruntowanie podstawowych pojęć:
Proces, szereg, stacjonarność, biały szum

Plan bloku ugruntowującego podstawowe pojęcia

- 1 Proces stochastyczny — definicja formalna
- 2 Szereg czasowy — **dwa rozumienia**, dwa języki
- 3 Determinizm jako proces o zerowej wariancji
- 4 Stacjonarność: ścisła i słaba
- 5 Funkcja autokowariancji $\gamma(h)$, autokorelacji $\rho(h)$
- 6 Biały szum — hierarchia trzech wariantów
- 7 Ergodyczność (rozszerzenie)
- 8 Trzy modelowe przykłady: rzut monetą, błędzenie losowe, AR(1)
- 9 Spojrzenie na dane: SPY, Olsztyn, trzy tickery

Proces stochastyczny — definicja formalna

Definicja 1.1

Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną i T — niepustym zbiorem indeksów. *Procesem stochastycznym* nazywamy rodzinę

$$\{X_t\}_{t \in T}$$

zmiennych losowych $X_t : \Omega \rightarrow \mathbb{R}$ (lub $\mathbb{R}^d$).

Trzy istotne składniki:

- **Wspólna przestrzeń** $(\Omega, \mathcal{F}, \mathbb{P})$ — pozwala mówić o niezależności, korelacji, ergodyczności.
- **Zbiór indeksów** T — u nas zawsze $T \subseteq \mathbb{Z}$ (czas dyskretny).
- **Wartości** — u nas rzeczywiste lub wektorowe rzeczywiste.

Trajektoria (realizacja): dla ustalonego $\omega \in \Omega$ funkcja $T \ni t \mapsto X_t(\omega) \in \mathbb{R}$.

Trajektoria to jeden konkretny ciąg liczb. Proces to cała rodzina możliwych ciągów z ich prawdopodobieństwami.

Notacja stosowana w całym cyklu

Symbol	Znaczenie
X_t, Y_t	zmienne losowe procesu
x_t, y_t	obserwowane realizacje (liczby)
ε_t	innowacja, biały szum o średniej 0
σ_t^2	wariancja warunkowa (GARCH)
L	operator opóźnień, $LX_t = X_{t-1}$
ϕ_i, θ_i	parametry AR i MA
ω, α, β	parametry GARCH
λ_i	wartości własne macierzy dynamiki
$\Phi(L), \Theta(L)$	wielomiany operatora opóźnień
T	długość obserwowanej trajektorii

Krytyczna konsekwentność

X_t to **zmienna losowa**, x_t to **liczba**. Mylenie tych dwóch znaczeń to najczęstsze źródło nieporozumień w komunikacji między matematykiem a inżynierem danych.

Szereg czasowy — dwa rozumienia tego samego słowa

Definicja 1.2 — ujęcie matematyczne

Szereg czasowy to proces stochastyczny $\{X_t\}_{t \in T}$ z $T \subseteq \mathbb{Z}$.

Czyli: **szereg** $\subset$ **procesy stochastyczne**. Obiekt probabilistyczny, którego nigdy w pełni nie obserwujemy.

Definicja 1.3 — ujęcie praktyczne

Szereg czasowy to skończony, uporządkowany ciąg liczb $(x_1, x_2, \dots, x_T)$ z etykietami czasowymi. Dane, które trzymamy w pamięci.

Pogodzenie

W ujęciu praktycznym szereg *jest realizacją* (trajektorią) procesu z ujęcia matematycznego:

$$\underbrace{(x_1, \dots, x_T)}_{\text{szereg w sensie praktyka}} = \underbrace{(X_1(\omega), \dots, X_T(\omega))}_{\text{realizacja procesu}} \quad \text{dla pewnego, niedostępnego nam, } \omega.$$

Te same pytania w dwóch językach

Matematyk pyta:

“Czy proces jest stacjonarny?”

“Czy proces ma skończony drugi moment?”

“Jaka jest gęstość spektralna?”

“Czy estymator $\hat{\phi}$ jest zgodny?”

Praktyk DS/ML pyta:

“Czy mogę bez problemu trenować model na pierwszej połowie i testować na drugiej?”

“Czy mogę liczyć MSE w sposób klasyczny?”

“Czy widzę cykle w periodogramie i o jakiej częstotliwości?”

“Czy moja prognoza ma sens dla rosnącej próbki?”

Dydaktyczna zasada cyklu

W każdym wierszu *oba* pytania to to samo pytanie sformułowane w innym języku. Świadomość tej tożsamości jest jednym z głównych celów dydaktycznych cyklu.

Proces stochastyczny vs realizacja: Proste intuicyjne przykłady

Proces stochastyczny vs realizacja

Poziom teoretyczny

$$(X_t)_{t \in T}$$

Proces stochastyczny to rodzina zmiennych losowych uporządkowanych w czasie.

To model probabilistyczny opisujący, *jakie trajektorie są możliwe* oraz z jakim prawdopodobieństwem mogą się pojawić.

Poziom empiryczny

$$(x_1, x_2, \dots, x_n)$$

Realizacja (trajektoria) to jedna konkretna ścieżka wygenerowana przez proces.


To nasze dane: liczby zapisane w pliku CSV lub XLSX.

Uwaga terminologiczna

W literaturze słowo *szereg czasowy* bywa używane zarówno dla procesu, jak i dla jego realizacji. Dlatego na zajęciach zawsze rozróżniamy:

wielkie X_t vs małe x_t .

Jedna obserwacja to tylko jedna z wielu możliwych trajektorii



Intuicja: Proces stochastyczny wyznacza **rozkład na przestrzeni wszystkich ścieżek (trajektorii)**

My obserwujemy tylko **jedną** z nich.

Dlaczego to ważne?

To od razu tłumaczy problem statystyki szeregów czasowych: z jednej ścieżki próbujemy wnioskować o całym mechanizmie

Zabawkowy przykład: ten sam obiekt z dwóch perspektyw

Proces

Rozważmy model

$$X_t = \cos\left(\frac{2\pi t}{12}\right) + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2).$$

Proces mówi nam, że istnieje **deterministyczna fala** oraz **losowe zakłócenie**.

Jedna realizacja

Po wylosowaniu konkretnych wartości ε_t dostajemy np.

$$x_1 = 0.91, x_2 = 0.36, x_3 = -0.08, x_4 = -0.72, \dots$$

czyli zwykły ciąg liczb.

Morał

Ten sam obiekt można opisać:

- jako **wzór probabilistyczny** — język procesu,
- jako **konkretną sekwencję liczb** — język realizacji.

Przykład 1: temperatura w Olsztynie

Proces

Matematyczny opis mechanizmu generującego temperaturę:

- sezonowość dobową,
- sezonowość roczną,
- lokalne zakłócenia pogodowe.

W praktyce modelujemy więc **średni profil** plus **reszty losowe**.

Realizacja

Konkretne odczyty godzinowe x_t z lat 2023–2025 zapisane w pliku z danymi.

To jedna ścieżka wygenerowana przez rzeczywisty układ atmosferyczny.

Postawa metodologiczna

Nie utożsamiamy modelu z rzeczywistością. Przyjmujemy zasadę Boxa:

“All models are wrong, but some are useful.”

Przykład 2: AAPL — ceny, przyrosty i log-zwroty

Proces

Modelowy opis układu ekonomiczno-finansowego:

- informacje o firmie,
- nastroje inwestorów,
- szoki rynkowe.

Realizacja

Wykres, który widzimy w danych giełdowych, to tylko jedna zaobserwowana trajektoria.

Bardzo ważne rozróżnienie

- **Ceny** P_t są zwykle silnie zależne od przeszłości i niestacjonarne.
- **Log-zwroty** $r_t = \log(P_t/P_{t-1})$ bywają dużo bliższe białemu szumowi w średniej.

To właśnie log-zwroty modelujemy dalej modelami AR/MA/ARMA.

Dlaczego teoria szeregów czasowych jest trudniejsza niż klasyczna statystyka?

Klasyczna statystyka i.i.d.

Mamy wiele niezależnych obserwacji:

$$Y_1, \dots, Y_n \stackrel{iid}{\sim} F.$$

Każda obserwacja jest kolejną replikacją z tej samej populacji.

Szeregi czasowe

Mamy zwykle jedną realizację:

$$x_1, \dots, x_n,$$

a kolejne obserwacje są ze sobą zależne w czasie.

Po co potem stacjonarność i ergodyczność?

- **stacjonarność** pozwala traktować różne momenty czasu jako porównywalne,
- **ergodyczność** uzasadnia przechodzenie od średnich po czasie do średnich po realizacjach.

Podsekcja 1. Modele regresji harmonicznej

Idea

Regresja harmoniczna opisuje **deterministyczną sezonowość** przez funkcje sinus i cosinus.

Dlaczego jest naturalna dla pogody?

Dla Olsztyna okresy są znane i fizycznie stabilne:

24 godziny, 365.25 dnia.

Dlaczego jest słaba dla AAPL?

Dla log-zwrotów AAPL nie widać stabilnej sezonowości w średniej. Dopasowanie harmoniczne pełni tu głównie rolę **negatywnego testu**: pokazuje, że wzorzec sezonowy jest znikomy.

Regresja harmoniczna — pogoda w Olsztynie

$$y_t = \beta_0 + \beta_1 \sin \frac{2\pi h_t}{24} + \beta_2 \cos \frac{2\pi h_t}{24} + \beta_3 \sin \frac{2\pi d_t}{365.25} + \beta_4 \cos \frac{2\pi d_t}{365.25} + u_t$$

Parametr	Estymata	se	t	Interpretacja
β_0	+9.544	0.025	+383.7	średni poziom
β_1	-2.139	0.035	-60.8	sin dobowy
β_2	-2.081	0.035	-59.2	cos dobowy
β_3	-3.128	0.035	-88.9	sin roczny
β_4	-9.441	0.035	-268.4	cos roczny

Najważniejsze liczby

Amplituda dobowa $\approx 2.98^\circ\text{C}$, amplituda roczna $\approx 9.95^\circ\text{C}$, $R^2 \approx 0.768$.

Regresja harmoniczna — AAPL

Dla log-zwrotów AAPL dopasowano prosty model roczny:

$$r_t = \alpha_0 + \alpha_1 \sin \frac{2\pi d_t}{365.25} + \alpha_2 \cos \frac{2\pi d_t}{365.25} + \varepsilon_t.$$

Parametr	Estymata	Komentarz
α_0	+0.001054	średnia dzienna
α_1	−0.000467	bardzo mały efekt
α_2	−0.000567	bardzo mały efekt
R^2	0.0010	praktycznie zero
$\hat{\sigma}^2$	0.000258	niemal jak bez modelu

Wniosek

Regresja harmoniczna ma sens dla **pogody**, natomiast dla **AAPL** nie wyjaśnia istotnej części średniej. To zgodne z wcześniejszą obserwacją o braku sezonowości w log-zwrotach.

Podsekcja 2. Modele AR

Definicja

Model autoregresyjny rzędu p ma postać

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t.$$

Intuicja

AR modeluje **pamięć stanu**: przyszłość zależy od własnej przeszłości procesu.

Jak czytać wyniki?

Patrzemy równocześnie na:

- estymaty parametrów,
- $\hat{\sigma}^2$,
- BIC / AIC,
- sens merytoryczny modelu.

Modele AR — pogoda vs AAPL

Szereg	Model	Parametry AR	$\hat{\sigma}^2$	BIC
Pogoda	AR(1)	$\phi_1 = 0.984$	0.512	57 059
Pogoda	AR(2)	$\phi_1 = 1.486, \phi_2 = -0.510$	0.378	49 121
Pogoda	AR(3)	$\phi_1 = 1.463, \phi_2 = -0.441, \phi_3 \approx -0.05$	0.378	49 071
AAPL	AR(1)	$\phi_1 = 0.057$	0.000256	-4054.4
AAPL	AR(2)	$\phi_1 = 0.054, \phi_2 = 0.058$	0.000255	-4050.3
AAPL	AR(3)	$\phi_1 = 0.057, \phi_2 = 0.061, \phi_3 = -0.061$	0.000254	-4046.5

Pogoda

Silna lokalna pamięć. Przejście z AR(1) do AR(2) daje ogromną poprawę.

AAPL

Współczynniki są bardzo małe; średnia log-zwrotów pozostaje bliska białemu szumowi.

Podsekcja 3. Modele MA

Definicja

Model średniej ruchomej rzędu q ma postać

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Intuicja

MA modeluje **pamięć szoków**: dzisiejsza obserwacja zależy od bieżącego i przeszłych zaburzeń.

Ważna różnica względem AR

W MA występują nieobserwowane błędy ε_t , dlatego estymacja jest trudniejsza i opiera się na MLE numerycznym.

Modele MA — pogoda vs AAPL

Szereg	Model	Parametry MA	$\hat{\sigma}^2$	BIC
Pogoda	MA(1)	$\theta_1 = 0.929$	4.74	115 597
Pogoda	MA(2)	$\theta_1 = 1.439, \theta_2 = 0.802$	2.00	92 920
AAPL	MA(1)	$\theta_1 = 0.051$	0.000256	-4054.1
AAPL	MA(2)	$\theta_1 = 0.060, \theta_2 = 0.074$	0.000255	-4051.2

Pogoda

Czyste MA wypada zdecydowanie gorzej niż AR. To sygnał, że sama pamięć szoków nie wystarcza do opisu lokalnej dynamiki temperatury.

AAPL

Dopasowanie formalnie jest możliwe, ale poprawa względem modelu bez struktury średniej jest znikoma.

Podsekcja 4. Modele ARMA

Definicja

Model mieszany łączy pamięć stanu i pamięć szoków:

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Dlaczego ARMA?

AR jest dobry dla **dłuższej pamięci**, MA dla **szybkich korekt**. ARMA pozwala modelować oba mechanizmy jednocześnie.

Modele ARMA — pogoda w Olsztynie

Model	Parametry	$\hat{\sigma}^2$	BIC
ARMA(1,1)	$\phi_1 = 0.976, \theta_1 = 0.411$	0.409	51 183
ARMA(2,1)	$\phi_1 = 1.615, \phi_2 = -0.637, \theta_1 = -0.148$	0.379	49 155
ARMA(2,2)	$\phi_1 = 1.633, \phi_2 = -0.654, \theta_1 = -0.164, \theta_2 = -0.021$	0.379	49 193

Wniosek

Najlepszy BIC w całej siatce ma tu nadal **AR(2)**. Modele ARMA są blisko, ale nie dają przewagi wystarczającej, by uzasadnić większą złożoność.

Modele ARMA — AAPL

Model	Parametry	$\hat{\sigma}^2$	BIC
ARMA(1,1)	$\phi_1 = 0.903, \theta_1 = -0.913$	0.000257	-4045.7
ARMA(2,1)	$\phi_1 = -0.501, \phi_2 = 0.093, \theta_1 = 0.558$	0.000255	-4045.2
ARMA(2,2)	$\phi_1 = 1.057, \phi_2 = -0.988, \theta_1 = -1.043, \theta_2 = 1.000$	0.000249	-4049.3

Ostrożność metodologiczna

Dla AAPL najbardziej sensowny pozostaje model **ARMA(0,0)** z wcześniejszej prezentacji. Modele bogatsze potrafią generować parametry bliskie brzegowi stacjonarności lub near-cancellation, mimo że ekonomicznie nie niosą istotnej informacji prognostycznej.

Synteza porównawcza: dwa światy, dwie logiki modelowania

Aspekt	Pogoda w Olsztynie	AAPL (log-zwroty)
Sezonowość w średniej	silna, deterministyczna	praktycznie brak
Pierwszy sensowny krok	regresja harmoniczna	praca bezpośrednio na r_t
Dominująca pamięć	pamięć średniej / lokalna bezwładność	średnia bliska białemu szumowi
Która klasa modeli pomaga?	harmoniczna + AR(2) / proste ARMA	najczęściej bardzo prosty model średniej
Pułapka dydaktyczna	mylenie sezonowości z pamięcią AR	mylenie cen z log-zwrotami

Najważniejsza lekcja

Nie dobieramy modelu dlatego, że jest bardziej skomplikowany. Dobieramy go dlatego, że odpowiada **strukturze danych i naturze zjawiska**.

Determinizm jako proces o zerowej wariancji

Definicja 1.4

Proces $\{X_t\}$ jest *deterministyczny*, jeżeli istnieje funkcja $f : T \rightarrow \mathbb{R}$ taka, że $\mathbb{P}(X_t = f(t) \text{ dla każdego } t) = 1$.

Równoważnie: $\text{Var}(X_t) = 0$ dla każdego t .

Po co o tym wspominać?

- Każda **prognoza** $\mathbb{E}[X_{T+h} \mid \mathcal{F}_T]$ jest *deterministyczna* (funkcja).
- Każda **średnia warunkowa** w modelu (komponent “signal”) jest deterministyczna.
- Dekompozycja $X_t = \mu_t + \varepsilon_t$ to dekompozycja na komponent deterministyczny (μ_t) plus losowy (ε_t).

Zapowiedź bloku 5

Regresja harmoniczna dla godzinowej temperatury w Olsztynie:

$$\mu_t = a_0 + a_1 \sin(\omega_{\text{rok}} t) + b_1 \cos(\omega_{\text{rok}} t) + a_2 \sin(\omega_{\text{doba}} t) + b_2 \cos(\omega_{\text{doba}} t)$$

opisuje dominujący komponent *deterministyczny*; reszta ε_t idzie do modelu stochastycznego.

Stacjonarność słaba (kowariancyjna)

Definicja 1.5

Proces $\{X_t\}_{t \in \mathbb{Z}}$ z $\mathbb{E}|X_t|^2 < \infty$ jest *słabo stacjonarny*, jeżeli zachodzą **trzy warunki**:

- (SS1) **stała średnia**: $\mathbb{E}[X_t] = \mu$ dla każdego t ,
- (SS2) **stała wariancja**: $\text{Var}(X_t) = \sigma^2$ dla każdego t ,
- (SS3) **kowariancja zależy tylko od opóźnienia**: $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$.

Funkcja $\gamma : \mathbb{Z} \rightarrow \mathbb{R}$ z (SS3) — *funkcja autokowariancji* procesu. Zauważmy: $\gamma(0) = \sigma^2$.

Praktyka: dlaczego *słaba*, a nie *ściła*

- **Sprawdzalność**: (SS1)–(SS3) można *empirycznie* weryfikować (estymować średnią, wariancję, ACF na podpróbkach).
- **Wystarczalność**: dla AR/MA/ARMA struktura probabilistyczna sprowadza się do drugich momentów.
- **Tożsamość gaussowska**: dla procesu gaussowskiego stacjonarność słaba $\equiv$ ściła.

Stacjonarność ścisła vs. słaba

Definicja stacjonarności ścisłej

$\{X_t\}$ jest *ściśle stacjonarny*, jeżeli dla każdego $k \geq 1$, każdych $t_1 < \dots < t_k$ i każdego $h \in \mathbb{Z}$:

$$(X_{t_1}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_k+h}).$$

Cała struktura probabilistyczna jest niezmiennicza ze względu na przesunięcie w czasie.

Twierdzenie 1.1

Stacjonarność ścisła $\Rightarrow$ stacjonarność słaba (przy $\mathbb{E}|X_t|^2 < \infty$).

Implikacja odwrotna nie zachodzi.

Kontrprzykład: ciąg niezależnych zmiennych z naprzemiennie $\mathcal{N}(0, 1)$ i Studenta t_5 przeskalowanym do wariancji 1 — pierwsze dwa momenty zgodne, ale rozkłady się różnią.

Konwencja kursu: gdy mówimy “stacjonarność” bez przymiotnika, mamy na myśli słabą.

Autokowariancja $\gamma(h)$ i autokorelacja $\rho(h)$

Definicje

- *Funkcja autokowariancji*: $\gamma(h) = \text{Cov}(X_t, X_{t+h})$ (nie zależy od t).
- *Funkcja autokorelacji (ACF)*: $\rho(h) = \frac{\gamma(h)}{\gamma(0)}$ (gdy $\gamma(0) > 0$).

Własności ACF (do sprawdzenia jako ćwiczenie elementarne):

- (i) $\rho(0) = 1$,
- (ii) $\rho(-h) = \rho(h)$ (symetria),
- (iii) $|\rho(h)| \leq 1$ dla każdego h (Cauchy–Schwarz).

Po co ACF w kursie?

ACF będzie **głównym narzędziem identyfikacyjnym** w bloku 4: na jej kształcie odróżnimy AR (geometryczne zanikanie), MA (urywanie po q) i ARMA (mieszanka).

Biały szum — hierarchia trzech wariantów

Definicja 1.6

$\{\varepsilon_t\}_{t \in \mathbb{Z}}$ jest *białym szumem* $WN(0, \sigma^2)$, jeżeli:

- (BS1) $\mathbb{E}[\varepsilon_t] = 0$ (White Noise) dla każdego t ,
- (BS2) $\text{Var}(\varepsilon_t) = \sigma^2$ dla każdego t (ze $0 < \sigma^2 < \infty$),
- (BS3) $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ dla $t \neq s$.

Hierarchia ścisła:

biały szum gaussowski $\subsetneq$ IID biały szum $\subsetneq$ biały szum

Pułapka, do której wracamy w bloku 6

Nieskorelowanie (BS3) jest *istotnie słabsze* niż **niezależność**. Można skonstruować proces, w którym

$$\text{Cov}(\varepsilon_t, \varepsilon_{t+1}) = 0, \quad \text{ale} \quad \text{Cov}(\varepsilon_t^2, \varepsilon_{t+1}^2) \neq 0.$$

To jest dokładnie konstrukcja **ARCH/GARCH** z bloku 6.

ACF białego szumu i pochodzenie nazwy

ACF białego szumu — wzorzec referencyjny

$$\gamma(h) = \begin{cases} \sigma^2 & h = 0 \\ 0 & h \neq 0 \end{cases}, \quad \rho(h) = \begin{cases} 1 & h = 0 \\ 0 & h \neq 0 \end{cases}.$$

“Palik” o wysokości 1 w zerze i zera wszędzie indziej.

Strategia diagnostyczna w blokach 4 i 7

Po dopasowaniu modelu do szeregu chcemy, żeby *reszty* $\hat{\varepsilon}_t$ miały taki właśnie kształt ACF. To formalizujemy testem *Ljunga–Boxa* w bloku 7.

Skąd nazwa “biały”? Z analogii do światła białego: w bloku 9 zobaczymy, że *gęstość spektralna* białego szumu jest stała na całym przedziale częstotliwości. Tak jak światło białe zawiera wszystkie kolory w tej samej proporcji, biały szum zawiera wszystkie częstotliwości w tej samej proporcji.

Ergodyczność — kiedy średnia czasowa = średnia probabilistyczna

Pytanie centralne ★ dla ambitnych

Estymując średnią procesu, używamy

$$\bar{X}_T = \frac{1}{T} \sum_{t=1}^T X_t \quad (\text{średnia po czasie z jednej trajektorii}).$$

Chcemy estymować $\mu = \mathbb{E}[X_t]$ (średnia po przestrzeni probabilistycznej). Co gwarantuje, że jedno zbiega do drugiego?

Twierdzenie ergodyczne, wersja L^2

Niech $\{X_t\}$ będzie procesem słabo stacjonarnym z $\mathbb{E}[X_t] = \mu$ i autokowariancją γ . Jeżeli $\frac{1}{T} \sum_{h=0}^{T-1} \gamma(h) \rightarrow 0$ przy $T \rightarrow \infty$, to $\bar{X}_T \rightarrow \mu$ w sensie L^2 .

Co warto zapamiętać: wszystkie modele cyklu (AR z $|\phi| < 1$, MA, ARMA, GARCH stabilny) są *ergodyczne* — estymacja z jednej trajektorii ma sens. Wyjątek (blok 5): proces z pierwiastkiem jednostkowym.

Błądzenie losowe — pierwszy przykład niestacjonarności

Konstrukcja

$\{\varepsilon_t\}_{t \geq 1}$ — IID biały szum o wariancji σ^2 , $X_0 = 0$. Definiujemy:

$$X_t = X_{t-1} + \varepsilon_t = \sum_{s=1}^t \varepsilon_s.$$

Sprawdzamy stacjonarność:

- **Średnia:** $\mathbb{E}[X_t] = 0$ ✓ (warunek (SS1) spełniony)
- **Wariancja:** korzystając z niezależności,



$$\text{Var}(X_t) = \sum_{s=1}^t \text{Var}(\varepsilon_s) = t\sigma^2.$$

Wariancja rośnie liniowo z czasem — warunek (SS2) **naruszony!**

Wniosek

Błądzenie losowe **nie jest** stacjonarne. Jest naszym pierwszym konkretnym przykładem procesu niestacjonarnego, do którego wrócimy w bloku 5 jako wzorca dla pojęcia *pierwiastek jednostkowy* ($\lambda = 1$).

Weryfikacja symulacyjna: 1000 trajektorii błędzenia losowego



Empirycznie potwierdzona teoria

Dla $T = 200$, $\sigma^2 = 1$ teoria przewiduje $\text{Var}(X_T) = T\sigma^2 = 200$. Empirycznie z 1000 replikacji: $\widehat{\text{Var}}(X_{200}) = 200,23$. Zgodność doskonała.

Komentarz dydaktyczny. W panelu (a) widać, że *pojedyncza* trajektoria może wyglądać niewinnie. Dopiero zestawienie wielu trajektorii pokazuje, że *rozkład w czasie* się zmienia. Inżynier ML, mając w ręku tylko jedną trajektorię, mógłby tego nie zauważyć.

AR(1) — pierwszy konkretny stacjonarny proces

Konstrukcja

$|\phi| < 1$, $\{\varepsilon_t\} \sim \text{WN}(0, \sigma^2)$ IID. Rekurencja:

$$X_t = \phi X_{t-1} + \varepsilon_t.$$

Heurystyczne sprawdzenie warunków (SS1)–(SS3), zakładając stacjonarność:

- **Średnia:** $\mu = \phi\mu + 0 \Rightarrow (1 - \phi)\mu = 0 \Rightarrow \mu = 0$.
- **Wariancja:** $\sigma_X^2 = \phi^2 \sigma_X^2 + \sigma^2 \Rightarrow \sigma_X^2 = \frac{\sigma^2}{1 - \phi^2}$. Dla $\phi = 0,5$, $\sigma^2 = 1$: $\sigma_X^2 \approx 1,333$.
- **Autokowariancja:** $\gamma(h) = \phi^h \sigma_X^2$ dla $h \geq 0$. **ACF:** $\rho(h) = \phi^{|h|}$.

Powiązanie z wartością własną — pierwsze pojawienie

Rekurencja $X_t = \phi X_{t-1} + \varepsilon_t$ to skalarny układ z “macierzą” $A = (\phi)$ rozmiaru 1×1 . Jedyna wartość własna to $\lambda = \phi$. Warunek $|\phi| < 1$ to dokładnie $|\lambda| < 1$.

Ten sam wzór będzie się powtarzał dla AR(2), AR(p) i GARCH.

D1.1. Spojrzenie na log-zwroty SPY

Dane: yahoo_finance_daily, kolumna Log_Return, ticker SPY, $T = 750$ obserwacji dziennych (2023-2025).



Wielkość	Wartość
średnia $\bar{x}$	+0,000839
odch. std. s	+0,009630
wariancja s^2	+0,000093
skośność	+0,603
kurtoza nadwyżkowa	+18,06
min	-0,060
max	+0,100
JB statystyka	10 239,1
JB p -wartość	≈ 0

Co już teraz widać

- Średnia dodatnia, ale blisko zera ($\sim 0,08\%/dz.$)
- $s \approx 1\%$ dziennie — skala dla GARCH-a (blok 6)
- **Kurtoza ≈ 18** — bardzo ciężkie ogony, daleko od normalności
- Test Jarque–Bera: $H_0 : \mathcal{N}$ silnie odrzucone

Implikacja dla bloku 6: użyjemy rozkładu Studenta- t jako rozkładu warunkowego innowacji.

D1.1. Wykres log-zwrotów SPY (2023–2025)




Test (nieformalny) stacjonarności — po podokresach

Podokres	n	średnia	wariancja
2023 (cały rok)	249	+0,000951	0,000068
2024 (cały rok)	252	+0,000882	0,000063
2025 (cały rok)	249	+0,000685	0,000149

Wariancja w 2025 jest **ponad dwa razy większa** niż w 2024. Zapowiedź *klastrowania zmienności* z bloku 6.

D1.2. Temperatura w Olsztynie — dramatyczna niestacjonarność




Test (nieformalny) stacjonarności: styczeń vs. lipiec, dla każdego roku osobno

Rok	średnia sty.	wariancja sty.	średnia lip.	wariancja lip.
2023	+1,91 °C	15,43	+18,63 °C	15,95
2024	-2,15 °C	25,56	+20,03 °C	17,24
2025	+1,34 °C	9,73	+18,17 °C	13,76

Średnia różni się o $\sim 18^{\circ}\text{C}$ między styczniem a lipcem. Wariancja styczniowa: **2–3-krotnie** między latami. Surowy szereg jest wyraźnie niestacjonarny — naprawiamy w bloku 5.

D1.3. Trzy tickery jako trzy realizacje? Niezupełnie.



Statystyki sumaryczne

Ticker	$\bar{x}$	s
SPY	0,000839	0,00963
AAPL	0,001061	0,01604
MSFT	0,000979	0,01457

Korelacje par log-zwrotów

	SPY	AAPL	MSFT
SPY	1,000	0,690	0,672
AAPL	0,690	1,000	0,486
MSFT	0,672	0,486	1,000

Wniosek: korelacje 0,49–0,69 wykluczają niezależne realizacje. Mamy proces wektorowy $(X_t^{\text{SPY}}, X_t^{\text{AAPL}}, X_t^{\text{MSFT}})$, jego *jedna* trójwymiarowa trajektoria.

Ugruntowanie zrozumienia podstawowych pojęć dotyczących analizy i konstruowania modeli czasowych

dr hab. A. Jankowski

Instytut Informatyki UWM

27 kwietnia, 2026