

ARMA

Dr hab. Andrzej Jankowski

Instytut Informatyki, Uniwersytet Warmińsko-Mazurski w Olsztynie

4 maja 2026

Cel prezentacji

Cel dydaktyczny

Ten cykl bloków nie ma nauczyć zapamiętywania nazw modeli. Ma nauczyć **procedury diagnostycznej**: najpierw patrzymy na dane, potem usuwamy oczywistą strukturę sezonową, następnie dopasowujemy model ARMA i dopiero na końcu sprawdzamy reszty.

Centralny morał całego cyklu

Najpierw diagnozujemy strukturę danych, potem wybieramy model, a na końcu sprawdzamy reszty.

Trzy slogany, które będą wracać

Sezonowość pierwsza, ARMA druga.

Reszty – ostatni egzamin modelu.
model dla wariancji.

Model dla średniej $\neq$

Plan kolejnych bloków tematycznych

- 1 **Eksploracja sezonowości:** wykres, periodogram, ACF.
- 2 **Odsezonowanie regresją harmoniczną:** sinus, cosinus, amplituda, R^2 , reszty.
- 3 **AR, MA, ARMA:** definicje, intuicje, symulacje.
- 4 **Selekcja ARMA:** MLE, AIC/BIC, siatka modeli, czytanie `summary()`.
- 5 **Diagnostyka reszt:** ACF reszt, ACF kwadratów, Ljung–Box, ARCH-LM.
- 6 **Synteza procedury:** notebook, raport, test dnia tygodnia, mostek do GARCH.
- 7 **Końcowe rozwiązanie Zadania A:** raport wzorcowy dla pogody i SPY.

Rola bloku 1

blok 1 odpowiada na pytanie: **czy w danych istnieje struktura, którą powinniśmy zauważyć zanim użyjemy ARMA?**

Zadanie A – pełne sformułowanie

Dla wzorcowych danych **SPY** oraz **pogody w Olsztynie** należy wykonać następujące czynności:

- 1 Dopasować model $\text{ARMA}(p, q)$, gdzie $p, q \in \{0, 1, 2\}$.
- 2 Wybrać model na podstawie AIC oraz BIC.
- 3 Oszacować parametry metodą MLE.
- 4 Przygotować obowiązkową pisemną analizę sezonowości.
- 5 Przeprowadzić diagnostykę reszt: ACF reszt, ACF kwadratów reszt, efekt ARCH.

Minimalny zbiór produktów

- tabela AIC/BIC dla dziewięciu modeli $\text{ARMA}(p, q)$,
- wykresy ACF,
- pisemne odpowiedzi diagnostyczne,
- interpretacja poprawności modelu.

Dlaczego to zadanie jest ważne dydaktycznie?

Uczy procedury, nie tylko wzoru

Student musi połączyć:

- wizualizację danych,
- statystyczne myślenie o zależności,
- selekcję modelu,
- estymację MLE,
- diagnostykę reszt.

Uczy pokory wobec danych

Ten sam algorytm ARMA nie wystarczy dla obu szeregów:

- pogoda ma silną sezonowość średniej,
- SPY ma słabą strukturę średniej, ale silną strukturę wariancji.

Najczęstszy błąd początkującego

Od razu uruchomić `ARIMA(...)` i uznać, że wynik `summary()` jest rozwiązaniem. W tym kursie uczymy się, dlaczego to za mało.

Dane referencyjne w tym cyklu


Pogoda w Olsztynie

- plik: `olsztyn_weather_hourly.csv`,
- zmienna: `temperature_2m`,
- obserwacje godzinowe,
- okres: 2023-01-01 – 2025-12-31,
- liczba obserwacji: 26304,
- średnia: ok. $9,54^{\circ}\text{C}$,
- odchylenie standardowe: ok. $8,38^{\circ}\text{C}$.

SPY

- plik: `yahoo_finance_daily.csv`,
- filtr: `Ticker == "SPY"`,
- zmienna: `Log_Return`,
- obserwacje dzienne sesyjne,
- okres zwrotów: 2023-01-04 – 2025-12-30,
- liczba log-zwrotów: 750,
- średnia: ok. 0,000839,
- odchylenie standardowe: ok. 0,009630.

Dwa szeregi, dwie historie



Pogoda

Silna struktura sezonowa jest widoczna gołym okiem: zima–lato oraz rytmy krótsze. Tu hasło brzmi: **sezonowość pierwsza, ARMA druga.**



SPY

Log-zwroty nie mają wyraźnej sezonowości średniej. Widać jednak okresy większej i mniejszej zmienności: **burza po burzy, cisza po ciszy.**

Definicja szeregu czasowego

Definicja robocza

Szereg czasowy to obserwacje uporządkowane według czasu:

$$y_1, y_2, \dots, y_T,$$

gdzie indeks t oznacza kolejność czasową: godzinę, dzień, sesję giełdową, miesiąc itd.

Interpretacja

W szeregu czasowym kolejność nie jest ozdobą. Jest częścią informacji. Temperatura o 13:00 jest zwykle bardziej podobna do temperatury o 12:00 niż do losowo wybranej temperatury z całego roku.

Pułapka

W zwykłej próbie iid można często przetasować wiersze danych i nic istotnego się nie zmienia. W szeregu czasowym przetasowanie niszczy sens zależności czasowych.

Szereg czasowy a próba iid

Próba iid

$X_1, \dots, X_n$ niezależne i z tego samego rozkładu.

- Kolejność zwykle nie ma znaczenia.
- Głównym celem jest opis rozkładu populacji.
- Typowe pytanie: jaka jest średnia populacji?

Szereg czasowy

$Y_1, \dots, Y_T$ mogą być zależne w czasie.

- Kolejność ma znaczenie.
- Liczy się pamięć, sezonowość, zmienność.
- Typowe pytanie: czy Y_t zależy od Y_{t-k} ?

Most do ARMA

ARMA jest modelem właśnie dlatego, że zakłada, iż obecna wartość może mieć związek z przeszłymi wartościami i przeszłymi szokami.

Trzy składniki: trend, sezonowość, składnik losowy

Prosty schemat myślowy

Często zaczynamy od intuicyjnego rozkładu:

$$y_t = \text{trend}_t + \text{sezonowość}_t + \text{składnik losowy}_t.$$

Trend

Długookresowy kierunek zmian.
Przykład: wzrost ceny indeksu w kilkuletnim okresie.

Sezonowość

Powtarzalny wzorec o znanym lub możliwym do wykrycia okresie.

Losowość

To, czego nie wyjaśnia trend ani sezonowość. Nie oznacza to automatycznie białego szumu.

Ważne

Ten rozkład jest modelem myślowym, nie automatyczną prawdą. Dane trzeba sprawdzić.

Definicja sezonowości

Sezonowość

Mówimy, że szereg ma **sezonowość**, gdy pewien wzorzec powtarza się regularnie co okres S :

y_{t+S} jest statystycznie podobne do y_t .

Przykłady okresów

- temperatura godzinowa: $S = 24$ godzin – rytm dobowy,
- temperatura godzinowa: $S = 8760$ godzin – rytm roczny w roku 365-dniowym,
- dane giełdowe dzienne: potencjalny rytm tygodniowy to $S = 5$ sesji, nie $S = 7$ dni kalendarzowych.

Pułapka jednostek

Nie wolno mieszać jednostek. Jeśli t liczymy w godzinach, to sezon roczny ma około $365 \cdot 24 = 8760$ kroków. Jeśli t liczymy w dniach, ma około 365 kroków.

Deterministyczna i stochastyczna sezonowość

Sezonowość deterministyczna

Wzorzec opisujemy stałą funkcją czasu, np.

$$m_t = a \sin(\omega t) + b \cos(\omega t).$$

- Dobra dla regularnych cykli.
- Naturalna dla temperatury.
- Prowadzi do regresji harmonicznej.

Sezonowość stochastyczna

Wzorzec zmienia się losowo, np. sezonowość nie jest idealnie stała w czasie.

- Może wymagać modeli SARIMA/SARIMAX.
- Może mieć zmienną amplitudę.
- W pogodzie jest to realistyczne rozszerzenie.

W Zadaniu A

Przyjmujemy prosty, dydaktyczny punkt startu: najpierw rozpoznajemy sezonowość, a w kolejnym bloku odsezonowujemy pogodę regresją harmoniczną.

Dlaczego jedna skala czasowa nie wystarczy?

Zasada

Szereg czasowy trzeba oglądać w kilku powiększeniach. Inne struktury widać w skali lat, inne w skali tygodnia, a inne w skali dwóch dób.

Pełny okres

Czy widać trend albo sezon roczny?

Tydzień

Czy widać cykl dobowy, dni nietypowe, skoki?

48 godzin


Czy lokalny mechanizm wygląda regularnie?

Pytanie diagnostyczne

Czy wzorzec, który widzę na wykresie, jest stabilny, czy tylko przypadkowy dla jednego fragmentu?

Olsztyn: pełny okres

Olsztyn: temperatura godzinowa, pełny okres




Interpretacja

W pełnym okresie widzimy wyraźny rytm roczny: wartości zimowe są systematycznie niższe niż letnie. Ten sygnał jest tak silny, że ARMA dopasowane bezpośrednio do temperatury modelowałoby głównie sezonowość, a nie resztową zależność krótkookresową.

Olsztyn: tydzień letni


Olsztyn: tydzień lipcowy - rytm dobowy na tle sezonu



Co ćwiczymy?

Patrzemy, czy w ciągu tygodnia pojawia się powtarzalny rytm dobowy: wzrost temperatury w ciągu dnia i spadek nocą. To nie jest jeszcze dowód formalny, ale bardzo mocna wskazówka.

Olsztyn: 48 godzin



Interpretacja lokalna

Na krótkim fragmencie łatwiej zobaczyć mechanikę cyklu dobowego. W praktyce wykres 48 godzin odpowiada pytaniu: czy kolejne godziny są podobne do siebie i czy po 24 godzinach wracamy do podobnej fazy dnia?

SPY: cena i log-zwroty




Cena

Cena może mieć trend i nie jest naturalnym kandydatem do prostego ARMA bez przygotowania.

Log-zwroty

W Zadaniu A modelujemy log-zwroty. Średnia jest blisko zera, ale zmienność nie jest stała.

SPY: fragment 60 sesji



Interpretacja

W log-zwrotach SPY nie widzimy tak naturalnego i stabilnego rytmu jak w temperaturze. To nie znaczy, że dane są całkowicie losowe. Oznacza raczej, że **średnia** log-zwrotów jest trudna do przewidywania prostym rytmem sezonowym.

Po co periodogram?

Intuicja

Periodogram odpowiada na pytanie: **dla jakich częstotliwości sinus i cosinus szczególnie dobrze pasują do danych?**

Slogan

Periodogram jest mapą kandydatów na sezonowość, nie ostatecznym wyrokiem.

Co zobaczymy?

Jeśli w danych istnieje mocny cykl o okresie S , to w periodogramie często pojawia się pik dla częstotliwości $f = 1/S$.

Częstotliwość i okres: najważniejszy wzór

Relacja

Jeśli f oznacza częstotliwość mierzoną w cyklach na jeden krok czasu, a S oznacza okres w krokach czasu, to

$$S = \frac{1}{f}.$$

Przykłady

- $f = 1/24$ dla danych godzinowych oznacza okres $S = 24$ godziny.
- $f = 1/8760$ dla danych godzinowych oznacza okres $S = 8760$ godzin, czyli około rok.
- $f = 1/5$ dla danych sesyjnych SPY oznacza okres $S = 5$ sesji giełdowych.

Pułapka

Dla SPY nie szukamy automatycznie okresu 7, bo giełda nie ma zwykle obserwacji w soboty i niedziele. Tydzień handlowy ma około 5 sesji.

Periodogram: czego szukamy w danych pogodowych?

Idea

Periodogram pokazuje, które częstotliwości są szczególnie silne w szeregu czasowym. W danych pogodowych oznacza to szukanie regularnych cykli, np.:

- cyklu dobowego: temperatura zmienia się między dniem i nocą,
- cyklu tygodniowego: możliwy wzorzec związany z organizacją pomiarów lub aktywnością człowieka,
- cyklu rocznego: sezonowość lato–zima.

Przykład

Dla godzinowych danych pogodowych z Olsztyna pik periodogramu przy okresie około

24

oznacza silny cykl dobowy.

Jak obliczamy periodogram?

Niech mamy szereg godzinowych temperatur:

$$x_1, x_2, \dots, x_n.$$

Najpierw odejmujemy średnią:

$$\tilde{x}_t = x_t - \bar{x}.$$

Następnie dla częstotliwości Fouriera

$$\omega_j = \frac{2\pi j}{n}, \quad j = 0, 1, \dots, n-1,$$

liczymy dyskretną transformatę Fouriera:

$$D(\omega_j) = \sum_{t=1}^n \tilde{x}_t e^{-i\omega_j t}.$$

Periodogram to kwadrat modułu tej transformaty:

$$I(\omega_j) = \frac{1}{n} |D(\omega_j)|^2.$$

Periodogram w Pythonie dla temperatury w Olsztynie

Zakładamy, że mamy wektor temperatur godzinowych:

$$x = (x_1, \dots, x_n).$$

```
import numpy as np
import matplotlib.pyplot as plt

# x = szereg godzinowych temperatur, np. Olsztyn
x = np.asarray(x)
n = len(x)

# odejmujemy srednia
x_centered = x - np.mean(x)


# transformata Fouriera
fft_values = np.fft.fft(x_centered)

# periodogram
periodogram = (1 / n) * np.abs(fft_values)**2

# czestotliwosci: cykle na jedna obserwacje
freq = np.fft.fftfreq(n, d=1)
```

Olsztyn: periodogram temperatury

Olsztyn: periodogram jako mapa kandydatów na sezonowość



Interpretacja

Wykres pokazuje mocne kandydatury na okres roczny oraz dobowy. To wspiera diagnozę z wykresów czasowych: temperatura ma silną sezonowość deterministyczną, którą trzeba potraktować przed ARMA.

Największe piki periodogramu temperatury

Okres	Moc
8768.0 h	49.48
24.0 h	4.453
24.1 h	0.5295
23.9 h	0.5234
1143.7 h	0.4799
4384.0 h	0.4346
907.0 h	0.4107
1252.6 h	0.4


Jak czytać tabelę?

Tabela pokazuje okresy o dużej mocy w periodogramie. Nie traktujemy ich jako automatycznego testu istotności, lecz jako kandydatów do dalszej interpretacji.

Dydaktyczny wniosek

Jeśli wykres, periodogram i ACF wskazują tę samą strukturę, mówimy o **triangulacji diagnozy**. To dużo mocniejsze niż pojedynczy wykres.

SPY: periodogram log-zwrotów



Interpretacja

Dla SPY periodogram nie daje tak jasnego, stabilnego obrazu sezonowości średniej jak dla temperatury. Ewentualny pik przy kilku sesjach należy traktować ostrożnie i konfrontować z testem dnia tygodnia oraz ACF.

Największe piki periodogramu SPY

Okres	Moc
10.4 d	1.534e-06
2.2 d	1.47e-06
3.4 d	1.275e-06
6.5 d	1.182e-06
9.3 d	1.169e-06
9.7 d	1.136e-06
8.1 d	9.597e-07
21.4 d	8.58e-07

Ostrzeżenie

W finansach łatwo znaleźć pozorne cykle w krótkiej próbie. Piki periodogramu dla log-zwrotów nie są automatycznym dowodem sezonowości. W Zadaniu A oczekujemy pisemnej, ostrożnej interpretacji.

Dobre sformułowanie

„W danych referencyjnych SPY nie widać silnej, stabilnej sezonowości średniej porównywalnej z sezonowością temperatury w Olsztynie.”

Kod Python: periodogram

```
import numpy as np
from scipy.signal import periodogram

# y: wektor obserwacji, np. temperatura godzinowa
x = y - np.mean(y)
freq, power = periodogram(x, fs=1.0, scaling="spectrum")

# Pomijamy freq=0, bo odpowiada składowej stałej.
period = 1 / freq[1:]
power = power[1:]

# Przykład: period blisko 24 oznacza cykl dobowy,
# a period blisko 8760 oznacza cykl roczny w danych
# godzinowych.
```

Uwaga o jednostkach

Parametr `fs=1.0` oznacza, że jeden krok czasu to jedna obserwacja. Dla temperatury jest to jedna godzina, dla SPY jedna sesja giełdowa.

Autokorelacja: pytanie o pamięć szeregu

Definicja intuicyjna

Autokorelacja dla opóźnienia k mierzy, jak silnie y_t jest liniowo związane z y_{t-k} .

Definicja dla procesu słabo stacjonarnego

Jeśli $\gamma(k) = \text{Cov}(Y_t, Y_{t-k})$, to

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}.$$

W praktyce estymujemy $\rho(k)$ z danych i rysujemy wykres ACF.

Interpretacja

Duża dodatnia ACF dla małych opóźnień oznacza, że wysokie wartości często następują po wysokich, a niskie po niskich.

ACF jako sygnatura sezonowości


Co może pokazać ACF?

- wolny spadek: długotrwała zależność albo trend/sezonowość,
- piki przy 24, 48, 72, ...: sezonowość dobową w danych godzinowych,
- piki przy 5, 10, 15, ...: możliwy rytm tygodniowy w danych sesyjnych,
- ACF blisko zera: brak wyraźnej liniowej pamięci średniej.

Pułapka

ACF blisko zera dla log-zwrotów SPY nie oznacza, że nie ma żadnej struktury. Trzeba sprawdzić ACF kwadratów zwrotów, bo struktura może mieszkać w wariancji.

Olsztyn: ACF temperatury do 14 dni




Interpretacja

ACF jest bardzo wysoka dla małych opóźnień i pokazuje ślady rytmu dobowego. Temperatura ma pamięć: jeśli teraz jest ciepło, za godzinę zwykle nadal jest podobnie.

Olsztyn: ACF średnich dobowych i sezon roczny


Olsztyn: ACF średnich dobowych - ślad sezonowości rocznej



Interpretacja

Po agregacji do średnich dobowych łatwiej zobaczyć długą strukturę roczną. To pokazuje, dlaczego dobór skali wizualizacji ma znaczenie.


SPY: ACF log-zwrotów



Interpretacja

ACF log-zwrotów jest w większości bliska zeru. To wspiera prosty model średniej, nawet $\text{ARMA}(0,0)$ w danych referencyjnych według BIC. Ale to jeszcze nie kończy diagnostyki.

SPY: ACF kwadratów log-zwrotów – zapowiedź bloku 5



Kluczowa interpretacja

Kwadraty log-zwrotów pokazują zależność. To klasyczna sytuacja finansowa: **średnia jest nieprzewidywalna, ale ryzyko jest**. Właśnie tu pojawia się most do ARCH/GARCH.

Kod Python: ACF

```
from statsmodels.graphics.tsaplots import plot_acf
import matplotlib.pyplot as plt


# ACF szeregu
plot_acf(y, lags=60)
plt.show()

# ACF kwadratów reszt lub zwrotów
u = y - y.mean()
plot_acf(u**2, lags=60)
plt.show()
```

Dydaktyczna zasada

W Zadaniu A nie wystarczy ACF oryginalnego szeregu. Po dopasowaniu modelu trzeba narysować ACF reszt oraz ACF kwadratów reszt.

Triangulacja: wykres, periodogram, ACF



Wniosek

Nie opieramy diagnozy na jednym narzędziu. Jeśli trzy narzędzia mówią podobną historię, mamy mocniejszą podstawę do decyzji modelarskiej.

Diagnoza dla pogody w Olsztynie

Wykres

Pełny okres pokazuje silny cykl roczny. Krótkie fragmenty pokazują rytm dobowy.

Periodogram

Wskazuje kandydatów na okres dobowy i roczny.

ACF

Pokazuje bardzo silną pamięć i ślady sezonowości w opóźnieniach.

Wzorcowe zdanie do raportu

„Dane pogodowe z Olsztyna wykazują silną sezonowość roczną i dobową. Dlatego bezpośrednie dopasowanie ARMA do temperatury byłoby niewłaściwe jako pierwszy krok; najpierw należy usunąć składnik sezonowy, np. regresją harmoniczną.”

Diagnoza dla SPY

Wykres

Log-zwroty oscylują wokół zera, bez jasnego cyklu średniej.

Periodogram

Nie daje jednoznacznej sezonowości porównywalnej z pogodą.

ACF

ACF zwrotów jest mała, ale ACF kwadratów wskazuje strukturę wariancji.

Wzorcowe zdanie do raportu

„Dla log-zwrotów SPY nie obserwujemy silnej sezonowości średniej. Nie oznacza to jednak braku struktury w danych: zależność pojawia się w zmienności, co sugeruje efekt ARCH i motywuje późniejsze modele GARCH.”

Jak blok 1 prowadzi do bloku 2?

Problem

Dla pogody widzimy sezonowość. ARMA jest modelem dla zależności krótkookresowej wokół średniej, a nie narzędziem do „połykania” oczywistego cyklu rocznego i dobowego bez refleksji.

Rozwiązanie w bloku 2

Zbudujemy regresję harmoniczną:

$$y_t = \beta_0 + \beta_1 \sin(\omega_y t) + \beta_2 \cos(\omega_y t) + \beta_3 \sin(\omega_h t) + \beta_4 \cos(\omega_h t) + e_t.$$

Potem ARMA będziemy dopasowywać do reszt e_t , a nie do surowej temperatury.

Slogan

Sezonowość pierwsza, ARMA druga.

Pułapki z bloku 1 – lista kontrolna

Czego nie robić?

- ❶ Nie mylić częstotliwości f z okresem S : pamiętamy $S = 1/f$.
- ❷ Nie używać okresu 7 dla SPY bez zastanowienia; dla danych sesyjnych tygodni to zwykle 5 obserwacji.
- ❸ Nie traktować periodogramu jako formalnego testu istotności.
- ❹ Nie interpretować ACF zwrotów SPY bliskiej zeru jako dowodu, że „w danych nie ma nic”.
- ❺ Nie dopasowywać ARMA do surowej temperatury bez komentarza o sezonowości.

Co powinno znaleźć się w raporcie?

Krótką, pisemną diagnozę: co widać na wykresie, co sugeruje periodogram, co potwierdza albo osłabia ACF, oraz jaka decyzja modelarska z tego wynika.

Mini-ćwiczenie dla studentów

Zadanie

Dla jednego z dwóch zbiorów danych napisz trzy zdania diagnostyczne:

- 1 Co widać na wykresie szeregu w czasie?
- 2 Jaki okres lub brak okresu sugeruje periodogram?
- 3 Czy ACF wspiera tę diagnozę?

Wersja wzorcowa – pogoda

„W pełnym szeregu temperatury widać silną sezonowość roczną, a na krótkich fragmentach rytm dobowy. Periodogram wskazuje kandydatów na okresy około 24 godzin i około roku. ACF jest wysoka dla małych opóźnień i pokazuje strukturę sezonową, dlatego przed ARMA należy zastosować odsezonowanie.”

Wersja wzorcowa – SPY

„Log-zwroty SPY oscylują wokół zera i nie pokazują wyraźnej sezonowości średniej. Periodogram nie dostarcza tak silnego sygnału jak w temperaturze. ACF log-zwrotów jest bliska zeru, ale ACF kwadratów wskazuje zależność zmienności.”

Podsumowanie bloku 1

Co już umiemy?

- odróżnić szereg czasowy od próby iid,
- nazwać trend, sezonowość i składnik losowy,
- wyjaśnić sezonowość deterministyczną i stochastyczną,
- oglądać szereg w wielu skalach,
- używać periodogramu jako mapy kandydatów na okresy,
- interpretować ACF jako miarę pamięci szeregu,
- porównać pogodę w Olsztynie i SPY.

Najważniejszy wniosek

Pogoda wymaga jawnego potraktowania sezonowości przed ARMA. SPY nie wymaga regresji harmonicznej dla średniej jako naturalnego pierwszego kroku, ale wymaga czujności wobec zmienności.

Koniec części 1

Dalszy ciąg

Koniec części 1. W następnej części kontynuujemy od bloku 2.

blok 2

Zbudujemy regresję harmoniczną dla temperatury w Olsztynie, obliczymy amplitudę roczną i dobową, zinterpretujemy R^2 oraz pokażemy, dlaczego reszty po harmonikach nie są jeszcze białym szumem.

Cel bloku 2

Po tym bloku student powinien umieć

- zbudować regresję harmoniczną dla sezonowości dobowej i rocznej,
- zrozumieć, dlaczego model z sinusami i cosinusami jest zwykłą regresją liniową,
- policzyć i zinterpretować amplitudę jednej pary $\sin / \cos$,
- zinterpretować R^2 , reszty i ograniczenia modelu harmonicznego,
- wyjaśnić, dlaczego dla SPY regresja harmoniczna zwykle nie jest naturalnym pierwszym krokiem.

Efekt praktyczny

Po bloku 2 będziemy mieli nowy szereg: **reszty po odsezonowaniu pogody**. To właśnie na tych resztach będziemy dopasowywać modele ARMA w kolejnych blokach.

Przypomnienie z bloku 1: diagnoza sezonowości

Pogoda w Olsztynie

- silny rytm roczny: zima–lato–zima,
- silny rytm dobowy: noc–dzień–noc,
- sezonowość widoczna na wykresie, periodogramie i ACF.

SPY

- log-zwroty nie mają wyraźnej sezonowości średniej,
- ACF zwrotów jest zwykle bliska zeru,
- struktura ujawnia się mocniej w wariancji, nie w średniej.

Wniosek metodyczny

Dla pogody najpierw budujemy model sezonowości. Dla SPY zwykle przechodzimy bezpośrednio do prostego modelu średniej i diagnostyki wariancji.

Wprowadzenie do regresji harmonicznej: Sinus, cosinus i przesunięcie fazowe

Punkt wyjścia

Chcemy pokazać, że kombinacja

$$a \sin(\omega t) + b \cos(\omega t)$$

jest w istocie jedną falą sinusoidalną, ale z odpowiednio dobraną amplitudą i przesunięciem.

Wzór na sinus sumy kątów

Korzystamy ze wzoru:

$$\sin(\alpha + \varphi) = \sin \alpha \cos \varphi + \cos \alpha \sin \varphi.$$

Dla $\alpha = \omega t$ otrzymujemy:

$$A \sin(\omega t + \varphi) = A \cos \varphi \sin(\omega t) + A \sin \varphi \cos(\omega t).$$

Porównanie współczynników

Jeżeli

$$a = A \cos \varphi, \quad b = A \sin \varphi,$$

to

$$a \sin(\omega t) + b \cos(\omega t) = A \sin(\omega t + \varphi).$$

Amplituda i faza

Amplituda

$$\begin{aligned}a &= A \cos \varphi, & b &= A \sin \varphi \\a^2 + b^2 &= A^2 \cos^2 \varphi + A^2 \sin^2 \varphi = A^2. \\A &= \sqrt{a^2 + b^2}.\end{aligned}$$

Amplituda A opisuje **siłę wahań sezonowych**.

Faza

Faza φ opisuje **przesunięcie fali w czasie**, czyli informuje, gdzie w cyklu wypada maksimum.

$$\begin{aligned}a &= A \cos \varphi, & b &= A \sin \varphi \\ \tan \varphi &= \frac{b}{a}.\end{aligned}$$

Interpretacja dla sezonowości: Model

$$y_t = \beta_0 + a \sin(\omega t) + b \cos(\omega t) + \varepsilon_t$$

uczy się jednocześnie:

Podsumowanie bazowych intuicji: Dlaczego sinus i cosinus?

Idea

Sezonowość oznacza powtarzalność. Najprostszy matematyczny opis powtarzalności to fala sinusoidalna:

$$\sin(\omega t), \quad \cos(\omega t).$$

Para $\sin / \cos$ pozwala modelowi nie tylko falować, ale także **przesuwać moment maksimum**.

Dlaczego dwie funkcje, a nie jedna?

Sam sinus ma maksimum w narzuconym miejscu. Kombinacja

$$a \sin(\omega t) + b \cos(\omega t)$$

pozwała dobrać zarówno **siłę wahań**, jak i **fazę**, czyli położenie maksimum w czasie.

Model harmoniczny dla temperatury w Olsztynie

Model roboczy

$$y_t = \beta_0 + \beta_1 \sin(\omega_h t) + \beta_2 \cos(\omega_h t) + \beta_3 \sin(\omega_y t) + \beta_4 \cos(\omega_y t) + e_t.$$

Rytm dobowy

$$\omega_h = \frac{2\pi}{24}.$$

Jednostką czasu jest godzina, więc okres dobowy to 24 obserwacje.

Rytm roczny

$$\omega_y = \frac{2\pi}{8760}.$$

Rok przybliżamy przez $365 \cdot 24 = 8760$ godzin.

Najważniejsza pułapka: jednostki czasu

Błąd bardzo częsty

Jeżeli t liczymy w godzinach, to nie wolno użyć

$$\omega_y = \frac{2\pi}{365}.$$

To byłaby częstotliwość roczna dla danych dziennych, a nie godzinowych.

Zasada

Okres musi być wyrażony w tej samej jednostce, w której liczony jest indeks t .

dane godzinowe: $S = 8760$, dane dzienne: $S = 365$.

Dlaczego ten model jest liniowy?

Uwaga kluczowa

Model wygląda „sinusoidalnie”, ale jest **liniowy względem parametrów**:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \beta_3 x_{3t} + \beta_4 x_{4t} + e_t,$$

gdzie

$$x_{1t} = \sin(\omega_h t), \quad x_{2t} = \cos(\omega_h t), \quad x_{3t} = \sin(\omega_y t), \quad x_{4t} = \cos(\omega_y t).$$

Konsekwencja praktyczna

Nie potrzebujemy skomplikowanej nieliniowej optymalizacji. Możemy użyć zwykłego OLS: `statsmodels.OLS(y, X).fit()`.

Macierz projektująca $\mathbf{X}$

Dla T obserwacji zapisujemy model w postaci macierzowej:


$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

$$\mathbf{X} = \begin{bmatrix} 1 & \sin(\omega_h 0) & \cos(\omega_h 0) & \sin(\omega_y 0) & \cos(\omega_y 0) \\ 1 & \sin(\omega_h 1) & \cos(\omega_h 1) & \sin(\omega_y 1) & \cos(\omega_y 1) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & \sin(\omega_h (T-1)) & \cos(\omega_h (T-1)) & \sin(\omega_y (T-1)) & \cos(\omega_y (T-1)) \end{bmatrix}.$$

Interpretacja

Każdy wiersz macierzy $\mathbf{X}$ opisuje, w jakiej fazie cyklu dobowego i rocznego znajduje się dana obserwacja.

Macierz cech harmonicznych: jak wygląda w danych?



Co widać?

Cechy dobowe wykonują pełne oscylacje co 24 godziny. Cechy roczne w pierwszym tygodniu zmieniają się bardzo powoli, bo jeden pełny cykl trwa około 8760 godzin.

OLS: co właściwie minimalizujemy?

Zwykła metoda najmniejszych kwadratów

OLS wybiera takie parametry $\hat{\beta}$, aby suma kwadratów reszt była jak najmniejsza:

$$\hat{\beta} = \arg \min_{\beta} \sum_{t=1}^T (y_t - \mathbf{x}_t^{\top} \beta)^2.$$

Wzór macierzowy

Jeżeli macierz $\mathbf{X}^{\top} \mathbf{X}$ jest odwracalna, to

$$\hat{\beta} = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{y}.$$

Kod Python: regresja harmoniczna dla Olsztyna

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

weather = pd.read_csv("olsztyn_weather_hourly.csv")
y = weather["temperature_2m"].to_numpy()
T = len(y)
t = np.arange(T)

omega_h = 2*np.pi/24          # cykl dobowy, t w godzinach
omega_y = 2*np.pi/8760        # cykl roczny, t w godzinach

X = np.column_stack([
    np.ones(T),
    np.sin(omega_h*t), np.cos(omega_h*t),
    np.sin(omega_y*t), np.cos(omega_y*t)
])

model = sm.OLS(y, X).fit()
fitted = model.fittedvalues
resid = model.resid
print(model.summary())
```

Dane referencyjne: wynik OLS dla pogody

Zmienna	Współczynnik	Błąd std.	Statystyka t
Stała β_0	9,551	0,025	384,3
$\sin(2\pi t/24)$	-2,139	0,035	-60,9
$\cos(2\pi t/24)$	-2,081	0,035	-59,2
$\sin(2\pi t/8760)$	-3,120	0,035	-88,7
$\cos(2\pi t/8760)$	-9,444	0,035	-268,8

Wartości syntetyczne

- $R^2 \approx 0,769$.
- Amplituda dobowa: około $2,98^\circ\text{C}$.
- Amplituda roczna: około $9,95^\circ\text{C}$.
- Odchylenie standardowe reszt: około $4,03^\circ\text{C}$.

Amplituda jednej pary sin/cos

Wzór

Dla jednej pary harmoniczej

$$a \sin(\omega t) + b \cos(\omega t)$$

amplituda wynosi

$$A = \sqrt{a^2 + b^2}.$$

Interpretacja

Amplituda mówi, o ile maksymalnie składnik sezonowy odchyła się od poziomu bazowego. Jeżeli amplituda dobową wynosi 3°C , to sam rytm dobowy może zmieniać oczekiwaną temperaturę mniej więcej o $\pm 3^\circ\text{C}$ wokół odpowiedniego poziomu.

Amplitudy w danych pogodowych

Rytm dobowy

$$A_h = \sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2} \approx 2,98 \text{ } ^\circ\text{C}.$$

Maksimum dobowego składnika przypada w przybliżeniu na godzinę 15,1.

Rytm roczny

$$A_y = \sqrt{\hat{\beta}_3^2 + \hat{\beta}_4^2} \approx 9,95 \text{ } ^\circ\text{C}.$$

Maksimum rocznego składnika przypada około dnia roku 201,0.

Komentarz dydaktyczny

Amplituda jest bardziej czytelna niż osobne współczynniki przy sinusie i cosinusie. Student powinien umieć przejść od pary współczynników do jednej liczby interpretowalnej w stopniach Celsjusza.

Pułapka: amplituda przy wielu harmonicznym

Czego nie robić

Nie wolno interpretować

$$\sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2 + \hat{\beta}_3^2 + \hat{\beta}_4^2}$$


jako jednej sensownej amplitudy całej sezonowości, bo mieszamy dwa różne okresy: dzień i rok.

Poprawna praktyka

Amplitudę liczymy **osobno dla każdej pary** odpowiadającej jednemu okresowi:

$$A_h = \sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2}, \quad A_y = \sqrt{\hat{\beta}_3^2 + \hat{\beta}_4^2}.$$


Składnik dobowy: przeciętny rytm dnia



Jak to czytać?

To nie jest prognoza konkretnej temperatury w danym dniu. To przeciętny wkład pory dnia do oczekiwanej temperatury w modelu harmonicznym.


Składnik roczny: przeciętny rytm sezonowy



Jak to czytać?

Model opisuje gładki cykl roczny: chłodniej zimą, cieplej latem. Nie opisuje frontów atmosferycznych, upałów ani nagłych spadków temperatury.


Dopasowanie harmoniczne: pełny okres



Wniosek

Model harmoniczny dobrze chwyta ogólny kształt sezonowości rocznej, ale nie ma ambicji opisanie wszystkich krótkookresowych zmian pogody.


Dopasowanie harmoniczne: pierwsze 14 dni



Co jest ważne?

Rytm dobowy jest obecny, ale rzeczywista pogoda ma dodatkową dynamikę. Dlatego po odsezonowaniu zostaje szereg reszt, który nie będzie białym szumem.

Dopasowanie harmoniczne: tydzień lipcowy



Ostrzeżenie

Stała amplituda dobową to uproszczenie. W rzeczywistości amplituda dobowych wahań zależy od zachmurzenia, wiatru, wilgotności i sytuacji synoptycznej.

Błąd modelu a reszta z modelu

Model teoretyczny

W regresji zakładamy, że obserwowana wartość ma postać

$$y_t = m(t) + \varepsilon_t,$$

gdzie $m(t)$ opisuje systematyczną część zjawiska, a ε_t jest **błędem losowym**.

Przykład: regresja harmoniczna

W modelu harmonicznym możemy mieć na przykład

$$m(t) = \beta_0 + a \sin(\omega t) + b \cos(\omega t).$$

Wtedy

$$y_t = \beta_0 + a \sin(\omega t) + b \cos(\omega t) + \varepsilon_t.$$

Reszta z dopasowanego modelu

Po estymacji parametrów otrzymujemy wartości dopasowane $\hat{y}_t$. Reszta to różnica:

$$\hat{e}_t = y_t - \hat{y}_t.$$

Co oznacza R kwadrat?

Definicja

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\sum_t \hat{e}_t^2}{\sum_t (y_t - \bar{y})^2}.$$

Interpretacja w naszych danych

Dla temperatury w Olsztynie model harmoniczny daje $R^2 \approx 0,769$. Oznacza to, że bardzo duża część zmienności temperatury jest związana z deterministycznym rytmem dobowym i rocznym.

Ale uwaga

Wysokie R^2 nie oznacza, że reszty są niezależne. Model może dobrze usuwać sezonowość i jednocześnie pozostawiać silną autokorelację.

Reszty po harmonikach: nowy szereg do modelowania

Reszta same w sobie generują bardzo ważny szereg związany z modelem tzw. SZEREG RESZT

$$\hat{e}_t = y_t - \hat{y}_t.$$


Interpretacja

Reszta to ta część temperatury, której nie wyjaśnia przeciętny rytm dobowy i roczny. W resztach zostają między innymi epizody pogodowe, fronty, fale ciepła, ochłodzenia i lokalna autokorelacja.

Most do bloku 3 i 4

To właśnie szereg $\hat{e}_t$ będzie wejściem do modeli ARMA w części pogodowej Zadania A.

Reszty po harmonikach: pełny okres




Wniosek

Po odjęciu gładkiej sezonowości widać epizody: kilka dni cieplejszych lub chłodniejszych niż model sezonowy. To jest naturalny kandydat do modelowania autoregresyjnego.

ACF reszt po harmonikach


ACF reszt po harmonikach: reszty nie są białym szumem



Kluczowy wniosek

Reszty po harmonikach nie są białym szumem. Odsezonowanie usuwa dużą część struktury deterministycznej, ale nie usuwa krótkookresowej zależności pogodowej.


Rozkład reszt: histogram



Komentarz

Histogram pomaga zobaczyć skalę typowych błędów modelu sezonowego. Nie zastępuje jednak diagnostyki ACF ani testów reszt.

Q-Q plot jako rozszerzenie



Po co to oglądać? ★ dla ambitnych

Q-Q plot pokazuje, czy rozkład reszt przypomina rozkład normalny. W Zadaniu A normalność nie jest głównym kryterium, ale pomaga zrozumieć ograniczenia prostego modelu.

Na czym polega odsezonowanie szeregu?

Idea

Odsezonowanie polega na usunięciu z szeregu czasowego regularnych, powtarzalnych wahań sezonowych.

Przykład: pogoda

W temperaturze powietrza w Olsztynie obserwujemy zwykle rytm dobowy oraz rytm roczny.

Cel

$\text{dane odsezonowane} = \text{dane oryginalne} - \text{oszacowana sezonowość}.$

Model: średni poziom, sezonowość i błąd

Model teoretyczny

Temperaturę w chwili t możemy zapisać jako:

$$y_t = \mu + s_t + \varepsilon_t,$$

gdzie:

μ – średni poziom, s_t – sezonowość, ε_t – błąd losowy.

Interpretacja pogodowa

Składnik s_t opisuje typowy rytm:

noc–dzień, zima–lato.

Błąd ε_t opisuje to, czego model sezonowy nie wyjaśnia.

Odsezonowanie przez odjęcie sezonowości

Krok 1: estymujemy sezonowość

Na podstawie danych budujemy model sezonowości:

$$\hat{s}_t.$$

Krok 2: odejmujemy sezonowość

Szereg odsezonowany definiujemy jako:

$$y_t^{\text{odsez}} = y_t - \hat{s}_t.$$

Znaczenie

Po odjęciu $\hat{s}_t$ widzimy, czy dana obserwacja była wyższa lub niższa niż wynikałoby z typowego rytmu sezonowego.

Przykład harmoniczny dla temperatury

Rytm dobowy

Dla danych godzinowych rytm dobowy można opisać przez:

$$s_t^{(doba)} = a_1 \sin\left(\frac{2\pi t}{24}\right) + b_1 \cos\left(\frac{2\pi t}{24}\right).$$

Rytm roczny

Rytm roczny dla danych godzinowych można opisać przez:

$$s_t^{(rok)} = a_2 \sin\left(\frac{2\pi t}{365 \cdot 24}\right) + b_2 \cos\left(\frac{2\pi t}{365 \cdot 24}\right).$$

Łączna sezonowość

$$\hat{s}_t = \hat{s}_t^{(doba)} + \hat{s}_t^{(rok)}.$$

Odsezonowanie a reszty modelu

Dopasowany model

Jeżeli po estymacji mamy:

$$\hat{y}_t = \hat{\mu} + \hat{s}_t,$$

to reszta modelu wynosi:

$$\hat{e}_t = y_t - \hat{y}_t = y_t - (\hat{\mu} + \hat{s}_t).$$

Szereg odsezonowany

Odsezonowanie zwykle oznacza odjęcie tylko sezonowości:

$$y_t^{\text{odsez}} = y_t - \hat{s}_t.$$

Ważna zależność

$$y_t^{\text{odsez}} = y_t - \hat{s}_t = \hat{\mu} + \hat{e}_t.$$

Dlaczego odsezonowane dane to nie zawsze reszty?

Reszty

Reszty powstają po odjęciu całej wartości dopasowanej:

$$\hat{e}_t = y_t - (\hat{\mu} + \hat{s}_t).$$

Dane odsezonowane

Dane odsezonowane powstają po odjęciu tylko sezonowości:

$$y_t^{\text{odsez}} = y_t - \hat{s}_t.$$

Wniosek

dane odsezonowane = średni poziom + reszty

w modelu:

$$y_t = \mu + s_t + \varepsilon_t.$$

Co zostaje po odsezonowaniu?

Przed odsezonowaniem

W oryginalnym szeregu temperatury dominują regularne wzorce:

cieplej w dzień, chłodniej w nocy, cieplej latem, chłodniej zimą.

Po odsezonowaniu

Po odjęciu $\hat{s}_t$ łatwiej zauważyć:

- nietypowo ciepłe lub zimne dni,
- fale upałów i ochłodzenia,
- anomalie pogodowe,
- pozostałą autokorelację.

Ważne

Odsezonowanie nie oznacza usunięcia całej struktury z danych. Usuwamy tylko tę część, którą model uznał za sezonową.

Czy możemy wierzyć klasycznym błędom standardowym OLS?

Problem

Klasyczny output OLS zakłada między innymi, że reszty są nieskorelowane. W danych pogodowych to założenie jest wyraźnie naruszone.

Co z tego wynika?

- Same współczynniki OLS mogą być użyteczne jako opis sezonowości.
- Klasyczne błędy standardowe i wartości t mogą być zbyt optymistyczne.
- Przy bardzo dużym T prawie wszystko może wyglądać „istotnie statystycznie”.

Praktyka w tym kursie

Dla regresji harmonicznej używamy OLS głównie jako narzędzia do **odsezonowania**, a nie jako pełnego modelu probabilistycznego z idealnymi błędami standardowymi.

Dlaczego nie nadinterpretować statystyk t ?

W danych referencyjnych

Mamy $T = 26304$ obserwacji godzinowych. Przy tak dużej próbie nawet małe efekty mogą mieć ogromne statystyki t .

Pułapka

Zdanie „ $|t| > 50$, więc odkryliśmy fundamentalne prawo fizyki” jest błędne. Duża statystyka t mówi, że efekt jest bardzo precyzyjnie wykryty w dużej próbie, ale nie mówi sama z siebie, czy model jest kompletny.

Lepsze pytania

- Czy amplitudy mają sens fizyczny?
- Czy reszty nadal mają strukturę?
- Czy model wystarcza jako pierwszy krok przed ARMA?

Deterministyczna a stochastyczna sezonowość

Sezonowość deterministyczna

Wzorzec sezonowy jest opisany znaną funkcją czasu:

$$\sin(\omega t), \quad \cos(\omega t).$$

Przykład: przeciętny rytm dobowy i roczny temperatury.

Sezonowość stochastyczna

Sezonowość jest częścią procesu losowego, np. przez opóźnienia sezonowe lub modele SARIMA.

W tym cyklu

Do Zadania A wystarczy podejście deterministyczne dla pogody: usuwamy główne harmoniczne, a potem modelujemy reszty ARMA.

Druga harmonika: kiedy warto ją dodać?

Idea rozszerzenia

Jeżeli jedna fala roczna jest zbyt gładka, możemy dodać drugą harmoniczną:

$$\gamma_1 \sin(2\omega_y t) + \gamma_2 \cos(2\omega_y t).$$

Analogicznie dla rytmu dobowego można dodać okres 12 godzin.

Interpretacja

Druga harmonika pozwala modelować bardziej niesymetryczne przebiegi, np. inne tempo ocieplania wiosną i ochładzania jesienią.

Ostrzeżenie

Więcej harmonicznych poprawia dopasowanie, ale może zacząć maskować dynamikę, którą chcemy później diagnozować w resztach.

Kod Python: wariant z drugą harmoniką

```
X2 = np.column_stack([
    np.ones(T),
    np.sin(omega_h*t), np.cos(omega_h*t),
    np.sin(2*omega_h*t), np.cos(2*omega_h*t),
    np.sin(omega_y*t), np.cos(omega_y*t),
    np.sin(2*omega_y*t), np.cos(2*omega_y*t),
])

model2 = sm.OLS(y, X2).fit()
print(model.rsquared, model2.rsquared)
```

Komentarz

To jest rozszerzenie. W podstawowym rozwiązaniu Zadania A wystarczy model z jedną parą dobową i jedną parą roczną, o ile jasno opiszemy jego ograniczenia.

Czy regresja harmoniczna jest naturalna dla SPY?

Dane SPY

Analizujemy dzienne log-zwroty. W danych referencyjnych mamy około 750 obserwacji, średnią $8,39 \cdot 10^{-4}$ oraz odchylenie standardowe $9,63 \cdot 10^{-3}$.


Najważniejszy kontrast

Dla temperatury sezonowość średniej jest bardzo silna. Dla log-zwrotów SPY sezonowość średniej jest zwykle słaba albo praktycznie nieużyteczna.

Co zamiast tego?

Dla SPY centralnym problemem nie jest sezonowość średniej, lecz struktura wariancji: okresy wysokiej zmienności grupują się w czasie.


SPY: średnie zwroty według dnia tygodnia



Interpretacja ostrożna

Różnice średnich między dniami tygodnia mogą istnieć w próbie, ale są małe względem dziennej zmienności zwrotów. W bloku 6 wrócimy do testu F efektu dnia tygodnia.


SPY: próba harmonicznego cyklu 5-sesyjnego



Wniosek

Prosty model harmoniczny o okresie 5 sesji ma w danych referencyjnych $R^2 \approx 0,0001$ i amplitudę około $1,46 \cdot 10^{-4}$. To jest praktycznie zerowe wyjaśnienie zmienności log-zwrotów.

SPY: średnia a zmienność



Slogan

Średnia jest nieprzewidywalna, ale ryzyko jest.

Dlaczego dla SPY nie zaczynamy od harmonik?

Dla pogody

- wiemy, że Ziemia obraca się wokół osi i wokół Słońca,
- rytmy 24 godziny i 8760 godzin mają jasną interpretację fizyczną,
- amplitudy są duże i praktycznie ważne.

Dla SPY

- sesyjny cykl tygodniowy może być badany, ale nie dominuje średniej,
- silniejsza struktura jest zwykle w zmienności, nie w średniej,
- dlatego model średniej może być bardzo prosty, nawet ARMA(0,0).

Procedura dla pogody po bloku 2

- 1 Wczytaj dane godzinowe Olsztyna.
- 2 Utwórz indeks czasu $t = 0, 1, \dots, T - 1$ w godzinach.
- 3 Zbuduj cechy: $\sin(2\pi t/24)$, $\cos(2\pi t/24)$, $\sin(2\pi t/8760)$, $\cos(2\pi t/8760)$.
- 4 Dopasuj OLS.
- 5 Policz amplitudy osobno dla rytmu dobowego i rocznego.
- 6 Zapisz reszty $\hat{e}_t$.
- 7 Sprawdź wykres reszt i ACF reszt.

Produkt do Zadania A

Pisemna analiza sezonowości oraz szereg reszt po harmonikach, na którym budujemy ARMA.

Trzy obowiązkowe pytania pisemne

Pytanie 1

Czy jest sezonowość, jaka i o jakiej amplitudzie?

Pytanie 2

Jak poradzić sobie z sezonowością przed dopasowaniem ARMA?

Pytanie 3

Czy stałe harmoniki to dobre założenie?

Dzisiejszy cel

Po tym bloku student powinien umieć napisać sensowną odpowiedź na wszystkie trzy pytania dla pogody w Olsztynie.

Wzorcowa odpowiedź: pytanie 1

Przykładowy akapit

W danych pogodowych z Olsztyna widoczna jest silna sezonowość roczna oraz dobowa. Sezonowość roczna wynika z cyklu pór roku, a sezonowość dobowa z cyklu dzień–noc. W modelu harmonicznym z jedną parą sinus–cosinus dla okresu rocznego i jedną parą dla okresu dobowego amplituda roczna wynosi około $9,95^{\circ}\text{C}$, a amplituda dobowa około $2,98^{\circ}\text{C}$. Oznacza to, że sezonowość jest nie tylko statystycznie widoczna, ale także praktycznie bardzo istotna.

Czego unikać?

Nie piszemy tylko: „jest sezonowość, bo wykres faluje”. Należy podać typ sezonowości, okresy i przynajmniej przybliżoną skalę amplitud.

Wzorcowa odpowiedź: pytanie 2

Przykładowy akapit

Przed dopasowaniem modelu ARMA do temperatury należy usunąć główne składniki sezonowe. W tym celu można zastosować regresję harmoniczną z funkcjami $\sin(2\pi t/24)$, $\cos(2\pi t/24)$, $\sin(2\pi t/8760)$ i $\cos(2\pi t/8760)$, gdzie t jest liczone w godzinach. Następnie modele ARMA dopasowuje się nie do surowej temperatury, lecz do reszt po tej regresji. Takie podejście oddziela deterministyczną sezonowość od krótkookresowej dynamiki reszt.

Slogan

Sezonowość pierwsza, ARMA druga.

Wzorcowa odpowiedź: pytanie 3

Przykładowy akapit

Założenie stałych harmonik jest dobrym pierwszym przybliżeniem, ponieważ pozwala prosto i interpretowalnie opisać przeciętny rytm dobowy i roczny. Nie jest jednak pełnym opisem pogody. W rzeczywistości amplituda cyklu dobowego może zależeć od pory roku, zachmurzenia, opadów i sytuacji synoptycznej. Dlatego po regresji harmonicznej reszty nadal wymagają diagnostyki i zwykle modelowania za pomocą ARMA.

Czego unikać?

Nie twierdzimy, że $R^2 \approx 0,769$ kończy analizę. To bardzo dobry opis sezonowości, ale nie dowód, że reszty są losowe.

Najczęstsze błędy w bloku 2

Lista kontrolna pułapek

- 1 Użycie $2\pi/365$ przy danych godzinowych.
- 2 Mylenie wyrazu wolnego β_0 z amplitudą.
- 3 Liczenie jednej amplitudy z kilku różnych okresów naraz.
- 4 Uznać wysokie R^2 za dowód białego szumu reszt.
- 5 Traktować klasyczne błędy standardowe OLS jako w pełni wiarygodne mimo autokorelacji.
- 6 Dopasować ARMA bezpośrednio do surowej temperatury, ignorując sezonowość.
- 7 Szukać na siłę harmonicznego sezonowości średniej w SPY.

Co zabieramy do bloku 3?

Stan po bloku 2

- Dla pogody mamy model sezonowości i reszty po harmonikach.
- Wiemy, że reszty pogodowe nadal są autokorelacyjne.
- Dla SPY wiemy, że sezonowość średniej nie jest dominującym problemem.

Następny krok

W bloku 3 wprowadzimy modele AR, MA i ARMA. Będziemy pytać, czy zależności widoczne w resztach da się opisać za pomocą pamięci wartości szeregu oraz pamięci szoków.

Hasło na koniec

Reszty po sezonowości są początkiem modelowania, nie końcem analizy.

ARMA

Dr hab. Andrzej Jankowski

Instytut Informatyki, Uniwersytet Warmińsko-Mazurski w Olsztynie

4 maja 2026