

AR, MA, ARMA

Dr hab. Andrzej Jankowski, prof UWM

Instytut Informatyki, Uniwersytet Warmińsko-Mazurski w Olsztynie

11 maja 2026

Po co periodogram?

Intuicja

Periodogram odpowiada na pytanie: **dla jakich częstotliwości sinus i cosinus szczególnie dobrze pasują do danych?**

Slogan

Periodogram jest mapą kandydatów na sezonowość, nie ostatecznym wyrokiem.

Co zobaczymy?

Jeśli w danych istnieje mocny cykl o okresie S , to w periodogramie często pojawia się pik dla częstotliwości $f = 1/S$.

Częstotliwość i okres: najważniejszy wzór

Relacja

Jeśli f oznacza częstotliwość mierzoną w cyklach na jeden krok czasu, a S oznacza okres w krokach czasu, to

$$S = \frac{1}{f}.$$

Przykłady


- $f = 1/24$ dla danych godzinowych oznacza okres $S = 24$ godziny.
- $f = 1/8760$ dla danych godzinowych oznacza okres $S = 8760$ godzin, czyli około rok.
- $f = 1/5$ dla danych sesyjnych SPY oznacza okres $S = 5$ sesji giełdowych.

Pułapka

Dla SPY nie szukamy automatycznie okresu 7, bo giełda nie ma zwykle obserwacji w soboty i niedziele. Tydzień handlowy ma około 5 sesji.

Olsztyn: periodogram temperatury


Olsztyn: periodogram jako mapa kandydatów na sezonowość



Interpretacja

Wykres pokazuje mocne kandydatury na okres roczny oraz dobowy. To wspiera diagnozę z wykresów czasowych: temperatura ma silną sezonowość deterministyczną, którą trzeba potraktować przed ARMA.

SPY: periodogram log-zwrotów



Interpretacja

Dla SPY periodogram nie daje tak jasnego, stabilnego obrazu sezonowości średniej jak dla temperatury. Ewentualny pik przy kilku sesjach należy traktować ostrożnie i konfrontować z testem dnia tygodnia oraz ACF.

Jak obliczamy periodogram?

Niech mamy szereg godzinowych temperatur:

$$x_1, x_2, \dots, x_n.$$

Najpierw odejmujemy średnią:

$$\tilde{x}_t = x_t - \bar{x}.$$

Następnie dla częstotliwości Fouriera

$$\omega_j = \frac{2\pi j}{n}, \quad j = 0, 1, \dots, n-1,$$

liczymy dyskretną transformatę Fouriera:

$$D(\omega_j) = \sum_{t=1}^n \tilde{x}_t e^{-i\omega_j t}.$$

Periodogram to kwadrat modułu tej transformaty:

$$I(\omega_j) = \frac{1}{n} |D(\omega_j)|^2.$$

ACF Autokorelacja: pytanie o pamięć
szeregu

Autokorelacja: pytanie o pamięć szeregu

Definicja intuicyjna

Autokorelacja dla opóźnienia k mierzy, jak silnie y_t jest liniowo związane z y_{t-k} .

Definicja dla procesu słabo stacjonarnego

Jeśli $\gamma(k) = \text{Cov}(Y_t, Y_{t-k})$, to

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}.$$

W praktyce estymujemy $\rho(k)$ z danych i rysujemy wykres ACF.

Interpretacja

Duża dodatnia ACF dla małych opóźnień oznacza, że wysokie wartości często następują po wysokich, a niskie po niskich.

ACF jako sygnatura sezonowości


Co może pokazać ACF?

- wolny spadek: długotrwała zależność albo trend/sezonowość,
- piki przy 24, 48, 72, ...: sezonowość dobową w danych godzinowych,
- piki przy 5, 10, 15, ...: możliwy rytm tygodniowy w danych sesyjnych,
- ACF blisko zera: brak wyraźnej liniowej pamięci średniej.

Pułapka

ACF blisko zera dla log-zwrotów SPY nie oznacza, że nie ma żadnej struktury. Trzeba sprawdzić ACF kwadratów zwrotów, bo struktura może mieszkać w wariancji.

Olsztyn: ACF temperatury do 14 dni




Interpretacja

ACF jest bardzo wysoka dla małych opóźnień i pokazuje ślady rytmu dobowego. Temperatura ma pamięć: jeśli teraz jest ciepło, za godzinę zwykle nadal jest podobnie.

Olsztyn: ACF średnich dobowych i sezon roczny


Olsztyn: ACF średnich dobowych - ślad sezonowości rocznej



Interpretacja

Po agregacji do średnich dobowych łatwiej zobaczyć długą strukturę roczną. To pokazuje, dlaczego dobór skali wizualizacji ma znaczenie.


SPY: ACF log-zwrotów



Interpretacja

ACF log-zwrotów jest w większości bliska zeru. To wspiera prosty model średniej, nawet $\text{ARMA}(0,0)$ w danych referencyjnych według BIC. Ale to jeszcze nie kończy diagnostyki.


SPY: ACF kwadratów log-zwrotów – zapowiedź bloku 5



Kluczowa interpretacja

Kwadraty log-zwrotów pokazują zależność. To klasyczna sytuacja finansowa: **średnia jest nieprzewidywalna, ale ryzyko jest**. Właśnie tu pojawia się most do ARCH/GARCH.

Triangulacja: wykres, periodogram, ACF



Wniosek

Nie opieramy diagnozy na jednym narzędziu. Jeśli trzy narzędzia mówią podobną historię, mamy mocniejszą podstawę do decyzji modelarskiej.

Diagnoza dla pogody w Olsztynie

Wykres

Pełny okres pokazuje silny cykl roczny. Krótkie fragmenty pokazują rytm dobowy.

Periodogram

Wskazuje kandydatów na okres dobowy i roczny.

ACF

Pokazuje bardzo silną pamięć i ślady sezonowości w opóźnieniach.

Wzorcowe zdanie do raportu

„Dane pogodowe z Olsztyna wykazują silną sezonowość roczną i dobową. Dlatego bezpośrednie dopasowanie ARMA do temperatury byłoby niewłaściwe jako pierwszy krok; najpierw należy usunąć składnik sezonowy, np. regresją harmoniczną.”

Diagnoza dla SPY

Wykres

Log-zwroty oscylują wokół zera, bez jasnego cyklu średniej.

Periodogram

Nie daje jednoznacznej sezonowości porównywalnej z pogodą.

ACF

ACF zwrotów jest mała, ale ACF kwadratów wskazuje strukturę wariancji.

Wzorcowe zdanie do raportu

„Dla log-zwrotów SPY nie obserwujemy silnej sezonowości średniej. Nie oznacza to jednak braku struktury w danych: zależność pojawia się w zmienności, co sugeruje efekt ARCH i motywuje późniejsze modele GARCH.”

Jak blok 1 prowadzi do bloku 2?

Problem

Dla pogody widzimy sezonowość. ARMA jest modelem dla zależności krótkookresowej wokół średniej, a nie narzędziem do „połykania” oczywistego cyklu rocznego i dobowego bez refleksji.

Rozwiązanie w bloku 2

Zbudujemy regresję harmoniczną:

$$y_t = \beta_0 + \beta_1 \sin(\omega_y t) + \beta_2 \cos(\omega_y t) + \beta_3 \sin(\omega_h t) + \beta_4 \cos(\omega_h t) + e_t.$$

Potem ARMA będziemy dopasowywać do reszt e_t , a nie do surowej temperatury.

Slogan

Sezonowość pierwsza, ARMA druga.

Pułapki z bloku 1 – lista kontrolna

Czego nie robić?

- ❶ Nie mylić częstotliwości f z okresem S : pamiętamy $S = 1/f$.
- ❷ Nie używać okresu 7 dla SPY bez zastanowienia; dla danych sesyjnych tygodni to zwykle 5 obserwacji.
- ❸ Nie traktować periodogramu jako formalnego testu istotności.
- ❹ Nie interpretować ACF zwrotów SPY bliskiej zeru jako dowodu, że „w danych nie ma nic”.
- ❺ Nie dopasowywać ARMA do surowej temperatury bez komentarza o sezonowości.

Co powinno znaleźć się w raporcie?

Krótką, pisemną diagnozę: co widać na wykresie, co sugeruje periodogram, co potwierdza albo osłabia ACF, oraz jaka decyzja modelarska z tego wynika.

Mini-ćwiczenie dla studentów

Zadanie

Dla jednego z dwóch zbiorów danych napisz trzy zdania diagnostyczne:

- 1 Co widać na wykresie szeregu w czasie?
- 2 Jaki okres lub brak okresu sugeruje periodogram?
- 3 Czy ACF wspiera tę diagnozę?

Wersja wzorcowa – pogoda

„W pełnym szeregu temperatury widać silną sezonowość roczną, a na krótkich fragmentach rytm dobowy. Periodogram wskazuje kandydatów na okresy około 24 godzin i około roku. ACF jest wysoka dla małych opóźnień i pokazuje strukturę sezonową, dlatego przed ARMA należy zastosować odsezonowanie.”

Wersja wzorcowa – SPY

„Log-zwroty SPY oscylują wokół zera i nie pokazują wyraźnej sezonowości średniej. Periodogram nie dostarcza tak silnego sygnału jak w temperaturze. ACF log-zwrotów jest bliska zeru, ale ACF kwadratów wskazuje zależność zmienności.”

Podsumowanie bloku 1

Co już umiemy?

- odróżnić szereg czasowy od próby iid,
- nazwać trend, sezonowość i składnik losowy,
- wyjaśnić sezonowość deterministyczną i stochastyczną,
- oglądać szereg w wielu skalach,
- używać periodogramu jako mapy kandydatów na okresy,
- interpretować ACF jako miarę pamięci szeregu,
- porównać pogodę w Olsztynie i SPY.

Najważniejszy wniosek

Pogoda wymaga jawnego potraktowania sezonowości przed ARMA. SPY nie wymaga regresji harmonicznej dla średniej jako naturalnego pierwszego kroku, ale wymaga czujności wobec zmienności.

Koniec części 1

Dalszy ciąg

Koniec części 1. W następnej części kontynuujemy od bloku 2.

blok 2

Zbudujemy regresję harmoniczną dla temperatury w Olsztynie, obliczymy amplitudę roczną i dobową, zinterpretujemy R^2 oraz pokażemy, dlaczego reszty po harmonikach nie są jeszcze białym szumem.

Cel bloku 2

Po tym bloku student powinien umieć

- zbudować regresję harmoniczną dla sezonowości dobowej i rocznej,
- zrozumieć, dlaczego model z sinusami i cosinusami jest zwykłą regresją liniową,
- policzyć i zinterpretować amplitudę jednej pary $\sin / \cos$,
- zinterpretować R^2 , reszty i ograniczenia modelu harmonicznego,
- wyjaśnić, dlaczego dla SPY regresja harmoniczna zwykle nie jest naturalnym pierwszym krokiem.

Efekt praktyczny

Po bloku 2 będziemy mieli nowy szereg: **reszty po odsezonowaniu pogody**. To właśnie na tych resztach będziemy dopasowywać modele ARMA w kolejnych blokach.

Przypomnienie z bloku 1: diagnoza sezonowości

Pogoda w Olsztynie

- silny rytm roczny: zima–lato–zima,
- silny rytm dobowy: noc–dzień–noc,
- sezonowość widoczna na wykresie, periodogramie i ACF.

SPY

- log-zwroty nie mają wyraźnej sezonowości średniej,
- ACF zwrotów jest zwykle bliska zeru,
- struktura ujawnia się mocniej w wariancji, nie w średniej.

Wniosek metodyczny

Dla pogody najpierw budujemy model sezonowości. Dla SPY zwykle przechodzimy bezpośrednio do prostego modelu średniej i diagnostyki wariancji.

Regresji harmoniczna

Wprowadzenie do regresji harmoniczej: Sinus, cosinus i przesunięcie fazowe

Punkt wyjścia

Chcemy pokazać, że kombinacja

$$a \sin(\omega t) + b \cos(\omega t)$$

jest w istocie jedną falą sinusoidalną, ale z odpowiednio dobraną amplitudą i przesunięciem.

Wzór na sinus sumy kątów

Korzystamy ze wzoru:

$$\sin(\alpha + \varphi) = \sin \alpha \cos \varphi + \cos \alpha \sin \varphi.$$

Dla $\alpha = \omega t$ otrzymujemy:

$$A \sin(\omega t + \varphi) = A \cos \varphi \sin(\omega t) + A \sin \varphi \cos(\omega t).$$

Porównanie współczynników

Jeżeli

$$a = A \cos \varphi, \quad b = A \sin \varphi,$$

to

$$a \sin(\omega t) + b \cos(\omega t) = A \sin(\omega t + \varphi).$$

Amplituda i faza

Amplituda

$$\begin{aligned}a &= A \cos \varphi, & b &= A \sin \varphi \\a^2 + b^2 &= A^2 \cos^2 \varphi + A^2 \sin^2 \varphi = A^2. \\A &= \sqrt{a^2 + b^2}.\end{aligned}$$

Amplituda A opisuje **siłę wahań sezonowych**.

Faza

Faza φ opisuje **przesunięcie fali w czasie**, czyli informuje, gdzie w cyklu wypada maksimum.

$$\begin{aligned}a &= A \cos \varphi, & b &= A \sin \varphi \\ \tan \varphi &= \frac{b}{a}.\end{aligned}$$

Interpretacja dla sezonowości: Model

$$y_t = \beta_0 + a \sin(\omega t) + b \cos(\omega t) + \varepsilon_t$$

uczy się jednocześnie:

Podsumowanie bazowych intuicji: Dlaczego sinus i cosinus?

Idea

Sezonowość oznacza powtarzalność. Najprostszy matematyczny opis powtarzalności to fala sinusoidalna:

$$\sin(\omega t), \quad \cos(\omega t).$$

Para $\sin / \cos$ pozwala modelowi nie tylko falować, ale także **przesuwać moment maksimum**.

Dlaczego dwie funkcje, a nie jedna?

Sam sinus ma maksimum w narzuconym miejscu. Kombinacja

$$a \sin(\omega t) + b \cos(\omega t)$$

pozwała dobrać zarówno **siłę wahań**, jak i **fazę**, czyli położenie maksimum w czasie.

Model harmoniczny dla temperatury w Olsztynie

Model roboczy

$$y_t = \beta_0 + \beta_1 \sin(\omega_h t) + \beta_2 \cos(\omega_h t) + \beta_3 \sin(\omega_y t) + \beta_4 \cos(\omega_y t) + e_t.$$

Rytm dobowy

$$\omega_h = \frac{2\pi}{24}.$$

Jednostką czasu jest godzina, więc okres dobowy to 24 obserwacje.

Rytm roczny

$$\omega_y = \frac{2\pi}{8760}.$$

Rok przybliżamy przez $365 \cdot 24 = 8760$ godzin.

Najważniejsza pułapka: jednostki czasu

Błąd bardzo częsty

Jeżeli t liczymy w godzinach, to nie wolno użyć

$$\omega_y = \frac{2\pi}{365}.$$

To byłaby częstotliwość roczna dla danych dziennych, a nie godzinowych.

Zasada

Okres musi być wyrażony w tej samej jednostce, w której liczony jest indeks t .

dane godzinowe: $S = 8760$, dane dzienne: $S = 365$.

Dlaczego ten model jest liniowy?

Uwaga kluczowa

Model wygląda „sinusoidalnie”, ale jest **liniowy względem parametrów**:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \beta_3 x_{3t} + \beta_4 x_{4t} + e_t,$$

gdzie

$$x_{1t} = \sin(\omega_h t), \quad x_{2t} = \cos(\omega_h t), \quad x_{3t} = \sin(\omega_y t), \quad x_{4t} = \cos(\omega_y t).$$

Konsekwencja praktyczna

Nie potrzebujemy skomplikowanej nieliniowej optymalizacji. Możemy użyć zwykłego OLS: `statsmodels.OLS(y, X).fit()`.

Macierz projektująca $\mathbf{X}$

Dla T obserwacji zapisujemy model w postaci macierzowej:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e},$$

$$\mathbf{X} = \begin{bmatrix} 1 & \sin(\omega_h 0) & \cos(\omega_h 0) & \sin(\omega_y 0) & \cos(\omega_y 0) \\ 1 & \sin(\omega_h 1) & \cos(\omega_h 1) & \sin(\omega_y 1) & \cos(\omega_y 1) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & \sin(\omega_h (T-1)) & \cos(\omega_h (T-1)) & \sin(\omega_y (T-1)) & \cos(\omega_y (T-1)) \end{bmatrix}.$$

Interpretacja

Każdy wiersz macierzy $\mathbf{X}$ opisuje, w jakiej fazie cyklu dobowego i rocznego znajduje się dana obserwacja.

Dane referencyjne: wynik OLS dla pogody

Zmienna	Współczynnik	Błąd std.	Statystyka t
Stała β_0	9,551	0,025	384,3
$\sin(2\pi t/24)$	-2,139	0,035	-60,9
$\cos(2\pi t/24)$	-2,081	0,035	-59,2
$\sin(2\pi t/8760)$	-3,120	0,035	-88,7
$\cos(2\pi t/8760)$	-9,444	0,035	-268,8

Wartości syntetyczne

- $R^2 \approx 0,769$.
- Amplituda dobowa: około $2,98^\circ\text{C}$.
- Amplituda roczna: około $9,95^\circ\text{C}$.
- Odchylenie standardowe reszt: około $4,03^\circ\text{C}$.

Amplituda i interpretacja

Amplituda jednej pary sin/cos

Wzór

Dla jednej pary harmoniczej

$$a \sin(\omega t) + b \cos(\omega t)$$

amplituda wynosi

$$A = \sqrt{a^2 + b^2}.$$

Interpretacja

Amplituda mówi, o ile maksymalnie składnik sezonowy odchyła się od poziomu bazowego. Jeżeli amplituda dobową wynosi 3°C , to sam rytm dobowy może zmieniać oczekiwaną temperaturę mniej więcej o $\pm 3^\circ\text{C}$ wokół odpowiedniego poziomu.

Amplitudy w danych pogodowych

Rytm dobowy

$$A_h = \sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2} \approx 2,98 \text{ } ^\circ\text{C}.$$

Maksimum dobowego składnika przypada w przybliżeniu na godzinę 15,1.

Rytm roczny

$$A_y = \sqrt{\hat{\beta}_3^2 + \hat{\beta}_4^2} \approx 9,95 \text{ } ^\circ\text{C}.$$

Maksimum rocznego składnika przypada około dnia roku 201,0.

Komentarz dydaktyczny

Amplituda jest bardziej czytelna niż osobne współczynniki przy sinusie i cosinusie. Student powinien umieć przejść od pary współczynników do jednej liczby interpretowalnej w stopniach Celsjusza.

Pułapka: amplituda przy wielu harmonicznym

Czego nie robić

Nie wolno interpretować

$$\sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2 + \hat{\beta}_3^2 + \hat{\beta}_4^2}$$


jako jednej sensownej amplitudy całej sezonowości, bo mieszamy dwa różne okresy: dzień i rok.

Poprawna praktyka

Amplitudę liczymy **osobno dla każdej pary** odpowiadającej jednemu okresowi:

$$A_h = \sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2}, \quad A_y = \sqrt{\hat{\beta}_3^2 + \hat{\beta}_4^2}.$$


Składnik dobowy: przeciętny rytm dnia



Jak to czytać?

To nie jest prognoza konkretnej temperatury w danym dniu. To przeciętny wkład pory dnia do oczekiwanej temperatury w modelu harmonicznym.

Składnik roczny: przeciętny rytm sezonowy




Jak to czytać?

Model opisuje gładki cykl roczny: chłodniej zimą, cieplej latem. Nie opisuje frontów atmosferycznych, upałów ani nagłych spadków temperatury.

Dopasowanie i reszty


Dopasowanie harmoniczne: pełny okres



Wniosek

Model harmoniczny dobrze chwytą ogólny kształt sezonowości rocznej, ale nie ma ambicji opisanie wszystkich krótkookresowych zmian pogody.


Dopasowanie harmoniczne: pierwsze 14 dni



Co jest ważne?

Rytm dobowy jest obecny, ale rzeczywista pogoda ma dodatkową dynamikę. Dlatego po odsezonowaniu zostaje szereg reszt, który nie będzie białym szumem.

Dopasowanie harmoniczne: tydzień lipcowy



Ostrzeżenie

Stała amplituda dobową to uproszczenie. W rzeczywistości amplituda dobowych wahań zależy od zachmurzenia, wiatru, wilgotności i sytuacji synoptycznej.

Błąd losowy (innowacja, zakłócenie, szok), a
pojęcie reszty z modelu

Pojęcia podstawowe: błąd losowy (innowacja, zakłócenie, szok), a reszty z modelu

W ekonometrii i analizie szeregów czasowych bardzo ważne jest rozróżnienie między tym, co należy do modelu teoretycznego, a tym, co możemy policzyć z danych.

Błąd losowy: pojęcie teoretyczne

- Oznaczamy go zwykle przez ε_t .
- W modelu teoretycznym piszemy:

$$y_t = m_t + \varepsilon_t.$$

- ε_t opisuje tę część zmiennej y_t , której nie wyjaśnia prawdziwa część systematyczna m_t .
- Jest **nieobserwowalny**, ponieważ nie znamy prawdziwego modelu populacyjnego.

Reszta: pojęcie empiryczne

- Oznaczamy ją zwykle przez e_t lub $\hat{\varepsilon}_t$.
- Po dopasowaniu modelu mamy:

$$e_t = y_t - \hat{m}_t.$$

- Jest to różnica między obserwacją y_t a wartością dopasowaną przez nasz model.
- Jest **obliczalna** — możemy ją policzyć dla każdej obserwacji.

Intuicja: błąd losowy to odchylenie od nieznanego, prawdziwego modelu; reszta to odchylenie od modelu, który faktycznie dopasowaliśmy do danych.

Dlaczego reszty są tak ważne?

Dwa poziomy opisu danych

model teoretyczny: $y_t = m_t + \varepsilon_t$,

model dopasowany: $y_t = \hat{m}_t + e_t$.

- Nie znamy prawdziwej funkcji m_t ani prawdziwych błędów ε_t .
- Z danych wyznaczamy jedynie przybliżenie $\hat{m}_t$.
- Dlatego w praktyce analizujemy **reszty**:

$$e_t = y_t - \hat{m}_t.$$

- Jeżeli model dobrze uchwycił strukturę danych, reszty powinny być możliwie mało uporządkowane.

Najważniejsza myśl

Reszty są ostatnim egzaminem modelu. Jeżeli w resztach nadal widzimy strukturę, to znaczy, że model czegoś jeszcze nie wyjaśnił.

Przykład: temperatura w Olsztynie

- Rozważmy godzinowe pomiary **temperatury w Olsztynie**.
- Taki szereg zwykle zawiera kilka źródeł regularności:
 - **sezonowość dobową** — temperatura zmienia się w rytmie dnia i nocy,
 - **sezonowość roczną** — temperatura zmienia się w rytmie pór roku,
 - krótkookresowe zależności pogodowe — np. ciepłe godziny często następują po ciepłych godzinach.
- Dlatego przed użyciem prostego modelu ARMA warto najpierw oddzielić regularną część sezonową od nieregularnych odchyleń.

Przykładowy model części systematycznej

$$\hat{m}_t = \hat{\beta}_0 + \hat{a}_1 \sin(\omega_d t) + \hat{b}_1 \cos(\omega_d t) + \hat{a}_2 \sin(\omega_r t) + \hat{b}_2 \cos(\omega_r t),$$

gdzie ω_d odpowiada cyklowi dobowemu, a ω_r cyklowi rocznemu.

Odsezonowanie: co właściwie odejmujemy?

Uwaga na ważne rozróżnienie

Od danych nie odejmujemy “magicznej sezonowości”, lecz dopasowaną przez model **część systematyczną** szeregu.

Jeżeli model systematyczny oznaczmy przez $\hat{m}_t$, to reszty mają postać:

$$e_t = y_t - \hat{m}_t.$$

- W najprostszym przypadku $\hat{m}_t$ może oznaczać tylko średni poziom.
- W przypadku temperatury $\hat{m}_t$ może zawierać średni poziom oraz sezonowość dobową i roczną.
- W bardziej złożonych modelach $\hat{m}_t$ może zawierać także trend, zmienne objaśniające lub inne składniki deterministyczne.

Interpretacja

Reszta e_t mówi, ile zostało z obserwacji y_t po usunięciu tego, co nasz model uznał za regularną, systematyczną część danych.

Po co potem model ARMA?

Założmy, że po dopasowaniu sezonowości otrzymaliśmy reszty:

$$e_t = y_t - \hat{m}_t.$$

- Jeżeli reszty są już podobne do białego szumu, prosty model sezonowy może wystarczyć.
- Jeżeli jednak reszty nadal są autokorelacyjne, to znaczy, że zawierają pamięć czasową.
- Wtedy możemy modelować reszty za pomocą modeli AR, MA lub ARMA.

Rola ARMA

Modele ARMA nie modelują bezpośrednio całej temperatury. W tym podejściu modelują tę część danych, która została po usunięciu regularnego składnika sezonowego.

dane = część systematyczna + reszta modelowana przez ARMA.

Prognoza: część systematyczna plus prognoza reszty

Połączenie regresji harmonicznej i modelu ARMA prowadzi do naturalnego wzoru:

$$\hat{y}_{t+h} = \underbrace{\hat{m}_{t+h}}_{\text{średni poziom} + \text{sezonowość}} + \underbrace{\hat{e}_{t+h}}_{\text{prognoza reszty, np. ARMA}}.$$

Część systematyczna

- średni poziom,
- sezonowość dobową,
- sezonowość roczną,
- ewentualnie trend lub inne zmienne.

Część resztowa

- krótkookresowa pamięć procesu,
- autokorelacja po odsezonowaniu,
- lokalne odchylenia od sezonowego wzorca.

Wniosek dydaktyczny

Najpierw diagnozujemy i usuwamy silną sezonowość, potem sprawdzamy reszty, a dopiero na końcu dobieramy model ARMA dla pozostałych zależności.

Najważniejsze przesłanie dla Zadania A

Procedura myślenia

- 1 Obejrzyj szereg czasowy.
- 2 Zidentyfikuj sezonowość i inne regularne struktury.
- 3 Dopasuj część systematyczną modelu.
- 4 Policz reszty:

$$e_t = y_t - \hat{m}_t.$$

- 5 Zbadaj ACF reszt.
- 6 Jeżeli reszty mają autokorelację, rozważ modele ARMA(p, q).
- 7 Po dopasowaniu ARMA sprawdź reszty końcowe modelu.

Pułapka

Nie wolno automatycznie dopasowywać ARMA do surowej temperatury, ignorując silną sezonowość dobową i roczną. Wtedy ARMA próbuje udawać model sezonowy, do czego nie jest najlepszym narzędziem.

Sezonowość pierwsza, ARMA druga, reszty na końcu jako egzamin modelu.

Błąd modelu a reszta z modelu

Model teoretyczny

W regresji zakładamy, że obserwowana wartość ma postać

$$y_t = m(t) + \varepsilon_t,$$

gdzie $m(t)$ opisuje systematyczną część zjawiska, a ε_t jest **błędem losowym**.

Przykład: regresja harmoniczna

W modelu harmonicznym możemy mieć na przykład

$$m(t) = \beta_0 + a \sin(\omega t) + b \cos(\omega t).$$

Wtedy

$$y_t = \beta_0 + a \sin(\omega t) + b \cos(\omega t) + \varepsilon_t.$$

Reszta z dopasowanego modelu

Po estymacji parametrów otrzymujemy wartości dopasowane $\hat{y}_t$. Reszta to różnica:

$$\hat{e}_t = y_t - \hat{y}_t.$$

Reszty po harmonikach (tzn po odsezonowaniu regresją harmoniczną): nowy szereg do modelowania

Reszta same w sobie generują bardzo ważny szereg związany z modelem tzw. SZEREG RESZT

$$\hat{e}_t = y_t - \hat{y}_t.$$


Interpretacja

Reszta to ta część temperatury, której nie wyjaśnia przeciętny rytm dobowy i roczny. W resztach zostają między innymi epizody pogodowe, fronty, fale ciepła, ochłodzenia i lokalna autokorelacja.

Most do bloku 3 i 4

To właśnie szereg $\hat{e}_t$ będzie wejściem do modeli ARMA w części pogodowej Zadania A.

Reszty po harmonikach (tzn po odsezonowaniu regresją harmoniczną): pełny okres




Wniosek

Po odjęciu gładkiej sezonowości widać epizody: kilka dni cieplejszych lub chłodniejszych niż model sezonowy. To jest naturalny kandydat do modelowania autoregresyjnego.

ACF reszt po harmonikach


ACF reszt po harmonikach: reszty nie są białym szumem



Kluczowy wniosek

Reszty po harmonikach nie są białym szumem. Odsezonowanie usuwa dużą część struktury deterministycznej, ale nie usuwa krótkookresowej zależności pogodowej.


Rozkład reszt: histogram



Komentarz

Histogram pomaga zobaczyć skalę typowych błędów modelu sezonowego. Nie zastępuje jednak diagnostyki ACF ani testów reszt.

Q-Q plot jako rozszerzenie



Po co to oglądać? ★ dla ambitnych

Q-Q plot pokazuje, czy rozkład reszt przypomina rozkład normalny. W Zadaniu A normalność nie jest głównym kryterium, ale pomaga zrozumieć ograniczenia prostego modelu.

Od białego szumu do pamięci

Punkt startowy: biały szum

Definicja intuicyjna

Biały szum to szereg losowych zaburzeń

$$\varepsilon_t \stackrel{\text{iid}}{\sim} (0, \sigma^2),$$

który nie ma pamięci: przeszłe wartości nie pomagają przewidzieć kolejnych wartości.

Co jest przewidywalne?

$$\mathbb{E}(\varepsilon_t \mid \varepsilon_{t-1}, \varepsilon_{t-2}, \dots) = 0.$$

Najlepsza prognoza średniej to zero.

Pułapka

Biały szum nie znaczy, że pojedyncze obserwacje są małe. Oznacza brak systematycznej zależności liniowej w czasie.

Po co modele ARMA?

Problem


W wielu szeregach reszta dzisiejsza nie jest całkowicie niezależna od wczorajszej.

- Jeżeli dzisiaj temperatura po odsezonowaniu jest wyższa niż zwykle, jutro często nadal bywa wyższa niż zwykle.
- Jeżeli dzisiaj na rynku pojawił się szok, jego wpływ może być widoczny przez kilka dni.
- ARMA daje mały, kontrolowany język opisu takich zależności.

Dydaktyczna wersja pytania

Czy szereg pamięta głównie **własne dawne wartości**, czy **dawne losowe szoki**, czy jedno i drugie?

Dwa typy pamięci



Najważniejszy kontrast

- AR: dzisiejszy poziom zależy od poprzednich poziomów.
- MA: dzisiejszy poziom zależy od dzisiejszego i poprzednich szoków.
- ARMA: oszczędny kompromis, często dobry w praktyce.

Model AR

AutoRegressive odel (model autoregresyjny)

Model AR(p): definicja

Autoregresja rzędu p

$$y_t = c + \varphi_1 y_{t-1} + \cdots + \varphi_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \stackrel{\text{iid}}{\sim} (0, \sigma^2).$$

Intuicja

Model AR pamięta **wartości szeregu**. Jeżeli y_{t-1} było duże, to przez składnik $\varphi_1 y_{t-1}$ wpływa na y_t .

Pułapka

Nie każda autoregresja jest stacjonarna. Duże współczynniki mogą powodować zbyt długą pamięć, niestabilność albo zachowanie podobne do błędzenia losowego.

AR(1): najważniejszy model startowy

Wzór

$$y_t = c + \varphi y_{t-1} + \varepsilon_t.$$

Interpretacja φ

- $\varphi = 0$: brak pamięci liniowej,
- $0 < \varphi < 1$: dodatnia pamięć,
- φ blisko 1: bardzo wolne wygasanie,
- $\varphi = 1$: granica niestacjonarności.


Stacjonarność AR(1)

Dla prostego AR(1) warunek stacjonarności brzmi:



$$|\varphi| < 1.$$

Wtedy wpływ dawnego zaburzenia zanika w czasie.

Symulacje AR(1): co robi φ ?



AR(1), $\varphi = 0,9$: szereg i ACF



Sygnatura ACF

Dla AR(1) ACF zwykle **wygasa stopniowo**. Nie ucina się po pierwszym opóźnieniu.

ACF AR(1): rachunek, który warto zapamiętać

Dla stacjonarnego AR(1)

Jeżeli

$$y_t = \varphi y_{t-1} + \varepsilon_t, \quad |\varphi| < 1,$$

to teoretyczna autokorelacja ma postać

$$\rho(k) = \varphi^k, \quad k = 0, 1, 2, \dots$$

Przykład liczbowy

Dla $\varphi = 0,8$ mamy

$$\rho(1) = 0,8, \quad \rho(2) = 0,64, \quad \rho(5) = 0,32768.$$

Pamięć nie znika od razu, tylko maleje geometrycznie.

Half-life dla AR(1)

Pytanie

Po ilu krokach wpływ zaburzenia spada mniej więcej o połowę?

Dla AR(1) z $0 < \varphi < 1$ rozwiązujemy równanie

$$\varphi^h = \frac{1}{2}.$$

Stąd

$$h = \frac{\log(1/2)}{\log(\varphi)}.$$

φ	half-life
0.50	1.00
0.70	1.94
0.80	3.11
0.90	6.58
0.95	13.51
0.99	68.97

Half-life: ważne ograniczenie

Pułapka

Half-life w tej prostej formie jest pojęciem bezpośrednio związanym z AR(1). Nie należy automatycznie przenosić tego wzoru na AR(2), ARMA albo modele nieliniowe.

Jak mówić poprawnie?

- Dla AR(1): można mówić o czasie połowicznego zaniku φ^h .
- Dla AR(2): dynamika zależy od pierwiastków równania charakterystycznego.
- Dla ARMA: kształt reakcji na szok może być bardziej złożony.

AR(p): kiedy $p > 1$?

Intuicja

AR(p) używa kilku poprzednich wartości:

$$y_t = c + \varphi_1 y_{t-1} + \cdots + \varphi_p y_{t-p} + \varepsilon_t.$$

- $p = 1$: pamięć wczorajszej wartości.
- $p = 2$: dodatkowo pamięć wartości sprzed dwóch kroków.
- Większe p może pomóc, ale zwiększa liczbę parametrów i ryzyko nadmiernego dopasowania.

Zasada Zadania A

Nie szukamy modelu ogromnego. Testujemy tylko $p \in \{0, 1, 2\}$, bo celem jest prosty, stabilny model dydaktyczny.

AR(2): pierwiastki jako rozszerzenie

Dla ambitnych ★ dla ambitnych

Dla modelu AR(2)

$$y_t = \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t$$

stacjonarność można badać przez pierwiastki wielomianu AR

$$\Phi(z) = 1 - \varphi_1 z - \varphi_2 z^2.$$

Model jest stacjonarny, gdy wszystkie pierwiastki równania

$$\Phi(z) = 0$$

leżą poza kołem jednostkowym, czyli mają moduł większy od 1.

Co wystarczy w Zadaniu A?

W praktyce statsmodels zwykle kontroluje warunki stacjonarności podczas estymacji ARMA/SARIMAX. Student powinien jednak wiedzieć, że AR(2) może mieć bogatszą dynamikę niż AR(1): wygasanie monotoniczne, wygasanie oscylacyjne albo niestacjonarność.

Model MA

Moving Average model (model średniej
ruchomej)

Model MA(q): definicja

Średnia ruchoma rzędu q

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \stackrel{\text{iid}}{\sim} (0, \sigma^2).$$

Intuicja

Model MA pamięta **szoki**, a nie obserwowane wartości szeregu. Dzisiejsza wartość składa się z dzisiejszego zaburzenia i kilku poprzednich zaburzeń.

Szok a reszta

W zapisie modelu ε_t oznacza teoretyczny, nieobserwowalny **szok** albo **innowację**. Po dopasowaniu modelu reszty $\hat{\varepsilon}_t$ traktujemy jako empiryczne oszacowania tych szoków.

Pułapka

MA(1) nie ma nieskończonej pamięci szoków w samym wzorze. Wzór zawiera tylko ε_t i ε_{t-1} .

Model MA(q): definicja

Średnia ruchoma rzędu q

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \stackrel{\text{iid}}{\sim} (0, \sigma^2).$$

Intuicja

Model MA pamięta **szoki**, a nie obserwowane wartości szeregu. Dzisiejsza wartość składa się z dzisiejszego zaburzenia i kilku poprzednich zaburzeń.

Czy przeszłe szoki są znane?

Formalnie ε_{t-2} jest nieobserwowalnym szokiem teoretycznym. Po dopasowaniu modelu znamy jednak resztę

$$\hat{\varepsilon}_{t-2},$$

którą traktujemy jako empiryczne oszacowanie tego szoku. Dlatego w praktyce prognozowania przeszłe szoki zastępujemy przeszłymi resztami.

Pułapka

MA(1) nie ma nieskończonej pamięci szoków w samym wzorze. Wzór zawiera tylko ε_t i ε_{t-1} .

MA(1): model jednego opóźnionego szoku

Wzór

$$y_t = c + \varepsilon_t + \theta \varepsilon_{t-1}.$$

Interpretacja

Jeżeli w chwili $t - 1$ pojawił się szok, to wpływa jeszcze na y_t , ale nie występuje bezpośrednio w y_{t+2} .



ACF

Dla MA(1) teoretyczna ACF ucina się po opóźnieniu 1:

$$\rho(k) = 0 \quad \text{dla } k > 1.$$

W próbie zobaczymy wartości bliskie zeru, nie dokładnie zero.

Symulacja MA(1): szereg i ACF



Sygnatura ACF

Dla MA(1) zależność jest krótka: pierwszy lag może być wyraźny, a dalsze lągi powinny być małe. W losowej próbie pojawiają się jednak przypadkowe piki.

Dlaczego MA jest trudniejsze intuicyjnie?

Ukryte szoki

W modelu MA w równaniu występują $\varepsilon_{t-1}, \varepsilon_{t-2}, \dots$, których nie obserwujemy bezpośrednio. Obserwujemy y_t , a szoki są rekonstruowane przez procedurę estymacji.

Metodyczna intuicja dla studentów

AR mówi: „dzisiejszy wynik zależy od wczorajszego wyniku”. MA mówi: „dzisiejszy wynik zależy od dzisiejszej niespodzianki i echa poprzedniej niespodzianki”.

Uwaga o znaku parametru MA

Typowa pułapka

W różnych książkach i bibliotekach można spotkać różne konwencje znaku dla składników MA. Dlatego znak parametru θ trzeba interpretować w konwencji użytego oprogramowania.

W praktyce w Zadaniu A

- Nie porównujemy mechanicznie znaku θ z innym podręcznikiem.
- Patrzymy na summary, AIC/BIC i diagnostykę reszt.
- Jeżeli chcemy interpretować efekt szoku, robimy to ostrożnie i w konwencji modelu.

Model ARMA

Model ARMA(p,q): definicja

Połączenie AR i MA

$$y_t = c + \varphi_1 y_{t-1} + \cdots + \varphi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Intuicja

ARMA pozwala jednocześnie opisać pamięć wartości szeregu i pamięć krótkich szoków. Czasem mały ARMA(1,1) zastępuje większy czysty AR albo większy czysty MA.

ARMA(1,1): prosty kompromis

Wzór

$$y_t = c + \varphi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}.$$

Część AR

φy_{t-1} mówi: poprzednia wartość ma wpływ na dzisiejszą wartość.



Część MA

$\theta \varepsilon_{t-1}$ mówi: poprzedni szok ma jeszcze echo w dzisiejszej wartości.

Dlaczego to jest oszczędne?

Dwa parametry dynamiczne mogą często opisać kształt ACF, który wymagałby kilku opóźnień w czystym AR.

Symulacja ARMA(1,1): szereg i ACF




Interpretacja

ACF modelu ARMA zwykle nie uciną się tak prosto jak w MA(1), ale jej kształt może być modyfikowany przez część MA.

Porównanie sygnatur ACF

Teoretyczny kształt ACF: AR wygasa, MA ucina się



Reguła praktyczna

- AR: ACF zwykle wygasa stopniowo.
- MA: ACF ucina się po skończonej liczbie lagów w teorii.
- ARMA: ACF wygasa, ale kształt początkowy może być bardziej elastyczny.

ACF i PACF: co trzeba wiedzieć teraz?

ACF

ACF mierzy korelację y_t z y_{t-k} . W Zadaniu A obowiązkowo rysujemy ACF danych, reszt i kwadratów reszt.

PACF

PACF mierzy zależność z opóźnieniem k po usunięciu wpływu krótszych opóźnień. Jest pomocna przy identyfikacji AR, ale w Zadaniu A najważniejsza jest siatka 9 modeli i AIC/BIC.

Uwaga dydaktyczna

Nie uczymy się tu „magicznego czytania” modelu wyłącznie z ACF/PACF. Używamy ACF do intuicji i diagnostyki, a wybór w Zadaniu A opieramy na AIC/BIC.

Zasada parsymonii

Parsymonia

Wybieramy model możliwie prosty, ale wystarczający do opisania najważniejszej struktury danych.

Dlaczego prosty model?

- łatwiejsza interpretacja,
- mniejsze ryzyko overfittingu,
- stabilniejsze wyniki w kolejnych próbach.

Dlaczego nie za prosty?

Jeśli model zostawia autokorelację w resztach, to nie zdał ostatniego egzaminu. Prosty model nie może być wymówką dla złej diagnostyki.

Siatka 9 modeli w Zadaniu A

Zakres modeli

W Zadaniu A dopasowujemy $\text{ARMA}(p, q)$, gdzie

$$p, q \in \{0, 1, 2\}.$$

Daje to 9 modeli.

	$q = 0$	$q = 1$	$q = 2$
$p = 0$	ARMA(0,0)	ARMA(0,1)	ARMA(0,2)
$p = 1$	ARMA(1,0)	ARMA(1,1)	ARMA(1,2)
$p = 2$	ARMA(2,0)	ARMA(2,1)	ARMA(2,2)

Na razie

Nie wybieramy modelu „na oko”. blok 4 pokaże AIC/BIC i MLE.

ARMA(0,0) też jest modelem

ARMA(0,0)

$$y_t = c + \varepsilon_t.$$


Interpretacja

To model stałej średniej plus biały szum. Może być całkiem rozsądnym modelem średniej dla dziennych log-zwrotów SPY.

Pułapka

Jeżeli ARMA(0,0) dobrze opisuje średnią, nie znaczy to, że dane są „całkowicie losowe”. Kwadraty zwrotów mogą mieć silną zależność, czyli strukturę wariancji.


Pogoda: harmoniki opisują rytm, ale nie całą dynamikę



Interpretacja

Regresja harmoniczna daje gładki rytm dobowo-roczny. Rzeczywista temperatura ma jednak epizody pogodowe: fronty, ochłodzenia, ocieplenia. Te epizody tworzą autokorelację reszt.

Pogoda: reszty po harmonikach nadal mają pamięć




Wniosek

Jeżeli reszty układają się w kilugodzinne lub kilkudniowe okresy dodatnie i ujemne, to model harmoniczny nie wystarcza. Wtedy ARMA jest naturalnym kolejnym krokiem.

Pogoda: ACF reszt po harmonikach


ACF reszt pogody po harmonikach: ARMA ma co modelować



Interpretacja diagnostyczna

ACF reszt nie znika natychmiast. To oznacza, że w resztach pozostała struktura średniej warunkowej. W Zadaniu A dopasujemy do tych reszt siatkę modeli ARMA.


SPY: log-zwroty jako kandydat do prostego modelu średniej



Interpretacja

Zwroty SPY oscylują wokół zera. Gołym okiem nie widać rytmu typu „zima-lato” albo „dzień-noc”. To inny typ danych niż pogoda.


SPY: ACF log-zwrotów



Wniosek dla modelu średniej

ACF log-zwrotów SPY jest bliska zeru. Dlatego według BIC w danych referencyjnych często wystarcza model ARMA(0,0) dla średniej.

SPY: ale kwadraty zwrotów mówią inną historię



Najważniejsza interpretacja

Brak wyraźnej ACF zwrotów nie oznacza braku struktury. ACF kwadratów zwrotów pokazuje zależność w zmienności. To jest zapowiedź modeli ARCH/GARCH.

Kontrast: pogoda vs SPY

Cecha	Pogoda w Olsztynie	SPY log-zwroty
Sezonowość średniej	bardzo silna roczna i dobowa	brak wyraźnej sezonowości średniej
Pierwszy krok	regresja harmoniczna	analiza zwrotów bez harmonik
Co modeluje ARMA?	reszty po harmonikach	średnią log-zwrotów
Typowy wynik BIC	bogatszy model, np. ARMA na resztach	często ARMA(0,0)
Główna trudność	pozostałości sezonowości i autokorelacja	wariancja, klastrowanie zmienności

Slogan

Średnia jest nieprzewidywalna, ale ryzyko jest.

Symulacja AR(1) w Pythonie

```
import numpy as np

rng = np.random.default_rng(123)
n = 300
phi = 0.9
eps = rng.normal(0, 1, size=n)
y = np.zeros(n)

for t in range(1, n):
    y[t] = phi * y[t-1] + eps[t]
```

Co student ma zauważyć?

Kod pokazuje definicję rekurencyjną. Aby policzyć y_t , potrzebujemy poprzedniej wartości y_{t-1} i nowego szoku ε_t .

Symulacja MA(1) w Pythonie

```
import numpy as np

rng = np.random.default_rng(123)
n = 300
theta = 0.8
eps = rng.normal(0, 1, size=n + 1)

#  $y_t = \epsilon_t + \theta * \epsilon_{t-1}$ 
y = eps[1:] + theta * eps[:-1]
```

Co student ma zauważyć?

W MA(1) nie używamy poprzedniego y . Używamy poprzedniego szoku, który w prawdziwych danych nie jest bezpośrednio obserwowany.

Dopasowanie ARMA w statsmodels

```
from statsmodels.tsa.statespace.sarimax import SARIMAX

# ARMA(p, q) zapisujemy jako SARIMAX(order=(p, 0, q))
p, q = 1, 1
model = SARIMAX(y, order=(p, 0, q), trend="c",
enforce_stationarity=True,
enforce_invertibility=True)
res = model.fit(dispatch=False)
print(res.summary())
```

Dlaczego SARIMAX?

SARIMAX pozwala dopasować ARMA jako szczególny przypadek modelu ARIMA z $d = 0$. W Zadaniu A będziemy używać właśnie takiej konwencji.

Siatka 9 modeli: szkic kodu

```
rows = []
for p in [0, 1, 2]:
    for q in [0, 1, 2]:
        model = SARIMAX(y, order=(p, 0, q), trend="c",
                        enforce_stationarity=True,
                        enforce_invertibility=True)
        res = model.fit(dispatch=False)
        rows.append({"p": p, "q": q,
                    "aic": res.aic,
                    "bic": res.bic,
                    "llf": res.llf})
```

Na razie bez wyboru

Ten kod przygotowuje tabelę. blok 4 wyjaśni, dlaczego wybieramy minimum AIC/BIC, a nie maksimum log-likelihood bez kary za liczbę parametrów.

Pułapki i typowe błędy

Pułapka 1: „ACF AR(1) uciną się po 1”

Błąd

Student widzi nazwę AR(1) i zakłada, że tylko pierwszy lag ma znaczenie w ACF.

Poprawnie

Dla AR(1) zależność w modelu dotyczy tylko y_{t-1} , ale ACF teoretyczna zwykle wygasa powoli:

$$\rho(k) = \varphi^k.$$

To MA(1) ma ACF ucinającą się po pierwszym lag w teorii.

Pułapka 2: „AR jest zawsze stacjonarne”

Błąd

Każdy model zapisany wzorem AR traktujemy jako bezpieczny model stacjonarny.

Poprawnie

AR(1) jest stacjonarny tylko wtedy, gdy $|\varphi| < 1$. Dla AR(2) i wyższych rzędów warunki są bardziej złożone i wiążą się z pierwiastkami wielomianu AR.

Pułapka 3: „MA(1) ma pamięć nieskończoną”

Błąd

Student myli model MA z nazwą „średnia ruchoma” znaną z wygładzania i sądzi, że MA(1) stale kumuluje całą przeszłość.

Poprawnie

MA(1) w równaniu zawiera tylko dzisiejszy i poprzedni szok:

$$y_t = c + \varepsilon_t + \theta \varepsilon_{t-1}.$$

Właśnie dlatego ACF MA(1) ucina się po lag 1 w teorii.

Pułapka 4: „SPY jest losowy, więc nie ma nic do modelowania”

Błąd

Na podstawie ACF log-zwrotów bliskiej zero stwierdzamy, że cały proces jest nieinteresujący.

Poprawnie

Możemy powiedzieć ostrożniej:

Średnia log-zwrotów SPY jest bliska białemu szumowi, ale wariancja ma strukturę. Kwadraty zwrotów wykazują zależności, więc ryzyko jest modelowalne.

Pułapka 5: „Pogodę modelujemy ARMA bez odsezonowania”

Błąd

Dopasowujemy ARMA bezpośrednio do temperatury godzinowej i udajemy, że model ARMA ma opisać sezonowość roczną i dobową.

Poprawnie

Najpierw odsezonowujemy pogodę regresją harmoniczną, a ARMA dopasowujemy do reszt. To daje model bardziej zgodny z mechanizmem danych.

Slogan

Sezonowość pierwsza, ARMA druga.

Co zapamiętać z tego bloku?

Minimum

- AR pamięta dawne wartości szeregu.
- MA pamięta dawne szoki.
- ARMA łączy oba mechanizmy.
- AR(1) jest stacjonarne przy $|\varphi| < 1$.
- ACF AR(1) zwykle wygasa, a ACF MA(1) ucina się po pierwszym lag w teorii.
- W Zadaniu A testujemy 9 modeli ARMA(p, q), $p, q \in \{0, 1, 2\}$.

Mini-checklista po bloku

Pytanie	Oczekiwana odpowiedź studenta
Co robi AR?	Modeluje zależność od poprzednich wartości szeregu.
Co robi MA?	Modeluje echo poprzednich szoków losowych.
Co robi ARMA?	Łączy pamięć wartości i pamięć szoków.
Kiedy AR(1) jest stacjonarne?	Gdy $ \varphi < 1$.
Czy ARMA(0,0) jest dopuszczalny?	Tak, to stała średnia plus biały szum.
Czy brak ACF zwrotów SPY kończy analizę?	Nie, trzeba zbadać kwadraty reszt i ARCH.

AR, MA, ARMA

Dr hab. Andrzej Jankowski, prof UWM

Instytut Informatyki, Uniwersytet Warmińsko-Mazurski w Olsztynie

11 maja 2026