

OLS (Ordinary Least Squares) & MLE (Maximum Likelihood Estimation)

Dr hab. Andrzej Jankowski, prof. UWM

Instytut Informatyki, UWM Olsztyn

18 maja, 2026

Wprowadzenie do OLS:
Prosty przykład
- model liniowy i OLS
do szacowania cen mieszkań za m^2

Dane: ceny mieszkań w Warszawie w 2025 r.

Mieszkanie	Liczba pokoi x_i	Cena za m ² y_i [zł]
1	1	18 000
2	2	16 500
3	3	15 500
4	4	14 500

Model liniowy

Zakładamy model postaci:

$$\text{cena za m}^2 = \beta_0 + \beta_1 \cdot \text{liczba pokoi}$$

Podstawiając dane z każdego mieszkania, otrzymujemy układ równań:

$$\beta_0 + 1 \cdot \beta_1 = 18\,000$$

$$\beta_0 + 2 \cdot \beta_1 = 16\,500$$

$$\beta_0 + 3 \cdot \beta_1 = 15\,500$$

$$\beta_0 + 4 \cdot \beta_1 = 14\,500$$

Zapis macierzowy $X\beta = y$

Układ równań w postaci macierzowej:

$$\underbrace{\begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix}}_X \underbrace{\begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}}_{\beta} = \underbrace{\begin{bmatrix} 18\,000 \\ 16\,500 \\ 15\,500 \\ 14\,500 \end{bmatrix}}_y$$

Mamy 4 równania i 2 niewiadome (β_0, β_1) — układ **nadokreślony**, tzn mamy więcej równań niż niewiadomych zmiennych.

Problem dopasowania — motywacja

Sytuacja


Mamy n obserwacji par (x_i, y_i) i podejrzewamy liniową zależność:

$$y_i \approx \beta_0 + \beta_1 x_i.$$

Punkty **nie leżą** dokładnie na prostej — dane mają szum.

Pytanie

Skoro przez chmurę punktów można poprowadzić wiele prostych — którą wybrać i **dłaczego**?



Trzy spojrzenia na OLS

OLS możemy zrozumieć z trzech komplementarnych perspektyw:

1. Algebra liniowa

Układ $\mathbf{X}\beta = \mathbf{y}$ — co zrobić, gdy jest **nadokreślony**?

2. Geometria

Rzut ortogonalny wektora $\mathbf{y}$ na podprzestrzeń $\text{Col}(\mathbf{X})$.

3. Optymalizacja

Minimalizacja sumy kwadratów reszt $\|\mathbf{y} - \mathbf{X}\beta\|^2$.

Nietrudno można udowodnić, że:

Wszystkie trzy **perspektywy** dają dokładnie ten sam wzór na wektor $\hat{\beta}$:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Sformułowanie problemu

Rozważmy układ równań:

$$\mathbf{X}\boldsymbol{\beta} = \mathbf{y},$$

gdzie:

- ▶ $\mathbf{X}$ — macierz $n \times k$ (**macierz planu**, ang. *design matrix*)
- ▶ $\boldsymbol{\beta} \in \mathbb{R}^k$ — wektor niewiadomych (parametrów)
- ▶ $\mathbf{y} \in \mathbb{R}^n$ — wektor prawej strony (obserwacje)

Interpretacja

Każdy wiersz $\mathbf{X}$ to jedna obserwacja; każda kolumna — jedna **zmienna objaśniająca**. Iloczyn $\mathbf{X}\boldsymbol{\beta}$ to n kombinacji liniowych kolumn $\mathbf{X}$ z wagami $\beta_1, \dots, \beta_k$.

Pytanie: czy istnieje $\boldsymbol{\beta}$ takie, że $\mathbf{X}\boldsymbol{\beta} = \mathbf{y}$ **dokładnie**?

Trzy scenariusze — zależnie od relacji n i k

$n = k$
(kwadratowy)

Gdy $\mathbf{X}$ jest **odwracalna**:

$$\beta = \mathbf{X}^{-1}\mathbf{y}$$

Dokładnie jedno rozwiązanie.
Klasyczna algebra liniowa.

$n < k$
(nieoznaczony)

Więcej niewiadomych niż równań.

Zazwyczaj: ∞ rozwiązań

Cała rodzina punktów spełnia układ.

$n > k$
(nadokreślony)

Więcej równań niż niewiadomych.

Zazwyczaj: **brak** rozwiązania

Typowa sytuacja w statystyce!

Pytanie kluczowe

Co zrobić w przypadku trzecim — gdy $\mathbf{X}\beta = \mathbf{y}$ **nie ma** rozwiązania?

Przykład 1 — układ kwadratowy ($n = k = 3$)

Niech

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 3 \\ 6 \end{pmatrix}.$$

Rozwiązujemy układ wprost (macierz dolnotrójkątna):

$$\begin{aligned} \beta_1 &= 1, \\ \beta_1 + \beta_2 &= 3 \Rightarrow \beta_2 = 2, \\ \beta_1 + \beta_2 + \beta_3 &= 6 \Rightarrow \beta_3 = 3. \end{aligned}$$

Wynik

$\beta = (1, 2, 3)^\top$. Rozwiązanie **istnieje i jest jedyne**, bo $\det \mathbf{X} = 1 \neq 0$.

Przykład 2 — układ nadokreślony ($n = 5, k = 2$)

Dane: pięć obserwacji (x_i, y_i) z modelem $y = \beta_0 + \beta_1 x$:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 2 \\ 3 \\ 5 \\ 7 \\ 11 \end{pmatrix}.$$

Układ ma 5 równań i tylko 2 niewiadome:

$$\beta_0 + 1\beta_1 = 2,$$

$$\beta_0 + 2\beta_1 = 3,$$

$$\beta_0 + 3\beta_1 = 5,$$

$$\beta_0 + 4\beta_1 = 7,$$

$$\beta_0 + 5\beta_1 = 11.$$

Przykład 2 — dlaczego nie ma rozwiązania?

Pierwsze dwa równania:

$$\beta_0 + \beta_1 = 2$$

$$\beta_0 + 2\beta_1 = 3$$

dają $\beta_1 = 1$, $\beta_0 = 1$.

Czy spełniają pozostałe?

- ▶ $1 + 1 \cdot 3 = 4 \neq 5$ ✗
- ▶ $1 + 1 \cdot 4 = 5 \neq 7$ ✗
- ▶ $1 + 1 \cdot 5 = 6 \neq 11$ ✗

Wniosek geometryczny

Pięć punktów (x_i, y_i) **nie leży** na jednej prostej.

Z punktu widzenia algebry: wektor y **nie należy** do podprzestrzeni $\text{Col}(\mathbf{X}) \subset \mathbb{R}^5$ rozpinanej przez kolumny $\mathbf{X}$.

Pomysł OLS

Skoro nie da się trafić w y dokładnie — znajdziemy β , dla którego $\mathbf{X}\beta$ jest **najbliżej** y .

Przestrzeń kolumnowa $\text{Col}(\mathbf{X})$

Definicja

Niech $\mathbf{X} = [\mathbf{x}_1 \mid \mathbf{x}_2 \mid \cdots \mid \mathbf{x}_k]$. Przestrzeń kolumnowa to:

$$\text{Col}(\mathbf{X}) = \{\mathbf{X}\boldsymbol{\beta} : \boldsymbol{\beta} \in \mathbb{R}^k\} = \text{span}\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k\} \subset \mathbb{R}^n.$$

- ▶ Jest to **podprzestrzeń liniowa** przestrzeni $\mathbb{R}^n$.
- ▶ Jej wymiar to $\text{rank}(\mathbf{X}) \leq \min(n, k)$.
- ▶ Geometrycznie: zbiór wszystkich wektorów „osiągalnych” przez kombinacje liniowe kolumn $\mathbf{X}$.

Kluczowa obserwacja

Układ $\mathbf{X}\boldsymbol{\beta} = \mathbf{y}$ ma **dokładne** rozwiązanie wtedy i tylko wtedy, gdy $\mathbf{y} \in \text{Col}(\mathbf{X})$.

Col(**X**) w naszym przykładzie ($n=5$, $k=2$)

Kolumny **X** to wektory w $\mathbb{R}^5$:

$$\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{pmatrix}.$$

Col(**X**) to **płaszczyzna** (podprzestrzeń 2-wymiarowa) zanurzona w $\mathbb{R}^5$.

Tylko bardzo specjalne wektory $\mathbf{y} \in \mathbb{R}^5$ na niej leżą — takie, których współrzędne układają się dokładnie na linii prostej w sensie zależności $y_i = a + bx_i$.

Nasz $\mathbf{y} = (2, 3, 5, 7, 11)^\top$ NIE leży na tej płaszczyźnie

Stąd brak rozwiązania dokładnego. Potrzebujemy „najbliższego punktu w Col(**X**)” — czyli **rzutu**.

Rzut ortogonalny — intuicja

Idea geometryczna


Niech $V \subset \mathbb{R}^n$ będzie podprzestrzenią liniową. Rzut ortogonalny wektora $\mathbf{y}$ na V to wektor $\hat{\mathbf{y}} \in V$ taki, że:

- 1 $\hat{\mathbf{y}} \in V$,
- 2 $(\mathbf{y} - \hat{\mathbf{y}}) \perp V$ (prostopadłość do każdego $\mathbf{v} \in V$).

Własność minimalizacyjna

$\hat{\mathbf{y}}$ to **najbliższy** punkt podprzestrzeni V względem wektora $\mathbf{y}$:

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{v} \in V} \|\mathbf{y} - \mathbf{v}\|^2.$$



Twierdzenie o rzucie ortogonalnym — własności

Niech P będzie operatorem rzutu ortogonalnego na podprzestrzeń $V \subset \mathbb{R}^n$. Wtedy:

1. Idempotentność

$$P^2 = P.$$

Rzutowanie już zrzutowanego wektora nic nie zmienia.

2. Symetria

$$P^\top = P.$$

Macierz rzutu jest symetryczna.

3. Rozkład wektora

Każde $\mathbf{y} \in \mathbb{R}^n$ rozkłada się jednoznacznie:

$$\mathbf{y} = \underbrace{P\mathbf{y}}_{\in V} + \underbrace{(\mathbf{y} - P\mathbf{y})}_{\in V^\perp}.$$

4. Ortogonalność reszty

$$(\mathbf{y} - P\mathbf{y}) \perp \mathbf{v} \quad \forall \mathbf{v} \in V.$$

Te cztery własności wystarczą, by wyprowadzić cały OLS

Zaraz zobaczymy, jak.

Idea OLS — minimalizacja sumy kwadratów

Definicja (Ordinary Least Squares)

Estymator OLS to $\hat{\beta} \in \mathbb{R}^k$ minimalizujący:

$$S(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2 = \sum_{i=1}^n (y_i - (\mathbf{X}\beta)_i)^2 = \sum_{i=1}^n e_i^2.$$

Dlaczego kwadraty, a nie zwykłe różnice?

- ▶ dodatnie i ujemne reszty by się znosiły,
- ▶ kwadrat „karze” silniej duże odchylenia,
- ▶ daje rozwiązanie **analityczne** (zamknięty wzór, bez iteracji).

Geometryczna interpretacja minimalizacji

Co tak naprawdę minimalizujemy?

$$S(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2$$

to **kwadrat odległości** od $\mathbf{y}$ do $\mathbf{X}\beta \in \text{Col}(\mathbf{X})$.

Ponieważ $\mathbf{X}\beta$ przebiega po całym $\text{Col}(\mathbf{X})$, gdy β przebiega $\mathbb{R}^k$:

$$\min_{\beta \in \mathbb{R}^k} \|\mathbf{y} - \mathbf{X}\beta\|^2 = \min_{\mathbf{v} \in \text{Col}(\mathbf{X})} \|\mathbf{y} - \mathbf{v}\|^2.$$

Wniosek

Wektor dopasowanych wartości $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$ to **rzut ortogonalny** $\mathbf{y}$ na $\text{Col}(\mathbf{X})$.

OLS to nic innego jak rzutowanie ortogonalne.

Warunek normalności — klucz do wzoru

Z poprzedniego slajdu: $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ musi być **prostopadłe** do $\text{Col}(\mathbf{X})$.

Co to znaczy w języku macierzy?

$\mathbf{e}$ prostopadłe do $\text{Col}(\mathbf{X}) \Leftrightarrow \mathbf{e}$ prostopadłe do **każdej** kolumny $\mathbf{X}$:

$$\mathbf{x}_j^\top \mathbf{e} = 0 \quad \text{dla } j = 1, \dots, k.$$

Zapisując wszystkie te warunki naraz:

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}$$

Tradycyjna nazwa

Równanie $\mathbf{X}^\top \mathbf{e} = \mathbf{0}$ nazywamy **równaniami normalnymi**.

Wyprowadzanie wzoru na OLS

Wyprowadzenie I — droga geometryczna

Zaczynamy od warunku normalnego $\mathbf{X}^\top \mathbf{e} = \mathbf{0}$ i podstawiamy $\mathbf{e} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$:

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$$

$$\mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{0}$$

$$\mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$$

Jeśli macierz $\mathbf{X}^\top \mathbf{X}$ jest **odwracalna** (co zachodzi $\Leftrightarrow$ kolumny $\mathbf{X}$ są liniowo niezależne), to:

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}}$$

Zauważmy

Otrzymany wzór wynika **wyłącznie** z geometrii (prostokątności reszt). Nie korzystaliśmy z rachunku różniczkowego.

Wyprowadzenie II — droga analityczna (pochodne)

Rozwijamy funkcję straty:

$$\begin{aligned} S(\beta) &= (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \\ &= \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta. \end{aligned}$$

Liczymy gradient względem β (skorzystamy z $\nabla_\beta(\beta^\top \mathbf{a}) = \mathbf{a}$ oraz $\nabla_\beta(\beta^\top \mathbf{A} \beta) = 2\mathbf{A}\beta$ dla symetrycznej $\mathbf{A}$):

$$\nabla_\beta S(\beta) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \beta.$$

Przyrównujemy do zera:

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y} \quad \Rightarrow \quad \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Ten sam wzór!

Druga pochodna $\nabla^2 S = 2\mathbf{X}^\top \mathbf{X}$ jest dodatnio półokreślona, więc to minimum.

Wzór końcowy i jego struktura

Estymator OLS

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Co robi ten wzór, krok po kroku:

- ▶ $\mathbf{X}^\top \mathbf{y}$ — to wektor *korelacji* każdej zmiennej z $\mathbf{y}$ (macierz $k \times 1$),
- ▶ $\mathbf{X}^\top \mathbf{X}$ — to macierz *kowariancji* między zmiennymi objaśnianymi (macierz $k \times k$),
- ▶ $(\mathbf{X}^\top \mathbf{X})^{-1}$ — „odbiera” wpływ wzajemnych korelacji między zmiennymi,
- ▶ wynik: k współczynników jednoznacznie określających najlepszą hiperpłaszczyznę dopasowania.

Warunek istnienia

Wzór działa wtedy, gdy $\mathbf{X}^\top \mathbf{X}$ jest **odwracalna**, co jest równoważne liniowej niezależności kolumn $\mathbf{X}$ (tzn. $\text{rank}(\mathbf{X}) = k$).

Macierz kapeluszowa (hat matrix)

Skoro $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, to wektor dopasowanych wartości:

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta} = \underbrace{\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{=: \mathbf{H}} \mathbf{y}.$$

Definicja

$$\mathbf{H} = \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad \hat{\mathbf{y}} = \mathbf{H} \mathbf{y}.$$

„Kapelusznik” — nakłada kapelusz $\hat{}$ na wektor $\mathbf{y}$.

Interpretacja

$\mathbf{H}$ to **macierz operatora rzutu ortogonalnego** na $\text{Col}(\mathbf{X})$. Dla dowolnego $\mathbf{y}$:

$$\hat{\mathbf{y}} = \mathbf{H} \mathbf{y} = \text{rzut ortogonalny } \mathbf{y} \text{ na } \text{Col}(\mathbf{X}).$$

Własności macierzy kapeluszowej

Sprawdźmy, że $\mathbf{H}$ ma własności prawdziwego rzutu:

Idempotentność: $\mathbf{H}^2 = \mathbf{H}$

$$\begin{aligned}\mathbf{H}^2 &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \cdot \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \\ &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \underbrace{(\mathbf{X}^\top \mathbf{X})(\mathbf{X}^\top \mathbf{X})^{-1}}_{=\mathbf{I}} \mathbf{X}^\top \\ &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \mathbf{H}.\end{aligned}$$

Symetria: $\mathbf{H}^\top = \mathbf{H}$

$$\begin{aligned}\mathbf{H}^\top &= (\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top)^\top \\ &= \mathbf{X} ((\mathbf{X}^\top \mathbf{X})^{-1})^\top \mathbf{X}^\top \\ &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \mathbf{H}.\end{aligned}$$

(Korzystamy z $(\mathbf{X}^\top \mathbf{X})^\top = \mathbf{X}^\top \mathbf{X}$.)

Wniosek

$\mathbf{H}$ spełnia algebraiczne aksjomaty rzutu ortogonalnego — nasza geometryczna intuicja jest **poprawna**.

Przykład numeryczny 1: szacowanie cen mieszkań

Przykład I — Model liniowy

Zakładamy model postaci:

$$\text{cena za m}^2 = \beta_0 + \beta_1 \cdot \text{liczba pokoi}$$

Podstawiając dane z każdego mieszkania, otrzymujemy układ równań:

$$\beta_0 + 1 \cdot \beta_1 = 18\,000$$

$$\beta_0 + 2 \cdot \beta_1 = 16\,500$$

$$\beta_0 + 3 \cdot \beta_1 = 15\,500$$

$$\beta_0 + 4 \cdot \beta_1 = 14\,500$$

Czy istnieje rozwiązanie dokładne?

Sprawdźmy z dwóch pierwszych równań:

$$\beta_0 + \beta_1 = 18\,000, \quad \beta_0 + 2\beta_1 = 16\,500$$

Stąd $\beta_1 = -1500$, $\beta_0 = 19\,500$.

Ale dla trzeciego mieszkania dostalibyśmy:

$$19\,500 - 3 \cdot 1500 = 15\,000 \neq 15\,500$$

Sprzeczność — **nie ma dokładnego rozwiązania**. Szukamy więc rozwiązania przybliżonego metodą najmniejszych kwadratów.

Przykład I — Równanie normalne

Rozwiązanie najmniejszych kwadratów spełnia:

$$X^{\top} X \hat{\beta} = X^{\top} y$$

Obliczamy:

$$X^{\top} X = \begin{bmatrix} 4 & 10 \\ 10 & 30 \end{bmatrix}, \quad X^{\top} y = \begin{bmatrix} 64\,500 \\ 155\,500 \end{bmatrix}$$

Wyznacznik $\det(X^{\top} X) = 4 \cdot 30 - 10^2 = 20$, więc macierz jest odwracalna.

Przykład I — Obliczenie $\hat{\beta}$

Odwracamy macierz 2×2 :

$$(X^{\top} X)^{-1} = \frac{1}{20} \begin{bmatrix} 30 & -10 \\ -10 & 4 \end{bmatrix} = \begin{bmatrix} 1,5 & -0,5 \\ -0,5 & 0,2 \end{bmatrix}$$

Skąd:

$$\hat{\beta} = (X^{\top} X)^{-1} X^{\top} y = \begin{bmatrix} 1,5 \cdot 64\,500 - 0,5 \cdot 155\,500 \\ -0,5 \cdot 64\,500 + 0,2 \cdot 155\,500 \end{bmatrix} = \begin{bmatrix} 19\,000 \\ -1\,150 \end{bmatrix}$$

Przykład I — Wynik i interpretacja

Dopasowany model

$$\text{cena za m}^2 \approx 19\,000 - 1\,150 \cdot \text{liczba pokoi}$$

Interpretacja:

- ▶ $\hat{\beta}_0 = 19\,000$ zł — przewidywana cena za m² dla „mieszkania zerowego” (interpretacja czysto matematyczna).
- ▶ $\hat{\beta}_1 = -1\,150$ zł — każdy dodatkowy pokój wiąże się ze spadkiem ceny za m² o ok. 1 150 zł.
- ▶ Większe mieszkania zwykle mają niższą cenę jednostkową.

Przykład I — Reszty: jak dobrze model pasuje

x_i	y_i	$\hat{y}_i = 19000 - 1150x_i$	reszta $e_i = y_i - \hat{y}_i$
1	18 000	17 850	+150
2	16 500	16 700	-200
3	15 500	15 550	-50
4	14 500	14 400	+100

- ▶ Suma reszt $\sum e_i = 0$ — własność OLS z wyrazem wolnym.
- ▶ Suma kwadratów reszt $\sum e_i^2 = 75\,000$ — to wartość, którą minimalizowaliśmy.

Dlaczego suma reszt jest zerowa?

Warunek: model zawiera wyraz wolny β_0 (kolumna jedynek w X).

OLS minimalizuje sumę kwadratów reszt:

$$S(\beta) = \sum_{i=1}^n (y_i - x_i^\top \beta)^2$$

W punkcie minimum pochodne cząstkowe znikają — to **równania normalne**:

$$\frac{\partial S}{\partial \beta_j} = -2 \sum_{i=1}^n x_{ij} (y_i - x_i^\top \hat{\beta}) = -2 \sum_{i=1}^n x_{ij} e_i = 0$$

Czyli dla *każdej* kolumny macierzy X :

$$\sum_{i=1}^n x_{ij} e_i = 0 \quad \Longleftrightarrow \quad X^\top e = 0$$

Pierwsza kolumna X to same jedynki ($x_{i0} = 1$), więc:

$$\sum_{i=1}^n 1 \cdot e_i = \sum_{i=1}^n e_i = 0 \quad \blacksquare$$

Przykład numeryczny 2: prosta regresja

Przykład numeryczny II — prosta regresja ($n = 5, k = 2$)

Wracamy do danych z początku:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 2 \\ 3 \\ 5 \\ 7 \\ 11 \end{pmatrix}.$$

Cel: znaleźć $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)^\top$, tzn. „najlepszą prostą” przechodzącą przez pięć punktów.

Plan obliczeń:

- 1 Obliczyć $\mathbf{X}^\top \mathbf{X}$ (macierz 2×2).
- 2 Obliczyć $\mathbf{X}^\top \mathbf{y}$ (wektor 2×1).
- 3 Obliczyć $(\mathbf{X}^\top \mathbf{X})^{-1}$.
- 4 Pomnożyć: $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$.

Przykład II — krok 1: obliczenie $\mathbf{X}^\top \mathbf{X}$

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix}.$$

Obliczamy sumy:

- ▶ $\sum 1 = 5$
- ▶ $\sum x_i = 1 + 2 + 3 + 4 + 5 = 15$
- ▶ $\sum x_i^2 = 1 + 4 + 9 + 16 + 25 = 55$

Wynik

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}.$$

Przykład II — kroki 2 i 3: $\mathbf{X}^\top \mathbf{y}$ i odwrotność

Krok 2: $\mathbf{X}^\top \mathbf{y}$:

- ▶ $\sum y_i = 2 + 3 + 5 + 7 + 11 = 28$
- ▶ $\sum x_i y_i = 1 \cdot 2 + 2 \cdot 3 + 3 \cdot 5 + 4 \cdot 7 + 5 \cdot 11 = 2 + 6 + 15 + 28 + 55 = 106$

$$\mathbf{X}^\top \mathbf{y} = \begin{pmatrix} 28 \\ 106 \end{pmatrix}.$$

Krok 3: odwrotność $\mathbf{X}^\top \mathbf{X}$. Mamy $\det(\mathbf{X}^\top \mathbf{X}) = 5 \cdot 55 - 15^2 = 275 - 225 = 50$.

Dla macierzy 2×2 : $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$, więc:

$$(\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}.$$

Przykład II — krok 4: wynik

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \begin{pmatrix} 28 \\ 106 \end{pmatrix}.$$

Obliczamy:

$$\begin{aligned} \frac{1}{50} (55 \cdot 28 - 15 \cdot 106) &= \frac{1540 - 1590}{50} = \frac{-50}{50} = -1, \\ \frac{1}{50} (-15 \cdot 28 + 5 \cdot 106) &= \frac{-420 + 530}{50} = \frac{110}{50} = 2,2. \end{aligned}$$

Wynik

$$\hat{\beta} = \begin{pmatrix} -1 \\ 2,2 \end{pmatrix}, \quad \text{czyli najlepsza prosta to } \hat{y} = -1 + 2,2x.$$

Przykład II — weryfikacja ortogonalności reszt

Liczmy dopasowane wartości $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$:

$$\hat{\mathbf{y}}_i = -1 + 2,2 x_i \Rightarrow \hat{\mathbf{y}} = (1,2; 3,4; 5,6; 7,8; 10,0)^\top.$$

Reszty $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$:

$$\mathbf{e} = (0,8; -0,4; -0,6; -0,8; 1,0)^\top.$$

Sprawdzamy warunek normalności $\mathbf{X}^\top \mathbf{e} = \mathbf{0}$:

$$\sum e_i = 0,8 - 0,4 - 0,6 - 0,8 + 1,0 = 0 \quad \checkmark$$

$$\begin{aligned} \sum x_i e_i &= 1(0,8) + 2(-0,4) + 3(-0,6) + 4(-0,8) + 5(1,0) \\ &= 0,8 - 0,8 - 1,8 - 3,2 + 5 = 0 \quad \checkmark \end{aligned}$$

Geometria potwierdzona

Reszty są dokładnie ortogonalne do obu kolumn $\mathbf{X}$ — tak jak nakazuje teoria rzutu.

Przykład numeryczny 3: regresja wieloraka

Przykład numeryczny III — regresja wielokrotna ($n = 5, k = 3$)

Dodajemy drugą zmienną objaśniającą. Mamy model $y = \beta_0 + \beta_1 x + \beta_2 z + \varepsilon$:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 1 & 3 & 1 \\ 1 & 4 & 2 \\ 1 & 5 & 2 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 3 \\ 5 \\ 8 \\ 9 \end{pmatrix}.$$

Macierz $\mathbf{X}$ ma teraz **trzy kolumny**: stałą, x i z .

Plan ten sam: obliczyć $\mathbf{X}^\top \mathbf{X}$ (3×3), $\mathbf{X}^\top \mathbf{y}$ (3×1), odwrócić, pomnożyć.

Przykład III — obliczenie $\mathbf{X}^\top \mathbf{X}$ i $\mathbf{X}^\top \mathbf{y}$

Sumy potrzebne do $\mathbf{X}^\top \mathbf{X}$:

- ▶ $\sum 1 = 5, \sum x_i = 15, \sum z_i = 6$
- ▶ $\sum x_i^2 = 55, \sum x_i z_i = 0 + 2 + 3 + 8 + 10 = 23, \sum z_i^2 = 0 + 1 + 1 + 4 + 4 = 10$

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 15 & 6 \\ 15 & 55 & 23 \\ 6 & 23 & 10 \end{pmatrix}.$$

Sumy do $\mathbf{X}^\top \mathbf{y}$:

- ▶ $\sum y_i = 4 + 3 + 5 + 8 + 9 = 29$
- ▶ $\sum x_i y_i = 4 + 6 + 15 + 32 + 45 = 102$
- ▶ $\sum z_i y_i = 0 + 3 + 5 + 16 + 18 = 42$

$$\mathbf{X}^\top \mathbf{y} = \begin{pmatrix} 29 \\ 102 \\ 42 \end{pmatrix}.$$

Przykład III — układ normalny i rozwiązanie

Układ normalny $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$ to:

$$\begin{pmatrix} 5 & 15 & 6 \\ 15 & 55 & 23 \\ 6 & 23 & 10 \end{pmatrix} \hat{\boldsymbol{\beta}} = \begin{pmatrix} 29 \\ 102 \\ 42 \end{pmatrix}.$$

Wyznacznik $\det(\mathbf{X}^\top \mathbf{X}) = 15$ (rozwinięcie Laplace'a po pierwszym wierszu). Macierz odwrotna:

$$(\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{15} \begin{pmatrix} 21 & -12 & 15 \\ -12 & 14 & -25 \\ 15 & -25 & 50 \end{pmatrix}.$$

Mnożymy: $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$:

$$\hat{\boldsymbol{\beta}} = \frac{1}{15} \begin{pmatrix} 21 \cdot 29 - 12 \cdot 102 + 15 \cdot 42 \\ -12 \cdot 29 + 14 \cdot 102 - 25 \cdot 42 \\ 15 \cdot 29 - 25 \cdot 102 + 50 \cdot 42 \end{pmatrix} = \frac{1}{15} \begin{pmatrix} 15 \\ 30 \\ -15 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}.$$

Przykład III — weryfikacja

Najlepsze dopasowanie:

$$\hat{y} = 1 + 2x - z.$$

Weryfikujemy mnożąc $\mathbf{X}^\top \mathbf{X} \cdot \hat{\boldsymbol{\beta}}$:

$$\begin{pmatrix} 5 & 15 & 6 \\ 15 & 55 & 23 \\ 6 & 23 & 10 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix} = \begin{pmatrix} 5 + 30 - 6 \\ 15 + 110 - 23 \\ 6 + 46 - 10 \end{pmatrix} = \begin{pmatrix} 29 \\ 102 \\ 42 \end{pmatrix} \checkmark$$

Wniosek

Otrzymane $\hat{\boldsymbol{\beta}} = (1, 2, -1)^\top$ spełnia równania normalne — to autentyczne rozwiązanie OLS.

Praktyczna uwaga

Dla $k > 2$ ręczne odwracanie staje się żmudne — w praktyce stosujemy oprogramowanie (`lm()` w R, `statsmodels` w Pythonie, ...).

Co robić gdy $X^T * X$ nie jest odwracalna ?

Kiedy $\mathbf{X}^\top \mathbf{X}$ nie jest odwracalna?

Problem współliniowości

$\mathbf{X}^\top \mathbf{X}$ jest **nieodwracalna** $\Leftrightarrow$ kolumny $\mathbf{X}$ są **liniowo zależne** ($\text{rank}(\mathbf{X}) < k$).

Przykłady patologii:

- ▶ Jedna kolumna jest dokładną kombinacją liniową innych (np. zmienna w %, w ułamkach i w punktach procentowych).
- ▶ Mamy więcej zmiennych niż obserwacji ($k > n$, „ p większe niż n ”).
- ▶ Numerycznie: kolumny prawie współliniowe $\Rightarrow$ macierz źle uwarunkowana, wzór numerycznie niestabilny.

Konsekwencje

- ▶ Rozwiązanie układu $\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$ **nadal istnieje** (niejedyne), ale wzór $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ traci sens.
- ▶ Geometrycznie: rzut $\hat{\mathbf{y}}$ na $\text{Col}(\mathbf{X})$ jest jednoznaczny, ale parametryzacja $\hat{\boldsymbol{\beta}}$ — nie.

Podstawowe podejście: Pseudoodwrotność Moore'a–Penrose'a

Definicja (operacyjna)

Dla dowolnej macierzy $\mathbf{X}$ (niekoniecznie odwracalnej) istnieje jednoznacznie określona macierz $\mathbf{X}^+$ taka, że:

$$\hat{\beta} = \mathbf{X}^+ \mathbf{y}$$

daje **minimalne pod względem normy** rozwiązanie problemu $\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|^2$.

Gdy $\mathbf{X}^\top \mathbf{X}$ jest odwracalna ($\text{rank}(\mathbf{X}) = k$, $n \geq k$):

$$\mathbf{X}^+ = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \quad (\text{klasyczny wzór OLS}).$$

Uogólnienie

Pseudoodwrotność **zawsze** istnieje — nawet gdy $\mathbf{X}$ ma kolumny współliniowe lub gdy $n < k$. To prawdziwe uogólnienie OLS na patologiczne przypadki.

Podjęcia bazujące na regularyzacji i/lub redukcji wymiarów: Co, gdy $\mathbf{X}^\top \mathbf{X}$ nie jest odwracalna?

Współliniowość (multicollinearity)

Dwie lub więcej kolumn $\mathbf{X}$ są (prawie) liniowo zależne. Wtedy $\det(\mathbf{X}^\top \mathbf{X}) \approx 0$, odwracanie jest niestabilne, a wagi $\hat{\mathbf{w}}$ „wybuchają” i zmieniają się drastycznie przy małych zmianach danych.

Przykład „szkolny”

Niech cechy: x_1 = wzrost w cm, x_2 = wzrost w m. Wtedy $x_2 = 0,01 \cdot x_1$, a kolumny w $\mathbf{X}$ są **idealnie zależne**. Wzoru zamkniętego nie ma.

Trzy klasyczne odpowiedzi

- 1 **Pseudo-odwrotność Moore’a-Penrose’a**: $\hat{\mathbf{w}} = \mathbf{X}^+ \mathbf{y}$ (zawsze istnieje, np. przez SVD).
- 2 **Regularyzacja Ridge**: $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$ — $\lambda > 0$ ratuje odwracalność.
- 3 **Redukcja wymiarów**: PCA, wybór cech, usunięcie zbędnych predyktorów.

Zapowiedź: regresja grzbietowa (Ridge) jako most do regularyzacji

Idea Ridge (Tichonow, 1943; Hoerl-Kennard, 1970)

Modyfikujemy funkcję straty:

$$L_{\text{Ridge}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|_2^2, \quad \lambda \geq 0.$$

- ▶ Drugi składnik „karze” wielkie wagi.
- ▶ Wynik: $\hat{\mathbf{w}}_{\text{Ridge}} = (\mathbf{X}^\top \mathbf{X} + n\lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$.
- ▶ Macierz **zawsze odwracalna** dla $\lambda > 0$.

Dwa sposoby patrzenia na to samo

- ▶ *Algebraicznie*: numeryczny stabilizator macierzy.
- ▶ *Probabilistycznie*: prior gaussowski na wagi $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{I})$ + Bayes (MAP).

Analiza jakości modelu regresji
za pomocą diagnostyki reszt

Reszty w modelu regresji liniowej

Definicja

Reszta (residuum) – różnica między wartością obserwowaną a wartością dopasowaną przez model:

$$e_i = y_i - \hat{y}_i, \quad i = 1, \dots, n,$$

lub wektorowo: $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}.$


Intuicja

- ▶ y_i – rzeczywista obserwacja,
- ▶ $\hat{y}_i$ – predykcja modelu w punkcie x_i ,
- ▶ e_i – **pionowy odstęp** obserwacji od prostej regresji.

Reszta e_i to *próbkowy odpowiednik* nieobserwowalnego błędu ε_i .


Po co?: Analiza RSS - Residual Sum of Squares.

Diagnostyka modelu – weryfikacja losowości, normalności i stałej wariancji błędów; wyznaczenie $\text{RSS} = \sum_{i=1}^n e_i^2$




Diagnostyka — co mówią reszty?


Reszty OK



Nieliniowość



Heteroskedasty.



Złota zasada

Zawsze rysuj wykres reszt vs. predykcji. *Bez tego nie wiesz, czy w ogóle używasz dobrego modelu.*

Współczynniki determinacji R^2

Współczynnik determinacji R^2

Trzy sumy kwadratów

- ▶ **TSS** (Total Sum of Squares) = $\sum_i (y_i - \bar{y})^2$ — całkowita zmienność y .
- ▶ **RSS** (Residual Sum of Squares) = $\sum_i (y_i - \hat{y}_i)^2$ — niewyjaśniona zmienność (błąd).
- ▶ **ESS** (Explained Sum of Squares) = $\sum_i (\hat{y}_i - \bar{y})^2$ — wyjaśniona przez model.

Dla regresji z biasem: $\text{TSS} = \text{ESS} + \text{RSS}$ (Pitagoras geometryczny).

Definicja

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\text{Niewyjaśniona zmienność (suma kwadratów błędów modelu)}}{\text{zmienność danych (wariancja danych)}} \in [0, 1].$$

Interpretacja: ułamek wariancji y wyjaśniony przez model.

Pułapka

R^2 **rośnie** (lub utrzymuje się) z każdą dodaną cechą — nawet czysto losową! Nie używaj R^2 do porównywania modeli o różnej liczbie cech.

R^2 skorygowane i kara za złożoność

Definicja

$$R_{\text{adj}}^2 = 1 - \frac{\text{RSS}/(n - d - 1)}{\text{TSS}/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - d - 1}.$$

Własność

- ▶ Może **spadać**, gdy dodajemy bezużyteczne cechy.
- ▶ Penalizuje liczbę parametrów d .
- ▶ Pierwsze podejście do **trade-offu złożoności** (Wykład 5.2: bias-variance).

Inne kryteria informacyjne

- ▶ AIC (Akaike) $\propto 2k - 2\ell$
- ▶ BIC (Bayesian) $\propto k \log n - 2\ell$
- ▶ Mallows' C_p

Każde = „jakość dopasowania – kara za złożoność”.

Założenia możliwości stosowania regresji
liniowej (akronim LINE)

Założenia możliwości stosowania regresji liniowej (akronim LINE)

Litera	Założenie	Co psuje to założenie?
L iniowość	$\mathbb{E}[y \mathbf{x}] = \mathbf{w}^\top \mathbf{x}$	Relacje nieliniowe (np. kwadratowe), brakujące cechy.
I ndependence	$\varepsilon_i \perp \varepsilon_j$ dla $i \neq j$	Szereg czasowy z autokorelacją, dane klastrowane.
N ormalność	$\varepsilon_i \sim \mathcal{N}$	Outliery, rozkłady ciężkoogonowe (heavy tails).
E qual var.	$\text{Var}(\varepsilon_i) = \sigma^2$ (homosk.)	Heteroskedastyczność — wariancja rośnie z $\mathbf{x}$.

Ważne

Naruszenie nie unicestwia metody, ale podważa interpretację statystyczną: testy istotności, przedziały ufności, p -wartości. W ML często liczy się tylko predykcja — założenia są mniej krytyczne.

Pomost do dalszej części Wykładu: kiedy równania normalne zawodzą?

Trzy scenariusze

- ❶ **Skala:** $d = 10^6$ cech (np. NLP, computer vision). Macierz $\mathbf{X}^\top \mathbf{X}$ ma 10^{12} elementów — nie zmieści się w pamięci, a co dopiero da odwrócić.
- ❷ **Modele nieliniowe** (regresja logistyczna, sieci): brak wzoru zamkniętego — gradient = jedyna droga.
- ❸ **Streaming:** dane napływają online (logi serwera, sensory IoT) — musimy aktualizować model na bieżąco.

Recepta: gradient descent (Wykład 3.2)

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \cdot \nabla L(\mathbf{w}^{(t)}) = \mathbf{w}^{(t)} + \frac{2\eta}{n} \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\mathbf{w}^{(t)}).$$

Iteracyjnie. Bez odwracania macierzy. Skaluje się do dowolnego d i n .

Mini-ćwiczenie domowe

Zadanie

Cz. 1 (na kartce): Mając dane $(x_1, y_1) = (1, 2)$, $(x_2, y_2) = (2, 3)$, $(x_3, y_3) = (3, 5)$ wyznacz analitycznie $\hat{w}_0$ i $\hat{w}_1$ w modelu $\hat{y} = w_0 + w_1x$. Sprawdź numerycznie.

Cz. 2 (Python, NumPy): Zaimplementuj funkcję `fit_linreg(X, y)` korzystającą z równań normalnych. Porównaj wyniki z `sklearn.linear_model.LinearRegression` na wybranym zbiorze (np. `california_housing`).

Cz. 3 (refleksja): Co się stanie z $(X^\top X)^{-1}$, jeśli dodasz kolumnę będącą dokładnym duplikatem innej? Sprawdź eksperymentalnie i wytłumacz, dlaczego.

Bonus ★ dla ambitnych

Implementuj wariant z **regularyzacją Ridge**: $\hat{w} = (X^\top X + \lambda I)^{-1} X^\top y$. Porównaj wagi dla $\lambda \in \{0, 0.1, 1, 10, 100\}$.


Regresja liniowa w nowoczesnym AI/ML

Gdzie naprawdę jest używana?

- ▶ **Baseline** każdego projektu predykcyjnego — „jeśli skomplikowany model nie pobije liniowego, mamy problem”.
- ▶ **Ostatnia warstwa** sieci neuronowych w regresji.
- ▶ **Ridge / Lasso** — regularyzacja w high-dimensional ML.
- ▶ **Generalized Linear Models** (GLM): logit, Poisson, gamma.

Co dziedziczymy do dalszych modeli?

- ▶ **Strata** = $-\log p(y \mid \mathbf{x}; \mathbf{w})$ ($\rightarrow$ cross-entropy w klasyfikacji).
- ▶ **Optymalizacja** = gradient descent (Wykład 3.2).
- ▶ **Cechy** = ten sam wektor $\mathbf{x}$ trafia do **każdego** algorytmu.
- ▶ **Diagnostyka** = reszty, R^2 , kr. uczenia.



Podsumowanie części o regresji liniowej i metodzie OLS

Jeden wzór — trzy interpretacje

$$\hat{w} = (X^T X)^{-1} X^T y$$

Algebraiczna
układ równań

Geometryczna
rzut prostopadły

Probabilistyczna
MLE / gauss. szum

Co zabieramy do następnego wykładu

- 1 Strata MSE *nie* jest arbitralnym wyborem.
- 2 Macierz $X^T X$ to „sygnatura” geometrii cech.
- 3 Współliniowość $\Rightarrow$ regularyzacja (Ridge, Lasso) $\Rightarrow$ Bayes (priory).
- 4 Skalowanie $\Rightarrow$ gradient descent.

Motywacja MLE jako uogólnienia OLS
i przykłady zastosowań
w których OLS zawodzi

Kiedy OLS pokrywa się z MLE?

Rozważmy model liniowy $y_i = x_i^\top \beta + \varepsilon_i$.

Twierdzenie: Estymator MLE pokrywa się z OLS wtedy i tylko wtedy, gdy:

$$\varepsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$$

Co to oznacza w praktyce:

- ▶ **independent** — błędy niezależne między obserwacjami,
- ▶ **identically distributed** — ten sam rozkład, w szczególności *stała wariancja* σ^2 (homoskedastyczność),
- ▶ **normal** — rozkład normalny ze średnią 0.

Zerowa średnia wynika z obecności wyrazu wolnego β_0 — gdy $\mathbb{E}[\varepsilon_i] = c \neq 0$, β_0 wchłania to c .

Dlaczego MLE = OLS dla błędów normalnych?

Funkcja wiarygodności dla $\varepsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$:

$$L(\beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i^\top \beta)^2}{2\sigma^2}\right)$$

Log-wiarygodność:

$$\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i^\top \beta)^2$$

Maksymalizacja $\ln L$ względem $\beta \iff$ minimalizacja sumy kwadratów reszt:

$$\hat{\beta}_{\text{MLE}} = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i^\top \beta)^2 = \hat{\beta}_{\text{OLS}}$$

Hierarchia estymatorów

Założenia o ε	MLE pokrywa się z:
$\mathcal{N}(0, \sigma^2 I)$ — iid normalne	OLS
$\mathcal{N}(0, \text{diag}(\sigma_i^2))$ — różne wariancje	WLS (ważone MNK)
$\mathcal{N}(0, \Sigma)$ — dowolna kowariancja	GLS (uogólnione MNK)
Inny rozkład (Laplace, t , ...)	Inny estymator

- ▶ **WLS:** $\hat{\beta} = (X^\top W X)^{-1} X^\top W y$, gdzie $W = \text{diag}(1/\sigma_i^2)$
- ▶ **GLS:** $\hat{\beta} = (X^\top \Sigma^{-1} X)^{-1} X^\top \Sigma^{-1} y$

A jeśli błędy nie są normalne?

Twierdzenie Gaussa-Markowa: Jeśli błędy są:

- ▶ nieskorelowane,
- ▶ mają zerową średnią,
- ▶ mają stałą wariancję σ^2 ,

to OLS jest **BLUE** — *Best Linear Unbiased Estimator*, czyli ma najmniejszą wariancję wśród liniowych nieobciążonych estymatorów.

Wnioski:

- ▶ Normalność nie jest potrzebna do *nieobciążoności* i *efektywności* OLS.
- ▶ Normalność jest potrzebna do *testów istotności* i *przedziałów ufności* w skończonej próbie.
- ▶ Dla dużych prób działa CLT i normalność błędów jest mniej krytyczna.

Gdzie OLS zawodzi — uczenie maszynowe (1/2)

1. Klasyfikacja binarna — regresja logistyczna

- ▶ $y_i \in \{0, 1\}$ (spam/nie spam, klient kupi/nie kupi)
- ▶ OLS dawałby przewidywania spoza $[0, 1]$.
- ▶ MLE z rozkładem Bernoulliego: $P(y_i = 1) = \sigma(x_i^\top \beta)$.

2. Zliczenia — regresja Poissona

- ▶ $y_i \in \{0, 1, 2, \dots\}$ (liczba kliknięć, wypadków, transakcji)
- ▶ OLS może dać ujemne przewidywania.
- ▶ MLE: $y_i \sim \text{Poisson}(\exp(x_i^\top \beta))$.

3. Dane z grubymi ogonami — regresja odporna

- ▶ OLS bardzo wrażliwy na outliery (kwadrat błędu).
- ▶ MLE z rozkładem t -Studenta lub Laplace'a $\rightarrow$ regresja kwantylowa.

4. Modele wielopoziomowe / mieszane

- ▶ Dane hierarchiczne: uczniowie w klasach, pacjenci w szpitalach.
- ▶ Efekty losowe na poziomie grupy — OLS ignoruje strukturę.
- ▶ MLE (lub REML) modeluje wariancję na różnych poziomach.

5. Modele latentne

- ▶ Analiza czynnikowa, mieszaniny gaussowskie (GMM), HMM.
- ▶ Zmienne ukryte → algorytm EM (oparty na MLE).
- ▶ OLS w ogóle nie ma jak się tu zastosować.

6. Regularyzacja — ridge, LASSO, elastic net

- ▶ Dane wysokowymiarowe ($p > n$, np. genetyka, NLP, obrazy).
- ▶ OLS nie działa: $X^T X$ nieodwracalna.
- ▶ MAP (Bayesian MLE z priorem) → regularyzacja.

Gdzie OLS zawodzi — szeregi czasowe (1/2)

W szeregach czasowych **autokorelacja** łamie założenie niezależności:

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-1}) \neq 0$$

OLS daje wtedy obciążone błędy standardowe i błędne testy istotności.

1. Modele **ARIMA** (Box-Jenkins)

- ▶ $X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots$
- ▶ Estymacja przez MLE z założeniem rozkładu reszt.
- ▶ OLS dla $\text{AR}(p)$ daje obciążone wyniki w małych próbach.

2. Modele **GARCH** — zmienna wariancja

- ▶ Wariancja zależy od czasu: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$.
- ▶ Typowe dla danych finansowych (skupiska zmienności).
- ▶ OLS zakłada homoskedastyczność $\rightarrow$ wymagana MLE.

3. Modele przestrzeni stanów / filtr Kalmana

- ▶ Ukryty stan s_t ewoluuje w czasie, obserwujemy $y_t = Hs_t + \varepsilon_t$.
- ▶ Zastosowania: nawigacja, śledzenie obiektów, ekonometria.
- ▶ MLE przez algorytm Kalmana — OLS nie obsługuje zmiennych ukrytych.

4. Analiza przeżycia (cenzorowane dane czasowe)

- ▶ Wiemy, że zdarzenie nastąpiło *po* czasie t (cenzura prawostronna).
- ▶ Modele Coxa, Weibulla, AFT — wszystkie oparte na MLE.
- ▶ OLS nie umie wykorzystać informacji z obserwacji cenzorowanych.

5. Reżimy / zmiany strukturalne

- ▶ Modele Markowa z przełączaniem reżimów (Hamilton, 1989).
- ▶ Ukryty stan rynku (hossa/bessa) — MLE przez EM.

Podsumowanie motywacji MLE jako uogólnienia OLS

Kluczowa idea

MLE to *ogólna zasada* estymacji oparta na maksymalizacji prawdopodobieństwa danych. OLS to jej *szczególny przypadek* dla błędów iid normalnych.

Kiedy używać OLS?

- ▶ Zmienna objaśniana ciągła, błędy w przybliżeniu symetryczne i niezależne.
- ▶ Dane przekrojowe (cross-sectional), brak silnych outlierów.
- ▶ Szybki, ma rozwiązanie zamknięte, łatwa interpretacja.

Kiedy sięgać po MLE?

- ▶ Dane dyskretne, ograniczone, cenzorowane.
- ▶ Heteroskedastyczność, autokorelacja, zmienne ukryte.
- ▶ Modele nieliniowe w parametrach, hierarchiczne, czasowe.

Podstawowe intuicje MLE

Pytanie otwierające

Eksperyment myślowy (90 sekund w sali)

Rzucamy monetą **10 razy** i wypada **7 orłów**.

Czy moneta jest uczciwa?

Trzy odruchy intuicji:

- ▶ „7 z 10 to dużo, więc moneta jest stronnicza”.
- ▶ „7 z 10 mieści się w błędzie statystycznym, moneta jest uczciwa”.
- ▶ „To zależy — ale od czego dokładnie?”

To jest serce statystyki

Z jednej próbki wnioskujemy o *nieobserwowalnym* parametrze θ (prawdopodobieństwie orła).

Potrzebujemy **frameworku**, który *numerycznie* przekuje dane w wniosek o θ . Tym frameworkiem jest **MLE**.

Po pierwsze — spójrzmy na liczby

Zadanie: obliczyć $\mathbb{P}(K = 7 \mid n = 10, \theta)$ dla różnych θ .

Wzór dwumianowy: $\mathbb{P}(K = k \mid n, \theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$, tu $\binom{10}{7} = 120$.

θ	$\theta^7(1 - \theta)^3$	$\mathbb{P}(K = 7 \mid \theta)$	komentarz
0,1	$1,1 \cdot 10^{-7}$	0,0000	dane <i>prawie niemożliwe</i>
0,3	$7,5 \cdot 10^{-5}$	0,0090	dane mało prawdopodobne
0,5	$7,8 \cdot 10^{-4}$	0,1172	moneta uczciwa: tylko 12%
0,7	$2,2 \cdot 10^{-3}$	0,2668	najwięcej!
0,9	$4,8 \cdot 10^{-4}$	0,0574	moneta zbyt orla

Obserwacja

Wartość $\theta = 0,7$ *najlepiej tłumaczy* obserwowane dane — to właśnie kandydat na $\hat{\theta}_{\text{MLE}}$. Zauważcie, że żadna z liczb w drugiej kolumnie nie jest „prawdopodobieństwem θ ” — to wartości funkcji *wiarygodności* przy różnych θ .


Prawdopodobieństwo vs wiarygodność — definicje

Prawdopodobieństwo	Wiarygodność
$\mathbb{P}(x \mid \theta)$ <i>funkcja zmiennej x</i>	$L(\theta \mid x)$ <i>funkcja zmiennej θ</i>
θ ustalone (znane) x losowe (rozkład)	θ <i>nieznane</i> (szukamy) x ustalone (<i>obserwacja</i>)
Suma/całka po x równa 1	Suma/całka po θ <i>nie musi</i> być 1
„Jak rozłożone są dane przy danym modelu?”	„Który model najlepiej pasuje do moich danych?”

Klucz

Te same liczby, $p(x; \theta) = L(\theta; x) = \mathbb{P}(x \mid \theta)$ — ta sama *funkcja dwóch zmiennych*, ale czytamy ją w **prostopadłych kierunkach**.

Wizualizacja: dwa kierunki tej samej funkcji



Ta sama tablica liczb $p(x, \theta)$ — inna interpretacja w zależności od tego, *co jest ustalone*.

To NIE jest rozkład prawdopodobieństwa po θ

Krytyczne ostrzeżenie

$L(\theta | x)$ **nie jest** rozkładem prawdopodobieństwa θ .

Zazwyczaj $\int L(\theta | x) d\theta \neq 1$.

Przykład: dla Bernoulliego z $k = 7, n = 10$:

$$\int_0^1 \theta^7 (1 - \theta)^3 d\theta = B(8, 4) = \frac{7! 3!}{11!} = \frac{1}{1320} \approx 0,00076 \neq 1.$$

Dlaczego to jest ważne?

- ▶ Wiarygodność **rangowa**: porównujemy $L(\theta_1)$ z $L(\theta_2)$, ale nie pytamy „jakie jest prawdopodobieństwo θ ”.
- ▶ Aby uzyskać rozkład $p(\theta | x)$, potrzebujemy podejścia *bayesowskiego*: $p(\theta | x) \propto L(\theta | x) \cdot p(\theta)$ (prior).
- ▶ Cały kurs MLE = „frequentist” — θ to *stała*, choć nieznana.

Funkcja wiarygodności dla próby IID

Założenie IID (*Independent and Identically Distributed*):

- ▶ dane $x_1, x_2, \dots, x_n$ *niezależne*,
- ▶ każde z *tego samego* rozkładu $p(x \mid \theta)$.

Definicja wiarygodności dla próby IID

$$L(\theta) = L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid \theta)$$

Dlaczego iloczyn?

Bo dla niezależnych zdarzeń: $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$.

Przykład — moneta, $n=3$, dane: O, O, R

$$L(\theta) = \theta \cdot \theta \cdot (1 - \theta) = \theta^2(1 - \theta).$$

Dla $\theta = 0,5$: $L = 0,125$. Dla $\theta = 0,7$: $L = 0,147$.

Wniosek: $\theta = 0,7$ „lepiej tłumaczy” OOR niż $\theta = 0,5$.

Logarytm dla wygody — log-wiarygodność

Definicja log-wiarygodności

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log p(x_i | \theta)$$

Trzy powody, dla których pracujemy z ℓ a nie z L :

- 1 **Łatwiejsze różniczkowanie.** Pochodna sumy = suma pochodnych. Pochodna iloczynu wymaga reguły iloczynu (i to dla n czynników!).
- 2 **Stabilność numeryczna.** Iloczyn 1000 liczb rzędu 10^{-3} to 10^{-3000} — *underflow*. Suma logarytmów: liczby rzędu -7 , sumują się bez problemu.
- 3 **Monotoniczność logarytmu.** $\log$ jest funkcją rosnącą, więc:

$$\arg \max_{\theta} L(\theta) = \arg \max_{\theta} \ell(\theta).$$

Maksimum w *tym samym* punkcie.

Numeryczna pułapka — przykład rachunkowy

Sytuacja: $n = 1000$ punktów, każdy o wartości pdf $\approx 0,01$ (typowe dla rozkładu Gaussa w 1D z $\sigma = 1$ na ogonach).

Naiwne podejście

$$L = \prod_{i=1}^{1000} p_i \approx 0,01^{1000} = 10^{-2000}$$

IEEE-754 (`double`): *najmniejsza dodatnia* liczba $\approx 10^{-308}$.

Wynik: 0.0 — *underflow*, gradient zniknął.

Z logarytmem

$$\ell = \sum_{i=1}^{1000} \log p_i \approx 1000 \cdot \log(0,01)$$

$$\approx 1000 \cdot (-4,605) = -4605$$

Liczba rzędu -10^3 — *trywialna* dla każdego komputera.

Dlatego w bibliotekach ML widzicie zawsze „log-loss”, nigdy „loss” jako iloczyn

Cross-entropy, NLL, `logsumexp` — to wszystko numeryczna ochrona przed underflow.

Definicja MLE

Estymator największej wiarygodności (MLE)

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta \in \Theta} L(\theta) = \arg \max_{\theta \in \Theta} \ell(\theta)$$


Algorytm (gdy istnieje rozwiązanie zamknięte):

- 1 Zapisz pdf/pmf: $p(x | \theta)$.
- 2 Zbuduj log-likelihood: $\ell(\theta) = \sum_{i=1}^n \log p(x_i | \theta)$.
- 3 Policz pochodną (*score function*): $s(\theta) = \frac{d\ell}{d\theta}$.
- 4 Przyporównaj do zera i rozwiąż: $s(\hat{\theta}) = 0$.
- 5 Sprawdź drugi rząd: $\left. \frac{d^2\ell}{d\theta^2} \right|_{\hat{\theta}} < 0$ — *wklęsłość*, czyli maksimum.

Powiązanie z Blokiem 1

Trzy z pięciu kroków to *czysta optymalizacja* z poprzedniego bloku: gradient zerowy + warunek drugiego rzędu. MLE to **zadanie optymalizacyjne**.

Geometryczna intuicja — $\ell(\theta)$ jako wzgórze



- ▶ Wykres $\ell(\theta) = 7 \log \theta + 3 \log(1 - \theta)$ dla próby $k = 7$ orłów na $n = 10$ rzutów.
- ▶ Szczyt = MLE. W szczycie pochodna $s(\theta) = 0$ (zielona styczna pozioma).
- ▶ Wklęsłość krzywej daje *informację* o niepewności (macierze informacji Fishera).

Przykład 1 — rozkład Bernoulliego (motywacja)

Model: pojedynczy rzut monetą, $X \in \{0, 1\}$ (1 = orzeł).

$$p(x \mid \theta) = \theta^x (1 - \theta)^{1-x}, \quad \theta \in [0, 1].$$

Próba IID: $x_1, \dots, x_n$, niech $k = \sum x_i$ to liczba orłów.

Funkcja wiarygodności:

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} = \theta^k (1 - \theta)^{n-k}$$

Log-wiarygodność:

$$\ell(\theta) = k \log \theta + (n - k) \log(1 - \theta)$$

Statystyka dostateczna

Cała informacja o θ z próby zawiera się w *jednej liczbie* $k = \sum x_i$. To pojęcie *statystyki dostatecznej* — ważne dla efektywnego ML w środowiskach o ograniczonej pamięci (*streaming*).

Przykład 1 — Bernoulli (wyprowadzenie MLE)

Krok 1: pochodna log-wiarygodności

$$\frac{d\ell}{d\theta} = \frac{k}{\theta} - \frac{n-k}{1-\theta}$$

Krok 2: przyrównanie do zera

$$\begin{aligned}\frac{k}{\theta} = \frac{n-k}{1-\theta} &\Rightarrow k(1-\theta) = (n-k)\theta \Rightarrow k - k\theta = n\theta - k\theta \\ &\Rightarrow k = n\theta\end{aligned}$$

Krok 3: rozwiązanie

Wynik MLE dla Bernoulliego: *Częstość względna sukcesów* — intuicyjny estymator.

$$\hat{\theta}_{\text{MLE}} = \frac{k}{n} = \bar{x}$$


Krok 4: weryfikacja drugiego rzędu

$$\frac{d^2\ell}{d\theta^2} = -\frac{k}{\theta^2} - \frac{n-k}{(1-\theta)^2} < 0 \quad (\text{zawsze}) \Rightarrow \ell \text{ wklęsła} \Rightarrow \text{maksimum.}$$

Powrót do monety — wynik liczbowy

Dane: 7 orłów na 10 rzutów.

MLE: $\hat{\theta}_{\text{MLE}} = 7/10 = 0,7$.



Uwaga — to nie jest cała odpowiedź!

„Najbardziej prawdopodobne” θ nie znaczy „udowodnione”. Dla $n = 10$ niepewność jest *ogromna*: rozsądny przedział ufności rozciąga się od $\sim 0,4$ do $\sim 0,9$.

Jak to formalnie zmierzyć? **Macierz informacji Fishera**.

Przykład 1: Log-wiarygodność rozkładu Bernoulliego

to ujemna wartość
entropii krzyżowej

- podstawy maszynowego uczenia
klasyfikatorów binarnych

Założenia modelu Bernoulliego

Zanim zapiszemy log-wiarygodność, ustalmy ramy probabilistyczne.

Założenia

- ▶ Obserwujemy n prób (rozmiar próby) o wyniku binarnym: sukces/porażka.
- ▶ Próby są **niezależne** i pochodzą z tego samego rozkładu Bernoulliego z nieznanym parametrem $\theta \in (0, 1)$ (założenie i.i.d.).
- ▶ $k = \sum_{i=1}^n y_i$ to liczba sukcesów; $y_i \in \{0, 1\}$ to etykieta i -tej próby.

Łączne prawdopodobieństwo zaobserwowania dokładnie k sukcesów w n próbach:

$$P(K = k \mid \theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

Dlaczego pomijamy $\binom{n}{k}$?

Współczynnik dwumianowy **nie zależy od** θ — jest stałą multiplikatywną. Przy maksymalizacji względem θ (lub różniczkowaniu $\log \mathcal{L}$) znika, więc bez straty informacji rozważamy funkcje:

$$\mathcal{L}(\theta) \propto \theta^k (1 - \theta)^{n-k}$$

Log-wiarygodność rozkładu Bernoulliego

Zaczynamy od klasycznego wzoru na log-wiarygodność dla n prób, gdzie odnotowano k sukcesów:

Log-wiarygodność (Statystyka)

$$\log \mathcal{L}(\theta) = k \log \theta + (n - k) \log(1 - \theta)$$

W uczeniu maszynowym każdą obserwację i traktujemy osobno, używając etykiet $y_i \in \{0, 1\}$:

- ▶ Suma sukcesów: $k = \sum_{i=1}^n y_i$
- ▶ Suma porażek: $n - k = \sum_{i=1}^n (1 - y_i)$

Podstawiając, otrzymujemy postać sumaryczną:

$$\log \mathcal{L}(\theta) = \sum_{i=1}^n [y_i \log \theta + (1 - y_i) \log(1 - \theta)]$$

Związek z Binarną Entropią Krzyżową (BCE)

W uczeniu maszynowym definiujemy funkcję straty (którą chcemy minimalizować). Dla przewidywań modelu $\hat{y}_i$ (odpowiednik θ):

Binary Cross-Entropy Loss

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Kluczowa relacja

$$J(\theta) = -\frac{1}{n} \log \mathcal{L}(\theta)$$

- ▶ **Znak minus:** Statystyka maksymalizuje wiarygodność, ML minimalizuje stratę (koszt).
- ▶ **Skalowanie $1/n$:** ML zazwyczaj optymalizuje średni błąd z próbki, aby funkcja była niezależna od rozmiaru zbioru danych.
- ▶ **Wniosek:** To matematycznie to samo pojęcie.

Od Bernoulliego do regresji logistycznej

Dotychczas zakładaliśmy **wspólne** θ dla wszystkich obserwacji. W regresji logistycznej każda obserwacja dostaje **własne** prawdopodobieństwo sukcesu, zależne od cech $x_i \in \mathbb{R}^d$:

Parametryzacja warunkowa

$$\theta_i = \sigma(x_i^\top w) = \frac{1}{1 + e^{-x_i^\top w}}, \quad w \in \mathbb{R}^d$$

Podstawiając $\theta \rightarrow \theta_i$ do log-wiarygodności sumarycznej:

$$\log \mathcal{L}(w) = \sum_{i=1}^n [y_i \log \sigma(x_i^\top w) + (1 - y_i) \log(1 - \sigma(x_i^\top w))]$$

Funkcja kosztu = ujemna log-wiarygodność

Minimalizacja **binary cross-entropy** jest równoważna maksymalizacji wiarygodności (MLE):

$$\mathcal{J}(w) = -\frac{1}{n} \log \mathcal{L}(w)$$


Założenie i.i.d. wciąż obowiązuje — zmienia się tylko to, że θ_i zależy od x_i , a uczymy się wag w , a nie pojedynczego parametru.

Maszynowe uczenie klasyfikatorów binarnych to — MLE $\rightarrow$ Cross-Entropy

Setup klasyfikacji binarnej: $y_i \in \{0, 1\}$, model: $\mathbb{P}(y_i = 1 \mid \mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \pi_i$.

$y_i \sim \text{Bernoulli}(\pi_i)$ daje log-wiarygodność:

$$\ell(\mathbf{w}) = \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)]$$



Pointa

Cross-entropy nie spadnie z nieba. To negatywna log-wiarygodność Bernoulliego/multinomial. Gdy w sieci widzicie `nn.CrossEntropyLoss`, w środku siedzi MLE rozkładu jakościowego.

Przykład 2:
rozkład normalny ze znanym σ^2

Przykład 2 — rozkład normalny ze znanym σ^2

Model: $X_i \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 znane, szacujemy μ .

$$p(x \mid \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Log-wiarygodność:

$$\begin{aligned}\ell(\mu) &= \sum_{i=1}^n \log p(x_i \mid \mu) \\ &= \sum_{i=1}^n \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \right] \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\end{aligned}$$

Wskazówka

Pierwszy człon *nie zależy od μ* — znika w pochodnej. Drugi człon to **minus suma kwadratów reszt**. Maksymalizacja ℓ względem $\mu \iff$ *minimalizacja sumy kwadratów*. To jest pierwszy krok do **regresji liniowej**!

Przykład 2 — wyprowadzenie MLE średniej

Pochodna:

$$\frac{d\ell}{d\mu} = -\frac{1}{2\sigma^2} \sum_{i=1}^n 2(x_i - \mu) \cdot (-1) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)$$

Równanie wiarygodności:

$$\sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \sum x_i - n\mu = 0$$

Wynik MLE: Średnia próbkowa — znów estymator, którego używaliśmy intuicyjnie.

$$\hat{\mu}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

Przykład rachunkowy: próba {2,1; 2,5; 1,9; 2,3; 2,2}, $\sigma^2 = 0,1$ znane.

$$\hat{\mu}_{\text{MLE}} = \frac{2,1 + 2,5 + 1,9 + 2,3 + 2,2}{5} = \frac{11,0}{5} = 2,2$$

Przykład 3: rozkład normalny, dwa
parametry nieznane

Przykład 3 — rozkład normalny, dwa parametry

Model: $X_i \sim \mathcal{N}(\mu, \sigma^2)$, szacujemy **oba** parametry (μ, σ^2) .

Log-wiarygodność:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

Gradient = 0 — układ dwóch równań:


$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{x}$$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \hat{\mu})^2$$

Wynik

$$\hat{\mu}_{\text{MLE}} = \bar{x}, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Wizualizacja log-wiarygodności w 2D



Powierzchnia $\ell(\mu, \sigma^2)$ dla próby $\{2,1; 2,5; 1,9; 2,3; 2,2\}$. **Czerwona kropka** = MLE $(\hat{\mu}, \hat{\sigma}^2) = (2,2; 0,04)$.

Krajobraz log-wiarygodności — ten sam obraz, który pojawia się na wielu kursach ML.

Komentarz — obciążenie estymatora wariancji

MLE wariancji jest *obciążony*. MLE **niedoszacowuje** wariancję, szczególnie dla małego n .

$$\mathbb{E}[\hat{\sigma}_{\text{MLE}}^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2$$

Stąd dwie konwencje:

- ▶ Dzielnik n — estymator MLE $\hat{\sigma}_{\text{MLE}}^2$ (asymptotycznie nieobciążony).
- ▶ Dzielnik $n - 1$ — **poprawka Bessela**, daje estymator nieobciążony s^2 .

n	$(n-1)/n$	różnica względna	wniosek
5	0,80	20%	istotna
30	0,97	3%	mała
1000	0,999	0,1%	pomijalna

W ML

Dla dużych zbiorów (typowe $n \gg 10^4$) różnica jest pomijalna, dlatego biblioteki ML (`torch.var`, `numpy.var`) domyślnie używają n (MLE). Tylko klasyczna statystyka i `pandas` domyślnie używają $n - 1$.

Wniosek koncepcyjny — MLE wyprowadza estymatory

Wielka idea

MLE *nie wymyśla* nowych estymatorów — on **wyprowadza** te, których używaliśmy intuicyjnie, z jednej zasady.

„Naturalny” estymator	$\Leftarrow$ MLE	Założony rozkład
Częstość względna k/n	$\Leftarrow$	Bernoulli(θ)
Średnia próbkowa $\bar{x}$	$\Leftarrow$	$\mathcal{N}(\mu, \sigma^2)$
Wariancja próbkowa $\frac{1}{n} \sum (x_i - \bar{x})^2$	$\Leftarrow$	$\mathcal{N}(\mu, \sigma^2)$
Odwrotność średniej $1/\bar{x}$	$\Leftarrow$	Exp(λ)
MSE w regresji liniowej	$\Leftarrow$	$\mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2)$
Cross-Entropy w klasyfikacji	$\Leftarrow$	Bernoulli/Multinomial

Dwa ostatnie wiersze — to nasze *Bloki 3 i 4*. Przerobimy je w nadchodzących wykładach.


Most do dalszej części wykładu — MLE $\rightarrow$
MSE (podstawa OLS)

Most do dalszeć części wykładu — MLE $\rightarrow$ MSE (podstawa OLS)

Setup regresji liniowej: $y_i = \mathbf{w}^\top \mathbf{x}_i + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

Zatem $y_i \mid \mathbf{x}_i \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}_i, \sigma^2)$ i log-wiarygodność:

$$\ell(\mathbf{w}) = \text{const} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{w}^\top \mathbf{x}_i)^2$$



Pointa

MSE nie jest arbitralnym wyborem. To MLE Gaussa — gdy zakładasz szum normalny i optymalizujesz wiarygodność, MSE *wypada sam*.

Dlatego MSE jest tak naturalne, gdy reszty są „gładkie” i dlaczego *przestaje* być optymalne, gdy szum nie jest gaussowski (np. outliers $\rightarrow$ trzeba MAE/Huber).

Co, gdy nie ma rozwiązania zamkniętego?

Sytuacja: pochodna $d\ell/d\theta = 0$ jest *nieliniowa* w θ i nie da się jej rozwiązać analitycznie.

Przykłady z naszego kursu:

- ▶ Regresja logistyczna — $\sigma(\mathbf{w}^\top \mathbf{x})$ wewnątrz logarytmu.
- ▶ Sieci neuronowe — log-likelihood to funkcja milionów wag, niewklęsta.
- ▶ Modele mieszane — suma normalnych, brak zamkniętej formuły.

Numerycznie szukamy maksimum

Skoro $\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta)$, używamy metod optymalizacyjnych z :

$$\theta_{t+1} = \theta_t + \eta \nabla \ell(\theta_t) \quad (\text{gradient ascent})$$

Lub *równoważnie*:

$$\theta_{t+1} = \theta_t - \eta \nabla (-\ell(\theta_t)) \quad (\text{gradient descent na NLL})$$

Konwencja

W ML zwykle minimalizujemy **NLL** (*Negative Log-Likelihood*). Stąd hasło: „*trening sieci = SGD na NLL*”.

Własności MLE — przegląd asymptotyczny

Trzy filary asymptotyczne (gdy $n \rightarrow \infty$)

- ① **Asymptotyczna nieobciążoność:** $\mathbb{E}[\hat{\theta}_{\text{MLE}}] \rightarrow \theta_0$

Praktycznie: przy dużej próbie systematyczny błąd zanika.

- ② **Asymptotyczna normalność:**

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta_0) \xrightarrow{d} \mathcal{N}(0, I^{-1}(\theta_0))$$

Praktycznie: możemy budować przedziały ufności i testować hipotezy — to jest sens zastosowania macierzy informacji Fishera.

- ③ **Asymptotyczna efektywność:** MLE osiąga *dolne ograniczenie Craméra-Rao*.

Praktycznie: żaden inny „uczciwy” estymator nie ma mniejszej wariancji asymptotycznie.

Uwaga — te własności są *asymptotyczne*

Dla małego n MLE może być obciążony (jak wariancja Gaussa), nieoptymalny i mieć duży rozrzut. „Asymptotyczne” nie znaczy „zawsze”.

Niezmienniczość MLE — ważna własność praktyczna

Twierdzenie

Jeśli $\hat{\theta}_{\text{MLE}}$ jest MLE parametru θ , to dla *dowolnej* (mierzalnej) funkcji g :

$$\widehat{g(\theta)}_{\text{MLE}} = g(\hat{\theta}_{\text{MLE}})$$

Przykład 1 — Bernoulli, iloraz szans $\omega = \theta/(1 - \theta)$

$$\hat{\omega}_{\text{MLE}} = \frac{\hat{\theta}_{\text{MLE}}}{1 - \hat{\theta}_{\text{MLE}}}, \quad \text{dla } k = 7, n = 10 : \quad \hat{\omega} = \frac{0,7}{0,3} = 2,\bar{3}$$

Przykład 2 — Gauss, odchylenie zamiast wariancji: $\hat{\sigma}_{\text{MLE}} = \sqrt{\hat{\sigma}_{\text{MLE}}^2}$.

Dlaczego to jest praktycznie ważne w ML?

W ML często optymalizujemy w *wygodnej* parametryzacji. Zamiast $\sigma^2 > 0$ (ograniczenie), optymalizujemy $\rho = \log \sigma^2 \in \mathbb{R}$ (bez ograniczeń) — a potem $\hat{\sigma}^2 = e^{\hat{\rho}}$. Niezmienniczość MLE *gwarantuje*, że dostajemy ten sam estymator.

Pułapka 1 — mała próba


Symulacja: 10 000 razy losujemy próbę n z $\mathcal{N}(0, 1)$, liczymy $\hat{\sigma}_{\text{MLE}}^2$.

n	$\mathbb{E}[\hat{\sigma}_{\text{MLE}}^2]$ (numerycznie)	błąd systematyczny	$\text{SD}(\hat{\sigma}^2)$
5	0,80	−20%	0,50
20	0,95	−5%	0,31
100	0,99	−1%	0,14
1000	1,00	0%	0,045

Implikacje dla AI/ML

- ▶ Małe *batche* → niedokładna estymata wariancji → BatchNorm ze „złą” statystyką.
- ▶ Mały zbiór walidacyjny → szum w estymacie błędu uogólnienia.
- ▶ Mały zbiór do tuning’u hiperparametrów → *overfitting do walidacji*.

Pułapka 2 — maksima lokalne i identyfikowalność



Trzy realne pułapki

- ▶ **Maksima lokalne.** Niewklęste ℓ (sieci neuronowe!) $\rightarrow$ gradient ascent znajduje *lokalne* maksimum, nie globalne. Stąd różne uruchomienia $\rightarrow$ różne modele.
- ▶ **Identyfikowalność.** Dwa różne θ dające *tę samą* dystrybucję danych $\rightarrow$ MLE nie ma jednoznacznego rozwiązania (np. permutacje neuronów w sieci).
- ▶ **Logarytm zera.** Gdy w danych pojawia się punkt o $p(x | \theta) = 0$, to $\ell = -\infty$. Praktyczne: *label smoothing*, dodanie ε do prawdopodobieństw.

Mini-ćwiczenie — rozkład wykładniczy

Zadanie

Dana próba IID z rozkładu wykładniczego $\text{Exp}(\lambda)$ o gęstości

$$p(x \mid \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0.$$

Próba: $x = (1,2; 0,9; 1,1; 1,3; 0,8)$.

Znajdź $\hat{\lambda}_{\text{MLE}}$.

Wskazówki dydaktyczne:

- 1 Zaczynij od $L(\lambda) = \prod_i \lambda e^{-\lambda x_i}$.
- 2 Logarytmuj.
- 3 Pochodna po λ , do zera, rozwiąż.
- 4 Sprawdź drugi rząd.

Spróbujcie sami przed kliknięciem dalej — 3 minuty na sali.

Mini-ćwiczenie — rozwiązanie

Krok 1: log-wiarygodność

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}$$

$$\ell(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n x_i$$

Krok 2: pochodna i równanie wiarygodności

$$\frac{d\ell}{d\lambda} = \frac{n}{\lambda} - \sum x_i = 0 \Rightarrow \hat{\lambda}_{\text{MLE}} = \frac{n}{\sum x_i} = \frac{1}{\bar{x}}$$

Krok 3: weryfikacja — $d^2\ell/d\lambda^2 = -n/\lambda^2 < 0$ — **maksimum**.

Rachunek na danych


$$\sum x_i = 1,2 + 0,9 + 1,1 + 1,3 + 0,8 = 5,3, \quad n = 5.$$

$$\hat{\lambda}_{\text{MLE}} = \frac{5}{5,3} \approx 0,943$$

Estymowana *intensywność* (rate parameter).

Średni czas oczekiwania — $1/\hat{\lambda} \approx 1,06$ jednostek.

MLE w pipeline ML — schemat



Diagnostyka modeli OLS

Sztuka odróżniania dobrego modelu od pozornie dobrego modelu

Studium przypadku: temperatura w Olsztynie
rok 2024 (uczenie) vs rok 2025 (test)

Pomost: od regresji liniowej do ARMA/GARCH

Plan prezentacji w zakresie Diagnostyki Modeli

Idea wykładu

Bierzemy **te same dane treningowe** (12 średnich miesięcznych temperatury w Olsztynie 2024) i konstruujemy **cztery różne modele OLS**. Sprawdzamy, jak *cały arsenał* diagnostyki radzi sobie z ich oceną — **w dwóch trybach**: in-sample (rok 2024) i out-of-sample (rok 2025).

Sześć części wykładu:

- 1 **Cztery modele OLS** — specyfikacja, rachunki, reszty 2024 i 2025.
- 2 **Diagnostyka geometrii cech** — $\text{cond}(\mathbf{X}^\top \mathbf{X})$, VIF.
- 3 **Diagnostyka dopasowania** — reszty, autokorelacja, R^2 in/out-of-sample.
- 4 **Kryteria informacyjne** — AIC, BIC i ich zaskakujące werdykty.
- 5 **Walidacja out-of-sample** — końcowy sędzia (a może nie?).
- 6 **Synteza i pomost do ARMA/GARCH** — gdzie OLS się kończy.

Cel dydaktyczny

Nauczyć się **rozróżniać modele dobre od pozornie dobrych**. Każde z kryteriów odpowiada na inne pytanie — żadne pojedyncze nie wystarczy. *Nawet walidacja.*

Dwa lata danych w różnych rolach
oraz cztery modele regresji


Centralna idea: dwa lata, dwie role

Rok 2024 — zbiór treningowy

12 średnich miesięcznych. Na nich **fitujemy** każdy model: liczymy $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$. Wszystkie klasyczne miary (R^2 , AIC, BIC, cond, VIF) są *liczone na tym zbiorze*. To są diagnostyki *in-sample*.

Rok 2025 — zbiór testowy

Kolejne 12 średnich miesięcznych. Tych danych model *nie widzi* podczas fitowania. Stosujemy współczynniki wyuczone na 2024, liczymy prognozę $\hat{T}_i^{(25)}$ i porównujemy z rzeczywistym $T_i^{(25)}$. To są diagnostyki *out-of-sample*.



Dane: średnie miesięczne 2024 i 2025

Z bazy 26 304 obserwacji godzinnych agregujemy do średnich miesięcznych. Każdej średniej przypisujemy *dzień środkowy* miesiąca d_i jako znacznik czasu.

Miesiąc	d_i	$T_i^{(24)}$ [°C]	$T_i^{(25)}$ [°C]	Δ
Styczeń	15	−2,15	+1,34	+3,49
Luty	46	+4,05	−1,60	−5,65
Marzec	75	+5,12	+5,08	−0,04
Kwiecień	106	+9,44	+9,61	+0,17
Maj	136	+16,31	+10,09	−6,22
Czerwiec	167	+18,03	+16,36	−1,67
Lipiec	197	+20,03	+18,17	−1,86
Sierpień	228	+19,89	+17,10	−2,79
Wrzesień	259	+17,72	+15,21	−2,52
Październik	289	+9,27	+8,05	−1,22
Listopad	320	+3,86	+3,23	−0,64
Grudzień	350	+2,72	+2,18	−0,54
Średnia		10,36	8,73	−1,63

Charakterystyka różnic

Większość miesięcy 2025 chłodniejsza o 1–3 °C. Wyjątek: zimny luty (−5,65) i *wybitnie* zimny maj (−6,22) — to są naturalne wahania międzyroczne, których model harmoniczny **nie zna**.

Cztery modele do porównania

Wszystkie cztery fitowane na 2024, oceniane na 2024 i 2025. Startują od cech $\sin \theta$ i $\cos \theta$, różnią się tym, *co jeszcze dorzucamy*.

Model	Specyfikacja	k – liczba parametrów	Motywacja
A	$T = \beta_0 + \beta_1 \sin \theta + \beta_2 \cos \theta$	3	podstawa — sezonowość
B	$A + \beta_3 T_{t-1}$	4	„wczorajsza temperatura niesie informację”
C ₁	$A + \beta_3 \cdot \text{apparent_temp}$	4	„bogata cecha meteorologiczna”
C ₂	$A + 6 \text{ atrybutów meteo}$	9	„im więcej cech, tym lepiej”
D	$A + \beta_3 \sin 2\theta + \beta_4 \cos 2\theta$	5	drugi harmonik (Fourier)

Pipeline dla każdego modelu

- 1 Budujemy $\mathbf{X}^{(24)}$ i $\mathbf{y}^{(24)}$ z danych treningowych.
- 2 Liczymy $\hat{\beta} = (\mathbf{X}^{(24)\top} \mathbf{X}^{(24)})^{-1} \mathbf{X}^{(24)\top} \mathbf{y}^{(24)}$.
- 3 **In-sample:** $\hat{\mathbf{y}}^{(24)} = \mathbf{X}^{(24)} \hat{\beta}$, $\mathbf{e}^{(24)} = \mathbf{y}^{(24)} - \hat{\mathbf{y}}^{(24)}$.
- 4 **Out-of-sample:** $\hat{\mathbf{y}}^{(25)} = \mathbf{X}^{(25)} \hat{\beta}$, $\mathbf{e}^{(25)} = \mathbf{y}^{(25)} - \hat{\mathbf{y}}^{(25)}$.

Model A

Model A — harmoniczny $k = 1$: specyfikacja

Model: $T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \varepsilon_i$, gdzie $\theta_i = 2\pi d_i/366$. **Macierz $\mathbf{X}^{(24)}$ i wektor $\mathbf{y}^{(24)}$:**

$$\mathbf{X}^{(24)} = \begin{pmatrix} 1 & +0,2547 & +0,9670 \\ 1 & +0,7101 & +0,7041 \\ \vdots & \vdots & \vdots \\ 1 & -0,2712 & +0,9625 \end{pmatrix}_{12 \times 3}, \quad \mathbf{y}^{(24)} = \begin{pmatrix} -2,15 \\ +4,05 \\ \vdots \\ +2,72 \end{pmatrix}.$$

Liczba parametrów

$k = 3$ niewiadome $(\beta_0, \beta_1, \beta_2)$, $n = 12$ równań. Układ *nadokreślony* ($n > k$) — klasyczna sytuacja OLS.

Uwaga

Macierz $\mathbf{X}^{(25)}$ ma *identyczne* cechy $\sin \theta_i, \cos \theta_i$ (te same dni roku) — ale jej $\mathbf{y}^{(25)}$ to inne wartości. Te same kolumny $\mathbf{X}$, inne $\mathbf{y}$.

Model A — rachunki na zbiorze treningowym (2024)

Krok 1. $\mathbf{X}^{(24)\top} \mathbf{X}^{(24)}$ (sumujemy po 12 miesiącach):

$$\mathbf{X}^{(24)\top} \mathbf{X}^{(24)} = \begin{pmatrix} 12 & 0,04 & 0,01 \\ 0,04 & 6,02 & 0,00 \\ 0,01 & 0,00 & 5,98 \end{pmatrix} \approx \text{diag}(12, 6,02, 5,98).$$

Krok 2. $\mathbf{X}^{(24)\top} \mathbf{y}^{(24)}$:

$$\mathbf{X}^{(24)\top} \mathbf{y}^{(24)} = \begin{pmatrix} \sum T_i^{(24)} \\ \sum T_i^{(24)} \sin \theta_i \\ \sum T_i^{(24)} \cos \theta_i \end{pmatrix} = \begin{pmatrix} 124,29 \\ -15,15 \\ -59,49 \end{pmatrix}.$$

Krok 3. Rozwiązanie:

$$\hat{\boldsymbol{\beta}}_A = \begin{pmatrix} 10,38 \\ -2,58 \\ -9,97 \end{pmatrix}$$

Model A — reszty in-sample (2024) i out-of-sample (2025)

d_i	Train: rok 2024			Test: rok 2025		
	$T_i^{(24)}$	$\hat{T}_i^{(24)}$	$e_i^{(24)}$	$T_i^{(25)}$	$\hat{T}_i^{(25)}$	$e_i^{(25)}$
15	-2,15	+0,08	-2,23	+1,34	+0,08	+1,26
46	+4,05	+1,53	+2,52	-1,60	+1,53	-3,13
75	+5,12	+5,11	+0,01	+5,08	+4,96	+0,12
106	+9,44	+10,33	-0,89	+9,61	+10,15	-0,54
136	+16,31	+15,41	+0,90	+10,09	+15,25	-5,17
167	+18,03	+19,27	-1,24	+16,36	+19,18	-2,82
197	+20,03	+20,67	-0,64	+18,17	+20,67	-2,50
228	+19,89	+19,31	+0,57	+17,10	+19,40	-2,30
259	+17,72	+15,49	+2,24	+15,21	+15,64	-0,43
289	+9,27	+10,42	-1,15	+8,05	+10,60	-2,55
320	+3,86	+5,19	-1,33	+3,23	+5,35	-2,12
350	+2,72	+1,48	+1,23	+2,18	+1,57	+0,60
RSS			24,87			69,39

Pierwsza obserwacja na 2025

RSS na 2025 jest **2,8 razy większe** niż na 2024. Większość reszt 2025 jest *ujemna* — model systematycznie przewiduje za wysoko, bo 2025 był chłodniejszy. To nie „wina” modelu — to wahania międzyroczne, których model nie zna.

Model B

Model B — harmoniczny + lag-1: specyfikacja

Model: $T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \beta_3 T_{i-1} + \varepsilon_i$. **Nowa cecha:** T_{i-1} = średnia temperatura poprzedniego miesiąca.

- ▶ Dla stycznia 2024 bierzemy grudzień 2023: $T_0^{(24)} = 0,66^\circ\text{C}$.
- ▶ Dla stycznia 2025 bierzemy grudzień 2024: $T_0^{(25)} = 2,72^\circ\text{C}$.

$$\mathbf{X}^{(24)} = \begin{pmatrix} 1 & +0,2547 & +0,9670 & +0,66 \\ 1 & +0,7101 & +0,7041 & -2,15 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & -0,2712 & +0,9625 & +3,86 \end{pmatrix}_{12 \times 4}.$$

Motywacja

Intuicja fizyczna: ciepły grudzień $\Rightarrow$ ciepły styczeń, bo masy powietrza i grunt przenoszą energię. To samo serce co modele autoregresyjne (AR), do których wrócimy w Części VI.

Model B — rachunki

$\mathbf{X}^\top \mathbf{X}$ już NIE jest diagonalna — T_{i-1} ma niezerowe iloczyny z $\sin \theta_i$ i $\cos \theta_i$:

$$\mathbf{X}^{(24)\top} \mathbf{X}^{(24)} = \begin{pmatrix} 12 & 0,04 & 0,01 & 7,88 \\ 0,04 & 6,02 & 0,00 & 5,06 \\ 0,01 & 0,00 & 5,98 & 27,45 \\ 7,88 & 5,06 & 27,45 & 197,3 \end{pmatrix}.$$

Rozwiązanie OLS:

$$\hat{\beta}_B = \begin{pmatrix} 13,30 \\ -4,67 \\ -12,16 \\ -0,29 \end{pmatrix}$$

Niepokojąca obserwacja

Współczynnik przy lag-1 wynosi $\hat{\beta}_3 = -0,29$ — **ujemny i bliski zera!** Zgodnie z modelem, „wczorajsza temperatura ma odjąć coś od dzisiejszej”. To kompletnie niefizyczne. Co więcej, **wszystkie** pozostałe współczynniki uległy znacznym zmianom względem modelu A. Współliniowość rozregulowała OLS.

Model B — reszty in-sample i out-of-sample

d_i	Train: rok 2024			Test: rok 2025		
	$T_i^{(24)}$	$\hat{T}_i^{(24)}$	$e_i^{(24)}$	$T_i^{(25)}$	$\hat{T}_i^{(25)}$	$e_i^{(25)}$
15	-2,15	+0,16	-2,32	+1,34	-0,42	+1,76
46	+4,05	+2,04	+2,01	-1,60	+1,04	-2,64
75	+5,12	+4,26	+0,86	+5,08	+5,70	-0,62
106	+9,44	+10,30	-0,87	+9,61	+10,10	-0,49
136	+16,31	+15,64	+0,67	+10,09	+15,38	-5,30
167	+18,03	+19,07	-1,04	+16,36	+20,72	-4,36
197	+20,03	+21,06	-1,03	+18,17	+21,51	-3,34
228	+19,89	+19,53	+0,35	+17,10	+20,15	-3,05
259	+17,72	+15,31	+2,42	+15,21	+16,29	-1,08
289	+9,27	+9,76	-0,48	+8,05	+10,70	-2,65
320	+3,86	+5,40	-1,54	+3,23	+5,96	-2,73
350	+2,72	+1,76	+0,96	+2,18	+2,08	+0,10
RSS			22,98			93,90

Pierwszy dowód przeuczenia

RSS na 2024 spadło z 24,87 (model A) na 22,98 (model B). *Pozornie poprawa.* Ale RSS na 2025 wzrosło z 69,39 do **93,90** — o 35%! Model B *nauczył się szumu* 2024, a na 2025 *daje gorsze prognozy* niż prostszy model A. **Walidacja out-of-sample obnażyła pułapkę**, której R^2 in-sample nie widziało.

Model C_1

Model C_1 — leakage z `apparent_temperature`

Model: $T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \beta_3 A_i + \varepsilon_i$, gdzie A_i to średnia miesięczna temperatura odczuwalna (`apparent_temperature`). **Wynik OLS:**

$$\hat{\beta}_{C_1} = (3,71; 0,25; 0,44; 0,87)^\top, \quad R^2 = 0,9987.$$

Wszystkie współczynniki harmoniczne **niemal zerowe** (sin: 0,25 vs 2,58; cos: 0,44 vs 9,97). $\hat{\beta}_{\cos}$ **zmienił znak!** Tylko `apparent_temp` „liczy się”.

Diagnoza problemu

`apparent_temperature` to *deterministyczna funkcja* temperatury — wzór z T , wiatru i wilgotności. Korelacja 0,9992 z T to nie talent atrybutu, to **matematyczna tożsamość ukryta w danych**. Model przewiduje T z funkcji T . To klasyczny *data leakage*.

Model C_1 — reszty in-sample i out-of-sample

d_i	Train: rok 2024			Test: rok 2025		
	$T_i^{(24)}$	$\hat{T}_i^{(24)}$	$e_i^{(24)}$	$T_i^{(25)}$	$\hat{T}_i^{(25)}$	$e_i^{(25)}$
15	-2,15	-2,07	-0,08	+1,34	+1,64	-0,31
46	+4,05	+4,16	-0,11	-1,60	-0,90	-0,70
75	+5,12	+5,13	-0,00	+5,08	+5,12	-0,04
106	+9,44	+9,13	+0,31	+9,61	+9,54	+0,07
136	+16,31	+15,99	+0,32	+10,09	+9,92	+0,17
167	+18,03	+18,26	-0,23	+16,36	+16,10	+0,26
197	+20,03	+20,46	-0,43	+18,17	+18,94	-0,77
228	+19,89	+20,11	-0,22	+17,10	+17,36	-0,26
259	+17,72	+17,21	+0,51	+15,21	+15,54	-0,33
289	+9,27	+9,08	+0,19	+8,05	+7,85	+0,19
320	+3,86	+3,83	+0,03	+3,23	+3,74	-0,51
350	+2,72	+3,01	-0,29	+2,18	+2,69	-0,52
RSS			0,88			2,03

Niepokojąco świetnie

Model C_1 ma **rewelacyjne** reszty zarówno na 2024 ($\max |e| = 0,51$), jak i na 2025 ($\max |e| = 0,77$). RSS na 2025 jest tylko 2,3 razy większe niż na 2024 — lepszy stosunek niż model A (2,8). **Walidacja nie obnaża problemu**. Czemu? Bo *leakage przenika oba zbiory*: `apparent_temperature` w 2025 też zawiera ukrytą wartość $T^{(25)}$.

Model C_2

Model C_2 — leakage z 6 atrybutami meteo

Model: $T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \sum_{j=1}^6 \gamma_j \cdot \text{atr}_i^{(j)} + \varepsilon_i$, $k = 9$. Dodajemy wszystkie atrybuty meteorologiczne z bazy: `apparent_temp`, `dew_point`, `humidity`, `pressure`, `wind_speed`, `cloud_cover`. **Wynik OLS:**

$$\hat{\beta}_{C_2} \approx (-4,43; 0,15; 0,63; 0,48; 0,48; -0,14; 0,02; 0,08; 0,00)^\top, \quad R_{2024}^2 = 0,99997.$$

$n = 12$ obserwacji, $k = 9$ parametrów

Mamy tylko 3 stopnie swobody! Model praktycznie **przechodzi przez wszystkie punkty**. $RSS = 0,023$ — pozostałość $\sigma \approx 0,04^\circ\text{C}$, gdy oryginalna zmienność temperatury to $\pm 11^\circ\text{C}$.

Spektakularne dopasowanie, ale ile warte?

Cztery z sześciu atrybutów (`apparent`, `dew_point`, `humidity`, `cloud_cover`) są silnie skorelowane z temperaturą. To wszystko *ta sama informacja powtórzona*. Skutek: ogromna współliniowość ($\text{cond} \approx 10^{12}$), ale *pozornie genialne* dopasowanie.

Model C₂ — reszty in-sample i out-of-sample

d_i	Train: rok 2024			Test: rok 2025		
	$T_i^{(24)}$	$\hat{T}_i^{(24)}$	$e_i^{(24)}$	$T_i^{(25)}$	$\hat{T}_i^{(25)}$	$e_i^{(25)}$
15	-2,15	-2,15	-0,00	+1,34	+1,30	+0,04
46	+4,05	+3,99	+0,06	-1,60	-1,15	-0,45
75	+5,12	+5,18	-0,05	+5,08	+5,19	-0,11
106	+9,44	+9,48	-0,05	+9,61	+9,71	-0,10
136	+16,31	+16,27	+0,04	+10,09	+9,69	+0,40
167	+18,03	+17,96	+0,07	+16,36	+16,25	+0,11
197	+20,03	+20,06	-0,04	+18,17	+17,95	+0,22
228	+19,89	+19,95	-0,06	+17,10	+16,97	+0,13
259	+17,72	+17,72	-0,00	+15,21	+15,31	-0,10
289	+9,27	+9,23	+0,04	+8,05	+7,75	+0,29
320	+3,86	+3,85	+0,02	+3,23	+2,87	+0,36
350	+2,72	+2,75	-0,03	+2,18	+2,13	+0,04
RSS			0,023			0,69

Najbardziej alarmujący wynik

RSS skoczył z 0,023 na 0,69 — **30-krotny wzrost!** To jasny znak *przeuczenia*. Ale wciąż 0,69 to lepiej niż 69,39 modelu A. Walidacja **wciąż nie obnaża** strukturalnego problemu — wskazuje tylko, że model uczy się szumu. **Najgłębsza pułapka, jaką spotkamy.**

Model D

Model D — dwa harmoniki: specyfikacja

Model: $T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \beta_3 \sin 2\theta_i + \beta_4 \cos 2\theta_i + \varepsilon_i$. Druga para harmoników: $\sin(4\pi d/366)$ i $\cos(4\pi d/366)$ — fala o *podwójnej* częstotliwości (dwa cykle na rok). Pozwala uchwycić *asymetrię sezonów*: szybkie wiosenne ocieplenie vs powolne jesienne wystudzenie. $\mathbf{X}^{(24)\top} \mathbf{X}^{(24)}$ pozostaje **prawie diagonalna**:

$$\mathbf{X}^{(24)\top} \mathbf{X}^{(24)} \approx \text{diag}(12, 6,02, 5,98, 6,02, 5,98).$$

Rozwiązanie OLS:

$$\hat{\beta}_D = (10,37; -2,59; -9,97; 0,70; -0,44)^\top.$$

Kluczowa obserwacja

Współczynniki *pierwszego* harmonika **prawie nie drgnęły** (10,37 vs 10,38; -2,59 vs -2,58; -9,97 vs -9,97). To dzięki ortogonalności — dodanie nowych cech *nie burzy* interpretacji starych. Druga para wnosi małą poprawkę: amplituda $\sqrt{0,70^2 + 0,44^2} = 0,83^\circ\text{C}$, czyli ok. 8% siły pierwszego harmonika.

Model D — reszty in-sample i out-of-sample

d_i	Train: rok 2024			Test: rok 2025		
	$T_i^{(24)}$	$\hat{T}_i^{(24)}$	$e_i^{(24)}$	$T_i^{(25)}$	$\hat{T}_i^{(25)}$	$e_i^{(25)}$
15	-2,15	+0,03	-2,19	+1,34	+0,03	+1,30
46	+4,05	+2,23	+1,82	-1,60	+2,23	-3,83
75	+5,12	+5,86	-0,73	+5,08	+5,72	-0,64
106	+9,44	+10,38	-0,94	+9,61	+10,23	-0,62
136	+16,31	+14,72	+1,59	+10,09	+14,58	-4,49
167	+18,03	+18,52	-0,49	+16,36	+18,42	-2,06
197	+20,03	+20,60	-0,58	+18,17	+20,57	-2,40
228	+19,89	+20,01	-0,12	+17,10	+20,08	-2,98
259	+17,72	+16,23	+1,49	+15,21	+16,40	-1,19
289	+9,27	+10,48	-1,21	+8,05	+10,68	-2,64
320	+3,86	+4,49	-0,63	+3,23	+4,66	-1,43
350	+2,72	+0,73	+1,99	+2,18	+0,81	+1,37
RSS			20,68			68,59

Uczciwa poprawa względem A

Train: 20,68 vs 24,87 modelu A (17% poprawa). Test: 68,59 vs 69,39 modelu A (1% poprawa). Stosunek test/train = 3,32 vs 2,79 dla A — **nieco gorzej generalizuje**. Czyli D dopasowuje się trochę lepiej, ale tylko nieznacznie lepiej prognozuje. Czy warta inwestycja 2 parametrów? Tu właśnie przyda się AIC.

Diagnostyka geometrii cech modelu

np. za pomocą

$\text{cond}(\mathbf{X}^\top \mathbf{X})$

(moc uwarunkowania)

Motywacja: dlaczego sama wartość $\hat{\beta}$ to za mało?

Po Części I wiemy, że *wszystkie* cztery modele dają jakieś rozwiązanie OLS. Ale wiemy też, że niektóre z nich (B, C_1 , C_2) miały dziwne objawy:

- ▶ Współczynniki „skaczą” przy dodawaniu cech (B: $\hat{\beta}_{\sin}$ z $-2,58$ na $-4,67$).
- ▶ Znaki niespodziewane (C_1 : $\hat{\beta}_{\cos}$ z $-9,97$ na $+0,44$).
- ▶ Macierz $\mathbf{X}^\top \mathbf{X}$ *prawie osobliwa* (C_2 : wyznacznik bliski zera).

Pytanie diagnostyczne

Czy istnieje **jednoliczbowy wskaźnik**, który powie, „jak bardzo” kolumny macierzy $\mathbf{X}$ są niezależne (czyli jak „zdrowa” jest geometria cech)? Tak — nawet **dwa**: $\text{cond}(\mathbf{X}^\top \mathbf{X})$ i VIF.

Co naprawdę mierzymy

Geometria cech zależy tylko od macierzy $\mathbf{X}$ — nie od $\mathbf{y}$. Te diagnostyki są *identyczne* dla 2024 i 2025, bo $\sin \theta_i$, $\cos \theta_i$ to te same wartości w obu latach. Dla modeli B, C_1 , C_2 zmieniają się tylko nieznacznie (wartości cech rok do roku różnią się).

Moc uwarunkowania $\text{cond}(\mathbf{X}^\top \mathbf{X})$

Definicja Mocy Uwarunkowania (przez wartości własne)

Niech $\lambda_{\max}, \lambda_{\min} > 0$ to największa i najmniejsza wartość własna macierzy symetrycznej dodatniej $\mathbf{X}^\top \mathbf{X}$. Wtedy:

$$\text{cond}(\mathbf{X}^\top \mathbf{X}) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Intuicja geometryczna: kolumny $\mathbf{X}$ wyznaczają w $\mathbb{R}^n$ „równoległoscian”. Wartości własne $\mathbf{X}^\top \mathbf{X}$ to kwadraty długości jego osi głównych. Jeśli wszystkie kolumny są *ortogonalne i tej samej długości*, równoległoscian jest sześcianem, $\lambda_{\max}/\lambda_{\min} = 1$. Jeśli kolumny są *prawie współliniowe*, jedna oś jest bardzo krótka, $\lambda_{\min} \rightarrow 0$, $\text{cond} \rightarrow \infty$.

Praktyczna interpretacja

- ▶ $\text{cond} = 1$ — ortogonalność idealna (cechy w pełni niezależne).
- ▶ $\text{cond} < 30$ — zdrowa geometria.
- ▶ $30 < \text{cond} < 100$ — umiarkowana współliniowość.
- ▶ $\text{cond} > 100$ — silna współliniowość, $\hat{\beta}$ może być **numerycznie niestabilna**.
- ▶ $\text{cond} > 10^6$ — praktyczna osobliwość, wyniki niewiarygodne.

Moc uwarunkowania $\text{cond}(\mathbf{X}^\top \mathbf{X})$ dla naszych modeli

Model	k	$\text{cond}(\mathbf{X}^\top \mathbf{X})$	Werdykt
A	3	2,01	idealna ortogonalność
B	4	$1,86 \cdot 10^4$	silna współliniowość
C ₁	4	$1,15 \cdot 10^4$	
C ₂	9	$1,70 \cdot 10^{12}$	praktyczna osobliwość
D	5	2,02	idealna ortogonalność

Co widać

- ▶ Modele **A i D** mają identyczny wskaźnik 2,0 — mimo że D ma więcej cech! Dodatkowa para sin/cos jest *ortogonalna* do oryginalnej. To prawda Fouriera: regularne próbkowanie funkcji trygonometrycznych zachowuje ortogonalność.
- ▶ Modele **B, C₁, C₂** są **kategorycznie inne** — współczynniki cond rzędu 10^4 – 10^{12} .

Ograniczenie cond

Cond jest *globalny* — mówi tylko „coś jest nie tak”, ale nie wskazuje, **która konkretnie cecha** jest winowajcą. Tu właśnie wchodzi VIF.

VIF — Variance Inflation Factor

VIF — Variance Inflation Factor: definicja

Definicja operacyjna

Dla każdej cechy j (oprócz stałej) liczymy *regresję pomocniczą*: regresujemy $\mathbf{X}_{:,j}$ na wszystkie pozostałe cechy:

$$\mathbf{X}_{:,j} = \alpha_0 + \sum_{l \neq j} \alpha_l \mathbf{X}_{:,l} + u_j.$$

Niech R_j^2 to współczynnik determinacji tej regresji. Wtedy:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

Interpretacja — mnożnik wariancji

Można pokazać, że $\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(n-1) \text{Var}(X_j)} \cdot \text{VIF}_j$. Czyli VIF mówi, **ile razy** wariancja estymatora $\hat{\beta}_j$ jest większa, niż gdyby cecha X_j była *ortogonalna* do reszty.

$\text{VIF} = 10 \Rightarrow$ błąd standardowy $\hat{\beta}_j$ jest $\sqrt{10} \approx 3,2$ razy większy niż w sytuacji ortogonalności.

VIF — progi i interpretacja

VIF_j	R_j^2	Interpretacja
≈ 1	≈ 0	Cecha <i>ortogonalna</i> do reszty — idealnie.
1 – 5	0 – 0,8	Umiarkowana korelacja — zwykle akceptowalne.
5 – 10	0,8 – 0,9	Wyraźna współliniowość — uważać.
> 10	$> 0,9$	Silna współliniowość — klasyczna „czerwona flaga”.
> 100	$> 0,99$	Praktyczna współliniowość (cecha prawie „duplikat”).

Trzy zalety VIF nad cond

- 1 **Per-cecha** — wskazuje *konkretną* winowajczynię, a nie tylko że „coś jest złe”.
- 2 **Niezależne od skali** — bazuje na R^2 , więc nieczułe na różnice jednostek (cm vs km).
- 3 **Intuicyjna interpretacja** — „mój błąd standardowy jest $\sqrt{VIF}$ razy większy”.

VIF dla naszych modeli

Model A		Model B		Model C ₁		Model D	
Cecha	VIF	Cecha	VIF	Cecha	VIF	Cecha	VIF
$\sin \theta$	1,00	$\sin \theta$	14,9	$\sin \theta$	3,0	$\sin \theta$	1,00
$\cos \theta$	1,00	$\cos \theta$	16,3	$\cos \theta$	28,0	$\cos \theta$	1,00
		T_{-1}	30,2	A	30,0	$\sin 2\theta$	1,00
						$\cos 2\theta$	1,00

Model C₂ (osobno, bo dużo cech):

Cecha	sin	cos	app	dew	hum	prs	wnd	cld
VIF	14	30	1339	685	125	11	15	11

VIF wskazuje palcem winowajców

- ▶ **Model B:** lag-1 (VIF=30) jest skorelowany z parą $\sin / \cos$ (sam koduje sezonowość!). Korelacja T_{-1} z $\sin$: $-0,68$; z $\cos$: $-0,71$.
- ▶ **Model C₁:** `apparent_temp` i $\cos \theta$ są *prawie* duplikatami (korelacja $-0,95$).
- ▶ **Model C₂:** `apparent_temp` i `dew_point` — VIF > 1000. **Klasyczna współliniowość ekstremna:** te zmienne są *prawie matematycznie tożsame*.

Cond vs VIF — kiedy które (1/2)?

Cond($\mathbf{X}^\top \mathbf{X}$)

Co umie:

- ▶ Jednoliczbowy „termometr” całej macierzy.
- ▶ Bezpośrednio związany ze stabilnością numeryczną.
- ▶ Łatwy do policzenia (jedno SVD).

Czego nie umie:

- ▶ **Wrażliwy na skalę** cech (bez standaryzacji bezsensowny).
- ▶ Nie wskazuje konkretnej winowajczyny.

VIF

Co umie:

- ▶ Per-cecha — wskazuje *kogo* wyrzucić.
- ▶ Niezależne od skali (bazuje na R^2).
- ▶ Bezpośrednio interpretowalne (mnożnik wariancji).

Czego nie umie:

- ▶ Wymaga $k - 1$ regresji pomocniczych.
- ▶ Nieinformatywny dla cech idealnie skorelowanych ($R_j^2 \rightarrow 1$).

Cond vs VIF — kiedy które (2/2)?

W praktyce: używamy obu

Cond jako szybkie „sprawdzenie temperatury”. Jeśli wysokie — liczymy VIF dla *lokalizacji* problemu i decydujemy: usuwać cechę, łączyć cechy, czy stosować regularyzację (Ridge, Lasso). To są tematy Wykładu o regularyzacji.


Czego **ani cond, ani VIF** nie wykryją

Modele A i D mają identyczne, idealne wskaźniki — ale jeden jest prostszy, drugi bardziej elastyczny. Geometria cech *nie mówi nic o przeuczeniu*. To zostawimy walidacji modelu na próbce walidacyjnej.

Co mówią reszty ?

Co mówią reszty — wykres e_i vs $\hat{T}_i$

Zaczynamy od najprostszej diagnostyki: rysujemy reszty względem przewidywań. Powinny układać się w *losową chmurę* bez wzorca.




Co widać


Modele A, B, D mają reszty rzędu $\pm 2^\circ\text{C}$, rozproszone bez wyraźnego wzorca. Model C₁ ma reszty rzędu $\pm 0,5^\circ\text{C}$. **Wszystkie wyglądają OK** na pierwszy rzut oka — ale to dopiero *in-sample*. Teraz porównamy z *out-of-sample*.

Reszty 2024 vs 2025 — Model A

Reszty 2024 (in-sample)



Reszty 2025 (out-of-sample)




Dwa różne objawy

2024: reszty rozproszone symetrycznie wokół zera (gwarantowane przez OLS, $\sum e_i = 0$).


2025: reszty **przeważnie ujemne**, średnia $-1,63$ °C. Model A systematycznie przewiduje za wysoko, bo 2025 był chłodniejszy niż 2024. To *niemodelowany trend roczny* — model nie zna „wahań międzyrocznych”.

Reszty 2024 vs 2025 — Model B (z lagiem)

Reszty 2024 (in-sample)



Reszty 2025 (out-of-sample)




Model B vs Model A na 2025

Reszty 2025 modelu B są **większe i bardziej ujemne** niż A. Średnia spadła z $-1,63$ (A) do $-2,03$ (B).

Dlaczego? Lag-1 „wsiąka” w sezonowość przez współliniowość — co skutkuje napompowanymi $\hat{\beta}_{\sin}, \hat{\beta}_{\cos}$ ($-4,67$ i $-12,16$ vs $-2,58$ i $-9,97$). Te „napompowane” współczynniki dają większe prognozy w lecie, więc reszty $T - \hat{T}$ stają się bardziej ujemne. **Przeuczenie ujawnia się tu jako podwójnie zły bias.**

Reszty 2024 vs 2025 — Model C_1 (z leakage)




Niepokojąco świetne

Skala reszt C_1 na 2025 jest ~ 5 razy mniejsza niż reszty A na 2024! Maksymalna reszta to zaledwie $-0,77^\circ\text{C}$. Model *wygląda* jak „świetnie generalizujący”.

Ale to złudzenie: cecha `apparent_temperature` 2025 *zawiera w sobie* ukrytą wartość $T^{(25)}$. Walidacja out-of-sample testuje, czy model *generalizuje* — ale tu cecha sama „podpowiada” modelowi odpowiedź. **To leakage przeprowadzony przez bramkę walidacji.**


Reszty 2024 vs 2025 — Model D (drugi harmonik)

Reszty 2024 (in-sample)



RSS = 20,68, $\bar{e} = 0,00$

Reszty 2025 (out-of-sample)



RSS = 68,59


Model D vs Model A na 2025

Reszty D na 2025 są **niemal identyczne** jak A: średnia $-1,64$ vs $-1,63$, RSS 68,59 vs 69,39.

Wniosek: drugi harmonik daje pewną drobną poprawę in-sample (RSS spadło z 24,87 na 20,68, czyli o 17%), ale **prawie zero poprawy out-of-sample**. D *lepiej dopasowuje się* do roku 2024, ale nie *lepiej generalizuje*. To bardziej „delikatne” przeuczenie niż w przypadku B — ale o tej samej naturze.

Reszty vs czas — pojawia się autokorelacja

Reszty modelu A na zbiorze 2024 ułożone w kolejności kalendarzowej:



Coś tu jest — wzorzec „zygzakiem”

Reszty mają tendencję do **zmiany znaku** między sąsiednimi miesiącami: $-$, $+$, $+$, $-$, $+$, $-$, $-$, $+$, $+$, $-$, $-$, $+$. Autokorelacja pierwszego rzędu: $\rho_1 = -0,39$ — **ujemna**. Model A pomija drobne odchylenia trygonometryczne (asymetria sezonów), które „wyciekają” do reszt w sposób systematyczny.

Co to znaczy formalnie

Założenie „I” z LINE (Independence) jest **naruszone** — reszty są skorelowane. To nie unicestwia OLS, ale podważa wiarygodność testów istotności i przedziałów ufności w klasycznej teorii. Potrzebujemy formalnego *testu* na autokorelację.

Test Durbina-Watsona

Definicja statystyki

Niech $e_1, e_2, \dots, e_n$ to reszty modelu OLS. Statystyka Durbina-Watsona:

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}.$$

Można pokazać, że $DW \approx 2(1 - \hat{\rho}_1)$, gdzie $\hat{\rho}_1$ to autokorelacja pierwszego rzędu.

$\hat{\rho}_1$	DW	Interpretacja
$\rho_1 = 0$	DW ≈ 2	brak autokorelacji (idealnie)
$\rho_1 > 0$	DW < 2	dodatnia autokorelacja (reszty utrzymują znak)
$\rho_1 < 0$	DW > 2	ujemna autokorelacja (reszty oscylują)

Praktyczne progi (dla małych n są szerokie „strefy niepewności”)

- ▶ DW $\in [1,5; 2,5]$ — akceptowalne (brak silnej autokorelacji)
- ▶ DW $< 1,5$ lub DW $> 2,5$ — problem
- ▶ DW < 1 lub DW > 3 — silna autokorelacja

Test Durbin-Watsona

Durbin-Watson dla naszych modeli (2024 i 2025) — z ostrzeżeniem

Model	$\hat{\rho}_1$ (2024)	DW ₂₀₂₄	$\hat{\rho}_1$ (2025)	DW ₂₀₂₅
A	−0,39	2,42	−0,21	1,05
B	−0,26	2,19	+0,08	0,67
C ₁	+0,25	1,43	−0,01	1,34
C ₂	+0,00	1,95	+0,19	1,48
D	−0,54	2,45	−0,35	1,06

Subtelna lekcja: DW na zbiorze testowym ma INNA interpretację

DW na 2025 spada do 1,05 dla modelu A. Wygląda jak **silna autokorelacja**. Ale czy *naprawdę* jest? Spójrz na statystykę uważnie: *reszty wycentrowane* (po odjęciu średniej $-1,63$) dają $\rho_1 = -0,21$ — a **DW po wycentrowaniu wynosi 1,94**, niemal idealne!

Wniosek: niskie DW na 2025 **nie jest objawem prawdziwej autokorelacji**, tylko *systematycznego przesunięcia* reszt. DW miesza dwa zjawiska: bias i autokorelację.

Sens diagnostyczny: DW jest dla reszt OLS takich, że $\sum e_i = 0$ z def. (na zbiorze treningowym).

Na *nowym* zbiorze, gdzie ta równość nie zachodzi, klasyczne progi DW **nie obowiązują**. To kolejny argument: walidacja out-of-sample wymaga *innych* narzędzi diagnostycznych niż in-sample.

Wskaźnik determinacji R^2 oraz
Skorygowany Wskaźnik R^2

R^2 — przypomnienie definicji

Definicja

Dla regresji z wyrazem wolnym:

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad \text{gdzie } \text{RSS} = \sum e_i^2, \quad \text{TSS} = \sum (y_i - \bar{y})^2.$$

Interpretacja: *ułamek wariancji y wyjaśniony przez model.* $R^2 = 1$ to dopasowanie idealne, $R^2 = 0$ to model nie lepszy od prostej średniej $\bar{y}$.

Trzy znane pułapki R^2

- 1 R^2 **nigdy nie maleje** przy dodawaniu cech — nawet czysto losowych.
- 2 R^2 jest **ślepy na strukturę reszt** (autokorelacja, heteroskedastyczność).
- 3 R^2 **nie wie nic o leakage** — premiuje go wręcz dramatycznie.

Pytanie dydaktyczne

Czy R^2 liczone na zbiorze testowym (out-of-sample) ratuje sytuację? *Czasem tak, ale jak zobaczymy — nie wobec leakage.*

R^2 in-sample dla naszych modeli

Model	k	RSS (2024)	R^2_{2024}	Werdykt R^2
A	3	24,87	0,9623	dobrze dopasowanie
B	4	22,98	0,9651	nieznaczna poprawa
C ₁	4	0,88	0,9987	„prawie idealne”
C ₂	9	0,023	0,99997	„praktycznie idealne”
D	5	20,68	0,9686	poprawa względem A

Według R^2 ranking jest jednoznaczny

$C_2 > C_1 > D > B > A$

Bezkrytyczne stosowanie R^2 wybrałoby model C₂ — z 9 parametrami i $\text{cond}(\mathbf{X}^\top \mathbf{X}) = 10^{12}$ — jako „najlepszy”. To **jaskrawe pogwałcenie zdrowego rozsądku**.

Co naprawić

R^2 trzeba uzupełnić o *karę za złożoność*. Najprostsza forma — R^2 skorygowane.

R^2 skorygowane — wzór i wyprowadzenie

Definicja

$$R_{\text{adj}}^2 = 1 - \frac{\text{RSS}/(n-k)}{\text{TSS}/(n-1)} = 1 - (1 - R^2) \frac{n-1}{n-k}.$$

Skąd ta forma? Zamiast porównywać surowe sumy kwadratów RSS i TSS, porównujemy ich *nieobciążone estymatory wariancji*: $s_{\text{model}}^2 = \text{RSS}/(n-k)$ i $s_{\text{TSS}}^2 = \text{TSS}/(n-1)$.

Kluczowa własność

- ▶ Czynniki $(n-1)/(n-k)$ **rośnie**, gdy k rośnie — co zwiększa karę.
- ▶ Jeśli nowa cecha redukuje RSS *nieproporcjonalnie* do wzrostu k , R_{adj}^2 **maleje**.
- ▶ Dla losowych cech (brak prawdziwej informacji), R_{adj}^2 średnio *maleje*, podczas gdy R^2 rośnie.

Granica zastosowania

R_{adj}^2 może być **ujemne** — model gorszy od trywialnej średniej. Dla k bliskiego n kara robi się ogromna, $R_{\text{adj}}^2 \rightarrow -\infty$. To poprawnie odzwierciedla „nie mam stopni swobody”.

R^2 skorygowane dla naszych modeli

Model	k	R^2_{2024}	$\frac{n-1}{n-k}$	R^2_{adj}	Zmiana
A	3	0,9623	$11/9 = 1,22$	0,9539	—
B	4	0,9651	$11/8 = 1,38$	0,9521	spadek!
C ₁	4	0,9987	$11/8 = 1,38$	0,9982	wzrost
C ₂	9	0,99997	$11/3 = 3,67$	0,9999	nieznaczna zmiana
D	5	0,9686	$11/7 = 1,57$	0,9507	spadek!

Co się zmieniło

- ▶ Wśród „uczciwych” modeli (A, B, D) **najwyższe R^2_{adj} ma A!** Mimo że R^2 było najniższe.
- ▶ Model B (lag-1) wyleciał *poniżej* A — kara większa niż zysk.
- ▶ Model D (drugi harmonik) też wyleciał poniżej A — dwie dodatkowe cechy nie warte poprawy RSS o 17%.

Ale leakage wciąż wygrywa

R^2_{adj} **nadal wybiera C₂ jako „najlepszy”**. Bo R^2 było prawie 1, kara za 9 parametrów (na 12 obserwacji!) nie wystarczy. **Klasyczne kryteria są ślepe na strukturalne wady danych.**

R^2 out-of-sample (na zbiorze testowym 2025)

R^2 można policzyć też na zbiorze testowym — używając $\hat{\beta}$ z 2024, ale RSS i TSS z 2025:

$$R^2_{\text{test}} = 1 - \frac{\sum (T_i^{(25)} - \hat{T}_i^{(25)})^2}{\sum (T_i^{(25)} - \bar{T}^{(25)})^2}.$$

Model	R^2_{2024}	R^2_{adj}	R^2_{2025}	$\Delta = R^2_{2024} - R^2_{2025}$
A	0,9623	0,9539	0,8640	-0,098
B	0,9651	0,9521	0,8160	-0,149
C ₁	0,9987	0,9982	0,9960	-0,003
C ₂	0,99997	0,9999	0,9986	-0,001
D	0,9686	0,9507	0,8656	-0,103

Dwa fascynujące wnioski

- 1 Model B ma **największy spadek R^2 między 2024 a 2025**: $0,965 \rightarrow 0,816$, $\Delta = 14,9\%$. **Dowód przeuczenia**. A spadek dla A to tylko 9,8%.
- 2 Modele leakage (C₁, C₂) **prawie nie tracą R^2** — bo apparent_temperature 2025 zawiera ukrytą $T^{(25)}$. **Walidacja nie obnaża leakage**.

Cztery wersje R^2 — pełna tabela porównawcza (1/2)

Zbierzmy wszystkie wersje R^2 w jedną tabelę. Pierwsze dwa to in-sample, trzecie i czwarte to out-of-sample.

Model	R^2_{2024}	R^2_{adj}	R^2_{2025}	Δ	ranking <i>uczciwych</i>
A	0,962	0,954	0,864	−0,098	1. (wśród A,B,D)
B	0,965	0,952	0,816	− 0,149	3.
C ₁	0,999	0,998	0,996	−0,003	(leakage)
C ₂	1,000	1,000	0,999	−0,001	(leakage)
D	0,969	0,951	0,866	−0,103	2.

Cztery wersje R^2 — pełna tabela porównawcza (2/2)

Wniosek o modelach „uczciwych”

Po wykluczeniu leakage (C_1 , C_2), **wszystkie cztery wersje R^2 jednogłośnie wskazują model A** jako najlepszy:

- ▶ Najwyższe R^2_{adj} (kara za złożoność dobrze rozłożona).
- ▶ Najmniejszy spadek między 2024 a 2025 (najlepsza generalizacja).
- ▶ Najprostszy ($k = 3$).

Pułapka leakage trwa

R^2 skorygowane i R^2 out-of-sample **nie wystarczają**, żeby odsiać C_1 i C_2 . Potrzebujemy diagnostyk wymiaru *strukturalnego*, nie statystycznego — wiedzy dziedzinowej. To temat Części V.

Motywacja:

dlaczego potrzebujemy

jeszcze dodatkowe kryteria oceny modeli?

Wprowadzenie do wskaźników AIC oraz BIC

Motywacja: czemu jeszcze jedno kryterium?

Dotychczas mamy

- ▶ R^2 — mierzy dopasowanie, ale rośnie z liczbą cech.
- ▶ R^2_{adj} — karze złożoność, ale tylko poprzez prosty czynnik $(n - 1)/(n - k)$.

Co byśmy chcieli dodatkowo

Kryterium, które:

- ▶ ma **teoretyczne uzasadnienie** (nie tylko „karę za k ”)
- ▶ pozwala **porównywać modele** o różnej liczbie parametrów
- ▶ pozwala **rankować** modele w sposób ilościowy (ΔAIC)

Dwa klasyki: AIC i BIC

AIC (Akaike, 1974) wywodzi się z teorii informacji Kullbacka-Leiblera.

BIC (Schwarz, 1978) wywodzi się z bayesowskiej teorii porównania modeli.

Oba mają **tę samą strukturę**: „minus log-wiarygodność plus kara”, ale z różną siłą kary.

AIC dla OLS — wyprowadzenie

Ogólna definicja

$$\text{AIC} = -2\ell(\hat{\theta}) + 2k,$$

gdzie $\ell(\hat{\theta})$ to log-wiarygodność w maksimum (MLE), a k to liczba parametrów.

Dla OLS z założeniem gaussowskim $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$:

$$\ell(\hat{\beta}, \hat{\sigma}^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \hat{\sigma}^2 - \frac{1}{2\hat{\sigma}^2} \underbrace{\sum (y_i - \mathbf{X}_i \hat{\beta})^2}_{=\text{RSS}}$$

W maksimum: $\hat{\sigma}^2 = \text{RSS}/n$, więc:

$$\ell_{\max} = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\text{RSS}/n) - \frac{n}{2}.$$

AIC dla OLS

$$\text{AIC} = n \log(\text{RSS}/n) + 2k + \text{const}$$

Niższe AIC = lepszy model. Stała nie ma znaczenia przy porównywaniu.

BIC dla OLS — wyprowadzenie

Ogólna definicja

$$\text{BIC} = -2 \ell(\hat{\theta}) + k \log n.$$

Dla OLS (analogicznie do AIC):

$$\text{BIC} = n \log(\text{RSS}/n) + k \log n + \text{const}$$

Aspekt	AIC	BIC
Kara za parametr	2 (stała)	$\log n$ (rośnie z próbą)
Dla $n = 12$	2	$\log 12 \approx 2,48$
Dla $n = 100$	2	$\log 100 \approx 4,61$
Dla $n = 10\,000$	2	$\log 10\,000 \approx 9,21$

Praktyczna różnica

BIC **silniej karze** złożoność (im większa próba, tym silniej). AIC dąży do modelu o najlepszej prognozie, BIC do modelu „najbliższego prawdy”.

AIC i BIC dla naszych modeli

Model	k	RSS (2024)	$\log(\text{RSS}/n)$	AIC	BIC
A	3	24,87	+0,73	48,80	50,25
B	4	22,98	+0,65	49,85	51,79
C ₁	4	0,88	-2,61	10,68	12,62
C ₂	9	0,023	-6,26	-22,90	-18,54
D	5	20,68	+0,54	50,59	53,01

Zaskakujące zwycięstwo leakage

Najniższe AIC i BIC ma model C₂! Drugie miejsce: C₁. Modele „uczciwe” (A, B, D) są **daleko za leakage**: AIC $\approx$ 49–50 vs -22 dla C₂. Różnica 70 jednostek!

Czemu kara nie wystarczy

Spójrz na człon $n \log(\text{RSS}/n)$: dla C₂ to $12 \cdot (-6,26) = -75$. Kara za 9 parametrów to tylko $2 \cdot 9 = 18$ (AIC). **Spadek RSS o cztery rzędy wielkości miażdży karę za złożoność.**

Po wykluczeniu leakage — ranking „uczciwych”

Model	k	AIC	BIC	$\Delta\text{AIC vs A}$	Werdykt
A	3	48,80	50,25	—	zwycięzca
B	4	49,85	51,79	+1,05	w strefie remisowej
D	5	50,59	53,01	+1,79	w strefie remisowej

Reguła Burnhama-Andersona dla ΔAIC

- ▶ $\Delta\text{AIC} < 2$ — modele **statystycznie nierozróżnialne**
- ▶ $\Delta\text{AIC} \in [2, 7]$ — słabe dowody przeciw gorszemu modelowi
- ▶ $\Delta\text{AIC} > 10$ — silne dowody, model gorszy do odrzucenia

Co to znaczy dla nas

Wszystkie trzy uczciwe modele mają $\Delta\text{AIC} < 2$ — są **nominalnie nierozróżnialne na 2024**. AIC daje miłą preferencję A, ale nie odrzuca B ani D.

Pamiętajmy: $n = 12$ to mała próba. Strefa niepewności jest szeroka.

Zgodność uczciwych kryteriów

Kryterium	A	B	D	Werdykt (uczciwe)
R_{adj}^2	0,9539	0,9521	0,9507	A najlepszy
AIC	48,80	49,85	50,59	A najlepszy
BIC	50,25	51,79	53,01	A najlepszy
R_{test}^2	0,864	0,816	0,866	D ślad. lepszy

Trzy kryteria zgodnie wybierają A

R_{adj}^2 , AIC, BIC — wszystkie trzy klasyczne kryteria informacyjne **zgodnie wskazują A** jako najlepszy uczciwy model.

Out-of-sample R^2 daje minimalną przewagę D (0,866 vs 0,864), ale różnica jest w trzecim miejscu po przecinku — czyli zupełnie nieistotna.

Ale klasyczne kryteria nadal premiuje leakage

Wszystkie trzy uczciwe kryteria (AIC, BIC, R_{adj}^2) wciąż wybierają C_2 jako „najlepszy”. **Strukturalna pułapka trwa**. Co jeszcze możemy zrobić?

Pipeline walidacji modeli regresji

Filozofia walidacji — po co?

Wszystkie dotychczasowe kryteria mają wspólną wadę

R^2 , R^2_{adj} , AIC, BIC, cond, VIF, DW — wszystkie liczone są **na tych samych danych**, na których model był fitowany. To są diagnostyki *in-sample*.

Ale prawdziwy test modelu prognostycznego to: „*jak działa na danych, których nigdy nie widział?*” To pytanie o **generalizację**.

Walidacja out-of-sample

Idea: dzielimy dane na zbiór *treningowy* (gdzie fitujemy model) i *testowy* (gdzie sprawdzamy generalizację).


W naszym studium: **2024 = train**, **2025 = test**. To naturalny podział — czas po prostu płynął, nie „wybraliśmy” arbitralnie.

Dlaczego to JEDYNE uczciwe kryterium

Każda diagnostyka *in-sample* może być oszukana przez model, który dopasowuje się do szumu (przeuczenie). Walidacja wymaga, by model *przewidział*, a nie tylko *odtworzył* dane.

Mocna teza: **tylko walidacja out-of-sample odpowiada na pytanie „czy model jest dobry”**. (Z jednym wyjątkiem — o nim za chwilę.)

Procedura walidacji — pipeline



Co liczymy i co porównujemy

- ▶ RSS_{2024} , RSS_{2025} — sumy kwadratów reszt
- ▶ $RMSE_{2024}$, $RMSE_{2025}$ — pierwiastki kwadratowe średnich kwadratów reszt (w jednostkach °C)
- ▶ MAE_{2024} , MAE_{2025} — średnie wartości bezwzględne reszt (bardziej odporne na outliery)
- ▶ RSS_{2025}/RSS_{2024} — „współczynnik degradacji”

Wyniki walidacji — tabela porównawcza

Model	RSS ₂₄	RSS ₂₅	RMSE ₂₄	RMSE ₂₅	ratio	Ranking
A	24,87	69,39	1,44	2,41	2,79	1. (uczciwe)
B	22,98	93,90	1,38	2,80	4,09	3. (przeucz.)
C ₁	0,88	2,03	0,27	0,41	2,31	2. (<i>leakage</i>)
C ₂	0,023	0,69	0,04	0,24	29,7	1. (<i>leakage</i>)
D	20,68	68,59	1,31	2,39	3,32	2. (uczciwe)

Trzy uderzające obserwacje

- 1 **Model B kompletnie przegrywa walidację:** $RSS_{25} = 93,9$ vs A 69,4. Dodanie lag-1 nie tylko nie pomogło, ale **aktywnie zaszkodziło**.
- 2 **Modele C₁, C₂ mają wciąż najlepsze wyniki:** $RSS_{25} = 2,03$ i 0,69. Leakage prześlizguje się przez walidację, bo **atributy meteo 2025 nadal zawierają ukrytą $T^{(25)}$** .
- 3 **Model C₂ ma stosunek 29,7:** to klasyczny objaw *przeuczenia* — RSS skoczyło 30-krotnie. Sygnał ostrzegawczy, ale wciąż RSS_{25} jest świetne.

Diagnoza A vs B — dowód przeuczenia z lagiem

Hipoteza w Części I: model B z lag-1 cierpi na współliniowość, co rozregulowuje współczynniki harmoniczne. **Pytanie kontrolne:** czy ta hipoteza ma poparcie out-of-sample?

Miara	Model A	Model B	Werdykt
RSS_{2024}	24,87	22,98	B nieznacznie lepszy
RSS_{2025}	69,39	93,90	A znacznie lepszy (−26%)
Stosunek deg.	2,79	4,09	B przeuczony
Średnia reszt 2025	−1,63	−2,03	B większy bias
$\hat{\beta}_{\sin}$	−2,58	−4,67	B napompowany
$\hat{\beta}_{\cos}$	−9,97	−12,16	B napompowany

Dowód: hipoteza potwierdzona—Wszystkie sześć miar wskazuje w tym samym kierunku:

model B *dopasowuje się do szumu* 2024 kosztem prognoz 2025. **Walidacja out-of-sample jest jedynym kryterium, które obnaża to bezpośrednio** — pozostałe (R^2 , AIC) dawały sygnał słaby (B przegrywał o włos).

Lekcja

Kryteria in-sample i ich kara za *k wykryły* problem, ale subtelnie. Walidacja *dramatyzuje* problem — przyrost RSS o 35% jest niemożliwy do zignorowania.

Diagnoza C_1 , C_2 — leakage prześlizgnął się przez walidację

Najtrudniejsza pułapka, jaką spotkamy

Modele leakage wciąż **wygrywają walidację**: C_1 ma $\text{RMSE}_{25} = 0,41^\circ\text{C}$, C_2 ma $\text{RMSE}_{25} = 0,24^\circ\text{C}$. Modele uczciwe (A, D) mają $\text{RMSE}_{25} \approx 2,4^\circ\text{C}$. Sześć razy gorzej!

Dlaczego walidacja nie pomaga?

Bo `apparent_temperature` $A_i = f(T_i, \text{wiatr}_i, \text{wilg.}_i)$ — to *deterministyczna funkcja* temperatury.

Walidacja zakłada, że dane testowe są *niezależne* od mechanizmu generowania y . Tu są zależne „od tyłu”: A_i **zawiera** T_i .

Czyli model nie „przewiduje” — on po prostu *czyta* ukrytą informację z cechy. I to działa dla 2024, i dla 2025, i dla każdego roku.

Konsekwencja praktyczna — look-ahead bias

W realnej prognozie 1 lipca 2025 musielibyśmy *znać* `apparent_temperature` 1 lipca 2025. Ale ona **jest liczona z** temperatury. Żeby przewidzieć T , musimy najpierw znać T .

Model jest *niewdrażalny* — mimo świetnych statystyk.

Wniosek finalny: nawet walidacja nie wystarczy (1/2)

R^2 : model maks. dopasowany do y

R^2_{adj} , AIC, BIC: dopasowanie + kara za złożoność

Cond, VIF: zdrowa geometria cech

Reszty, autokorelacja: brak strukturalnych wzorców

Walidacja out-of-sample: prawdziwa generalizacja

Wiedza dziedzinowa: skąd biorą się cechy?

Wniosek finalny: nawet walidacja nie wystarczy (2/2)

Każdy poziom oszukalny przez kolejny problem

- ▶ R^2 oszukany przez *więcej cech*.
- ▶ R^2_{adj} , AIC, BIC oszukane przez *leakage*.
- ▶ Cond, VIF **wykrywają** współliniowość, ale nie wiedzą, czy cecha to leakage.
- ▶ Walidacja **wykrywa przeuczenie**, ale nie wykrywa leakage, gdy ten przenika *cały* zbiór danych.
- ▶ **Tylko wiedza dziedzinowa** mówi: „Apparent_temperature to wzór z T — nie używać”.

Pointa wykładu

Statystyka i ML to potężne narzędzia, **ale nigdy nie zastąpią rozumienia danych**. Każdy kurs ML, który nie uczy „co znaczą cechy w mojej domenie”, uczy tylko technik, nie sztuki modelowania.

Tabela zbiorcza — wszystkie kryteria,
wszystkie modele

Tabela zbiorcza — wszystkie kryteria, wszystkie modele

Model	k	cond	VIF max	R^2	R^2_{adj}	R^2_{test}	AIC	BIC
A	3	2	1,0	0,962	0,954	0,864	48,80	50,25
B	4	$1,9 \cdot 10^4$	30	0,965	0,952	0,816	49,85	51,79
C ₁	4	$1,2 \cdot 10^4$	30	0,999	0,998	0,996	10,68	12,62
C ₂	9	$1,7 \cdot 10^{12}$	1339	1,000	1,000	0,999	-22,90	-18,54
D	5	2	1,0	0,969	0,951	0,866	50,59	53,01

Sygnały alarmowe wg kolorów:

- ▶ Zielony: zdrowy model (A).
- ▶ Żółty: model z umiarkowanymi problemami (B — współliniowość).
- ▶ Czerwony: model z leakage (C₁, C₂).
- ▶ Niebieski: model rozbudowany, ale uczciwy (D).

Ostateczny wybór: A

Model A wygrywa lub remisuje na wszystkich uczciwych kryteriach (cond, VIF, R^2_{adj} , AIC, BIC, walidacja). Najprostszy, najbardziej stabilny, najlepiej generalizuje — klasyczna brzytwa Ockhama.

Werdykt — który model jest najlepszy?

Werdykt — który model jest najlepszy?

Po przeanalizowaniu wszystkich kryteriów, oto jednoznaczna odpowiedź:

Kryterium	Werdykt	Uzasadnienie
Cond, VIF	A (lub D)	Idealna ortogonalność cech, cond = 2,0.
R^2_{adj}	A	Najwyższe wśród uczciwych: 0,954.
AIC	A	Najniższe wśród uczciwych: 48,80.
BIC	A	Najniższe wśród uczciwych: 50,25.
RSS na 2025 (walidacja)	A (lub D)	69,4 vs 93,9 dla B, 68,6 dla D.
Stabilność współczynników	A	$\hat{\beta}$ ma sens fizyczny i nie zmienia się.
Wiedza dziedzinowa	A, D	Cechy egzogeniczne, bez leakage.
R^2 (surowe)	C_2	Wprowadza w błąd — premia za leakage.

Werdykt finalny

Najlepszy model to A — czysto harmoniczny

$$T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \varepsilon_i, \quad \hat{\beta}_A = (10,38; -2,58; -9,97)^\top$$

Dlaczego model A wygrywa — pełne uzasadnienie

Krok 1: wykluczamy C_1 i C_2 ze względów strukturalnych

Mają niesamowite statystyki ($R^2 \approx 1,000$), ale używają cechy `apparent_temperature`, która jest **deterministyczną funkcją** T . To data leakage — model przewiduje T z *funkcji* T . Niewdrażalny w praktyce. Eliminujemy.

Krok 2: wśród uczciwych (A, B, D) wykluczamy B

- ▶ **Współliniowość:** $\text{cond} = 18\,643$, $\text{VIF} = 30$ — silny problem geometryczny.
- ▶ **Niefizyczne $\hat{\beta}$:** $\hat{\beta}_{T_{-1}} = -0,29$ (ujemny, mimo że fizycznie powinien być dodatni).
- ▶ **Przeuczenie:** stosunek $\text{RSS}_{\text{test}}/\text{RSS}_{\text{train}} = 4,1$ vs $2,8$ dla A. **Lag-1 dodał szumu, nie sygnału.**
- ▶ **Łamie założenie IID:** lag jako predyktor wprowadza autokorelację błędów.

Krok 3: wśród A i D wybieramy A (brzytwa Ockhama)

A i D mają **prawie identyczne** wyniki: RSS na 2025 = $69,4$ vs $68,6$ (1% różnica). Cond identyczne (2,0). VIF identyczne (1,0).

Ale D ma **dwa parametry więcej**: amplituda drugiego harmonika to tylko $0,83^\circ\text{C}$ (8% pierwszego). To „kosmetyczna” poprawka, która nie zasługuje na dwa parametry.

Werdykt R_{adj}^2 , **AIC**, **BIC**: A wygrywa, bo prostszy przy podobnym dopasowaniu. **Brzytwa Ockhama działa.**

Hierarchia diagnostyk
co która umie wykryć?

Hierarchia diagnostyk — co która umie wykryć?

Narzędzie	dopas.	kara k	współlin.	przeucz.	leakage
R^2	✓	✗	✗	✗	✗
R^2_{adj}	✓	✓	✗	✗	✗
AIC	✓	✓	✗	✗	✗
BIC	✓	✓✓	✗	✗	✗
$\text{Cond}(\mathbf{X}^\top \mathbf{X})$	✗	✗	✓	✗	✗
VIF	✗	✗	✓✓	✗	✗
Wykres reszt	✗	✗	✗	✓	✗
Durbin-Watson	✗	✗	✗	✓	✗
R^2_{test} (walid.)	✗	✗	✗	✓✓	(~)
Wiedza dziedzinowa	—	—	—	—	✓✓✓

Wniosek metodologiczny

Żadne pojedyncze narzędzie nie wystarczy. Potrzebujemy *portfolio* kryteriów — każde wskazuje inny aspekt jakości modelu.

I to jest właśnie sztuka modelowania: **wiedzieć, którego narzędzia użyć, kiedy, i jak interpretować jego werdykt w świetle innych.**

Hierarchia cech regresyjnych

Klasa cechy	Przykład w naszym studium	Problem	Wdrożenie?
Egzogeniczna, deterministyczna	$\sin \theta, \cos \theta$ z czasu kal. (model A, D)	brak — idealny regresor	✓ tak
Egzogeniczna, skorel.	ciśnienie, wiatr (gdyby były same)	współliniowość, niestabilność $\hat{\beta}$	✓ ostrożnie
Autoregresyjna (lag y)	T_{t-1} (model B)	łamie IID, multicol.	✓ ale inny paradygmat
Endogeniczna	dew_point (model C_2)	odwrócona przyczynowość	✗ struktur. błędny
Funkcja y	apparent_temp (C_1, C_2)	tożsamość matematyczna	✗ nigdy

Trzy pytania przed dodaniem nowej cechy

- 1 Czy ta cecha mogłaby logicznie *wpłynąć* na y — a nie odwrotnie? (*endogeniczność*)
- 2 Czy znam jej wartość w *momencie*, kiedy chcę przewidzieć y ? (*look-ahead bias*)
- 3 Czy nie jest po prostu *inną parametryzacją* czegoś, co już mam? (*współliniowość, leakage*)

Model B chciał być AR(1)
— co poszło nie tak?

Model B chciał być AR(1) — co poszło nie tak?

Diagnoza

Model B: $T_t = \beta_0 + \beta_1 \sin \theta_t + \beta_2 \cos \theta_t + \beta_3 T_{t-1} + \varepsilon_t$.

Lag-1 to klasyczny element *autoregresji* (AR(1)). Intencja motywująca: „wczorajsza temperatura przewiduje dzisiejszą”. To prawda *fizyczna*. Ale liczba $\hat{\beta}_3 = -0,29$ ujemna — *niefizyczna*.

Co się dzieje matematycznie

Sezonowość **już jest** w cechach $\sin \theta, \cos \theta$. Cecha T_{t-1} też koduje sezonowość (bo sąsiednie miesiące mają podobną T).

Wynik: OLS *rozdziela* sezonowość między trzy skorelowane cechy. Każda dostaje „kawałek”. Niektóre kawałki są ujemne, by skompensować inne. **Indywidualne współczynniki przestają mieć interpretację.**

Trzy klasyczne błędy w modelu B

- 1 **Konceptualnie**: mieszamy dwa paradygmaty — deterministyczną sezonowość i stochastyczną autoregresję.
- 2 **Statystycznie**: lag-1 łamie założenie IID — reszty staną się skorelowane (zaobserwowaliśmy ρ_1 ujemne dla A).
- 3 **Praktycznie**: OLS daje obciążone estymatory dla modeli z autoregresją — trzeba *innego* estymatora.

AR(1) zrobione poprawnie — estymacja na danych 2024

Model: czyste AR(1) bez harmoników:

$$T_t = c + \phi T_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2).$$

Estymacja: OLS warunkowe na T_{t-1} (lub MLE — tu zbiegają):

$$\hat{c} = 2,09, \quad \hat{\phi} = 0,811.$$

Interpretacja:

- ▶ $\hat{\phi} = 0,81 > 0$ — dodatnia, fizyczna autoregresja!
- ▶ $|\hat{\phi}| < 1$ — proces stacjonarny, średnia długoterminowa $\hat{c}/(1 - \hat{\phi}) = 11,1$ °C (zgadza się z $\bar{T}_{2024} = 10,4$).


Ale — prognoza iteracyjna na 2025 jest fatalna

Prognoza AR(1) na cały rok 2025 (iteracyjnie, $\hat{T}_{t+1} = \hat{c} + \hat{\phi}\hat{T}_t$):

$$\text{RMSE}_{2025} = 5,91 \text{ °C}, \quad \text{RSS}_{2025} = 418,6$$

Dla porównania: model A ma $\text{RMSE} = 2,40$ °C, $\text{RSS} = 69,4$. AR(1) jest prawie 3 razy gorszy od najprostszego modelu harmonicznego!

Dlaczego czyste AR(1) zawodzi? Co to znaczy?



Geometria błędu

AR(1) z $\phi = 0,81$ **konverguje do średniej** $11,1^{\circ}\text{C}$ wykładniczo szybko. W ciągu kilku miesięcy „zapomina” o stanie początkowym i daje *stałą prognozę*.

Ale temperatura ma **deterministyczną sezonowość**, której AR nie potrafi wygenerować. Trzeba mu *podać* sezonowość zewnętrznie.

ARMA jako uogólnienie

ARMA jako uogólnienie

Model ARMA(p, q)

$$T_t = c + \underbrace{\phi_1 T_{t-1} + \dots + \phi_p T_{t-p}}_{\text{AR}(p)} + \varepsilon_t + \underbrace{\theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}}_{\text{MA}(q)}$$

AR (autoregresja): obecna wartość zależy od p poprzednich obserwacji.

MA (moving average): obecna wartość zależy od q poprzednich *szumów*.

Po co MA?

MA opisuje sytuację: szok ekonomiczny w czasie t wpływa na wartość $t + 1, t + 2, \dots$, ale jego efekt zanika. *Pamięć szumu*, nie wartości.

Najważniejsze różnice OLS $\rightarrow$ ARMA

- ▶ **Estymacja:** OLS warunkowy lub MLE (gdy MA — musi być iteracyjna).
- ▶ **Identyfikacja:** potrzebne narzędzia ACF, PACF — nie ma „jednego wzoru”.
- ▶ **Diagnostyka:** test Ljunga-Boxa na resztach zamiast Durбина-Watsona.
- ▶ **Prognozowanie:** z dynamiką czasową, nie z funkcją czasu.

GARCH — gdy wariancja jest dynamiczna

GARCH — gdy wariancja jest dynamiczna

Model GARCH(p, q)

Klasyczne ARMA zakłada *stałą wariancję* szumu ε_t . GARCH (Bollerslev, 1986) modeluje wariancję jako:

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2.$$

Czyli *wariancja zależy od czasu* — duże szoki rodzą duże szoki.

Gdzie GARCH jest niezbędny

- ▶ **Finanse**: zmienność (volatility) cen aktywów — skupiska zmienności, kryzysy.
- ▶ **Klimatologia**: zmienna burzliwość atmosfery (np. tornada).
- ▶ **Energia**: ceny prądu, gazu — skoki zmienności w okresach kryzysów dostaw.

Czego OLS nigdy nie umiał

OLS zakłada *homoskedastyczność* ($\text{Var}(\varepsilon_i) = \sigma^2$ stałe). Jeśli wariancja jest dynamiczna, klasyczna teoria OLS *przestaje obowiązywać*: testy istotności, przedziały ufności, predykcyjne PI — wszystko zawodne. Tu rozszerzenie z OLS na MLE **nie jest opcjonalne** — jest konieczne.

Podsumowanie i pomost dalej

Top 10 lekcji z tej prezentacji

#	Lekcja
1	Brzytwa Ockhama działa. Spośród modeli o porównywalnym dopasowaniu zawsze wybieraj najprostszy — ma najlepsze szanse generalizacji. (Model A wygrał wszystkie uczciwe kryteria.)
2	Cechy ortogonalne to złoto. Ortogonalność $\mathbf{X}^T \mathbf{X} \approx \text{diag}$ daje stabilne $\hat{\beta}$, niezależną interpretację i odporność numeryczną. (Modele A i D miały $\text{cond} = 2,0$.)
3	Współliniowość rozregulowuje $\hat{\beta}$. Skorelowane cechy dają duże VIF, niestabilne współczynniki i często zmieniają znak (lag-1 w modelu B: $\hat{\beta} = -0,29$ zamiast $+0,8$).
4	R^2 rośnie monotonicznie z liczbą cech. Nigdy nie używaj surowego R^2 do porównywania modeli o różnym k . Zawsze sięgaj po R^2_{adj} , AIC lub BIC.
5	Każde kryterium odpowiada na inne pytanie. $\text{Cond/VIF} \rightarrow$ geometria, $R^2_{\text{adj}}/\text{AIC}/\text{BIC} \rightarrow$ dopasowanie z karą, walidacja $\rightarrow$ generalizacja. Żadne pojedyncze nie wystarcza.
6	In-sample $\neq$ out-of-sample. Te same diagnostyki (np. DW) mają inną interpretację na zbiorze testowym. Niskie DW out-of-sample to często <i>bias</i> , nie autokorelacja.
7	Wahania międzyroczne łamią modele. 2025 był chłodniejszy o $1,6^\circ\text{C}$ niż 2024 — żaden z 4 modeli tego nie uchwycił. Trendy długookresowe to inny temat (kointegracja).
8	Walidacja obnaża przeuczenie, ale NIE leakage. Stosunek $\text{RSS}_{\text{test}}/\text{RSS}_{\text{train}} = 4$ dla B wykrył przeuczenie. Ale leakage przenikał oba zbiory — niewykrywalny.
9	Wysokie R^2 jest podejrzeniem, nie potwierdzeniem. $R^2 = 0,999$ powinno zapalić czerwoną lampkę: „co właściwie jest po prawej stronie równania?”
10	Wiedza dziedzinowa jest ostatnią ale bardzo ważną linią obrony. Statystyka nie odróżni cechy egzogenicznej od endogenicznej ani od funkcji y . To rozumienie danych, a nie matematyka, ratuje przed leakage i przeuczeniem.

Podsumowanie i pomost dalej

Czego nauczyliśmy się w tej prezentacji

- 1 **OLS jest mocny, ale nie nieomylny**: te same dane, cztery modele, drastycznie różne werdykty.
- 2 **Diagnostyka to portfolio**: R^2 , R^2_{adj} , AIC, BIC, cond, VIF, walidacja — każde wskazuje inny aspekt.
- 3 **Walidacja out-of-sample to klucz**, ale nawet ona nie wykryje leakage.
- 4 **Wiedza dziedzinowa jest ostatnią linią obrony** przed strukturalnymi błędami modelu.
- 5 **Modele autoregresyjne wymagają innej teorii** — OLS nie jest wystarczający.



Ćwiczenie domowe — przegląd

Cele ćwiczenia

Powtarzamy całe studium przypadku samodzielnie, ale na *innym* mieście (lub innym roku) — żeby przekonać się, że wnioski przenoszą się na inne dane. Ćwiczenie ma cztery części:

- 1 **Na kartce** — powtórzyć rachunki dla małego podzbioru danych.
- 2 **W Pythonie** — zbudować pełny pipeline OLS z diagnostyką.
- 3 **Eksperyment numeryczny** — zbadać, jak rosnące n zmienia werdykty.
- 4 **Refleksja** — odpowiedzieć na pytania dydaktyczne.

Dane wejściowe

Każdy student wybiera *inne miasto* z bazy Open-Meteo (np. Warszawa, Berlin, Helsinki, Madryt, Reykjavik) lub *inny rok* (np. 2022 jako train, 2023 jako test). Im bardziej egzotyczne dane, tym ciekawsze obserwacje — Reykjavik ma asymetryczne sezony, Madryt znacznie wyższą amplitudę dobową.

Deadline i format oddania

Jupyter notebook (.ipynb) + PDF z odpowiedziami na pytania refleksyjne. Termin: 2 tygodnie.

Ćwiczenie — Część 1 (na kartce, ~30 minut)

Dane: czteropunktowy podzbiór miesięcznych średnich z wybranego miasta. Wystarczą 4 środki kwartałów:

$$(d_1, T_1), (d_2, T_2), (d_3, T_3), (d_4, T_4) = (46, T_{II}), (137, T_V), (228, T_{VIII}), (319, T_{XI}).$$

Model: $T_i = \beta_0 + \beta_1 \sin \theta_i + \beta_2 \cos \theta_i + \varepsilon_i$, gdzie $\theta_i = 2\pi d_i/366$. **Zadania:**

- 1 Wypełnić tabelę cech $\sin \theta_i, \cos \theta_i$ dla czterech punktów.
- 2 Zbudować macierz $\mathbf{X}$ (4×3) i wektor $\mathbf{y}$ (4×1).
- 3 Obliczyć $\mathbf{X}^\top \mathbf{X}$ i $\mathbf{X}^\top \mathbf{y}$ (powinieneś uzyskać macierz prawie diagonalną!).
- 4 Rozwiązać $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$ i wyznaczyć $\hat{\boldsymbol{\beta}} = (\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2)^\top$.
- 5 Obliczyć dopasowane wartości $\hat{\mathbf{y}} = \mathbf{X} \hat{\boldsymbol{\beta}}$ i reszty $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$.
- 6 **Sprawdzić** warunek normalności: czy $\mathbf{X}^\top \mathbf{e} \approx \mathbf{0}$?
- 7 **Interpretacja:** co oznacza Twój $\hat{\beta}_0$? Amplituda $\sqrt{\hat{\beta}_1^2 + \hat{\beta}_2^2}$?

Wskazówka

Wybierz kwartały, dla których $\sin \theta$ i $\cos \theta$ mają proste wartości ($\approx \pm 1$ lub ≈ 0). Wtedy $\mathbf{X}^\top \mathbf{X}$ wyjdzie prawie diagonalne i odwracanie macierzy będzie banalne.

Ćwiczenie — Część 2 (Python, ~2 godziny)

Cel: zaimplementować pełny pipeline OLS z diagnostyką dla 5 modeli (A, B, C₁, C₂, D) na pełnych 12 miesiącach. **Etap 2a — Pipeline funkcyjny:**

- ▶ `fit_ols(X, y)` — zwraca $\hat{\beta}$ przez równania normalne (**nie używaj** `sklearn.LinearRegression`; pracuj z `numpy.linalg.solve`).
- ▶ `diagnose(X, y, X_test, y_test, beta)` — zwraca słownik z RSS_{train} , RSS_{test} , R^2 , R^2_{adj} , R^2_{test} , AIC, BIC, cond, VIF_{max} , DW.

Etap 2b — Tabela porównawcza: stwórz DataFrame z wszystkimi diagnostykami $\times$ 5 modeli. Powinieneś otrzymać tabelę analogiczną do slajdu 51. **Etap 2c — Wykresy:**

- ▶ Dla każdego modelu — wykres reszt 2024 i 2025 obok siebie.
- ▶ Dla modelu A i D — wykres dopasowanej krzywej $\hat{T}(d)$ na tle danych.
- ▶ Tabela porównawcza VIF — bar chart per model.

Weryfikacja

Porównaj swoje wyniki z `statsmodels.OLS(...).fit()`. Powinny zgadzać się do co najmniej 4 miejsc po przecinku.

Ćwiczenie — Część 3 (eksperyment numeryczny) i Część 4 (refleksja)

Część 3 — co się dzieje, gdy zmieniamy częstość próbkowania?

- ▶ Powtórz analizę dla danych *dziennych* ($n=366$) zamiast miesięcznych ($n=12$).
- ▶ Powtórz dla danych *godzinnych* ($n=8784$) — model z dwoma sezonowościami: roczną i dobową, czyli 4 cechy $\sin / \cos$.
- ▶ **Pytania:** jak zmieniają się AIC, BIC, walidacja w funkcji n ? Czy AR(1) zaczyna mieć sens?

Część 4 — pytania do refleksji (oddaj jako PDF):

- 1 Twój kolega zbudował model z $R^2 = 0,998$ przewidujący kursy walut. Jakie 5 pytań mu zadasz przed zaakceptowaniem modelu?
- 2 Czy istnieje cecha, której zawsze możesz użyć bez ryzyka leakage? Jak to uzasadnisz?
- 3 Dlaczego `apparent_temperature` prowadzi do leakage, a `cloud_cover` też ma wysoką korelację z T — ale nie jest klasycznym przykładem leakage? Gdzie jest granica?
- 4 Wymień 3 sytuacje praktyczne (z dowolnej dziedziny), w których walidacja out-of-sample mogłaby zostać oszukana przez leakage analogiczny do naszej `apparent_temperature`.

Bonus (+20% oceny) ★ dla ambitnych

Zaimplementuj *Ridge regression* dla modeli B i C₂ — czy regularyzacja ratuje współliniowość? Porównaj wagi dla $\lambda \in \{0; 0,1; 1; 10; 100\}$.

Czego się dziś nauczyliśmy

Warto zapamiętać

- 1 Założenia do stosowanie OLS, to LINE (Liniowość, Independence (niezależność), Normalność oraz Equal variance (równa wariancja)
- 2 Wybór najlepszego modelu opiera się na wielu kryteriach
- 3 Wiarygodność $L(\theta | x)$ to ta sama funkcja co $p(x | \theta)$ — czytana w drugim kierunku.
- 4 MLE = „parametr, przy którym dane wyglądają najmniej dziwnie”: $\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \sum \log p(x_i | \theta)$.
- 5 Wszystkie klasyczne straty w ML (MSE, CE, BCE, NLL) to negatywne log-wiarygodności odpowiednich rozkładów.

Algorytm w trzech krokach

(1) Napisz $\ell(\theta) = \sum \log p(x_i | \theta)$. (2) Różniczkuj. (3) Rozwiąż $\nabla \ell = \mathbf{0}$.

OLS (Ordinary Least Squares) & MLE (Maximum Likelihood Estimation)

Dr hab. Andrzej Jankowski, prof. UWM

Instytut Informatyki, UWM Olsztyn

18 maja, 2026