

Od słabej stacjonarności do ARMA

Modele AR, MA oraz ich połączenie w ARMA na przykładzie temperatury w Olsztynie

Dr hab. Andrzej Jankowski, Profesor UWM

Modelowanie szeregów czasowych

25 maj, 2025

Cel: przypomnieć ideę modeli AR / MA / ARMA i pokazać, dlaczego ich połączenie jest naturalne.

Pokazać szkic przykładowego rozwiązania zadania 2

Plan: jedna spójna historia

- 1 **Słaba stacjonarność** — czego wymagamy od „spokojnego” szeregu.
- 2 **Dane pogodowe** — dlaczego *nie* są stacjonarne.
- 3 **Odsezonowanie** — po odjęciu sezonu zostają **anomalie** (reszty).
- 4 **Model AR** — pamięć w *wartościach*.
- 5 **Model MA** — pamięć w *szokach*.
- 6 **Model ARMA** — dlaczego ich połączenie jest **oczywiste**.
- 7 **Zadanie 2** - przykładowe rozwiązanie

Przez cały wykład pracujemy na jednym przykładzie: dobową temperaturę w Olsztynie.

Słaba (kowariancyjna) stacjonarność

Szereg $\{Y_t\}$ jest **słabo stacjonarny**, gdy spełnia trzy warunki:

Trzy warunki

- 1 **Stała średnia:** $\mathbb{E}[Y_t] = \mu$ — niezależna od t .
- 2 **Stała wariancja:** $\text{Var}(Y_t) = \sigma^2$ — niezależna od t .
- 3 **Autokowariancja zależna tylko od odstępów:**

$$\text{Cov}(Y_t, Y_{t+h}) = \gamma(h), \quad \text{nie od } t.$$

Intuicyjnie: *statystyczny charakter szeregu nie zmienia się w czasie* — jutro „wygląda” tak samo jak wczoraj. To jest fundament, na którym stoją AR / MA / ARMA.


Temperatura w Olsztynie **nie** jest stacjonarna

Surowa dobowa temperatura T_t łamie przede wszystkim **warunek stałej średniej**:

- lato $\approx +18^\circ\text{C}$, zima $\approx -2^\circ\text{C}$,
- średnia jest funkcją *pory roku*, nie stałą.

Uczciwa uwaga

Sezon siedzi też w *wariancji*: zima bywa bardziej „rozchwiana” niż lato. Dlatego po odjęciu sezonu dostaniemy stacjonarność **tylko w przybliżeniu**.



Wyraźny roczny cykl: średnia „wędruje” z porą roku.

Odsezonowanie: rozkładamy szereg na dwie części

Dopasujemy **komponent sezonowy** S_t (regresja harmoniczna: sinusy/cosinusy + trend) i odejmujemy go od danych:


$$\underbrace{T_t}_{\text{temperatura}} = \underbrace{S_t}_{\text{sezon (przewidywalny)}} + \underbrace{X_t}_{\text{anomalia (to, co zostaje)}}$$

Anomalia = reszta po odsezonowaniu

$$X_t = T_t - S_t \quad \text{czyli: o ile dzisiaj jest cieplej / chłodniej niż „typowo”}$$

- S_t tłumaczy *kiedy* jest ciepło — to czysta sezonowość.
- X_t jest **w przybliżeniu słabo stacjonarna**: średnia ≈ 0 , podobna wariancja przez rok.
- **To na X_t , a nie na T_t , działają modele AR / MA / ARMA.**

Mapa całego procesu



Modele pracują w środku — na anomalii. Sezon dokładamy z powrotem na końcu.

Model $AR(p)$: dzisiejsza anomalia zależy od wczorajszej

Definicja $AR(p)$

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \varepsilon_t, \quad \varepsilon_t \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2).$$

Intuicja meteorologiczna:

- jeśli dziś jest cieplej niż zwykle, jutro też pewnie będzie — układ pogody ma **inercję**;
- efekt minionej anomalii *wygasa geometrycznie*:
 $\phi, \phi^2, \phi^3, \dots$
- nigdy nie znika nagle — ciągnie się „ogonem”.

- **wejście**: przeszłe *anomalie*
 $X_{t-1}, X_{t-2}, \dots$
- **wyjście**: prognoza **anomalii** $\hat{X}_t$
- ε_t — losowy szok („dzisiejsza niespodzianka”).

Identyfikacja: PACF ucina się po opóźnieniu p , ACF zanika stopniowo.

Najpierw: czym jest „szok”? Dwie różne rzeczy

Studenci mylą dwa pojęcia o tej samej nazwie. **To kluczowy moment.**

Szok ε_t — składnik modelu

- *nieobserwowalna* innowacja,
- element **definicji** modelu,
- teoretyczna „niespodzianka” w chwili t .

Reszta $\hat{\varepsilon}_t = X_t - \hat{X}_t$

- *policzalny* błąd dopasowania,
- **produkt uboczny** estymacji,
- dostajemy ją *po* dopasowaniu modelu.

Konsekwencja — zapamiętaj to

Modele **AR, MA i ARMA** nie prognozują **szoków**. Zawsze prognozują **anomalie** X_t , bo przyszłe szoki mają wartość oczekiwaną zero: $\mathbb{E}[\varepsilon_{t+h}] = 0$.

Uwaga: modele ARCH/GARCH prognozują *wariancję* szoku $\text{Var}(\varepsilon_{t+h})$ (zmiennosc), a nie jego *wartość* — $\mathbb{E}[\varepsilon_{t+h}] = 0$ wciąż obowiązuje.

Model $MA(q)$: echo minionych szoków

Definicja $MA(q)$

$$X_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2).$$


Intuicja meteorologiczna:

- przez Olsztyn przechodzi front — to nagły **szok** ε_t ;
- jego wpływ „rozmazuje się” jeszcze przez dzień–dwa, a potem **urywa się**;
- dzisiejsza anomalia to suma dzisiejszego szoku i *ech* kilku ostatnich.

- **wejście**: przeszłe *szoki* $\varepsilon_{t-1}, \dots, \varepsilon_{t-q}$
- **wyjście**: prognoza **anomalii** $\hat{X}_t$
- pamięć **krótka i urywająca się** (po q krokach znika).

Identyfikacja: ACF ucina się po opóźnieniu q , PACF zanika stopniowo — odwrotnie niż w AR.

AR vs MA: dwa rodzaje pamięci



AR: długi, gładko gasnący ślad przeszłości.

MA: krótka, ostro ucięta pamięć szoków.

Pomysł na ARMA: dwa niezależne kanały informacji

Co wpływa na dzisiejszą anomalię X_t ? **Dwie różne rzeczy:**

Kanał 1 — przeszłe poziomy (AR)

Co już *wiemy* z minionych anomalii:

$$\phi_1 X_{t-1} + \dots + \phi_p X_{t-p}$$

Kanał 2 — przeszłe niespodzianki (MA)

Echo minionych szoków:

$$\theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

To są **dwa osobne źródła informacji**. Skoro każde coś wnosi — po prostu **dodajemy oba** (plus dzisiejszy szok ε_t).

Sklejenie w jednym równaniu — krok po kroku

- ❶ Zaczynamy od czystego **AR(1)** — pamięć w wartościach:

$$X_t = \phi_1 X_{t-1} + \varepsilon_t$$

- ❷ Zauważamy: wczorajsza *niespodzianka* ε_{t-1} też może dziś „pobrzmiwać”. Dokładamy **człon MA**:

$$X_t = \phi_1 X_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- ❸ Gotowe — to już **ARMA(1,1)**. Ogólnie:

Definicja ARMA(p, q)

$$X_t = \underbrace{\phi_1 X_{t-1} + \cdots + \phi_p X_{t-p}}_{\text{AR: pamięć w wartościach}} + \varepsilon_t + \underbrace{\theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}}_{\text{MA: pamięć w szokach}}$$

Uwaga: ARMA $\neq$ AR + MA

Kusząca, ale błędna myśl

„Mam dwa wzory na X_t — wystarczy je *dodać*, żeby dostać ARMA.”

AR(1) i MA(1) to **dwa konkurencyjne modele** tego samego X_t — nie dwa fakty naraz:

$$\text{AR: } X_t = \phi X_{t-1} + \varepsilon_t^{\text{AR}}$$

$$\text{MA: } X_t = \varepsilon_t^{\text{MA}} + \theta \varepsilon_{t-1}^{\text{MA}}$$

Gdybyśmy dodali je *stronami*, dostalibyśmy:

$$2X_t = \phi X_{t-1} + \theta \varepsilon_{t-1}^{\text{MA}} + \underbrace{\varepsilon_t^{\text{AR}} + \varepsilon_t^{\text{MA}}}_{\text{dwa różne szoki!}}$$

- to dwa *rywalizujące* opisy — ich suma to bezsensowna „średnia modeli”;
- $\varepsilon_t^{\text{AR}} \neq \varepsilon_t^{\text{MA}}$ — ten sam symbol, **inny obiekt**.

Poprawnie (poprzedni slajd): dokładamy *człon* do prawej strony *jednego* równania — po prawej zostaje **jeden** szok ε_t .

Ta sama logika, co w regresji

Analogia: nikt nie dodaje równań regresji

$$y = \beta_0 + \varepsilon \quad \text{oraz} \quad y = \beta_1 x + \varepsilon \quad \implies \quad \cancel{2y = \beta_0 + \beta_1 x + 2\varepsilon}$$

Zamiast tego budujemy **jeden bogatszy** model: $y = \beta_0 + \beta_1 x + \varepsilon$ — więcej członów objaśniających, **jeden** błąd.

ARMA działa **identycznie**: dokładamy człony po prawej, składnik losowy zostaje jeden.

Wniosek — ϕ, θ to inne liczby niż w modelach pojedynczych

$$\phi^{\text{AR}} \neq \phi^{\text{ARMA}}, \quad \theta^{\text{MA}} \neq \theta^{\text{ARMA}}$$

W czystym AR(1) współczynnik musi *sam* udźwignąć całą zależność; w ARMA część pracy przejmuje człon $\theta\varepsilon_{t-1}$, więc ϕ wychodzi inne.

Dlatego ARMA estymujemy **od zera** (wspólne MLE po ϕ, θ, σ^2) — nie „pożyczamy” $\hat{\phi}$ z AR i $\hat{\theta}$ z MA. Stąd porównujemy *całe* modele przez AIC/BIC.

Po co łączyć? Bo oddzielnie bywa nieoszczędnie

Sam AR

Żeby opisać krótkie „echo” szoku, AR potrzebuje *wielu* opóźnień $\Rightarrow$ marnuje parametry.

Sam MA

Słabo łapie *trwałą inercję* (utrzymujący się układ baryczny) — jego pamięć urywa się za szybko.

ARMA — najlepsze z obu

- **trwała inercja** $\leftarrow$ część AR,
- **krótkie echo szoku** $\leftarrow$ część MA,
- ten sam szereg opisany **oszczędniej** (mniejsze k).

Oszczędność parametrów jest później nagradzana przez AIC
/ BIC (kara za złożoność $\propto k$).

Wszystkie trzy prognozują **to samo**

Model	Wykorzystuje	Prognozuje	Sygnatura ACF/PACF
AR (p)	przeszłe anomalie X_{t-k}	anomalie X_t	PACF ucina się po p
MA (q)	przeszłe szoki ε_{t-k}	anomalie X_t	ACF ucina się po q
ARMA (p, q)	anomalie i szoki	anomalie X_t	oba zanikają stopniowo

Wspólny mianownik

Żaden z tych modeli nie prognozuje „reszt” ani „szoków”. Wszystkie prognozują **anomalie** X_t — a pełną temperaturę $\hat{T}_{t+h} = \hat{S}_{t+h} + \hat{X}_{t+h}$ dostajemy, dokładając z powrotem sezon.

Podsumowanie w jednym zdaniu

AR — pamięć w wartościach.



MA — pamięć w szokach.

ARMA — oba kanały w jednym równaniu.

Wszystkie działają na **anomalii** X_t (po odsezonowaniu)
i wszystkie prognozują **anomalie**, a nie szoki.

Dalej naturalnie wchodzi: identyfikacja p, q z ACF/PACF oraz wybór modelu przez log-likelihood, AIC i BIC.

Symulacja ARMA(1,1): szereg i ACF




Interpretacja

ACF modelu ARMA zwykle nie ucina się tak prosto jak w MA(1), ale jej kształt może być modyfikowany przez część MA.

Porównanie sygnatur ACF

Teoretyczny kształt ACF: AR wygasa, MA ucina się



Reguła praktyczna

- AR: ACF zwykle wygasa stopniowo.
- MA: ACF ucina się po skończonej liczbie lagów w teorii.
- ARMA: ACF wygasa, ale kształt początkowy może być bardziej elastyczny.

ACF i PACF: co trzeba wiedzieć teraz?

ACF

ACF mierzy korelację y_t z y_{t-k} . W Zadaniu 2 obowiązkowo rysujemy ACF danych, reszt i kwadratów reszt.

PACF

PACF mierzy zależność z opóźnieniem k po usunięciu wpływu krótszych opóźnień. Jest pomocna przy identyfikacji AR, ale w Zadaniu 2 najważniejsza jest siatka 9 modeli i AIC/BIC.

Uwaga dydaktyczna

Nie uczymy się tu „magicznego czytania” modelu wyłącznie z ACF/PACF. Używamy ACF do intuicji i diagnostyki, a wybór w Zadaniu 2 opieramy na AIC/BIC.

Zasada parsymonii

Parsymonia

Wybieramy model możliwie prosty, ale wystarczający do opisania najważniejszej struktury danych.

Dlaczego prosty model?

- łatwiejsza interpretacja,
- mniejsze ryzyko overfittingu,
- stabilniejsze wyniki w kolejnych próbach.

Dlaczego nie za prosty?

Jeśli model zostawia autokorelację w resztach, to nie zdał ostatniego egzaminu. Prosty model nie może być wymówką dla złej diagnostyki.

Od danych do siatki modeli

Dwa szeregi, dwie strategie

Pogoda w Olsztynie

- Szereg: temperatura godzinowa.
- Silna sezonowość dobową i roczną.
- Najpierw regresja harmoniczna.
- ARMA dopasowujemy do reszt po harmonikach.


SPY

- Szereg: dzienne log-zwroty.
- Brak wyraźnej sezonowości średniej.
- ARMA dopasowujemy bezpośrednio do log-zwrotów.
- Wariancja może być strukturalna — to sprawdzimy później.

Morał

Sezonowość pierwsza, ARMA druga.


Pogoda: co modelujemy po regresji harmonicznej?



Interpretacja

Regresja harmoniczna usunęła dużą część deterministycznej sezonowości, ale reszty nadal mają pamięć. Jeżeli po ciepłej godzinie następuje zwykle ciepła godzina, to model ARMA może opisać krótkookresową dynamikę.

SPY: co modelujemy?



Interpretacja

Log-zwroty oscylują wokół zera. Model średniej może być bardzo prosty, ale okresy dużej zmienności tworzą klastry. To jest zapowiedź różnicy: **model dla średniej** to nie to samo co **model dla wariancji**.

Siatka 9 modeli ARMA

Zakres w Zadaniu 2

Dopasowujemy wszystkie modele

$$\text{ARMA}(p, q), \quad p, q \in \{0, 1, 2\}.$$

Daje to dokładnie 9 kandydatów.

	$q = 0$	$q = 1$	$q = 2$
$p = 0$	ARMA(0,0)	ARMA(0,1)	ARMA(0,2)
$p = 1$	ARMA(1,0)	ARMA(1,1)	ARMA(1,2)
$p = 2$	ARMA(2,0)	ARMA(2,1)	ARMA(2,2)

Dlaczego tylko do 2?

To jest ćwiczenie dydaktyczne: chcemy porównać modele, nie zbudować automatyczną fabrykę modeli. Mała siatka pozwala ręcznie zrozumieć każdy wynik.

Co oznacza estymacja MLE?

Idea

MLE, czyli metoda największej wiarygodności, wybiera takie parametry, przy których obserwowane dane byłyby najbardziej prawdopodobne w ramach danego modelu.

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta),$$

gdzie $\ell(\theta)$ jest logarytmem funkcji wiarygodności.

Intuicja bez formalizmu

Nie pytamy: „czy model jest prawdziwy?”. Pytamy raczej: „dla którego zestawu parametrów ten model najlepiej tłumaczy obserwowany przebieg szeregu?”.

Log-likelihood: dlaczego logarytm?

Wiarygodność jako iloczyn

W wielu modelach wiarygodność ma postać iloczynu gęstości lub prawdopodobieństw:

$$L(\theta) = \prod_{t=1}^T f(y_t \mid \mathcal{F}_{t-1}; \theta).$$

Iloczyny wielu małych liczb są numerycznie niewygodne.

Logarytm

$$\ell(\theta) = \log L(\theta) = \sum_{t=1}^T \log f(y_t \mid \mathcal{F}_{t-1}; \theta).$$

Suma jest łatwiejsza do liczenia niż iloczyn.

Do zapamiętania

Większy log-likelihood oznacza lepsze dopasowanie *wewnątrz tej samej próbki i rodziny porównywanych modeli*.

Dlaczego sam log-likelihood nie wystarcza?

Problem

Bardziej złożony model ma więcej parametrów i zwykle może dopasować dane lepiej. Dlatego jego log-likelihood często jest większy.

Pułapka


Nie wolno wybierać modelu tylko dlatego, że ma najwyższy log-likelihood. To prowadzi do faworyzowania modeli zbyt złożonych.

Rozwiązanie

Kryteria AIC i BIC łączą dwa elementy:

- 1 nagrodę za dopasowanie, czyli duży log-likelihood;
- 2 karę za liczbę parametrów.


Pogoda: log-likelihood a liczba parametrów



Jak czytać ten wykres?

Jeżeli log-likelihood rośnie po dodaniu parametrów, nie jest to jeszcze argument za większym modelem. Musimy zapytać: czy poprawa dopasowania jest wystarczająco duża, aby uzasadnić

SPY: log-likelihood a liczba parametrów



Typowy obraz dla log-zwrotów

Różnice log-likelihood między prostymi modelami średniej są często niewielkie. Wtedy BIC zwykle wybiera model bardzo prosty, bo zysk z dodatkowych parametrów nie rekompensuje kary za złożoność.

AIC i BIC: wzory

Kryteria informacyjne

$$\text{AIC} = -2\ell + 2k, \quad \text{BIC} = -2\ell + k \ln T.$$

- ℓ — log-likelihood dopasowanego modelu;
- k — liczba estymowanych parametrów;
- T — liczba obserwacji użyta w estymacji.

Najważniejsza zasada

AIC i BIC minimalizujemy.

Dlaczego w kryteriach jest -2ℓ ?

Kierunek optymalizacji

MLE maksymalizuje ℓ . Kryteria informacyjne są zapisane tak, aby je minimalizować:

większy $\ell \Rightarrow -2\ell$ jest mniejsze.

Praktyczne czytanie tabeli

Nie musimy ręcznie analizować skali log-likelihood. Wystarczy porównać AIC/BIC: najmniejsza wartość oznacza preferowany model według danego kryterium.

AIC

$$\text{AIC} = -2\ell + 2k.$$

Kara za parametr wynosi 2.

Intuicja

AIC często wybiera model nieco bogatszy. Jest użyteczne, gdy zależy nam na dobrych własnościach predykcyjnych i nie chcemy zbyt mocno karać dodatkowych parametrów.

Pułapka

AIC nie jest „lepsze” od BIC w każdej sytuacji. Daje inną filozofię wyboru: bardziej predykcyjną, mniej konserwatywną.

BIC

$$\text{BIC} = -2\ell + k \ln T.$$

Kara za parametr rośnie z liczbą obserwacji.

Intuicja

BIC jest bardziej konserwatywne. W Zadaniu 2 preferujemy BIC, bo chcemy prosty, stabilny model średniej, który nie dopasowuje przypadkowego szumu.

Praktyczna rekomendacja do raportu

Najpierw pokaż tabelę AIC/BIC. Następnie napisz: „Model wybrany według BIC to ...”. Jeżeli AIC wskazuje inny model, krótko skomentuj konflikt.

AIC czy BIC: jak to opisać studentowi?

Kryterium	Co częściej robi?	Jak o nim mówić?
AIC	wybiera model bogatszy	„częściej sprzyja predykcji”
BIC	wybiera model prostszy	„konserwatywne, stabilniejsze dla małej siatki”

W Zadaniu 2

Jeżeli AIC i BIC są zgodne — sytuacja jest prosta. Jeżeli są rozbieżne — jako model główny przyjmujemy BIC, a rozbieżność traktujemy jako informację diagnostyczną.

Mini-przykład rachunkowy: kara za parametr

Założmy $T = 750$, czyli około tyle, ile log-zwrotów SPY

$$\ln(750) \approx 6,62.$$

Dodatkowy parametr zwiększa:

- AIC o 2,
- BIC o około 6,62.

Wniosek

Aby BIC zaakceptował jeden dodatkowy parametr, poprawa log-likelihood musi być wyraźniejsza niż w przypadku AIC.

Wybór modelu: AIC i BIC w praktyce

Pogoda: siatka $\text{ARMA}(p, q)$ dla reszt po regresji harmonicznej

Model	logLik	k	AIC	BIC
ARMA(0,0)	-22166,72	2	44337,43	44351,41
ARMA(0,1)	-17321,73	3	34649,46	34670,42
ARMA(0,2)	-14010,70	4	28029,41	28057,36
ARMA(1,0)	-8935,44	3	17876,89	17897,85
ARMA(1,1)	-8182,80	4	16373,60	16401,55
ARMA(1,2)	-8004,83	5	16019,67	16054,61
ARMA(2,0)	-7948,20	4	15904,40	15932,35
ARMA(2,1) $\leftarrow$ BIC	-7935,79	5	15881,58	15916,51
ARMA(2,2) $\leftarrow$ AIC	-7932,18	6	15876,36	15918,28

Co mówią kryteria

- AIC wskazuje **ARMA(2,2)**, BIC — **ARMA(2,1)**; różnica bierze się z silniejszej kary BIC za parametry ($k \ln T$ vs $2k$).
- **Dominuje pamięć AR**: sam AR(1) ($\ell = -8935,44$) bije sam MA(1) ($\ell = -17321,73$) o tysiące — w odsezonowanej pogodzie rządzi inercja, a MA to tylko korekta krótkookresowa.

W tabeli $k = p + q + 2$: parametry AR, parametry MA, stała/średnia oraz wariancja składnika losowego.

Rekomendacja modelu dla pogody

Rekomendacja

Jako model główny dla reszt po regresji harmonicznej rekomendujemy

ARMA(2, 1)

Dlaczego ARMA(2,1)?

- najniższy BIC w siatce (15916,51);
- prostszy niż ARMA(2,2) o jeden parametr;
- BIC premiuje oszczędność — dobry wybór, gdy diagnostyka reszt jest czysta.

ARMA(2,2): bliski konkurent

- najniższy AIC (15876,36), ale o parametr bogatszy;
- przewaga BIC modelu (2,1) jest mała:
 $15918,28 - 15916,51 = 1,77$;
- trzymamy jako alternatywę do diagnostyki.

Uwaga: BIC zależy od liczby obserwacji T

Z $\text{BIC} - \text{AIC} = k(\ln T - 2)$ wynika, że w tabeli implikowane jest $T \approx 8000$ — **sprawdź**, czy to pełny szereg godzinowy ($T = 26304$), czy krótszy roboczy. Przy $T = 26304$: $\text{BIC}_{(2,1)} \approx 15922,5$, $\text{BIC}_{(2,2)} \approx 15925,4$ — **ranking bez zmian: BIC wskazuje ARMA(2,1)**.

Pogoda: parametry modelu wybranego przez BIC

Pogoda: parametry modelu BIC

Parametr	estymata	błąd std.	z	p-value	95% CI
const	-0.0050	0.2586	-0.02	0.985	[-0.5118, 0.5018] \
ar.L1	1.5281	0.0180	84.89	0	[1.4928, 1.5634] \
ar.L2	-0.5532	0.0178	-31.14	7.45e-213	[-0.5881, -0.5184] \
ma.L1	-0.1107	0.0190	-5.81	6.21e-09	[-0.1480, -0.0733] \
sigma2	0.4255	0.0042	101.91	0	[0.4174, 0.4337] \

Jak czytać parametry?

Parametry AR mówią o pamięci względem wcześniejszych wartości reszt. Parametry MA mówią o pamięci względem wcześniejszych szoków. Wartości p-value są pomocne, ale nie zastępują diagnostyki reszt.

Pogoda: jak nie nadinterpretować parametrów?

Ostrożnie z opowieściami

Nie piszemy: „parametr $\varphi_1 = 1,53$ oznacza, że temperatura rośnie o $1,53^\circ\text{C}$ ”. To byłoby błędne.


Lepsza interpretacja

Model ARMA opisuje zależność reszt po usunięciu deterministycznej sezonowości. Parametry wskazują, że krótkookresowe odchylenia temperatury od wzorca sezonowego są silnie zależne w czasie.

Co potem?

Pełną ocenę modelu wykonujemy przez ACF reszt i testy diagnostyczne. Same parametry nie wystarczają.

Pogoda: zapowiedź diagnostyki reszt



Most do dalszych analiz

Nawet model wybrany według BIC musi zdać egzamin reszt. Jeżeli ACF reszt nadal ma wyraźne piki, model średniej nie domknął struktury zależności.

SPY: tabela AIC/BIC dla siatki 9 modeli

SPY: siatka ARMA(p,q), $p,q \in \{0,1,2\}$

Model	logLik	k	AIC	BIC
ARMA(0,0) $\leftarrow$ BIC	2418.43	2	-4832.86	-4823.62
ARMA(0,1)	2419.61	3	-4833.21	-4819.35
ARMA(0,2)	2420.08	4	-4832.15	-4813.67
ARMA(1,0)	2419.69	3	-4833.38	-4819.52
ARMA(1,1) $\leftarrow$ AIC	2421.09	4	-4834.18	-4815.70
ARMA(1,2)	2421.22	5	-4832.43	-4809.33
ARMA(2,0)	2420.30	4	-4832.60	-4814.12
ARMA(2,1)	2421.19	5	-4832.37	-4809.27
ARMA(2,2)	2422.54	6	-4833.07	-4805.35

Wniosek dla danych referencyjnych

Według BIC preferowany jest model **ARMA(0,0)** dla log-zwrotów SPY. AIC wskazuje nieco bogatszy model **ARMA(1,1)**, ale różnice są małe.

SPY: parametry modelu wybranego przez BIC

SPY: parametry modelu BIC

Parametr	estymata	błąd std.	z	p-value	95% CI
const	0.0008	0.0004	2.37	0.0179	[0.0001, 0.0015] \
sigma2	0.0001	0.0000	60.77	0	[0.0001, 0.0001] \

Co oznacza ARMA(0,0)?

Model ARMA(0,0) z wyrazem stałym to model stałej średniej plus biały szum w średniej:

$$r_t = \mu + \varepsilon_t.$$

To nie oznacza, że cały proces finansowy jest „zupełnie losowy”. Oznacza tylko, że model średniej jest bardzo prosty.

SPY: pułapka interpretacyjna

Błędne zdanie

„SPY jest losowy, bo BIC wybrał ARMA(0,0).”


Poprawne zdanie

„W tej próbie BIC nie znajduje silnej struktury liniowej w średniej log-zwrotów SPY. Nie wyklucza to struktury w wariancji, czyli efektu ARCH/GARCH.”

Slogan

Średnia jest nieprzewidywalna, ale ryzyko jest.

SPY: zapowiedź diagnostyki reszt



Most do dalszych analiz

Jeżeli ACF reszt jest bliska zeru, model średniej może być akceptowalny. Ale musimy jeszcze sprawdzić ACF kwadratów reszt i ARCH-LM.

Co to jest i jak czytać `summary()` ?

Skąd pochodzi `summary()`? — biblioteka `statsmodels`

Biblioteka

Korzystamy z `statsmodels` — pakietu Pythona do modeli statystycznych i ekonometrycznych. Modele ARMA/ARIMA są w module

```
statsmodels.tsa.arima.model.ARIMA.
```

`summary()` jest metodą obiektu wyników zwróconego przez `fit()`.

Instalacja

W terminalu (zwykle wraz z `pandas` i `numpy`):

```
pip install statsmodels pandas numpy
```

Powiązanie z poprzednim slajdem

To właśnie dlatego w wydruku widnieje „ARIMA”: w `statsmodels` ARMA(p, q) realizujemy jako ARIMA($p, 0, q$).

Czym jest `summary()`?

Definicja techniczna

`summary()` to **metoda obiektu wyników** dopasowanego modelu, a nie samego modelu:

```
res = model.fit() → res.summary().
```

Zwraca sformatowany raport (obiekt `Summary`), który możemy wydrukować lub wyświetlić.

Co tak naprawdę agreguje?

To warstwa prezentacji nad atrybutami obiektu wyników, m.in. `res.params`, `res.bse`, `res.pvalues`, `res.llf`, `res.aic`, `res.bic`. Te same liczby można odczytać programowo bez czytania tabeli.

Uwaga

`summary()` to *migawka* dopasowania, nie zastępuje pełnej diagnostyki reszt z bloku 5.

Jak używać — minimalny przykład

Dopasowanie modelu i wydruk

```
import pandas as pd
from statsmodels.tsa.arima.model import ARIMA

# y: szereg (np. log-zwroty SPY) jako pandas Series
    model = ARIMA(y, order=(2, 0, 1))    # ARMA(2,1): p=2, d=0, q=1
        res = model.fit()

    print(res.summary())                # tabela parametrow + diagnostyka
```

Jak używać — minimalny przykład

Dostęp do liczb bez czytania tabeli

```
res.aic, res.bic          # kryteria
                           informacyjne
res.params, res.bse       # estymaty i błędy
                           standardowe
res.pvalues               # p-value
                           parametrow

resid = res.resid         # reszty modelu
                           sredniej
sq = resid**2             # kwadraty reszt ->
                           diagnostyka wariacji
```

Slogan

`summary()` pokazuje, `res.*` pozwala policzyć dalej.

Co zawiera `summary()`?

Najważniejsze elementy

- 1 nazwa modelu i liczba obserwacji;
- 2 log-likelihood, AIC, BIC;
- 3 estymaty parametrów;
- 4 błędy standardowe, statystyki z, p-value, przedziały ufności;
- 5 informacje diagnostyczne pomocnicze: Jarque–Bera, test heteroskedastyczności (H), Ljung–Box dla opóźnienia 1.

Uwaga

`summary()` nie zastępuje pełnej diagnostyki z bloku 5. Traktujemy je jako metrykę techniczną i tabelę parametrów.

Pierwszy blok `summary()`: identyfikacja modelu

Co sprawdzamy?

- Czy model ma właściwy rząd, np. $\text{ARMA}(2,1)$ albo $\text{ARMA}(0,0)$?
- Czy liczba obserwacji zgadza się z opisaną próbą?
- Czy AIC/BIC odpowiadają tabeli porównawczej?

Typowe pytanie studenta

„Dlaczego w `summary()` widzę ARIMA, skoro mówiłem ARMA?”

Odpowiedź

W `statsmodels` $\text{ARMA}(p, q)$ jest implementowane jako $\text{ARIMA}(p, 0, q)$. Co więcej, w nowszych wersjach osobna klasa `ARMA` została wycofana, więc `ARIMA/SARIMAX` to jedyna dostępna ścieżka — etykieta „ARIMA” nie jest pomyłką, lecz konsekwencją API. Gdy $d = 0$, nie ma różnicowania, więc mówimy o ARMA.

Drugi blok summary(): parametry

Kolumny tabeli parametrów

Kolumna	Znaczenie
coef	estymata parametru
std err	oszacowany błąd standardowy
z	statystyka testowa, <i>dokładnie</i> coef/std err
P> z	p-value dla testu parametru
[0.025, 0.975]	przybliżony 95% przedział ufności

Co jest przybliżone?

Sama statystyka $z = \text{coef} / \text{std err}$ liczona jest dokładnie. Przybliżony jest jej *rozkład*: traktujemy go jako normalny tylko asymptotycznie (test Walda). Stąd „przybliżony” przedział ufności.

Pułapka

Istotny parametr nie oznacza dobrego modelu. Nieistotny parametr nie jest katastrofą, jeśli model przechodzi diagnostykę i jest uzasadniony kryterium informacyjnym.

Jak czytać p-value w ARMA?

Co p-value mówi?

P-value przy parametrze pyta lokalnie: czy dany parametr różni się od zera przy założeniach modelu i przybliżeniach asymptotycznych.

Czego p-value nie mówi?

- Nie mówi, że model jest poprawny diagnostycznie.
- Nie mówi, że reszty są białym szumem.
- Nie mówi, że nie ma efektu ARCH.
- Nie zastępuje porównania AIC/BIC.

Dla jakich hipotez liczone jest p-value?

Dwie różne rodziny testów w jednym wydruku

- ❶ **Tabela parametrów** (kolumna $P > |z|$) — po jednym teście na każdy parametr:

$$H_0 : \theta_i = 0 \quad H_1 : \theta_i \neq 0,$$

dwustronny test Walda oparty na asymptotycznej normalności.

- ❷ **Testy diagnostyczne na dole** — każdy ze swoją własną hipotezą zerową (patrz niżej).

Hipotezy zerowe testów diagnostycznych

Test	H_0
Ljung-Box (L1)(Q)	brak autokorelacji reszt (przy opóźnieniu 1)
Jarque-Bera (JB)	reszty mają rozkład normalny
Heteroskedasticity (H)	wariancja reszt jest stała (homoskedastyczność)

Dla jakich hipotez liczone jest p-value?

Dwie pułapki

Test H porównuje wariancję pierwszej i ostatniej części próby — **to nie jest ARCH-LM**. Z kolei p-value dla sigma2 jest mało sensowne: wariancja ≥ 0 , więc $H_0 : \sigma^2 = 0$ leży na brzegu przestrzeni parametrów.

Parametr sigma2

Znaczenie

sigma2 to oszacowana wariancja innowacji modelu średniej.

$$\varepsilon_t \sim \text{proces o wariancji } \sigma^2.$$

Pułapka dla SPY

Stała sigma2 w modelu ARMA nie oznacza, że wariancja w rzeczywistości jest stała. O tym decyduje diagnostyka kwadratów reszt.

Slogan

Model dla średniej $\neq$ model dla wariancji.

AR i MA w `summary()`: znaki i konwencje

W `statsmodels`

Parametry zapisywane są jako `ar.L1`, `ar.L2`, `ma.L1`, `ma.L2` — odpowiednio części autoregresyjnej i średniej ruchomej.

Pułapka znaków — konkretnie

`statsmodels` stosuje konwencję z **plusami** w części MA:

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Wiele podręczników w stylu Boxa–Jenkinsa zapisuje MA z **minusami**. Dlatego nie kopiujemy bezmyślnie interpretacji z innego źródła — zawsze sprawdzamy dokumentację pakietu i zachowanie modelu.

+++++

Czym jest `summary()`?

Definicja techniczna

`summary()` to **metoda obiektu wyników** dopasowanego modelu, a nie samego modelu:

```
res = model.fit() → res.summary().
```

Zwraca sformatowany raport (obiekt `Summary`), który możemy wydrukować lub wyświetlić.

Co tak naprawdę agreguje?

To warstwa prezentacji nad atrybutami obiektu wyników, m.in. `res.params`, `res.bse`, `res.pvalues`, `res.llf`, `res.aic`, `res.bic`. Te same liczby można odczytać programowo bez czytania tabeli.

Uwaga

`summary()` to *migawka* dopasowania, nie zastępuje pełnej diagnostyki reszt z bloku 5.

Co zawiera `summary()`?

Najważniejsze elementy

- 1 nazwa modelu i liczba obserwacji;
- 2 log-likelihood, AIC, BIC;
- 3 estymaty parametrów;
- 4 błędy standardowe, statystyki z, p-value, przedziały ufności;
- 5 informacje diagnostyczne pomocnicze: Jarque–Bera, test heteroskedastyczności (H), Ljung–Box dla opóźnienia 1.

Uwaga

`summary()` nie zastępuje pełnej diagnostyki z bloku 5. Traktujemy je jako metrykę techniczną i tabelę parametrów.

Pierwszy blok `summary()`: identyfikacja modelu

Co sprawdzamy?

- Czy model ma właściwy rząd, np. $\text{ARMA}(2,1)$ albo $\text{ARMA}(0,0)$?
- Czy liczba obserwacji zgadza się z opisaną próbą?
- Czy AIC/BIC odpowiadają tabeli porównawczej?

Typowe pytanie studenta

„Dlaczego w `summary()` widzę ARIMA, skoro mówiłem ARMA?”

Odpowiedź

W `statsmodels` $\text{ARMA}(p, q)$ jest implementowane jako $\text{ARIMA}(p, 0, q)$. Co więcej, w nowszych wersjach osobna klasa `ARMA` została wycofana, więc `ARIMA/SARIMAX` to jedyna dostępna ścieżka — etykieta „ARIMA” nie jest pomyłką, lecz konsekwencją API. Gdy $d = 0$, nie ma różnicowania, więc mówimy o ARMA.

Drugi blok summary(): parametry

Kolumny tabeli parametrów

Kolumna	Znaczenie
coef	estymata parametru
std err	oszacowany błąd standardowy
z	statystyka testowa, <i>dokładnie</i> coef/std err
P> z	p-value dla testu parametru
[0.025, 0.975]	przybliżony 95% przedział ufności

Co jest przybliżone?

Sama statystyka $z = \text{coef} / \text{std err}$ liczona jest dokładnie. Przybliżony jest jej *rozkład*: traktujemy go jako normalny tylko asymptotycznie (test Walda). Stąd „przybliżony” przedział ufności.

Pułapka

Istotny parametr nie oznacza dobrego modelu. Nieistotny parametr nie jest katastrofą, jeśli model przechodzi diagnostykę i jest uzasadniony kryterium informacyjnym.

Jak czytać p-value w ARMA?

Co p-value mówi?

P-value przy parametrze pyta lokalnie: czy dany parametr różni się od zera przy założeniach modelu i przybliżeniach asymptotycznych.

Czego p-value nie mówi?

- Nie mówi, że model jest poprawny diagnostycznie.
- Nie mówi, że reszty są białym szumem.
- Nie mówi, że nie ma efektu ARCH.
- Nie zastępuje porównania AIC/BIC.

Dla jakich hipotez liczone jest p-value?

Dwie różne rodziny testów w jednym wydruku

- ❶ **Tabela parametrów** (kolumna $P > |z|$) — po jednym teście na każdy parametr:

$$H_0 : \theta_i = 0 \quad H_1 : \theta_i \neq 0,$$

dwustronny test Walda oparty na asymptotycznej normalności.

- ❷ **Testy diagnostyczne na dole** — każdy ze swoją własną hipotezą zerową (patrz niżej).

Hipotezy zerowe testów diagnostycznych

Test	H_0
Ljung-Box (L1) (Q)	brak autokorelacji reszt (przy opóźnieniu 1)
Jarque-Bera (JB)	reszty mają rozkład normalny
Heteroskedasticity (H)	wariancja reszt jest stała (homoskedastyczność)

Dwie pułapki

Parametr sigma2

Znaczenie

sigma2 to oszacowana wariancja innowacji modelu średniej.

$$\varepsilon_t \sim \text{proces o wariancji } \sigma^2.$$

Pułapka dla SPY

Stała sigma2 w modelu ARMA nie oznacza, że wariancja w rzeczywistości jest stała. O tym decyduje diagnostyka kwadratów reszt.

Slogan

Model dla średniej $\neq$ model dla wariancji.

AR i MA w `summary()`: znaki i konwencje

W `statsmodels`

Parametry zapisywane są jako `ar.L1`, `ar.L2`, `ma.L1`, `ma.L2` — odpowiednio części autoregresyjnej i średniej ruchomej.

Pułapka znaków — konkretnie

`statsmodels` stosuje konwencję z **plusami** w części MA:

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Wiele podręczników w stylu Boxa–Jenkinsa zapisuje MA z **minusami**. Dlatego nie kopiujemy bezmyślnie interpretacji z innego źródła — zawsze sprawdzamy dokumentację pakietu i zachowanie modelu.

Monotoniczność log-likelihood jako sprawdzian techniczny

O co chodzi?

W obrębie zagnieżdżonych lub podobnych rodzin większy model często powinien mieć log-likelihood nie mniejszy niż model prostszy, bo ma więcej swobody.

Jak używać tego praktycznie?

Jeżeli bogatszy model ma dziwnie gorszy log-likelihood, może to oznaczać:

- problem ze zbieżnością optymalizacji;
- lokalne maksimum;
- inną efektywną próbę;
- ograniczenia stacjonarności/odwracalności.

Nie jest to twierdzenie do mechanicznego stosowania

To jest praktyczny alarm techniczny, nie formalna reguła wyboru modelu.

Wzorcowy akapit: pogoda

Propozycja do raportu

Po usunięciu deterministycznej sezonowości dobowej i rocznej za pomocą regresji harmonicznej dopasowano siatkę modeli $\text{ARMA}(p, q)$, $p, q \in \{0, 1, 2\}$, do reszt modelu harmonicznego. W danych referencyjnych kryterium BIC wskazało model $\text{ARMA}(2,1)$, natomiast AIC wskazało nieco bogatszy model $\text{ARMA}(2,2)$. Ponieważ w Zadaniu 2 preferujemy konserwatywną selekcję i stabilny model średniej, jako model główny przyjęto $\text{ARMA}(2,1)$. Ostateczna ocena modelu wymaga jednak diagnostyki reszt.

Dlaczego ten akapit jest dobry?

Zawiera: dane wejściowe, siatkę modeli, kryterium, konflikt AIC/BIC, decyzję oraz zastrzeżenie diagnostyczne.

Wzorcowy akapit: SPY

Propozycja do raportu

Dla log-zwrotów SPY dopasowano siatkę modeli $\text{ARMA}(p, q)$, $p, q \in \{0, 1, 2\}$. W danych referencyjnych kryterium BIC wskazało model $\text{ARMA}(0,0)$, czyli model stałej średniej i innowacji bez liniowej pamięci w średniej. AIC wskazało model $\text{ARMA}(1,1)$, ale poprawa dopasowania była niewystarczająca z punktu widzenia BIC. Wniosek dotyczy wyłącznie modelu średniej; struktura wariancji musi zostać sprawdzona osobno przez ACF kwadratów reszt i test ARCH-LM.

Najczęstsze błędy w raportach

Lista błędów

- 1 Wybór modelu o największym log-likelihood zamiast najmniejszym AIC/BIC.
- 2 Pisanie, że „AIC/BIC maksymalizujemy”.
- 3 Porównywanie AIC/BIC z modeli dopasowanych do różnych szeregów.
- 4 ARMA na surowej temperaturze bez wcześniejszego omówienia sezonowości.
- 5 Brak komentarza, gdy AIC i BIC wskazują różne modele.
- 6 Nadinterpretacja p-value parametrów.
- 7 Uznanie 2RMA(0,0) dla SPY za dowód „pełnej losowości rynku”.

Jak pisać o modelu ostrożnie?

Za mocno

„Najlepszy model to ARMA(2,1).”

Lepiej

„W tej próbie, spośród rozważanej siatki 9 modeli, BIC wskazuje ARMA(2,1).”

Dlaczego?

Model jest zawsze wybierany warunkowo: względem danych, zakresu modeli, metody estymacji i kryterium wyboru.

Porównywanie AIC/BIC: warunki uczciwego porównania

Można porównywać, gdy modele są dopasowane do:

- tej samej zmiennej;
- tej samej próbki czasowej;
- tej samej liczby obserwacji lub jawnie opisanej efektywnej próbki;
- tej samej transformacji danych;
- tej samej klasy założeń probabilistycznych.

Nie wolno

Nie porównujemy BIC modelu na surowej temperaturze z BIC modelu na resztach po harmonikach tak, jakby to była ta sama konkurencja. To są różne problemy modelowania.

Badanie reszt

Gdzie jesteśmy w cyklu?

Dotychczas

- 1 blok 1: rozpoznaliśmy sezonowość przez wykres, periodogram i ACF.
- 2 blok 2: odsezonowaliśmy pogodę regresją harmoniczną.
- 3 blok 3: poznaliśmy AR, MA i ARMA.
- 4 blok 4: wybraliśmy modele z siatki $\text{ARMA}(p, q)$ przez AIC/BIC i MLE.

Dziś

Sprawdzamy, czy wybrany model przeszedł ostatni egzamin: diagnostykę reszt.

Slogan bloku

Reszty — ostatni egzamin modelu.

Cel bloku 5

Po tym bloku student powinien umieć:

- 1 wyjaśnić, czym są reszty i dlaczego nie kończymy pracy na AIC/BIC;
- 2 narysować oraz zinterpretować ACF reszt;
- 3 narysować oraz zinterpretować ACF kwadratów reszt;
- 4 odróżnić problem modelu średniej od problemu modelu wariancji;
- 5 zastosować test Ljunga–Boxa z korektą $model_df=p+q$;
- 6 zastosować test ARCH-LM;
- 7 napisać poprawną interpretację diagnostyczną dla pogody i SPY.

Granica bloku

Nie budujemy jeszcze modelu GARCH. Pokazujemy, kiedy i dlaczego GARCH staje się potrzebny.

Przypomnienie Zadania 2: co dziś domykamy?

Minimalne produkty Zadania 2

- tabela AIC/BIC;
- wykresy ACF;
- pisemna odpowiedź na pytania diagnostyczne;
- interpretacja poprawności modelu.

Dzisiejszy wkład

Po dzisiejszym bloku student potrafi przygotować najważniejszą część raportu: ocenę, czy model ARMA jest wystarczający.

Najważniejsza zasada

Dobry AIC/BIC nie gwarantuje dobrych reszt.

Czym są reszty?

Definicja robocza

Jeżeli model przewiduje wartość $\hat{y}_t$, to reszta jest różnicą

$$\hat{u}_t = y_t - \hat{y}_t.$$

W modelu ARMA reszta jest przybliżeniem nieobserwowalnego szoku ε_t .

Intuicja

Reszty są tym, czego model nie wyjaśnił. Jeżeli w resztach nadal jest struktura, to model czegoś ważnego nie zauważył.

Pułapka

Nie wystarczy, że reszty „wyglądają losowo” na jednym wykresie. Trzeba sprawdzić zależność liniową i zależność w zmienności.

Co oznacza dobry model ARMA?

Idea białego szumu

Po poprawnym modelu średniej reszty powinny zachowywać się możliwie podobnie do białego szumu:

$$\mathbb{E}(\hat{u}_t) \approx 0, \quad \text{Corr}(\hat{u}_t, \hat{u}_{t-k}) \approx 0 \quad (k \geq 1).$$

Ale to nie wszystko

Nawet jeśli $\hat{u}_t$ nie są skorelowane, kwadraty $\hat{u}_t^2$ mogą być skorelowane. Wtedy średnia jest opisana, ale wariancja ma strukturę.

Slogan

Model dla średniej $\neq$ model dla wariancji.

Dwa pytania diagnostyczne

ACF reszt

Pytanie:

$$\text{Corr}(\hat{u}_t, \hat{u}_{t-k}) \approx 0?$$

Jeżeli nie, to model średniej jest niedostateczny.

ACF kwadratów reszt

Pytanie:

$$\text{Corr}(\hat{u}_t^2, \hat{u}_{t-k}^2) \approx 0?$$

Jeżeli nie, to wariancja jest strukturalna.

Interpretacja w jednym zdaniu

ACF reszt mówi o przewidywalności średniej, a ACF kwadratów reszt mówi o przewidywalności ryzyka lub wielkości błędu.

Dlaczego kwadraty reszt są ważne?

Prosta intuicja

Znak zwrotu SPY bywa trudny do przewidzenia. Ale wielkość ruchu może być przewidywalna:

- duże ruchy często grupują się po dużych ruchach;
- spokojne okresy często następują po spokojnych okresach;
- to jest klasterowanie zmienności.

Slogan finansowy


Średnia jest nieprzewidywalna, ale ryzyko jest.

Slogan obrazowy

Burza po burzy, cisza po ciszy.

Drzewo decyzyjne diagnostyki reszt

Drzewo decyzyjne diagnostyki reszt



Diagnostyka nie jest formalnością

Typowy błąd studenta

Student wybiera model o najniższym BIC, drukuje tabelę i kończy raport.

Poprawne myślenie

- 1 BIC wybiera kandydata.
- 2 Estymacja MLE daje parametry.
- 3 Diagnostyka reszt sprawdza, czy kandydat jest akceptowalny.
- 4 Jeżeli reszty mają strukturę, trzeba powiedzieć jaką i co to oznacza.

Morał

Najpierw diagnozujemy strukturę danych, potem wybieramy model, a na końcu sprawdzamy reszty.

ACF reszt — przypomnienie definicji

Autokorelacja reszt

Dla reszt $\hat{u}_t$ autokorelacja rzędu k mierzy zależność między resztą dzisiaj i resztą opóźnioną:

$$\hat{\rho}_k = \widehat{\text{Corr}}(\hat{u}_t, \hat{u}_{t-k}).$$

Interpretacja

Jeżeli $\hat{\rho}_k$ jest wyraźnie różne od zera, to błąd w chwili $t - k$ pomaga przewidywać błąd w chwili t .

Pułapka

Pojedynczy słaby pik nie zawsze dyskwalifikuje model. Seria systematycznych pików lub piki w naturalnych opóźnieniach sezonowych są dużo ważniejsze.

ACF kwadratów reszt — o co pytamy?

Autokorelacja kwadratów

Dla kwadratów reszt sprawdzamy

$$\widehat{\text{Corr}}(\hat{u}_t^2, \hat{u}_{t-k}^2).$$

To jest pytanie o zależność w wielkości odchyłeń, a nie w ich znaku.

Przykład intuicyjny

Jeżeli po dużym błędzie często pojawia się duży błąd, to $\hat{u}_t^2$ będzie dodatnio skorelowane z $\hat{u}_{t-1}^2$.

Wniosek modelowy

Istotna ACF kwadratów reszt sugeruje ARCH/GARCH, czyli modelowanie wariancji warunkowej.

Jak czytać słupki ACF?

Zasada praktyczna

Na wykresie ACF zwykle widzimy przedziały około

$$\pm \frac{1.96}{\sqrt{T}}.$$

Słupki poza tym pasmem są sygnałem potencjalnej autokorelacji.


Uwaga o dużym T

Dla bardzo dużych prób, np. pogody godzinowej, pasma są bardzo wąskie. Wtedy nawet małe zależności mogą być statystycznie istotne.

Dlatego patrzymy na dwa aspekty

- istotność statystyczną: czy pik wychodzi poza pasmo?
- rozmiar efektu: czy pik jest praktycznie duży?


Pogoda: reszty po harmonikach i ARMA(2,1)



Komentarz

Reszty są już znacznie bardziej lokalne niż surowa temperatura, ale nadal mogą mieć strukturę związaną z pogodą, frontami atmosferycznymi i nie w pełni uchwyconą sezonowością.


Pogoda: ACF reszt po ARMA(2,1)



Interpretacja dydaktyczna

Dla danych pogodowych nawet po harmonikach i ARMA mogą zostać zależności. To nie jest zaskoczenie: temperatura ma pamięć fizyczną i sezonowość nie jest idealnie stała.


Pogoda: ACF kwadratów reszt



Wniosek

Struktura w kwadratach reszt może oznaczać sezonową lub pogodową heteroskedastyczność: nie w każdym okresie roku i nie w każdej sytuacji meteorologicznej błędy mają tę samą wariancję.


Pogoda: krocząca zmienność reszt



Komentarz

Krocząca zmienność pomaga zobaczyć coś, czego zwykły wykres reszt nie pokazuje jasno: okresy większej i mniejszej niepewności modelu.


SPY: log-zwroty dzienne



Pierwsza obserwacja

Nie widać stabilnej sezonowości średniej jak w temperaturze. Widać natomiast okresy spokojne i okresy gwałtownych ruchów.


SPY: ACF reszt modelu ARMA(0,0)



Wniosek dla średniej

ACF reszt jest stosunkowo słaba. To wspiera interpretację, że prosty model średniej może być wystarczający dla log-zwrotów SPY w tej próbie.


SPY: ACF kwadratów reszt



Najważniejszy sygnał bloku

Kwadraty reszt mają silną strukturę. To oznacza, że model średniej może być OK, ale model stałej wariancji nie jest OK.

SPY: krocząca zmienność



Interpretacja

Ten wykres tłumaczy, dlaczego ACF kwadratów reszt jest ważna. Zmienność SPY nie jest stała: są okresy większego i mniejszego ryzyka.

Po co test Ljunga–Boxa?

Problem

Na wykresie ACF widzimy wiele opóźnień. Chcemy zadać pytanie zbiorcze:

Czy pierwsze h autokorelacji jest łącznie równe zero?

Hipotezy

$H_0 : \rho_1 = \rho_2 = \dots = \rho_h = 0, \quad H_1 : \text{co najmniej jedna z nich jest różna od zera.}$

Interpretacja

Ljung–Box nie wskazuje, który lag jest problemem. Mówi, czy autokorelacja jako grupa jest problemem.

Wzór

Dla próby długości T i opóźnienia h :

$$Q(h) = T(T + 2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{T - k}.$$

Przy H_0 statystyka ma przybliżony rozkład χ^2 .

Korekta stopni swobody

Jeżeli testujemy reszty po modelu $\text{ARMA}(p, q)$, używamy korekty:

$$\text{model_df} = p + q.$$

W praktyce porównujemy z rozkładem χ_{h-p-q}^2 .

Dlaczego `model_df=p+q` jest ważne?

Pułapka

Wywołanie testu Ljunga–Boxa bez `model_df` może dać zbyt optymistyczną lub niespójną interpretację reszt po modelu ARMA.

Intuicja

Parametry ARMA zostały dobrane tak, aby częściowo wyjaśnić autokorelację. Test powinien uwzględnić, że część stopni swobody zużyliśmy na estymację modelu.

Reguła do Zadania 2

Dla ARMA(2, 1) wpisujemy `model_df=3`; dla ARMA(2, 2) wpisujemy `model_df=4`; dla ARMA(0, 0) wpisujemy `model_df=0`.

Kod Python: Ljung–Box na resztach

```
from statsmodels.stats.diagnostic import
    acorr_ljungbox

# residuals: reszty po dopasowanym modelu ARMA(p,q)
# p, q: rzędy modelu
lb = acorr_ljungbox(
    residuals,
    lags=[10, 20],
    model_df=p + q,
    return_df=True
)
print(lb)
```

Komentarz

W raporcie nie wystarczy wkleić tabeli. Trzeba napisać, czy wynik wskazuje na pozostawioną autokorelację reszt.

Ljung–Box: jak czytać wynik?

Reguła praktyczna

- duże p -value: brak mocnych podstaw do odrzucenia hipotezy braku autokorelacji;
- małe p -value: reszty mają autokorelację do rzędu h .

Uwaga przy bardzo dużym T

W próbie godzinowej $T \approx 26304$ nawet małe zależności mogą dać ekstremalnie małe p -value. Dlatego interpretujemy wynik razem z wykresem ACF i skalą efektu.

Dobre zdanie do raportu

„Test wskazuje na statystyczną istotność autokorelacji, jednak z uwagi na bardzo dużą próbę oceniono również wykres ACF i praktyczny rozmiar pików.”

Efekt ARCH: intuicja

Co oznacza ARCH?

ARCH oznacza, że wariancja błędu w chwili t zależy od wcześniejszych kwadratów błędów.

Najprostszy schemat


$$\varepsilon_t = \sigma_t z_t, \quad \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2.$$

Jeżeli wczoraj był duży szok, dzisiejsza wariancja może być większa.

Slogan

Burza po burzy, cisza po ciszy.


Symulacja ARCH(1)



Interpretacja

Średnia może być bliska zera, ale rozrzut nie jest stały. Widać klastry dużej i małej zmienności.

Symulacja ARCH(1): ACF kwadratów



Wniosek

W szeregu ARCH zwykła ACF może być niewielka, ale ACF kwadratów jest dodatnia. To jest wzorec, którego szukamy w SPY.

Test ARCH-LM

Regresja pomocnicza

Dla reszt $\hat{u}_t$ estymujemy regresję:

$$\hat{u}_t^2 = \alpha_0 + \alpha_1 \hat{u}_{t-1}^2 + \cdots + \alpha_q \hat{u}_{t-q}^2 + v_t.$$

Statystyka LM

$$LM = TR^2.$$

Przy hipotezie braku efektu ARCH statystyka ma w przybliżeniu rozkład χ_q^2 .

Interpretacja

Małe p -value oznacza: wcześniejsze kwadraty reszt pomagają wyjaśniać obecne kwadraty reszt.

Kod Python: ARCH-LM

```
from statsmodels.stats.diagnostic import het_arch

# residuals: reszty po modelu średniej
arch_lm = het_arch(residuals, nlags=10)

lm_stat = arch_lm[0]
lm_pvalue = arch_lm[1]
f_stat = arch_lm[2]
f_pvalue = arch_lm[3]

print(lm_stat, lm_pvalue)
```

Komentarz

Dla danych dziennych SPY typowo używamy np. 5, 10 albo 20 opóźnień. W raporcie trzeba napisać, ile opóźnień wybrano.

ARCH-LM a Ljung–Box na kwadratach

Ljung–Box na $\hat{u}_t^2$

Sprawdza łączną autokorelację kwadratów reszt do rzędu h .

ARCH-LM

Estymuje regresję pomocniczą kwadratów reszt na ich opóźnieniach.

Jak używać w Zadaniu 2?

ACF kwadratów daje obraz, Ljung–Box na kwadratach daje test pomocniczy, a ARCH-LM jest formalnym testem efektu ARCH.

Pułapka

Nie zastępuj ARCH-LM samym wykresem ACF kwadratów, jeśli w zadaniu jest wymagana formalna diagnostyka efektu ARCH.

Tabela diagnostyczna: dane referencyjne

Dane	Test	Statystyka	p -value
Pogoda	Ljung–Box reszty, $h = 10$	51664.35	< 0.0001
Pogoda	Ljung–Box $\hat{u}^2$, $h = 10$	30725.93	< 0.0001
Pogoda	ARCH-LM, 24 opóźnień	18919.58	< 0.0001
SPY	Ljung–Box reszty, $h = 10$	15.26	0.1228
SPY	Ljung–Box $\hat{u}^2$, $h = 10$	174.82	< 0.0001
SPY	ARCH-LM, 10 opóźnień	132.36	< 0.0001

Uwaga techniczna

Wartości są referencyjne dla załączonych danych i przyjętej procedury. W raporcie studenta dopuszczalne są niewielkie różnice wynikające z wersji bibliotek, filtracji braków danych lub wariantu estymacji.

Komentarz do pogody

Wniosek główny

Model harmoniczny plus ARMA jest dobrym pierwszym przybliżeniem dynamiki temperatury, ale nie usuwa całej struktury z reszt.

Jak to opisać?

- ACF reszt może nadal wskazywać zależności, zwłaszcza przy dużej liczbie obserwacji.
- ACF kwadratów reszt może sugerować zmienność warunkową lub sezonową heteroskedastyczność.
- Wniosek nie brzmi: „model jest bezużyteczny”.
- Wniosek brzmi: „model jest sensownym pierwszym etapem, ale nie opisuje wszystkich aspektów procesu pogodowego”.

Komentarz do SPY

Wniosek główny

Dla SPY prosty model średniej, np. $ARMA(0, 0)$ według BIC, może być wystarczający dla średniej log-zwrotów, ale nie dla wariancji.

Jak to opisać?

- ACF reszt jest relatywnie słaba: średnia nie ma wyraźnej liniowej przewidywalności.
- ACF kwadratów reszt jest silna: zmienność grupuje się w czasie.
- ARCH-LM odrzuca hipotezę braku efektu ARCH.

Najważniejsze zdanie

SPY nie jest po prostu „losowy”: średnia jest bliska białemu szumowi, ale wariancja ma strukturę.

Q-Q plot: rozszerzenie diagnostyki

Po co Q-Q plot?

Q-Q plot porównuje rozkład reszt z rozkładem normalnym. Jest szczególnie użyteczny do wykrywania grubych ogonów i obserwacji ekstremalnych.


W Zadaniu 2

Q-Q plot jest rozszerzeniem, nie głównym wymaganiem. Główne wymaganie to ACF reszt, ACF kwadratów, Ljung–Box i ARCH-LM.

Pułapka

Nienormalność reszt nie jest tym samym co autokorelacja reszt. To dwa różne problemy diagnostyczne.


Pogoda: Q-Q plot reszt



Komentarz

Odstępstwa od prostej mogą wynikać z ekstremalnych zjawisk pogodowych, niedoskonałego odsezonowania i zmiennej wariancji.

SPY: Q-Q plot reszt



Komentarz

Dane finansowe często mają grubsze ogony niż rozkład normalny. To dodatkowo motywuje ostrożność w modelowaniu ryzyka.

Cztery możliwe sytuacje diagnostyczne

ACF reszt	ACF kwadratów reszt	Interpretacja
OK	OK	Model średniej i wariancji jako pierwsze przybliżenie jest akceptowalny.
Problem	OK	Trzeba poprawić model średniej: sezonowość, ARMA, transformacja.
OK	Problem	Średnia opisana, ale wariancja strukturalna: kandydat do GARCH.
Problem	Problem	Potrzebny bogatszy model, np. ARMA-GARCH albo poprawa sezonowości.

Najczęstszy przypadek SPY

ACF reszt relatywnie OK, ACF kwadratów problematyczna. To klasyczny mostek do GARCH.

Pułapka 1: tylko ACF reszt

Błędne postępowanie

Student rysuje ACF reszt, widzi małe słupki i pisze: „model jest dobry”.

Poprawka

Trzeba narysować również ACF kwadratów reszt. W finansach właśnie tam często widać najważniejszą strukturę.

Zdanie do zapamiętania

Brak autokorelacji zwrotów nie oznacza braku autokorelacji ryzyka.

Pułapka 2: `acorr_ljungbox` bez `model_df`

Błąd techniczny

Dla reszt po $\text{ARMA}(p, q)$ student wywołuje test Ljunga–Boxa tak, jakby żadnych parametrów ARMA nie estymowano.

Poprawka

Dla reszt po $\text{ARMA}(p, q)$ stosujemy:

$$\text{model_df} = p + q.$$

Uwaga

To jest szczególnie ważne, gdy liczba lagów testu jest mała względem liczby parametrów modelu.

Pułapka 3: „ $p < 0,05$, więc model zły”

Problem

W dużych próbach testy mają ogromną moc. Potrafią wykryć bardzo małe odchylenia od ideału.

Poprawne podejście

- sprawdzamy wykresy ACF;
- patrzymy na rozmiar autokorelacji;
- pytamy, czy problem ma znaczenie praktyczne;
- opisujemy ograniczenia modelu, zamiast wydawać prosty wyrok.

Szczególnie dla pogody

Przy $T \approx 26304$ formalne testy mogą odrzucać nawet wtedy, gdy model dydaktycznie dobrze pokazuje główną strukturę.

Pułapka 4: „SPY jest losowy”

Zbyt mocne zdanie

„SPY jest losowy, bo ACF log-zwrotów jest bliska zeru.”

Lepsze zdanie

„W tej próbie średnia log-zwrotów SPY nie wykazuje silnej liniowej autokorelacji, ale kwadraty reszt i test ARCH-LM wskazują na strukturę wariancji.”

Wersja bardzo krótka

Średnia bliska białemu szumowi, wariancja nie.

Pułapka 5: mylenie sezonowości i ARCH

Sezonowość

Powtarzalność związana z kalendarzem: doba, rok, tydzień handlowy.

ARCH

Zależność obecnej zmienności od wcześniejszych szoków: duże po dużych, małe po małych.

Uwaga

W pogodzie sezonowa heteroskedastyczność i zależności reszt mogą się mieszać. Dlatego interpretacja wymaga zdrowego rozsądku, a nie samego p -value.

Szablon interpretacji: ACF reszt

Wersja wzorcowa

„Wykres ACF reszt pokazuje, czy po dopasowaniu modelu pozostała liniowa zależność czasowa. Jeżeli większość słupków mieści się w pasmach ufności i brak regularnego wzorca, to model średniej można uznać za akceptowalny jako pierwsze przybliżenie. Jeżeli widoczne są systematyczne piki, należy rozważyć poprawę modelu średniej.”

Jak dostosować?

Dopisz nazwę danych, rząd modelu, najważniejsze lągi i wniosek: „średnia OK” albo „średnia wymaga poprawy”.

Szablon interpretacji: ACF kwadratów reszt

Wersja wzorcowa

„ACF kwadratów reszt sprawdza, czy wielkość błędów jest zależna w czasie. Istotne dodatnie autokorelacje kwadratów reszt wskazują, że wariancja nie jest stała i może zależeć od poprzednich szoków. W takim przypadku model ARMA opisuje co najwyżej średnią, natomiast do wariancji potrzebny jest model typu ARCH/GARCH.”

Najczęstsze zastosowanie

To zdanie jest szczególnie ważne dla SPY.

Szablon interpretacji: Ljung–Box

Wersja wzorcowa

„Test Ljunga–Boxa dla reszt do opóźnienia h służy do zbiorczego sprawdzenia, czy pierwsze autokorelacje reszt są równe zero. W obliczeniach uwzględniono korektę stopni swobody $\text{model_df}=p+q$. Małe p -value wskazuje na pozostawioną autokorelację reszt, natomiast duże p -value nie daje podstaw do odrzucenia hipotezy o braku autokorelacji.”

Nie pisz

„Test Ljunga–Boxa dowodzi, że model jest dobry.” Test nie dowodzi dobroci modelu. On tylko nie znalazł określonego problemu.

Szablon interpretacji: ARCH-LM

Wersja wzorcowa

„Test ARCH-LM sprawdza, czy kwadraty reszt można wyjaśnić ich opóźnieniami. Odrzucenie hipotezy zerowej oznacza obecność efektu ARCH, czyli zależności w wariancji warunkowej. W takim przypadku model ARMA nie wystarcza do pełnego opisu ryzyka i naturalnym rozszerzeniem jest model GARCH.”

Dla SPY

To jest główny mostek do Zadania B: prognozowania i modelowania zmienności.

Gotowy akapit: pogoda

Przykładowy tekst do raportu

„Dla temperatury w Olsztynie najpierw usunięto główne składowe sezonowe za pomocą regresji harmonicznej, a następnie dopasowano model ARMA do reszt. Diagnostyka reszt wskazuje, że model uchwycił istotną część struktury średniej, ale w resztach mogą pozostawać zależności czasowe i zależności w kwadratach reszt. W danych godzinowych, przy bardzo dużej liczbie obserwacji, formalne testy są bardzo czułe, dlatego wyniki testów należy interpretować łącznie z wykresami ACF i rozmiarem efektów.”

Gotowy akapit: SPY

Przykładowy tekst do raportu

„Dla log-zwrotów SPY model średniej wybrany przez BIC jest bardzo prosty. Diagnostyka ACF reszt nie wskazuje na silną liniową przewidywalność średniej. Jednocześnie ACF kwadratów reszt oraz test ARCH-LM wskazują na wyraźną strukturę wariancji. Oznacza to, że model ARMA może być wystarczający jako model średniej, ale nie opisuje zmienności. Naturalnym rozszerzeniem jest model GARCH.”

Kod: kompletna funkcja diagnostyczna

```
from statsmodels.stats.diagnostic import
    acorr_ljungbox, het_arch
from statsmodels.graphics.tsaplots import plot_acf
import matplotlib.pyplot as plt

def residual_diagnostics(residuals, p=0, q=0, lags
    =20, arch_lags=10):
    fig, ax = plt.subplots()
    plot_acf(residuals, lags=lags, ax=ax, zero=False)
    ax.set_title("ACF reszt")
    plt.show()

    fig, ax = plt.subplots()
    plot_acf(residuals**2, lags=lags, ax=ax, zero=False
    )
    ax.set_title("ACF kwadratow reszt")
    plt.show()

    lb = acorr_ljungbox(residuals, lags=[lags],
    model_df=p+q, return_df=True)
```

Kod: interpretacja wyniku ARCH-LM

```
lb, arch = residual_diagnostics(resid, p=0, q=0,
                                lags=20, arch_lags=10)

lm_stat, lm_pvalue = arch[0], arch[1]

if lm_pvalue < 0.05:
    print("Wykryto efekt ARCH: wariancja wymaga
          modelowania.")
else:
    print("Brak mocnych podstaw do stwierdzenia efektu
          ARCH.")
```

Uwaga dydaktyczna

Automatyczny komunikat nie zastępuje raportu. Student musi odnieść wynik do wykresów i sensu danych.

Kod: minimalny fragment do Zadania 2 dla SPY

```
spy = df[df["Ticker"] == "SPY"].copy()
y = spy["Log_Return"].dropna()

# BIC wskazał ARMA(0,0): reszty to odchylenia od ś
#   redniej
resid = y - y.mean()

lb = acorr_ljungbox(resid, lags=[10, 20],
model_df=0, return_df=True)
lb_sq = acorr_ljungbox(resid**2, lags=[10, 20],
model_df=0, return_df=True)
arch = het_arch(resid, nlags=10)

print(lb)
print(lb_sq)
print("ARCH-LM:", arch[0], arch[1])
```


Kod: minimalny fragment do Zadania 2 dla pogody

```
# Po regresji harmonicznej mamy harmonic_resid
# Po ARMA(p,q) mamy arma_resid

p, q = 2, 1 # przykład: model referencyjny z cyklu
resid = arma_resid

lb = acorr_ljungbox(resid, lags=[24, 48],
model_df=p+q, return_df=True)
lb_sq = acorr_ljungbox(resid**2, lags=[24, 48],
model_df=0, return_df=True)
arch = het_arch(resid, nlags=24)

print(lb)
print(lb_sq)
print("ARCH-LM:", arch[0], arch[1])
```

Dlaczego 24 i 48?

W danych godzinowych naturalne są opóźnienia dobowe i dwudobowe. Nie jest to jedyny możliwy wybór, ale jest sensownie uzasadniony.

Co student ma umieć po bloku 5?

- 1 Narysować ACF reszt i powiedzieć, czy model średniej zostawił autokorelację.
- 2 Narysować ACF kwadratów reszt i powiedzieć, czy wariancja ma strukturę.
- 3 Wykonać test Ljunga–Boxa z właściwym `model_df`.
- 4 Wykonać test ARCH-LM.
- 5 Napisać interpretację: osobno dla średniej i osobno dla wariancji.

Najważniejszy morał

**ARMA odpowiada głównie za średnią.
GARCH będzie odpowiadał za wariancję.**

Lista kontrolna do Zadania 2 w zakresie badania reszt

Diagnostyka reszt — minimum

- Czy pokazano ACF reszt?
- Czy pokazano ACF kwadratów reszt?
- Czy wykonano Ljung–Box dla reszt?
- Czy przy Ljung–Box uwzględniono $\text{model_df}=p+q$?
- Czy wykonano ARCH-LM?
- Czy interpretacja odróżnia średnią od wariancji?

Najczęstszy brak

Brak ACF kwadratów reszt i brak ARCH-LM. To poważny brak w Zadaniu 2.

Od słabej stacjonarności do ARMA

Modele AR, MA oraz ich połączenie w ARMA na przykładzie temperatury w Olsztynie

Dr hab. Andrzej Jankowski, Profesor UWM

Modelowanie szeregów czasowych

25 maj, 2025

Cel: przypomnieć ideę modeli AR / MA / ARMA i pokazać, dlaczego ich połączenie jest naturalne.

Pokazać szkic przykładowego rozwiązania zadania 2